自然语言处理

绪论

杨沐昀

哈尔滨工业大学计算学部
语言技术研究中心

yangmuyun@hit.edu.cn

课程信息

- 学时：48 （32授课+16实验）
- 上课时间及地点
  - 授课：2 学时 x16 次（第1-9 周，周二5-6节、周四3-4节，地点：.....）
  - 实验：4 学时 x 4 次（第6-9 周，周四/五9-12节，地点：格物楼 207,213）
- 成绩构成:
  - 实验：40%
  - 期末考试：60%

课程参考书 (1)

- 《自然语言处理》
  - 出版社：高等教育出版社
  - 主审 郑南宁
  - 编著 王海峰 杨沐昀 黄河燕 宗成庆 黄萱菁
  - 出版时间：2025.9
  - 人工智能“101计划”核心课程教材

课程参考书(2)

- 《自然语言处理：基于大语言模型的方法》
  - 出版社：电子工业出版社
  - 作者：车万翔，郭江，崔一鸣
  - 书号：ISBN 9787121415128
  - 出版时间：2025.2



课程内容

序号	教学内容	学时
1	**绪论** 基本概念；研究内容；发展历史；技术现状与挑战；	2
2	**自然语言处理基础I理论** 信息论、机器学习	2
3	**自然语言处理的统计建模及经典技术** 统计语言模型；自然语言处理经典技术；自然语言处理典型应用；	4
4	**自然语言处理中的深度学习基础** 神经网络基础；前馈神经网络；卷积神经网络；循环神经网络；Transformer	4
5	**自然语言处理技术评价** 概述；自然语言理解评价；自然语言生成评价；	2
6	**词向量及神经语言模型** 语言的向量表示；神经语言模型；预训练语言模型	3
7	**大语言模型的预训练** 模模型架构：分布式训练；预训练数据；	3
8	**大语言模型的有监督精调** 提示学习与上下文学习；有监督微调的基本原理；指令数据构建；微调策略；	2

课程内容(续)

序号	教学内容	学时
9	**大语言模型的强化学习** 基于人类反馈的强化学习；奖励模型；	2
10	**大语言模型的知识增强** 知识与知识图谱；知识抽取；知识增强的大语言模型；	2
11	**大语言模型的推理和部署** 算力基础；推理部署框架；模型压缩技术；	2
12	**大语言模型的应用场景适配** 提示工程；检索增强；基于大语言模型智能体；	2
13	**自然语言处理的前沿及趋势文本分类与情感分析** 发展前沿；低资源、多模态等；	2
14	**实验1：情感分析** 文本分类与聚类；情感分析方法；	1+3
15	**基于Transformer的机器翻译系统** 机器翻译的概况、训练基于Transformer的神经机器翻译模型、性能评价。	2+4
16	**类ChatGPT通用对话系统** 微调基础模型，实现对话功能，并给出评价结果	2+4

课程答疑

- 课程群
  - 哈工大app：10032164631142817 96
  - 群名： 自然语言处理C(2026-2027|秋季
  - 课件会上传到群里
  - 助教.....

自然语言处理C(2026-2027|秋季)
ID: 10032164631142817 96

WeLink扫一扫，立即加入

主要内容

- 自然语言处理概述
- 自然语言处理研究内容
- 自然语言处理发展历史
- 自然语言处理未来展望

语言是什么：进化的观点

补充材料

- 语言可能至是关键的进化优势
  - 尼人 vs 智人
  - 尼人（13万到3万年前）
    - 发达的大脑，脑量达 1300毫升
    - 制造比较精致的工具，会人工取火
    - 会埋葬同伴，而且用石器陪葬
  - 7万年前，智人走上人类舞台，尼人失踪成谜！
- 有研究发现：尼人声道像猩猩和婴儿一样，发音能力十分有限
  - 语言的协同也许是其中的一个因素，人类的深化传说中都有语言魔力的元素

语言是什么：文明的脉络

补充材料

- 中国：汉朝时产生了小学---传统语文学
  - 包括文字、音韵和训诂学
  - 文字学：《说文解字》（汉） …《康熙字典》 （清）
  - 音韵学：研究古汉语各时期声、韵、调系统及发展规律
    - 《切韵》 陆法言（隋）
  - 训诂学：研究古汉语词义；《尔雅》（汉或战国末）
- 印度：4~3 B.C.，出现了梵语语法
  - 形态：将词分成词干和词尾
  - 词类：名词、动词、介词、小品词
  - 语音：区分元音和辅音以及音节等

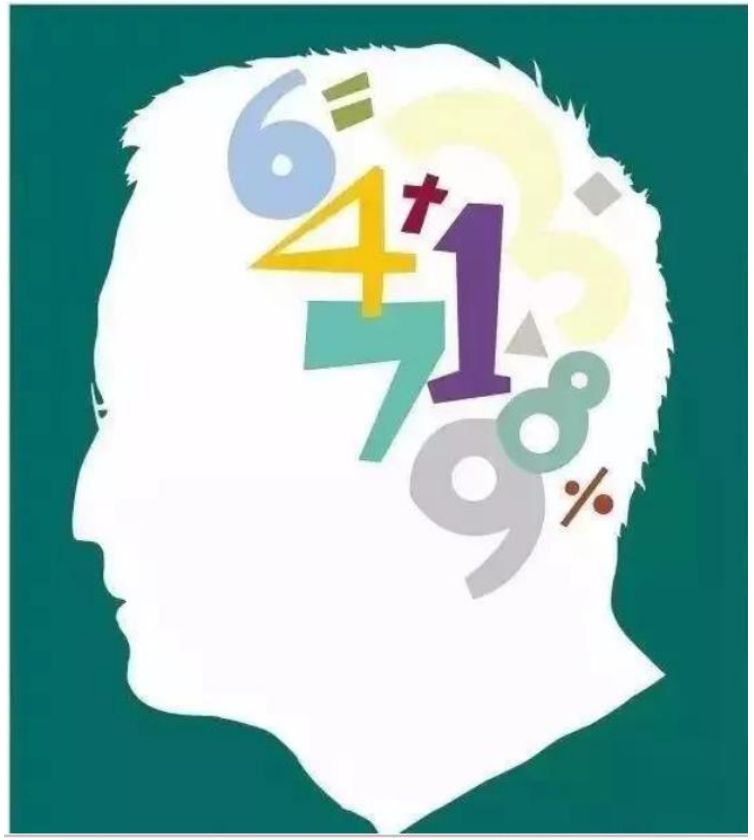
语言：文明的脉络

补充材料

- 古希腊：关于语言问题的两场论战
  - 第一场在“自然发生派”和“约定俗成派”之间展开，焦点集中在语言的形式与意义之间的关系上。
  - 第二场在“变则派”和“类推派”之间展开，焦点集中在语法结构是否规则这一问题上。
- 古罗马
  - 当时最著名的语法学家瓦罗的语法巨著《论拉丁语》（《拉丁语研究》），被认为是研究拉丁语的权威性著作
    - 区别了屈折形式和派生形式
    - 详细考察了拉丁语的性、数、格体系和结构功能

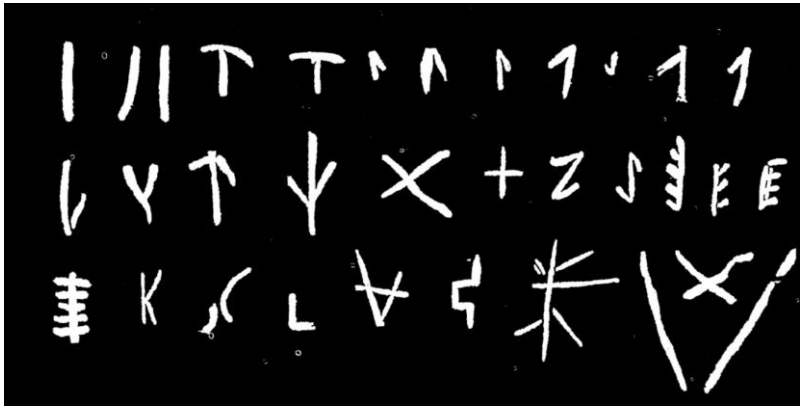
语言的特征

- 语言是什么
  - 语言是人类特有的音义结合的符号系统，具有交际和思维双重功能，由语音、词汇和语法构成层级体系，其核心特征包括社会性、系统性和创造性。
  - 语言是人类区别于其它生物最重要的特征之一，是人类思维的载体和沟通交流的工具。
- 语言的基本性质
  - 符号性
  - 系统性
  - 动态性



语言的特征

- 语言是符号性的
  - 人们用符号来代指现实中的事物、行为、状态等，形成共同理解的“语言符号”；
  - 这些符号不仅指向具体的事物，也能表达抽象的概念，使得人类能够沟通复杂的情感和思想



语言的特征

- 语言是系统性的
  - 语言并非随意组合的符号集合，而是一套有规则的符号系统；
  - 这些规则——通常称为语法——赋予了语言连贯性和稳定性，使得符号的排列、组合可以传递准确的含义；

语言的特征

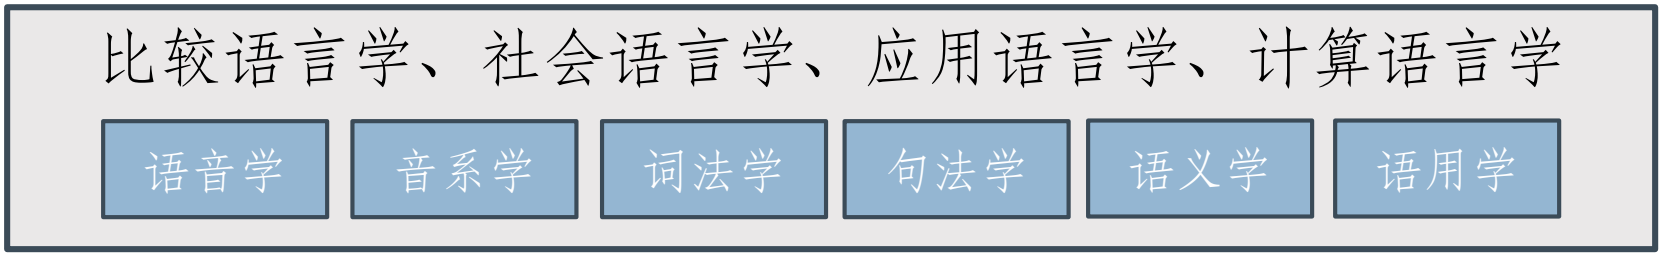
- 语言是动态发展的
  - 随着历史进程和社会变迁，语言的词汇、语法、语音不断演变，以适应新的需求和表达。

- 孙子：我对这个八卦不感兴趣，只是路过打酱油的。
- 奶奶：家里酱油还够用啊，不用去打，另外你怎么研究起来八卦了？

语言学的研究对象

- 语言学的研究对象可以概括为语言如何构成、如何使用、如何理解及其在社会中的作用

- 具体来说，语言学包括语音学、语法学、语义学、语用学等



- 语言学的各个分支互相补充、相互联系，共同揭示了语言这一复杂系统的多面性！

语言学的研究对象

- 语音学：研究语言的声音系统。它涉及语音的产生机制、声学特性以及分类方式。
  - 聚焦人类语音的物理、生理属性，典型的成果如国际音标

- 音系学：研究音位划分、组合规则及语音与语法互动等维度，注重语音结构规律及其历史演变
  - 聚焦语音的功能属性，典型应用“汉语拼音方案”

语言学的研究对象

- 语法学：关注的是语言的结构规则，研究词语和句子的构造方式，以及如何遵循规则形成符合语法的句子。

- 通常认为语法学包括句法学和词法（有称形态）学两部分，前者探讨单词如何组合成句子（即句法规则），后者则关注词形的构造（如词根、词缀、词的变化形式等）。

- 语法的研究不仅有助于语言学家理解不同语言表达方式的差异，也为语言学习和教学提供了科学的理论指导。

语言学的研究对象

- 语义学：研究的重点是语言的意义。这不仅包括词语的含义，还涉及句子的整体意义以及更复杂的语境含义。

- 语义学家探索词汇的语义范畴、词义的模糊性、歧义性等问题，并研究如何通过语言表达不同层次的含义。

- 例如，“语义场”理论通过分析词汇的相对关系来揭示不同词汇在特定文化或语境中的意义。

语言学的研究对象

- 语用学：关注语言的实际使用方式，即语言在不同情境下的变通和适应。
- 语用学家考察说话者和听话者之间的互动如何影响表达和理解，包括礼貌原则、言语行为理论、会话含义等。
- 例如，同一句话在不同场合中的含义可能截然不同，这种含义的变动反映了语用学的核心研究内容——语言如何随着情境的变化而调整。

自然语言处理

- 区别于具有严格形式的人造语言（如编程语言），人类生产生活中所使用的语言被称为自然语言，例如汉语、英语等。







- 研究让计算机理解并运用自然语言的理论和方法就是自然语言处理（Natural Language Processing, NLP）
  - 传统上处理的对象是文本

自然语言处理

- 自然语言处理vs语音识别
  - 人类语言除了书写符号以外，还有一种基本形式是语音，相关研究通常被归为语音技术。
  - 语音是人类发出的一种声音信号，有别于其它的声音信号，在声音之上还承载着语言。
  - 语音技术与自然语言处理技术密切相关，比如在语音识别中，语言模型是不可或缺的组成部分。



人工智能为什么选择研究语言

补充材料

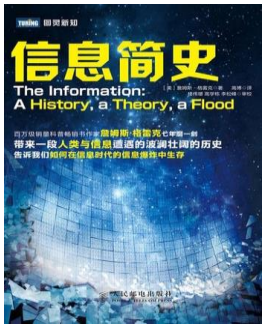
语言是客观信息、主观意志、思维逻辑的多维综合体

要求强大的概念抽象和信息推理能力，是多模态信息深度融合和推理的基础。



“语言不仅是描述现实的工具，更是我们思考和应对问题的方式”

——路德维希•维特根斯坦



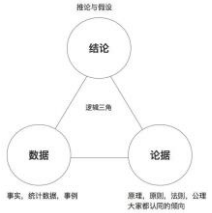
“语言本身就是人类有史以来最大的技术发明”

——詹姆斯•格雷克《信息简史》

语言本身就是对真实多模态世界加工、凝练、抽象后，赋予人类意识和逻辑思维的符号化。







那个苹果，看起来有点坏了，味道也不对，千万别吃，吃了你会拉肚子的。

领域共识

补充材料

“人工智能皇冠上的明珠”

- 自然语言处理成为**制约人工智能取得更大突破和更广泛应用的瓶颈**



“深度学习的下一个前沿课题是自然语言理解”

Yann LeCun
图灵奖得主、Facebook AI 负责人



“深度学习的下一个大的进展应该是让神经网络真正理解文档的内容”

Geoffrey Hinton
图灵奖得主、深度学习之父



“如果给我10亿美金，我会用这10亿美金建造一个NASA级别的自然语言处理研究项目”

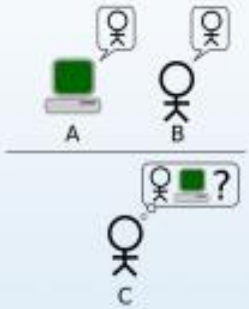
Michael I. Jordan
美国双院院士、世界知名机器学习专家



“下一个十年，懂语言者得天下”

沈向洋
美国工程院院士、微软前全球执行副总裁





图灵测试

国家定位

补充材料



国务院 《新一代人工智能发展规划》，2017

国家自然科学基金申请代码：信息学部

自然语言处理的层面

- 自然语言处理研究可以分为五个层面：
  - 符号层面：文字、语音等的输入;
  - 词法层面：分词、词性标注、命名实体识别;
  - 句法层面：短语结构分析、成分句法分析、依存关系分析等;
  - 语义层面：语义角色标注、指代消解、语义匹配等;
  - 语用层面：语言成分与上下文语境之间、字面含义与内在含义之间的相互关系等研究。

自然语言处理的挑战

- 由于自然语言的特性，自然语言处理面临很多挑战：
  - 歧义性与上下文依赖
  - 隐含信息与常识知识
  - 多样性与演变性
  - 低资源语言处理
  - 跨模态理解

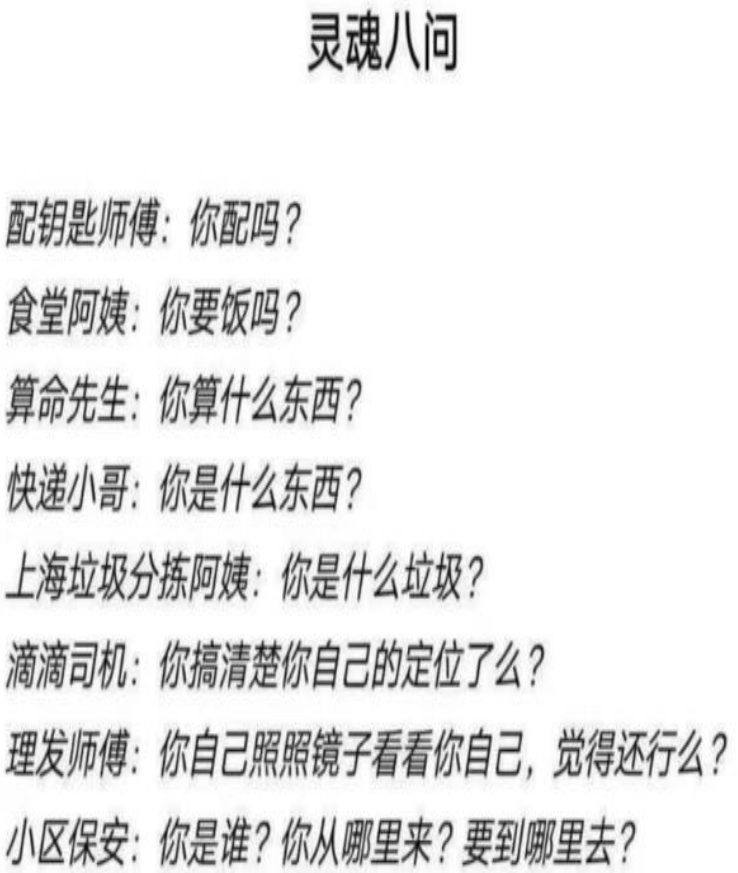
自然语言处理的挑战

- 歧义性与上下文依赖
  - 自然语言具有出高度的离散化和组合性，几千个字符通过多种方式组合，就可以表达无穷无尽的内容，导致自然语言普遍存在歧义性。
  - 语言的歧义性要求计算机不仅要理解句子内部的上下文，还要能够结合篇章、对话甚至更广泛的知识背景，才能准确把握语言的语用含义。

• 南京/市长/江大桥	南京市/长江/大桥
• 咬坏/孩子/的/狗	咬/坏孩子/的/狗

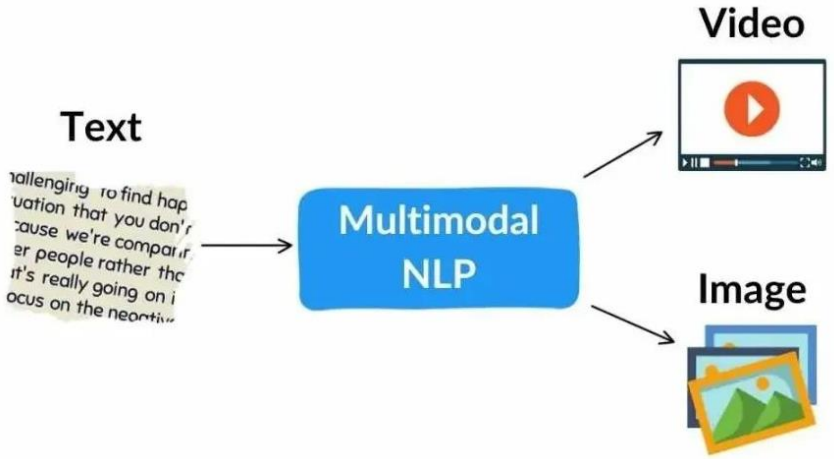
自然语言处理的挑战

- 隐含信息与常识
  - 为了提高信息传递的效率，人类在语言表达中常常省略显而易见的常识内容，而这些常识对于理解语言的深层含义至关重要。
  - 常识涵盖了世界的运行规律、因果关系、以及人们的思维方式等方方面面。让计算机具备常识难度极大。



自然语言处理的挑战

- 跨模态理解
  - 人类语言通常与其他模态（如图像、视频、音频）相结合，形成多模态的理解与表达方式。
  - 跨模态理解的核心挑战在于如何将不同模态的信息对齐和融合，以实现更全面的语义理解。

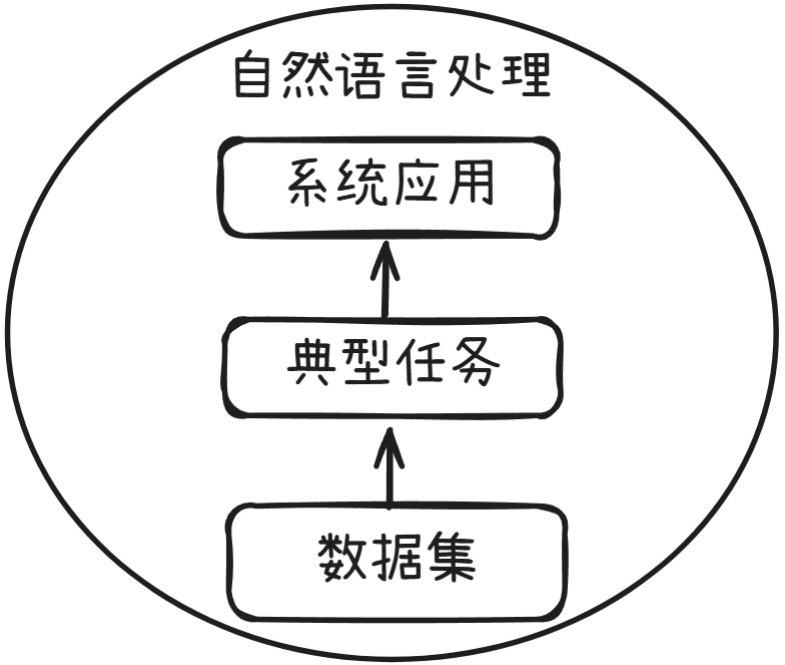


主要内容

- 自然语言处理概述
- 自然语言处理研究内容
- 自然语言处理发展历史
- 自然语言处理未来展望

自然语言处理研究内容

- 自然语言处理（NLP）是一个多维度的研究领域
  - 数据集
  - 典型任务
  - 系统应用



研究内容：数据集

- 数据集提供了丰富的训练语料和评估数据，也提供了理解自然语言多样性的宝贵资源

- 常见数据集类型：

1. 通用数据集
2. 专用领域数据集
3. 对话数据集
4. 平行数据集



思考：这里存在几个划分维度，有没有更好的梳理方法

研究内容：数据集

- 通用数据集
  - 通用数据集主要用于构建广泛适用的语言模型，通常涵盖新闻报道、百科全书条目、社交媒体帖子等多样化的文本类型。
  - 例如，Wikipedia和Common Crawl[1]提供了大规模、领域广泛的文本数据，它们不局限于任何特定领域，而是力求在数据的多样性和全面性上满足模型训练的需求。



研究内容：数据集

- 专用领域数据集
  - 专用领域数据集为支持特定领域的NLP应用而构建，例如医学、法律、金融等。
  - 构建这类数据集时，需特定来源的文本数据，例如PubMed数据库中的医学文章，并确保所选数据严格符合该专业领域的术语和语义标准。

研究内容：数据集

- 对话数据集(任务数据集)
  - 对话数据集是构建对话系统和聊天机器人的关键资源，包含人们在日常交流、客户服务等场景中的实际对话数据。
  - 这些数据集的显著特征是它们含有丰富的上下文信息和互动模式，使其非常适合训练对话生成和问答系统等应用。

研究内容：数据集

- 平行数据集
  - 平行数据集用于机器翻译和多语言信息处理，包含源语言与目标语言之间的成对句子、段落或篇章。
  - 这些数据集的显著特点在于，成对的文本数据是互为翻译的，保证了跨语言内容的语义对等性。
  - 常见的平行数据集有欧洲议会会话录 、联合国平行语料库等，是构建高质量机器翻译系统的关键资源。

研究内容：数据集

常用公开数据集

名称	数据集类型
WikiText数据集	语言建模
TREC（Text REtrieval Conference）	信息检索
CoNLL-2003 NER	命名实体识别
IMDB情感分析数据集	情感分析
SQuAD（Stanford Question Answering Dataset）	阅读理解
SNLI（Stanford Natural Language Inference）	自然语言推理
GLUE（General Language Understanding Evaluation）	多种NLP任务
WMT（Workshop on Machine Translation）	机器翻译

数据集样例

补充材料

- SQuAD: 阅读理解


```
{
  "data": [
    {
      "paragraphs": [
        {
          "context": "The Normans (Norman: Nourmands; French:
            Normands; Latin: Normanni) were the people who in the
            10th and 11th centuries gave their name to Normandy,
            a region in France. ",
          "qas": [
            {
              "answers": [
                {
                  "answer_start": 159,
                  "text": "France"
                }
              ],
              "id": "56ddde6b9a695914005b9628",
              "is_impossible": false,
              "question": "In what country is Normandy located?"
            }
          ]
        }
      ],
      "title": "Normans"
    }
  ],
  "version": 2
}
```

数据集样例

补充材料

- SNLI: 文本蕴含

Text	Judgments	Hypothesis
A man inspects the uniform of a figure in some East Asian country.	contradiction C C C C C	The man is sleeping
An older and younger man smiling.	neutral N N E N N	Two men are smiling and laughing at the cats playing on the floor.
A black race car starts up in front of a crowd of people.	contradiction C C C C C	A man is driving down a lonely road.
A soccer game with multiple males playing.	entailment E E E E E	Some men are playing a sport.
A smiling costumed woman is holding an umbrella.	neutral N N E C N	A happy woman in a fairy costume holds an umbrella.

https://blog.csdn.net/u010960155

自然语言处理典型任务

- 自然语言处理涵盖了广泛的任务：
  - 分词和词性标注
  - 命名实体识别
  - 句法分析
  - 语义角色标注
  - 情感分析
  - 文本匹配
  - 文本生成



自然语言处理典型任务

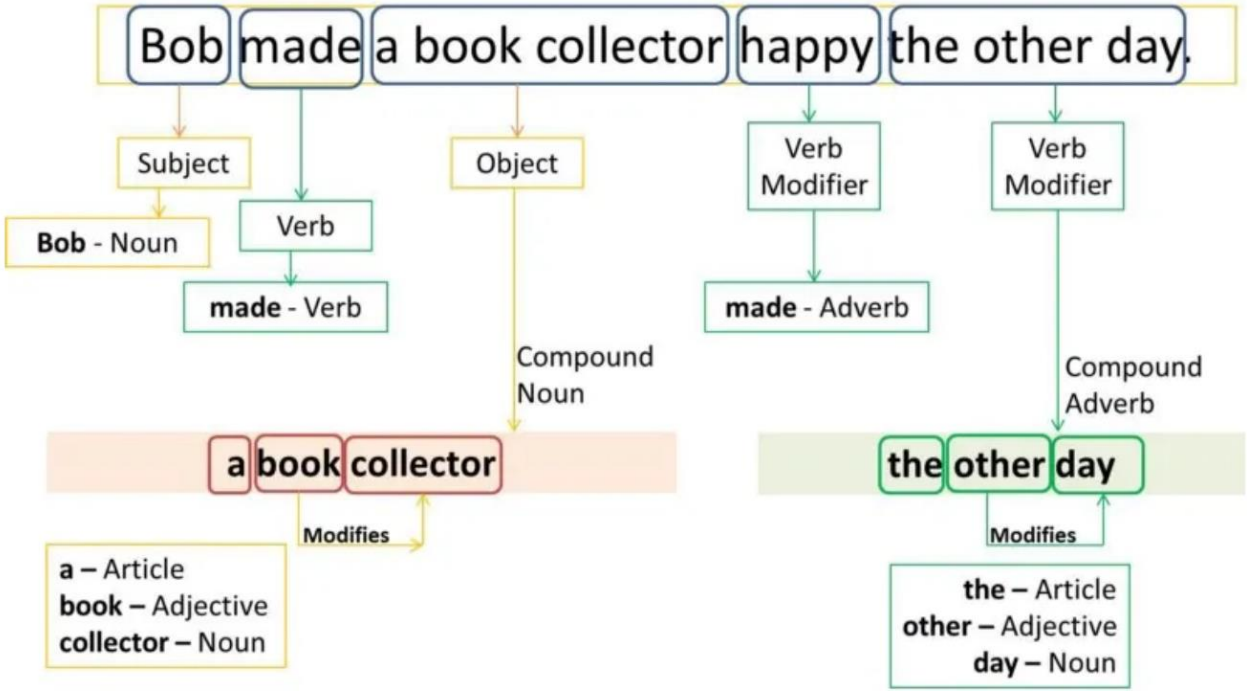
- 分词和词性标注
  - 分词（Word Segmentation）是将文本按词语或子词分割的过程，尤其在中文等无空格语言中尤为关键。
    - 和服务于三日后裁制完毕，并呈送将军府中。
    - 王府饭店的设施和服务是一流的。



    - 和服 | 务 | 于 | 三日 | 后 | 裁制 | 完毕，并 | 呈送 | 将军府 | 中。
    - 王府 | 饭店 | 的 | 设施 | 和 | 服务 | 是 | 一流 | 的。

自然语言处理典型任务

- 分词和词性标注
  - 词性标注（Part-of-Speech Tagging）则是在分词的基础上，为每个词标注其词性（如名词、动词、形容词、副词等）。



自然语言处理典型任务

- 命名实体识别
  - 命名实体识别（Named Entity Recognition，NER）旨在从文本中识别并提取特定实体，如人名、地名、机构名称或时间等。
  - 技术：序列标注(Sequence Labeling)
    - 它通过给句子中每个词分配特定标签，来识别出句子中的实体。
  - NER是信息抽取、知识图谱构建、智能搜索等应用的重要基础。

自然语言处理典型任务

- 命名实体识别
  - 命名实体识别（Named Entity Recognition，NER）旨在从文本中识别并提取特定实体，如人名、地名、机构名称或时间等。

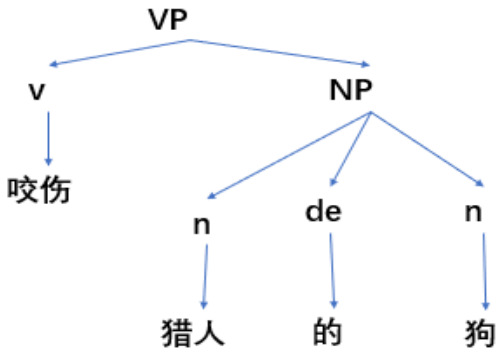


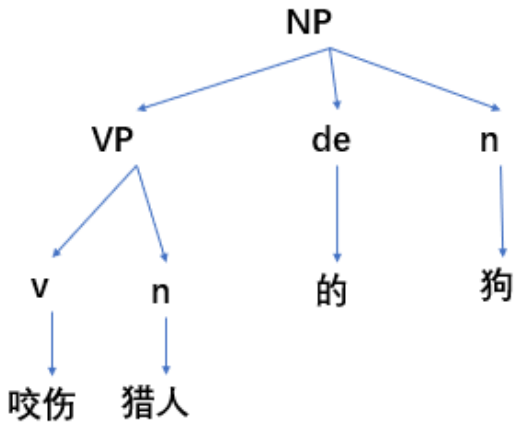
自然语言处理典型任务

- 句法分析
  - 句法分析（Parsing）是对句子语法结构深入解析的过程。通过句法分析，可以确定句子中的各个成分以及它们之间的关系。
  - 根据分析方式的不同，句法分析可分为短语结构分析和依存关系分析，前者将句子分解为名次短语、动词短语等短语结构，后者则关注词与词之间的依存关系。

自然语言处理典型任务

- 短语结构分析
  - VP[咬伤/v NP[猎人/n 的/de 狗/n]]
  - NP[VP[咬伤/v 猎人/n] 的/de 狗/n]

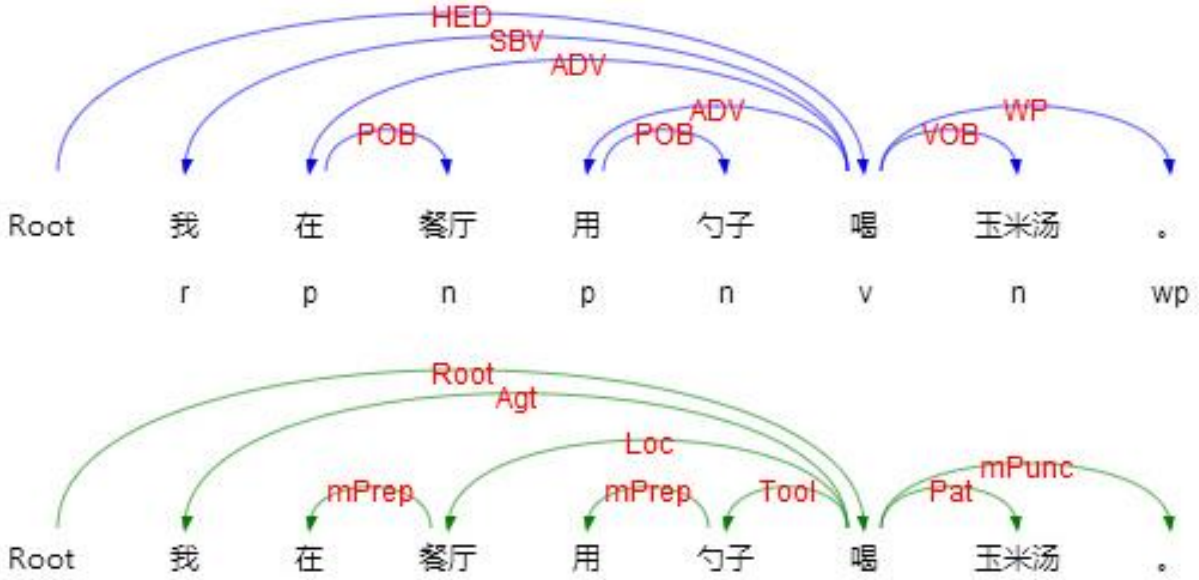




自然语言处理典型任务

补充材料

- 依存句法树
  - 可以表示短语结构和依存关系



依存分析树

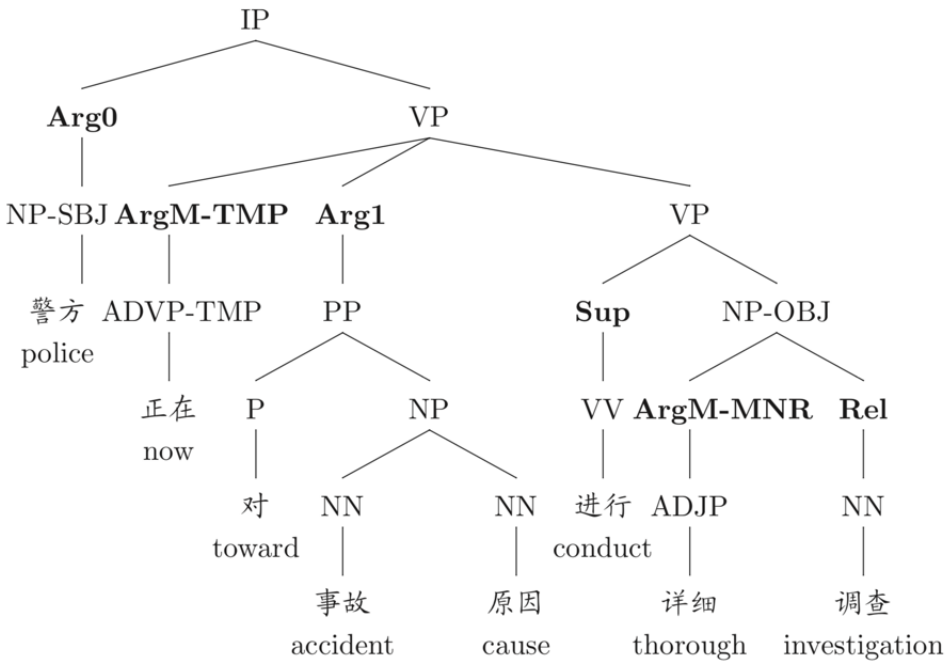
自然语言处理典型任务

- 语义角色标注
  - 语义角色标注（Semantic Role Labeling, SRL）是指对句子的语义进行分析，旨在识别和标注句子中每个谓词（通常是动词）与其周围词语之间的语义角色关系。
  - 每个语义角色表示动作或事件中不同参与者的角色或语义功能。语义角色标注在情感分析、对话系统等应用中具有重要作用。

自然语言处理典型任务

- 语义角色标注示例

补充材料



"The police are conducting a thorough investigation of the cause of the accident."

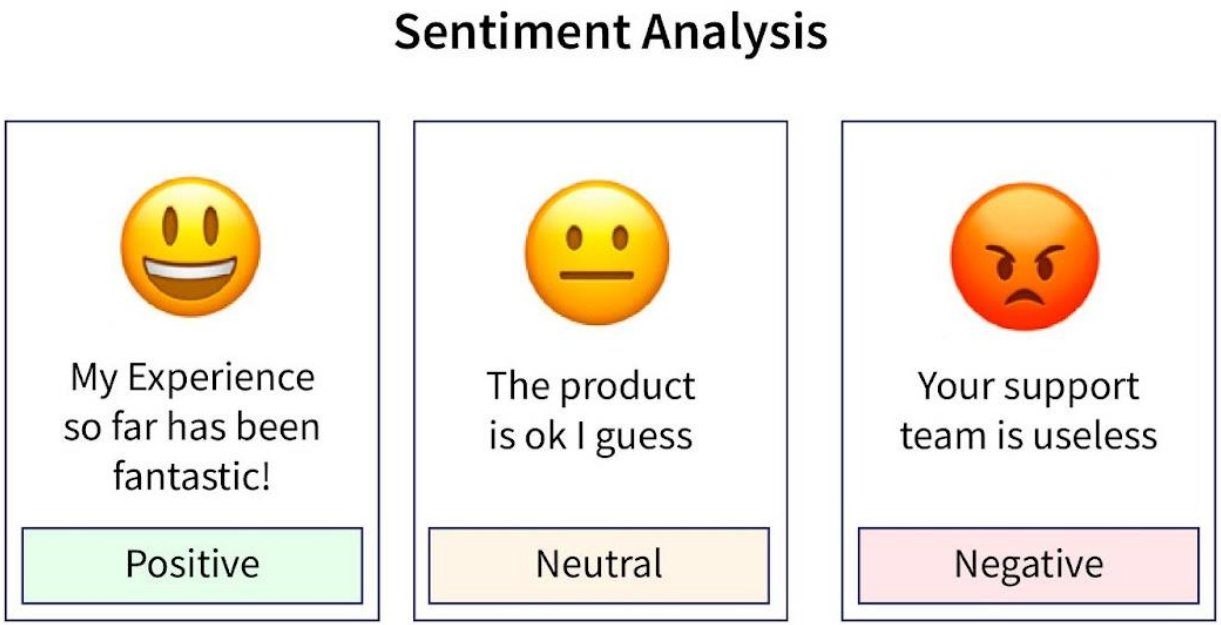
标签	含义
ArgM-DIS	标记语
ArgM-DGR	程度
ArgM-EXT	范围
ArgM-FRQ	频率
ArgM-LOC	地点
ArgM-MNR	方式
ArgM-PRP	目的
ArgM-TMP	时间
ArgM-TPC	主题
Arg0	施事
Arg1	受事
Arg2	范围
Arg3	动作开始
Arg4	动作结束
Arg5	其他动词相关
ArgM-ADV	状语
ArgM-BNF	受益人
ArgM-CND	条件
ArgM-DIR	方向

自然语言处理典型任务

- 情感分析
  - 情感分析（Sentiment Analysis）通过识别文本中的情感词汇和表达方式，判断文本中的情绪倾向，推测作者的情绪和态度，通常分为正面、负面以及中性等类别。
  - 情感分析广泛应用于社交媒体监测、市场分析、产品评论分析和用户反馈处理等领域。

自然语言处理典型任务

- 情感分析
  - 情感分析（Sentiment Analysis）通过识别文本中的情感词汇和表达方式，判断文本中的情绪倾向，推测作者的情绪和态度。

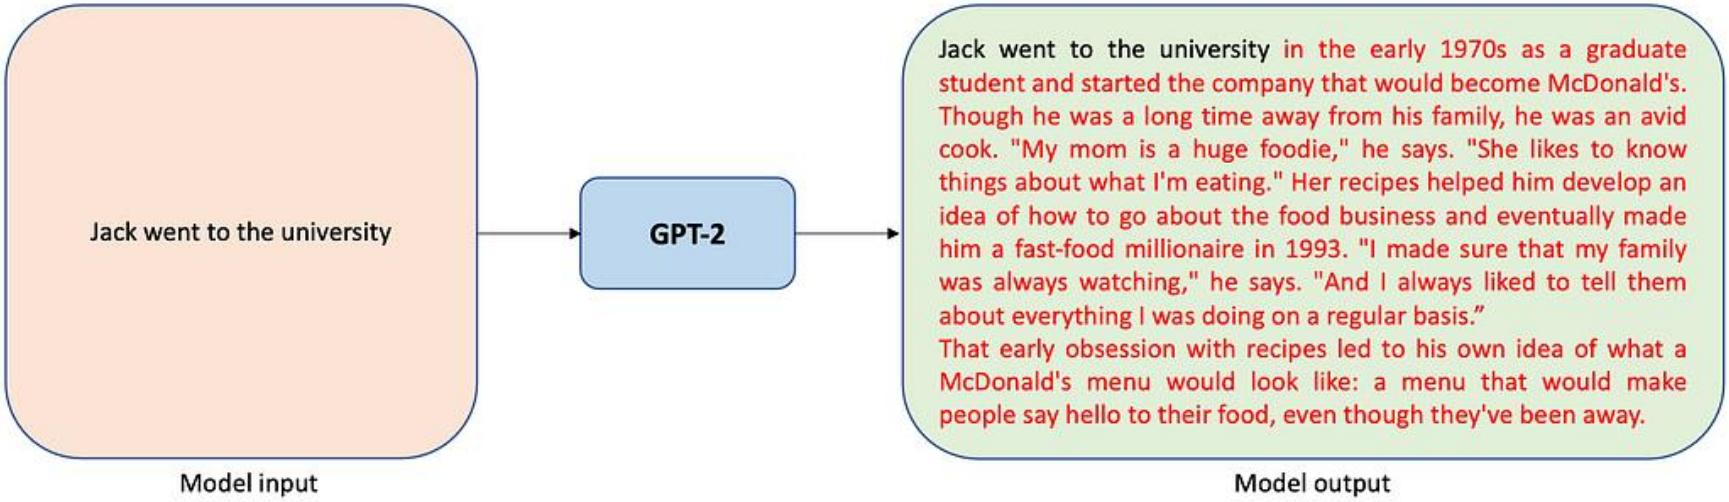


自然语言处理典型任务

- 文本匹配
  - 文本匹配是指通过比较两个文本（句子、段落或文档）之间的相似性或相关性，来判断它们是否匹配。
  - 具体任务形式包括信息检索、相似度计算、复述检测、文本蕴含和问答等，根据任务形式的不同，输入和输出也略有差异。
  - 文本匹配技术在自然语言处理领域有着广泛的应用，例如搜索引擎、聊天机器人和智能客服等。

自然语言处理典型任务

- 文本生成
  - 文本生成（Text Generation）是让计算机根据给定的输入或条件生成连贯的自然语言文本。
  - 文本生成广泛应用于新闻摘要、内容创作、对话系统等场景。



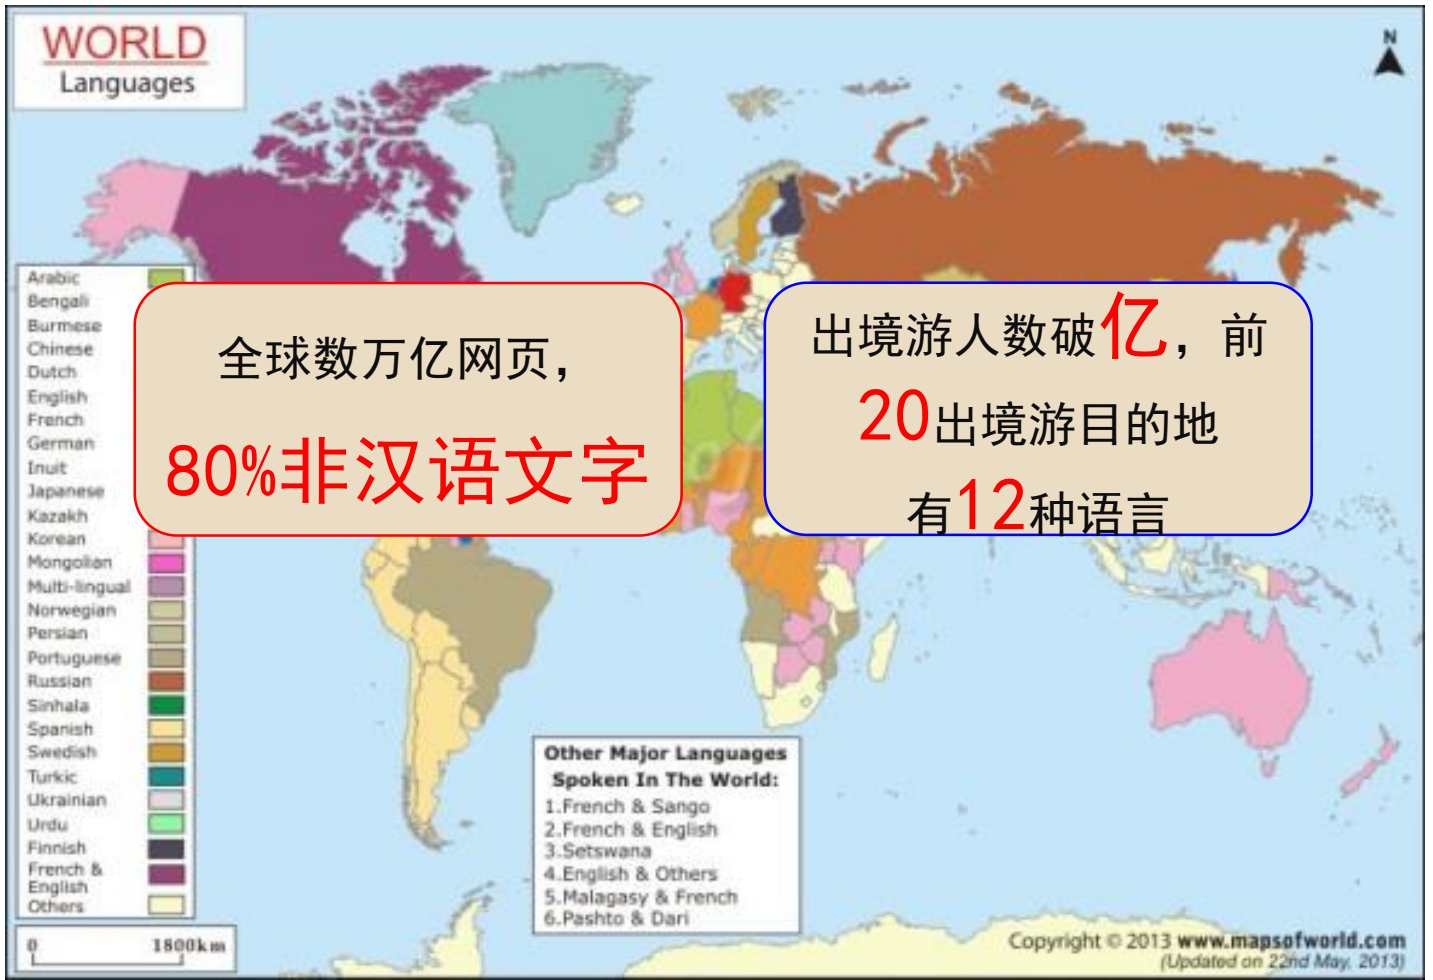
典型应用研究

- 自然语言处理包含很多典型的应用：
  - 机器翻译
  - 信息检索
  - 问答系统
  - 文本分类



典型应用研究

一、机器翻译



全球数万亿网页，

80%非汉语文字

出境游人数破亿，前

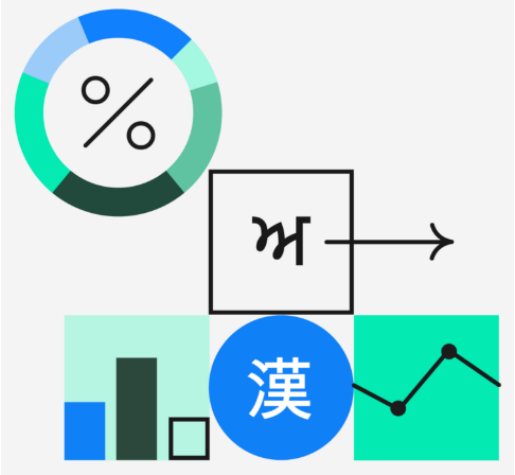
20出境游目的地

有12种语言

典型应用研究

一、机器翻译

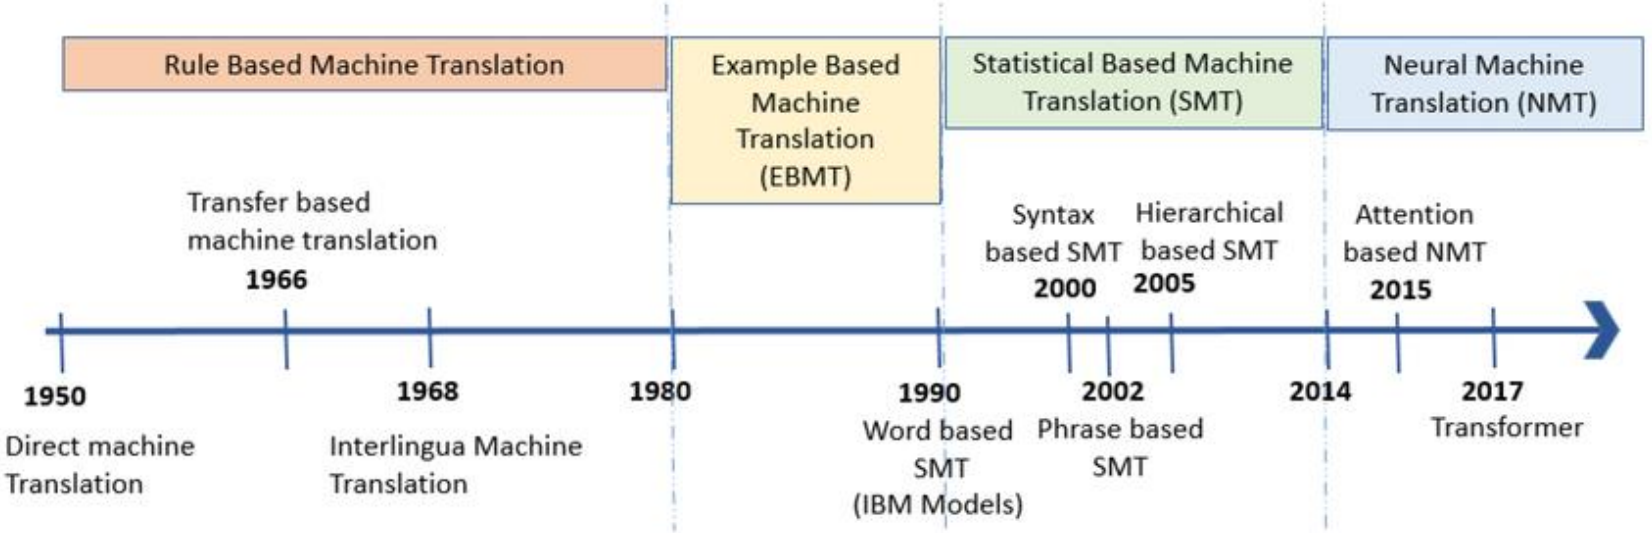
- 机器翻译（Machine Translation, MT）是NLP领域最早且最具挑战性的应用之一。
- 1. 基于统计的机器翻译（SMT）
- 2. 神经机器翻译（NMT）
- 3. 正在过渡于基于大模型的机器翻译



典型应用研究

一、机器翻译

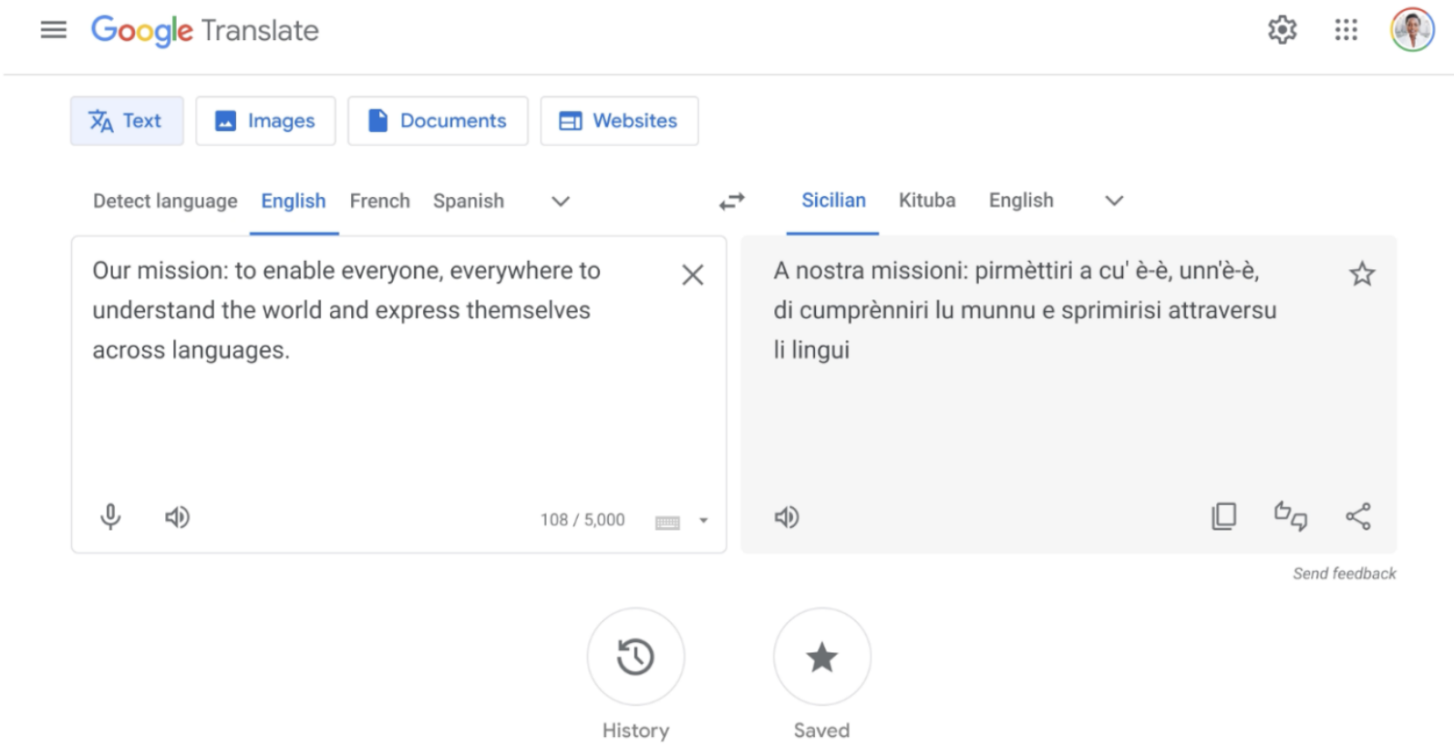
- 作为历史最悠久的NLP任务之一，机器翻译经历了很多代技术的变革：



典型应用研究

一、机器翻译

- 典型案例：谷歌翻译现在支持639种语言，并计划在未来扩充到1000种语言！



典型应用研究

二、信息检索：



- 信息检索（Information Retrieval, IR）旨在从大量文档或者知识库中，检索到与查询内容一致或相关的信息
- 1.关键词匹配
- 2.基于深度学习的检索模型

典型应用研究

二、信息检索：

1.关键词匹配：

- 依赖于关键词匹配和基于TF-IDF的特征表示，通过计算查询与文档的相似性实现信息检索。

$$w_{x,y} = tf_{x,y} \times \log\left(\frac{N}{df_x}\right)$$

TF-IDF

Term x within document y

$tf_{x,y}$ = frequency of x in y

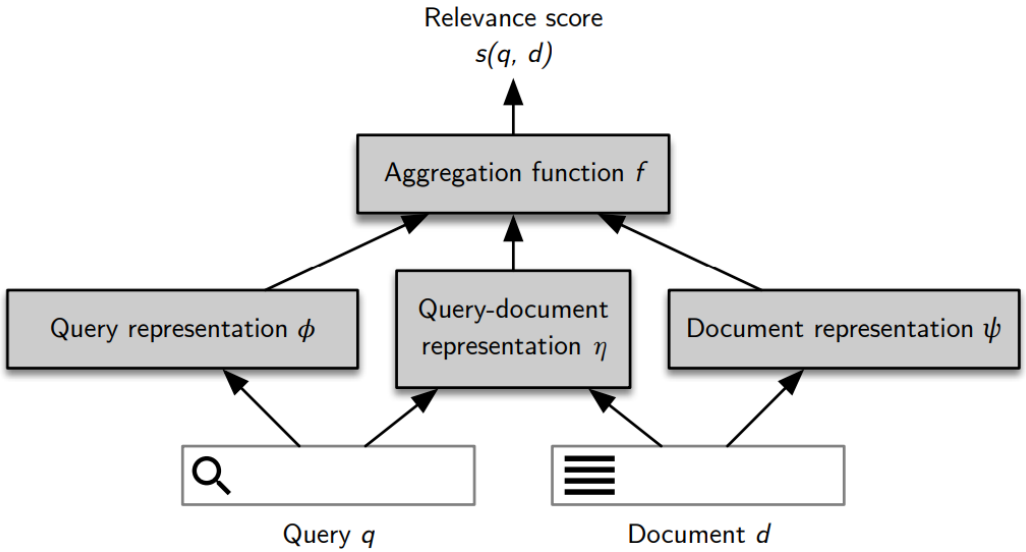
df_x = number of documents containing x

N = total number of documents

典型应用研究

二、信息检索：

- 2.基于深度学习的检索模型：
  - BERT、ERNIE等预训练模型被引入到信息检索系统中，通过深度语义理解提高了搜索的精确度。



典型应用研究

二、信息检索：

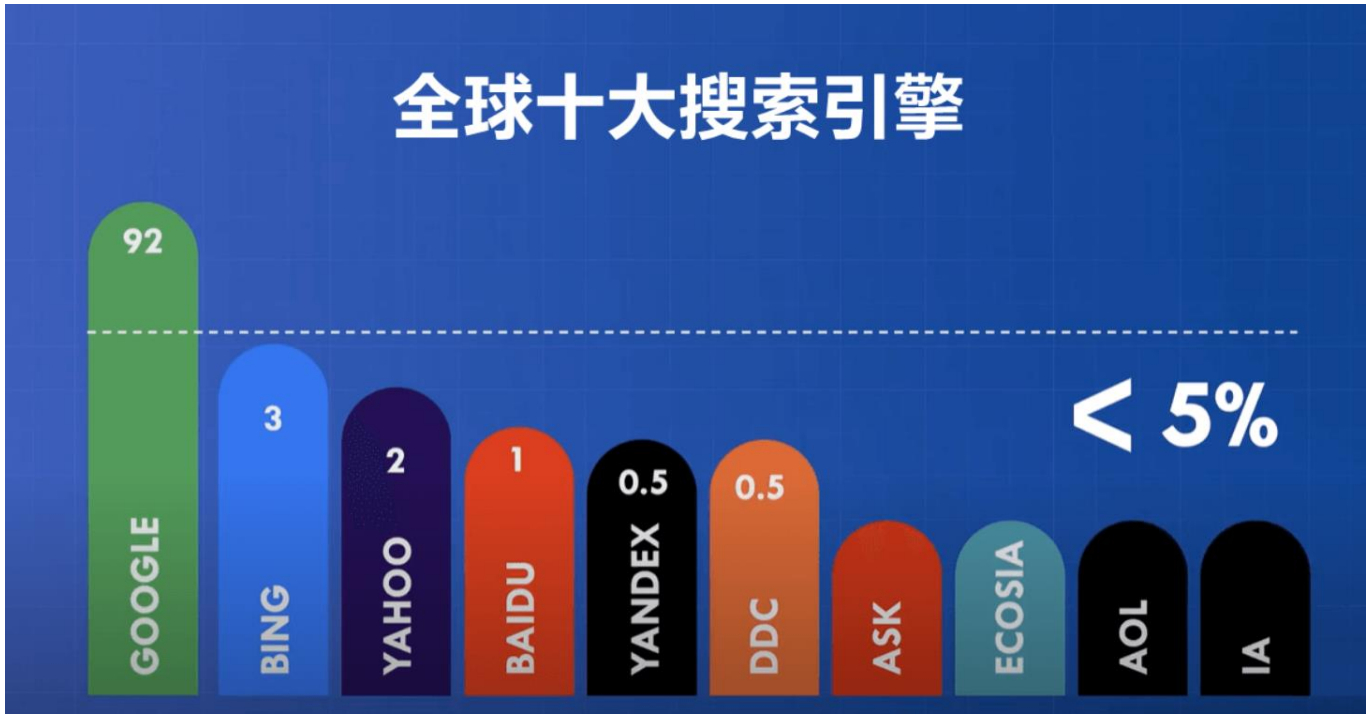
- 典型案例：Baidu、Google等搜索引擎，已经成为了当前互联网信息的门户，起到了不可替代的作用。



典型应用研究

二、信息检索：

- 谷歌仍然是全世界市场分量最大的搜索引擎！



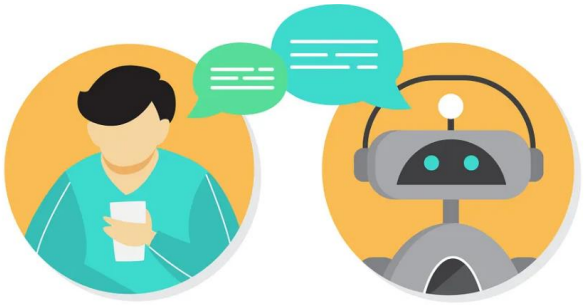
典型应用研究

三、问答系统

- 问答系统（Question Answering, QA）

  广泛应用于搜索引擎、智能客服等场景，

  目标是对用户的问题给出精确答案。

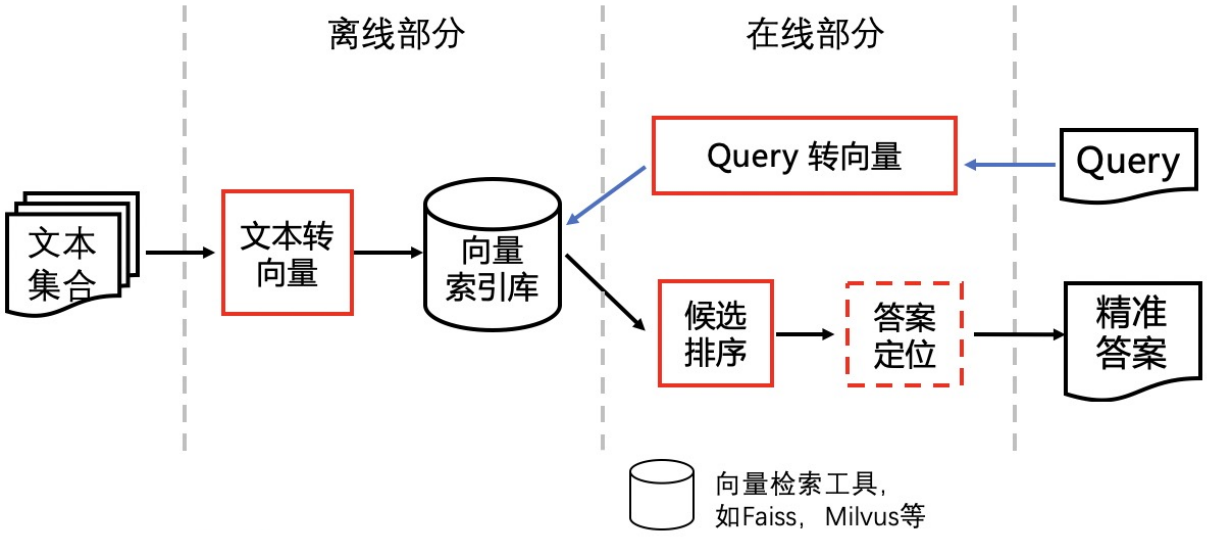


- 1.基于检索的问答系统
- 2.生成式问答系统

典型应用研究

三、问答系统

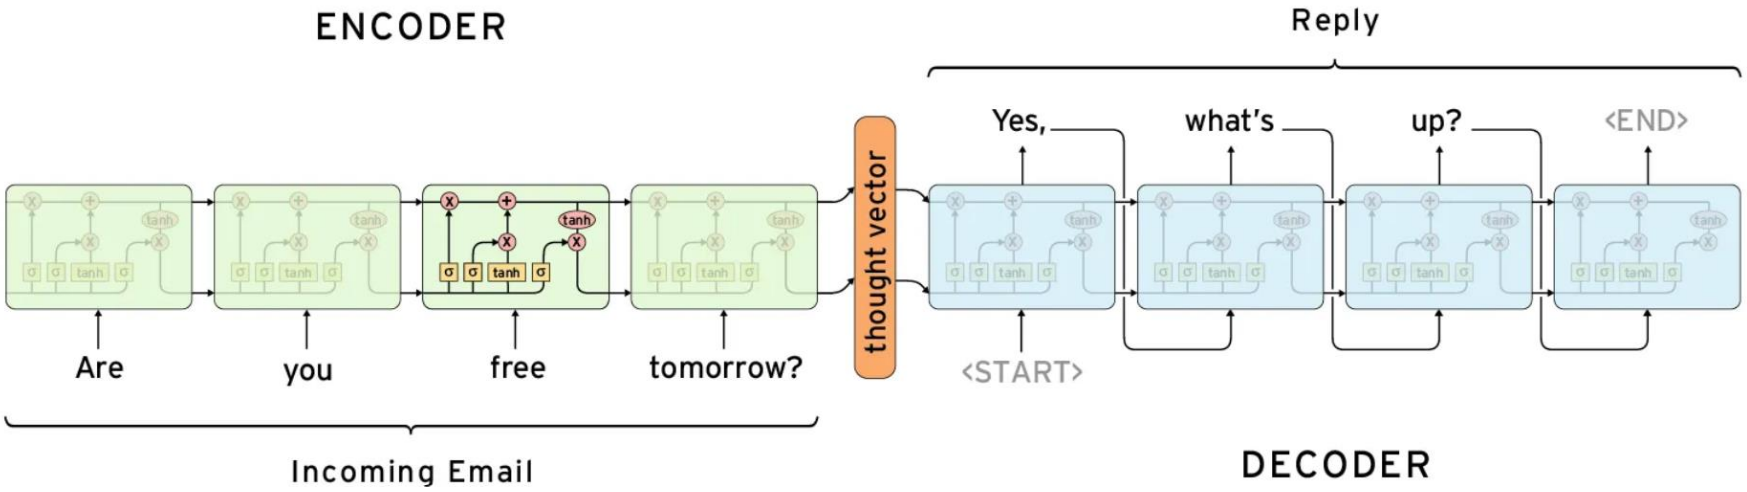
- 基于检索的问答系统：这类系统通过搜索找到与问题相关的文档段落，再从中提取出答案。



典型应用研究

三、问答系统

- 生成式问答系统：生成式问答系统基于生成模型给出答案，特别适合复杂的开放域问题。



典型应用研究

三、问答系统

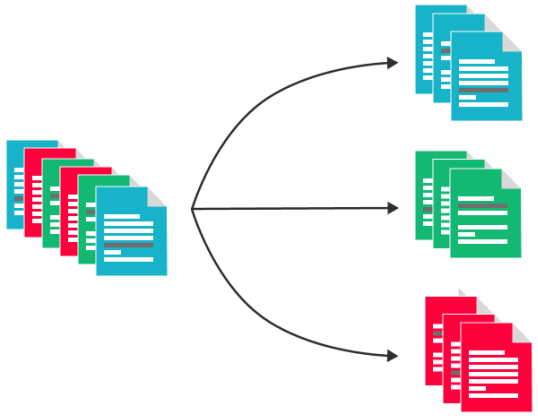
- 典型案例：2011年，在有奖问答综艺节目《危险边缘》中，IBM Waston与人类同台竞技。在决赛中， Waston打败了最高奖金得主布拉德·鲁特尔和连胜纪录保持者肯·詹宁斯。



典型应用研究

四、文本分类

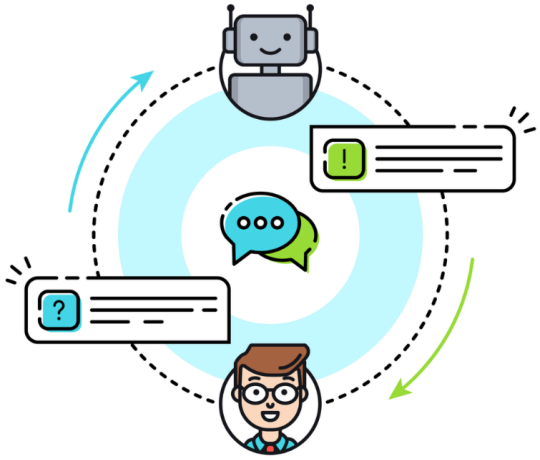
- 给定一段文本，归入提前定义的类别。广泛应用于垃圾邮件过滤、主题分类、新闻分类等场景。
- 1. 传统的文本分类方法
- 2. 基于深度学习的文本分类



典型应用研究

五、对话系统

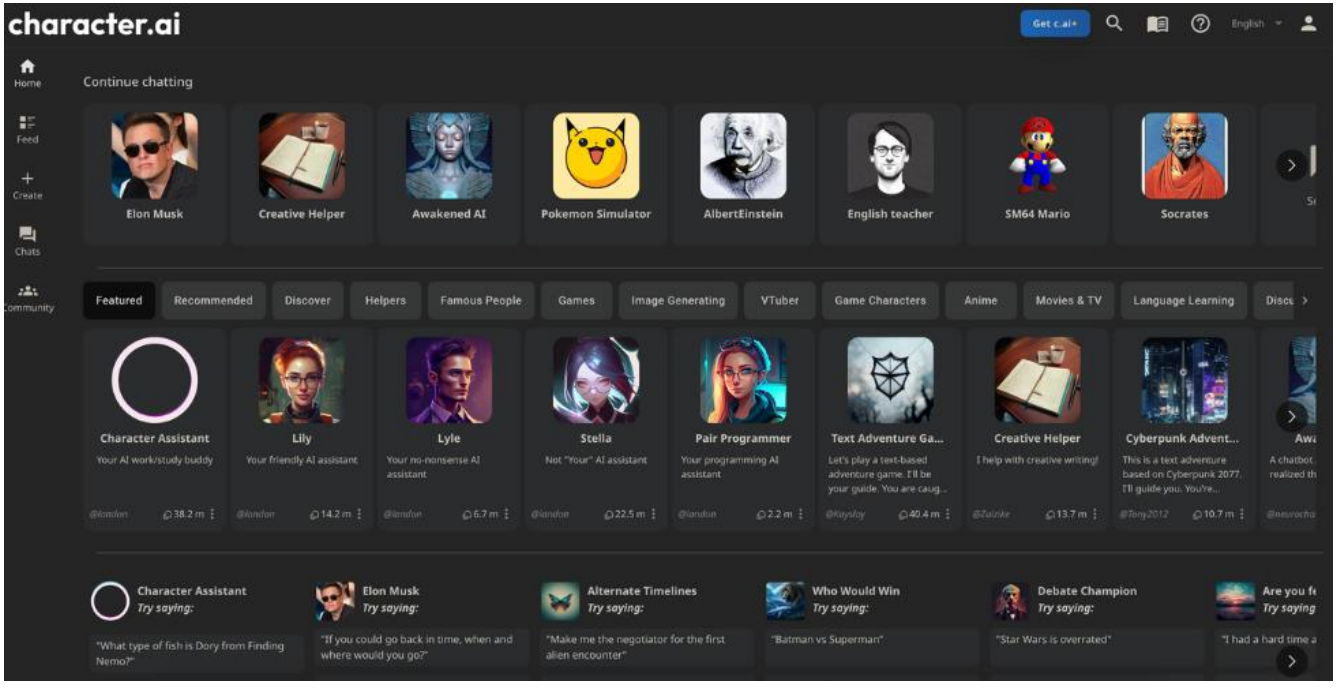
- 对话系统（Dialogue System）是一种能够自动进行自然语言交互的系统，广泛应用于客服、虚拟助手等场景。
- 1. 基于规则的对话系统
- 2. 基于深度学习的对话系统



典型应用研究

五、对话系统

- 典型案例：character.ai 以角色扮演为特色，获得了超过ChatGPT的用户时长。以美国市场为例，在2023年7月份，ChatGPT的平均用户使用时长只有10分钟，而character.ai的高达70分钟。

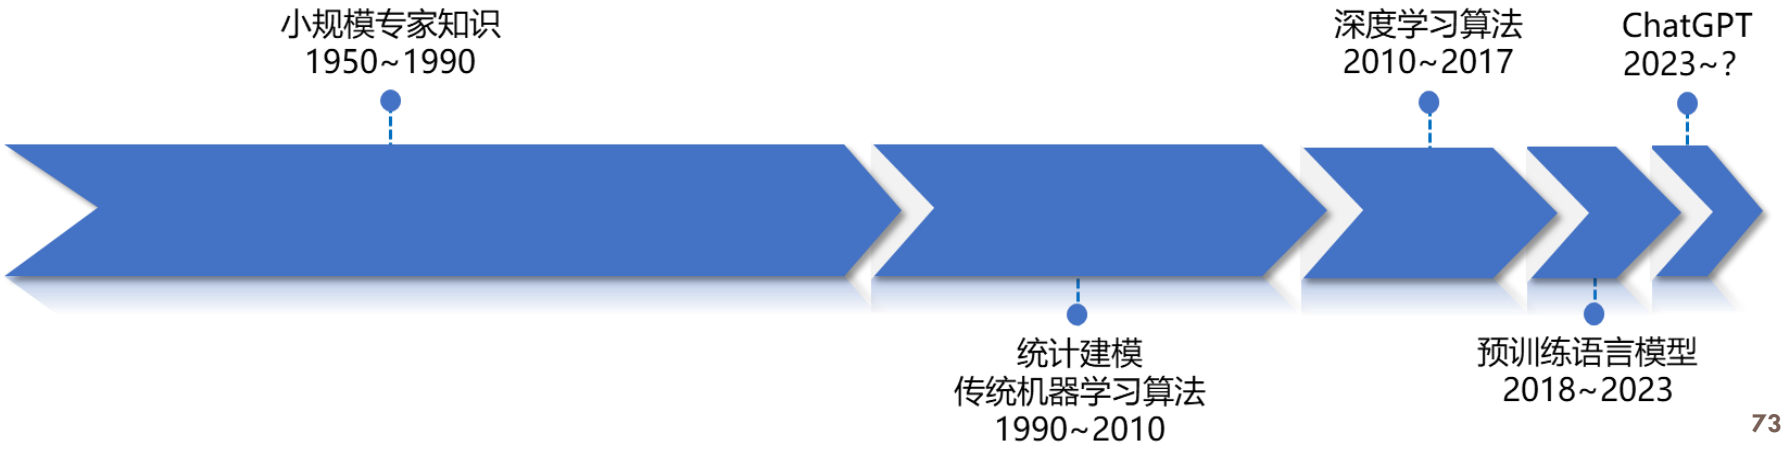


主要内容

- 自然语言处理概述
- 自然语言处理研究内容
- 自然语言处理发展历史
- 自然语言处理未来展望

自然语言处理历史

- 自然语言处理作为人工智能领域的重要分支，自20世纪50年代起，经历了多个发展阶段：
  - 基于规则的方法
  - 基于统计机器学习的方法
  - 基于神经网络（深度学习）的方法
  - 基于大模型的方法

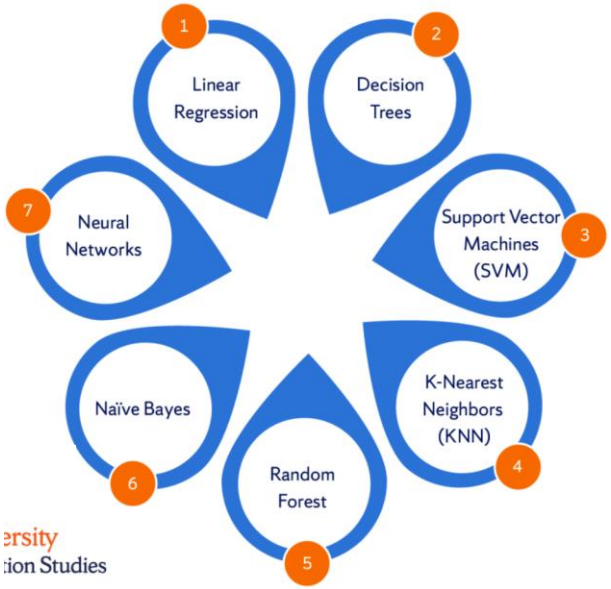


基于规则的方法

- **基于规则的方法**
  - **理论基础：**形式语言理论
  - **核心代表：**词汇功能语法（LFG）、短语结构语法（PSG）
  - **优点：**明确性、可解释性强
  - **缺点：**覆盖范围有限、可移植性差

统计机器学习方法

- **统计机器学习方法**
  - **理论基础：**统计学、概率论与信息论
    - 在20世纪90年代，随着计算机处理能力的大幅提升和大规模语言数据的逐渐积累，基于统计的机器学习方法开始兴起。
- **建立了丰富的自然语言处理技术体系**
  - 词性标注：隐马尔可夫模型/最大熵模型
  - 命名实体识别：最大熵模型/支持向量机/朴素贝叶斯
  - 文本分类：TF-IDF
  - 统计机器翻译：N-gram模型/隐马尔可夫模型
  - 情感分类：朴素贝叶斯/支持向量机/KNN

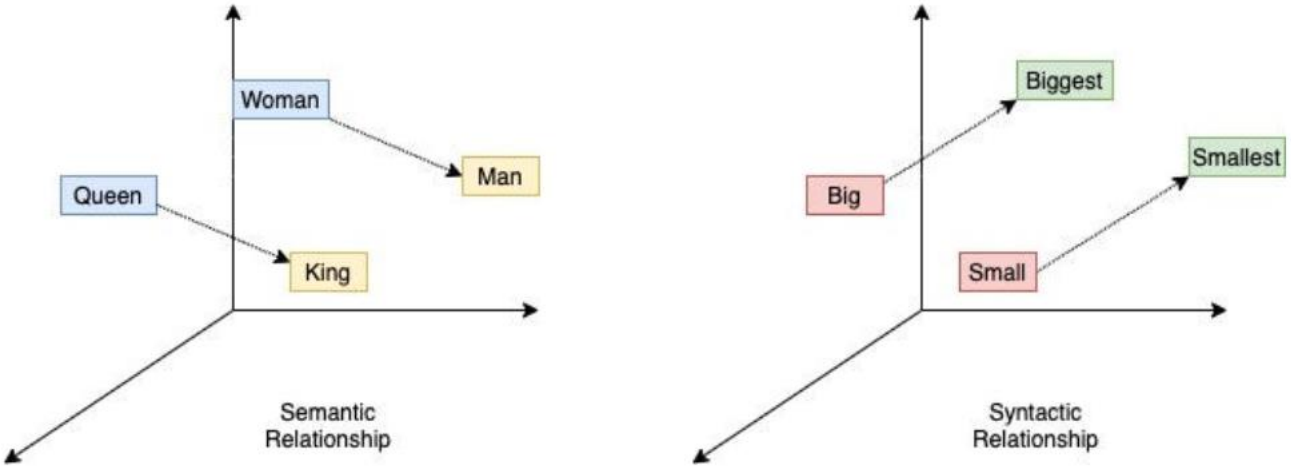


基于深度学习的方法

- **深度学习方法**
  - 随着算力的提升和数据规模的迅速增长，神经网络和深度学习理论逐渐在自然语言处理领域中占据主流地位。
  - 深度学习利用多层复杂的神经网络，能够从大规模数据中自动学习语义特征及关联关系。
  - 神经网络具备强大的表达能力，能够捕捉数据中的非线性关系，可以处理复杂的句法、语义和上下文依赖关系。

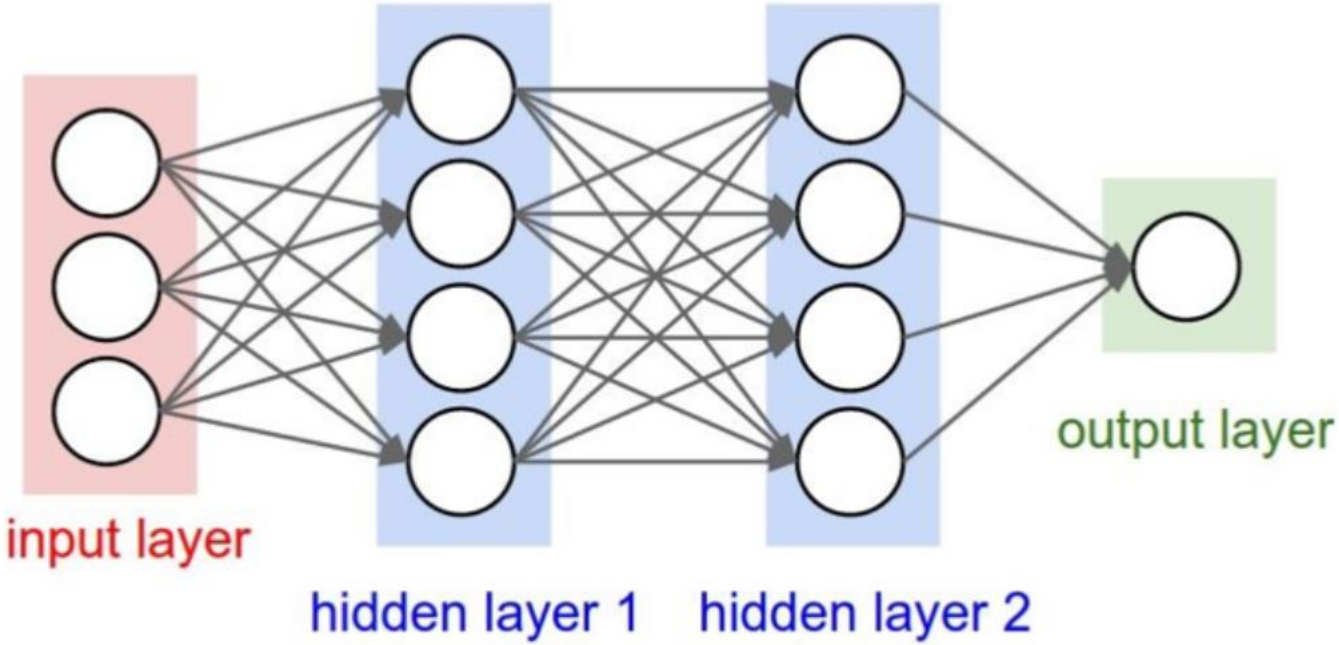
基于深度学习的方法

- 1. 词嵌入技术
  - 将词转换为连续向量，使语义相似的词在向量空间中靠近。
  - Word2Vec/GloVe:静态词向量，但难以处理多义词；
  - ElMo/BERT: 动态词向量，可以处理多义词问题！



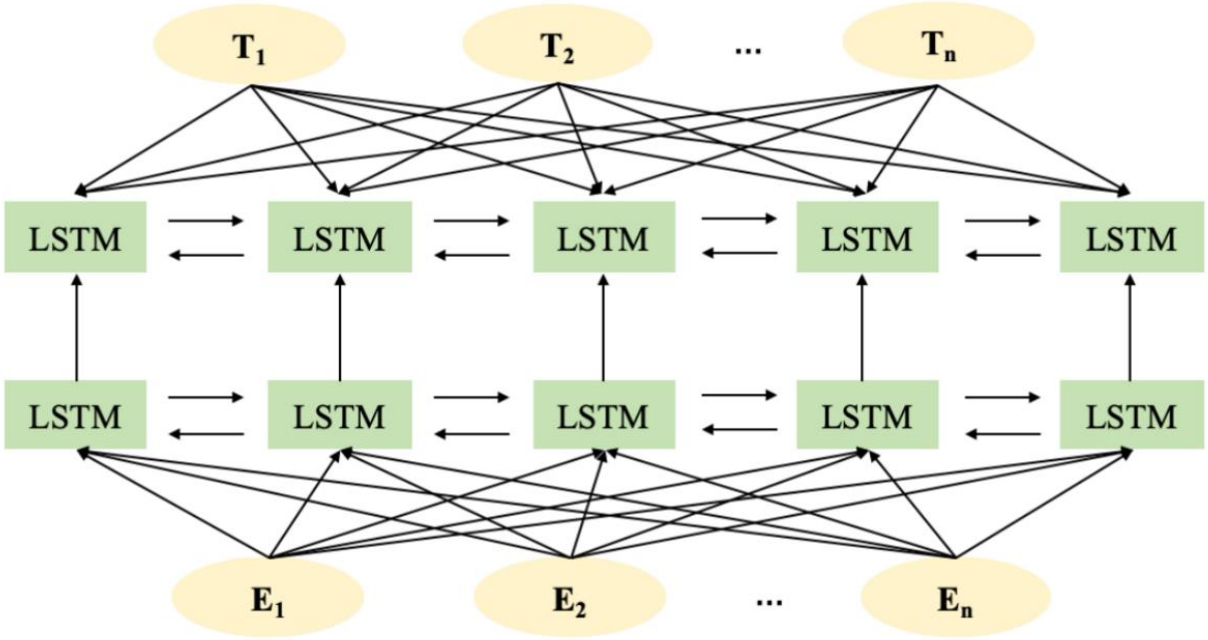
基于深度学习的方法

- 2. 主要神经网络模型
  - 全连接神经网络



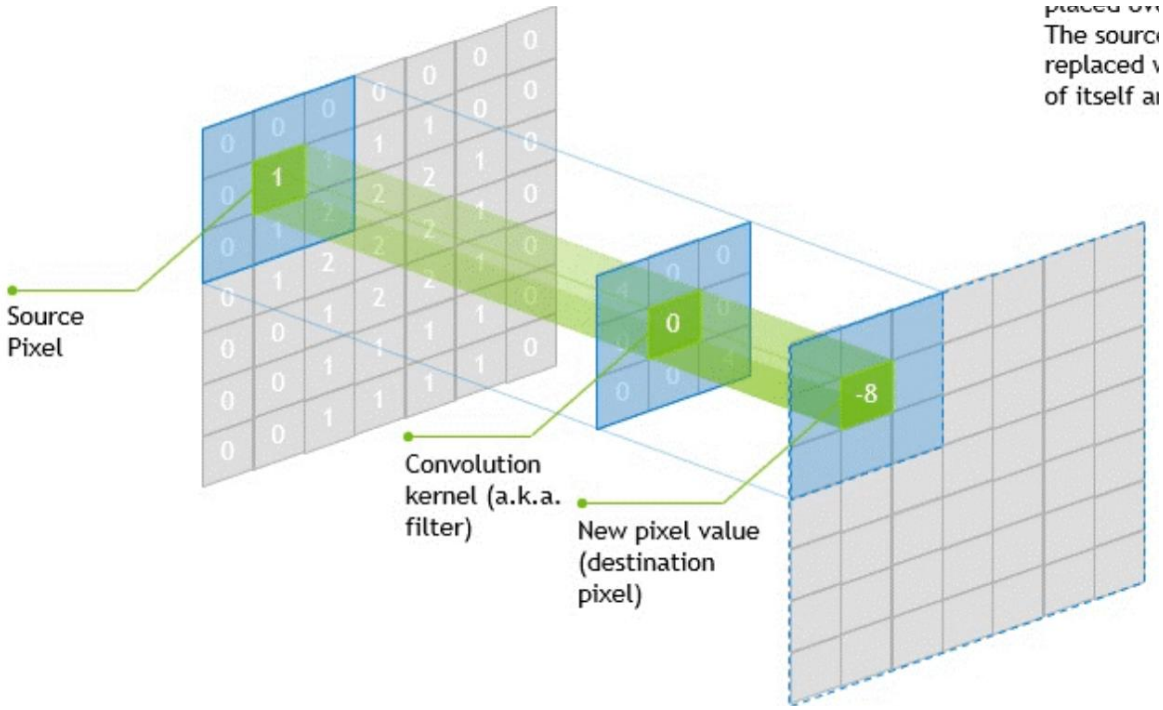
基于深度学习的方法

- 2. 主要神经网络模型
  - 循环神经网络



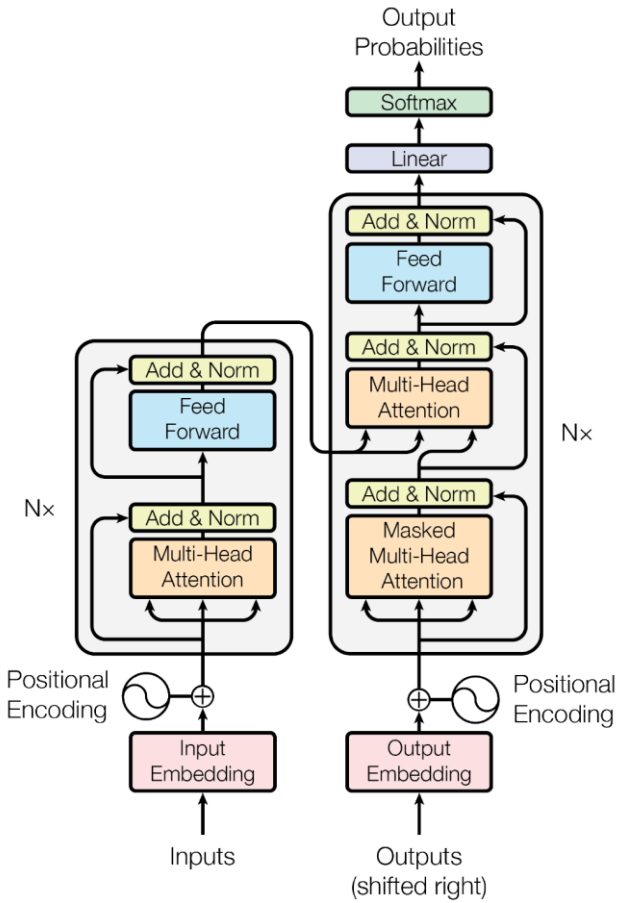
基于深度学习的方法

- 2. 主要神经网络模型
  - 卷积神经网络



基于深度学习的方法

- 2. 主要神经网络模型
  - Transformer



基于深度学习的方法

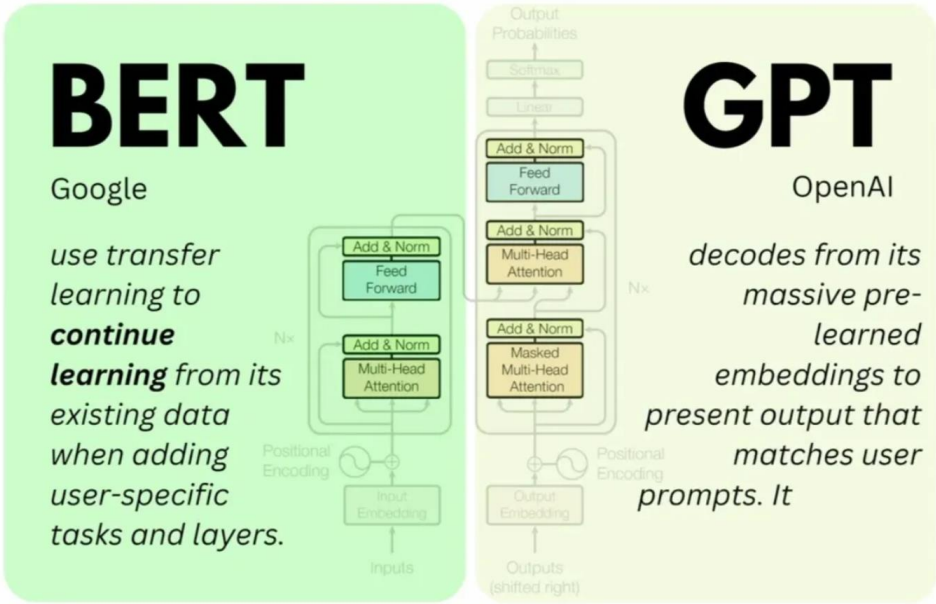
- 3. 深度学习的优势
  - 强大的特征学习能力：自动、高效地从数据中学习高阶、复杂的特征表示，不需要依赖人工构造特征；
  - 非线性映射能力：将输入数据映射到高维特征空间，有效捕捉数据中的非线性关系和复杂模式；
  - 数据驱动的动态适应性：具有更强的动态适应能力，可以在不同语言、领域和任务之间实现知识迁移；
  - 高度并行化计算：充分利用GPU、TPU等硬件的并行计算能力，高效处理大规模的自然语言数据；

基于规则、统计和神经网络方法的优势对比

维度	基于规则的方法	统计方法	深度学习方法
方法论	依赖人工编写的规则和语言学知识解析和处理语言	使用概率模型从数据中学习语言模式与规律，从而在不同NLP任务中实现预测或决策	使用神经网络从大规模数据中自动学习语义表示及模式，从而实现语言理解与生成
数据需求	低到中等，主要依赖专家定义的规则与知识，而非大量数据	高，需要大量标注数据以提高准确性	非常高，通常需要海量数据，尤其是预训练模型
模型复杂性	简单到中等，取决于规则系统的规模	中等到高，取决于模型类型（如HMM、n元语法模型等）	高，复杂的多层深度网络结构和大量参数
新领域适应性	低，每个新领域需要新的规则	中等，模型可以适应新领域，但可能需要重新训练	高，可通过微调实现跨领域的泛化
可解释性	高，规则是明确定义的且具有可解释性	中等，模型可以显示概率但可能缺乏透明度	低，解释性有限
处理语言歧义的能力	差，需要特定规则来处理每个歧义情况	中等，通过概率捕捉基本歧义，但缺乏上下文处理能力	高，能够通过上下文嵌入解决歧义
处理长距离依赖	较差，难以很好地捕捉长距离依赖	中等，通过n元语法或HMM等技术处理部分依赖	高，尤其是Transformer模型可以捕捉长距离依赖
主要优点	高可解释性，适合模式明确的窄领域	数据驱动，适应性强，比基于规则的方法更好地处理多样性	高精度，适应性强，能够学习复杂模式和表示
主要缺点	难以扩展，灵活性差，难以处理多样语言模式	性能依赖于数据质量和数量，可解释性一般	需要海量数据和计算资源，缺乏透明性

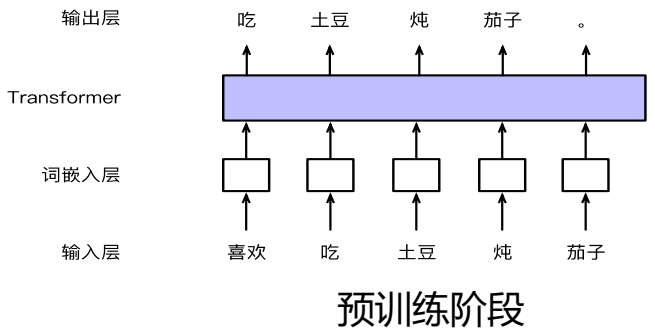
基于大模型的方法

- 预训练语言模型的核心思想：
  - 利用大规模无标注数据，通过自监督学习，学习到深层次的语义表示，从而具备强大的语言理解和生成能力。
- 里程碑模型
  - BERT
  - GPT系列
  - ...

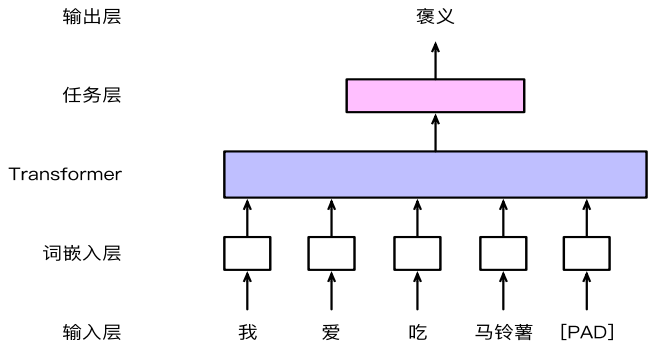


基于大模型的方法

- GPT: Generative Pre-trained Transformer (OpenAI 2018)
  - 使用单向的Transformer模型
  - 在目标任务上精调整个预训练模型
  - 接入的下游任务模型可以非常简单
- 开启自然语言处理**大规模预训练模型**时代



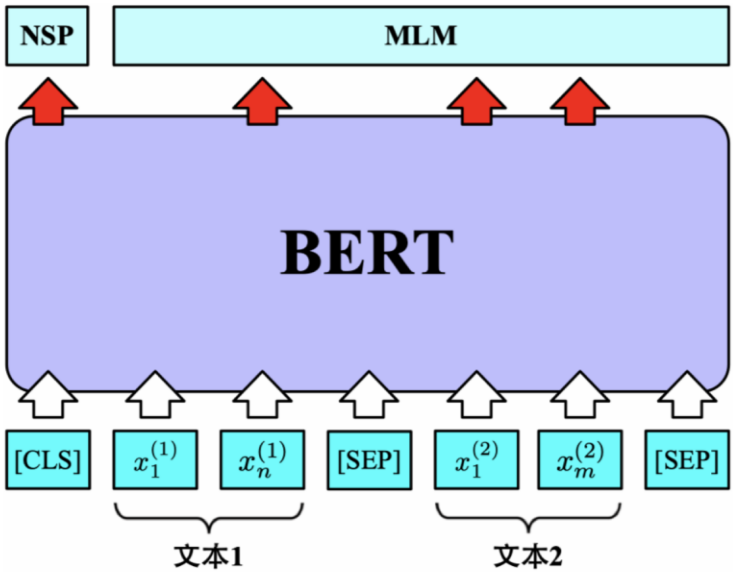
预训练阶段



精调阶段

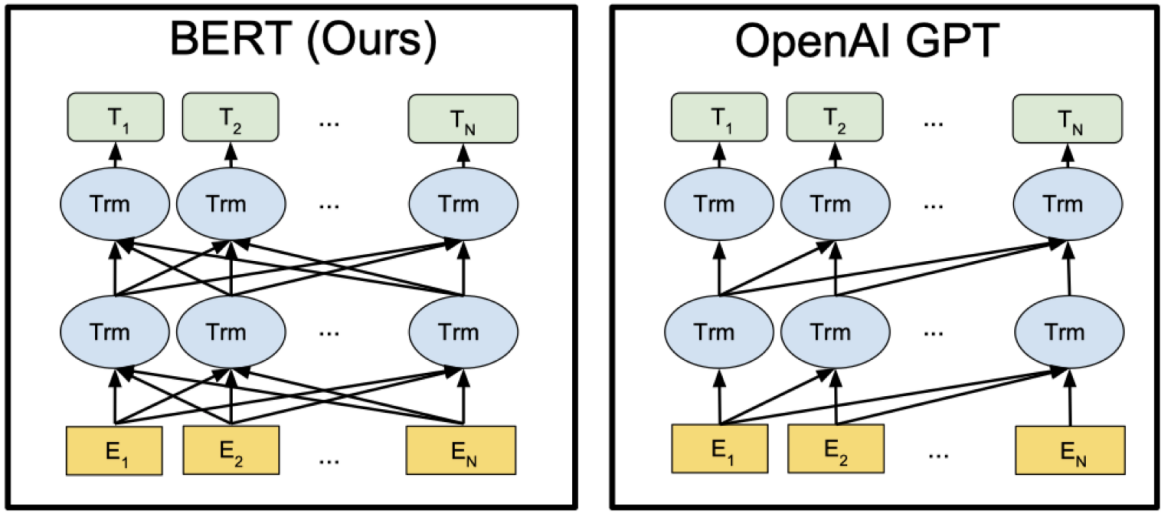
基于大模型的方法

- BERT：Bidirectional Encoder Representations from Transformers（Google 2018）
  - **整体结构：**由深层Transformer模型构成
  - **预训练任务：**
    - 掩码语言模型（MLM）
    - 下一个句子预测（NSP）



基于大模型的方法

- **GPT/BERT之间的对比**
  - GPT: **单向**从左至右的Transformer语言模型
    - 既可以用于自然语言理解，也可以用于自然语言生成
  - BERT: **双向** Transformer语言模型
    - 主要用于自然语言理解，难以用于自然语言生成



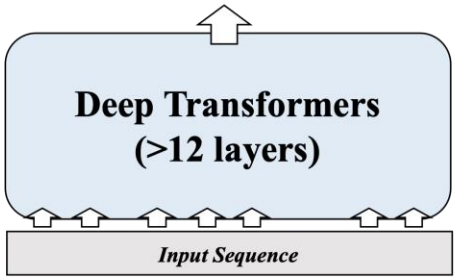
基于大模型的方法

预训练三要素

大数据
（无标注文本）

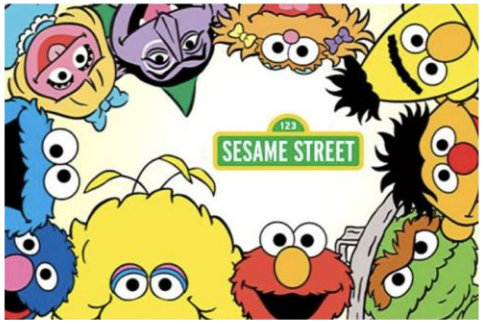


大模型
（深度神经网络）



大算力
（并行计算集群）





OpenAI

GPT

GPT-2

GPT-3



主要内容

- 自然语言处理概述
- 自然语言处理研究内容
- 自然语言处理发展历史
- 自然语言处理未来展望

自然语言处理展望

- 大规模预训练模型的演进
- 语言模型的持续学习
- 少样本学习和零样本学习
- 多模态和跨模态融合
- 安全可控、负责任的自然语言处理技术

习题

习题1：请结合语言学的不同分支，论述语言学研究的主要内容和意义。

习题2：为什么说自然语言处理具有显著跨学科特点？请详细论述。

习题3：试分析语言的基本特征及其在人类社会中的重要作用。

习题4：如何理解自然语言处理与传统语言学的区别与联系？

补充阅读材料

语言学产生的背景

- 历史比较语言学：18和19世纪欧洲
  - 梳理对比各种语言，探索它们在语音、词汇、语法上的对应关系和异同
  - 丹麦的拉斯克（R·Rask）、德国的格里木（J·Grimm）和葆朴（F·Bopp）被称为历史比较语言学的奠基者
  - 1786年（英）琼斯证明：古梵语和古希腊语、拉丁语有共同祖先。
  - 1799年（匈牙利）沙穆艾尔证明：匈牙利语和芬兰语同出一源。

出现：现代的语言学



- 现代语言学之父
  - 费尔迪南·德·索绪尔
    - Ferdinand de Saussure
    - 1857-1913
  - 从1907年始在日内瓦大学讲授“普通语言学”课
- 《普通语言学教程》1916，笔记和讲稿整理出版
- 把语言学塑造成为一门影响巨大的独立学科
- 他认为语言是基于符号及意义的一门科学
  - 现在一般通称为符号学

现代语言学：索绪尔的奠基工作

- **索绪尔的观点**
  - 区分了语言和言语这两个不同的概念。
  - 区分了语言的“能指”与“所指”
  - 区分共时性的研究与历时性的研究
    - 指出语言学重点在共时研究。
    - 语言符号的内在性质而不是演变过程
  - 指出语言是一个系统，它有自己固有的秩序。

现代语言学：索绪尔的奠基工作

- 语言和言语
  - 言语：指说话这种行为和说出来的具体的话
    - a.具有个人特点，丰富多彩（嗓音、用词等）。
    - b.说话所用的词语和规则是全社会共有的、是语言的具体应用
  - 语言：是从言语中概括出来的各言语要素的综合，是约定俗成的体系，有统一的语法规则和语音习惯，具有社会性。
- 两者关系：个别和一般的关系。言语是对语言的具体运用，没有语言也就没有言语；另一方面，语言也不能脱离言语，语言存在与言语之中，而言语是语言的存在形式。

现代语言学：索绪尔的奠基工作

- 语言和言语
  - 语言是一种工具，是一种规则；言语是人们利用这一工具和规则而产生的结果。
  - 语言是言语活动中同一社会群体共同掌握的，约定俗成的，有规律可循而又成系统的部分。
  - 言语是言语活动中去除语言部分所剩余的部分，是言语活动中个别的特殊的部分，具有个人特色
  - 语言体现在言语中，没有言语就无法体会语言；
  - 言语作品是无限的；语言规则是从言语作品中归纳出来的，是有限的。

现代语言学：索绪尔的奠基工作

- 区分语言和言语的意义：
  - 把语言作为语言学的研究对象：从言语中找出规则。
  - 有助于认清语言的客观存在，在语言研究中分清主要和次要；
  - 对语言的规范化也具有重要的意义。

现代语言学：索绪尔的奠基工作

- 研究语言系统的一个性质：符号性

语言的符号性

符号、能指、所指

用甲事物代表乙事物，而甲乙两事物之间没有必然的联系，甲事物就是代表乙事物的符号。甲事物就是符号的能指（形式），乙事物就是符号的所指（内容、意义）。

现代语言学：索绪尔的奠基工作

- **语言符号的性质：语言符号是音义结合的统一体。**
  - 语言是由语音和意义两个方面统一构成
    - 语音是语言的物质外壳，是语言的存在形式；
    - 意义是语言的内容。
  - 语音和意义在具体的语言中统一于一体的
    - 密不可分，二者互为存在条件
  - 语言符号的音义结合是社会约定俗成的。

现代语言学：索绪尔的奠基工作

- 语言符号的特点
  - 任意性：约定俗成
  - 线性：书写、口述、理解，都有先后过程
  - 稳定性：短期、局部
  - 渐变性：长期、全局
  - 社会性
    - 后来学者的观点
    - （不是索绪尔关心的，为什么）

现代语言学：索绪尔的奠基工作

- 语言符号的特点：任意性
  - 所指与能指联系具有任意性；
  - 很多语言学家认为是语音和语义结合的任意性。
    - Q：为何不说文字和语言语义的联系也是任意的?
  - 并不意味着用什么声音表示什么意义，对使用者来说是随意的，不受制约的。
  - 事实上，语言符号具有强制性，每个人都要遵守社会的约定俗成，不能任意的改变，否则就无法交际。

现代语言学：索绪尔的奠基工作

- 语言符号的特点：线性
  - 体现在具体的言语（交际过程）中。
  - 不管你要表述的思想感情是简单的，还是复杂的，语言符号都只能一个一个地按次序出现
  - 使离散的语言符号得以构成大大小小的音义结合体，可以使单个的语言符号组合成连续的语流。
  - 用“棋、下、有、一、完、没、的、盘”这八个词组成句子，看能组合成多少句子？
  - 答：一盘没有下完的棋、没有下完的一盘棋、没有一盘下完的棋、没下完的棋有一盘、下完的棋一盘没有、下完的棋没有一盘、有一盘没下完的棋、有没下完的一盘棋、棋没下完的有一盘、棋有一盘没下完……

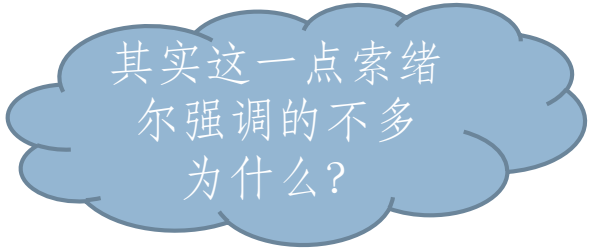
语言的社会性：交际工具

1. 语言是社会现象

- 语言只存在于社会之中，离开了社会就没有语言
- 社会依赖语言而得到维系。
- 语言为人类所独有，既有传承性又有习得性。
- 语言是社会的产物，既要以稳定的形式为社会服务，又要适合社会不断发展的需要。

2. 语言是一种特殊的社会现象。

- 语言是全民的交际工具。
- 语言既不属于经济基础，也不属于上层建筑。



现代语言学：索绪尔的奠基工作

- 语言系统的2种基本关系：组合聚合

  - 1.组合关系
  - 若干较小的语言单位组合成较大的语言单位，其构成成分之间的关系就是组合关系，又称线性序列关系。

老师	分析	课文
小王	讲	故事
李明	写	文章
我	看	电视
他	学	英语



现代语言学：索绪尔的奠基工作

- 语言系统：2种基本关系

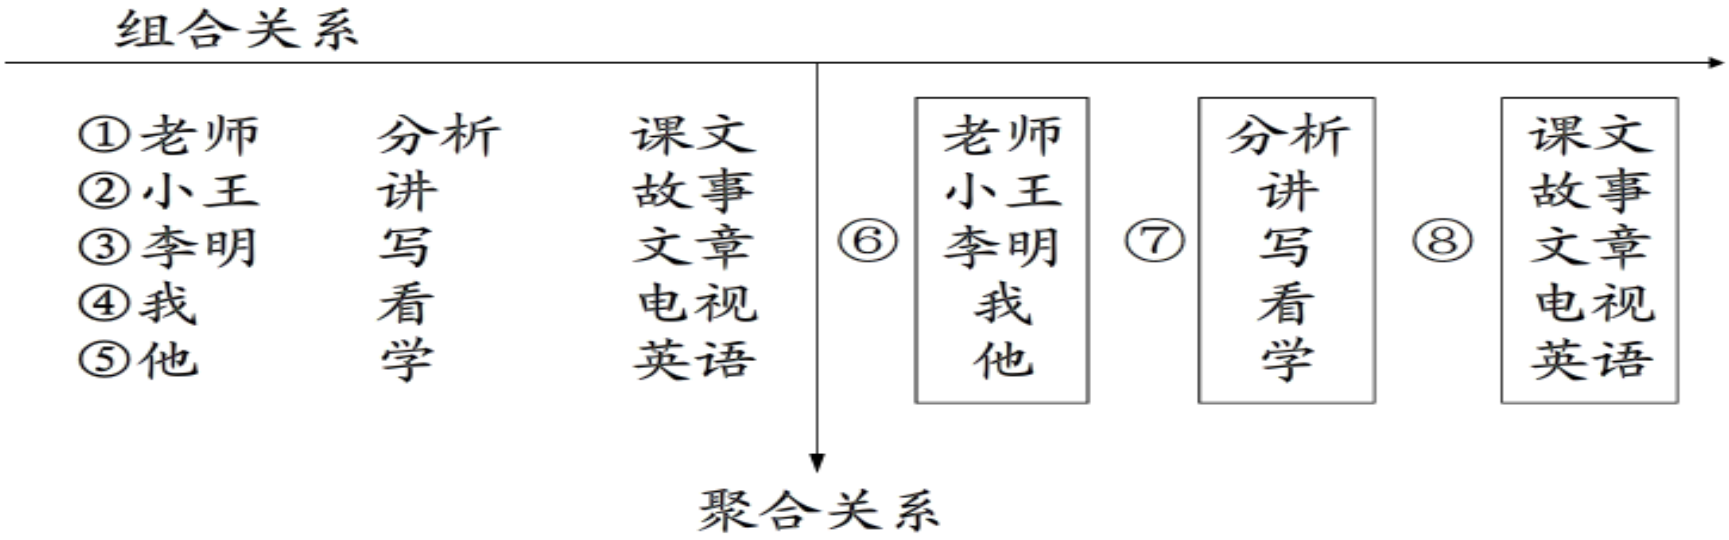
2.聚合关系

- 具有相同组合功能的语言单位之间的关系，就是聚合关系，又称联想关系。聚合关系专指那些具有替换关系的语言单位之间的关系。

老师	分析	课文
小王	讲	故事
李明	写	文章
我	看	电视
他	学	英语

现代语言学：索绪尔的奠基工作

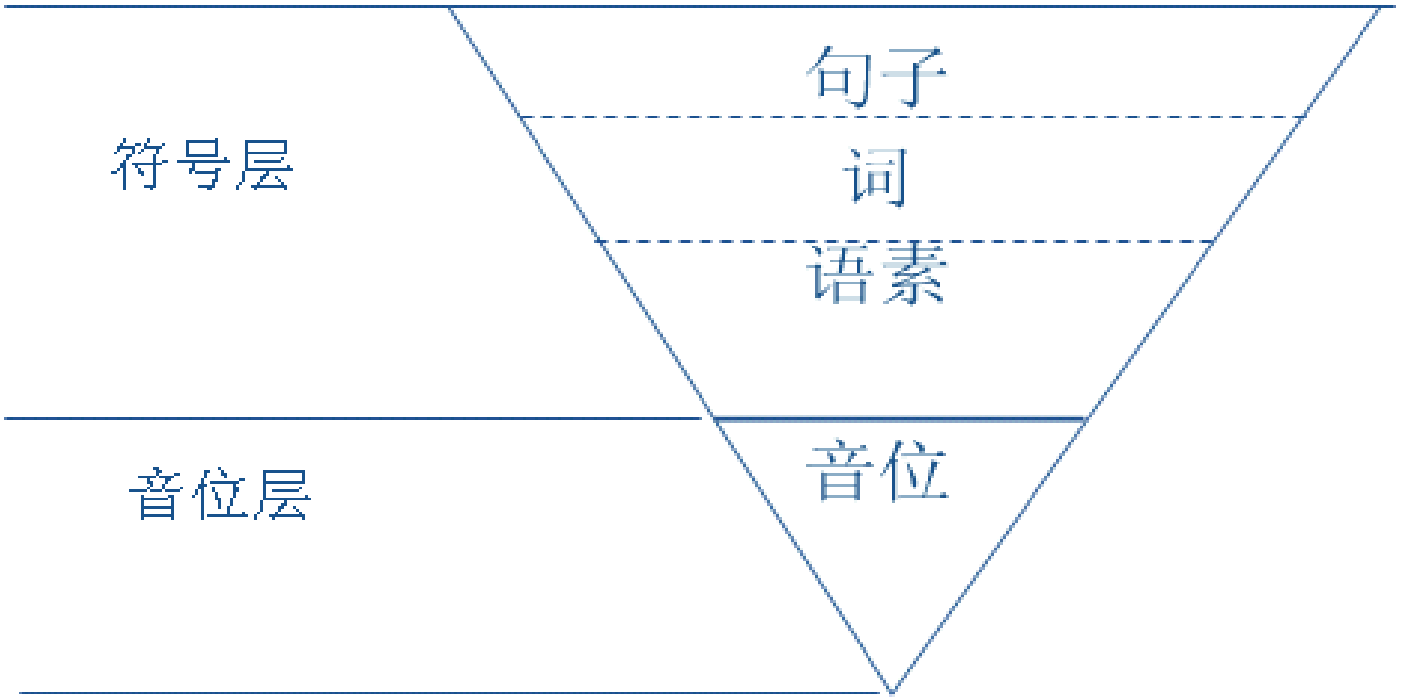
- 语言系统：2种基本关系



- 语言的组合关系和聚合关系是语言的两种根本关系，是语言系统的纲，把握了这个纲，就基本上把握了语言系统。

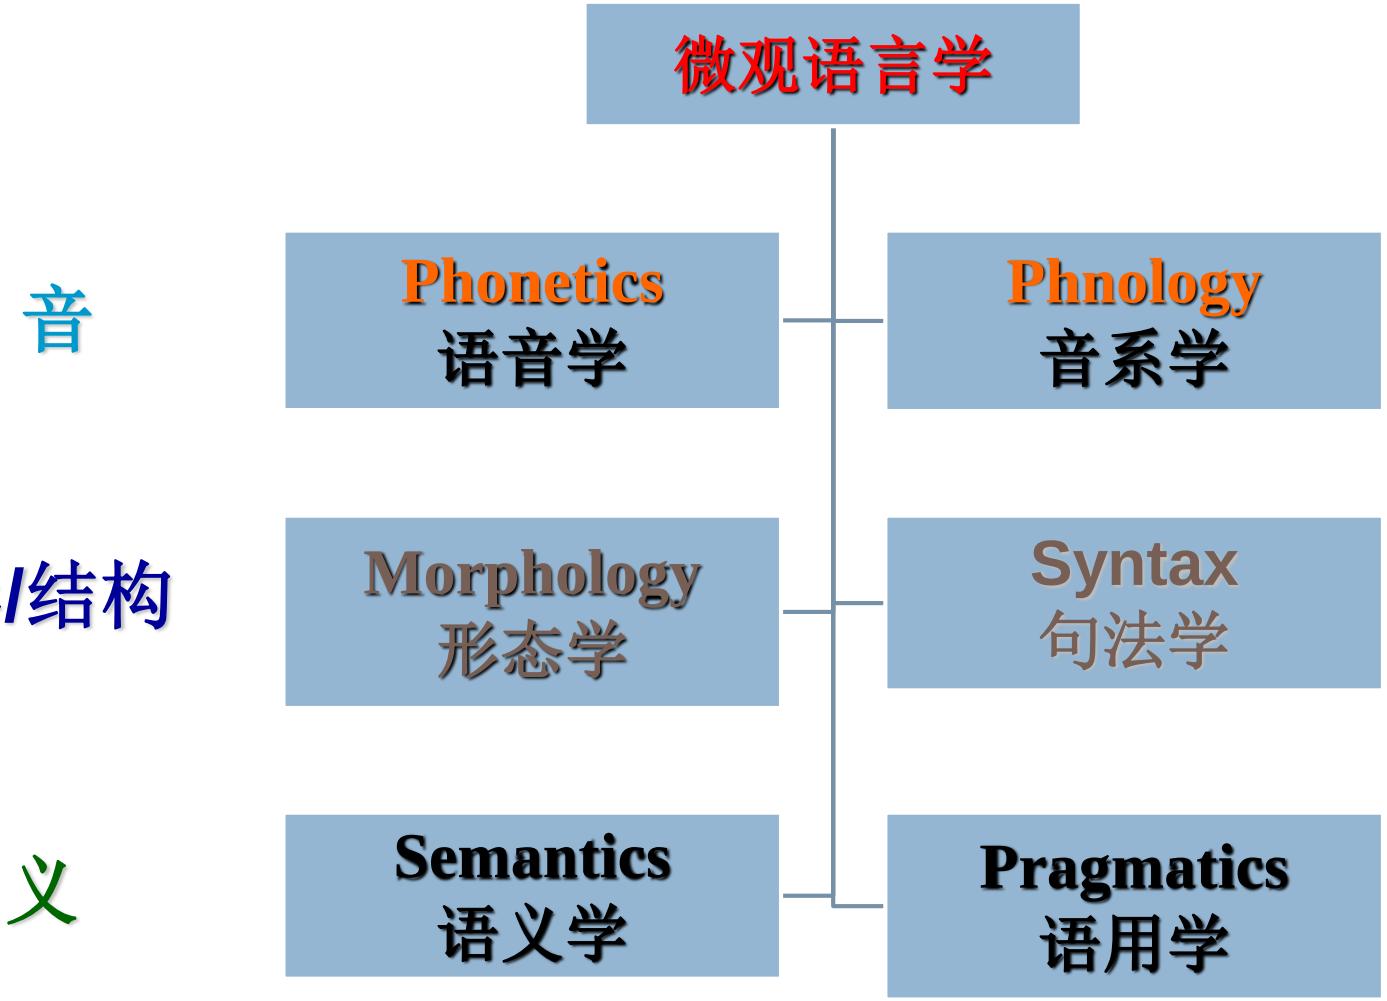
现代语言学：索绪尔的奠基工作

- 语言系统：层级体系—组合关系带来的结果



现代语言学分支

- Micro-linguistics, or Intra-linguistics



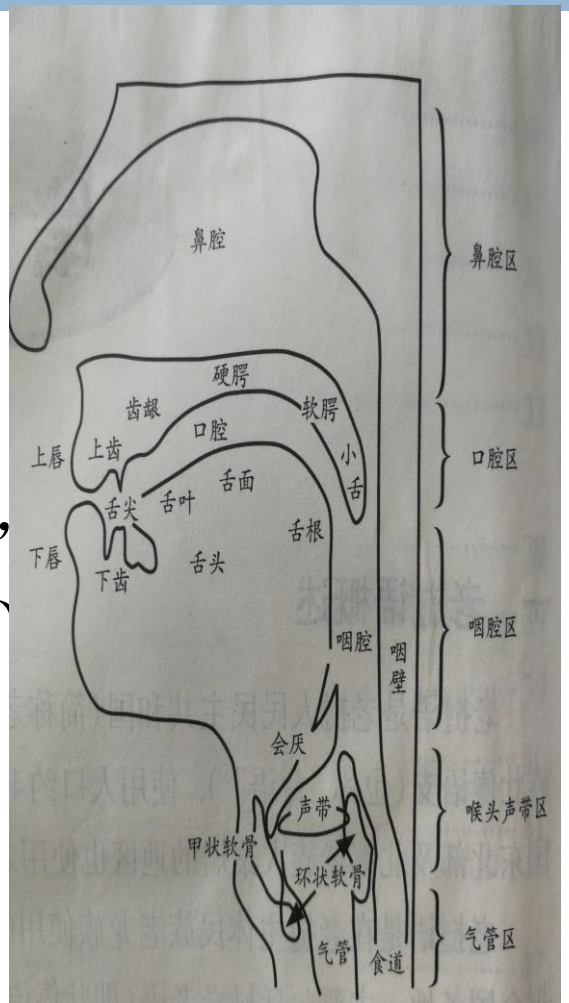
语音学

- 语音的物理性质
  - 音高、音强、音长、音色叫做声音的四要素，也是语音的四要素。

声音要素	含义	决定因素	发音中的影响因素	能够区别意义
音高	声音的高低	频率	声带的长短、厚薄、松紧	声调：妈、麻、马、骂 语调：他不来。他不来?
音强	声音的强弱	振幅	用力大小、呼出气流量大小	轻重音：content(重音在前，名词“内容”，居中为形容词“满意的”)
音长	声音的长短	时间		pull（“拖”短音）与pool（“水池”长音）
音色	声音的特色	声波形式	发音体、发音方法、共鸣器	f—v g—h

语音学

- 语音的生理基础
  - 人的发音器官是一条由肺部一直延伸到唇、鼻的形状复杂的“管道”。它由三部分组成：发音的动力源、发音体、共鸣腔。
  - 主动的发音器官：在人类的发音器官中，有些是能够活动的，如唇、舌头、软腭、小舌、下腭和声带等
  - 被动的发音器官：有些不能活动，如上齿、齿龈、硬腭等



发音器官纵侧面示意图

语音学

- 音标
  - 目前国际上最通行的是“国际音标”
  - 国际语音协会与1888年指定并开始使用的，后经多次修改，最近一次在1989年。
  - 大多采用拉丁字母及其大小写、手写体、变形等代表不同的音素，这点跟字母是完全不同的。
  - 国际音标中共有20个元音音素和28个辅音音素。

音系学

- Phonology studies the rules governing the structure, distribution, and sequencing of speech sounds and the shape of syllables. It deals with the sound system of a language by treating phoneme as the point of departure.
- 语音如何区别和表达意义

音系学

- 音素（phone）
  - 根据音质不同对一串语音不断加以切分，直到不能再分，这样得到的语音单位就是“音素”。
  - 比如汉语“lekailehua（乐开了花）”，往下切分可以得到：l、e、k、a、i 、 l、e、h、u、a共10个单位，从音质角度看，它们已经是最小的单位了，每一个单位都只体现为一个发音定位。所以，“音素”可以看作是从音质角度划分出来的最小的语音单位。
  - 音素可以分为元音和辅音。

音系学

- 音位（phoneme）
  - 区别意义的一组语言特征集合
  - 音系学的基本单位
  - 因素强调语音的差异，音位强调意义的差别
- 音位变体（allophone）
  - 同一音位在不同环境下的实现方式



语法、语义和语用

- 词法：词内部结构，包括语素和构词法
  - 英语的词尾曲折变化
- 句法：句子结构
- 语义：不同语言单元中的意义及其构成
- 语用：在具体场景下语言的使用
  - 固定的语义在不同情况下引起的主观感受

语言学分支

- Macro-linguistics, or Inter-linguistics
  - 社会语言学
  - 心理语言学
  - 神经语言学
- 应用语言学：另一种考虑维度
  - 计算语言学
  - 语言习得
  - 语言教学与语言测试
- 其他：历史语言学、对比语言学....