2 自然语言处理

基础理论

杨沐昀

哈尔滨工业大学计算学部
语言技术研究中心

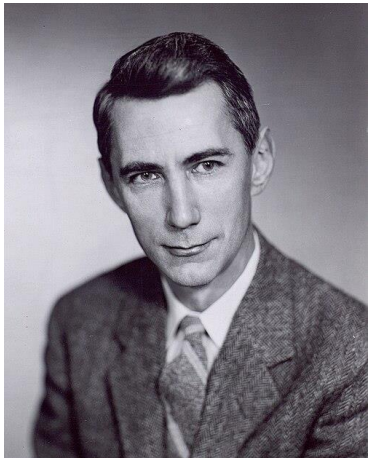
yangmuyun@hit.edu.cn

主要内容

- 信息论
- 机器学习概述
- 小结

信息论

- 信息论（Information Theory） 由克劳德·香农提出，是一门研究信息的度量、表示与传递的学科。



- 在自然语言处理领域，信息论方法在模型评估、训练优化和特征选择等方面发挥了至关重要的作用。

- 语言本身可以被视为一种信息的载体，而信息论为我们提供了一种定量化的手段，用以分析和理解语言的“不确定性”

熵

- 熵（Entropy）是信息论中核心概念之一，用于度量单个随机变量在所有可能取值上的平均不确定性。

- 给定一个离散型随机变量 X 以及其概率分布 $p(x)$，熵定义：

$$H(X) = -\sum_{x \in \mathcal{X}} p(x) log p(x)$$

  - $\mathcal{X}$ 表示随机变量 X 的所有可能取值空间
  - $p(x)$ 是表示离散变量$X = x$ 的概率
  - log 通常指以 2或以 e 为底。在信息论中，以 2 为底，单位是比特（bit），以 e 为底，则单位是纳特（nat）。

熵

- 一个离散型随机变量 X 以及其概率分布 $p(x)$，其熵：

$$H(X) = -\sum_{x \in \mathcal{X}} p(x) log p(x)$$

  - 当随机变量 X的分布越均匀，熵会越大；当X 的分布被某一个或少数几个取值主导，熵会较小。
  - 在极端情况下，如果 X 只可能取一个固定值，即，对某个 x，$p(x) = 1$ ，则它完全没有不确定性，熵为 0 。
    - 参阅教材图2-1：伯努利随机变量的熵（P29）

联合熵

- 联合熵（Joint Entropy）用于度量多个随机变量同时出现时所包含的总不确定性。以两个离散随机变量 X 和 Y同时出现为例，其联合熵定义为：

$$H(X,Y) = -\sum_{x\in\mathcal{X}} \sum_{y\in\mathcal{Y}} p(x,y)\log p(x,y)$$

  - 其中，$\mathcal{X}$ 和 $\mathcal{Y}$ 分别是随机变量 X 和 Y 的取值空间；$p(x,y)$ 表示二元事件 $(X=x, Y=y)$ 的联合概率。

联合熵

- 与单个随机变量的熵 $H(X)$ 或 $H(Y)$ 不同，联合熵 $H(X,Y)$ 描述了在同时考虑 X 和 Y 的所有可能取值时，系统所具有的不确定性 。

- 当 X 和 Y 相互独立时，$p(x,y)=p(x)p(y)$ ，可以推出：

$$H(X,Y) = H(X) + H(Y)$$

- 这意味着在独立情形下，各随机变量的熵可简单叠加。如果 X 和 Y 之间存在依赖关系，则联合熵会小于它们单独熵之和，因为知道 X 的信息可能会部分减少对 Y 的不确定性，反之亦然。

条件熵

- 条件熵（Conditional Entropy）是度量在已知随机变量 X 的值之后，随机变量 Y 还具有多少不确定性。

- 换言之，条件熵提供了一个量化指标，用于衡量在给定 X 的前提下，确定 Y 值所需的额外信息量。

- 从信息传递的角度来看，条件熵揭示了信息从 X 到 Y 之间的“不确定性”在多大程度上能够被已知的 X 所减少。

条件熵

- 以两个离散随机变量 X 和 Y同时出现为例，其条件熵定义为：

$$H(Y \mid X) = \sum_{x \in \mathcal{X}} p(x) H(Y|X = x)$$

$$= \sum_{x \in \mathcal{X}} p(x) \left(- \sum_{y \in \mathcal{Y}} p(y \mid x) \log p(y \mid x) \right)$$

$$= - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x) p(y \mid x) \log p(y \mid x)$$

  - 其中，$\mathcal{X}$ 和 $\mathcal{Y}$ 分别表示随机变量 X 和 Y 的取值空间；$p(x)$ 表示随机变量$X = x$ 的概率；$p(y \mid x)$ 表示在 $X = x$ 的前提下，$Y = y$ 的条件概率;
  - 而$p(x, y)$则表示 $X = x$，$Y = y$ 的联合概率

条件熵

- 已知条件概率 $p(y \mid x) = \frac{p(x,y)}{p(x)}$，可以对上页公式进行代换，具体过程如下：

$$H(Y \mid X) = -\sum_{x \in X} \sum_{y \in Y} p(x,y) \log p(y \mid x)$$

$$= -\sum_{x \in X} \sum_{y \in Y} p(x,y)[\log p(x,y) - \log p(x)]$$

$$= -\sum_{x \in X} \sum_{y \in Y} p(x,y) \log p(x,y) + \sum_{x \in X} \sum_{y \in Y} p(x,y) \log p(x)$$

上述过程中利用了对数的性质：

$$\log\left(\frac{p(x,y)}{p(x)}\right) = \log p(x,y) - \log p(x)$$

条件熵

- 继续观察第二个求和项 $+\Sigma_{x\in X}\ \Sigma_{y\in Y}\ p(x,y)\log p(x)$，由于对每个给定的 x，$\sum_{y\in Y}\ p(x,y)=p(x)$，可以将它简化为：

$$\sum_{x\in X}\sum_{y\in Y}p(x,y)\log p(x)=\sum_{x\in X}\left[\log p(x)\sum_{y\in Y}p(x,y)\right]$$

$$=\sum_{x\in X}p(x)\log p(x)$$

- 于是有，

$$H(Y\mid X)=-\sum_{x\in X}\sum_{y\in Y}p(x,y)\log p(x,y)+\sum_{x\in X}p(x)\log p(x)$$

由熵和联合熵的定义，可得：

$$H(Y\mid X)=\ H(X,Y)-\ H(X)$$

条件熵

- 条件熵：

$$H(Y \mid X) = H(X,Y) - H(X)$$

  - 结合以上定义，若随机变量 Y 对 X 具有高度依赖性，即 Y 在很大程度上由 X决定，则条件熵 H(Y | X) 将显著降低，表明 Y 的不确定性在已知 X 的情况下被大幅度减少。

  - 若随机变量 X 与 Y 相互独立，则条件熵 H(Y | X)等于 Y 的熵 H(Y)，这表明 X 对于减少 Y 的不确定性没有提供任何额外信息。

交叉熵

- 交叉熵（Cross Entropy）是一种衡量模型预测概率分布与真实概率分布之间差异情况的指标。
- 假设随机变量 X 真实分布 $X \sim p(x)$，将模型对X的预测分布记作 $Y \sim q(x)$，那么，真实分布和预测分布的交叉熵定义为：

$$H(p,q) = -\sum_x p(x)\log q(x)$$

  - 其中交叉熵则衡量了目标分布 $p(x)$ 和模型预测分布 $q(x)$ 之间的分布差异。

相对熵

- 相对熵，也称Kullback-Leibler 散度（以下简称KL散度），是一种非对称度量，用于衡量两个概率分布$p(x)$ 和 $q(x)$ 之间的相对差异，表示预测分布$q(x)$对真实分布$p(x)$的偏离程度。其定义为：

$$D_{KL}(p \parallel q) = \sum_{x \in X} p(x) \log \frac{p(x)}{q(x)}$$

  - 当 $p(x)=q(x)$ 时，$D_{KL}(p \parallel q) = 0$ ，表示预测分布与真实分布完全一致，没有任何信息偏离。

相对熵

- KL散度公式展开后可表示为：

$$D_{KL}(p \parallel q) = \sum_{x \in X} p(x) \log p(x) - \sum_{x \in X} p(x) \log q(x)$$

- 由熵的定义和交叉熵的定义，可将上式分解为两部分：
  - 其中第一部分的负数 $-\sum_{x \in X} p(x) \log p(x)$为真实分布$p(x)$的熵 $H(p)$

$$H(p) = -\sum_{x \in X} p(x) \log p(x)$$

  - 而第二部分 $-\sum_{x \in X} p(x) \log q(x)$为交叉熵 $H(p, q)$ ：

$$H(p, q) = -\sum_{x \in X} p(x) \log q(x)$$

相对熵

- 因此，KL 散度又可以表示为：

$$D_{KL}(p \parallel q) = H(p,q) - H(p)$$

  - 由上述公式，KL散度表示预测分布 $q(x)$ 偏离真实分布 $p(x)$ 所带来的额外成本。

  - 交叉熵 $H(p,q)=H(p)+D_KL\ (p \parallel q)$ 则可以看作包含真实熵 $H(p)$ 和相对差异 $D_KL\ (p \parallel q)$的综合度量。

困惑度

- 困惑度（Perplexity）可以用来衡量一个分布的不确定性，也可以用来衡量两个分布之间的差异，常用于衡量概率分布预测的效果。

- 假设随机变量 X 真实分布为$p(x)$, 模型预测分布为$q(x)$，那么，真实分布和预测分布的困惑度定义：

$$\text{Perplexity}(p,q) = 2^{-\sum_{x \in X} p(x) \log q(x)}$$

困惑度

- 根据交叉熵的定义，困惑度公式可改写为：

$$\text{Perplexity}(p,q) = 2^{H(p,q)}$$

  - 可以观察到，两个分布之间的困惑度与交叉熵密切相关，是交叉熵的指数形式。

- 根据KL散度推导出的公式$D_{KL}(p \parallel q) = H(p,q) - H(p)$，可以将上式进一步分解得到：

$$\text{Perplexity}(p,q) = 2^{H(p)} \cdot 2^{D_{KL}(p\|q)}$$

  - 因此困惑度同时包含了真实熵$H(p)$和相对熵$D_KL\ (p \parallel q)$两部分信息。

困惑度

- 为了更直观地理解困惑度的概念，我们以下面一个简单的语言模型为例进行说明。

- 假设我们有一个小型数据集，仅包含以下两句话：
  - “我 喜欢 学习。”
  - “我 喜欢 玩耍。”

困惑度

- 基于此数据集，可以构建一个简单的统计语言模型，用于根据前一个单词预测下一个单词的概率分布。

- 为了简化计算，仅考虑以下两个上下文的概率分布。

- 在训练语料中，“我”后面总是出现“喜欢”，因此在此数据集中单词“我”后的下一个单词为“喜欢”，模型预测概率为 $P($ 喜欢 $|$ 我 $)=1$

困惑度

- 而单词“喜欢”后面可能是“学习” 或“玩耍”，且两者出现的频率相同。

- 因此，单词“喜欢”后的下一个单词可能是“学习”，也可能是“玩耍”，预测概率分别为$P(\text{" 学习 "} \mid \text{" 喜欢 "})=0.5$和$P(\text{" 编程 "} \mid \text{" 喜欢 "})=0.5$。

困惑度

- 基于上述语言模型，可以对句子“我 喜欢 学习”进行预测，并计算其困惑度：

（1）预测“喜欢”的概率：在上下文出现单词“我”的条件下，模型预测“喜欢”的概率为 P（喜欢 | 我)=1 。由于预测是完全确定的，这一步预测熵为：

$$-\log_2(1) = 0$$

困惑度

- 基于上述语言模型，可以对句子“我 喜欢 学习”进行预测，并计算其困惑度：

（2）预测“学习”的概率：在上下文出现单词“喜欢”的条件下，模型预测“学习”和“编程”的概率均为 0.5。因此，当实际出现“学习”时，这一步的预测熵为：

$$-\log_2(0.5) = 1$$

困惑度

- 基于上述语言模型，可以对句子“我 喜欢 学习”进行预测，并计算其困惑度：

（3）计算平均熵：对于整句“我 喜欢 学习”，平均熵为两个单词预测的熵的平均值：

$$H(P) = \frac{0+1}{2} = 0.5$$

（4）计算困惑度：困惑度是平均熵的指数形式，即：

$$\text{Perplexity}(P) = 2^{H(P)} = 2^{0.5} \approx 1.414$$

主要内容

- 信息论
- 机器学习概述
- 小结

机器学习定义

- 什么是学习?
- “学习是系统通过经验提升性能的过程。

--- Herbert Simon

卡内基·梅隆大学

图灵奖(1975)

人工智能，人类认知心理学

诺贝尔经济学奖(1978)

经济组织内的决策过程



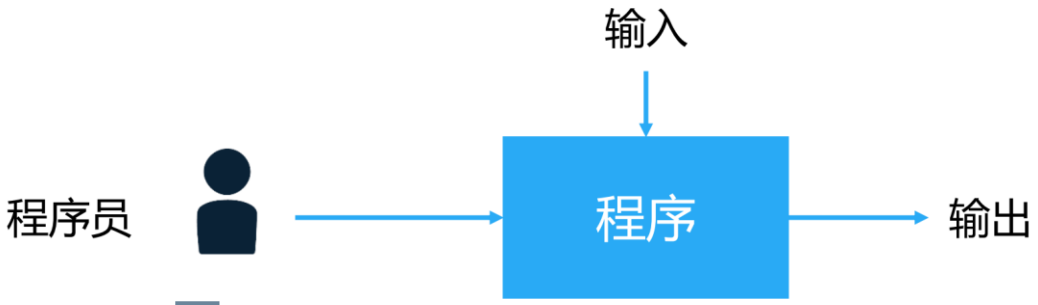
机器学习定义

- 什么是机器学习?
- 由Tom Mitchell 给出的更加数学化的定义:
  - 机器学习是一门研究学习算法的学科，这些算法能够:
    - 在某些任务 T 上
    - 通过经验 E
    - 提升性能 P
    - 非显式编程
  - 一个学习任务可以由三元组<T,E,P>明确定义

机器学习

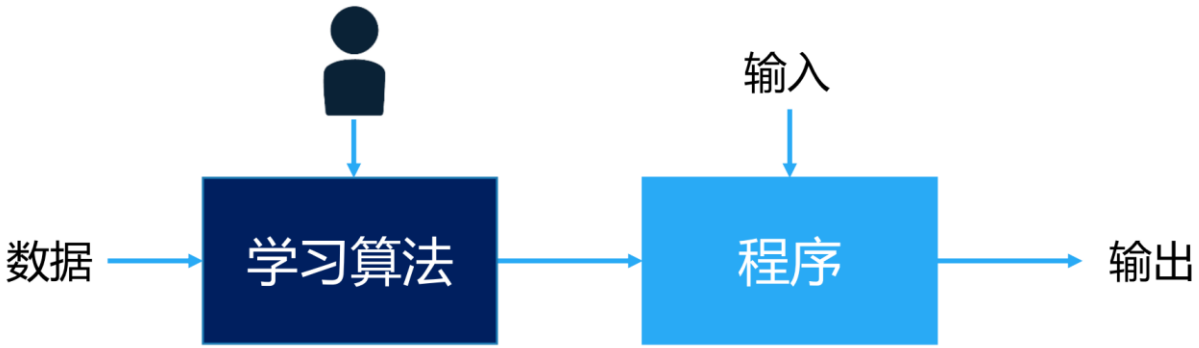


- 传统编程



- 机器学习方法

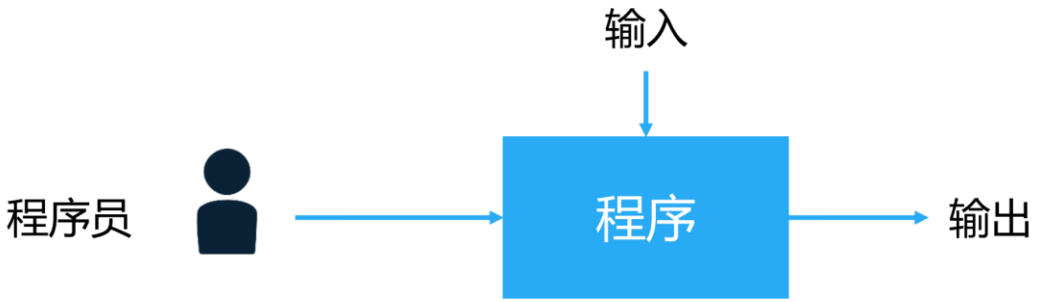
可否写这样的程序?



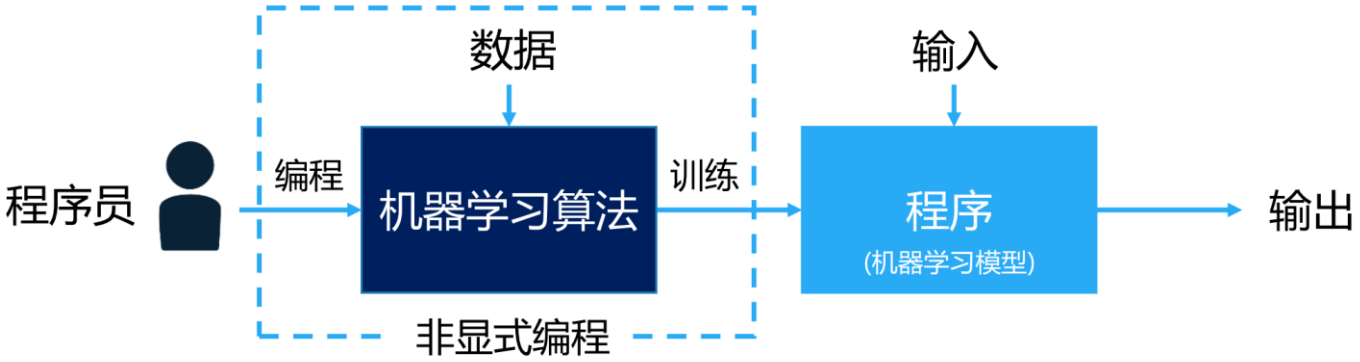
机器学习



- 传统编程



- 机器学习方法



机器学习历史



- 1950年代
  - Samuel 的跳棋程序
  - 创建机器学习术语



Arthur Samuel在1959年创造了"机器学习"这个词

- 1960年代
  - 神经网络，感知机
  - 模式识别
  - Minsky和Papert证明感知机的局限性

- 1970年代
  - 符号概念归纳
  - Winston的结构学习系统
  - 专家系统和知识获取瓶颈
  - Quinlan的ID3算法
  - 使用 AM 的数学发现

机器学习历史



- 1980年代:
  - 高级决策树和规则学习
  - 基于解释的学习 (EBL)
  - 学习、规划、解决问题
  - 三间小屋问题
  - 类比
  - 认知架构
  - 神经网络复苏 (反向传播)
  - Valiant的PAC学习理论
  - 注重实验方法
- 1990年代
  - 数据挖掘
  - 自适应软件代理和网络应用程序
  - 文本学习
  - 强化学习 (RL)
  - 归纳逻辑编程 (ILP)
  - 组合: 装袋、提升和堆叠
  - 贝叶斯网络学习
  - 支持向量机
  - 核方法

机器学习历史



- 2000年代
  - 图模型
  - 变分推理
  - 统计关系学习
  - 迁移学习
  - 序列标记
  - 集体分类和结构化输出
  - 计算机系统应用
  - 电子邮件管理
  - 学习的个性化助手
  - 机器人和视觉的学习
- 2010年代
  - 从大数据中学习
  - 结合知识图谱的机器学习
  - 深度强化学习，AlphaGo •
  - 视觉、语音、文本、网络、行为等的庞大应用 …
- 2020年代
  - 结合逻辑推理的深度学习
  - 超大规模预训练模型（GPT-3等）
  - 生成式模型的爆发（ChatGPT、DALL-E、Diffusion） …

机器学习思想

- 机器学习是人工智能重要的学科，在自然语言处理中发挥重要作用。
- 自然语言处理中涉及的机器学习方法，本章重点介绍的主要包括有：
  - 有监督学习
  - 无监督学习
  - 自监督学习（属于无监督学习）
  - 强化学习

有这样一种观点：机器学习类型

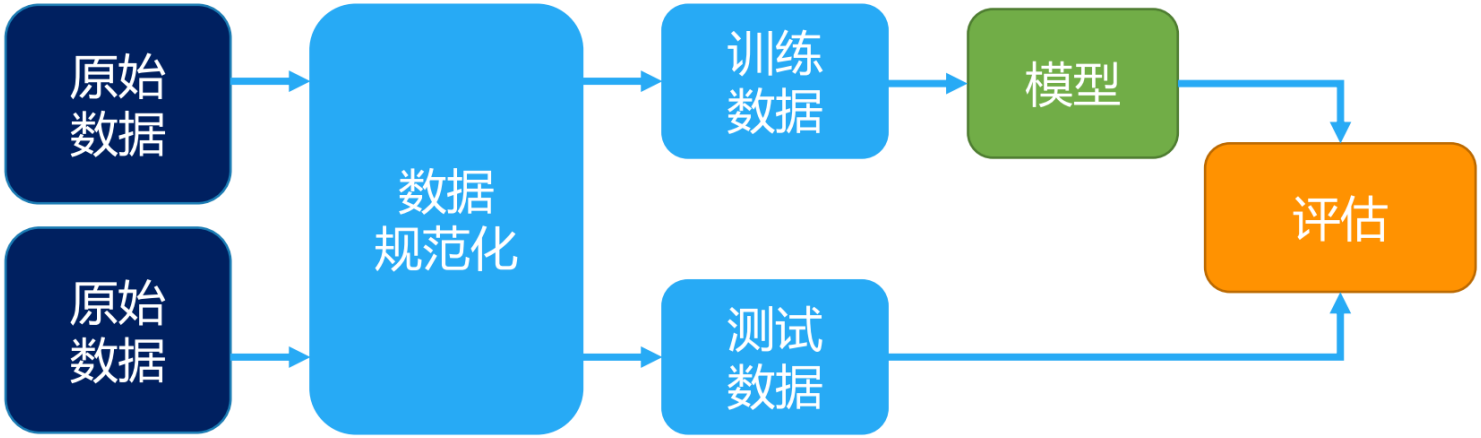
补充材料

- 预测
  - 根据数据预测所需的输出（监督学习）
  - 生成数据实例（无监督学习）
- 决策
  - 在动态环境中采取行动（强化学习）
    - 转变到新的状态
    - 获得即时奖励
    - 随着时间的推移最大化累积奖励

机器学习类别

- 有监督学习
  - 给定数据和标签，预测所需的输出
- 无监督学习
  - 分析和利用隐式数据模式/结构
- 强化学习
  - 学习在动态环境中动作执行的决策，并获得尽可能多的奖励值

机器学习过程



- 基本假设：在训练和测试数据中存在相同的模式（pattern）

有监督学习

- 定义
  - 给定带标签的训练数据集

$$D = \{(x_i, y_i)\}_{i=1,2,\ldots N}$$

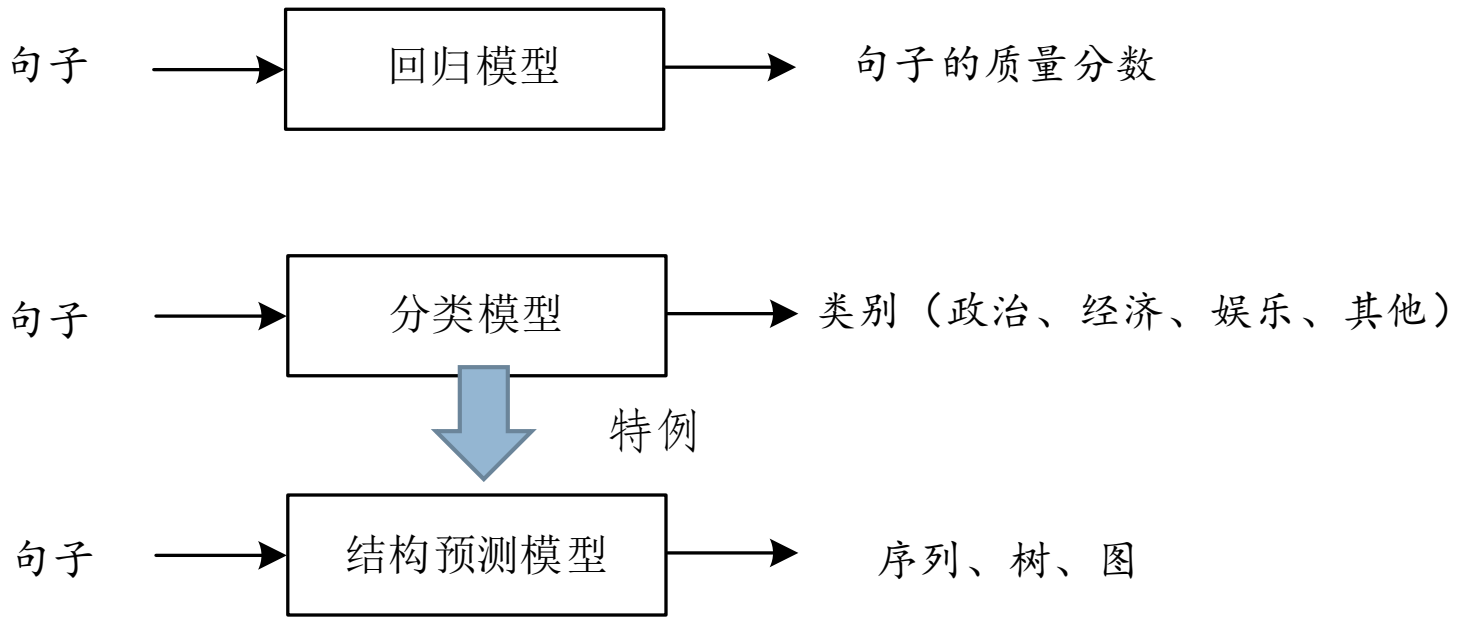
    - 其中x_i为输入样本，y_i为其对应的标签，让机器学习一个从样本映射到标签的函数映射

$$y_i = f_\theta(x_i) \mid y_i = f_\theta(x;\theta\ ); \mid p\,(y|x;\theta)$$

  - 函数集$\{f_\theta(\cdot)\}$被称为假设空间
  - 学习的过程即为参数 θ 的更新

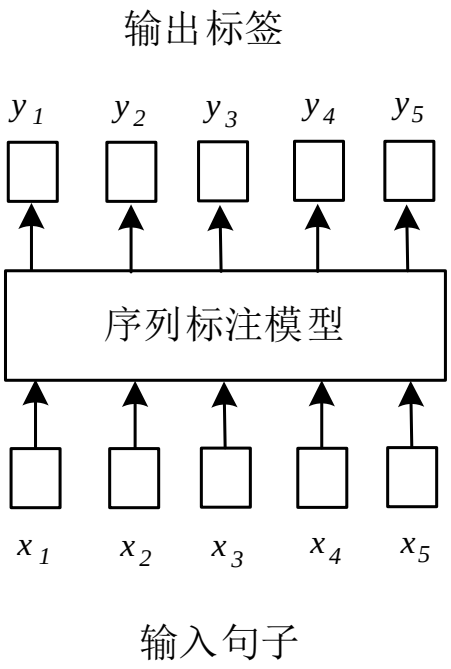
有监督学习

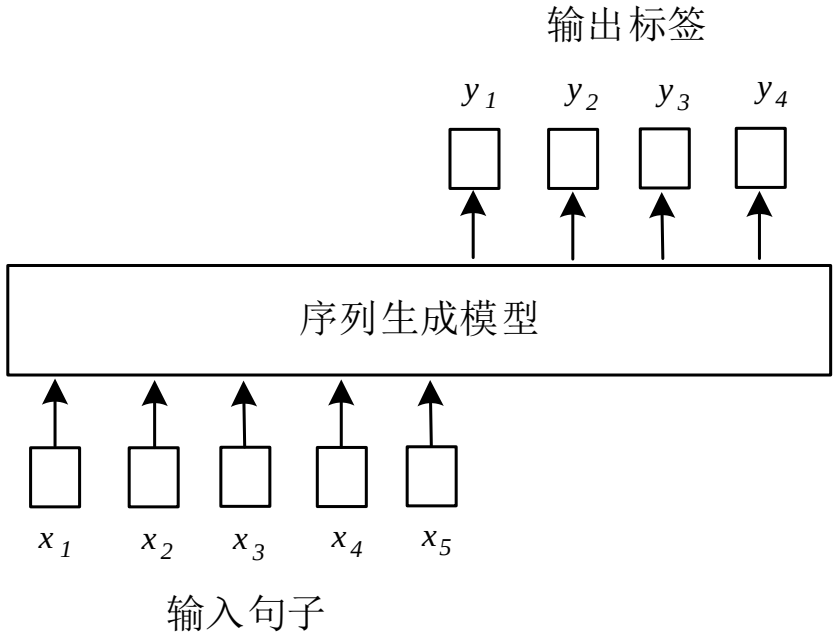
- 根据标签类型y的不同，有监督学习可以分为三种:



有监督学习

- 结构化学习:


输出标签
y_1 y_2 y_3 y_4 y_5
序列标注模型
x_1 x_2 x_3 x_4 x_5
输入句子


输出标签
y_1 y_2 y_3 y_4
序列生成模型
x_1 x_2 x_3 x_4 x_5
输入句子

无监督学习

- 无监督学习（Unsupervised Learning）是从无标签的数据中自动学习有价值的模式或内在规律。

- 与有监督学习不同，无监督学习算法不依赖于人工提供的标签，能够自动发现蕴含在无监督数据中的特征、类别、结构、概率分布等信息。

无监督学习

- 定义
  - 给定训练数据集

$$D = \{x_i\}_{i=1,2,\ldots,N}$$

  - 机器学习数据潜在的模式
    - 隐变量
    - 概率密度表示
    - 好的数据表示（用于分类）

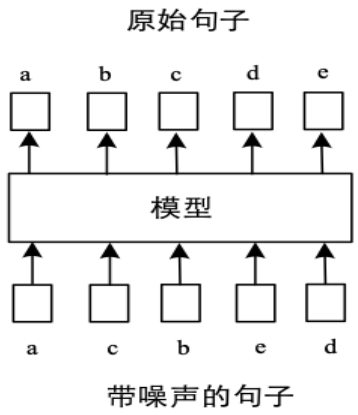
自监督学习

- 严格讲，自监督学习也是一种无监督学习方法 。同样地，自监督模型不依赖于有标注的数据集，它直接从输入数据自身获取监督信号。

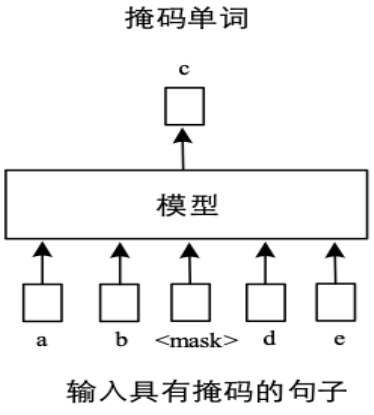
- 自监督学习常见的训练方式有两种：自预测学习和对比学习。通俗地讲，自预测学习的基本思想是“自己学习自己”，对比学习的基本思想为“自己只像自己”。

自监督学习-自预测学习

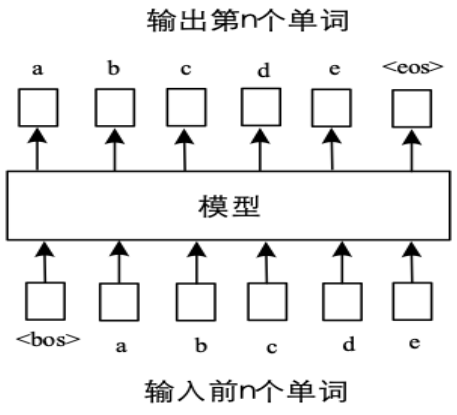
- 自预测学习的基本思想是根据输入的一部分信息预测其他部分信息，常见的自预测策略包括：
  - 去噪自编码器
  - 掩码预测
  - 自回归预测



(a) 去噪自编码器



(b) 掩码预测



(c) 自回归预测

自监督学习-对比学习

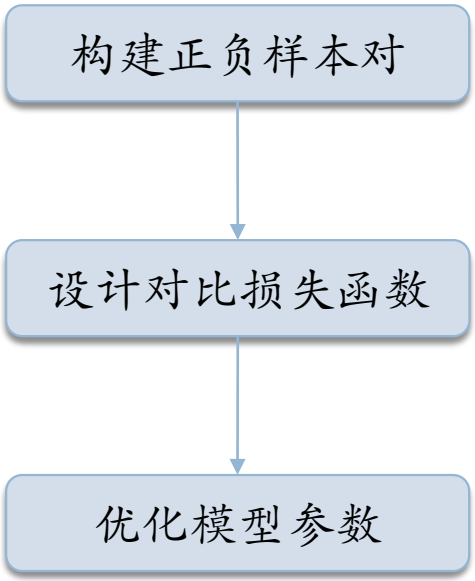
- 对比学习的核心思想是学习一种数据表示，使得相似的样本在特征空间中距离更近，而不相似的样本在特征空间中距离更远。

- 对比学习通过正负样本对训练模型，最小化正样本对间的距离，学习相似样本的共同特征，通过最大化负样本对之间的距离，学习区分不相关的样本。

- 对比学习通过对比正样本与负样本之间的差异学习数据的潜在表征，能够利用大量未标注的数据，无需人工标注。

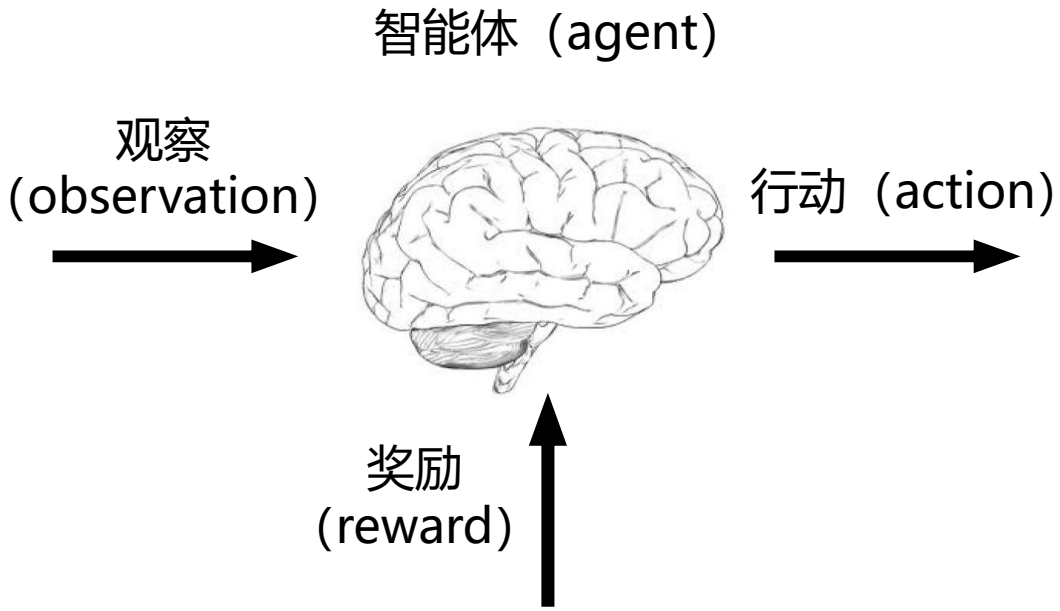
自监督学习-对比学习

- 对比学习的基本过程包括以下三个步骤：



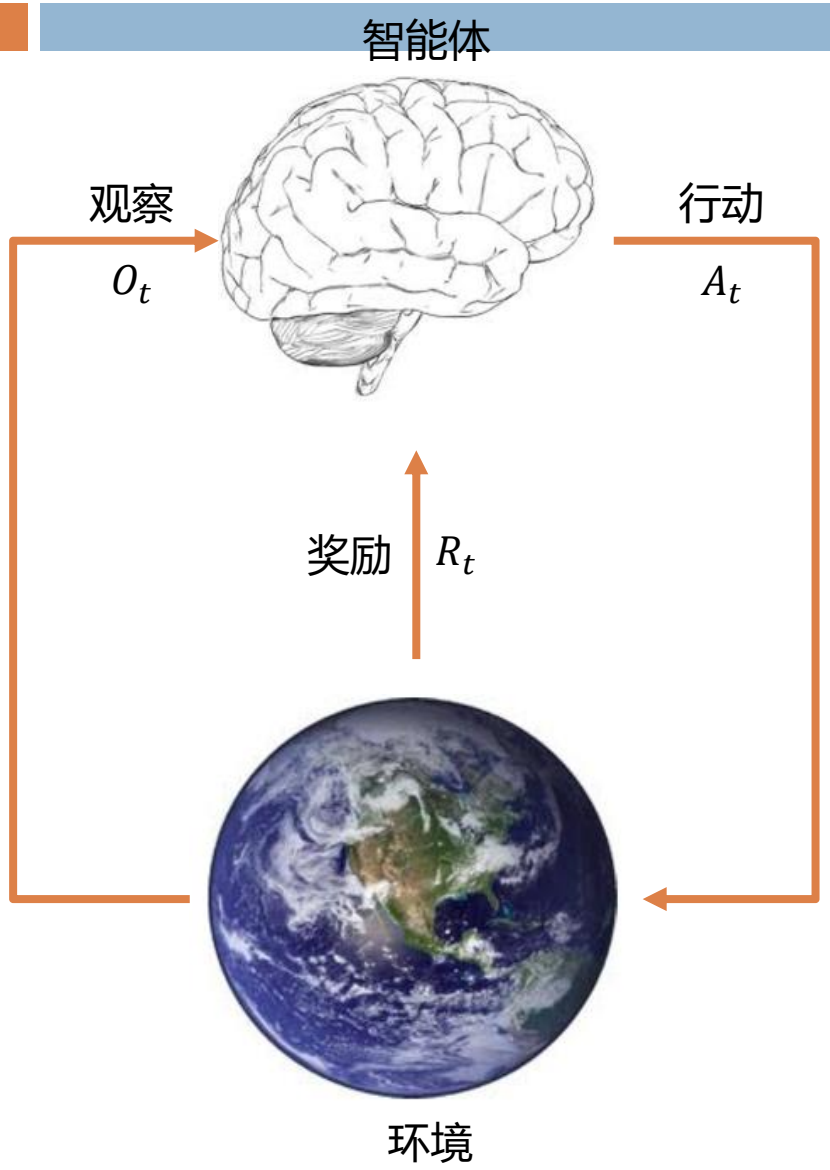
强化学习

- 通过从交互中学习来实现目标的计算方法



- 三个方面：
  - 感知：在某种程度上感知环境的状态
  - 行动：可以采取行动来影响状态或者达到目标
  - 目标：随着时间推移最大化累积奖励

强化学习交互过程



- 在每一步 t，智能体：
  - 获得观察 O_t
  - 获得奖励 R_t
  - 执行行动 A_t
- 环境：
  - 获得行动 A_t
  - 给出观察 O_{t+1}
  - 给出奖励 R_{t+1}
- t 在环境这一步增加

在与动态环境的交互中学习

有监督、无监督学习

Model ⟵



Fixed Data

强化学习

Agent ⟷



Dynamic Environment

Agent不同，交互出的数据也不同！

强化学习要素

- 历史（History）是观察、行动和奖励的序列

$$H_t = O_1, R_1, A_1, O_2, R_2, A_2, \ldots, O_{t-1}, R_{t-1}, A_{t-1}, O_t, R_t$$

  - 即，一直到时间t为止的所有可观测变量
  - 根据这个历史可以决定接下来会发生什么
    - 智能体选择行动
    - 环境选择观察和奖励



- 状态（state）是一种用于确定接下来会发生的事情（行动、观察、奖励）的信息
  - 状态是关于历史的函数　　$S_t = f(H_t)$

强化学习要素

- 策略（Policy）是学习智能体在特定时间的行为方式
  - 是从状态到行动的映射
  - 确定性策略（Deterministic Policy）

$$a = \pi(s)$$

  - 随机策略（Stochastic Policy）

$$\pi(a|s) = P(A_t = a \mid S_t = s)$$



强化学习要素

- 奖励（Reward） $R(s,a)$
  - 一个定义强化学习目标的标量
  - 能立即感知到什么是“好”的
- 价值函数（Value Function）
  - 状态价值是一个标量，用于定义对于长期来说什么是
  - 价值函数是对于未来累积奖励的预测
  - 用于评估在给定的策略下，状态的好坏



$$Q_\pi(s,a) = \mathbb{E}_\pi[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots | S_t = s, A_t = a]$$
$$= \mathbb{E}_\pi[R_{t+1} + \gamma Q_\pi(s', a') | S_t = s, A_t = a]$$

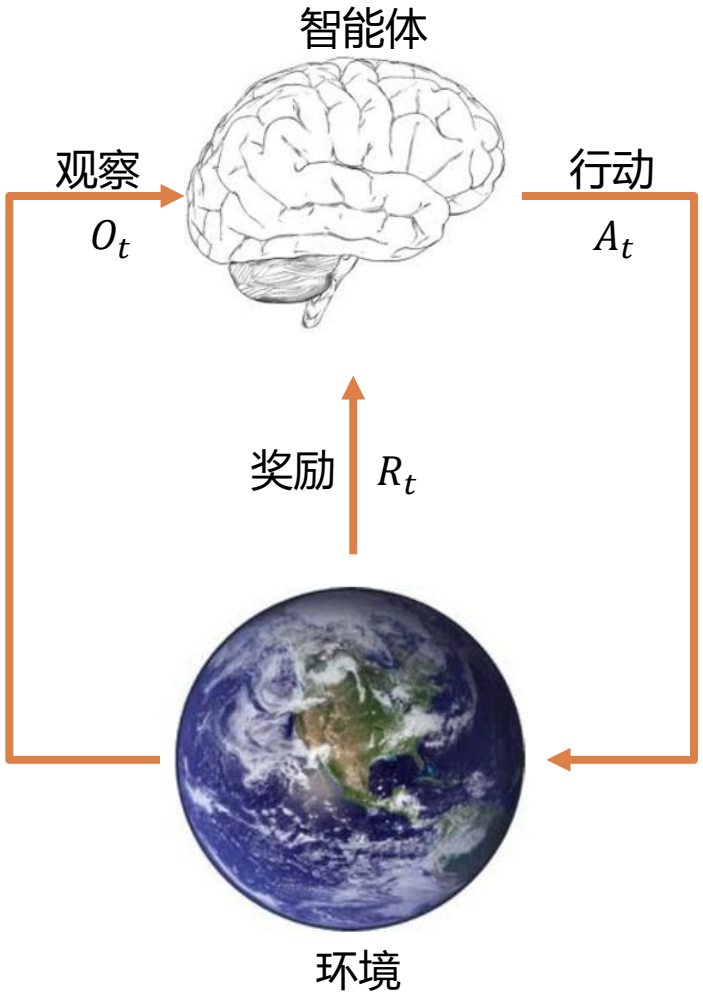
强化学习要素

- 环境的模型（Model）用于模拟环境的行为
  - 预测下一个状态

$$\mathcal{P}_{ss'}^{a} = \mathbb{P}[S_{t+1} = s' | S_t = s, A_t = a]$$

  - 预测下一个（立即）奖励

$$\mathcal{R}_{s}^{a} = \mathbb{E}[R_{t+1} | S_t = s, A_t = a]$$



主要内容

- 信息论
- 机器学习概述
- 小结

小结

- 本章介绍了自然语言处理领域所依赖的基础理论与技术方法，主要为信息论和机器学习的核心概念
- 在信息论中主要介绍了熵、条件熵、交叉熵、困惑度等概念
- 在机器学习一节，则主要介绍了有监督学习、无监督学习、自监督学习、强化学习

课后习题

- 习题1：请简述困惑度的意义以及它与交叉熵的关系。

- 习题2：如果一个语言模型的困惑度逐渐趋近于词汇表大小，结合模型的预测概率分布，推测可能发生了什么问题？如何改进？

- 习题3：分别收集尽量多的英语和汉语文本，编写程序计算这些文本中英语字母和汉字的熵。

课后习题

- 习题4：根据本章内容设计并实现一种算法，计算任意两个句子之间的相似性。

- 习题5：简述自然语言处理任务中常见的机器学习任务有哪些？它们之间有什么区别？

教材中的问题：

2.2中机器学习分类成四类（有监督学习、无监督学习、自监督学习和强化学习）讲述感觉并不是并列关系，而且无监督学习无具体实例。

第二章整体可能图少一些，可能简介居多没有什么需要图文并茂的。