自然语言处理

第三章：自然语言的统计建模与经典技术

杨沐昀

哈尔滨工业大学计算学部
语言技术研究中心

yangmuyun@hit.edu.cn

主要内容

- 统计语言模型
- 自然语言处理的经典技术
- 自然语言处理的典型应用

统计语言模型的重要性

核心地位

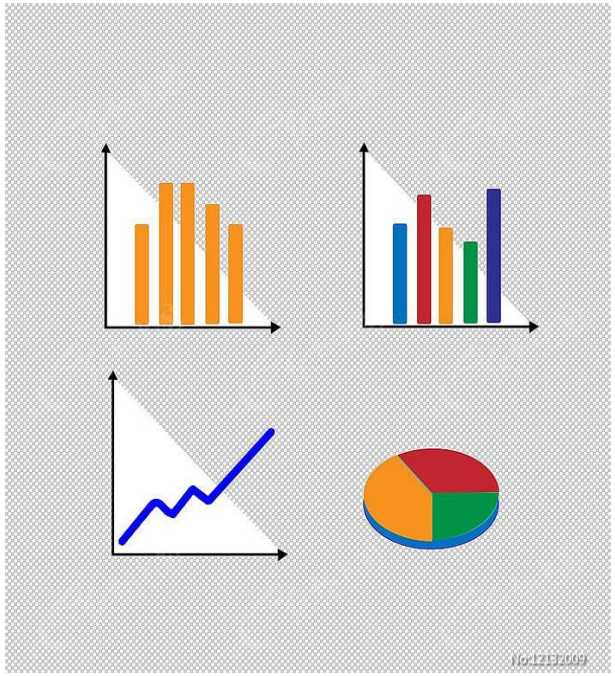
它为语言的建模提供了基础框架，能够有效处理语言的概率特性。

实际应用广泛

统计语言模型在机器翻译、语音识别、文本生成等实际场景中被广泛应用。

与前沿技术的联系

许多前沿NLP技术的核心理念与统计方法紧密相连。



统计语言模型

- 什么是统计语言模型
  - 定义：计算句子或词汇序列出现概率的模型
    - $P(w_1, \dots, w_l)$，$P(w_{l+1}|w_1, \dots, w_l)$
    - $P(w_1, \dots, w_l) = P(w_1)P(w_2|w_1)P(w_3|w_1w_2) \dots P(w_l|w_1w_2 \dots w_{l-1}) = \prod_{i=1}^{l} P(w_i|w_{1:i-1})$
  - 核心功能：语言模型的核心功能是计算自然语言句子或词汇序列出现的概率。
    - 对于句子‘The cat is on the mat’，理想的语言模型会赋予较高概率，因为它语法正确、语义通顺；
    - 而对‘The cat is on the sky’，则赋予较低概率，因为语法和语义都不合理。语言模型在自然语言处理中处于基础地位，是文本生成、语言理解等任务的关键。
  - 示例
    - 合理句子“我喜欢学习”
    - 不合理句子：“我/这/他/，”

n-gram模型

- 定义
  - 假设我们有一个t个词组成的句子$S = (X_1, X_2, X_3 \ldots, X_t)$，如何衡量它的概率呢，让我们假设，每一个词$X_i$都要依赖第一个单词$X_1$到它前一个单词的$X_{i-1}$影响：
    - $P(S) = P(X_1, X_2, X_3 \ldots, X_t) = P(X_1)P(X_2|X_1)\ldots P(X_t|X_1, X_2, X_3 \ldots, X_{t-1})$
  - n-gram模型是语言模型的一种主要形式，通过考虑有限范围的历史来计算单词序列的概率。N元语言模型**假设**下一词出现的概率只与前n-1个词有关
  - 这种假设称为马尔可夫假设（Markov Assumption）

马尔可夫假设

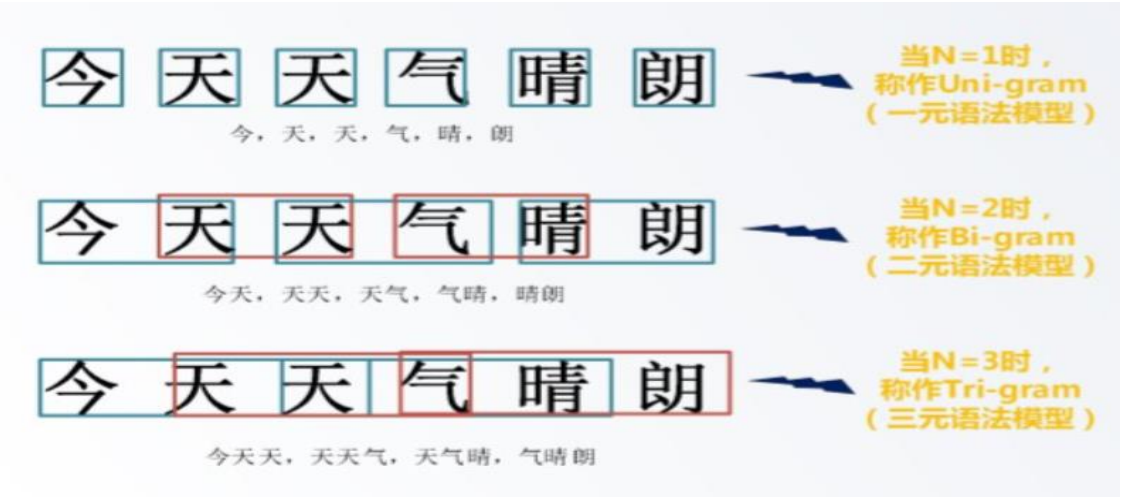
- 一个特例情况：系统的未来状态只依赖于当前状态，而与过去的历史状态无关。
  - 用公式表示，对于一个状态序列 $X_1, X_2, X_3 \ldots, X_t$：

    $$P(X_{t+1}|X_1, X_2, X_3 \ldots, X_t) = P(X_{t+1}|X_t)$$

  - 给定当前状态X_t，未来的状态X_{t+1}与之前的状态 $X_1, X_2, X_3 \ldots, X_{t-1}$无关。

n-gram模型

- n-gram模型的不同情况（下面所述对应0-2阶）
  - 一元文法模型仅考虑当前单词的独立概率
  - 二元文法模型考虑前一个单词对当前单词的影响
  - 三元文法模型则考虑前两个单词的影响
  - 随着n值的增加，模型的上下文范围扩大。



n-gram例子

- 我们假设一个小型训练语料库，包含以下3个句子：
  - 句子1: 我 喜欢 苹果
  - 句子2: 我 喜欢 香蕉
  - 句子3: 他 喜欢 苹果
- 语料库总词数：
  - 9个词（我、喜欢、苹果、我、喜欢、香蕉、他、喜欢、苹果）
- 我们将计算unigram（n=1）和bigram（n=2）模型的概率，并用一个测试句子计算其整体概率。

n-gram例子

- 步骤1：统计频次
  - （注意，这里没有考虑句头围这两个状态）
  - Unigram频次（单个词的出现次数）：
    - 我: 2
    - 喜欢: 3
    - 苹果: 2
    - 香蕉: 1
    - 他: 1
    - 总词数 N = 9
  - Bigram频次（词对的出现次数）：
    - (我,喜欢): 2
    - (喜欢,苹果): 2
    - (喜欢,香蕉): 1
    - (他,喜欢): 1

n-gram例子

- 步骤3：计算概率
  - Unigram概率：p(w) = C(w) / N
    - p(我) = 2/9 ≈ 0.222
    - p(喜欢) = 3/9 ≈ 0.333
    - p(苹果) = 2/9 ≈ 0.222
    - p(香蕉) = 1/9 ≈ 0.111
    - p(他) = 1/9 ≈ 0.111

n-gram例子

- 步骤3：计算概率
  - Bigram概率：$p(w_i \mid w_{i-1}) = C(w_{i-1}, w_i) / C(w_{i-1})$
    - 先计算条件前词的频次：
      - C(我) = 2
      - C(喜欢) = 3
      - C(他) = 1
      - C(苹果) = 2 (但苹果无后续)
      - C(香蕉) = 1 (无后续)
    - 示例概率：
      - p(喜欢 | 我) = C(我,喜欢)/C(我) = 2/2 = 1.0
      - p(苹果 | 喜欢) = C(喜欢,苹果)/C(喜欢) = 2/3 ≈ 0.667
      - p(香蕉 | 喜欢) = C(喜欢,香蕉)/C(喜欢) = 1/3 ≈ 0.333
      - p(喜欢 | 他) = C(他,喜欢)/C(他) = 1/1 = 1.0

n-gram例子

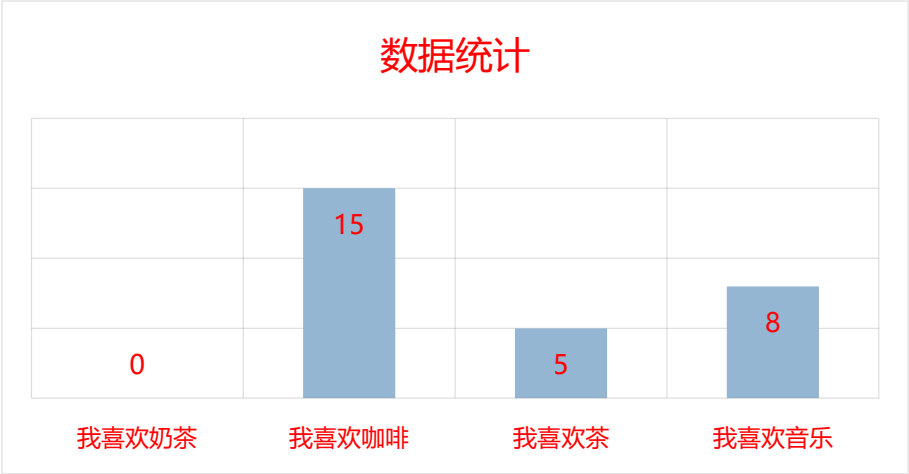
- 步骤4:句子概率计算:
  - “我 喜欢 苹果”
    - Unigram模型下概率（假设独立）：
      - p(s) = p(我) × p(喜欢) × p(苹果) = (2/9) × (3/9) × (2/9) ≈ 0.222 × 0.333 × 0.222 ≈ 0.0164
    - Bigram模型下概率:
      - p(s) = p(我) × p(喜欢 | 我) × p(苹果 | 喜欢)
      - p(我)：通常用起始概率，或假设为1/总句子数，这里为简单起见，用unigram p(我) = 2/9 ≈ 0.222（或在实际中加<start>标记）。</start>
      - 所以 p(s) ≈ 0.222 × 1.0 × 0.667 ≈ 0.148

数据稀疏现象

- 数据稀疏现象的原因
  - 在n元文法框架下，句子的概率是通过一系列条件概率的连续相乘来获得的。
  - 然而，随着n的增大，一个不可避免的问题是，某些单词或单词序列可能在数据集中并未出现，这将导致相应的条件概率为0，进而使得整个句子的概率预测也等于0

数据稀疏现象

- 数据稀疏现象在自然语言处理中非常普遍
  - 尤其是在n元文法模型中。许多n元组在训练数据中未出现，导致模型无法准确计算概率，影响模型的准确性和实用性。
- 举个例子：
  - 假设我们在训练语料里从没见过三元组 “我 喜欢 奶茶”，而见过 “我 喜欢 咖啡”。
  - P(奶茶 | 我, 喜欢) = 0



数据平滑方法

- 为了应对数据稀疏问题，提出了一些数据平滑的方法
  - 加一平滑
  - Good-Turing 平滑
  - Kneser-Ney 平滑
  - 回退

加一平滑

- 核心思想：
  - 假设所有 n-gram 至少出现过一次
  - 在统计频次时 统一加 1，避免零概率。
- 公式：
  - 初始公式：

$$p(w_i) = \frac{C(w_i)}{\sum_{k=1}^{|V|} C(w_k)}$$

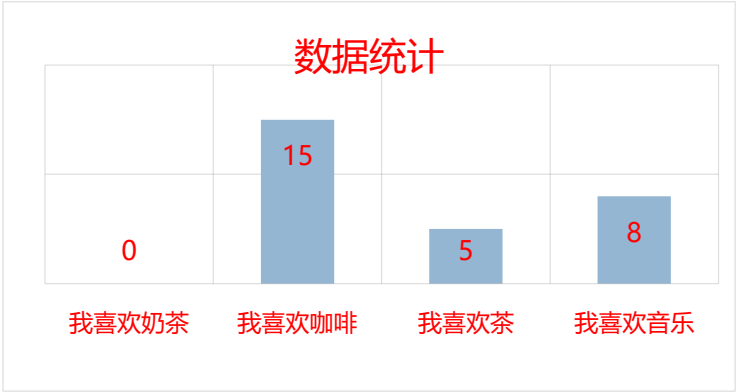
  - 加一平滑公式：

$$p(w_i) = \frac{C(w_i)+1}{\sum_{k=1}^{|V|} (C(w_k)+1)} = \frac{C(w_i)+1}{\sum_{k=1}^{|V|} C(w_k) + |V|}$$

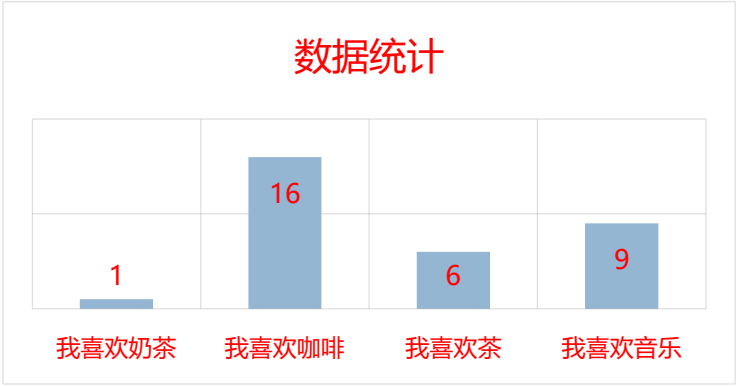
其中，V为词汇表，|V|表示词汇表中词的个数。

加一平滑示例

- 预料中：
  - “我 喜欢 咖啡” → 出现 15 次
  - “我 喜欢 奶茶” → 没出现过（0 次）
- 未平滑
  - P(奶茶|我 喜欢)=0 ✗
- 加一平滑
  - P(奶茶|我 喜欢)>0 ✓
  - 所有组合都有非零概率，更加鲁棒



加一平滑后



其他平滑方法

- Good-Turing 平滑核心思想：利用低频事件的分布规律来推测零事件的概率。
  - 将一部分概率质量从高频事件转移到未出现的事件。
- Kneser-Ney 平滑（最常用）
  - 不仅考虑上下文，还考虑词本身的多样性分布。
- 回退 (Back-off) 与 插值 (Interpolation)
  - 回退：当 n 元组缺失，退回到更低阶的 (n-1)-gram来估计概率。
  - 插值：同时结合 n-gram 与 (n-1)-gram 的概率，进行加权平均。

n元语法模型的优缺点

- 优点
  - n元文法模型具有计算简单、易于实现等优势。
- 缺点
  - n元文法模型存在数据稀疏性问题，尤其是当n值较大时，许多n元组在训练数据中未出现，导致模型对未见数据的处理能力不足。
- n的取值
  - 在n元文法模型中，n的取值对于模型的复杂性和上下文考虑范围具有直接的影响。

自然语言处理的经典技术

- 词法分析（聚焦于词汇层面）
- 句法分析（涵盖句子结构层面）
- 语义分析（深入语义理解层面）

词法分析

- 单词是自然语言中能够独立运用的最小单位，也是自然语言处理的基本单位。
- 词法分析就是利用计算机对自然语言的形态 、类型和结构等进行分析的技术。
- 常见的词法分析任务包括
  - 词语切分
  - 实体识别
  - 词性标注

词法分析任务

- 词语切分
- 实体识别
- 词性标注

词法切分

- 词语切分是将文本分割成有意义的单元（单词）的过程。
- 汉语分词规范问题是分词的首要问题。
  - 尽管部分标准文件为分词工作提供了一定指导，但在实际操作中，如何准确界定汉语中的单词仍是一个复杂的问题。
- 例子
  - 我爱自然语言处理。-->我/爱/自然语言处理/。
  - 苹果公司发布了新款手机。-->苹果公司/发布/了/新款/手机。

词法切分

- 汉语分词面临两大主要界限不清的问题
- 单字词与词素的区分。
  - 如“新华社25日讯”中的“日”，作为单字词时的意义与作为词素（构成词的一部分）时的意义截然不同词与短语的界定。
  - 诸如“花草”、“湖边”、“房顶”等组合，在语境不同时可能既可作为词也可作为短语，使得分词结果往往存在一定的主观性和不确定性。

词法切分

- 撇开汉语分词规范问题，自动分词主要面临如下两大挑战
  - 1）歧义切分字段处理
  - 2）未登录词的识别





歧义切分字段

- 交集型歧义
  - 指句子中存在多个可能的分词结果，而这些分词结果在词语的交集部分产生了重叠。
  - 例如，在句子“中国人为了实现自己的梦想”中，
    - 中国/人为/了/实现/自己/的/梦想
    - 中国人/为了/实现/自己/的/梦想
  - “中国人”和“人为”是两个可能的分词结果，它们在“中国”和“人”这两个词语的交集部分产生了歧义。
  - “大学生”、“研究生物”、“从小学起”、“为人民工作”、“中国产品质量”等词汇也普遍存在。

歧义切分字段

- 组合型歧义
  - 指某些词语或短语在组合时产生了多种可能的分词结果。
  - 例如，在句子“门把手弄坏了”中，
    - 门/把手/弄坏了
    - 门/把/手/弄坏了
  - “把手”既可以作为一个整体词语被切分出来，也可以被切分为“把”和“手”两个词语。这种歧义现象在“才能”、“马上”等词汇中也同样存在。

未登录词

- 语言是动态发展的，每时每刻都出现新的词汇
  - 专业用语：大模型、千问
  - 网络用语：凡尔赛、内卷
  - 领域变化等



切分方法

- 有词典的切分方法
  - 需要词典的帮助
- 统计切分方法
  - 统计学习和神经网络方法
  - 不需要词典帮助
  - 需要训练数据
  - 训练切分模型

最大匹配法

- 最大匹配法（maximum match, MM）是一种最简单的借助词典的切分方法
- 根据从输入句子中取出字串的顺序方向，该方法分为
  - 正向最大匹配法（forward maximum match, FMM）
  - 逆向最大匹配法（backward maximum match, BMM）

最大匹配法

- 基本思路
  - 首先建立一个词表
  - 假设词典中最长的词条为n个汉字，那么，每次从待切分的句子中取出n个连续的汉字，将这n个字构成的序列与词典中的每个词条进行匹配。
    - 如果匹配成功，则根据该词长确定切分点，
    - 否则，将取出的序列退减为n-1个字，再次与词典中的每个词进行匹配
      - 如果仍然匹配不成功，则再次缩短序列的长度，直到只剩一个汉字。
    - 重复上述取词、匹配操作过程，直到句子中每个字都被匹配完成。

正向最大匹配法

- 示例：
- 句子='我们在野生动物园玩'
- 字典= ['我们', '在', '在野', '生动', '野生', '动物园', '野生动物园', '物','玩']
- 词典最大长度 max_len = 5

正向最大匹配法

- 第一轮扫描：
  - 第1次：“我们在野生”，扫描词典，无
  - 第2次：“我们在野”，扫描词典，无
  - 第3次：“我们在”，扫描词典，无
  - 第4次：“我们”，扫描词典，有
  - 扫描中止，输出第1个词为“我们”，去除第1个词后，开始第2轮扫描



正向最大匹配法

- 第二轮扫描：
  - 第1次：“在野生动物”，扫描词典，无
  - 第2次：“在野生动”，扫描词典，无
  - 第3次：“在野生”，扫描词典，无
  - 第4次：“在野”，扫描词典，有
  - 扫描中止，输出第2个词为“在野”，去除第2个词后，开始第3轮扫描



正向最大匹配法

- 第三轮扫描：
  - 第1次：“在野生动物”，扫描词典，无
  - 第2次：“在野生动”，扫描词典，无
  - 第3次：“在野生”，扫描词典，无
  - 第4次：“在野”，扫描词典，有
  - 扫描中止，输出第2个词为“在野”，去除第2个词后，开始第3轮扫描



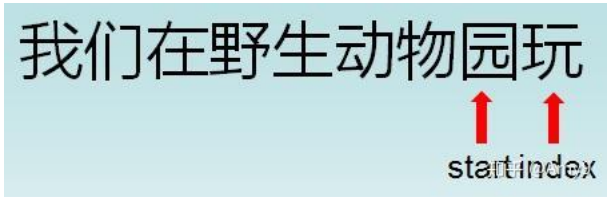
正向最大匹配法

- 第四轮扫描：
  - 第1次：“物园玩”，扫描词典，无
  - 第2次：“物园”，扫描词典，无
  - 第3次：“物”，扫描词典，有
  - 扫描中止，输出第4个词为“物”，去除第4个字后，开始第5轮扫描



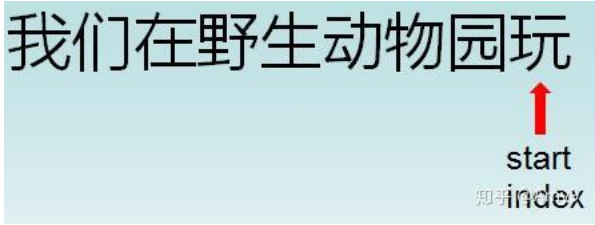
正向最大匹配法

- 第五轮扫描：
  - 第1次：“园玩”，扫描词典，无
  - 第2次：“园”，扫描词典，无
  - 扫描中止，输出第5个词为“园”，去除第5个字后，开始第6轮扫描



正向最大匹配法

- 第六轮扫描：
  - 第1次：“玩”，扫描词典，有
  - 扫描中止，输出第6个词为“玩”，，整体扫描结束。
  - 最终分词结果为：“我们/在野/生动/物/园/玩”。



反向最大匹配法

- 反向匹配法的情况下
- 第一轮扫描：
  - 第1次：“生动物园玩”，扫描词典，无
  - 第2次：“动物园玩”，扫描词典，无
  - 第3次：“物园玩”，扫描词典，无
  - 第4次：“园玩”，扫描词典，无
  - 第5次：“玩”，扫描词典，有
  - 扫描中止，输出第1个词为“玩”，去除第1个词后，开始第2轮扫描



反向最大匹配法

- 第二轮扫描：
  - 第1次：“野生动物园”，扫描词典，有
  - 扫描中止，输出第2个词为“野生动物园”，去除第2个词后，开始第3轮扫描



反向最大匹配法

- 第三轮扫描：
  - 第1次：“我们在”，扫描词典，无
  - 第2次：“们在”，扫描词典，无
  - 第3次：“在”，扫描词典，有
  - 扫描中止，输出第3个词为“在”，去除第3个词后，开始第4轮扫描



反向最大匹配法

- 第四轮扫描：
  - 第1次：“我们”，扫描词典，有
  - 扫描中止，输出第4个词为“我们”，去除第4个词后，整体扫描结束。
  - 最终分词结果为：“我们/在/野生动物园/玩”。



双向最大匹配法

- 双向最大匹配法：
  - FMM和BMM两种算法都分词一遍，选取一种分词结果输出。
  - 如：“我们在野生动物园玩”
    - 正向最大匹配法，最终分词结果为：“我们/在野/生动/物/园/玩”，其中，总分词数6个，单个词为3。
    - 逆向最大匹配法，最终分词结果为：“我们/在/野生动物园/玩”，其中，总分词数4个，单个词为2。
  - 选择标准：
    - 首先看两种方法结果的分词数，分词数越少越好；
    - 分词数相同的情况下，看单个词的数量，越少越好；
    - 因此最终输出为逆向结果。

词法分析任务

- 词语切分
- 实体识别
- 词性标注

实体抽取

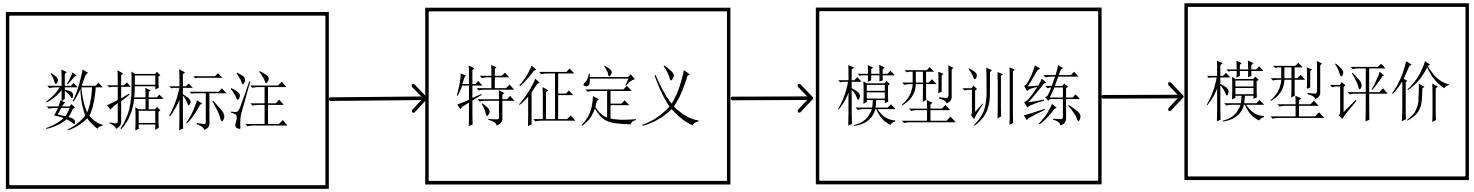
- 命名实体(Named Entity)是句子中重要的语义单元，一般指人名、地名、组织机构名、数字、日期、货币和数量。
  - 人名：科比、姚明...
  - 地名：北京、华盛顿...
  - 日期：2025年...
- 数字、日期、货币和数量等类别
  - 因其具有明显的规律和结构，
  - 通常可以通过基于规则的解析和正则表达式匹配等方法较为准确地提取
- 人名、地名和组织机构名
  - 其复杂性和多样性，成为了命名实体识别中的难点

实体抽取的方法

- 基于规则的方法
  - 由语言学专家手工制定规则
  - 优点：短时间内取得较好的效果
  - 缺点：耗费大量人力和时间、规则移植性差
- 基于统计和基于神经网络的方法
  - 有监督学习、标注数据进行训练
  - 常用模型：隐马尔可夫模型、条件马尔可夫模型、最大熵模型、条件随机场模型...

基于统计的实体识别流程

- 基于统计的的实体识别流程一般包括
  - 训练语料标注、
  - 特征定义
  - 模型训练
  - 模型评价



基于统计的实体识别流程

- 步骤1数据标注：
  - 一般采用BIOES 标注法，它是目前较为常用的命名实体标注方法，具体表示如下：
    - B （begin）表示该词或字位于某个实体的开始；
    - I （inside）表示该词或字位于某个实体的内部；
    - O（outside）表示该词或字位于某个实体的外部，不属于任何一类实体；
    - E（end） 表示这个词或者字处于一个实体的结束；
    - S 表示这个词是单独形成一个命名实体。
  - 例如“阿尔伯特 \· \爱因斯坦\1879年\3月\14日\出生\在\德国\

文本	阿尔伯特	·	爱因斯坦	1879年	3月	14日	出生	在	德国
标注	B-PER	I-PER	E-PER	B-TIME	I-TIME	E-TIME	O	O	S

基于统计的实体识别流程

- 步骤2特征定义：
  - 实体抽取常用的特征为：
  - 是否首字母大写、
  - 是否以句点结尾、
  - 是否包含数字、词性、词的n-gram 等、
  - 预定义的词表、
  - 地名列表等。

基于统计的实体识别流程

- 步骤3模型训练：
  - 条件随机场模型
    - 定义：条件随机场是一种判别式概率模型，是给定一组输入随机变量条件下另一组输出随机变量的条件概率分布模型，其特点是假设输出随机变量构成马尔可夫随机场。
    - 在NER中，CRF的目标是给定输入句子 $X = \{x_1, x_2, \dots, x_n\}$，预测对应的标签序列 $Y = \{y_1, y_2, \dots, y_n\}$，使得标签序列最优。

基于统计的实体识别流程

- 步骤3模型训练：
  - 条件随机场模型
    - 公式：CRF假设标签序列Y满足马尔可夫性质，即当前标签y_i只依赖于相邻的标签（如y_{i-1}, y_{i+1}）和输入序列X。定义为：$P(Y \mid X) = \frac{1}{Z(X)} exp(\sum_{i=1}^{n} \sum_k \lambda_k f_k(y_i, y_{i-1}, X, i))$
      - $f_k(y_i, y_{i-1}, X, i)$：特征函数，描述标签和输入之间的关系。例如，特征函数可以表示“当前词是‘北京’，标签为‘地点’”或“前一个标签是‘O’，当前标签是‘人名’”。
      - λ_k：特征函数的权重，通过训练学习得到。
      - $Z(X)$：归一化因子，确保概率和为 1，计算公式为：$Z(X) = \sum_{Y'} exp\left(\sum_{i=1}^{n} \sum_k \lambda_k f_k(y'_i, y'_{i-1}, X, i)\right)$

基于统计的实体识别流程

- 步骤3模型训练：
  - 训练过程
  - 训练CRF的目标是学习特征权重λ_k，使$P(Y|X)$最大化。
  - 通常使用最大似然估计或正则化方法（如L2正则化）优化目标函数。优化算法包括：
    - 梯度下降
    - L-BFGS
    - 随机梯度下降（SGD）
  - 训练时，模型通过标注数据（如“张伟/人名 去/O 北京/地点”）学习哪些特征对正确标签序列的预测最重要。

基于统计的实体识别流程

- 步骤3模型训练：
  - 推理过程
  - 给定输入序列X，CRF需要找到最优的标签序列Y^*，即：

$$Y^* = arg\,\max_{Y} P\,(Y \mid X)$$

  - 由于直接计算所有可能的Y组合代价高昂，CRF使用维特比算法（Viterbi Algorithm）高效解码，动态规划寻找得分最高的标签序列。

基于统计的实体识别流程

- 步骤4模型评估：
  - 常采用的评价指标有实体识别的
    - 精确率：模型预测出的实体中，有多少是正确的。
    - 召回率：真实实体中，模型成功预测的数量。
    - F1值：精确率 和 Recall 的调和平均数，用于综合评估模型公式

基于神经网络的实体识别

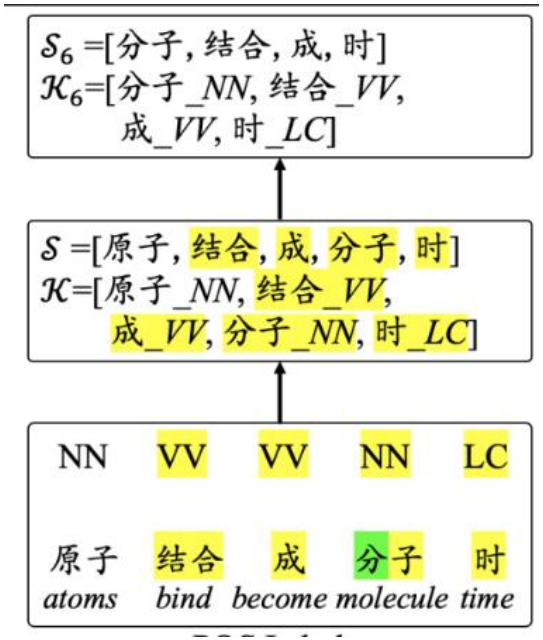
- 基于深度学习的实体识别方法，
  - 模型可以自动学习文本中的特征表示用于实体识别，
  - 优点是能自动学习特征，泛化能力强，缺点是训练依赖大量数据，计算成本较高，
  - 包括以下方法
    - 循环神经网络（RNN）
    - 长短时记忆网络（LSTM）
    - 卷积神经网络（CNN）
    - Transformer
  - 将在10.2节介绍

词法分析任务

- 词语切分
- 实体识别
- 词性标注

词性标注

- 词性
  - 或称词类（Part-of-Speech, POS）是词汇最重要的特性之一，代表了语言中词的语法分类。它作为连接词汇与句法的桥梁。



词性标注

- 词性一般分为两类
  - 实词
    - 体词：主要承担事物的名称或指代功能，如名词、代词等
    - 谓词：谓词则主要表示动作、状态或性质，如动词、形容词等
  - 虚词
    - 主要承担语法功能，如连词、介词、助词等，它们对于句子的构成和语义的表示起着关键作用。

词性标注

- 词性标注（POS tagging）的任务：
  - 让系统自动对词汇进行词性标记，在多种可能的词性中选择最符合上下文语境的词性标记。
    - 分词：把句子切开
    - 词性标注：把切开的词加上语法角色
  - 例如句子“我 爱 自然语言处理 。”
    - 我 / r （代词，代指“我”）
    - 爱 / v （动词，表示“喜欢”）
    - 自然 / n （名词，修饰“语言处理”）
    - 语言 / n （名词，核心名词）
    - 处理 / v （动词，动宾结构）
    - 。 / w （标点符号）

词性标注集合

- 为了进行词性标注，需要有一套完善的词性标注集。不同的标注集可能包含不同数量的词性类别和标记符号

- ICTCLAS汉语词性标注集

代码	名称	帮助记忆的诠释
Ag	形语素	形容词性语素。形容词代码为a，语素代码g前面置以A。
a	形容词	取英语形容词adjective的第1个字母。
ad	副形词	直接作状语的形容词。形容词代码a和副词代码d并在一起。
an	名形词	具有名词功能的形容词。形容词代码a和名词代码n并在一起。
b	区别词	取汉字“别”的声母。
c	连词	取英语连词conjunction的第1个字母。
Dg	副语素	副词性语素。副词代码为d，语素代码g前面置以D。
d	副词	取adverb的第2个字母，因其第1个字母已用于形容词。
e	叹词	取英语叹词exclamation的第1个字母。

- Penn Treebank的词性标注

	缩写	全称
1	CC	Coordinating conjunction 并列连词
2	CD	Cardinal number 基数词
3	DT	Determiner 限定词
4	EX	Existential there 存在型 there
5	FW	Foreign word 外文单词
6	IN	Preposition/superordinating. conjunction 介词/从属连词
7	JJ	Adjective 形容词
8	JJR	Adjective, comparative 形容词比较级
9	JJS	Adjective, superlative 形容词最高级
10	LS	List item marker 列表项标记
11	MD	Modal 情态动词
12	NN	Noun, singular or mass 名词（单数或不可数）
13	NNS	Noun, plural 名词（复数）

词性标注集合

- 对于英文句子 "I come to Beijing"，
- 使用Penn Treebank的词性标注
- 结果如下：I/PRP come/VBP to/TO Beijing/NNP。

词性标注的挑战

- 词性兼项问题
  - 一个词 ≠ 唯一词性
  - 具体词性取决于 上下文语境
  - 例如
    - “Time flies like an arrow.”
      - “Time”既可以作名词也可以作动词，但在该句中应被标注为名词
    - “I want you to web our annual report.”
      - “web”则可能是一个动词的新用法，需要被正确标注。

词性标注的方法

- 基于规则/有限状态机的词性标注方法
- 基于统计模型的词性标注方法
- 规则和统计方法相结合的词性标注方法

基于统计模型的词性标注方法

- 传统的统计模型主要包含特征抽取和词性分类两个部分。在基于条件随机场的词性标注方法中，特征选择是至关重要的步骤
  - 特征选择
    - 词汇的上下文信息
    - 词汇本身的词形信息
    - 词性历史信息
    - 统计特征

常用特征一：词汇的上下文信息

- 词汇上下文一定范围内的词语能够提供关于目标词汇词性的重要线索。
- 例如，动词后面通常接名词或代词，形容词后面则可能接名词。
  - 句子：她喜欢音乐
  - 分析：喜欢 前面是代词 他，后面是名词 音乐 → 说明 喜欢 很可能是动词。
  - 句子：He likes music.
  - 分析：likes 前有人称代词 He，后有名词 music → likes 是动词。

常用特征二：词汇本身的词形信息

- 词汇本身也能够为词性标注提供信息
- 例如词汇的拼写形式，包括前缀、后缀等
  - 例子（中文）：
    - 例如：美丽的 → 后面常接名词（如“美丽的风景”），-的结构提示前面“美丽”是形容词。
  - 例子（英文）：
    - quickly 结尾是 -ly → 基本可以判断为副词。
    - happiness 结尾是 -ness → 基本可以判断为名词

常用特征三：词性历史信息

- 在句子中，前面词汇的词性也可能对后面词汇的词性产生影响。因此，可以考虑将前面词汇的词性作为特征。
  - 例子（中文）：
    - 句子：北京 大学
    - 已知 北京 是名词，后面大概率还是名词（“大学”）。
  - 例子（英文）：
    - New York University
    - 前面是专有名词 New York，后面接 University 也是名词，构成复合名词。

常用特征四：统计特征

- 词汇在训练数据集中出现的频率，以及不同词性下该词汇的出现频率。
  - 例子（中文）：
    - 高频词 的、了、在 → 通常是虚词。
    - “发展”在语料中作为动词出现 70%（如“发展经济”），作为名词出现 30%（如“经济的发展”）。
  - 例子（英文）：
    - 高频词 the 几乎总是限定词（Det）。
    - run：名词（“a morning run”）出现频率 < 动词（“I run fast”） → 模型倾向先标注为动词。。

自然语言处理的经典技术

- 词法分析（聚焦于词汇层面）
- 句法分析（涵盖句子结构层面）
- 语义分析（深入语义理解层面）

句法分析

- 不同语言有着不同的句法结构。
  - 英文：主谓宾结构
  - 日文：主宾谓结构
- 句法分析是自然语言处理中的关键技术之一
  - 短语结构分析
  - 依存句法分析

句法分析

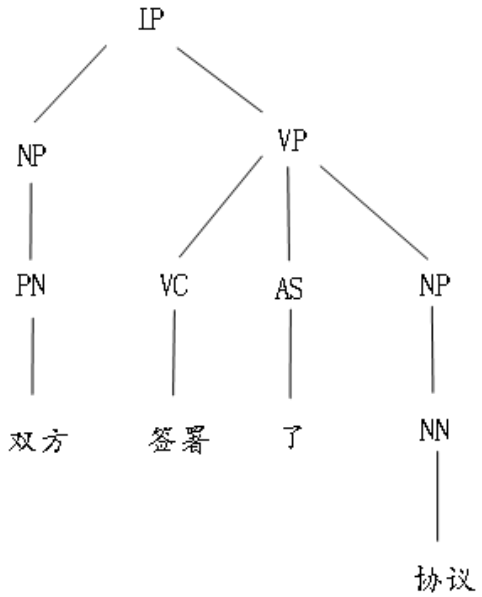
- 句法分析(syntactic parsing)任务的目标就是识别句子的结构关系，即：将输入句子中单词之间的线性次序，变成一个非线性的数据结构，如短语结构树
- 句法分析术语：
  - 句法分析：Parsing
  - 句法分析器：Parser

短语结构分析

- 完全句法分析(full parsing)
  - 对整个句子的短语组成结构进行分析，给出句子的句法结构树。
  - 被分析的句子构成一棵完整的句法分析树
- 局部句法分析(partial parsing)
  - 只需要分析句子中的某些短语，这种分析过程被称为局部句法分析。

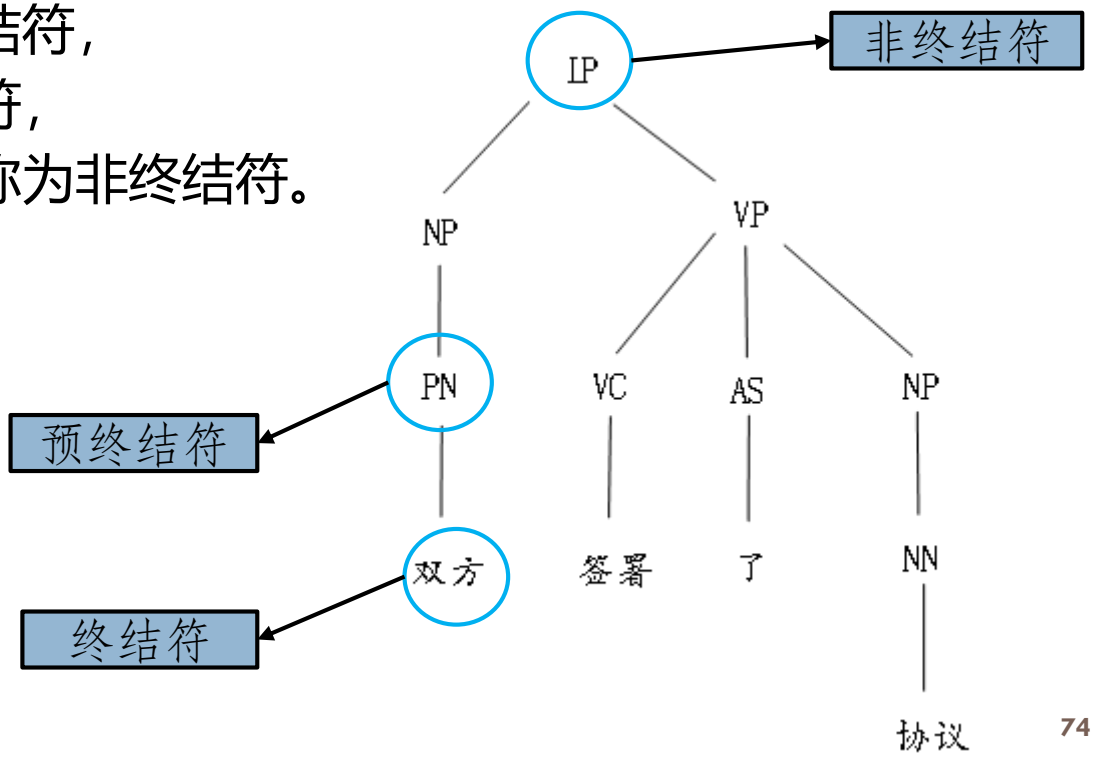
完全句法分析

- 给定句子：“双方签署了协议。”其短语句法树如图
  - IP表示整个“句子”，并作为根节点。
  - NP为“名词短语”，由“双方”这一代词构成。
  - VP表示“动词短语”，是句子中担当动词角色的短语，
    - “签署”（动词VV）
    - “了”（辅助标志AS）
    - “协议“（名词NN）



完全句法分析

- 短语结构树的叶子节点是句子中的每一个单词，
- 中间节点是单词词性和短语句法标记。因此在短语结构句法分析中，
  - 通常把单词称作终结符，
  - 把词性称为预终结符，
  - 其他短语句法标记称为非终结符。



局部句法分析

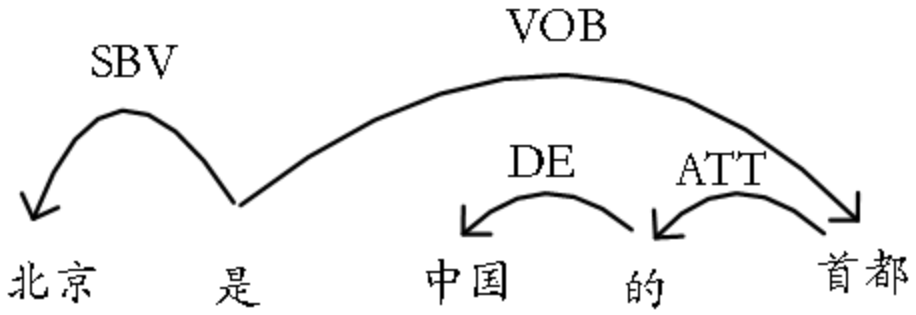
- 局部句法分析聚焦于句子中的特定短语进行分析。这种分析方法无需解析整个句子，而是有选择性地关注诸如“基本名词短语”这样的关键组成部分。
- 例如，在句子“他们是国科大优秀的毕业生”中，可以将其分解为“[他们]是[国科大优秀的毕业生]”的结构，仅对这两个核心短语进行句法分析。

依存句法分析

- 依存语法理论中，“依存”就是指词与词之间支配与被支配的关系，这种关系不是对等的，而是有方向的
  - 支配者：处于支配地位的成分
  - 从属者：处于被支配地位的成分
- 依存句法分析用带有方向的弧表示两个单词之间依存关系，
  - 支配者在有向弧的发出端，
  - 而被支配者则在箭头端，
  - 通常说被支配者依存于支配者

依存句法分析

- 依存句法树示例



- 例子：“北京是中国的首都”
  - “北京”作为主语，依存于动词“是”，表示“是”的陈述对象。依存关系标签可以表示为SBV（主语）。
  - “是”作为句子的谓语，是依存关系的中心词，支配其他成分。
  - “首都”作为句子的宾语，是动词“是”的陈述内容。依存关系标签可以表示为VOB（动宾关系）。

句法分析方法

- 规则法
  - 依靠预定义规则分析句子结构
- 概率统计法
  - 计算概率确定句子最可能的结构
- 神经网络方法
  - 利用神经网络模型自动学习语言规律和模式

规则句法分析方法

- 自底向上
  - 从句子中的词语出发，基本操作是将一个符号序列匹配归约为其产生式的左部（用每条产生式左边的符号来改写右边的符号），逐渐减少符号序列直到只剩下开始符S为止。
- 自顶向下
  - 从符号S开始搜索，用每条产生式右边的符号来改写左边的符号，然后通过不同的方式搜索并改写非终结符，直到生成了输入的句子或者遍历了所有可能的句子为止。
- 自底向上与自顶向下相结合
- 缺点：无法区分歧义结构

统计句法分析方法

- 上下文无关文法
- 概率上下文无关文法（PCFG）
  - 统计语言学中词与词、词与词组以及词组与词组之间的规约信息，并且可以由语法规则生成给定句子的概率。

概率上下文无关文法

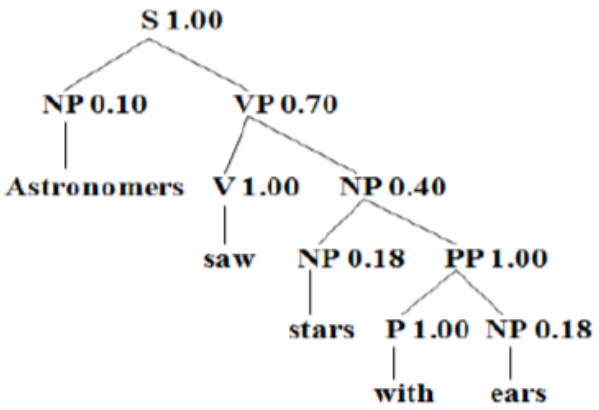
- 任务：
  - 1.句法分析树的消歧
  - 2.求最佳分析树
- 一个PCFG由如下五个部分组成：
  - 1.一个非终结符号集 N
  - 2.一个终结符号集 $\sum$
  - 3.一个开始非终结符 $S \in N$
  - 4.一个产生式集 R
  - 5.对任意产生式 $r \in R$，其概率为 $P(r)$，产生式具有形式：$X \rightarrow Y, P$，其中，$X \in N, Y \in (N \cup \sum)*$，且 $\sum \lambda (X \rightarrow \lambda) = 1$

概率上下文无关文法

概率上下文无关文法（PCFG）：

S → NP VP, 1.00	NP → NP PP, 0.40
VP → V NP, 0.70	VP → VP PP, 0.30
PP → P NP, 1.00	NP → ears, 0.18
NP → saw, 0.04	P → with, 1.00
NP → stars, 0.18	NP → telescopes, 0.1
V → saw, 1.00	NP → astronomers, 0.10

CFG分析树



自然语言处理的经典技术

- 词法分析（聚焦于词汇层面）
- 句法分析（涵盖句子结构层面）
- 语义分析（深入语义理解层面）

语义角色标注

- 语义角色标注（Semantic Role Labeling, SRL）
  - 核心任务：
    - 以句子为单位，围绕句子中的谓词（或动词）展开，深入分析句子中其他成分与该谓词之间所存在的语义关系。
    - 具体而言，语义角色标注能够揭示句子结构背后隐藏的语义角色，更深入地理解句子的意义。

语义角色标注

- 数据集
  - ChinesePropBank
  - ChineseNomBank
  - 两个数据集均基于中文树库的句法成分，通过人工标注的方式加入了丰富的语义角色信息

语义角色标注

- 语义角色标注的核心是谓词论元，表示为REL。
- 语义角色分为两大类：
  - 核心语义角色：ARG0至ARG4等，
    - ARG0通常表示动作的施事者（即执行动作的主体）
    - ARG1则代表受事者（即动作所直接作用的对象）。
  - 辅助性修饰角色，这些角色的标签均以ARGM开头，
    - 表示时间（如ARGM-TMP）
    - 地点（如ARGM-LOC）等额外信息。
    - 这些辅助性角色为句子提供了更为丰富和细致的语义描述，有助于更全面地理解句子的含义和背景。

语义角色标注的语义标签

- 例句：“今年中国银行仍将继续发挥其在支持外商投资企业方面的主渠道作用”。
- 该句子的语义角色标注如下：
  - ARG0:中国银行
  - ARG1:其在支持外商投资企业方面的主渠道作用
  - ARGM-TMP:今年
  - ARGM-ADV:仍
  - ARGM-ADV:将
  - REL: 发挥

语义角色	角色描述
REL	谓词
ARG0	施事者
ARG1	受事者
ARG2	范围或程度
ARG3	动作起点
ARG4	动作结束点
ARGM-ADV	状语
ARGM-BNF	受益者
ARGM-CND	条件

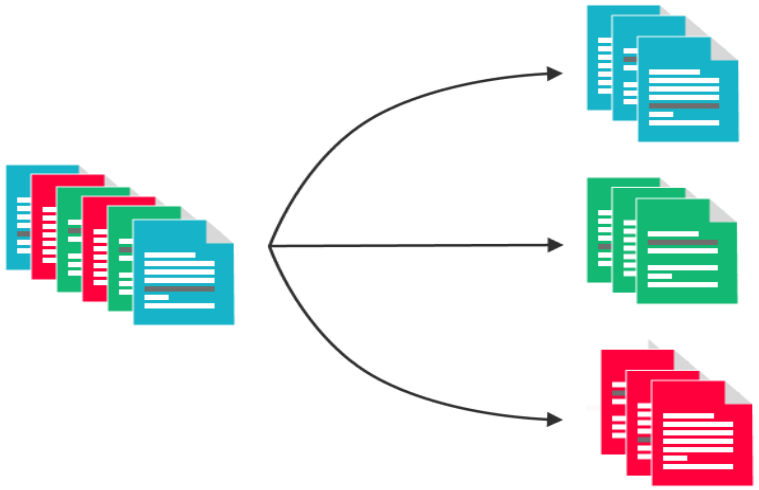
ARGM-DIR	方向
ARGM-LOC	地点
ARGM-MNR	方式
ARGM-PRP	目的
ARGM-TMP	时间
ARGM-TPC	主题
ARGM-PRD	次谓词

自然语言处理的典型应用

- 文本分类
  - 文本主题分类
  - 文本情感分类
- 信息抽取
  - 实体抽取
  - 关系抽取
  - 事件抽取
- 机器翻译

文本分类

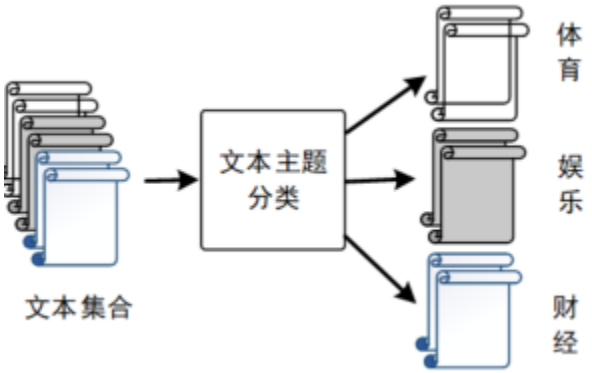
- 文本分类能够在给定的分类体系下，利用计算机自动判别文本的类型



文本分类

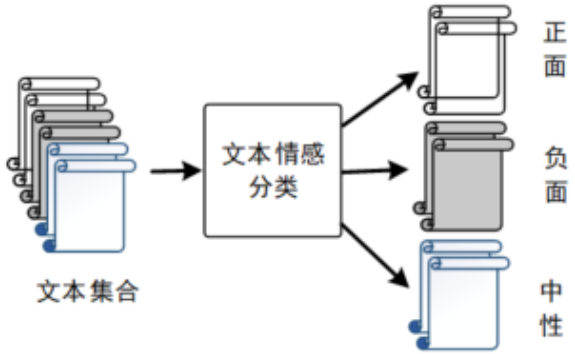
文本主题分类

- 给定一段文本，利用计算机识别出文本的主题，如“科技”、“体育”、“财经”等



文本情感分类

- 识别出给定文本所蕴含的情感极性，如“正向”、“负向”或者“中立”等



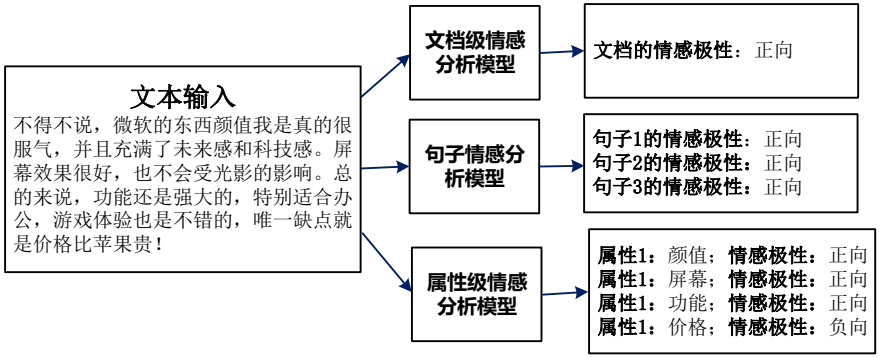
- 常见的文本分类任务还包括对话系统中的意图识别任务、自然语言推理任务和多选问答等任务

文本主题分类

- 按照文本数据类型的不同
  - 文档级（Document-level）文本分类
    - 输入为一段文档
  - 句子级（Sentence-level）文本分类
    - 输入为一个句子

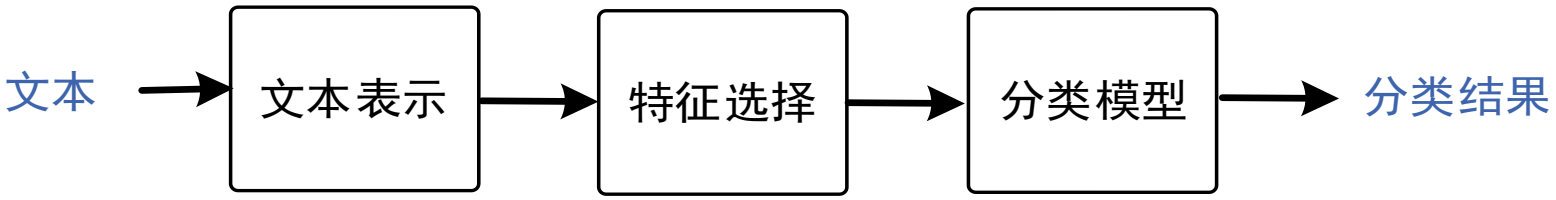
文本情感分析

- 按照文本数据类型的不同
  - 文档级（Document-level）
    - 以整个文档作为基本的分类单元
  - 句子级（Sentence-level）
    - 以某个句子作为情感分类的基本单元
  - 属性级（Aspect-level）
    - 假设一个句子中的每个属性术语都有各自的情感极性



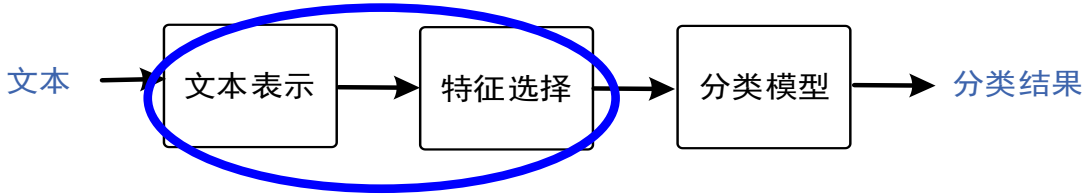
基于统计机器学习的文本分类方法

- 给定一段文本，
- 首先利用文本表示方法提取文本中蕴含的特征并构建相应的特征空间，
- 然后利用特征选择模型对初始的特征向量进行降维，
- 最后利用分类算法实现对文本主题的分类。



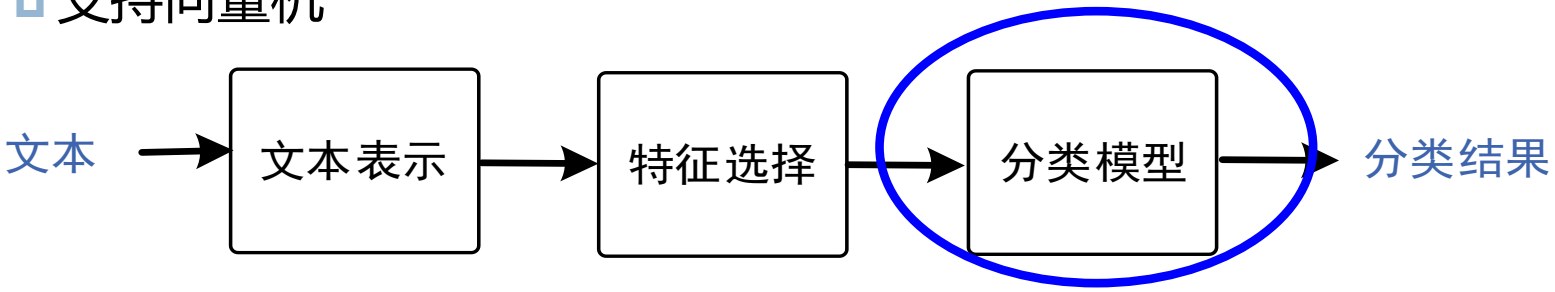
基于统计机器学习的文本分类方法

- （1）文本特征表示
  - 一方面，表示方法能够真实地反映文本的内容
  - 另一方面，又要求该方法对不同类型的文本有足够的区分能力
  - 方法：
    - 词袋模型
    - 向量空间模型
    - n元文法特征、
    - 词频和逆文档频率特征
    - 词向量



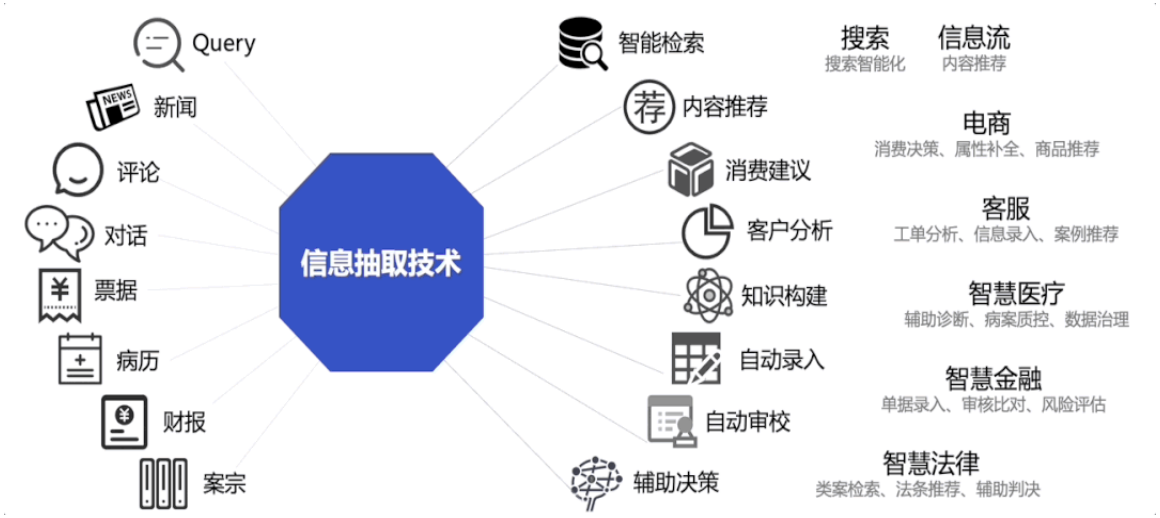
基于统计机器学习的文本分类方法

- （2）分类模型
  - K-近邻分类器
  - 决策树
  - 朴素贝叶斯模型
  - Logistic回归模型
  - 最大熵模型
  - 支持向量机



信息抽取

- 信息抽取是从非结构化、半结构化的自然语言文本 中抽取实体、属性、关系以及事件等信息，并形成结构化数据输出的一种文本数据挖掘技术。



信息抽取

- 实体抽取
- 关系抽取
- 事件抽取

实体抽取

- 之前介绍的命名实体一般为通用领域实体的分类。
- 在实际应用中，不同领域实体的类别有所不同，需要根据不同领域的特点和应用确定，
  - 例如在医疗领域，通常包括疾病名、药品名和仪器名等；
  - 而在电影领域，包含了电影名称、演员名和导演名以及票房等。

解剖部位　症状描述　独立症状　药物　手术

患者 3 月前因“直肠癌”于在我院于全麻下行直肠癌根治术（DIXON 术），手术过程顺利，术后给予抗感染及营养支持治疗，患者恢复好，切口愈合良好。术后病理示：直肠腺癌（中低度分化），浸润溃疡型，面积 3.5*2CM，侵达外膜。两端切线另送“近端”、“远端”及环周底部切除面未查见癌。肠壁一站（10 个）、中间组（8 个）淋巴结未查见癌。，免疫组化染色示：ERCC1 弥漫（+）、TS 少部分弱（+）、SYN（-）、CGA（-）。术后查无化疗禁忌后给予 3 周期化疗，方案为：奥沙利铂 150MG D1，亚叶酸钙 0.3G+替加氟 1.0G D2-D6，同时给与升白细胞、护肝、止吐、免疫增强治疗，患者副反应轻。院外期间患者一般情况好，无恶心，无腹痛腹胀胀不适，无现患者为行复查及化疗再次来院就诊，门诊以“直肠癌术后”收入院。近期患者精神可，饮食可，大便正常，小便正常，近期体重无明显变化。

关系抽取

- 关系定义为两个或者多个实体之间的语义关系，
- 关系抽取就是自动识别实体之间的语义联系。
- 在知识图谱构建、自动问答和推荐系统等任务中扮演着关键角色。



关系抽取

- 例如：“阿尔伯特·爱因斯坦1879年3月14日出生在德国”
- 给定实体“阿尔伯特·爱因斯坦”和“德国”，能够抽取出上述两个实体间的关系为“出生地”，进而形成三元组（阿尔伯特·爱因斯坦，出生地，德国）。
- 同样地，根据句子的语义关系可以抽取出关于“阿尔伯特·爱因斯坦”的另外一个三元组：（阿尔伯特·爱因斯坦，出生日期，1879年3月14日）。

关系抽取分类

- 根据实体的多少可以分为
  - 二元关系抽取：(实体1，关系，实体2)
    - 例如：
      - 乔布斯于创建了苹果。
      - 抽取结果：（乔布斯，创建，苹果）
  - 多元关系抽取
    - 形式：（实体1，实体2...实体3，关系）
    - 例如：
      - 1976年，乔布斯在加利福尼亚创建了苹果。
      - 抽取结果：（乔布斯，苹果，1976，加利福尼亚，创建事件）

关系抽取分类

- 根据数据来源的不同
  - 面向结构化数据的关系抽取
    - 关系数据库数据和表格数据等。
  - 面向非结构化文本的关系抽取
    - 以自然语言组成的文本
  - 面向半结构化数据的关系抽取
    - 包含了非结构化的文本。例如招标书、商品介绍书等。

关系抽取分类

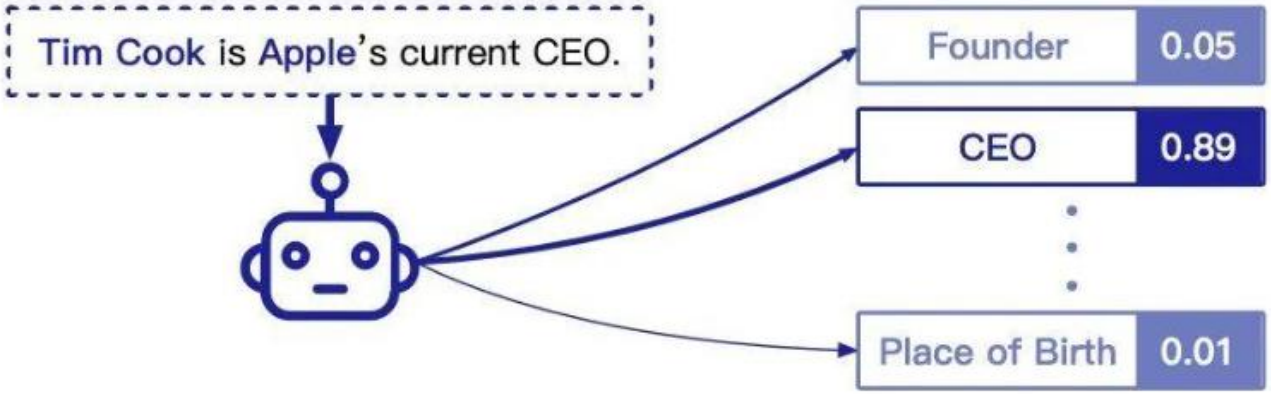
- 根据是否提前确定所有候选关系类别划分
  - 限定域关系抽取
    - 限定域是指候选关系集合中包含了预先定义的、有限个关系类别。
  - 开放域关系抽取
    - 开放域关系抽取不限定关系类别，模型根据语义关系直接抽取实体关系三元组。
- 接下来我们介绍面向非结构化文本的限定域关系抽取方法

传统基于模板的关系抽取方法

- 传统基于模板的方法是根据相关语料的特点，由领域专家手工编写模板，从文本中匹配具有特定关系的实体。
  - 如上述例子中，“阿尔伯特·爱因斯坦出生于德国”
  - 可以构建如下模板：“[X]出生于 [Y]”，表明 “X” 和 “Y” 之间为出生地关系。
  - 优点：可解释性强
  - 缺点：依赖大量领域专家、难以维护和可移植性差等
- 因此人们提出了基于统计学习的关系抽取方法。

基于统计学习的关系抽取方法

- 关系抽取任务属于一种分类任务，即给定一个句子和两个实体，从候选关系集合中判断实体间的关系。因此可以采用有监督学习，根据实体本身的信息和上下文对实体关系进行预测。



基于统计学习的关系抽取方法

- 给定句子：爱因斯坦出生于德国
- 实体：实体1 “爱因斯坦”和实体2“德国”
- 基于统计学习的关系抽取方法如何判断他们的关系？

基于统计学习的关系抽取方法

- 步骤1：数据标注
  - 预先定义候选的关系类别，并根据关系类别进行数据标注。
  - 例如候选关系集合{出生地、工作地、无}三类，
  - 根据上述候选类型标注“爱因斯坦出生于德国”中“爱因斯坦”和“德国”之间的关系为“出生地”

基于统计学习的关系抽取方法

- 步骤2：抽取特征表示
  - 给定一个句子和其中两个实体，同样需要抽取其特征表示，关系抽取任务中的特征主要包括以下3类
    - 实体特征
    - 词级别特征
    - 句法特征

基于统计学习的关系抽取方法

- 步骤2：抽取特征表示
  - 实体特征：实体特征为给定实体的有关特征，
    - 例如实体名称、实体类型、两个实体类型按顺序进行拼接。
    - “爱因斯坦”的实体类型为“PER（人名）”，
    - “德国”为“LOC”，实体类型按顺序进行拼接后的特征为“PER_LOC”。
    - 将实体类型按顺序进行拼接作为特征的主要原因在于关系类型往往和实体的顺序有关。

基于统计学习的关系抽取方法

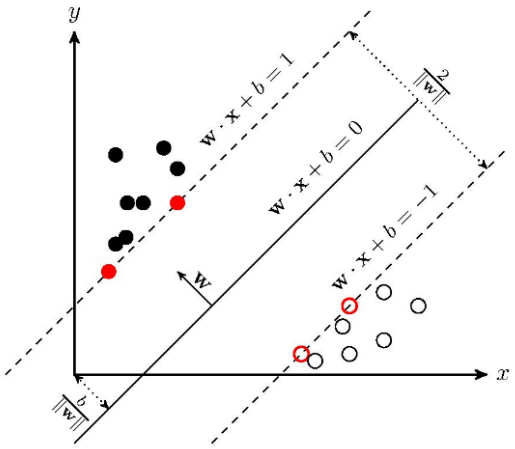
- 步骤2：抽取特征表示
  - 词级别特征
    - 常用的句子级别特征为实体1的前N个单词、实体2的后N个单词、两个实体之间的单词等。
  - 句法特征
    - 句法特征为句子的依存句法特征和短语句法树等。

基于统计学习的关系抽取方法

- 步骤3：选择分类模型
  - 抽取句子和实体的特征后，利用句子和实体的特征向量采用分类模型对关系进行分类，常用的分类模型为
    - 支持向量机
    - 最大熵
    - 朴素贝叶斯

基于统计学习的关系抽取方法

- 步骤3：选择分类模型
  - 支持向量机.(SVM, Support Vector Machine)
    - 基本思想：在特征空间中找到一个“最大间隔”的超平面，把不同类别的样本尽量分开。
  - 特点：
    - 样本少时也能有较好泛化能力；
    - 适合高维稀疏特征（如文本特征）；
    - 可通过核函数处理非线性关系。



基于统计学习的关系抽取方法

- 步骤3：选择分类模型
  - 最大熵模型 (MaxEnt, Maximum Entropy Model)
    - 基本思想：在满足训练数据约束的前提下，选择熵最大的分布，即最不偏向、最均匀的概率分布。
    - 公式：

$$P(y|x) = \frac{1}{Z(x)} \exp\left(\sum_i \lambda_i f_i(x, y)\right)$$

  - 特点：
    - 属于对数线性模型，能灵活利用各种特征；
    - 不需要独立性假设，比朴素贝叶斯更灵活；
    - 计算开销比 SVM 大

基于统计学习的关系抽取方法

- 步骤3：选择分类模型
  - 朴素贝叶斯 (Naive Bayes, NB)
    - 基本思想：基于贝叶斯定理计算条件概率，假设特征之间条件独立
  - 特点：
    - 简单高效，计算快；
    - 对特征独立性要求强（往往不成立，但效果仍可接受）；
    - 对数据量要求较小。

基于统计学习的关系抽取方法

- 步骤3：选择分类模型

模型	核心思想	优点	缺点	关系分类应用
支持向量机	最大间隔超平面	泛化好，适合高维稀疏特征	需要选择核函数，训练成本高	常用于文本/实体特征的关系分类
最大熵	最大化条件概率分布的熵	特征灵活，无独立性假设	训练复杂度高	利用多种上下文特征做分类
朴素贝叶斯	特征条件独立的贝叶斯分类	简单快速，数据需求少	独立性假设过强	快速基线模型

基于统计学习的关系抽取方法

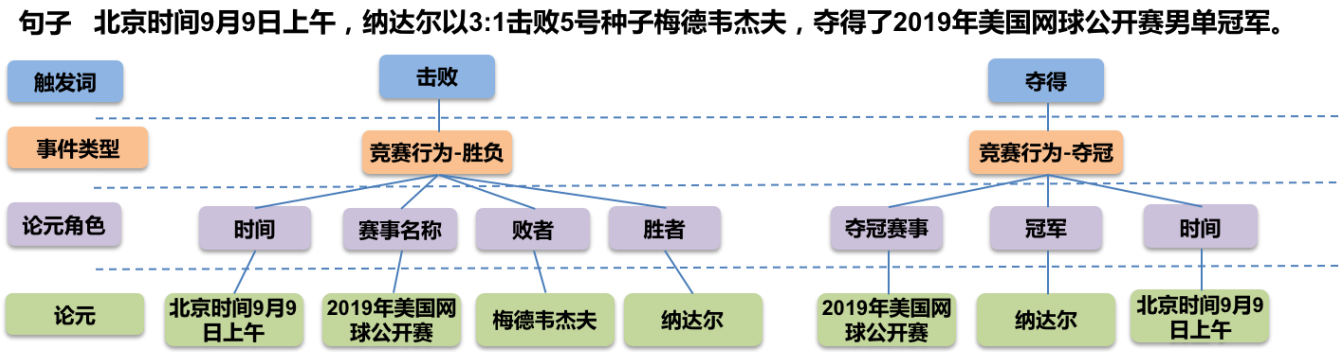
- 步骤4：模型评价
  - 关系抽取任务常采用的评价指标有关系抽取的
    - 精确率（Precision)
    - 召回率（Recall)
    - F1 值

事件抽取

- 不同领域中，事件的概念和内涵也各不相同。
- 在信息抽取领域，这里引述自动内容抽取评测会议（Automatic Content Extraction, ACE）对事件的定义：
  - 事件是发生在某个特定时间点或时间段、某个特定地域范围内，由一个或者多个角色参与的一个或者多个动作组成的事情或者状态的改变 。

事件抽取

- 事件抽取是从非结构化的文本中抽取人们感兴趣的事件信息并将其结构化的过程，
- 在智能问答、信息检索和推荐系统等领域有着重要的应用价值。



事件抽取

- ACE 2005标注的事件类型

Life（生活）	Be-born（出生），Marry（结婚），Divorce（离婚），Injure（受伤），Die（去世）
Movement（转移）	Transport（运输）
Transaction（交易）	Transfer-Ownership（所有权转移），Transfer-Money（资金转移）
Business（商业）	Start-Org（创办），Merge-Org（合并），Declare-Bankruptcy（申报破产），End-Org（倒闭）
Conflict（冲突）	Attack（袭击），Demonstrate（示威）
Contact（联系）	Meeting（会见），Phone-Write（电话-书信）
Personal（人员）	Start-Position（任职），End-Position（离职），Nominate（提名），Elect（选举）
Justice（司法）	Arrest-Jail（逮捕），Release-Parole（释放-假释），Trial-Hearing（审判），Charge-Indict（指控），Sue（起诉），Convict（定罪），Sentence（判决），Fine（罚款），Execute（处决），Extradite（引渡），Acquit（宣告无罪），Pardon（赦免），Appeal（上诉）

事件抽取

- 事件抽取涉及触发词、事件类型、事件论元和论元角色等概念
  - 事件描述/指称（Event Mention）：描述具体事件的文本，通常是一个句子或者多个句子。
  - 事件触发词（Event Trigger）：触发事件的核心词，决定事件类别的重要特征，通常是一个动词或代表动作的名词和短语。
  - 事件类型（Event Type）：事件描述和触发词决定了事件的类别
  - 事件论元（Event Argument）：事件的参与者论元角色（Argument Role）：事件论元在事件中充当的角色

事件抽取

- 示例：“阿尔伯特·爱因斯坦1879年3月14日出生在德国”
- 事件抽取结果：

事件触发词	出生在	
事件类型	出生	
事件论元	角色=人物	阿尔伯特·爱因斯坦
	角色=时间	1879 年 3 月 14 日
	角色=地点	德国

事件抽取

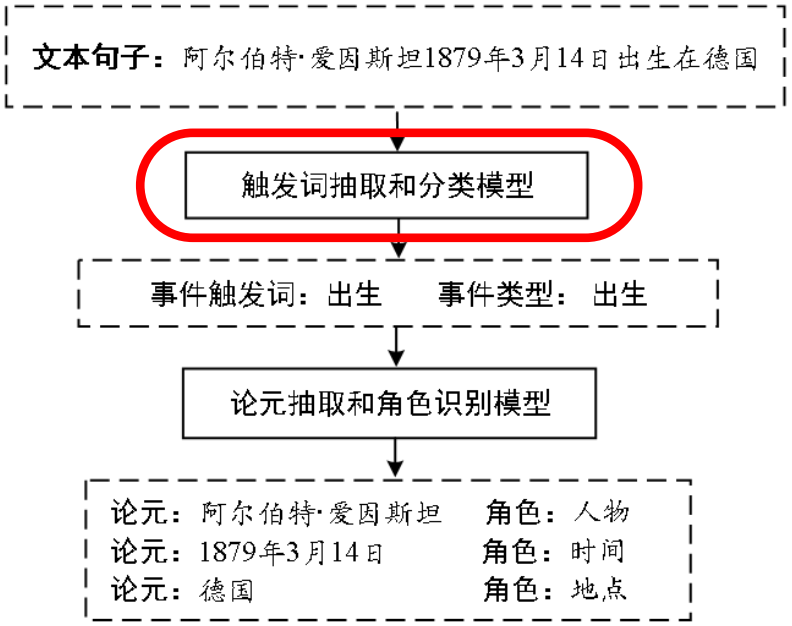
- 一般的事件抽取包含以下四项任务
  - 1）事件触发词检测：从给定的事件文本中抽取出事件触发词。
  - 2）事件触发词分类：根据事件触发词和事件描述，确定事件类型。
  - 3）事件论元识别：从给定的事件描述文本中识别出特定事件的所有论元。
  - 4）论元角色识别：根据事件类型和事件描述，确定事件论元的角色。

事件抽取的基本方法

- 基于模板匹配的方法（Event Trigger Detection）
  - 通过不同事件的词法、句法和规则进行总结，得到对应事件的匹配模板，实现对事件类型的检测和抽取。
  - 优点：在特定领域有着较好的抽取结果
  - 缺点：依赖专业知识，难以覆盖所有事件类型，泛化性较差。
- 基于统计学习和基于深度学习的事件抽取方法
  - 管道式抽取方法：不同的模型完成不同的子任务
  - 联合抽取方法：将四个任务由一个模型联合完成

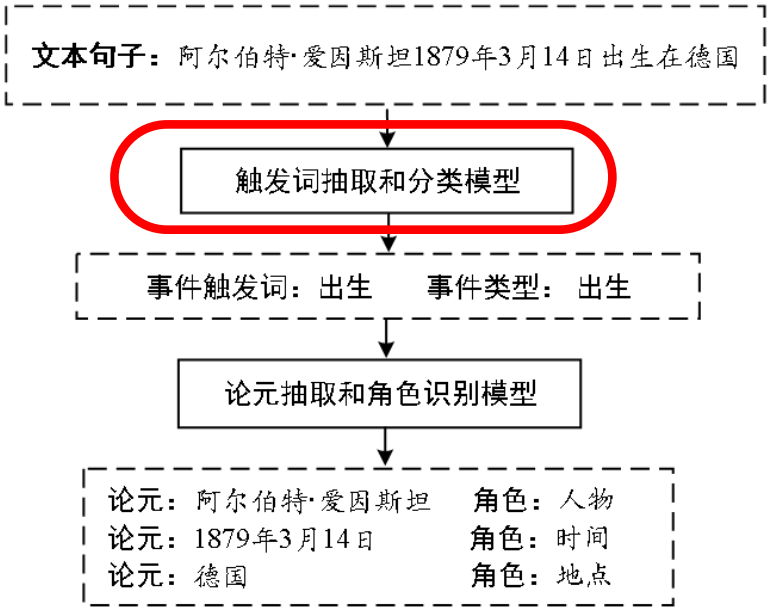
流水线式事件抽取方法

- 管道式事件抽取的示意图
  - 事件触发词检测和事件触发词分类通常由一个模型完成
    - 主要任务是抽取出句子中的触发词并进行事件分类，
  - 而事件论元识别和论元角色识别则由另一个模型完成
    - 给定事件类型和句子，抽取出句子中的论元并分配对应角色。



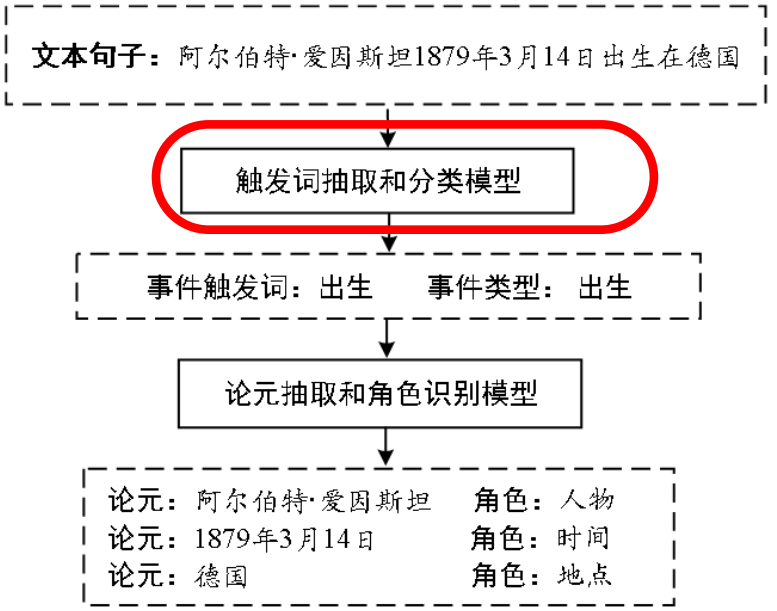
流水线式事件抽取方法

- 事件触发词检测和事件触发词任务
  - 任务类型：触发词一般为动词、部分名词和代词，因此事件触发词检测任务和事件触发词分类可以看作是特定词性单词的分类任务。
  - 例子：
    - “阿尔伯特·爱因斯坦1879年3月14日出生在德国”中“阿尔伯特·爱因斯坦”、“德国”、“出生”均可以当作触发词的候选。



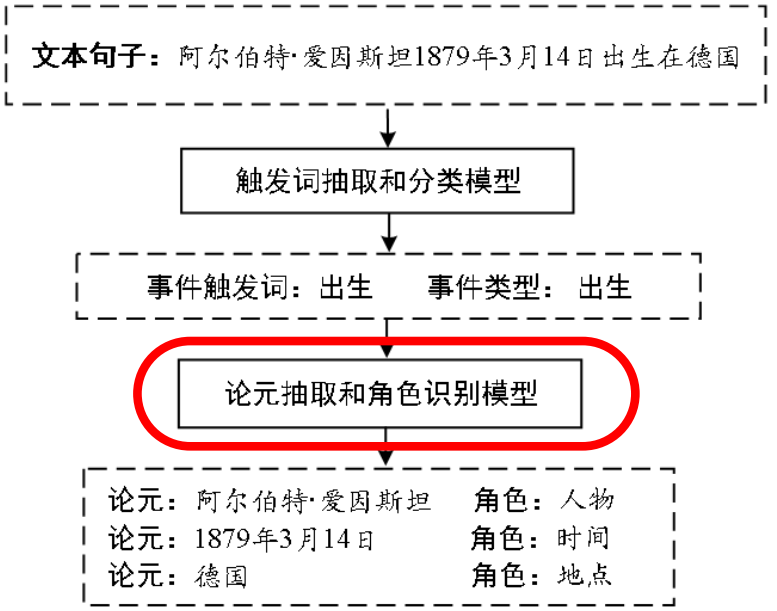
流水线式事件抽取方法

- 事件触发词检测和事件触发词任务
  - 分类器选择：最大熵、支持向量机等经典的分类模型
  - 特征选择
    - 1）词汇级特征
    - 2）句子级特征
    - 3）外部字典特征



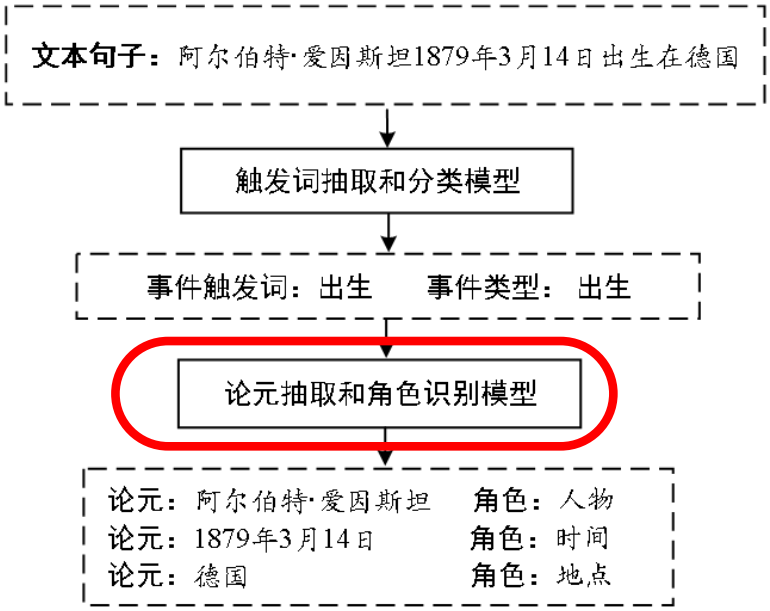
流水线式事件抽取方法

- 事件论元识别和论元角色识别任务
  - 任务形式：例如ACE2005标注事件中， 35个事件角色，加上一个None角色，共有36个事件角色，因此事件论元识别和论元角色识别可以简化为候选实体的36类多分类问题。



流水线式事件抽取方法

- 事件论元识别和论元角色识别任务
  - 关键：无论采用36类多分类任务，还是针对不同事件类型的多分类模型，特征选择依然是事件论元识别和论元角色识别的核心，常用的特征包括：
    - 1）事件类型和触发词特征
    - 2）词汇级特征
    - 3）句子级特征

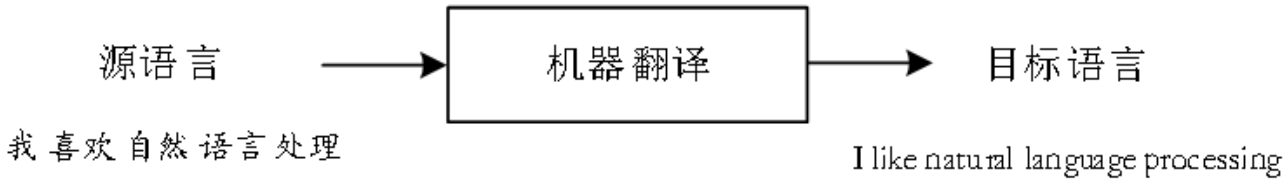


自然语言处理的典型应用

- 文本分类
  - 文本主题分类
  - 文本情感分类
- 信息抽取
  - 实体抽取
  - 关系抽取
  - 事件抽取
- 机器翻译

机器翻译

- 机器翻译 (machine translation, MT) 是用计算机把一种语言 翻译成另一种语言的一门学科和技术
- 见图，其中输入语言为源语言，输出语言为目标语言。其目标是建立高效的自动翻译算法，突破语言壁垒，实现人与人之间无障碍的交流与沟通。



机器翻译

- 机器翻译系统：现实应用







中非合作论坛上的翻译机



翻译耳机



第一届深空探测（天都）国际会议（讯飞同传）



第十八届中国会展经济国际合作论坛（讯飞同传）

机器翻译概述

- 目前全世界总共存在（7000？5651？）2197种语言;
- 其中总共有19种语言的使用人口达5000万;
- 传统的人工翻译已无法满足人类文明发展的需求;
- 机器翻译自计算机出现以来，一直是研究的热点;
  - 1947年，W. Weaver 就提出机器翻译备忘录



机器翻译的发展

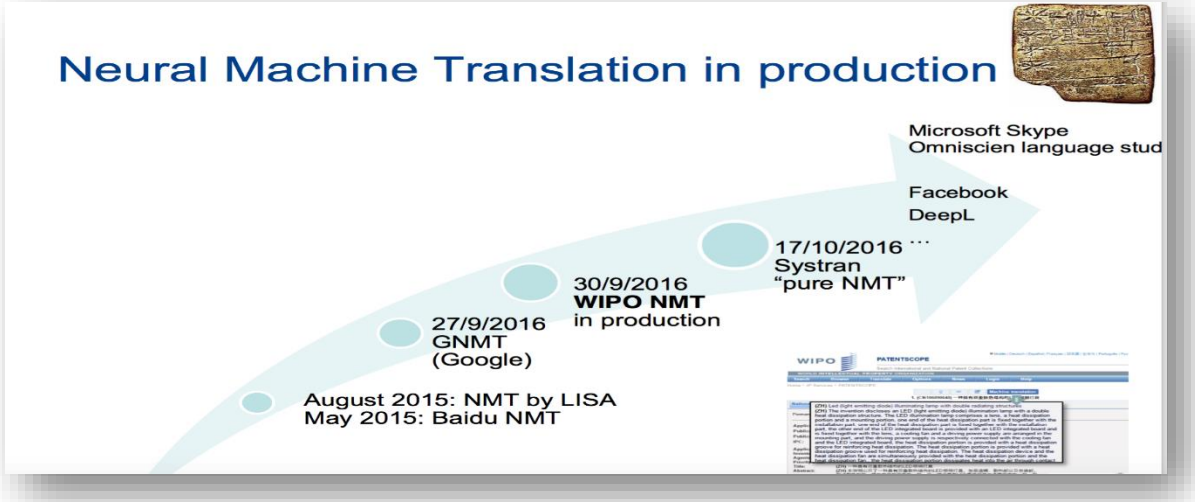
- 草创时期
  - 第一个翻译系统的诞生
    - 1954年 Georgetown 大学在 IBM 协助下，实现了第一个俄译英MT系统；
    - 该系统只有250条俄语词汇，6 条语法规则，可以翻译简单的俄语句子；

机器翻译的发展

- 低谷时期：1970 ~1976年
  - ALPAC报告
    - 1964年，美国科学院成立语言自动处理咨询委员会 (ALPAC)，调查机器翻译的研究情况
    - 1966年 11月公布了一个题为“语言与机器”的报告，简称 ALPAC 报告;
    - 报告宣称：
      - “在目前给机器翻译以大力支持还没有多少理由”；
      - “机器翻译遇到了难以克服的语义障碍 (semantic barrier)”；
    - 从此，机器翻译研究在世界范围内进入低迷状态;

机器翻译的发展

- 发展期：神经机器翻译模型
  - 2013～2023
  - Transformer结构成为目前主流



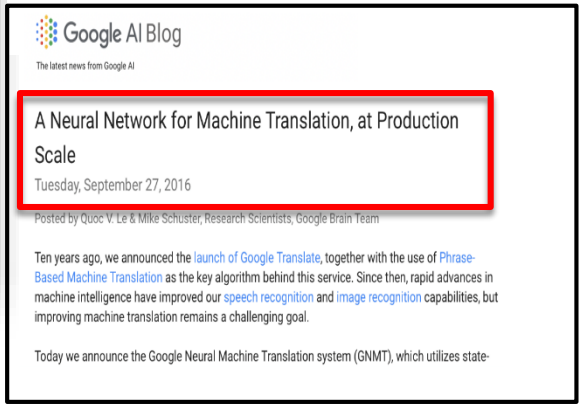

新华网 > 正文

人工智能领域新突破 百度发布基于深度学习的在线翻译系统

2015年05月21日 22:39:46 来源： 新华网 我有话要说(0人参与)

新华网北京5月21日新媒体专电（邱琪）日前，百度在机器翻译技术上取得突破，发布了融合统计和深度学习方法的在线翻译系统。该系统借助海量计算机模拟的神经元，模仿人脑"理解语言，生成译文"。

机器翻译一直被公认为是人工智能领域最难的课题之一。让机器理解语言，进而实现不同语言之间的翻译，不仅仅是几代科学家们孜孜追求的技术梦想，也寄托着普罗大众对自由沟通交流的美好愿望。


Google AI Blog

The latest news from Google AI

A Neural Network for Machine Translation, at Production Scale

Tuesday, September 27, 2016

Posted by Quoc V. Le & Mike Schuster, Research Scientists, Google Brain Team

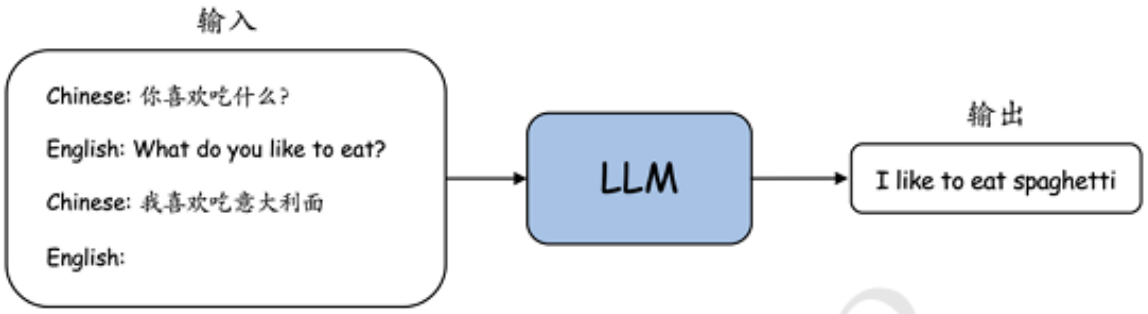
Ten years ago, we announced the launch of Google Translate, together with the use of Phrase-Based Machine Translation as the key algorithm behind this service. Since then, rapid advances in machine intelligence have improved our speech recognition and image recognition capabilities, but improving machine translation remains a challenging goal.

Today we announce the Google Neural Machine Translation system (GNMT), which utilizes state-

Bruno Pouliquen，世界知识产权组织机器翻译负责人， MTSUMMIT-2017

机器翻译的发展

- 大模型时代： 2023至今
  - 大语言模型（GPT/Qwen）能够理解人类指令，并根据指令完成包括翻译在内的各类任务；
  - 还具备情境学习（In-Context Learning，ICL）,思维链（Chain-of-Thought，CoT）等涌现能力
  - 大语言模型的强大能力为机器翻译范式革新提供了可能。



机器翻译的研究内容及难点

- 研究内容
  - 文本翻译：文本到文本的翻译;
    - ---->跨模态翻译：机器同传、Image Captioning
  - 文本对齐：翻译过程中的词/短语对齐情况（翻译知识获取）
  - 质量评价：不给出参考译文的条件下评价机器译文的质量
  - 译文后编辑：对机器译文进行人工后编辑;

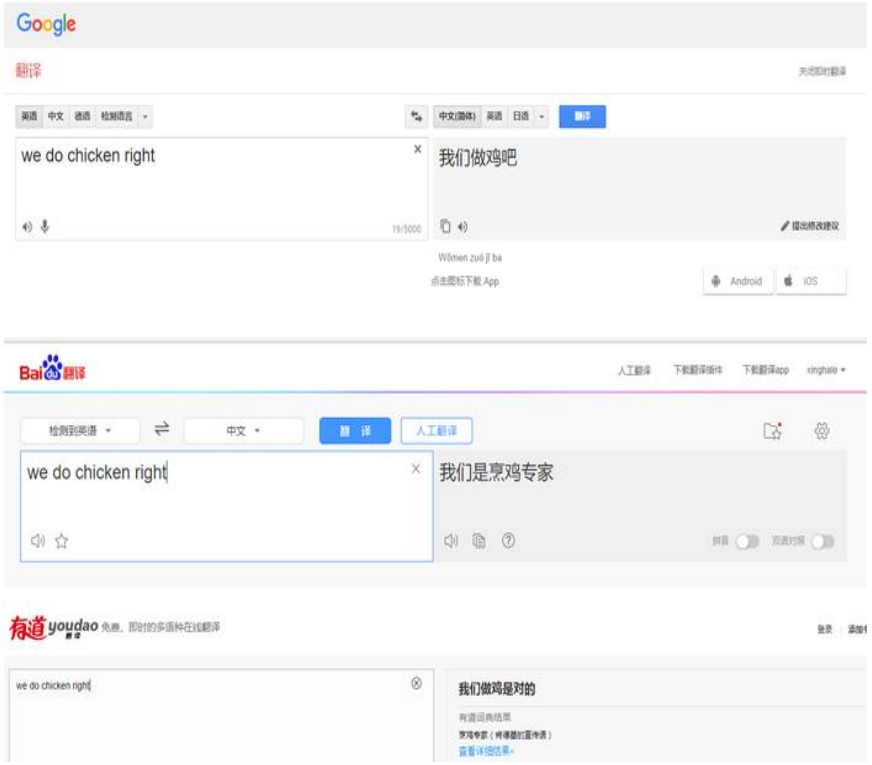
机器翻译的研究内容及难点

- 难点
  - 自然语言中普遍存在的歧义和未知现象
    - 句法结构歧义/词汇歧义 …
    - 新的词汇、术语、结构、语义 …
  - 机器翻译不仅仅是字符串的转换
    - 不同语言之间文化的差异
    - 现有方法无法表示和利用世界知识和常识
  - 机器翻译的解不唯一且没有统一的标准

机器翻译的研究内容及难点

- 难以解决的问题：歧义
  - We do chicken right.
    - 我们做鸡肉是对的;
    - 我们马上做鸡肉;
    - 我们做右边的鸡肉;

人要是行，干一行行一行，
一行行行行行；
要是不行，干一行不行一行，
一行不行行行不行



机器翻译的研究内容及难点

- 难以解决的问题：新词/专有名词

  如食品或菜单名的翻译：

  馒头：

  Steamed bread ?

  Steamed bun

  夫妻肺片：

  Fuqifeipian/ Spicy beef

  童子鸡：

  Spring chicken/ Broiler chicken

  ……

机器翻译概述（小结）

- 机器翻译的目标是协助而非替代。
  - 计算机帮助人类完成某些翻译工作而不是完全替代人；
  - 人与机器翻译系统之间应该是互补的关系，而不是相互竞争；
- 机器翻译还不成熟，需要的是人与系统的配合。
  - 辅助机器翻译可以大大减轻人的负担；
- “信、达、雅”是翻译追求的目标。
  - 计算机在这方面难以替代人；

机器翻译方法

- 传统机器翻译方法
- 统计机器翻译
- 神经机器翻译
- 大模型机器翻译

传统机器翻译方法

- 直接转换的机器翻译方法
- 基于规则的机器翻译方法
- 基于实例的机器翻译方法

直接转换的机器翻译方法

- 直接转换的机器翻译方法
  - 从源语言句子的表层出发，将单词、短语或句子直接置换成目标语言译文，必要时进行简单的词序调整。
  - 这类翻译系统一般针对某一个特定的语言对，将分析与生成、语言数据、文法和规则与程序等都融合在一起。
  - 举例

I like Mary. → Me(I) gusta(like) Maria(Mary).

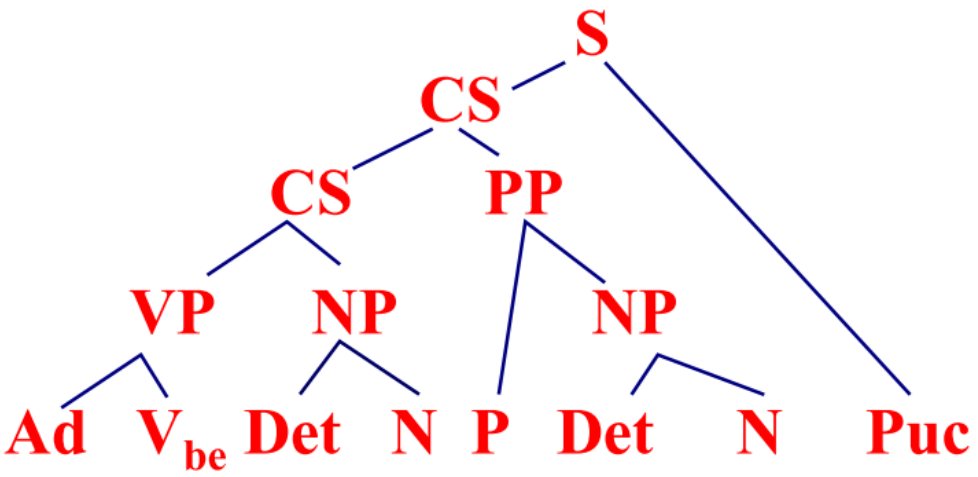
X like Y → Y X gusta

基于规则的机器翻译方法

- 基于规则的机器翻译方法
  - (a) 对源语言句子进行词法分析
  - (b) 对源语言句子进行句法/语义分析
  - (c) 源语言句子结构到译文结构的转换
  - (d) 译文句法结构生成
  - (e) 源语言词汇到译文词汇的转换
  - (f) 译文词法选择与生成

基于规则的翻译方法

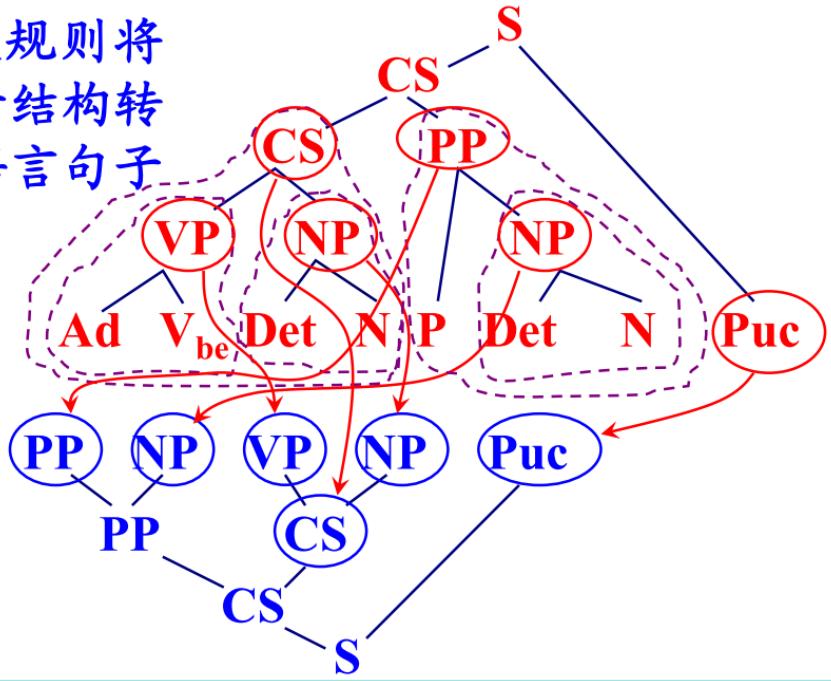
- 提升规则的泛化能力：句法结构
  - 给定源语言句子 There is a book on the desk.
  - 词法分析：There/Ad is/Vbe a/Det book/N on/P the/Det desk/N ./Puc
  - 利用句法规则进行句法结构分析：



基于规则的翻译方法

- 句法树的跨语言映射：异构难题，建模空间复杂，计算难度

■利用转换规则将源语言句子结构转换成目标语言句子结构



基于规则的翻译方法

- 执行过程
  - “独立分析 - 独立生成 - 相关转换” 又称基于转换的翻译方法
- 代表系统
  - ARIANE翻译系统：
    - 由法国格勒诺布尔(Grenoble)机器翻译研究所(GETA)开发
  - TAU-METEO：天气预报信息服务
    - 1976年蒙特利尔大学与加拿大联邦翻译局联合开发的实用性机器翻译系统

基于规则的翻译方法

- 评价
  - 优点：
    - 可以较好地保持原文的结构，产生的译文结构与原文的结构关系密切
    - 对于语言现象的或句法结构的明确的源语言语句具有较强的处理能力
  - 弱点：
    - 规则一般由人工编写，工作量大，主观性强，一致性难以保障
    - 不利于系统扩充，对非规范语言现 象缺乏相应的处理能力。

基于实例的翻译方法

- 1984年由日本学者长尾真提出

EBMT is an acronym for
Example-Based Machine Translation.

Analogy-based,
Memory-based,
Pattern-based,
Case-based,
Similarity-based,
,
,
,
,

Prof. **Nagao Makoto**'s seminal paper
"Translation by analogy" **in 1981**.

Machine translation systems developed so far have a kind of inherent contradiction in themselves. **The more detailed a system has become by the additional improvements, the cleaner the limitation and the boundary will be made as for translation ability**. To break through this difficulty **we have to think about the mechanism of human translation**, and have to build a model based on the fundamental function of the language processing in human brain.

What is EBMT

"Translation by analogy."

(1) Man does **not** translate a simple sentence by doing deep **linguistic analysis**, rather,
(2) Man does translation, first, by properly decomposing an input sentence into certain fragmental phrases…… The translation of each fragmental phrase will be done by the **analogy** translation principle **via proper examples** as its reference.

What is EBMT

- Nagao's Sample

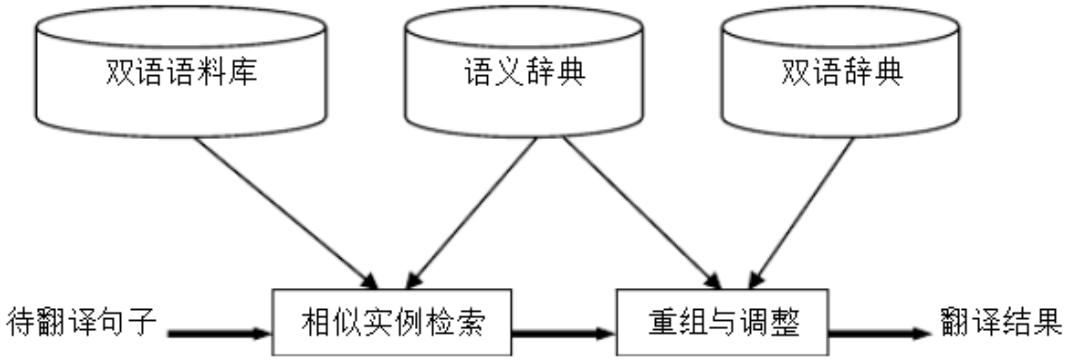
A selection of **Japanese** translations for the English word "eat"

1.	A man	eats	vegetables
	Hito-wa	yasai-o	**taberu**
2.	Acid	eats	metal
	San-wa	kinzoku-o	**okasu**

input	He	eats	potatoes
output	kare-wa	poteto-o	**taberu**

基于实例的翻译方法

- 方法概述
  - 输入语句 → 与事例相似度比较 → 翻译结果
  - 资源：大规模事例库
  - 代表系统：ATR-MATRIX (ATR, Japan)



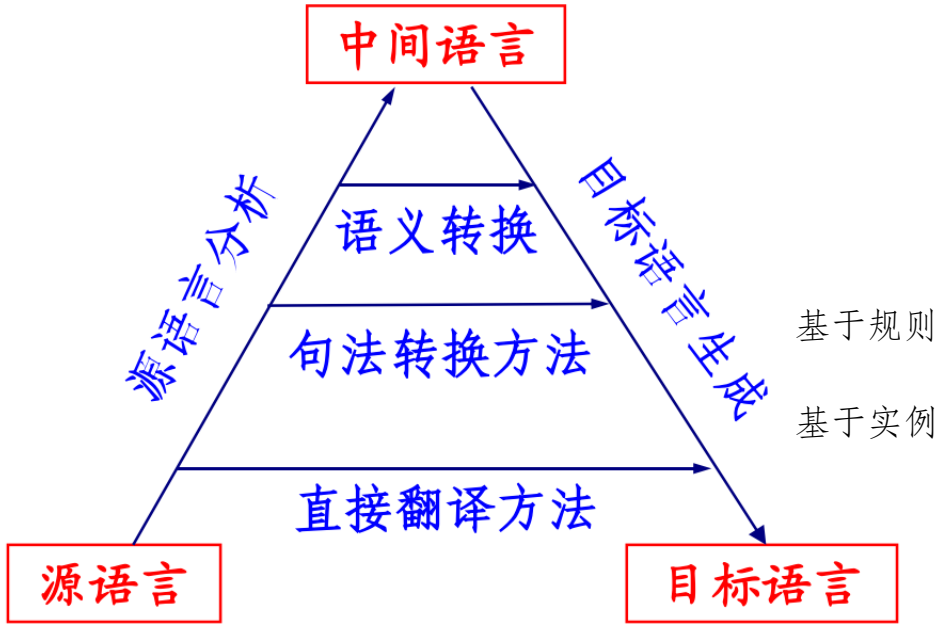
基于实例的翻译方法

- 举例
  - 待翻译句子：她 买了 一本 计算语言学 入门书。
  - 实例库中已有翻译实例
    - 实例1：
    - 她买了 一件 时髦的 夹克衫。
    - She bought a sharp jacket.
    - 实例2：
    - 他 正在 读 一本 计算语言学 入门书。
    - He is reading a book on introduction to Computational Linguistics.
  - 翻译实例重组得到译文：
    - She bought a book on introduction to Computational Linguistics.

基于实例的翻译方法

- 优点：
  - 不要求源语言句子必须符合语法规定;
  - 翻译机制一般不需要对源语言句子做深入分析;
- 缺点：
  - 两个不同的句子之间的相似性(包括结构相似性和语义相似性)往往难以把握
  - 在口语中，句子结构一般比较松散，成分冗余和省略都较严重;
  - 系统往往难以处理事例库中没有记录的陌生的语言现象；
  - 当事例库达到一定规模时，其事例检索的效率较低;

传统翻译方法小结



机器翻译方法

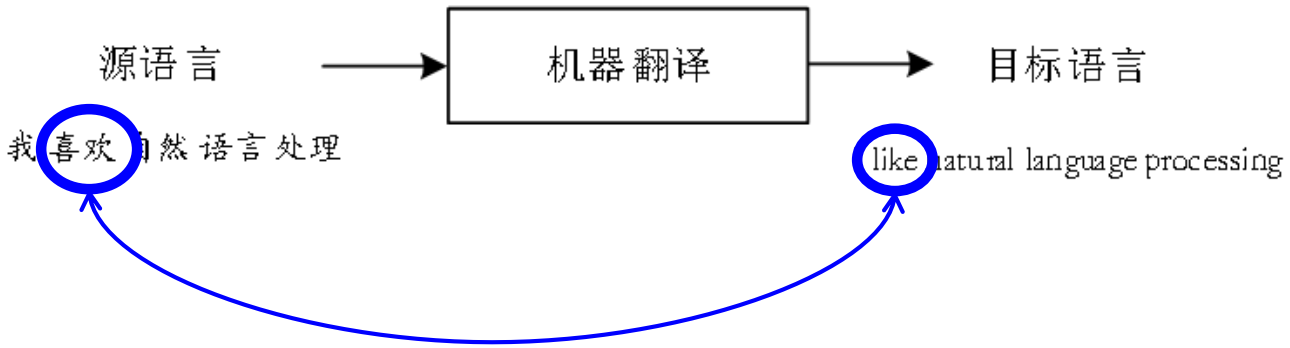
- 传统机器翻译方法
- 统计机器翻译
- 神经机器翻译
- 大模型机器翻译

统计机器翻译

- 数据驱动的机器翻译方法
  - 这些方法能够从海量双语平行语料中自动学习从源语言到目标语言的映射关系，
  - 然后，基于学到的映射关系，模型能够对新输入的源语言句子进行准确且流畅的翻译。

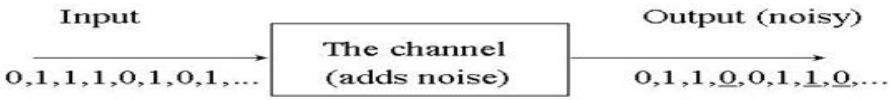
统计机器翻译

- 给定双语平行句对，统计翻译方法通过统计源语言和目标语言单词的共现频率抽取翻译规则，比如“喜欢”与“like”频繁一起出现则有可能互为翻译。
- 统计机器翻译模型的基本原理基于噪声信道模型



噪声信道模型

- 噪声信道模型
  - 形式：



  - 噪声信道试图通过有噪声的输出信号恢复输入信号。它用下面的公式定义：

$$\hat{I} = \arg\max_I P(I \mid O) = \arg\max_I \frac{P(O \mid I)P(I)}{P(O)} = \arg\max_I P(O \mid I)P(I)$$

  - 已知道输出为O，求解它的最大可能输入I，通过贝叶斯公式转换就可以得到：

$$\text{argmax}_I \frac{P(O|I)P(I)}{P(O)}$$

    - 对于某一个特定的输出，显然P(O)是不变的，原式可以再次化简为argmaxP(O|I)P(I).

噪声信道模型用于机器翻译

- 噪声信道模型假设信道输入端是目标语言句子T，通过噪声信道后，在信道输出端呈现为源语言句子S:
  - 1.统计机器翻译目标：给定观察到的源语言句子S，搜索最有可能的目标语言句子T:

$$T^{'} = \underset{T}{argmax} P(T|S) \tag{3.10}$$

  - 2.根据贝叶斯公式和条件概率公式，可以得到：

$$T^{'} = \underset{T}{argmax} P(T|S) = \underset{T}{argmax} \frac{P(S,T)}{P(S)} = \underset{T}{argmax} \frac{P(T)\times P(S|T)}{P(S)} \tag{3.11}$$

  - 3.由于源语言句子S的概率P(S)对于搜索最佳目标语言译文T来说是一个常量，一般可以省略，从而得到：

$$T^{'} = \underset{T}{argmax} P(T) \times P(S|T) \tag{3.12}$$

统计机器翻译

源语言句子： $S = s_1^m \equiv s_1 s_2 \cdots s_m$

目标语言句子： $T = t_1^l \equiv t_1 t_2 \cdots t_l$

贝叶斯公式： $p(T \mid S) = \dfrac{p(T) \times p(S \mid T)}{p(S)}$

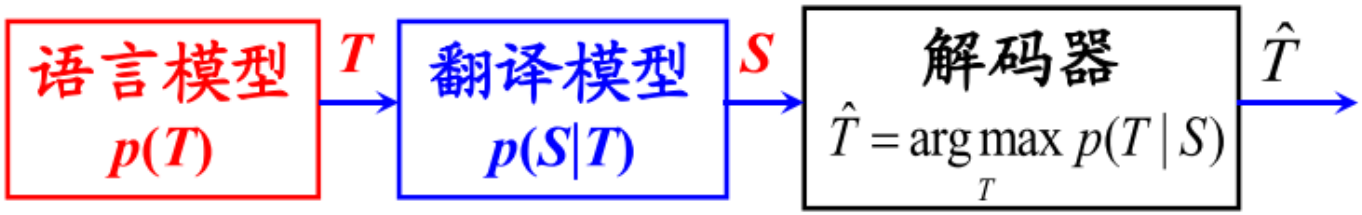
$$\hat{T} = \arg\max_T p(T) \times p(S \mid T)$$

语言模型
Language model, LM

翻译模型
Translation model, TM

统计机器翻译

- 根据公式3.12，$T' = \underset{T}{argmax} P(T) \times P(S|T)$
- 统计机器翻译模型至少需要解决三个问题
  - 三个关键问题
  - （1）估计语言模型概率 p(T)；
  - （2）估计翻译概率 p(S|T)；
  - （3）快速有效地搜索T 使得 p(T)×p(S | T) 最大



统计机器翻译

- 如何计算翻译概率，即准确地估计给定目标语言句子，生成源语言句子的概率?
  - 统计机器翻译中通常计算和之间词语的映射关系，并利用两个句子间词语翻译概率的乘积计算句子翻译概率。
  - IBM的Peter F. Brown等人从简单到复杂设计了五种模型来计算上述公式，称为IBM模型1-5，具体可以参考
    - Brown P F, Della Pietra S A, Della Pietra V J, et al. The mathematics of statistical machine translation: Parameter estimation[J]. Computational linguistics, 1993, 19(2): 263-311.

小结

- 经典的自然语言处理已经形成了相对完整的体系
  - 模型：统计语言模型
  - 任务：词法、句法、语义
    - 指向对不同语言现象的建模
  - 应用：信息抽取、文本分类、机器翻译
    - 还有文摘、问答、写作等很多类
    - 细粒度信息、文本以及整体语言的变化
  - 人们进一步明确了自然语言处理的复杂性与应用的广泛性
    - 从专家系统到机器学习技术取得的效果有限，深度学习应运而生。

课后习题

- 习题1：
  - 在统计自然语言处理中，n-gram模型是一个核心概念。请解释什么是n-gram模型，并讨论其优缺点。特别是在处理长文本和稀疏性问题时，n-gram模型面临哪些挑战？思考一下有没有一些改进的方法？
- 习题2：
  - 统计自然语言处理中的“平滑技术”是为了解决什么问题？ 请列举几种常见的平滑方法，并解释它们是如何工作的。为什么平滑技术在提高语言模型性能上如此重要？
- 习题3：
  - 句法分析方法有哪些类型？它们之间有什么区别？
- 习题4：
  - 在实际应用中，统计自然语言处理技术有哪些典型的应用场景？讨论在这些场景中，统计方法是如何被用来解决特定问题的。