案例：从语言直觉到计算模型

汉语分词与统计语言模型

杨沐昀
语言技术研究中心
计算学部

分词的提出和定义

- 词：是自然语言中能够独立运用的最小单位，是语言信息处理的基本单位。
  - わたしはとうきょうだいがくりゅうがくせいです．
  - سيارة دمرت بقصف أميركي لمدينة الصدر وفي الإطار عزت الدوري
- 分词：将句子转换成词序列
  - 中文、日文、韩语

分词的意义

- 一般认为，自动分词是正确的中文信息处理的基础
  - 文语转换
    - 他们是来 | 查 | 金泰 | 撞人那件事的。(“查”读音为cha)
    - 行侠仗义的 | 查金泰 | 远近闻名。 (“查”读音为zha)
- 给定一个句子分词，首先需要知道有哪些词
  - 南京市长江大桥
  - 词：南京、市、市长....

第一个难题：什么是词

- 汉语词定义不明确
  - 牛肉是词，马肉是不是？
  - 打倒是词，打死、打伤、饿死、涂黑是不是？
- 采用“分词单位”的说法，建立词表
  - 取舍理由不够充分，人为色彩过重
  - 过于复杂，难于把握
- 为操作的方便，必须确定统一的标准或规范

难题I解决思路：分词规范

- 汉语分词规范问题的提出
  - 分词是许多技术的基础：语音识别、信息检索、机器翻译等
  - 中文词之间没有明显分界符，不同人对同一句话词的界限有不同的看法，需要一个同一的标准。
  - 863/973和SIGHAN对计算机分词结果的评价都以人工分词结果作为标准，人工结果是否科学规范？
- 现有的规范
  - 《信息处理用现代汉语分词规范，中华人民共和国国家标准（GB/T13715）》
  - 《北京大学现代汉语语料库基本加工规范，北京大学，2002》
  - 《现代汉语语料库文本分词规范（Ver3.0），北京语言文化大学语言信息处理研究所、清华大学计算机科学与技术系，1998.12.09》
  - 《973当代汉语文本语料库分词、此行标注加工规范，山西大学，2003》
  - 《咨询处理用中文分词规范，台湾省，1998》

实践I：理性主义的分词方法

- 使用预先建立的词典（*根据分词规范得到的词表*）
- 依赖人的语言观察和经验直觉设计算法
  - 长度和频率
- 从研究角度来看，启发式函数设计过于主观
  - 假设条件过强
  - 并未建立与问题本质的联系
  - 均属于贪心策略，未及考虑全局最优

分词算法

- 基于字符串匹配的分词算法
  - 正向最大匹配
  - 逆向最大匹配
  - 双向最大匹配
  - 最短路径分词法

正向最大匹配分词(Forward Maximum Matching method, FMM)

- 基本思想：
  - 1. 设自动分词词典中最长词条所含汉字个数为I
  - 2. 取被处理材料当前字符串序数中的I个字作为匹配字段，查找分词词典。若词典中有这样的一个I字词，则匹配成功，匹配字段作为一个词被切分出来，转6
  - 3. 如果词典中找不到这样的一个I字词，则匹配失败
  - 4. 匹配字段去掉最后一个汉字，I--
  - 5. 重复2-4，直至切分成功为止
  - 6. I重新赋初值，转2，直到切分出所有词为止

最大匹配法

* FMM伪代码

```
for ( int i = 0; i < N; i ++) {
      for (int j = N; j > i; j --) {
            if (IsWord(input [i..j])) {
            output(input[i..j]);
            i = j;
            }
       }
       output(input[i]);
 }
```

- ##isword()是查字典过程; N：句子长度

逆向最大匹配分词(Backward Maximum Matching method, BMM法)

- 分词过程与FMM方法相同，不过是从句子(或文章)末尾开始处理，每次匹配不成功时去掉的是最前面的一个汉字
- “市场/中/国有/企业/才能/发展/
- 实验表明：逆向最大匹配法比最大匹配法更有效

最大匹配法的问题

- 存在分词错误 → 增加知识，局部修改
- 无法发现分词歧义 → 从单向最大匹配改为双向最大匹配

A. 正向最大匹配和逆向最大匹配结果不同

FMM 有意/ 见/ 分歧/

BMM 有/ 意见/ 分歧/

B. 正向最大匹配和逆向最大匹配结果相同

FMM & BMM 原子/ 结合/ 成分/ 子时/

实践II：最少分词法—对最大匹配的算法优化

- 分词结果中含词数最少
  - 等价于最短路径
- 优点：好于单向的最大匹配方法
  - 最大匹配：独立自主/和平/等/互利/的/原则
  - 最短路径：独立自主/和/平等互利/的/原则
- 缺点：忽略组合歧义，未解决大部分交叉歧义
  - 结合成分子时
  - 结合|成分|子 {} 结|合成|分子 {} 结合|成|分子
- 实现方法
  - 动态规划算法

实践III：最大词频分词法

- 另辟蹊径
  - 摒弃词长（物理属性）
  - 使用词频（统计属性）
- 基本思想：出现频率越高的词越可靠
  - 正确率可达到92%
  - 简便易行，效果一般好于基于词表的方法

难题发现：分词歧义

- 交集型切分歧义
  - 汉字串AJB被称作交集型切分歧义，如果满足AJ、JB同时为词(A、J、B分别为汉字串)。此时汉字串J被称作交集串。
    - [例] “结合成分子”
      - 结合 | 成 分|子 |
      - 结合|成|分子|
      - 结 | 合成 |分子|
    - [例] “美国会通过对台售武法案”
    - [例] “乒乓球拍卖完了”

难题发现：分词歧义

- 组合型切分歧义
  - 汉字串AB被称作组合型切分歧义，如果满足条件：A、B、AB同时为词
    - [例]组合型切分歧义：“起身”
    - 他站 | 起 | 身 | 来。
    - 他明天 | 起身 | 去北京。



难题发现：分词歧义

交集型歧义：组合型歧义 = 1: 22　语料规模：17,547字 [1]

语料规模：500万字新闻语料 [2]

歧义字段 \ 链长	1	2	3	4	5	6	7	8	总计
Token次数	47402	28790	1217	608	29	19	2	1	78248
比例%	50.58	47.02	1.56	0.78	0.04	0.02	0.00	0.00	100
Type种数	12686	10131	743	324	22	5	2	1	23914
比例%	53.05	42.36	3.11	1.35	0.09	0.02	0.01	0.01	100

[1] 刘挺、王开铸，1998，关于歧义字段切分的思考与实验。《中文信息学报》第2期，63-64页。

[2] 刘开瑛，2000，《中文文本自动分词和标注》，商务印书馆，65页。

真实文本中分词歧义的分布情况

Type是token去重后的结果；

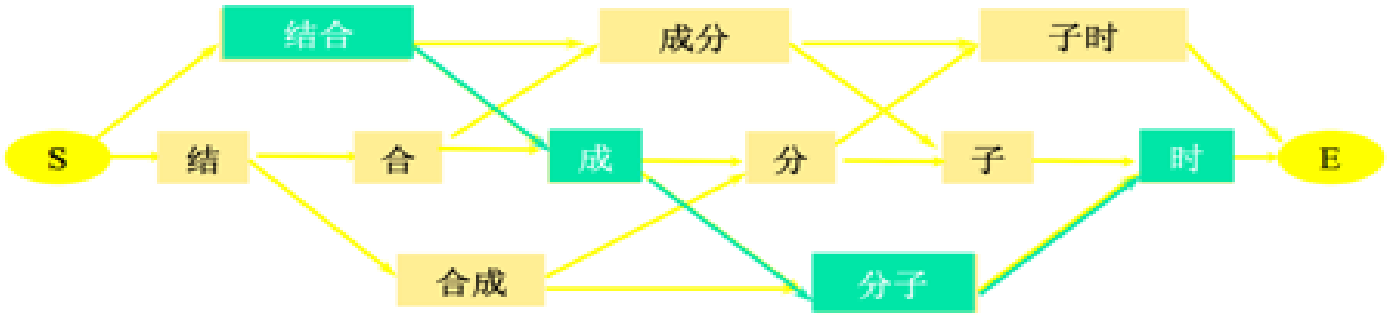
链长（连续交集歧义单词个数）： 治理解放大道路面积水 （8）

难题发现：新词与未登录词

- 虽然一般的词典都能覆盖大多数的词语，但有相当一部分的词语不可能穷尽地收入系统词典中，这些词语称为未登录词或新词
- 分类：
  - 专有名词：中文人名、地名、机构名称、外国译名、时间词
  - 重叠词：“高高兴兴”、“研究研究”
  - 派生词：“*一次性*用品”
  - 与领域相关的术语：“大模型”“新冠”
  - 新词（理性方法的瓶颈出现）：研究显示60%的分词错误是由新词导致
    - 中国自改革开放的20年来平均每年产生800多个新词语

里程碑：问题清楚了

* 问题空间：（基于词表的）全切分有向图
* 解：由S到E最优路径（动态规划搜索）
* 难点：分词歧义
* 核心任务：比长度/频率更优的评价函数



实践II：基于N元语法的分词

* 基于N元语法的切分排歧
  * {Text：输入文本，可以是一句话}

对比推导结果：为何不直接假设最后一步？

$$\hat{Seg} = \arg\max_{Seg} P(Seg \mid Text)$$

$$= \arg\max_{Seg} \frac{P(Text \mid Seg)P(Seg)}{P(Text)}$$

?

$$\propto \arg\max_{Seg} P(Text \mid Seg)P(Seg)$$

$$= \arg\max_{Seg} P(Seg)$$

?

实践II：基于N元语法的分词

* Seg简写为S，内含n个词： $\{w_1, w_2, ...w_n\}$

$$p(S) = p(w_1^n) = p(w_1) \cdot \prod_{i=2}^{n} p(w_i \mid w_1^{i-1})$$

* MM(马尔可夫模型/过程)： 有限历史假设，第n个词的出现概率仅依赖前n-1个词
  * *一种最简化的情况：一元文法/Uni-gram*

$$P（S）=p(w_1) \cdot p(w_2) \cdot p(w_3)....p(w_n)$$

#连乘的代码实现?

n元语法(n-gram)：概念

- 一元文法：n=1时，出现在第i位上的词ω_i独立于历史，记作unigram。
- 二元文法：n=2时，出现在第i位上的词ω_i只与前面的一个历史词ω_{i-1}有关，记作bigram，也被称为一阶马尔科夫链。
- 三元文法：n=3时，出现在第i位上的词ω_i只与与前面的两个历史词$\omega_{i-1}\omega_{i-2}$有关，记作trigram，也被称作二阶马尔科夫链。

实践II：基于N元语法的分词

- 采用二元语法：分词性能可以进一步提高

$$p(S) = p(w_1) \cdot p(w_2 \mid w_1) \cdot p(w_3 \mid w_2) \cdots p(w_n \mid w_{n-1})$$

- 采用更大的N：利用更多上下文信息
  - 考虑参数空间

    假设词表：20,000

#解决参数爆炸？

n	n-gram的个数
2 (bigrams)	400,000,000
3 (trigrams)	8,000,000,000,000
4 (4-grams)	1.6×10^{17}

N元语言模型的平滑

- 零概率问题: 测试句子中的词不在词表中
- 折扣法平滑（Smoothing）的思想是损有余而补不足，调整概率估计结果
  - 加1平滑（拉普拉斯平滑）

$$P(w_i|w_{i-1}) = \frac{C(w_{i-1}w_i)+1}{\sum_w \left(C(w_{i-1}w)+1\right)} = \frac{C(w_{i-1}w_i)+1}{C(w_{i-1})+|\mathbb{V}|}$$

  - |V| 为此表中词数

实践拓展：基于HMM的分词/词性标注一体化方法

- 词的句法类别
  - 词性集合
    - 名词、动词、形容词、副词、介词、助动词
    - 开放词类（Open Class）和封闭词类（Closed Class）
  - 可称为：语法类、句法类、POS标记、词类等
- 词的兼类现象
    - 打人=动词
    - 一打衬衫=量词
- 词性标注
  - 确定每个词在特定的句子中词性

实践拓展：基于HMM的分词/词性标注一体化方法

Tag	Description	Example	Tag	Description	Example
CC	Coordin. Conjunction	*and, but, or*	SYM	Symbol	*+,%, &*
CD	Cardinal number	*one, two, three*	TO	"to"	*to*
DT	Determiner	*a, the*	UH	Interjection	*ah, oops*
EX	Existential 'there'	*there*	VB	Verb, base form	*eat*
FW	Foreign word	*mea culpa*	VBD	Verb, past tense	*ate*
IN	Preposition/sub-conj	*of, in, by*	VBG	Verb, gerund	*eating*
JJ	Adjective	*yellow*	VBN	Verb, past participle	*eaten*
JJR	Adj., comparative	*bigger*	VBP	Verb, non-3sg pres	*eat*
JJS	Adj., superlative	*wildest*	VBZ	Verb, 3sg pres	*eats*
LS	List item marker	*1, 2, One*	WDT	Wh-determiner	*which, that*
MD	Modal	*can, should*	WP	Wh-pronoun	*what, who*
NN	Noun, sing. or mass	*llama*	WPS	Possessive wh-	*whose*
NNS	Noun, plural	*llamas*	WRB	Wh-adverb	*how, where*
NNP	Proper noun, singular	*IBM*	$	Dollar sign	$
NNPS	Proper noun, plural	*Carolinas*	#	Pound sign	#
PDT	Predeterminer	*all, both*	"	Left quote	(' or ")
POS	Possessive ending	*'s*	"	Right quote	(' or ")
PP	Personal pronoun	*I, you, he*	(	Left parenthesis	([, (, {, <)
PPS	Possessive pronoun	*your, one's*	)	Right parenthesis	( ],), }, >)
RB	Adverb	*quickly, never*	,	Comma	,
RBR	Adverb, comparative	*faster*	.	Sentence-final punc	(. ! ?)
RBS	Adverb, superlative	*fastest*	:	Mid-sentence punc	(: ; ... – -)
RP	Particle	*up, off*			

Penn Treebank词性集

实践拓展：基于HMM的分词/词性标注一体化方法

* POS歧义(在Brown语料库中)

无歧义的词(1 tag)：35,340个

有歧义的词(2-7tag)：4,100个

2tags	3,760
3tags	264
4tags	61
5tags	12
6tags	2
7tags	1

实践拓展：基于HMM的分词/词性标注一体化方法

- 输入：待处理句子S
- 输出：S的
  - 词序列 $W=w_1,w_2...w_n$
  - 词性序列 $T=t_1;t_2...t_n$
- 提示
  - W可以代表S
  - 分词结果即观测序列
  - 词性序列是状态序列

- 公式推导入

argmax P(?)

$P(T|S)$ --将词性作为求解目标

$\propto P(S|T)*P(T)$

$=> P(W|T)*P(T)$

以最可能的分词序列代替句子的概率

$P(T) = P(t_1,t_2...t_n)$ --n元文法

$\propto P(t_1,|S_{begin})*P(t_x|t_1)*...$

$*P(t_1|t_{n-1})*P(S_{end}|t_n)$

S_{begin}/S_{end}: 句首/句尾

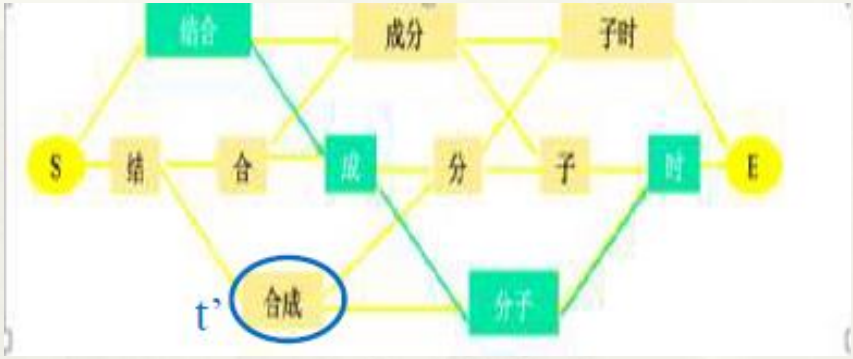
本处为2元文法

实践拓展：基于HMM的分词/词性标注一体化方法

- 公式推导(续)

$P(W|T)=P(w_1,w_2...w_n|t_1,t_2...t_n)$

$=P(w_1|t_1)*P(w_2|t_2)*...*P(w_n|t_n)$



注意：每个节点的内部词和词性有关系，
而节点间词彼此独立

- 最终公式：

$$T_{Best} = \arg\max_{T} \prod_{i=1}^{n} p(w_i \mid t_i) P(t_i \mid t_{i-1})$$

实践拓展：基于HMM的分词/词性标注一体化方法

- 采用一元文法整体计算

  $P(w_1|POS_1)\cdot P(POS_1)\cdot P(w_2|POS_2)\cdot P(POS_2)$

  $\cdot\cdots\cdots\cdot P(w_n|POS_n)\ P(POS_n)$

  - 问题：过于简化，丢失全部上下文信息
- 采用二元文法计算上式：更常见的策略

  $P(w_1|POS_1)\cdot P(POS_1|S_{begin})\cdot P(w_2|POS_2)$

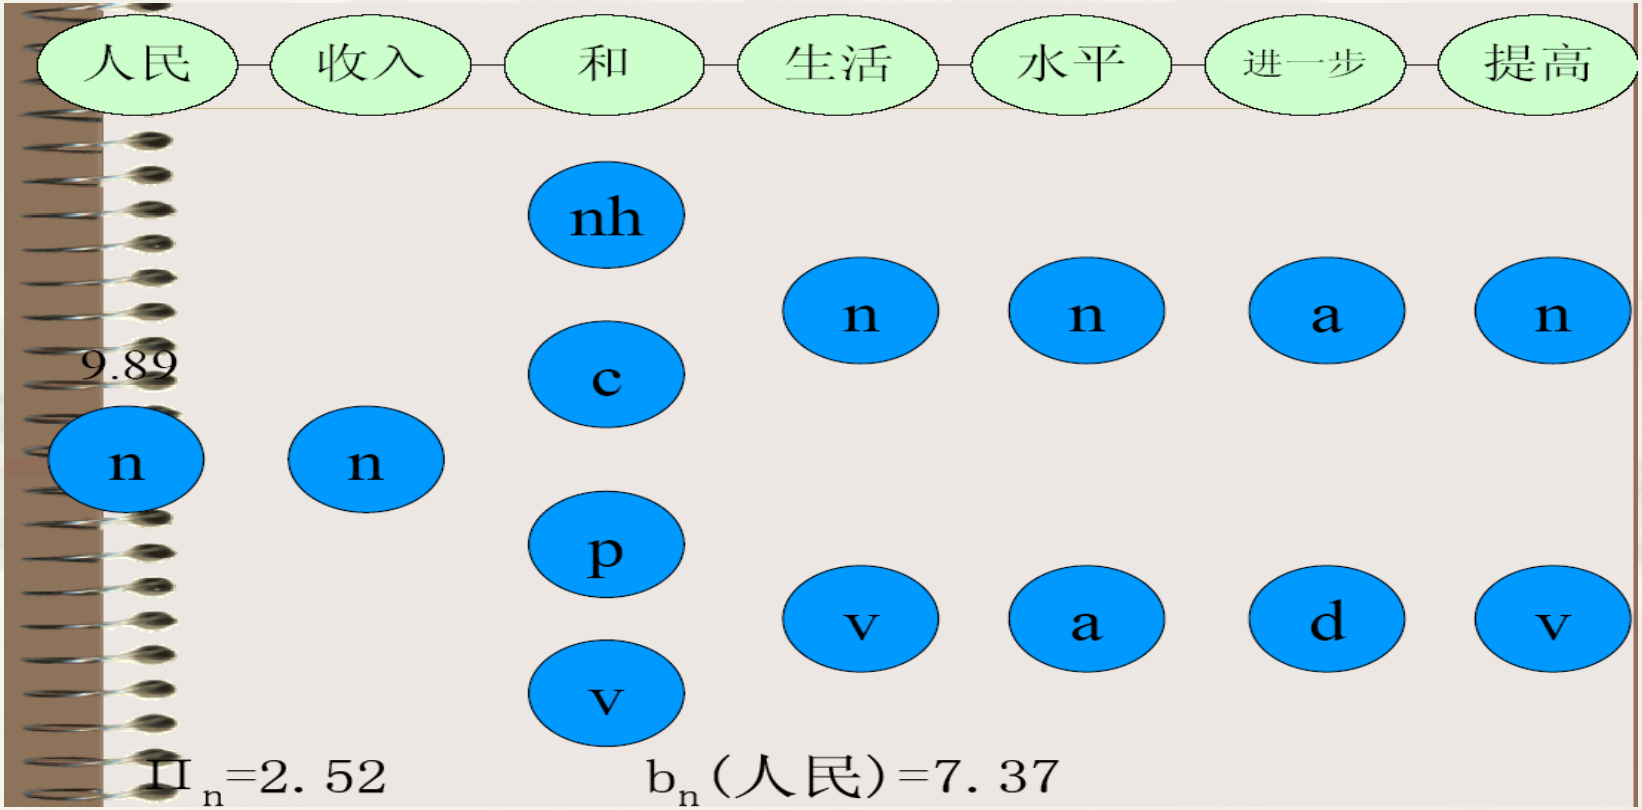
  $\cdot P(POS_2|POS_1)\cdot\cdots\cdots\cdot P(w_n|POS_n)\ P(POS_n|POS_{n-1})$

实践拓展：基于HMM的分词/词性标注一体化方法

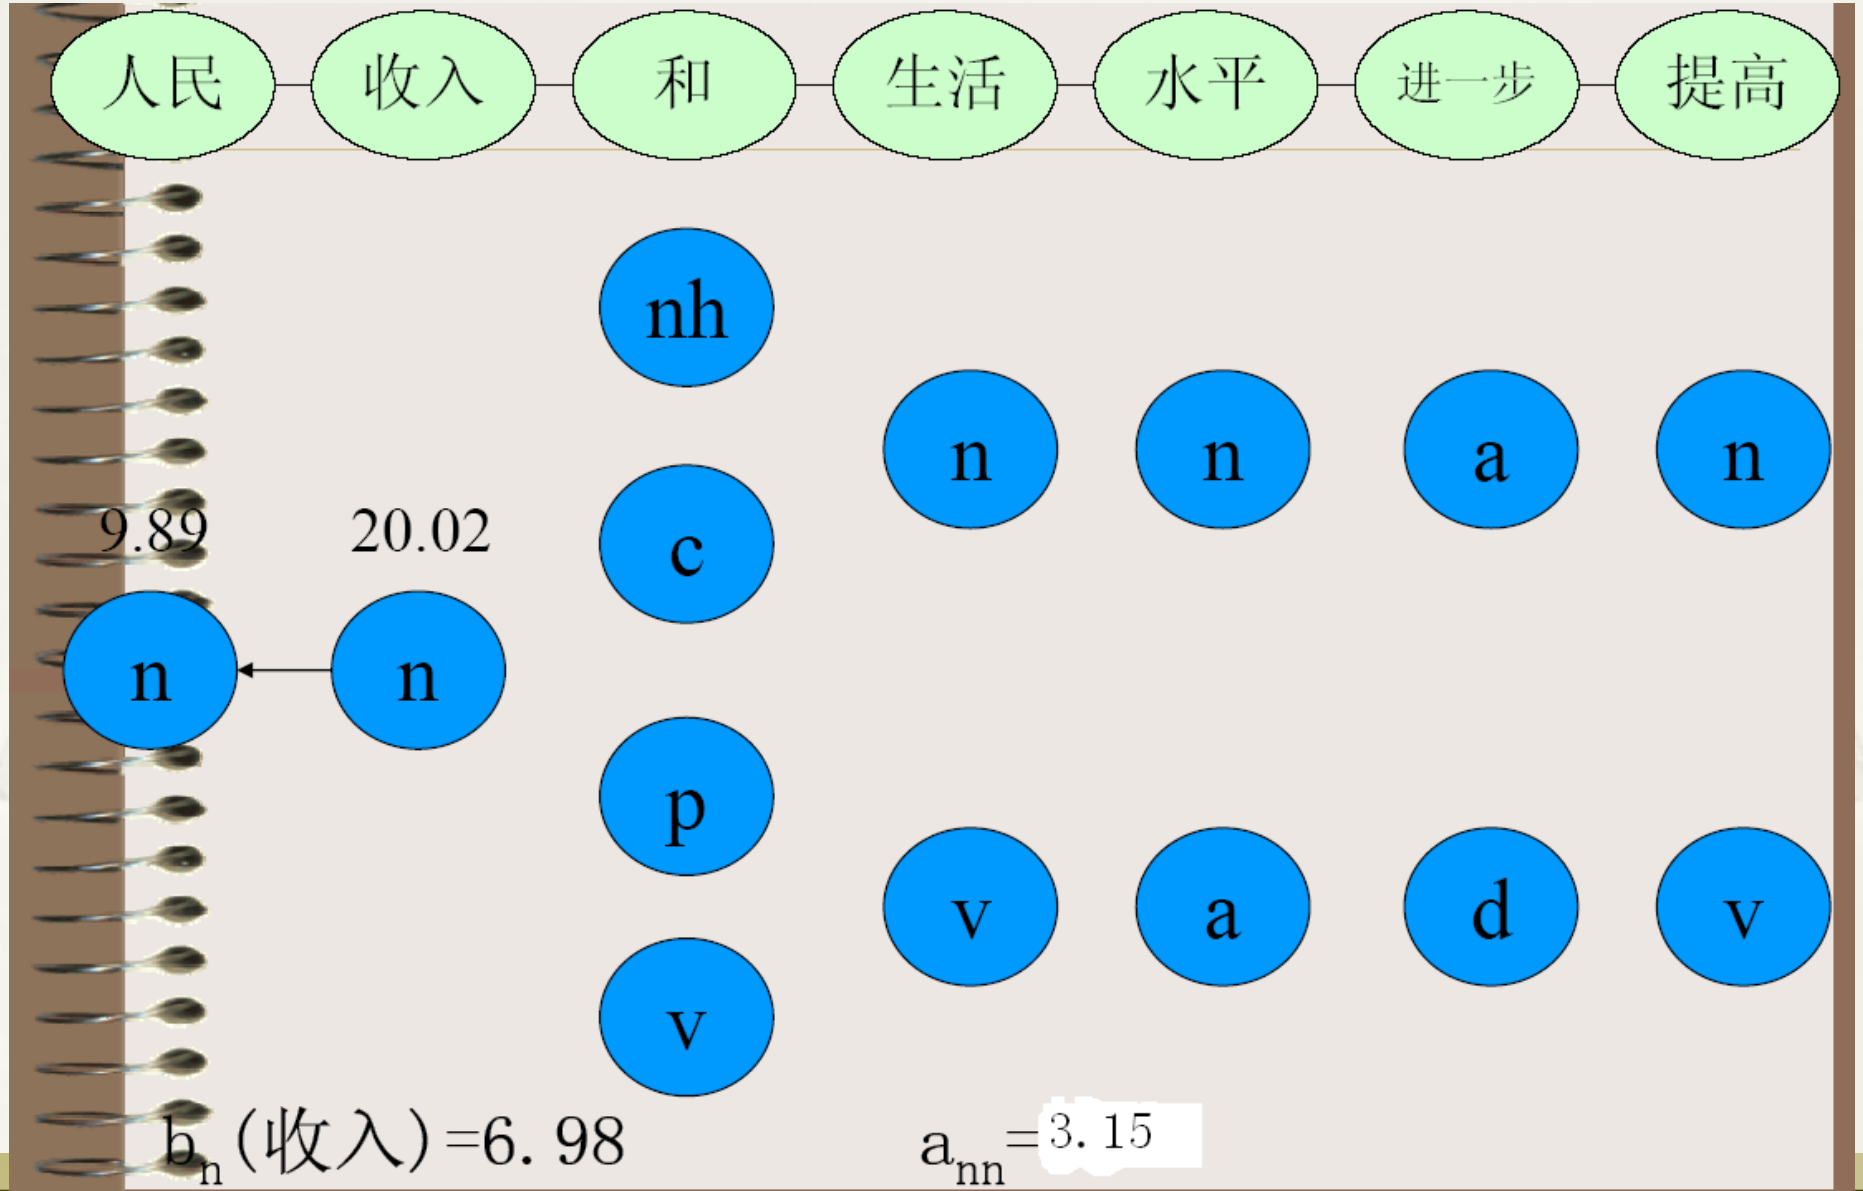
- 一个具体的分词+词性标注是如何完成的？
  - 第一步是候选词网格构造：利用词典匹配，列举输入句子所有可能的切分词语，并以词网格形式保存
  - 第二步计算词网格中的每一条路径的权值
  - 根据图搜索算法在图中找到一条权值最大的路径，作为最后的分词结果
    - 动态规划算法：Viterbi算法

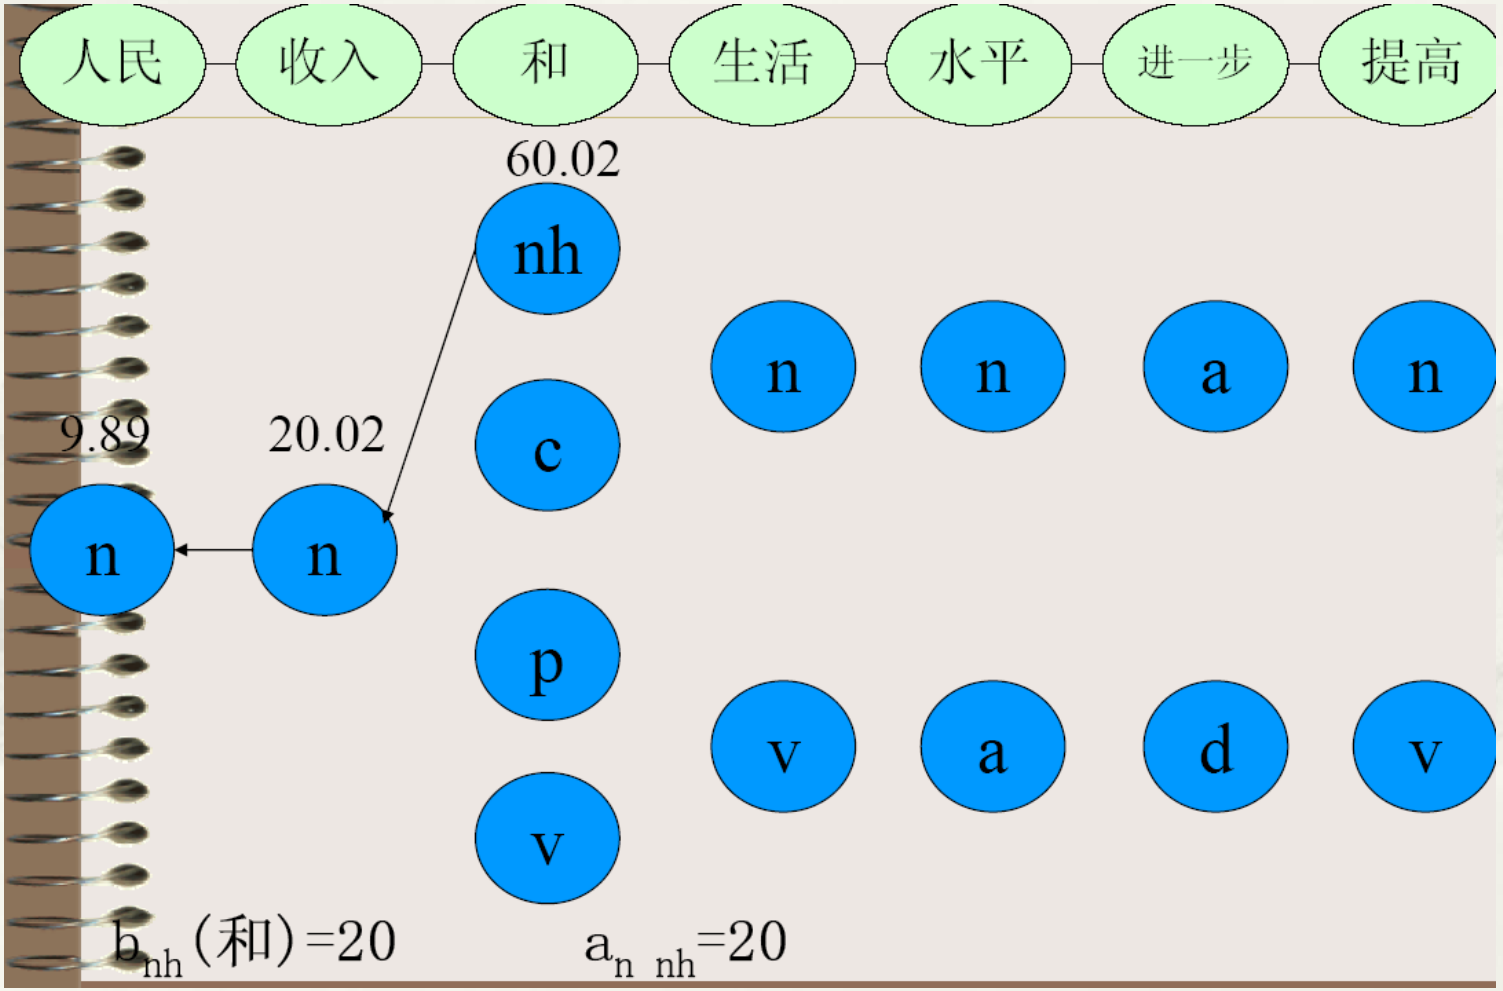
Viterbi搜索——例子

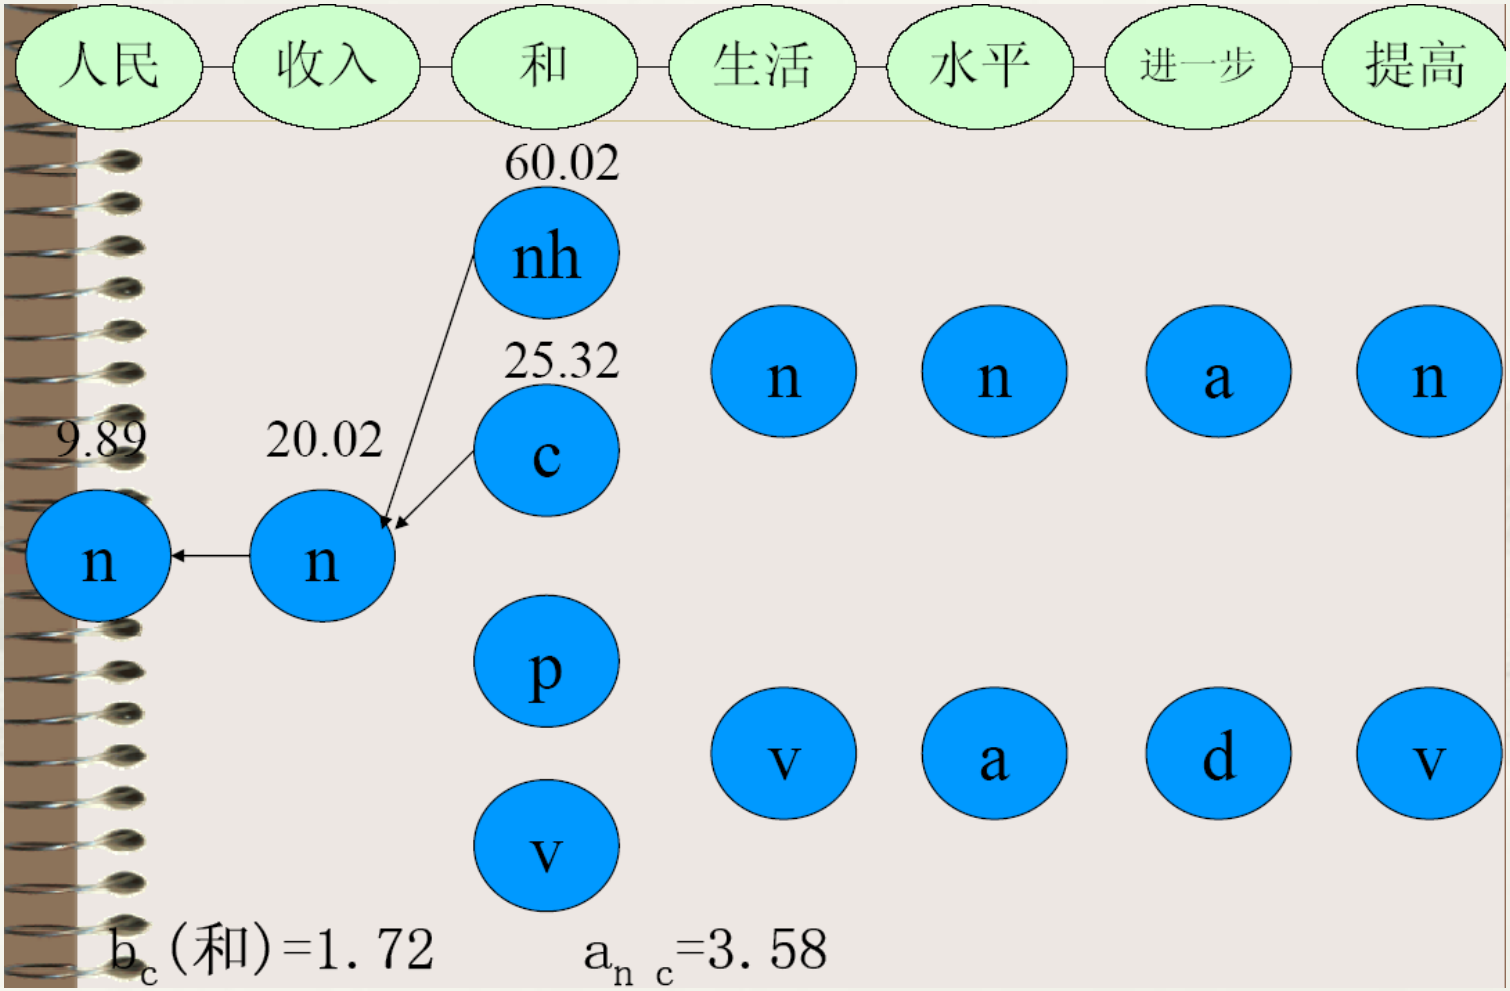
分词“词图”中的某段局部路径：

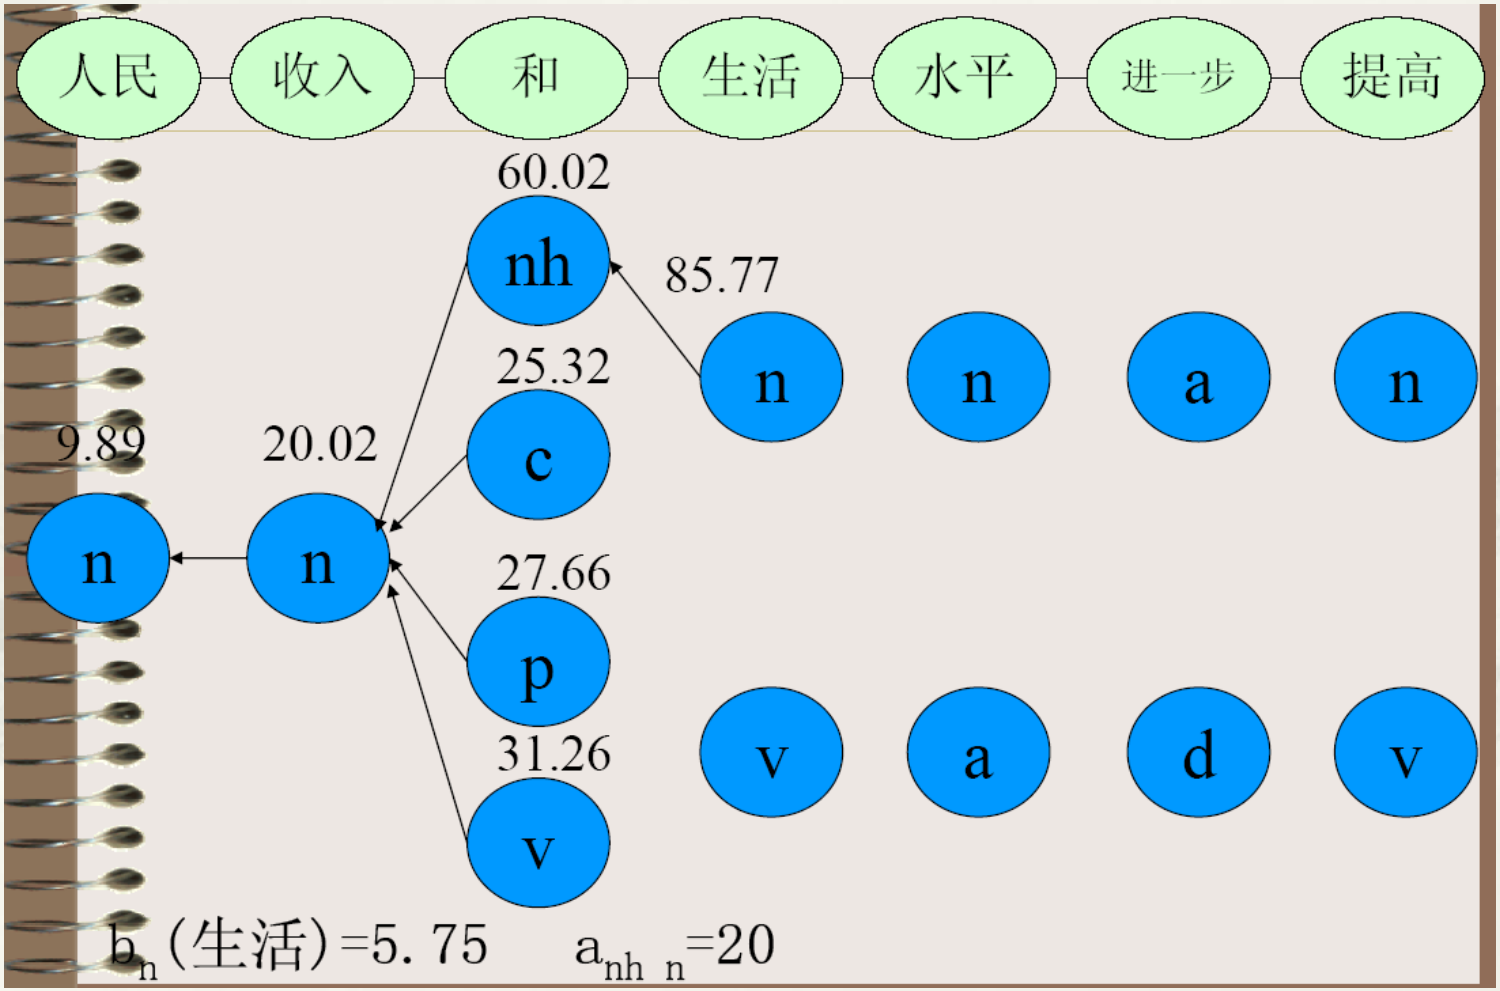


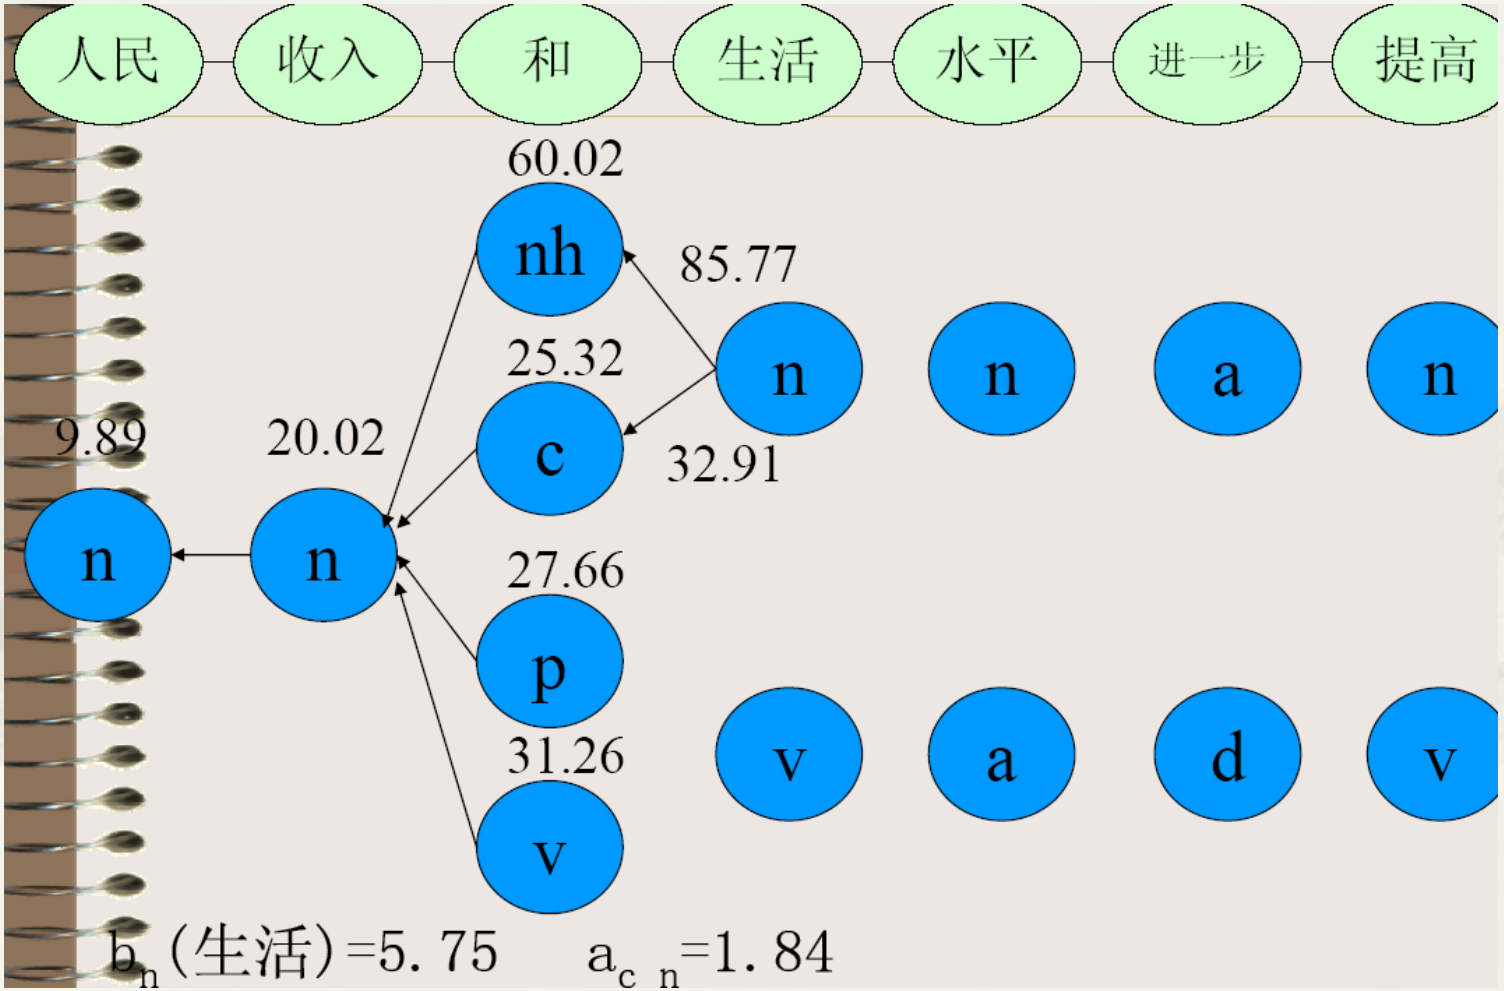
本例出处待考，谨在此致谢！

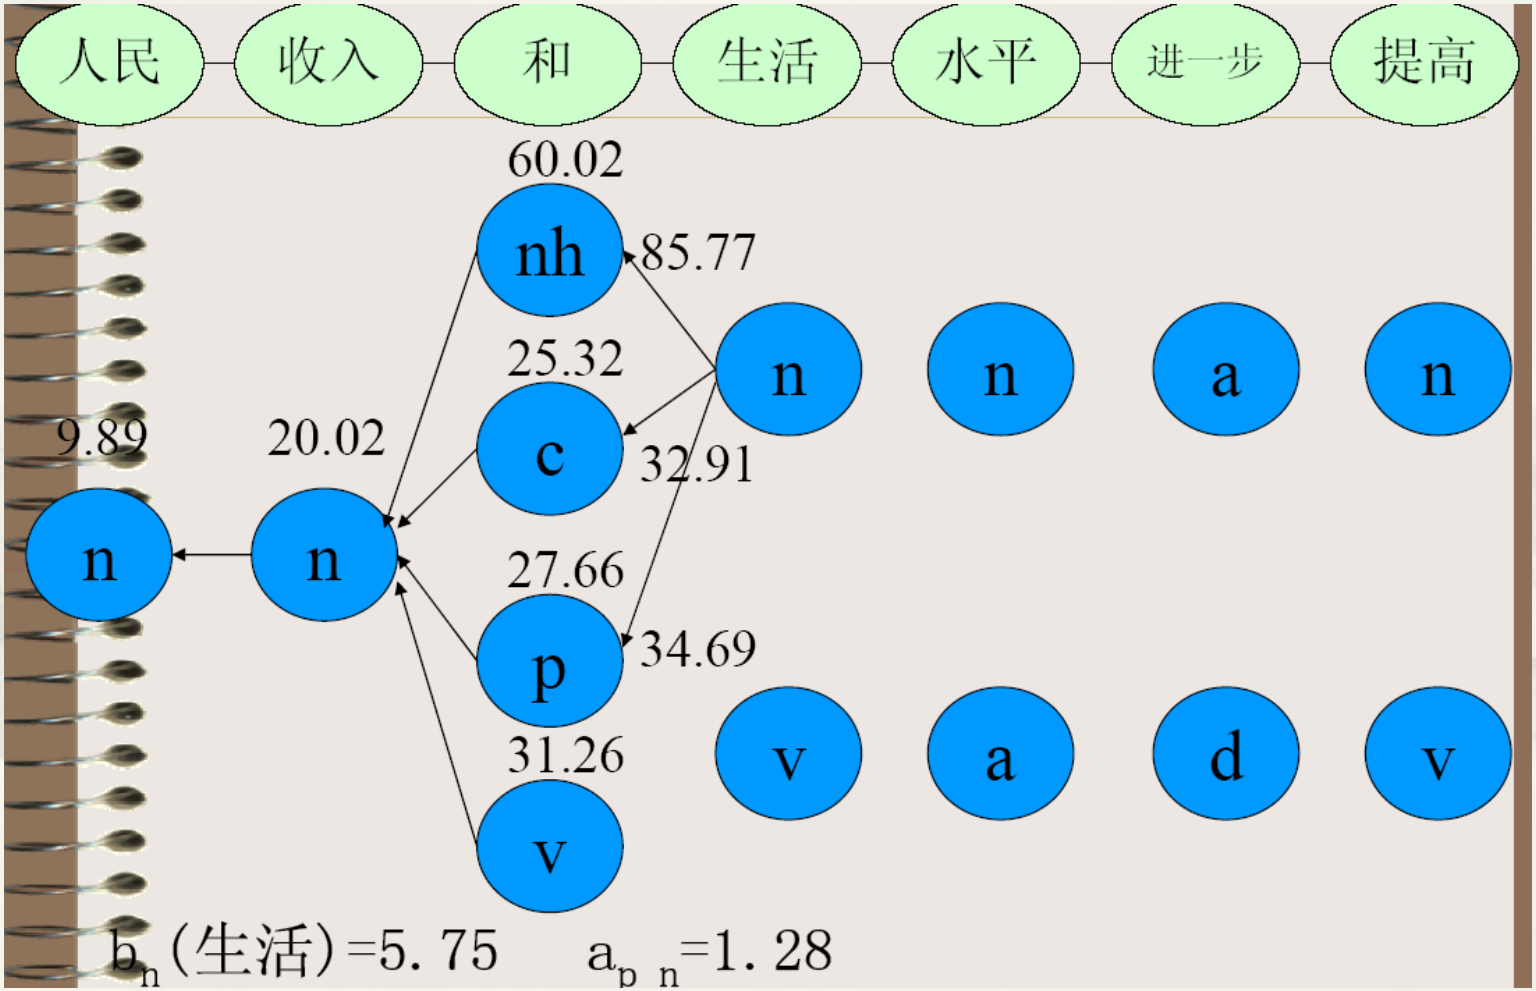

人民
收入
和
生活
水平
进一步
提高
nh
c
p
v
n
n
a
n
v
a
d
v
9.89
20.02
n
n
b_n(收入)=6.98
a_{nn}=3.15

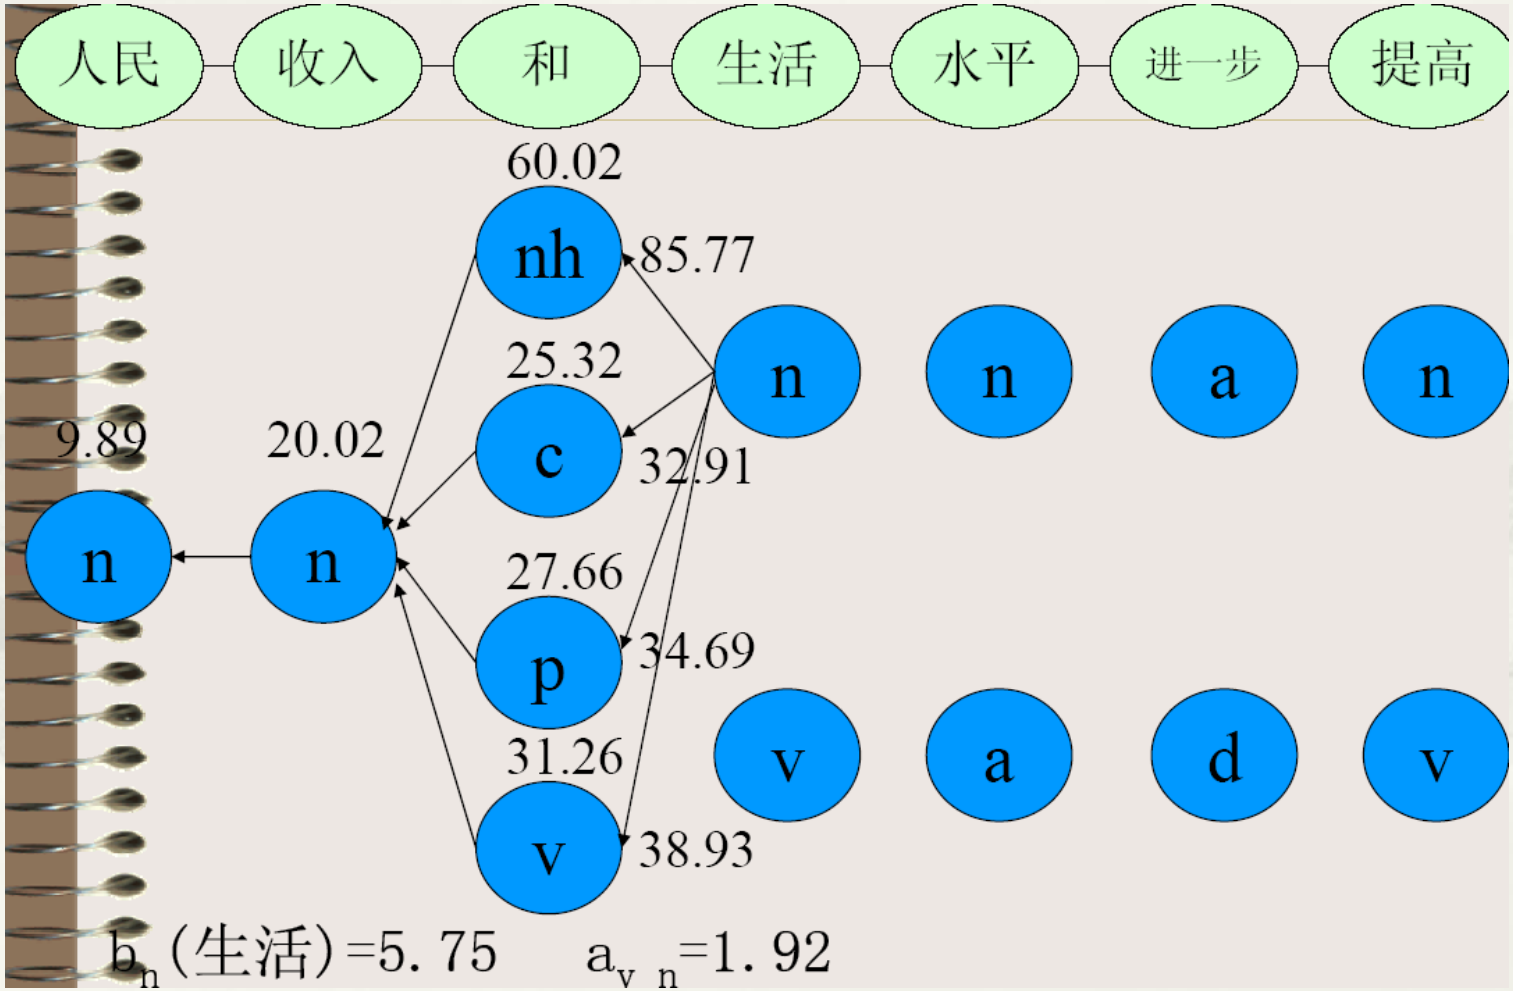

人民
收入
和
生活
水平
进一步
提高
60.02
nh
c
p
v
9.89
20.02
n
n
n
n
a
n
v
a
d
v
b_{nh}(和)=20
$a_{n\ nh}$=20


人民
收入
和
生活
水平
进一步
提高
60.02
nh
25.32
c
9.89
20.02
n
n
p
v
n
n
a
n
v
a
d
v
b_c(和)=1.72
a_n c=3.58

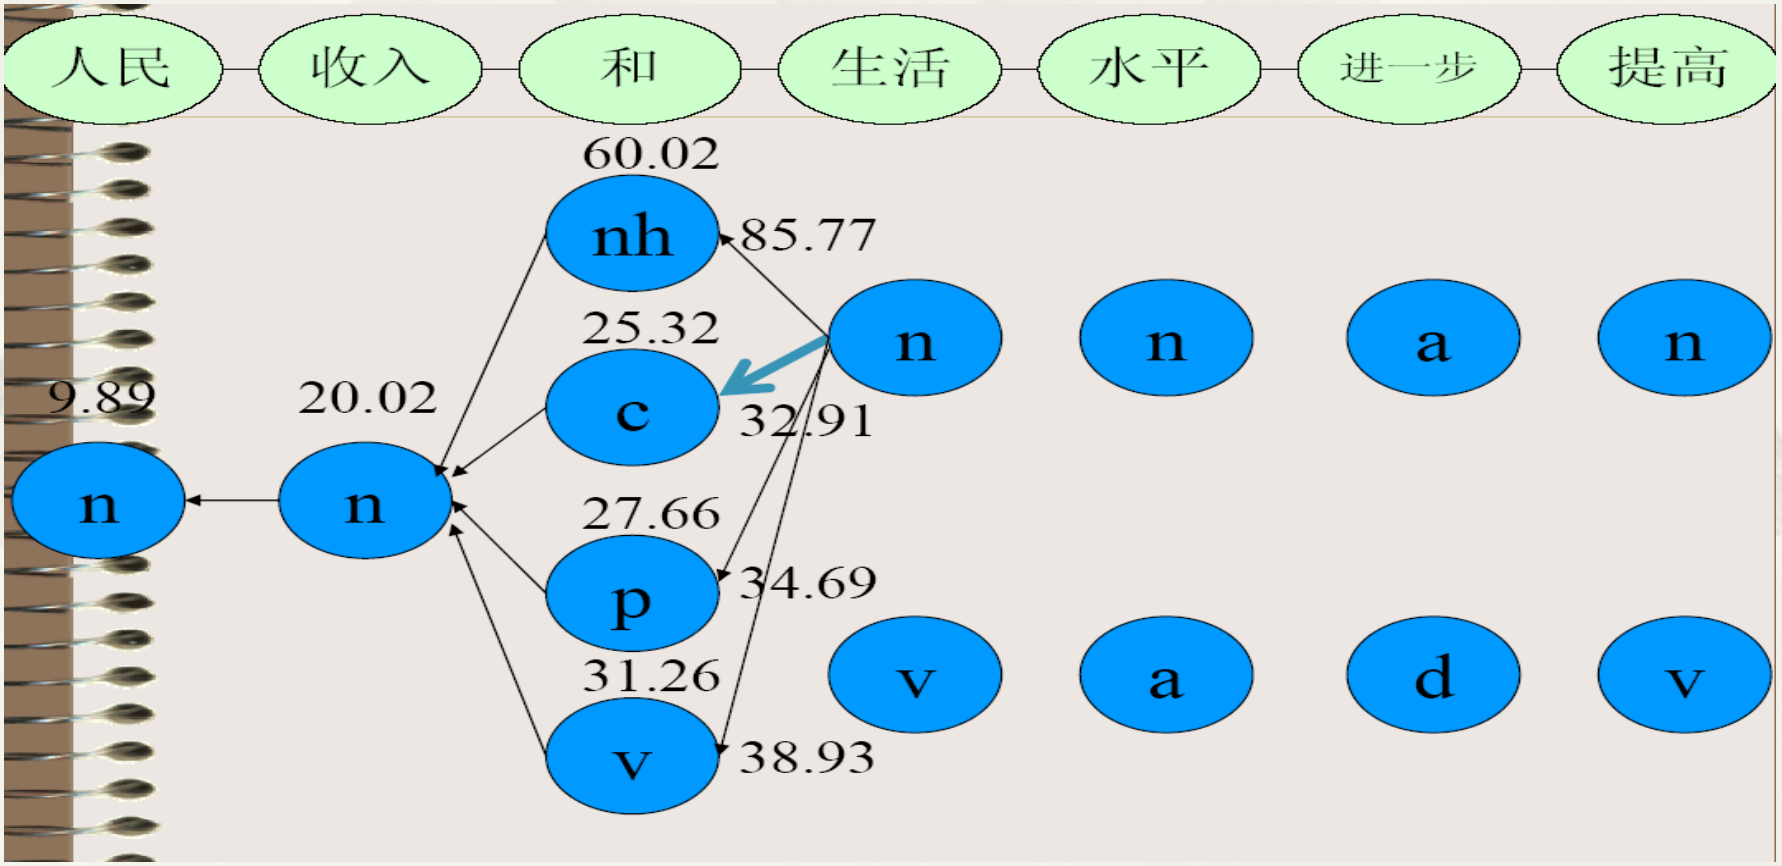

人民
收入
和
生活
水平
进一步
提高
60.02
nh
85.77
n
n
a
n
25.32
c
9.89
20.02
n
n
27.66
p
v
a
d
v
31.26
v
b_n(生活)=5.75
$a_{nh\ n}$=20

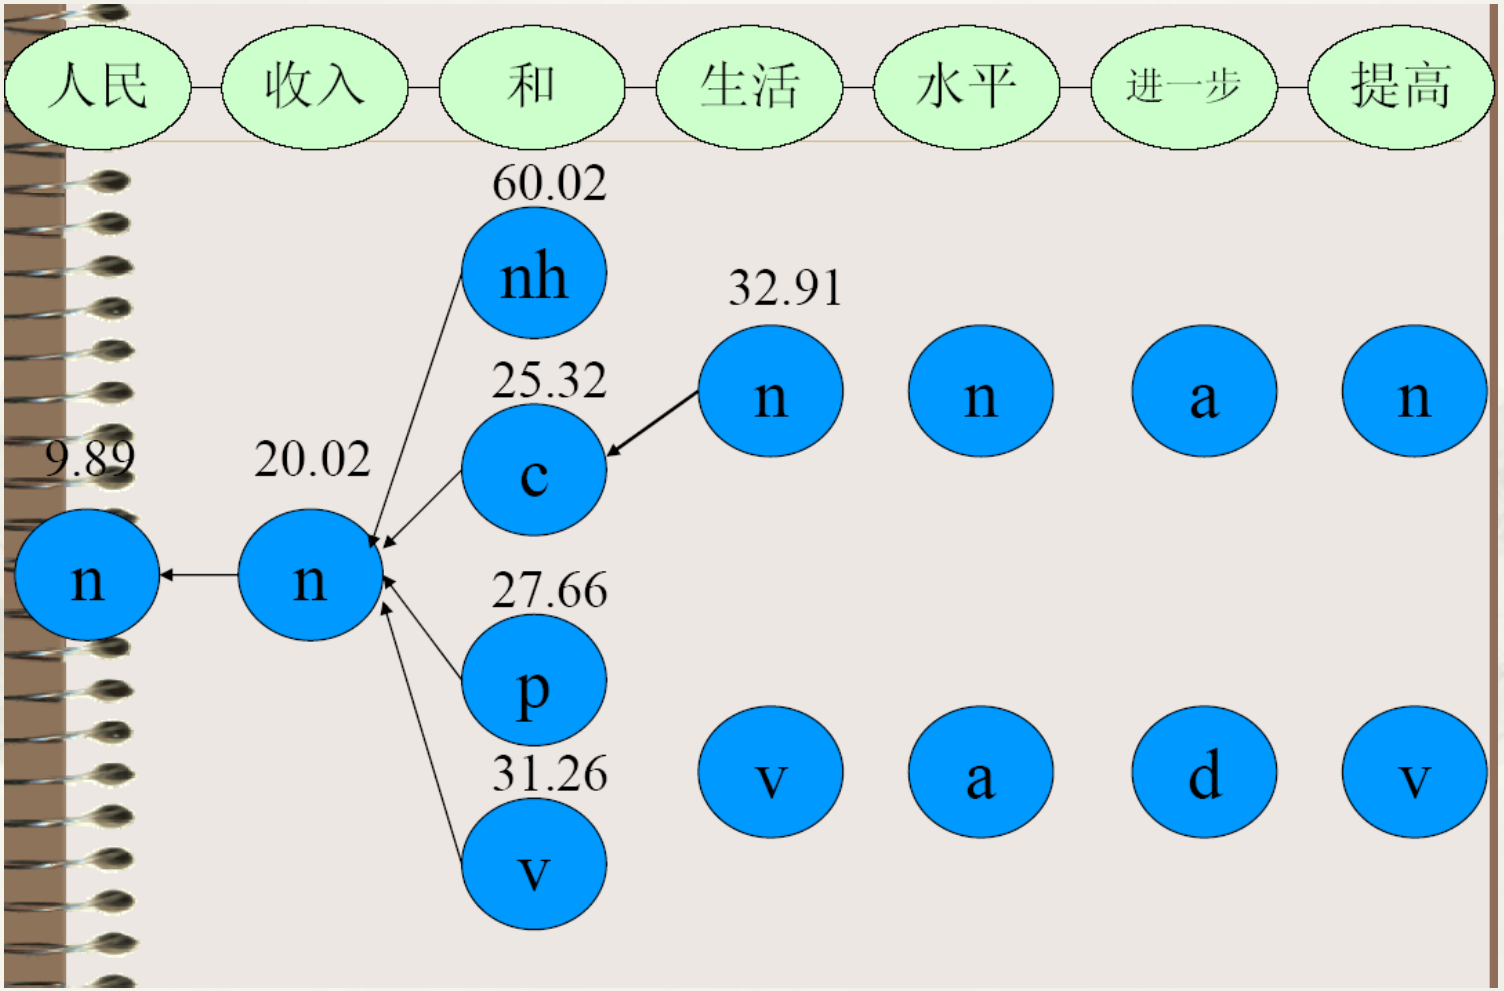

人民
收入
和
生活
水平
进一步
提高
60.02
nh
85.77
25.32
c
32.91
9.89
20.02
n
n
27.66
p
31.26
v
n
n
a
n
v
a
d
v
b_n(生活)=5.75
$a_{c\ n}$=1.84

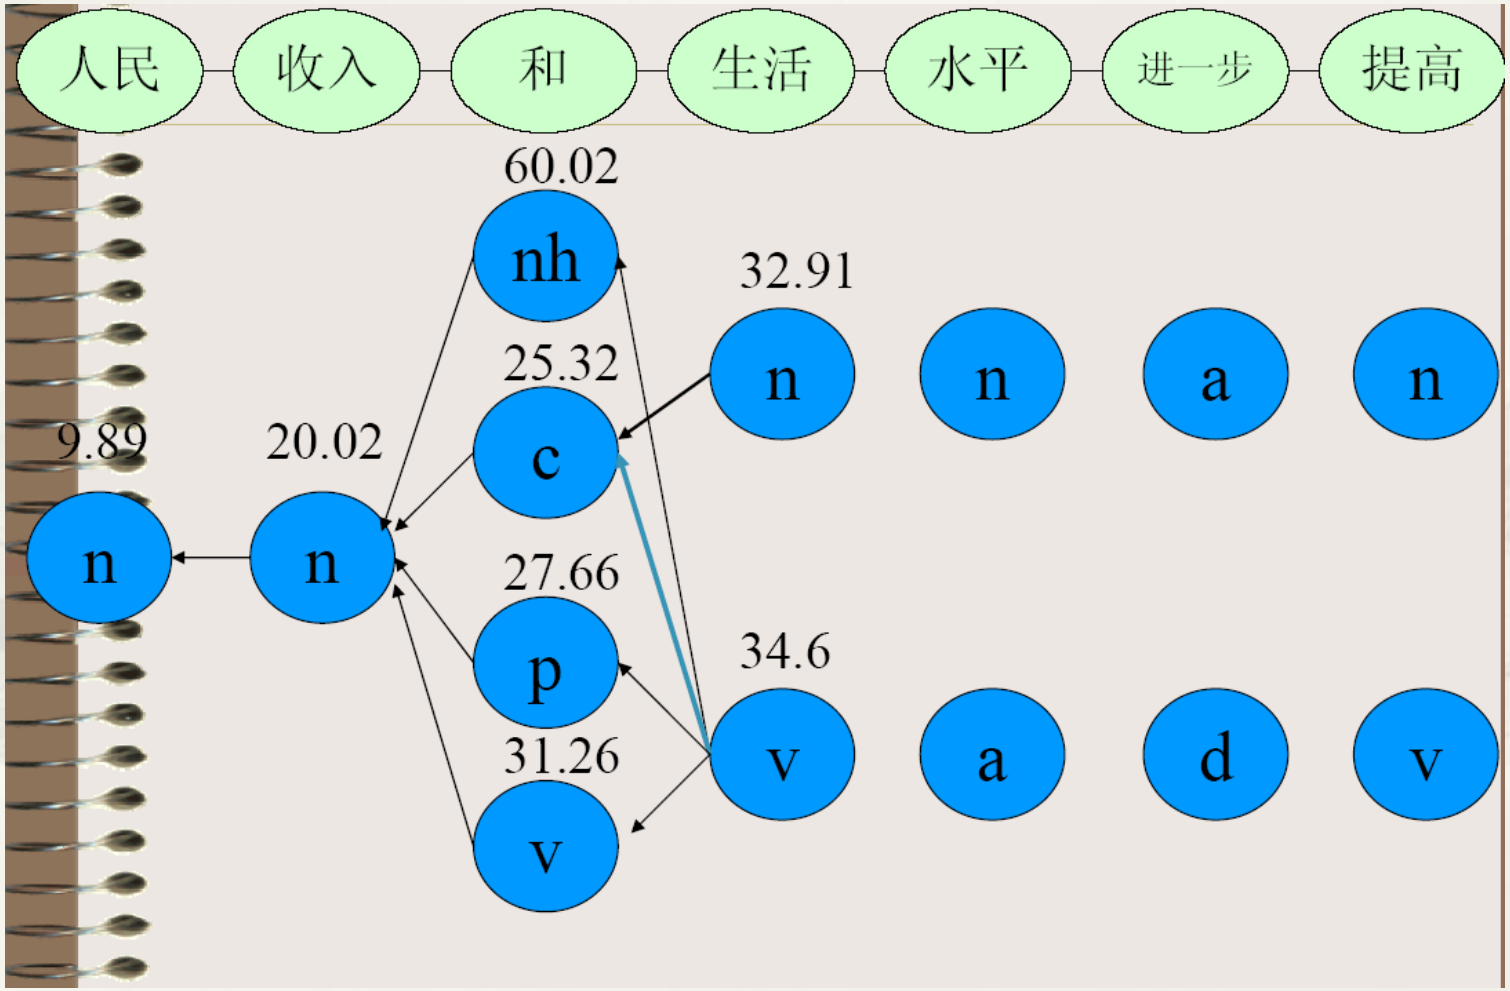

人民
收入
和
生活
水平
进一步
提高
60.02
nh
85.77
25.32
c
32.91
27.66
p
34.69
31.26
v
9.89
n
20.02
n
n
n
a
n
v
a
d
v
b_n(生活)=5.75
$a_{p\ n}$=1.28

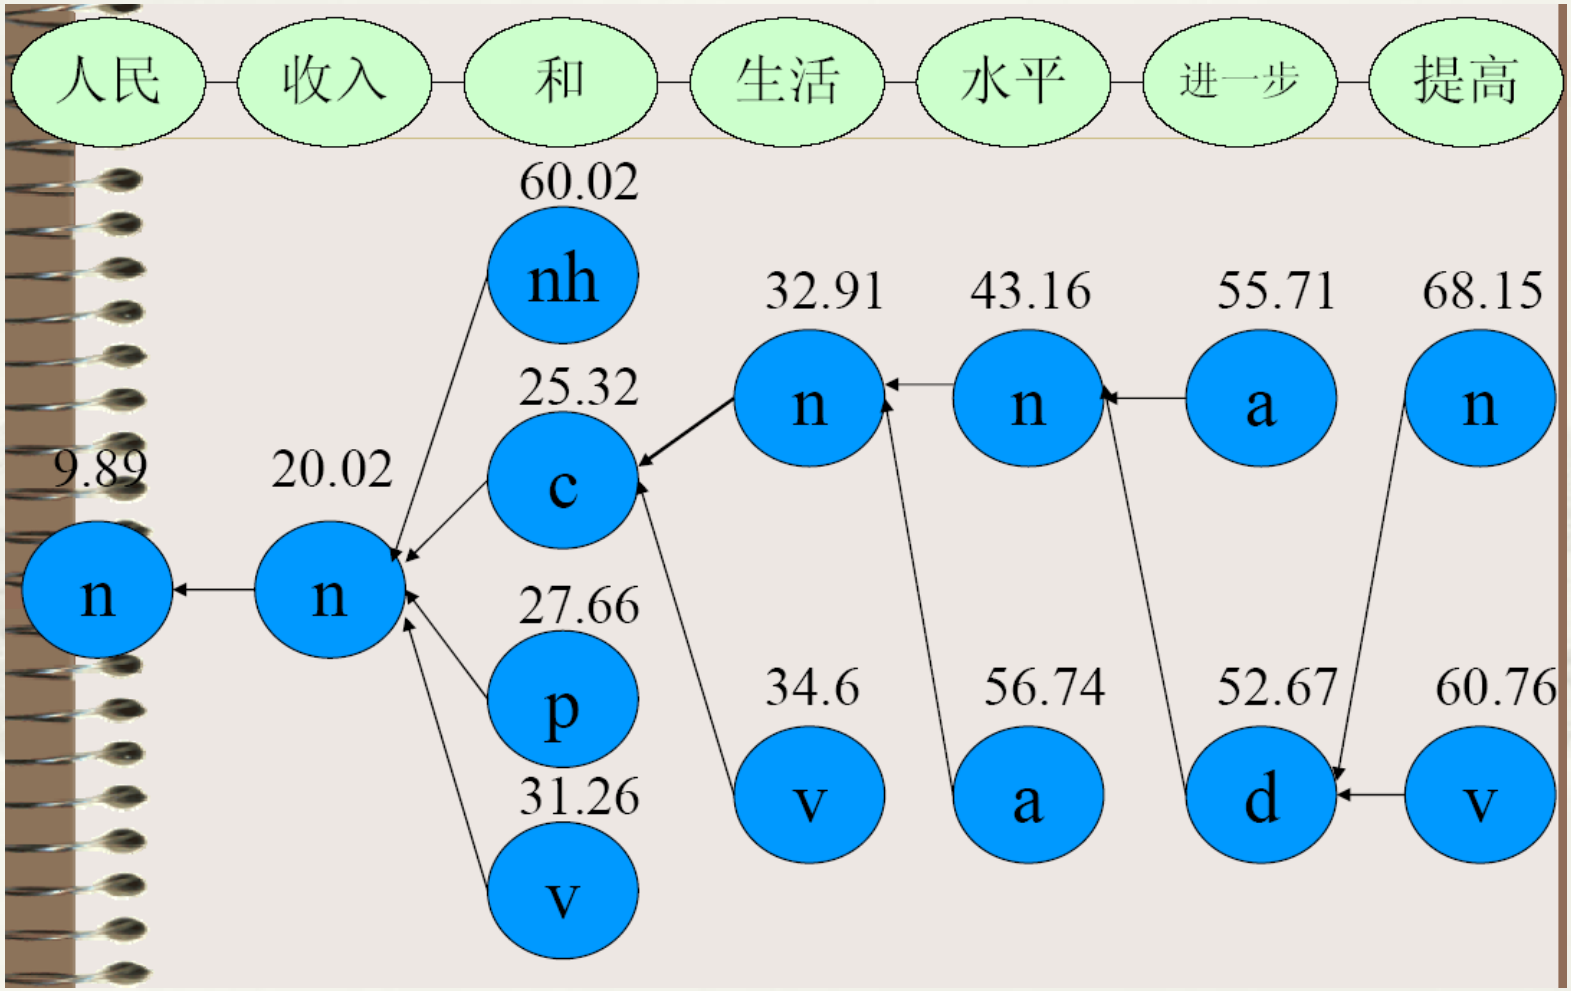

人民
收入
和
生活
水平
进一步
提高
60.02
nh
85.77
25.32
c
32.91
27.66
p
34.69
31.26
v
38.93
9.89
n
20.02
n
n
n
n
a
n
v
a
d
v
b_n(生活)=5.75
$a_{v\ n}$=1.92

记录“和→生活”的最佳路径是“c-n”

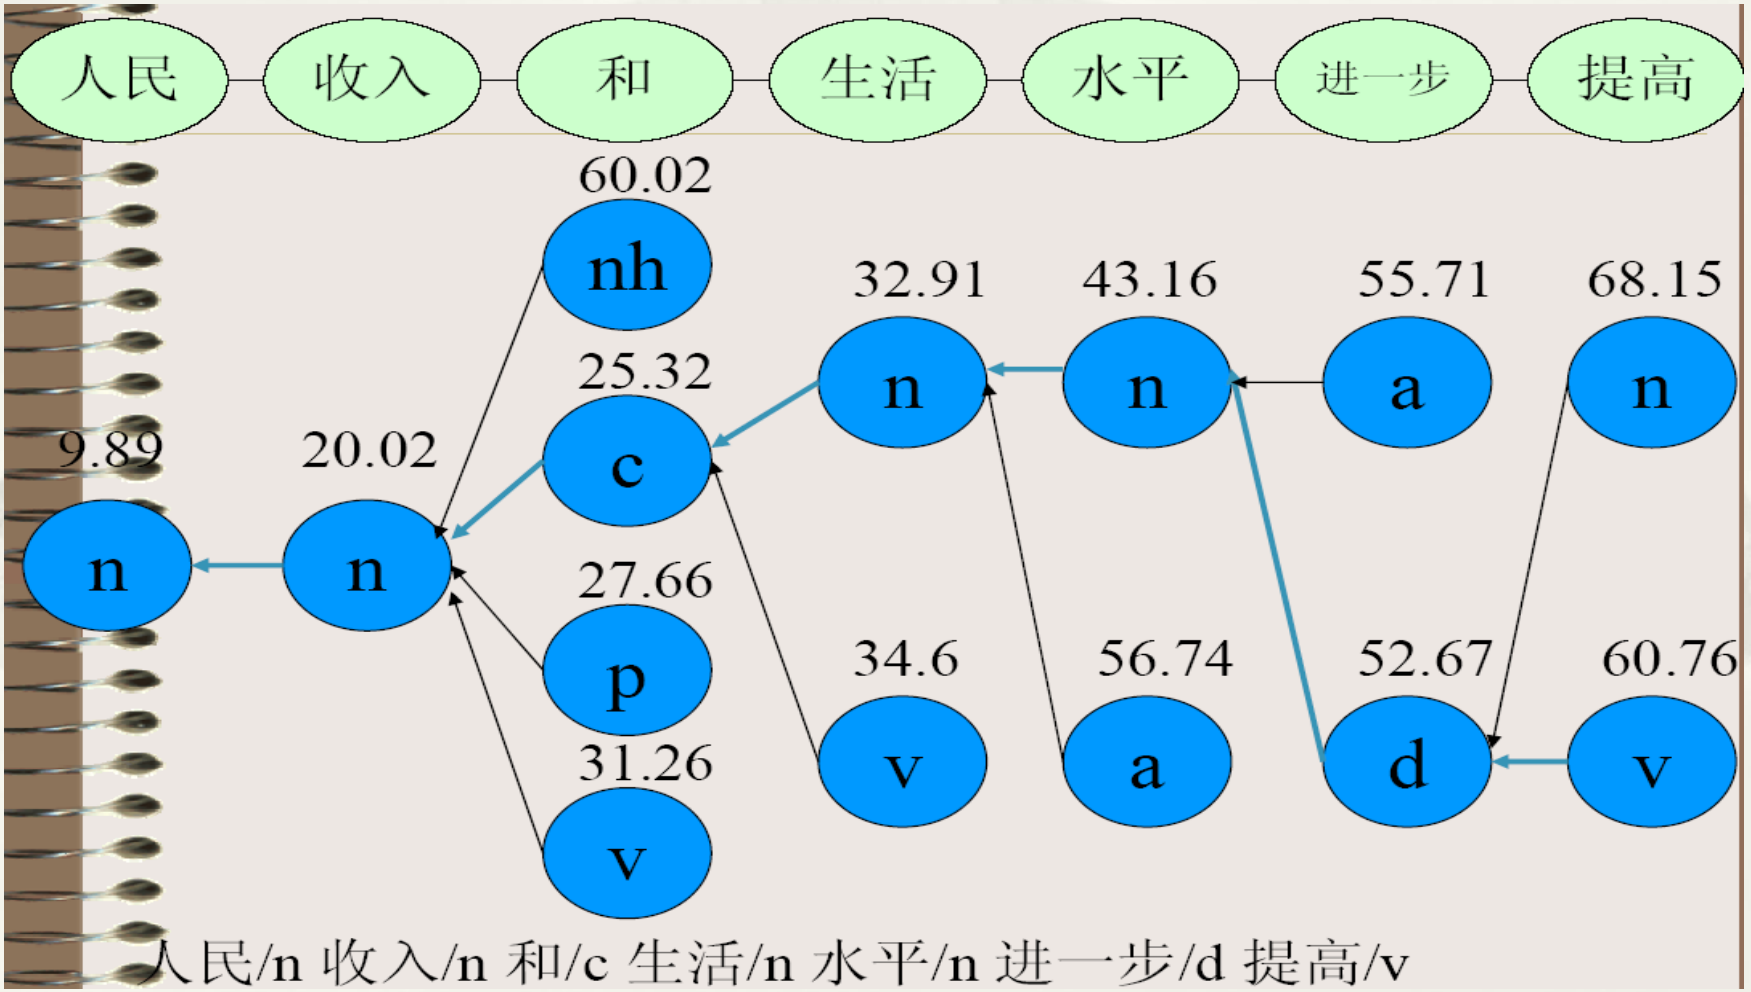



人民
收入
和
生活
水平
进一步
提高
60.02
nh
32.91
n
n
a
n
25.32
c
9.89
20.02
n
n
27.66
p
v
a
d
v
31.26
v


人民
收入
和
生活
水平
进一步
提高
60.02
nh
32.91
n
n
a
n
25.32
c
9.89
20.02
n
n
27.66
p
34.6
v
a
d
v
31.26
v


人民
收入
和
生活
水平
进一步
提高
9.89
n
20.02
n
60.02
nh
25.32
c
27.66
p
31.26
v
32.91
n
34.6
v
43.16
n
56.74
a
55.71
a
52.67
d
68.15
n
60.76
v

提取所有的“最优路径”记录，确定最优标记状态





END