自然语言处理

第5讲 自然语言处理系统评价

杨沐昀

哈尔滨工业大学计算学部
语言技术研究中心

yangmuyun@hit.edu.cn

主要内容

- 自然语言处理评价概述
- 自然语言理解评价
- 自然语言生成评价

评价的核心问题

- 自然语言处理的结果受“以人为本”的影响
  - 谁也赢不了 是牛是菜?
  - 谁也打不过 是赢是输?
- 评价的三个核心问题:
  - 评价数据
  - 评价方法
  - 评价指标

评价数据

关乎结果是否有效

- 数据划分：测试vs（训练、评估）
- 领域：通用 or 专业?
- 时效性
- 输入和输出的格式
- ……

评价方法

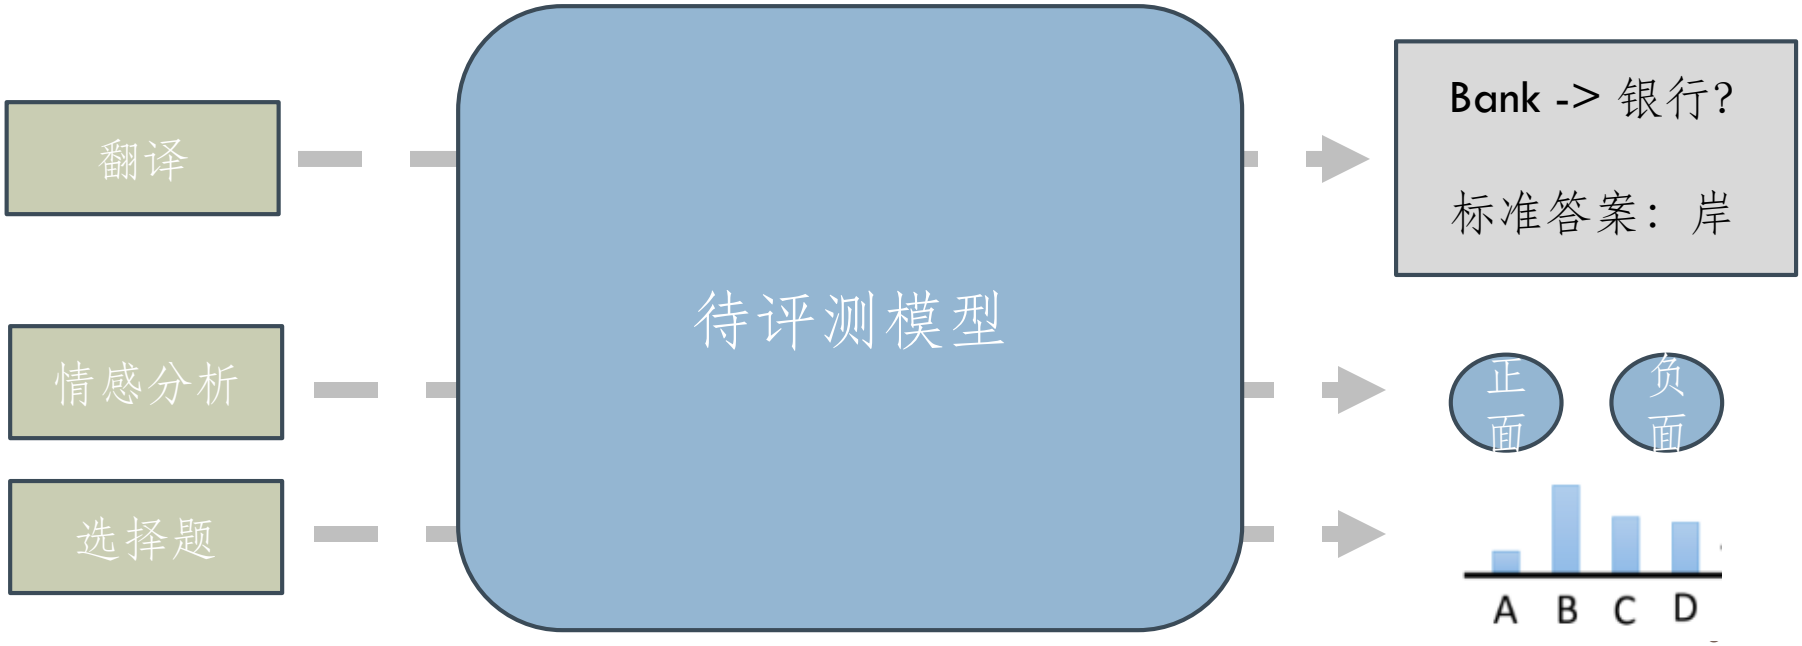
产生评价结果的方式：关乎结果是否准确

- 人工评价：稳定性？速度？成本？
- 基于统计的方法：简单有效，但是并不适用于所有的场景
- 模型自动打分：可扩展性强，存在模型偏见
- 评价方法广义上还包括评价策略、评价实施等因素……
  - 评价策略中有直接评价和间接评价之分

评价指标

定量形式：关乎结果定量是否妥当

- 不同的应用场景和输出格式，需要不同的指标进行评价
  - 模型输出：标签？一句话？得分？
  - 答案：有无标准答案？标准答案的完备性？



Benchmark基准测试—当前范式

- 评价实施：在解决了评价的三个基本问题后，就可以构建一个数据集以及相关的工具作为评价的框架
  - 大规模公开评测，或者
  - 公认的基准测试（**Benchmark)**
- 基准测试是评估和比较不同机器学习模型在特定任务上性能的一套标准化方法，提供统一的数据、任务和评估指标
  - 具体的任务定义：输入输出、任务复杂性
  - 统一、具体、划分好的数据集
  - 具体的评价指标以及基线

Benchmark基准测试

- 常见的Benchmark有：
  - 综合型：GLUE、BIG-BENCH……
  - 问答与阅读理解：SQuAD、TriviaQA……
  - 文本生成与摘要：CNN/Daily Mail、Xsum……
  - 自然语言推理与语义匹配：SNLI、MNLI……
  - 机器翻译：WMT、IWSLT……
  - 对话：Persona-Chat……
  - 代码、数学与推理：GSM8K、MATH……

评价的重要意义

- 加快模型开发
- 指导模型改进
- 促进技术进步
- 确保模型的可靠性和稳定性
- ……

自然语言处理任务的类型

- 自然语言处理任务大体可以分为两大类，分别是自然语言理解（NLU）和自然语言生成（NLG）

- **自然语言理解**：文本分类、实体识别等，输入是一段自然语言，而输出通常是类别或者分数，因此这类任务通常有唯一的标准答案

- **自然语言生成**：机器翻译、自动摘要等，系统需要输出一段文字，因此这类任务通常没有唯一的标准答案

主要内容

- 自然语言处理评价概述
- 自然语言理解评价
- 自然语言生成评价

自然语言理解评价

- 自然语言理解的任务通常可以归纳为分类任务或者回归任务
  - 分类任务解决属于哪个类别的问题，输出是离散值
  - 回归任务解决具体数值是多少的问题，输出是连续值
- 关键：模型的输出与标准答案的一致性

自然语言理解的分类问题评价

- 自然语言理解的任务中的分类问题：文本分类、序列标注、文本蕴含等，以文本分类为例，有下面这段文字：

“上海市交通委今日宣布，将于本月底在浦东新区率先启动智能公交试运行项目。该项目采用最新的自动驾驶技术与智能调度系统，能够根据实时路况调整发车间隔，提高运力利用率……”

任务需要判断，这段文字属于哪个类别：论文、小说还是新闻？

准确率

- 最基础的指标：准确率——输出类别正确的比例

$$Accuracy = \frac{n_{correct}}{n_{total}}$$

  - $n_{correct}$为判断正确的样例数量，n_{total}为总样例数量。
- 准确率是一个非常单一的评价指标，只能知道判断对的数量，却无法知道系统的缺陷在哪

混淆矩阵

- 准确率事实上把结果分为两个部分：正确的与错误的
- 但正确和错误的结果还存在更细粒度的划分
- 以二分类为例：数据样例中有两个类别，正例和负例
  - 判断正确的部分：被判断为正例的正例、被判断为负例的负例
  - 判断错误的部分：被判断为正例的负例、被判断为负例的正例

通过数量可以判断系统在某个类别上的缺陷等信息

混淆矩阵

- 以二分类为例：混淆矩阵如下

混淆矩阵		预测正负	
		正	负
真实正负	正	TP	FN
	负	FP	TN

- TP（True Positive）：实际为正，预测为正
- FN（False Negative）：实际为正，预测为负
- FP（False Positive）：实际为负，预测为正
- TN（True Negative）：实际为负，预测为负

混淆矩阵

- 根据混淆矩阵，准确率Accuracy的计算变为：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

混淆矩阵		预测正负	
		正	负
真实正负	正	TP	FN
	负	FP	TN

PRF值

- 根据混淆矩阵的信息，一定程度上可以认识到模型在不同类别上的表现差异，但在单类别上的能力有更细节的考量
- 两个重要的问题：
  - 被判断为正例的例子有多少真的是正例?
  - 真正的正例有多少被系统正确判断了?

PRF值

- 两个重要的问题：
  - 被判断为正例的例子有多少真的是正例?
  - 真正的正例有多少被系统正确判断了?
- 第一个问题考查的是系统给出的正例有多少是正确的，某种程度上和可信度接近
- 第二个问题考查的是系统的发掘能力，将潜在的正例发现的能力

PRF值

- 两个重要的问题：
  - 被判断为正例的例子有多少真的是正例?
  - 真正的正例有多少被系统正确判断了?
- Precision(准确率)和Recall(召回率)用于解释上面的问题
  - Precision(精确率)为判断正确的正例占总判断为正例的比例
  - Recall(召回率)为判断正确的正例占所有真正正例的比例

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

P与R的权衡

- 如果追求100%的精确，那么就尽量只判断少量样本降低FP，这样的结果是有大量的正例被判断为负例
- 如果追求100%的召回，那么就将所有的样本都判断为正例，这样的结果是有大量的负例被判断为正例
- 不同的场景可能有不同的侧重：

体检阶段，医院可能更注重召回率，这样可能能找到更多的潜在病人并提前治疗；而筛选出病人之后，医院可能需要进行复查来确认是否患病，这时候就需要更注重精确率。

F值

- F值用于综合衡量P与R值，展现模型效果：

$$F1 = \frac{2PR}{P + R}$$

- 上述的公式为F值的一个经典形式——F1值，它是P与R的调和平均，在这个形式下，R与P的重要程度是相同的

F值

- 在实际中，P与R的重要性可能不同，因此引入一个超参数k来调整两者在F值中的重要程度

订正：分子是$1+k^2$

$$F = \frac{(1+k)PR}{k^2P + R}$$

  - 其中，k可以用于平衡精确率和召回率之间的权重。值得注意的是，当k=1时，F值即是F1值，这也是F1中1的含义。

多分类问题中的PRF值

- 从引入混淆矩阵开始，讨论就一直在二分类问题中进行
- 转移到多分类上时，直接的问题是混淆矩阵的4个指标如何计算?
- 对于多分类问题，单独讨论某个类别时，事实上就是一个二分类问题，每一个类别都有一个单独的混淆矩阵

多分类问题中的PRF值-宏平均

- 宏平均(Macro)根据每个类别的混淆矩阵所计算出的P与R，进行算术平均，分别得到P与R的平均值，之后用这两个值计算F1

$$macro - P = \frac{1}{n}\sum_{i=1}^{n} P_i$$

$$macro - R = \frac{1}{n}\sum_{i=1}^{n} R_i$$

$$macro - F1 = \frac{2 * macro - P * macro - R}{macro - P + macro - R}$$

多分类问题中的PRF值-微平均

- 微平均则在个体上进行统计，将每个混淆矩阵的TP、TN、FP、FN进行相加，得到一个新的混淆矩阵，接着使用这个新的混淆矩阵计算micro-F1

$$micro - P = \frac{\sum TP}{\sum TP + \sum FP}$$

$$micro - R = \frac{\sum TP}{\sum TP + \sum FN}$$

$$micro - F1 = \frac{2 * micro - P * micro - R}{micro - P + micro - R}$$

宏平均与微平均的区别

- 宏平均对每个类别分类效果的考量是一样的，因此在小样本上的高质量结果则对宏平均影响较大。
- 微平均则对于不同类别根据数量进行了平均，因此，样本较少的类别的结果可能在一定程度上被忽略。

$$macro - P = \frac{1}{n}\sum_{i=1}^{n} P_i$$

$$micro - P = \frac{TP}{TP + FP}$$

$$macro - R = \frac{1}{n}\sum_{i=1}^{n} R_i$$

$$micro - R = \frac{TP}{TP + FN}$$

$$macro - F1 = \frac{2 * macro - P * macro - R}{macro - P + macro - R}$$

$$micro - F1 = \frac{2 * micro - P * micro - R}{micro - P + micro - R}$$

加权宏平均

- 宏平均对每个类别分类效果的考量是一样的，因此在小样本上的高质量结果则对宏平均影响较大。
- 如果对宏平均进行加权，就可以实现不同类别的侧重：

$$macro - P = \frac{1}{n}\sum_{i=1}^{n} w_i P_i$$

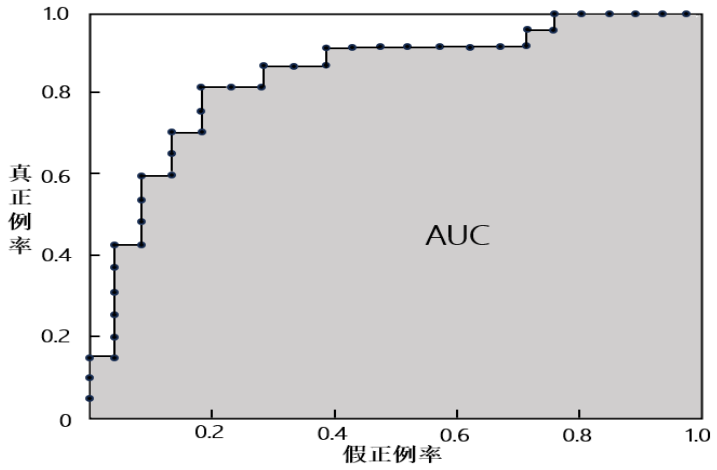
$$macro - R = \frac{1}{n}\sum_{i=1}^{n} w_i R_i$$

$$macro - F1 = \frac{2 * macro - P * macro - R}{macro - P + macro - R}$$

- 其中，w_i为每个类别所设定的权重

ROC曲线

- ROC曲线以假正例率（False Positive Rate, FPR）为横轴，真正例率（True Positive Rate, TPR）为纵轴，如下图所示：



$$TPR = TP/(TP+FN)$$
$$FPR = FP/(FP+TN)$$

- 基于ROC曲线，可以通过计算曲线下的面积，即AUC（Area Under Curve）值来评估分类模型的性能，面积越大，证明分类模型的效果越好。

自然语言理解的回归问题评价

- 自然语言理解的任务中的回归问题有：相似度计算、文本评分等等
- 任务需要模型输出一个连续的数值而不是类别这样离散的结果，举个例子：模型作为作文评分系统的一个部分，作文质量越高，系统应该给出的打分就越高。
- 自然语言理解中的评分任务常用的评价指标包括：平均绝对误差、均方根误差、皮尔逊相关系数

平均绝对误差

- 评价回归问题结果好坏的一个最直观方法，就是比较我们预测的值与实际值的误差大小。
- 给出预测值为$\hat{y}_i$，真实值为y_i，共有n个样本点，那么其误差可以这样计算：

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|\hat{y}_i - y_i|$$

- MAE的意思是平均绝对误差（Mean Absolute Error），其反映了预测值与真实值绝对误差的平均水平。
  - 平均绝对误差越小，模型估计的分数就越合理。

平均绝对误差

- 特点：
  - 计算简单
  - 对误差值更稳定——不敏感
  - 所有样本的错误具有相同的权重
- 适用场景：误差值敏感度低、需要等权重判断的场景

均方根误差

- 与平均绝对误差类似，方差也能衡量数据的离散程度

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2}$$

- RMSE的意思是均方根误差（Root Mean Square Error），其反映的是真实值与预测值的偏离程度。

均方根误差与平均绝对误差

- 均方根误差：
  - 对偏离值的敏感程度较高
  - 预测值在真实值上的变化程度
- 平均绝对误差：
  - 对偏离值敏感低
  - 预测值与真实值的距离

为什么不使用均方误差?

- 均方误差即不开根号的均方根误差:

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2$$

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2}$$

为什么不使用均方误差?

- 均方根误差将误差的度量转换回了原始数据的单位，它比均方误差更易于直接解释
- 如果数据单位是米，则均方误差的单位是平方米，而均方根误差的单位仍然是米。

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2}$$

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2$$

皮尔逊相关系数

- 皮尔逊相关系数（Pearson Correlation Coefficient）常常运用到变量之间的相关性分析中，是一种常用的回归指标
- 在作文评分的例子中，一个合理的思路是衡量系统评价的分数与实际作文应该得到的分数之间的相关性，相关性越大则说明我们的系统效果越好。

皮尔逊相关系数

- 协方差是两个变量之间总体误差的期望，但协方差的大小受到变量的量纲的影响。因此，皮尔逊相关系数对协方差进行标准化，计算方法如下：

$$\rho_{X,Y} = \frac{cov(X,Y)}{\sigma_X \sigma_Y} = \frac{E\big((X-\mu_X)(Y-\mu_Y)\big)}{\sigma_X \sigma_Y} = \frac{E(XY)-E(X)E(Y)}{\sqrt{E\left(X^2\right)-E^2(X)}\sqrt{E\left(Y^2\right)-E^2(Y)}}$$

其中，X与Y分别是要比较的两个变量，μ_X, μ_Y分别是两个变量的均值，σ_X, σ_Y分别为两个变量的均方差，$cov(X,Y)$为两个变量的协方差。

皮尔逊相关系数

- 皮尔逊相关系数计算方法如下：

$$\rho_{X,Y} = \frac{cov(X,Y)}{\sigma_X \sigma_Y} = \frac{E\big((X-\mu_X)(Y-\mu_Y)\big)}{\sigma_X \sigma_Y} = \frac{E(XY)-E(X)E(Y)}{\sqrt{E\big(X^2\big)-E^2(X)}\sqrt{E\big(Y^2\big)-E^2(Y)}}$$

- 通常这个系数可以用小写字母r表示，且其可以单纯地使用样本点进行估计：

$$r = \rho_{X,Y} = \frac{1}{n-1}\sum_{i=1}^{n}\left(\frac{X_i-\mu_X}{\sigma_X}\right)\left(\frac{Y_i-\mu_Y}{\sigma_Y}\right)$$

其中，(X,Y)为两个变量的一个样本点，n为样本点数量

皮尔逊相关系数的意义

- r的取值范围在$[-1,1]$之间，其数学上的意义可以用于衡量两个变量之间的线性关系
  - 当$r=1$时，说明X,Y完全正相关
  - 当$r=-1$时，说明X,Y完全负相关
  - 当$r=0$时，说明X,Y没有线性关系，但可能存在别的关系
  - |r|=（0~0.2~0.4~0.6~0.8~1）：几乎没有相关、弱相关、中的呢各相关、强相关、非常强的相关

皮尔逊相关系数的特点

- 对称性：X, Y在计算上对称
- 尺度不变性：尺度上与位置上的变换并不会影响r
  - 变量$X' = a + bX$,其中$a, b \in R$,则有$\rho_{X,Y} = \rho_{X',Y}$
- 使用均值和方差进行计算，如果数据中有离群值的话，皮尔逊相关系数会受到较大的影响

其他相关系数

- 斯皮尔曼相关系数
  - Spearman’s rank correlation coefficient
- 肯德尔相关系数
  - Lemdall’s τ (tau) rank correlation coefficient
- 用于信息检索中的排序学习结果评价

主要内容

- 自然语言处理评价概述
- 自然语言理解评价
- 自然语言生成评价

自然语言生成评价

- 相比自然语言理解任务，自然语言生成类任务的目标是生成一段文本，因此通常没有唯一的标准答案，难以用简单的对错来评价，相对更加复杂
  - 基于统计
  - 基于预训练模型
  - ……
- 随着预训练模型和大模型的引入，评价指标和评价方法两个概念之间的界限逐渐变得模糊

基于统计指标的评价方法

- 早期的自然语言生成评价依赖于字符串级别的统计评价指标
  - 困惑度、BLEU、ROUGE等
  - 不考虑到词的同义性
  - 简单易用，计算快捷

基于统计指标的评价方法-BLEU

- 自然语言生成类任务大多数是有条件的，即，给定源文本，生成对应的目标文本
  - 经典的任务就是机器翻译

- 机器翻译任务最常见的评价指标是BLEU（Bilingual Evaluation Understudy），其出发点是衡量翻译结果与参考译文之间的匹配程度，生成结果越接近参考译文，翻译质量越高。

基于统计指标的评价方法-BLEU

- BLEU的核心是通过比较**机器生成的翻译（Candidate）**与**人工参考译文（Reference）**之间的n-gram匹配程度，量化翻译质量

- 下面的句子，如何评价翻译质量？
  - 生成结果：The guard arrives late because it was still raining.
  - 参考译文：The guard arrived late because of the rain.

什么是n-gram?

- n 表示长度，gram 表示序列里的“一个单位”
- 例子（以词为单位）：
  - 句子：I love NLP
  - 1-gram: ["I", "love", "NLP"]
  - 2-gram: ["I love", "love NLP"]
  - 3-gram: ["I love NLP"]

基于统计指标的评价方法-BLEU

- BLEU通过统计n-gram匹配数量的方法来评价结果
  - 生成结果：The guard arrives late because it was still raining.
  - 参考译文：The guard arrived late because of the rain.
  - 以1-gram为例，结果中有9个1-gram，共有4个1-gram匹配：the, guard, late, because
  - 以2-gram为例，结果中有8个2-gram，共有2个2-gram匹配：
  - the guard, late because

基于统计指标的评价方法-BLEU

- BLEU值的计算公式如下：

$$BLEU = BP \times exp\left(\sum_{n=1}^{N}(W_n \times log(P_n))\right)$$

$$BP = \begin{cases} 1, & lc \geq lr \\ exp(1 - lr/lc) & lc \leq lr \end{cases}$$

- 其中，P_n为 n-gram 共现的准确率， W_n 为n-gram的权重。

BLEU-长度惩罚（Brevity Penalty, BP）

- 长度惩罚BP：

$$BP = \begin{cases} 1, & lc \geq lr \\ exp(1 - lr/lc) & lc \leq lr \end{cases}$$

- 惩罚的目的：
  - **当生成结果过短时（lc≪lr）**：
    BP值趋近于0（例如生成长度是参考的一半→BP≈0.6），显著降低最终BLEU值。
  - **当生成结果与参考长度相近或更长时**：
    BP=1，不影响BLEU值。

BLEU-长度惩罚（Brevity Penalty, BP）

- 纯n-gram的问题：**单纯依赖n-gram精确率会偏向过短的生成结果**
  - **短文本更容易匹配：**
    - 参考译文：The guard arrived late because of the heavy rain.
    - 生成结果（短）：The guard arrived late.
    - 生成结果B（完整但含冗余）：The guard arrived late since it was raining heavily.

BLEU-长度惩罚（Brevity Penalty, BP）

- 参考译文：The guard arrived late because of the heavy rain.
- 生成结果（短）：The guard arrived late.
  - 1-gram精确率：4/4 = 1.0
  - 2-gram精确率：3/3 = 1.0
- 生成结果B（完整但含冗余）：The guard arrived late since it was raining heavily.
  - 1-gram精确率：5/9 ≈ 0.56

BLEU-长度惩罚（Brevity Penalty, BP）

- 参考译文：The guard arrived late because of the heavy rain.
- 生成结果（短）：The guard arrived late.
  - 1-gram精确率：4/4 = 1.0
  - 2-gram精确率：3/3 = 1.0
  - BP惩罚项：约为0.44
- 生成结果B（完整但含冗余）：The guard arrived late since it was raining heavily.
  - 1-gram精确率：5/9 ≈ 0.56
  - BP惩罚项：1

BLEU的优缺点

- 优点：
  - 自动化：无需人工干预，适合大规模评估。
  - 可重复性：结果可复现，广泛用于论文对比。
  - 与人工评价相关性高：在段落/语料级别与人类评分显著相关。
- 缺点：
  - 忽略语义和流畅性：仅统计表面匹配，可能高估直译、低估意译。
  - 对词序敏感度低：n-gram窗口有限（如N≤4），长距离调序错误难以捕捉。
  - 依赖参考译文质量：参考译文不足或偏差会影响评分。

基于统计指标的评价方法-ROUGE

- 当文本生成的任务性质改变时，评价指标也随之发生改变。在文本摘要任务中，考虑到摘要任务的特点，主要使用ROUGE（Recall-Oriented Understudy for Gisting Evaluation）作为评价指标
- 与BLEU类似，ROUGE同样通过生成结果与参考答案之间的匹配程度来衡量生成质量，主要不同点就是把精确率替代为召回率
- 希望摘要结果能够完整地包含原始文本的主要信息

基于统计指标的评价方法-ROUGE

- ROUGE 包含多个变体，适用于不同粒度的评估：

变体	计算方式	适用场景
ROUGE-N	计算 n-gram 重叠率（N=1,2,3,4）	一般文本匹配
ROUGE-L	基于最长公共子序列（LCS）	衡量句子级流畅性和连贯性
ROUGE-W	加权 LCS（考虑连续性）	强调连贯的短语匹配
ROUGE-S	跳元（skip-gram）匹配	捕捉非连续但语义相关的词组
ROUGE-SU	跳元 + 单 gram 结合	改进短文本评估

基于统计指标的评价方法-ROUGE-N

- ROUGE-N主要计算的是 n-gram 的召回率，其公式如下：

$$ROUGE-N=\frac{\sum_{Y\in S}\sum_{n-gram\in Y}min\left[Count(Y,n-gram),Count\left(\hat{Y},n-gram\right)\right]}{\sum_{Y\in S}\sum_{n-gram\in Y}Count(Y,n-gram)}$$

- 其中，Y为参考摘要，$\hat{Y}$为生成摘要结果，分母即 n-gram 在参考摘要中出现的次数，而分子为摘要结果与参考摘要匹配到的 n-gram 数。

基于统计指标的评价方法-ROUGE-N

- 相同的例子：
  - 生成结果：The guard arrives late because it was still raining.
  - 参考译文：The guard arrived late because of the rain.
  - 共匹配到了4个1-gram和2个2-gram，但在ROUGE中计算的是召回率，而参考输出的长度为8个词，因此ROUGE-1 = 4/8，ROUGE-2 = 2/7。

基于统计指标的评价方法-ROUGE-L

- ROUGE-L 衡量生成文本和参考文本之间的**最长公共子序列（LCS）的匹配程度**，适合评估句子级的语义连贯性，其计算方式如下：

$$R_{LCS} = \frac{LCS(\hat{Y}, Y)}{len(Y)}$$

$$P_{LCS} = \frac{LCS(\hat{Y}, Y)}{len(\hat{Y})}$$

$$ROUGE - L = F_{LCS} = \frac{\left(1 + \beta^2\right) R_{LCS} P_{LCS}}{R_{LCS} + \beta^2 P_{LCS}}$$

基于统计指标的评价方法-ROUGE-L

- ROUGE-L 计算方式如下：

$$R_{LCS} = \frac{LCS(\hat{Y}, Y)}{len(Y)}$$

$$P_{LCS} = \frac{LCS(\hat{Y}, Y)}{len(\hat{Y})}$$

$$ROUGE - L = F_{LCS} = \frac{\left(1 + \beta^2\right) R_{LCS} P_{LCS}}{R_{LCS} + \beta^2 P_{LCS}}$$

- R 为召回率，P 为精确率，ROUGE-L 实际上是最长公共子序列的 F1 值。但通常 β 会被设置为一个很大的值，因此ROUGE-L 同样主要受到召回率的影响。

基于统计指标的评价方法-ROUGE-L

- 相同的例子：
  - 生成结果：The guard arrives late because it was still raining.
  - 参考译文：The guard arrived late because of the rain.

- 参考译文和待评价结果之间的最长公共子序列为“the guard late because”，即LCS（C，S）=4，即可计算ROUGE-L值。

基于预训练模型的评价方法

- 在文本生成类的任务中，基于字符串共现的统计评价指标存在一个天然的缺陷：无法考虑语义相同或相近的表达，即使两句话的语义完全相同，如果字符串匹配不到，那么得分仍然会很低。
- 如果翻译输出是：
  - Due to the rain, the guard's arrival was delayed.
  - 参考译文：The guard arrived late because of the rain.
  - 两者的实际意思应该是相同的，但统计指标会很低

基于预训练模型的评价方法

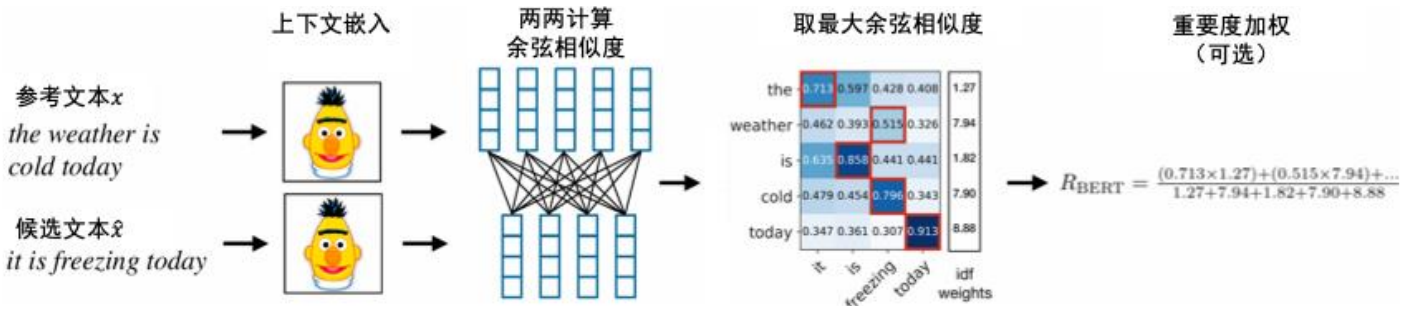
- 预训练模型可以用于进行词嵌入表示，将词汇和句子转化为连续的语义向量，并基于此构建评价指标
- 语义向量可以用于计算相似度等相关数值，提供模型效果的评价指标

基于预训练模型的评价方法-BERTScore

- BERTScore 的本质是衡量机器生成文本与参考文本之间的相似度，相似度越高，则认为待评估文本的质量越高
- 相似度的计算是基于预训练模型得到的向量表示

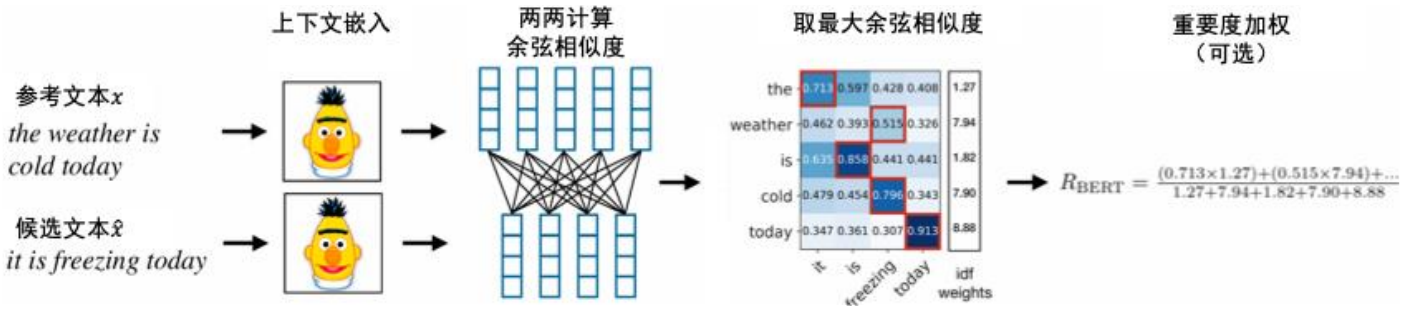
基于预训练模型的评价方法-BERTScore

- 给定一个由待评估系统生成的候选句$x = x_1, x_2, \ldots, x_k$和和经过人工标注的参考句$\hat{x} = \hat{x}_1, \hat{x}_2, \ldots, \hat{x}_l$， ， 他们都是由若干词元组成的一个序列
- 使用预训练模型对这两个句子进行嵌入生成一个向量表示



基于预训练模型的评价方法-BERTScore

- 与更早的word2vec之类的词向量模型不同，BERT生成的向量表示考虑了上下文的影响，从而识别相同单词在不同语境下的多义性



基于预训练模型的评价方法-BERTScore

- 设$f_{BERT}(\cdot)$为预训练好的BERT编码器，首先进行嵌入，输入是一个 token 序列，输出是同长度的向量序列：
  - $f_{\{BERT\}}: (x_1, x_2, \ldots, x_k) \mapsto (h_1, h_2, \ldots, h_k)$
  - x_i 是第 i个 $token$
  - $h_i \in R_d$,是对应的上下文向量表示（$BERT$ 的隐藏层输出）

基于预训练模型的评价方法-BERTScore

- 候选句：$x = (x_1, x_2, \ldots, x_k)$
- 参考句：$\hat{x} = (\hat{x}_1, \hat{x}_2, \ldots, \hat{x}_l)$
- 那么经过 BERT 编码后：

基于预训练模型的评价方法-BERTScore

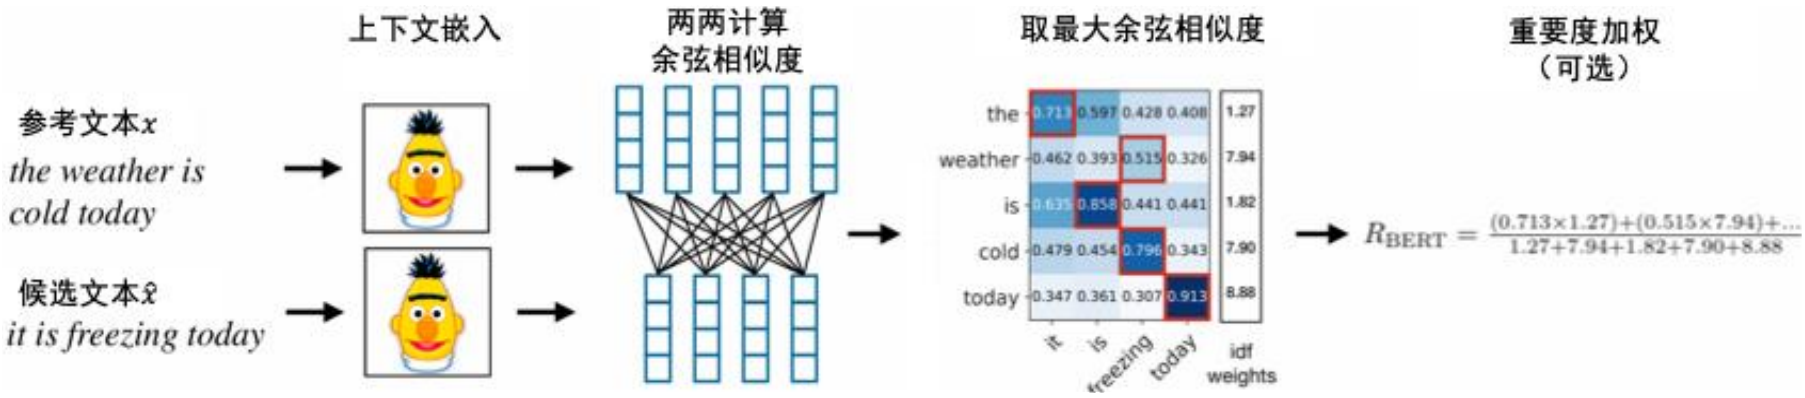
- 候选句：$x = (x_1, x_2, \ldots, x_k)$
- 参考句：$\hat{x} = (\hat{x}_1, \hat{x}_2, \ldots, \hat{x}_l)$
- 那么经过 BERT 编码后：

基于预训练模型的评价方法-BERTScore

- BERTScore的具体计算方式如下：
  - $R_{BERT} = \frac{1}{|x|}\sum_{x_i \in x} \max_{\widehat{x_j} \in \hat{x}} \mathrm{h}_i^T \widehat{h_j}$
  - $P_{BERT} = \frac{1}{|\hat{x}|}\sum_{\hat{x}_j \in \hat{x}} \max_{\mathrm{x_i} \in \mathrm{x}} h_i^T \widehat{h_j}$
  - $F_{BERT} = 2\frac{P_{BERT} \cdot R_{BERT}}{P_{BERT} + R_{BERT}}$

基于预训练模型的评价方法-BERTScore

- 例子：具体计算过程如图所示
  - 参考译文：The weather is cold today.
  - 待评价文本：It is freezing today.



基于预训练模型的评价方法-BERTScore

- 但这种方法会受到停用词，比如：the,on等常见单词的影响，对于这样的词元可以采用加权的方法减少影响，因此公式此时为：

$$P_{BERT} = \frac{1}{\sum w_j} \sum_{\hat{x}_j \in \hat{x}} w_j \max_{x_i \in x} h_i^T \hat{h}_j$$

$$R_{BERT} = \frac{1}{\sum w_i} \sum_{x_i \in x} w_i \max_{\hat{x}_j \in \hat{x}} h_i^T \hat{h}_j$$

基于预训练模型的评价方法-BERTScore

- 一种常用的加权方法是根据词频来降低影响：
- 可以对每个 token 加上 **逆文档频率（IDF）权重**，即：
  - $w_t = log \frac{N}{1+df(t)}$
  - N = 文档总数（在评测语料中，通常是一整个评测集的句子数）
  - df(t) = token t 出现过的文档数（即包含这个 token 的句子数）
  - 加 1 是为了避免分母为 0（平滑处理）

基于预训练模型的评价方法-BERTScore

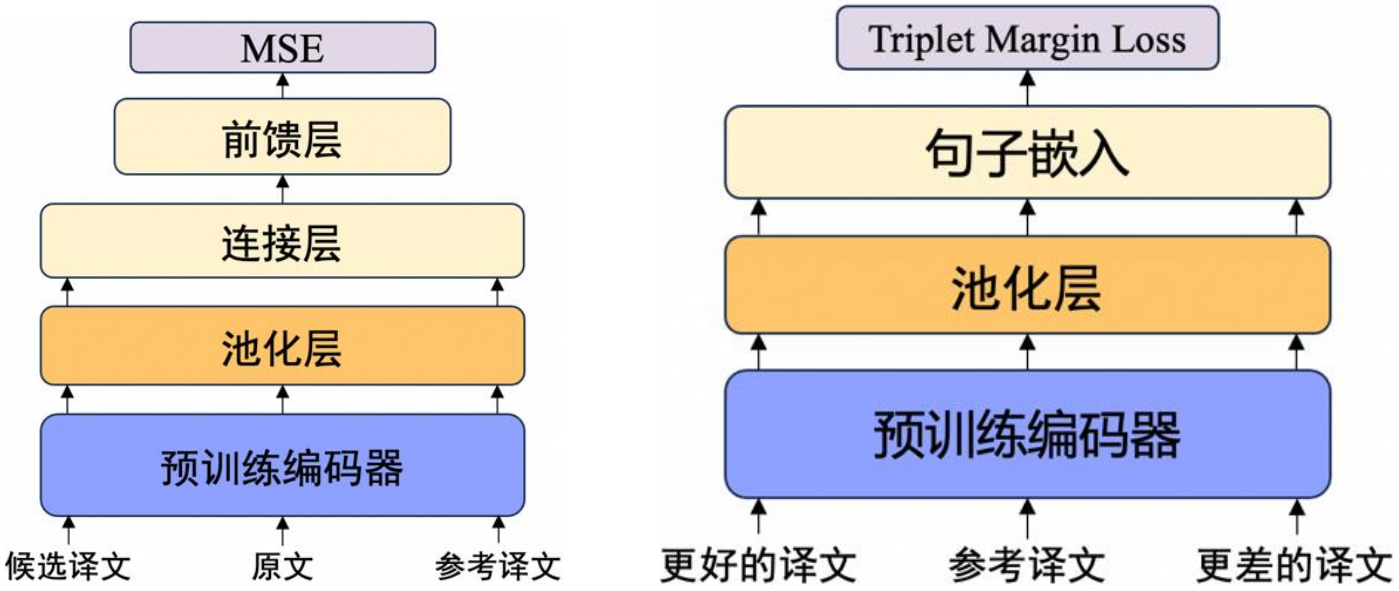
- 在BERTScore中，相同语义的不同表达也能被很好地匹配，得到一个较高的分数。在理论上，只要有对应的参考答案文本，BERTScore能被运用到任何NLG任务中。

基于预训练模型的评价方法-COMET

- COMET（Crosslingual Optimized Metric for Evaluation of Translation）专门应用于机器翻译任务的基于预训练模型的评价方法
- COMET 实际上是一个用于训练机器翻译评估模型的框架，这个框架包括两种不同的体系架构：估计器模型（Estimator Model）和翻译排名模型（Translation Ranking Model）

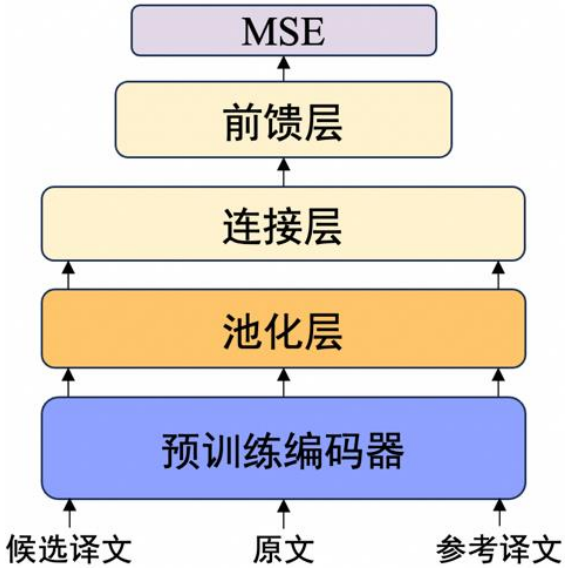
基于预训练模型的评价方法-COMET

- 前者用于按照回归方式预测一个质量分数，后者通过Triplet Margin Loss训练。两个模型均由一个跨语言编码器和一个池化层构成。



COMET估计器模型

- 估计器模型是回归型的评估方法：
- 输入：参考译文、源文本、系统生成的候选译文
- 输出：一个连续分值,直接预测该译文的质量。

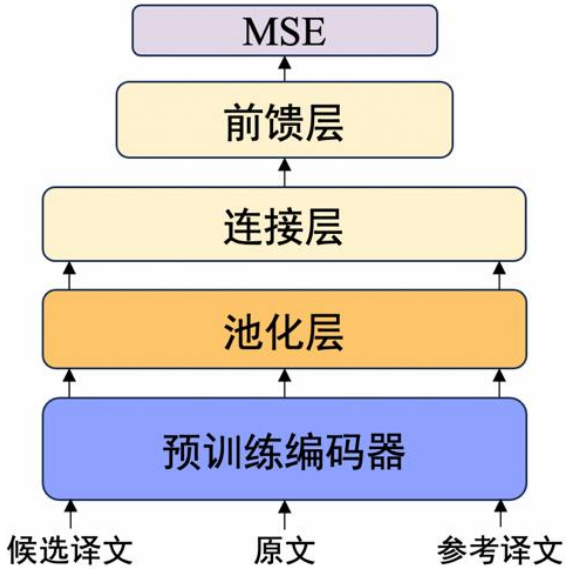


COMET估计器模型

- 预训练编码器：
  - 编码阶段使用多语言预训练语言模型对参考译文、源文本、系统生成的候选译文进行编码
  - 通常会拼接输入：
    - [CLS] source [SEP] hypothesis [SEP] reference
- 池化
  - 对输入 token 序列编码后，输出的是一个矩阵，而目标要将每个句子变成一个向量，因此对每个token进行池化得到一个向量

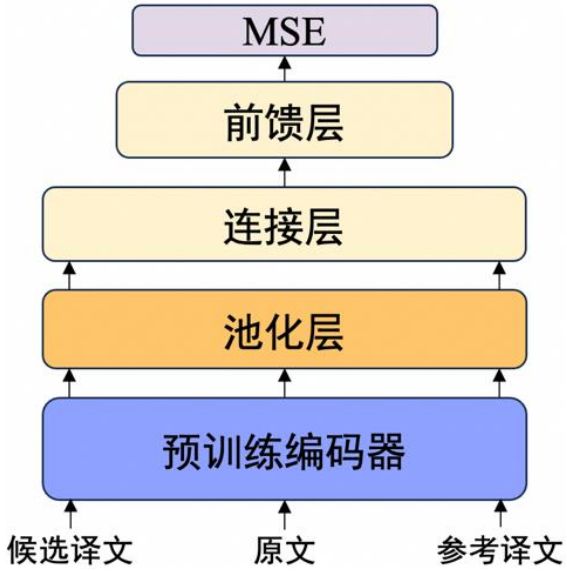
COMET估计器模型

- 特征链接：将池化后的向量进行拼接
- 前馈层：用一个全连接层（MLP）将特征映射为一个质量分数



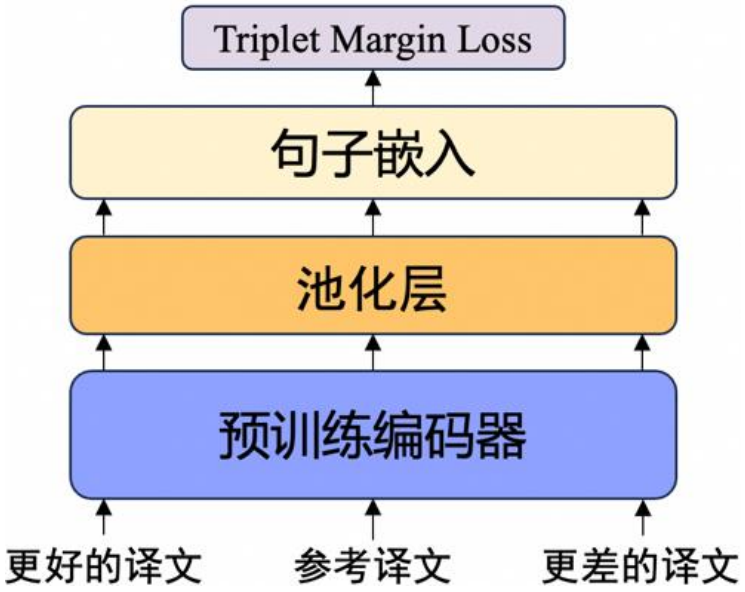
COMET估计器模型

- 整个模型通过最小化输出质量分数与标注的质量分数之间的均方差（Mean Squared Error，MSE）进行训练，实际上是一个回归任务。



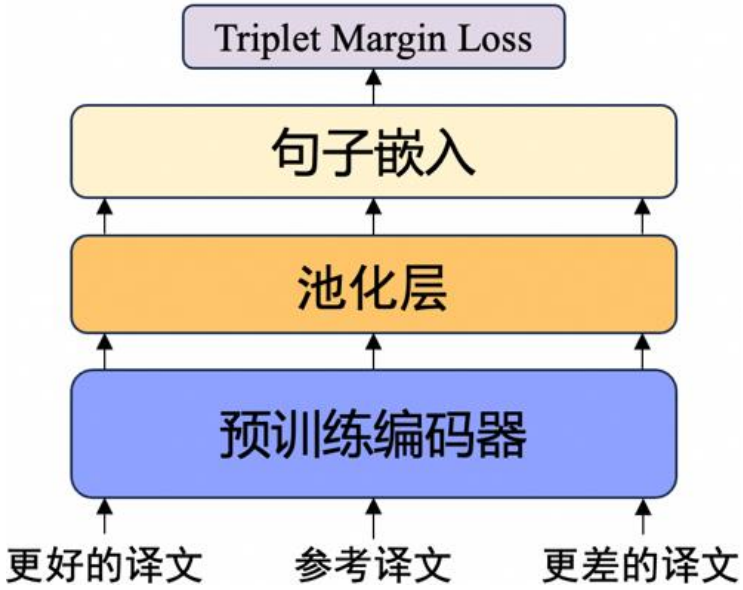
COMET翻译排名模型

- 与 **估计器模型** 直接回归质量分数不同，**翻译排名模型** 通过**成对比较**来学习译文优劣顺序



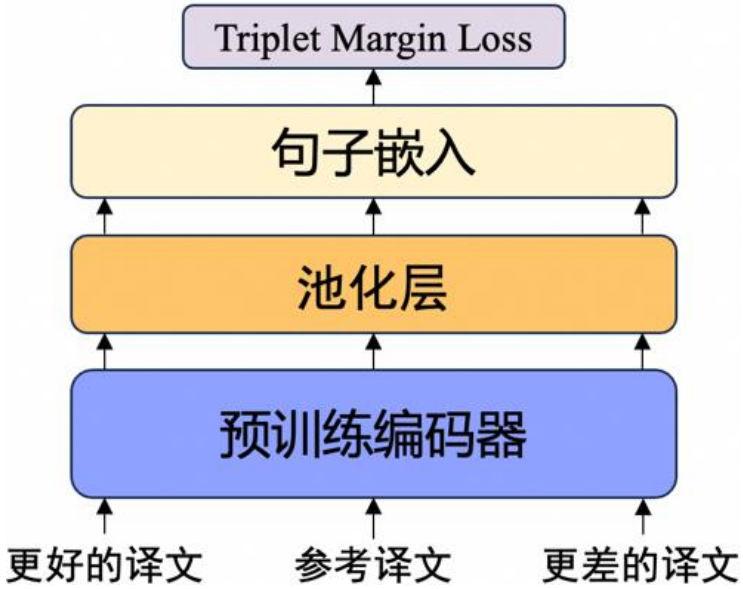
COMET翻译排名模型

- 训练阶段：
  - 输入：更好的生成译文（Positive）、参考译文（Reference）、更差的生成译文（Negative）
  - 训练目标：让“更好”译文的嵌入比“更差”译文更接近参考译文。



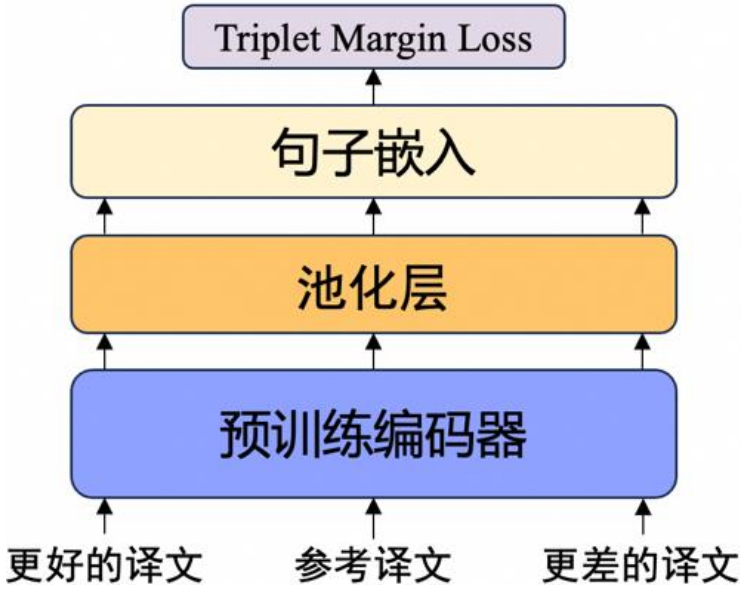
COMET翻译排名模型

- 编码与池化：与估计器模型类似
- 损失函数：Triplet Margin Loss
  - $L = \max\left(0, margin + d\left(v_{ref}, v_{pos}\right) - d\left(v_{ref}, v_{neg}\right)\right)$
  - 其中 $d(\cdot,\cdot)$ 是距离度量，margin 是间隔超参数。



COMET翻译排名模型

- 推理阶段：
  - 输入参考译文和候选译文编码
  - 池化得到向量
  - 根据向量相似度打分分数越高，表示候选译文越接近参考译文质量越好。



两种方法的优缺点

- 估计器模型：
  - 优点：直接给出可比的分数，适合系统性能跟踪与评测
  - 缺点：需要高质量标注数据（人工分数），跨领域泛化性较差
- 翻译排名模型：
  - 优点：不需要绝对分数，只需相对偏好标注（更容易收集，比如让人工比较两个译文）
  - 缺点：不能直接输出绝对质量分数，需要额外步骤做归一化。

基于大模型的评价方法

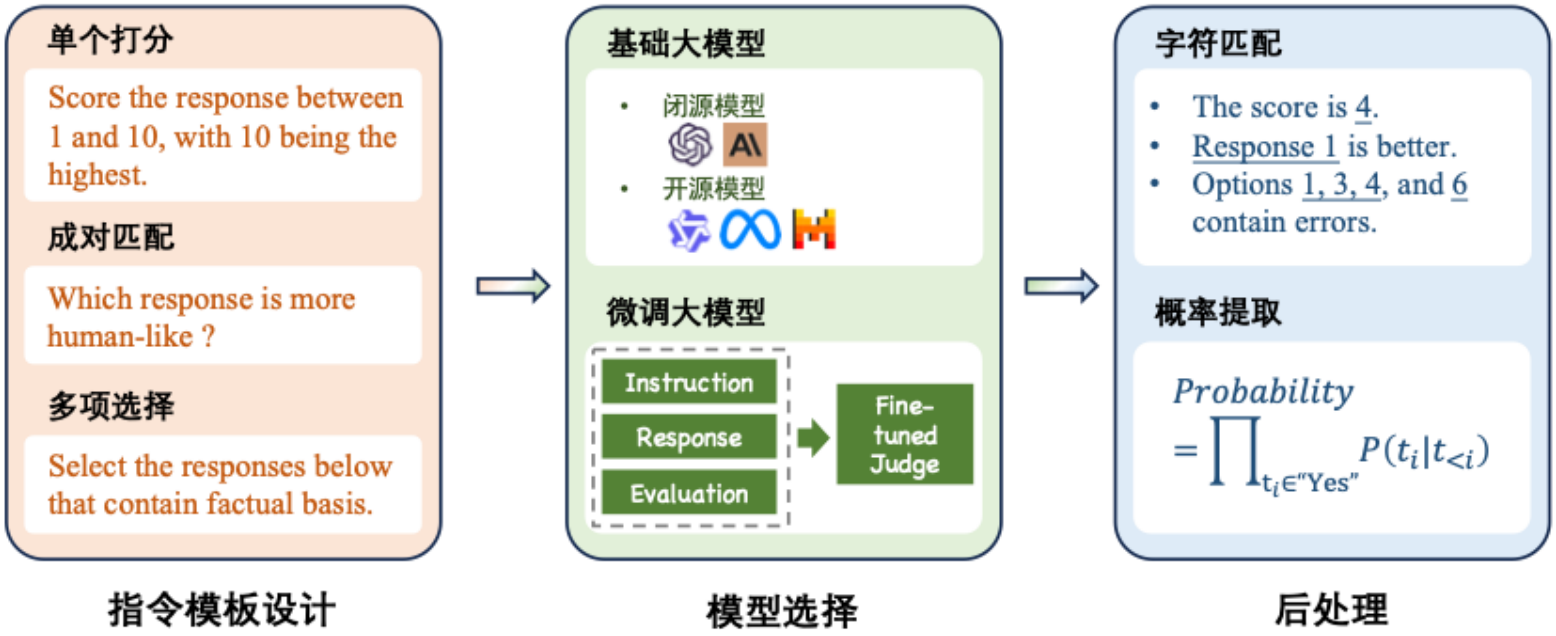
- 随着大模型时代的来临，自然语言处理任务逐渐被生成式模型所统一。在大模型能力的不断提升之下，生成类任务的形式、内容都变得越来越多样化，难度也在不断提升——**没有标准答案可言**

- 不论是基于统计指标的方法，还是基于预训练模型的方法，都逐渐难以满足生成任务的评价要求

- 当前的一些研究指出可以使用能力更强的大模型，例如GPT-4，代替人类对当前的大模型进行评价，这一方法被称为基于大模型的评价方法（LLM-as-a-Judge）

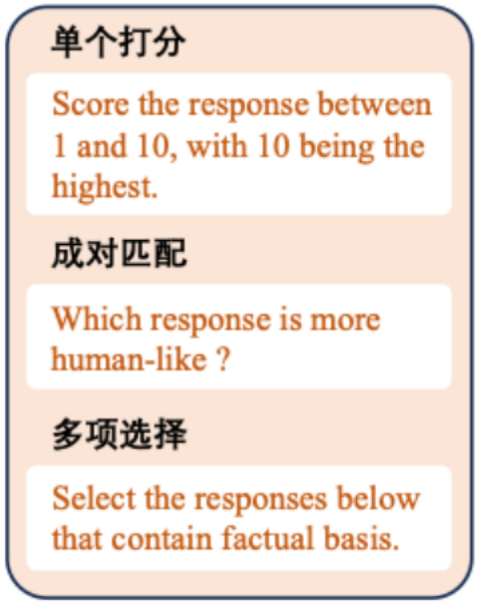
基于大模型的评价方法-步骤

- 基于大模型的评价方法通常分为以下三个步骤：



基于大模型的评价方法-指令模板设计

- **指令模版设计：**
  - **Prompt定义任务：**
    - 确定要评估的数据类型、输入方式以及评价标准
    - 不同的方法引导模型进行评估，包括生成评分、进行成对比较或者多项选择、回答是非问题



指令模板设计

基于大模型的评价方法-指令模板设计

指令模版例子

成对比较的指令模板：

Given a new article, which summary is better? Answer "Summary 0" or "Summary 1". You do not need to explain the reason.

Article: {Article}
Summary 0: {Summary_0}
Summary 1: {Summary_1}

评分形式的指令模板

Evaluate the quality of summaries written for a news article. Rate each summary on four dimensions: {Dimension_1}, {Dimension_2}, {Dimension_3}, and {Dimension_4}. You should rate on a scale from 1 (worst) to 5 (best).

Article: {Article}
Summary: {Summary}

基于大模型的评价方法-模型选择

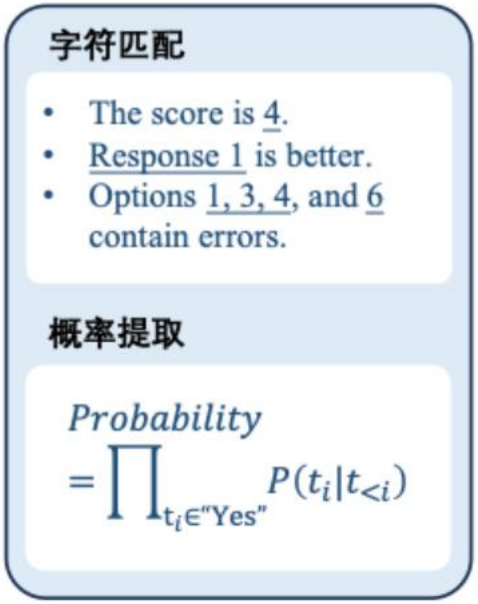
- 通用模型
  - 开源/闭源
- 特定微调过的大模型
  - 评估数据集对语言模型进行微调，提升其评估能力，从而训练评估专用的大模型



模型选择

基于大模型的评价方法-后处理

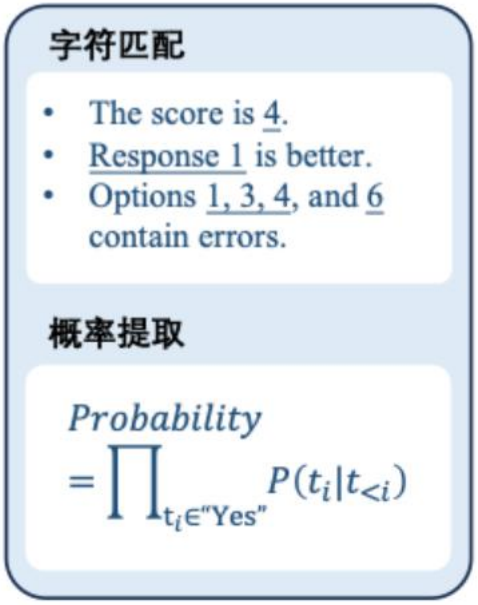
- 大模型用于评估时的输出通常也以文本的形式展现，因此需要从其中提取特定的内容作为评估结果



后处理

基于大模型的评价方法-后处理

- 大模型解码时输出的概率也可以为评估结果的一部分。
- 在此基础上，我们可能还需要借助于一些统计指标，例如概率的加权求和等，作为最终的评价结果。



后处理

基于大模型的评价方法

- 基于大模型的评价方法的效果与大模型的能力有直接关系
- 在MT-bench上的试验结果表明，GPT-4的评价结果和人类评价结果的一致率能达到85%，而人类之间评价结果的一致率仅有81%。

基于大模型的评价方法-优缺点

- 优点：
  - 充分利用了大模型的语言理解与生成能力，替代人类在评价中的角色，提升了评价效率和准确性
  - 具有**可扩展性**，不仅能用于大模型在有参考答案任务上的评价，还能在各类开放式任务上对大模型性能作出评价；
  - 通过在评价方法中引入**思维链**，不仅能提供最终的评价结果，还能给出相应的评价理由，增强了评价结果的可解释性。

基于大模型的评价方法-优缺点

- 缺点：
  - 大模型的推理和回复可能包含隐私或者机密内容，将这些内容发送给外部的大模型评价时，有潜在的**隐私泄漏**风险
  - 由于各类大模型的版本不断更新迭代，基于大模型的评价结果在稳定性上会受到影响，随着版本迭代，已有的评价结果将**难以复现**
  - 容易受到大模型**本身偏见**的影响，导致大模型倾向于给并不符合指令的回答更高的评价

基于大模型的评价方法-优缺点

- 大模型可能会受多种偏见的影响：
  - **位置偏见：**大模型在对多个答案进行排序和对比时，倾向于选择特定位置的答案
  - **长度偏见：**大模型倾向于给更加冗长的答案更高的评价
  - **自我偏见：**大模型倾向于给自己的答案，或者与自己答案相似的答案更高的评价

基于大模型的评价方法-总结

- 虽然基于大模型的评价方法在应用当中仍然具有不少的挑战，但是得益于大模型不断提升的能力，其在评价任务上的潜力也在不断提升。
- 因此，在当前的基于大模型的文本生成类任务中，基于大模型的评价方法逐渐成为了主流做法。

参考文献

- Papineni K, Roukos S, Ward T, et al. Bleu: a method for automatic evaluation of machine translation[C]//Proceedings of the 40th annual meeting of the Association for Computational Linguistics. 2002: 311-318.
- Lin C Y. Rouge: A package for automatic evaluation of summaries[C]//Text summarization branches out. 2004: 74-81.
- Zhang T, Kishore V, Wu F, et al. BERTScore: Evaluating Text Generation with BERT[C]//International Conference on Learning Representations.
- Rei R, Stewart C, Farinha A C, et al. COMET: A Neural Framework for MT Evaluation[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2020: 2685-2702.
- Gu J, Jiang X, Shi Z, et al. A Survey on LLM-as-a-Judge[J]. arXiv preprint arXiv:2411.15594, 2024.
- Gao M, Ruan J, Sun R, et al. Human-like summarization evaluation with chatgpt[J]. arXiv preprint arXiv:2304.02554, 2023.
- Huang H, Qu Y, Liu J, et al. An empirical study of llm-as-a-judge for llm evaluation: Fine-tuned judge models are task-specific classifiers[J]. arXiv preprint arXiv:2403.02839, 2024.
- Dubois Y, Galambosi B, Liang P, et al. Length-controlled alpacaeval: A simple way to debias automatic evaluators[J]. arXiv preprint arXiv:2404.04475, 2024.
- Zheng L, Chiang W L, Sheng Y, et al. Judging llm-as-a-judge with mt-bench and chatbot arena[J]. Advances in Neural Information Processing Systems, 2023, 36: 46595-46623.