自然语言处理

第9讲：大语言模型的强化学习

杨沐昀

哈尔滨工业大学计算学部
语言技术研究中心

2026年秋季学期

yangmuyun@hit.edu.cn

引言 —— 为什么需要 RLHF?

- 背景：有监督精调的局限性（依赖标准答案、难以对齐人类价值观）
- RLHF 的核心目标：通过人类反馈优化模型，实现 “3H 原则” （Helpfulness、Honesty、Harmless）
- 优势：评估文本整体质量，减少对人工标注的依赖

主要内容

- 人类反馈的强化学习
- 奖励模型

回顾：强化学习

- 一种通过智能体与环境的交互不断试探和调整策略，以最大化奖励的学习方法
- 主要挑战
  - 设计明确且有效的奖励函数
  - 奖励信号稀疏、难以反应人类需求或偏好

9.1.1 策略梯度 —— 基本概念

- 策略梯度：重要基础方法
- 直接对策略进行参数化建模并优化



- 策略梯度的核心组成：
- 演员（Actor）：执行动作与环境交互
- 环境（Environment）：接收动作并返回奖励和新状态
- 奖励函数（Reward Function）：评估动作的好坏

9.1.1 策略梯度——：问题描述

- 轨迹（Trajectory）：

$$\tau = \{s_1, a_1, s_2, a_2, \cdots, s_T, a_T\}$$

- 轨迹概率公式：

$$p_\theta(\tau) = p(s_1)p_\theta(a_1 \mid s_1)p(s_2 \mid s_1, a_1)p_\theta(a_2 \mid s_2)p(s_3 \mid s_2, a_2)\cdots$$
$$= p(s_1)\prod_{t=1}^{T} p_\theta(a_t \mid s_t)p(s_{t+1} \mid s_t, a_t)$$

- 回报（Return）：累计奖励 $R(\tau) = \sum_{t=1}^{T} r_t$
- 期望回报：

$$\bar{R}_\theta = \sum_\tau R(\tau)p_\theta(\tau) = \mathrm{E}_{\tau \sim p_\theta(\tau)}[R(\tau)]$$

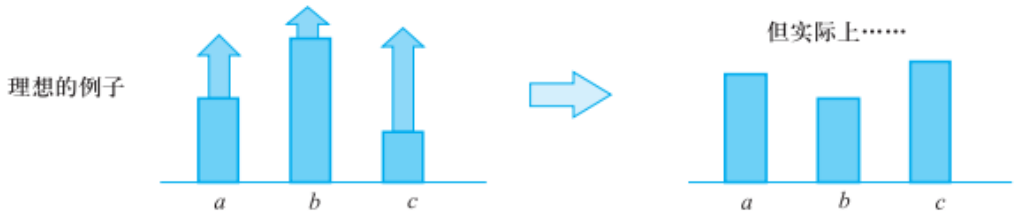
9.1.1 策略梯度——优化方法

- 梯度上升： $\nabla \bar{R}_\theta = \sum_\tau R(\tau) \nabla p_\theta(\tau)$

$$\nabla \bar{R}_\theta \approx \frac{1}{N} \sum_{n=1}^{N} \sum_{t=1}^{T_n} (R(\tau^n) - b) \nabla \log p_\theta(a_t^n \mid s_t^n)$$

其中，$b = \mathrm{E}_{\tau \sim p_\theta(\tau)} R(\tau)$，即回报的期望。该项在实践中常用的计算方法是，在训练过程中记录历史 $R(\tau^n)$ 的均值，用以估计回报的期望。

  - 关于b的由来
  - 直观来看，$R(\tau^n)$ 指示了 $p_\theta(a_t^n \mid s_t^n)$ 的调整方向和大小；
  - 在实践中往往会出现回报总是正的情况，由于有限采样和归一化的归一化影响，会扭曲原始概率分布



9.1.1 策略梯度 ——优化方法

- 进一步考虑某一动作只会对之后的状态产生影响，因此一条轨迹中的每个动作的价值不需要都计算全部奖励只和，只需考虑当前动作之后的奖励和；
- 另一个考虑是当前动作对时间较近的状态影响大，对时间间隔较大的状态，奖励衰减应更显著；
- 最终回报梯度表示为：

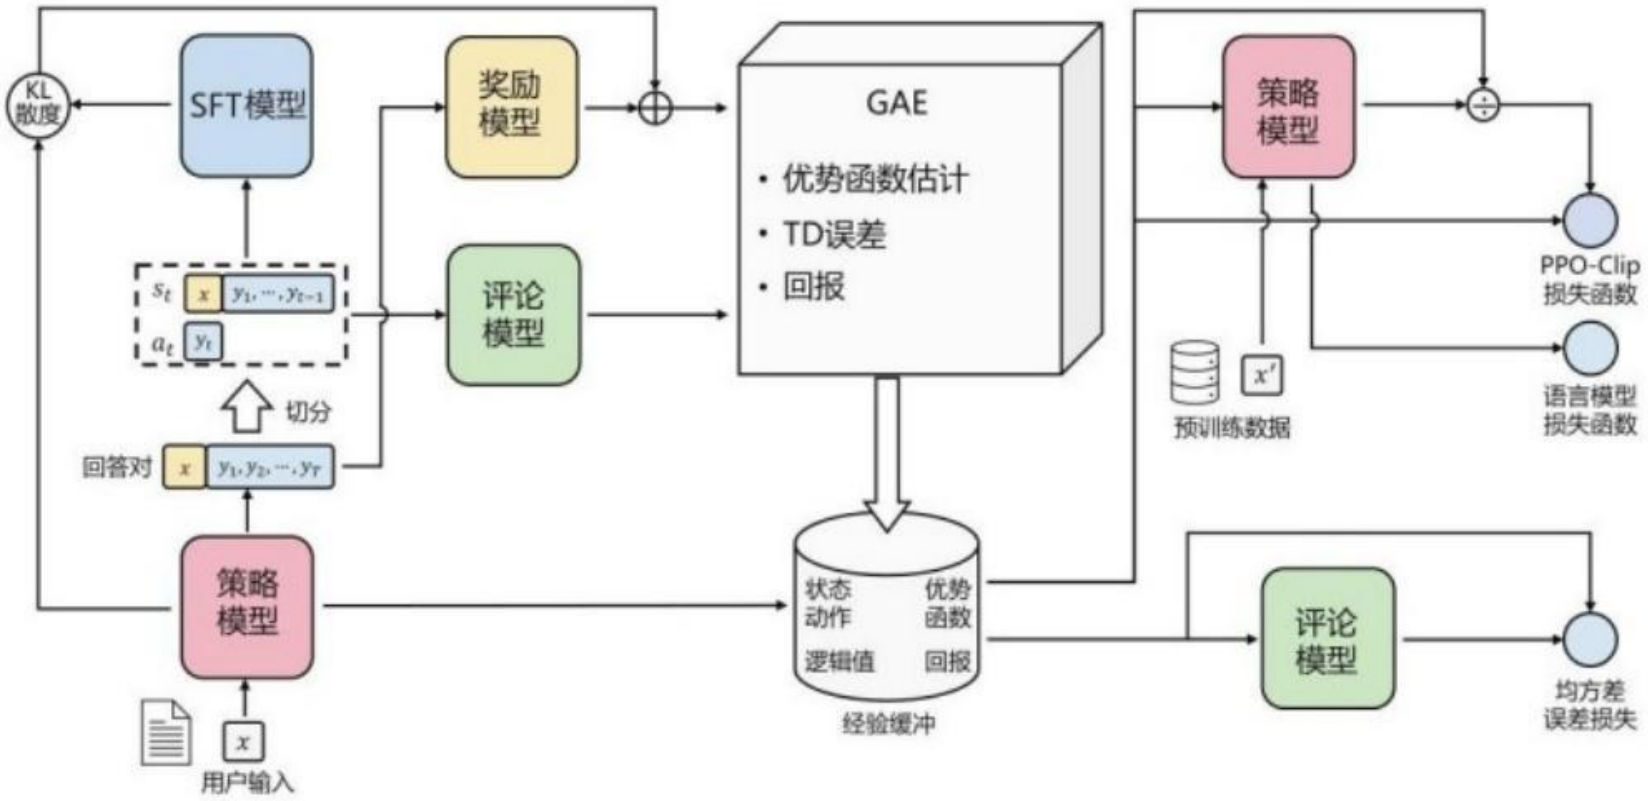
$$\nabla \bar{R}_\theta \approx \frac{1}{N}\sum_{n=1}^{N}\sum_{t=1}^{T_n}\left(\sum_{t'=t}^{T_n}\gamma^{t'-t}r_{t'}^{n}-b\right)\nabla \log p_\theta(a_t^n \mid s_t^n)$$

  - γ ∈[0,1] 是折扣因子，随着时间间隔增大，奖励的折扣也越大

9.1.2 RLHF 流程

- 本质：使用强化学习策略优化大语言模型
- 目标：大模型行为对齐人类价值观
  - Helpful，honest，harmless
- 核心步骤：
  - 奖励模型训练：拟合人类偏好，输出奖励分数（评估生成内容的质量符合人类价值观的程度）
  - 近端策略优化(PPO)：具体地，基于奖励信号优化策略模型
- PPO算法的核心模型：
  - 策略模型：基于输入生成回复
  - 奖励模型：根据回复输出奖励分，评估质量
  - 评论模型：预测回复的未来奖励、调整行为以选择最优策略
  - 参考模型：初始策略模型备份，限制策略变化范围，避免极端调整

9.1.2 RLHF 流程



PPO算法实施过程

9.1.2 RLHF 流程——PPO 实施步骤

- 环境采样：
  - 策略模型生成回复，奖励模型打分
- 优势估计：
  - 用评论模型和 GAE 计算优势函数
- 优化调整：
  - 用 PPO 约束策略更新幅度，保证稳定性

9.1.3 广义优势估计（GAE)

- 一种在策略梯度方法中，更稳定估计优势函数(advantage function)的方法
  - 减少高方差问题、同时降低偏差
- 动作价值(ActionValue)： $Q(s,a)$ $\sum_{t'=t}^{T,n} \gamma^{t'-t} r_{t'}^{n}$
- 状态价值(State Value)： $V(s)$ b(动作价值的期望)
  - 计算困难，一般使用神经网络函数拟和
- 优势函数：特定动作a相比于一个随机动作的优势

$$A(s,a) = Q(s,a) - V(s)$$

9.1.3 广义优势估计（GAE)

- 动作价值估计
  - 蒙特卡洛方法：从环境中采集完整数据，方差大
  - 时序差分方法(TD)：只采样下一步，后续回报通过状态价值函数估计；方差低，偏差大

$$Q(s_t, a_t) = r_t + \gamma V(s_{t+1})$$

  - 广义优势估计：平衡方差和偏差

$$A_t^{\mathrm{GAE}(\gamma,\lambda)} = (1-\lambda)(A_t^1 + \lambda A_t^2 + \lambda^2 A_t^3 + \cdots)$$

    - 对k步优势奖励进行指数衰减
    - 通过在高偏差（当 λ = 0 时，等价于TD） 和高方差（当 λ = 1 时，等价于蒙特卡洛） 的估计之间实现平滑插值， 巧妙地平衡了偏差与方差之间的权衡

9.1.4 近端策略优化算法

- 传统策略梯度问题
  - 数据效率低：需要从环境中大量采样轨迹τ，参数θ更新，之前的轨迹无法再次使用
- 近端策略优化(PPO)
  - 广泛用于机器人控制、自动驾驶、游戏
  - 重要性采样
  - 约束新旧策略差异（KL 散度或裁剪）

9.1.4 近端策略优化算法：重要性采样

- 假设随机变量 x 服从概率分布 p，可以从分布p中采样得到若干数据x^i近似计算函数期望：

$$E_{x\sim p}[f(x)] \approx \frac{1}{N}\sum_{i=1}^{N} f(x^i)$$

- 无法从分布p中采样时？
- 从另一个已知或易于采样的分布q中采样：

$$E_{x\sim p}[f(x)] = \int f(x)p(x)\mathrm{d}x = \int f(x)\frac{p(x)}{q(x)}q(x)\mathrm{d}x = \mathbb{E}_{x\sim q}\left[f(x)\frac{p(x)}{q(x)}\right]$$

- 重要性权重：$\frac{p(x^i)}{q(x^i)}$

9.1.4 近端策略优化算法：梯度更新与约束

- 梯度只更新负责学习的智能体策略π_θ，不更新负责采样的智能体策略为 $\pi_{\theta'}$
- 重要性采样的一个重要的稳定性保证是分布 p 和分布 q 不能相差太多， 因此 PPO 算法使用 KL 散度来约束θ和θ '，形式化表示为：

$$J_{\mathrm{PPO}}^{\theta'}(\theta) = J^{\theta'}(\theta) - \beta \mathrm{KL}(\theta, \theta')$$

$$J^{\theta'}(\theta) = \mathbb{E}_{(s_t,a_t)\sim\pi_{\theta'}}\left[\frac{p_\theta(a_t|s_t)}{p_{\theta'}(a_t|s_t)} A^{\theta'}(s_t, a_t)\right]$$

  - 并不是要保证参数的空间距离保持相似，而是保证动作概率的相似

9.1.6 直接偏好优化（DPO）

- 与PPO核心差异：
  - 跳过奖励模型，直接用人类偏好数据（<Prompt, Good, Bad>）训练，更为直接和高效
  - 约束更新：PPO 通过对新旧策略之间的更新幅度施加显式约束，确保策略优化不会偏离原策略过远。而 DPO 则通过优化偏好概率的相对一致性，隐式地实现类似约束。
- 本质： 二分类
- 损失函数：最大化 Good Response 的概率，最小化 Bad Response 的概率
- 优势：计算成本低，适合大模型，无需轨迹采样

主要内容

- 人类反馈的强化学习与奖励模型

- 奖励模型
  - 数据集收集
  - 模型训练
  - 开源数据
  - 生成式奖励模型

9.2.1 奖励模型 —— 数据收集

- 核心目标：收集符合 3H 原则的人类偏好数据
  - （Helpful ；Harmless；Honest）
  - 有用性数据：标注者评估模型回答的帮助性
  - 无害性数据：标注者诱导模型生成有害内容并评估
- 案例：Anthropic 的 HH-RLHF 数据集
  - HH-RLHF 数据集将强化学习与人类反馈结合，帮助模型实现复杂场景下符合人类直觉的输出。
  - 选择直观且熟悉的任务，并采用自然语言对话的方式收集反馈，提高数据的通用性和适用性。

9.2.1 奖励模型 —— 数据收集

- 案例：Anthropic 的 HH-RLHF 数据集
  - 收集工具：Amazon Mechanical Turk 平台



9.2.1 奖励模型 —— 数据收集

- 权衡与流程：避免过度保守或过度冒险
- 流程：
  - 任务执行：标注者与模型交互
  - 对比评估：二选一选择更优 / 更有害的回答
- 数据筛选：仅保留明确偏好（排除平局）

9.2.2 奖励模型训练

- 模型结构
  - 移除模型的最后一个非嵌入层，在最终的 Transformer 层之上添加一个额外的线性层
  - 无论输入的文本是什么都能够为文本序列的最后一个标记生成一个标量奖励值，且样本质量越高奖励值越大
- 配对比较数据集
  - 构成：相同输入生成的两个不同输出组成的样本对
- 损失函数

$$\mathcal{L}(\psi) = \log\sigma\left(r(x, y_w) - r(x, y_l)\right)$$

9.2.3 开源数据

- 针对奖励模型已有一些公开可用的数据集，涵盖多种任务需求

数据集	内容	规模	应用场景
Summarize from Feedback	摘要生成的对比与评分数据	19.4 万条	摘要生成模型优化
WebGPT人类反馈数据集	长文档问答的人类反馈	1.9 万条	问答模型对齐
HH-RLHF	人类偏好数据及红队测试对话数据	17 万条	奖励模型训练与鲁棒性测试
Stanford Human Preferences（SHP）	Reddit 高赞评论的偏好数据	38.5 万条	多样化偏好建模

总结

- RLHF 核心：通过人类反馈和强化学习实现模型与人类价值观对齐
- 关键技术：PPO、GAE（DPO、自奖励机制）
- 奖励模型：数据收集→训练→开源资源→（生成式改进）
- 未来方向：提升跨文化对齐、减少偏见、增强伦理一致性

课后习题（精选）

1. 简述 3H 原则及其在 RLHF 中的作用
2. 对比 PPO 与 DPO 的优缺点
3. 奖励模型中 KL 散度的作用是什么？
4. 若标注成本过高，有哪些替代方案构建奖励模型？