自然语言处理

第10讲：大语言模型知识增强与模型评价

杨沐昀

哈尔滨工业大学计算学部
语言技术研究中心

2026年秋季学期

yangmuyun@hit.edu.cn

主要内容

- 知识与知识图谱
- 知识抽取
- 知识增强的大语言模型
- 大语言模型的评价

10.1.1 知识的概念及表示

- 知识：人类通过观察、学习和思考世界中的各种现象而获得和总结出的所有概念、事实、规则或原则的集合。

  –中国电子技术标准化研究院. 知识图谱标准化白皮书（2019版）

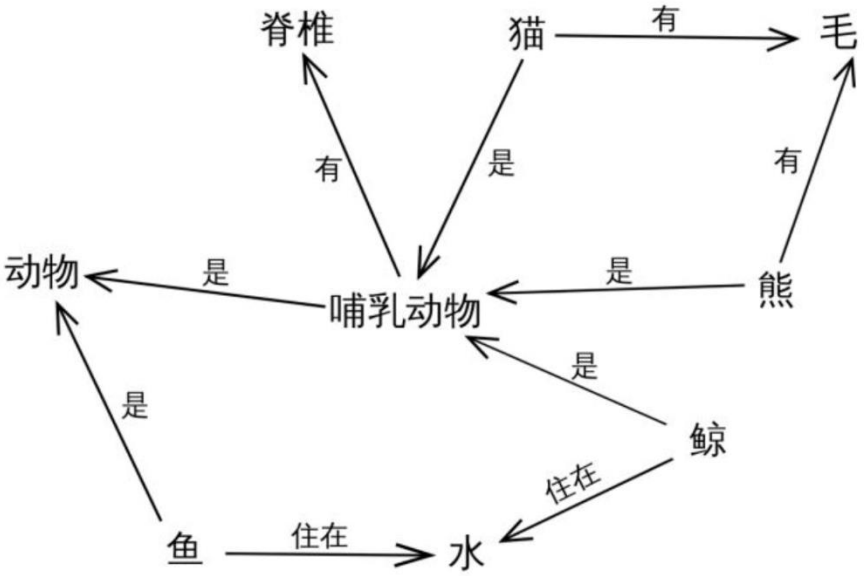
  - 知识是人类智慧的凝练和沉淀
  - 知识的研究一直是人工智能的重要方向之一
  - 其中知识表示至关重要
- 知识表示：用易于计算机处理的方式描述或表示知识，以支持计算机进行推理的方法与技术。

10.1.1 知识的概念及表示

- 经典知识表示方法
  - 一阶谓词逻辑
  - 语义网络
  - 产生式规则
  - 框架理论
- 知识表示的新阶段
  - 语义网（Semantic Web）

10.1.1 知识的概念及表示

- 语义网
  - 1989年，英国计算机科学家蒂姆·伯纳斯·李（Tim Berners-Lee）提出了超文本系统，并演化发展成万维网。
- 1998年，他正式提出了“语义网”的概念。
  - 基于图和链接的方式来组织语义信息
  - 图的节点代表世界中的实体（如人、机构、地点等）
  - 节点间的超链接表示实体之间的语义关系



10.1.1 知识的概念及表示

- 语义网技术标准
  - 万维网联盟（W3C）出台了一系列重要的技术标准，为互联网时代的知识表示提供了工具
  - RDF
  - RDFS
  - OWL

10.1.1 知识的概念及表示

- 语义网技术标准：RDF
  - RDF（Resource Description Framework）即资源描述框架，是一种描述网络资源的标准数据模型。

```
<?xml version="1.0"?>
    <RDF xmlns=http://www.w3.org/1999/02/22-rdf-syntax-ns#xmlna:DC=http://purl.org/metadata/dublin-core#>
        <Description about=http://www.dlib.org/dlib/may98/miller>
            <DC:title>
                An introduction to the Resource Description Framework
            </DC:title>
            <DC:creator>
                Eric Miller
            </DC:creator>
            <DC:date>
                1998-0501
            </DC:date>
        </Description>
    </RDF>
```

10.1.1 知识的概念及表示

- 语义网技术标准：RDF
  - 知识总是以三元组的形式出现，每个三元组包括一个主语、一个谓语和一个宾语。
  - 主语和谓语通常是统一资源标识符（URI），用于唯一标识资源或属性；
  - 宾语可以是URI、空白节点或文字值。
  - RDF数据可以表示为一个图，其中节点代表资源，边代表属性或关系。
  - 这种图形结构使得RDF非常适合表示复杂的数据关系和网络

10.1.1 知识的概念及表示

- 语义网技术标准：RDFS
  - RDFS作为RDF的扩展语言，丰富了RDF的语义描述能力，为构建复杂的知识库和语义模型提供了有力支持。

10.1.1 知识的概念及表示

- 语义网技术标准：OWL
  - OWL网络本体语言（OWL）是一种用于定义和实例化网络本体的声明性语言。
  - OWL建立在RDF和RDFS之上，提供了更丰富的语义表达能力，包括类、属性、个体及其之间的关系和限制。

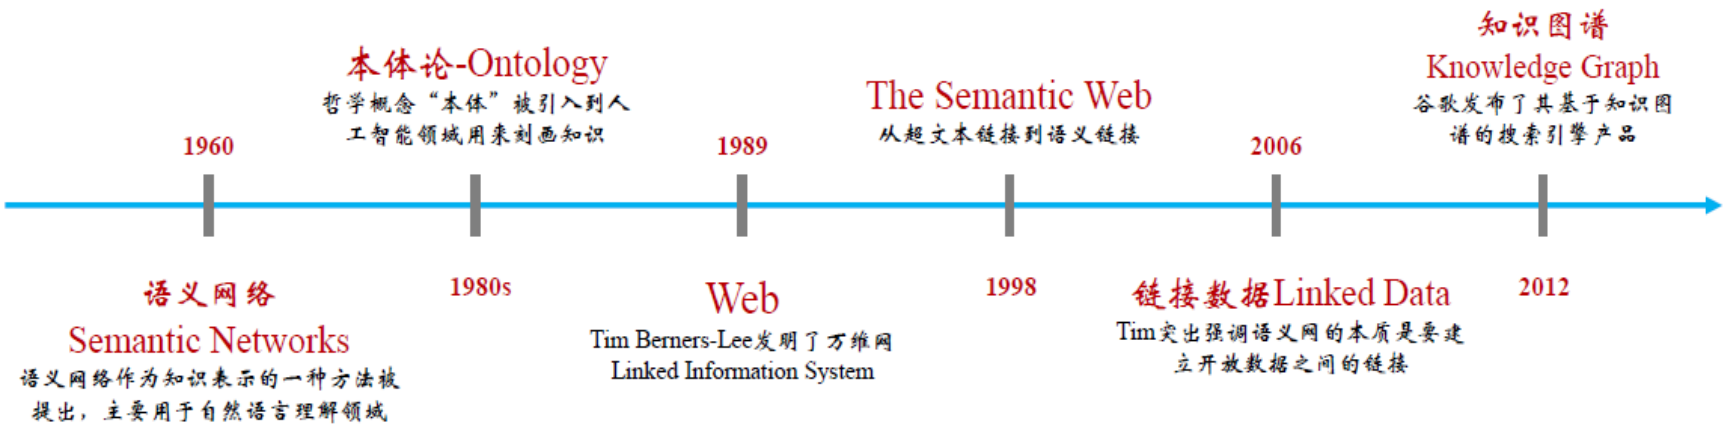
概念	关系	定义内容
哺乳动物 动物	子类	哺乳动物是动物的子类

10.1.1 知识的概念及表示

- 语义网技术标准：OWL
  - OWL支持基于描述逻辑的推理，能够根据已知的知识自动推导出新的知识；
  - OWL支持层次结构，允许概念之间的包含关系，形成树状或有向无环图的本体结构。
  - OWL可以被其他本体引用和重用，提高了本体的可维护性和可扩展性。

10.1 知识的概念及表述

- 知识图谱：有观点认为是语义网的特殊应用和发展



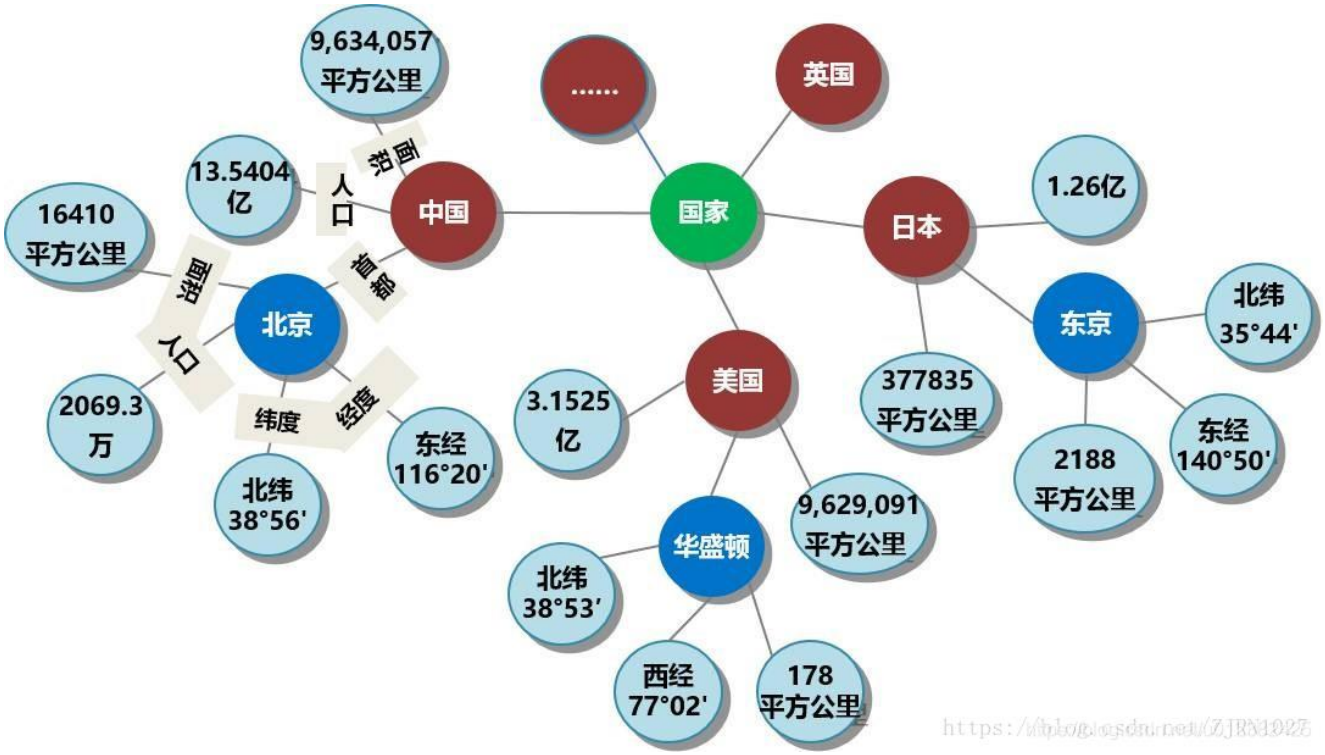
知识表示与知识库- Knowledge Representation / Knowledge Base

人工智能研究者陆续提出了大量知识表示的方法，如框架系统、产生式规则、描述逻辑等。

知识图谱的网络结构可以追溯到语义网络

10.1.1 知识的概念及表示

- 知识图谱（Knowledge Graph）以图结构的形式描述客观世界中概念、实体及其关系。



https://blog.csdn.net/ZJRN1027

10.1.1 知识的概念及表示

- 知识图谱将信息表达成更接近人类认知世界的形式，提供了一种更好地组织、管理和理解海量信息的能力。
- 知识图谱从数据中识别、发现和推断事物与概念之间的复杂关系，是事物关系的可计算模型。
- 知识图谱的构建涉及知识建模、知识抽取、图存储、关系推理等多方面的技术；
- 知识图谱的应用于推理、问答、语言理解、决策等多个领域。

10.1.2 知识图谱的构建

- 三元组：构成知识的基本单元
  - 通常表示为：（实体1，关系，实体2）
  - 实体1：通常表示一个具体的对象或概念
  - 关系：表示实体1和实体2之间的语义关联
    - 关系通常具有明确的类型，用于描述实体之间的不同联系。
  - 实体2：与实体1相关联的另一个实体，通过关系与实体1相连

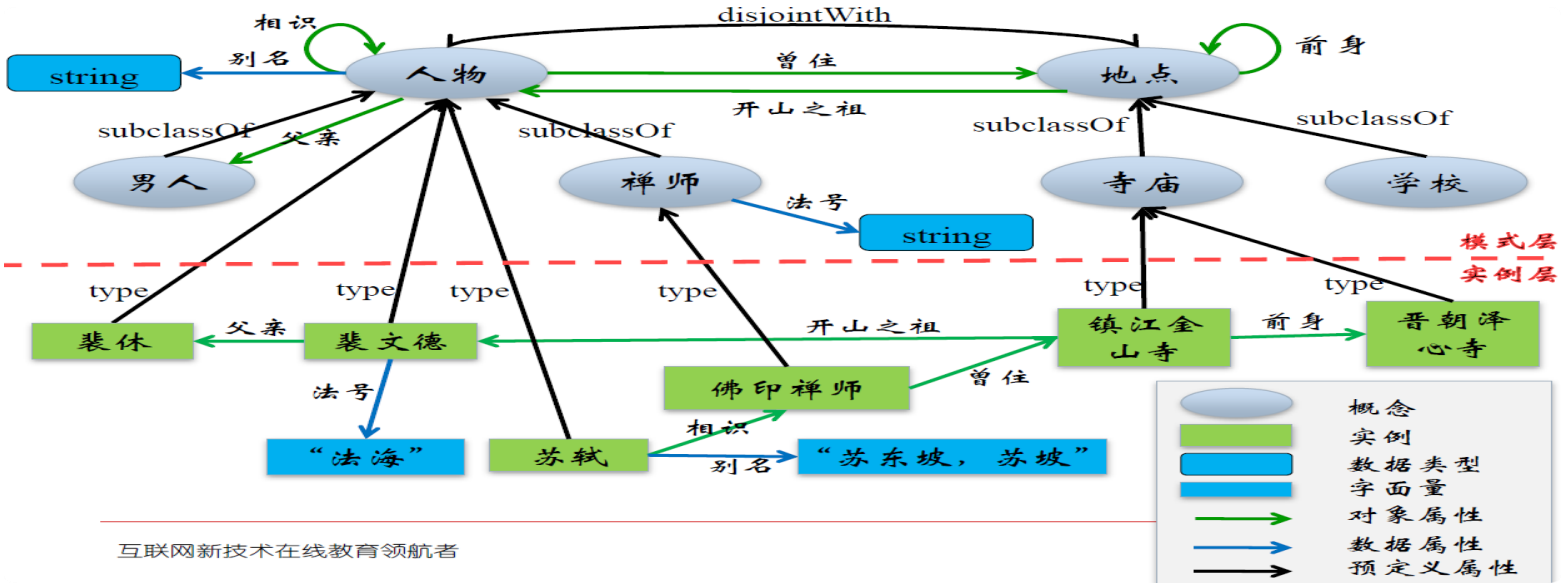
（中国，首都，北京）

10.1.2 知识图谱的构建

- 三元组表示形式
  - 主谓宾：　（牛顿，提出，万有引力）
  - 实体-属性-属性值：　（牛顿，出生地，英国）
- 三元组是知识图谱的基石
  - 通过将实体和关系抽象为三元组，可以将大量的知识结构化地表示出来
  - 有助于机器理解和推理

10.1.2 知识图谱的构建

- 知识图谱构建过程
  - 知识定义
  - 知识抽取
  - 知识补全
  - 知识存储



10.1.2 知识图谱的构建

- 知识图谱构建过程
  - 知识定义
    - 首先需要专家对原始数据进行抽样分析，掌握数据的结构特点、知识类型及内在关系；
    - 设计知识架构（schema）：设计和构建的和核心环节
      - 即定义知识图谱中的实体类别、属性及实体之间的关系类型。
      - 持续优化完善，去报规范性、完整性、一致性和可扩展性
    - 工具：Protégé
      - 提供了图形化界面和建模功能

10.1.2 知识图谱的构建

- 知识图谱构建过程
  - 知识定义
  - 知识抽取
    - 知识抽取是自动化构建大规模知识图谱的关键技术之一，目的是从不同来源、不同结构的数据中抽取知识到知识图谱中
      - 10.2节专门探讨

苹果公司是一家美国跨国公司，总部位于美国加利福尼亚库比蒂诺，致力于设计、开发和销售消费电子、计算机软件、在线服务和个人计算机。苹果公司由史蒂夫·乔布斯、史蒂夫·沃兹尼克、罗纳德·韦恩创立于1976年4月1日，开发和销售个人计算机。该公司于1977年1月3日正式称为苹果电脑公司，并于2007年1月9日改名为苹果公司，反应其业务重点转向消费电子领域。

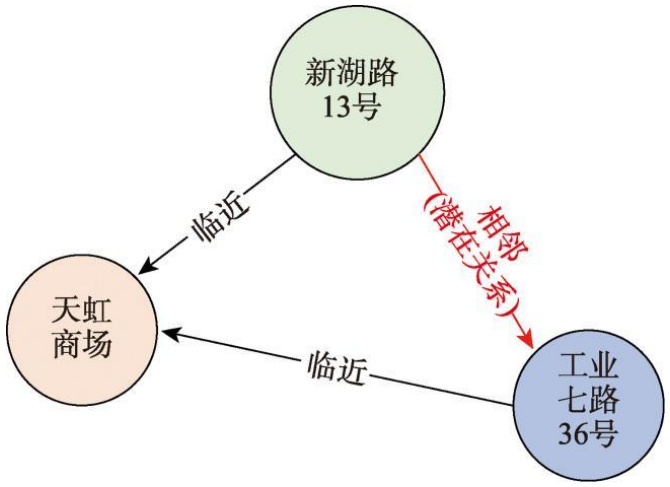


苹果公司	总部地址	美国加利福利亚库比蒂诺
苹果公司	创始人	史蒂夫·乔布斯
苹果公司	创始人	史蒂夫·沃兹尼克
苹果公司	创始人	罗纳德·韦恩
苹果公司	创立时间	1976年4月1日

知乎 @VoidOc

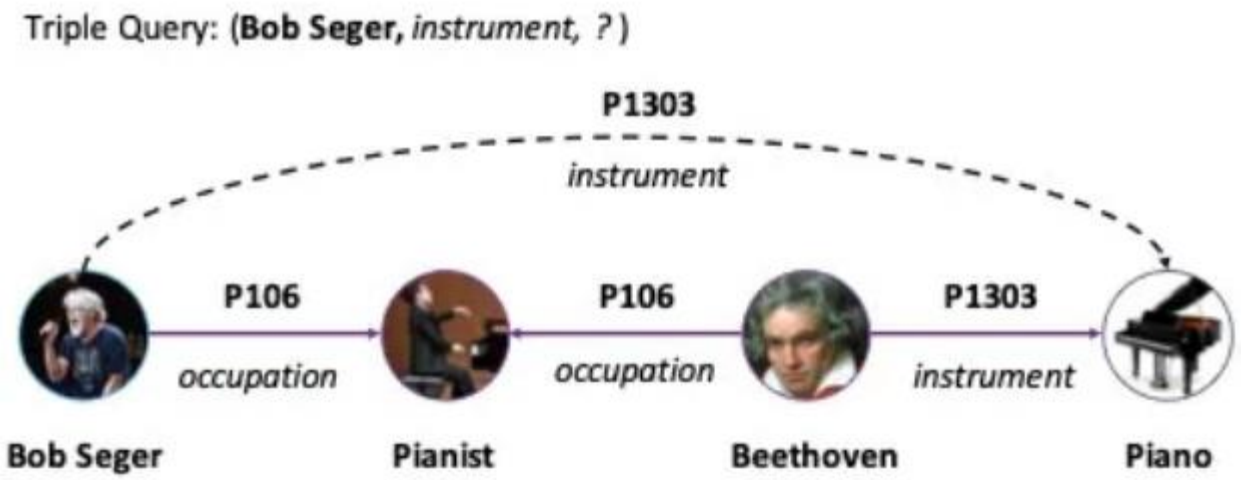
10.1.2 知识图谱的构建

- 知识图谱构建过程
  - 知识定义
  - 知识抽取
  - 知识补全
    - 通过推理或机器学习算法自动补充图谱中缺失的实体、关系或属性等信息。
    - 基于知识表示的方法
    - 基于路径查找的方法
    - 基于规则的方法
    - 基于深度学习的方法



10.1.2 知识图谱的构建

- 知识图谱构建过程
  - 知识定义
  - 知识抽取
  - 知识补全
    - 通过推理或机器学习算法自动补充图谱中缺失的实体、关系或属性等信息。



10.1.2 知识图谱的构建

- 知识图谱构建过程
  - 知识定义
  - 知识抽取
  - 知识补全
  - 知识存储：另一个关键环节
    - Neo4j是一款高性能的NoSQL图形数据库，它以原生图形数据库为核心，采用属性图方式存储和管理数据。
    - 图数据库使得数据之间的关系直观且易于查询，特别适合处理具有复杂关系的知识图谱数据。

10.1.2 知识图谱的构建

- 领域知识图谱
  - 专注于特定领域，如医疗、金融、法律等，更强的专业性
    - 不同于DFPedia,Yago,Wikidata等来源的通用知识图谱
  - 知识结构更加复杂、知识质量要求更高
  - 在知识结构方面，需要设计清晰、规范的本体体系，支持多层次、多类型的知识表示，并采用知识推理技术来挖掘隐含的知识；
  - 在知识质量方面，需要建立严格的知识审核和评估机制，确保知识的准确性和一致性。
  - 需要注重知识图谱的可维护性和可扩展性，以便适应领域发展的变化和新的应用需求。

主要内容

- 知识与知识图谱
- 知识抽取
- 知识增强的大语言模型
- 大语言模型的评价

10.2 知识抽取

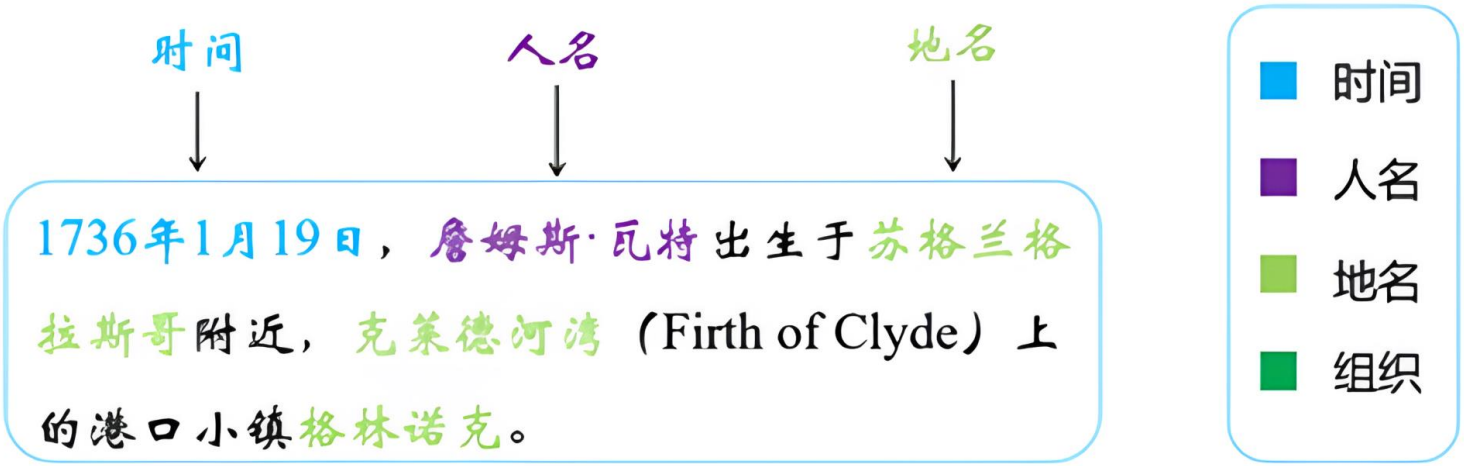
- 知识抽取定义
  - 知识抽取是指从可用的数据源（如文档、结构化文本、数据库、网页）中抽取出结构化的知识，即三元组。
  - 它是知识图谱构建的首要任务，也是知识图谱中知识获取的最主要途径。
  - 根据知识来源划分
    - 非结构化数据知识抽取
    - 结构化数据知识抽取
    - 半结构化数据知识抽取

10.2.1 非结构化数据知识抽取

- 非结构化数据源
  - 文本、图像、视频和音频
  - 无固定格式或模式，富含信息和知识
- 实体抽取
- 实体关系抽取
- 事件抽取

10.2.1 非结构化数据知识抽取

- 实体抽取：命名实体识别（Named Entity Recognition）
  - 目的是从文本中自动抽取所包含的实体集合
  - 包括人名、组织机构名、地理位置、时间、日期等等



10.2.1 非结构化数据知识抽取

- 实体抽取：基于规则的方法
  - 基于规则的方法依赖于手工编撰的规则集、命名实体库等。
  - 输入文本与规则或模板匹配时，相应的实体就会被识别出来。
  - 优点是可解释性强，能精确匹配特定模式；
  - 缺点是依赖人工构建规则，适应性差，难以覆盖复杂场景。

10.2.1 非结构化数据知识抽取

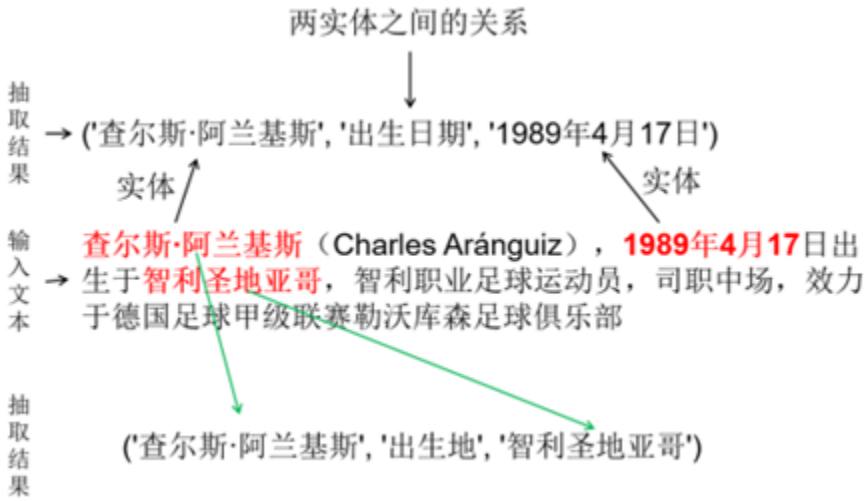
- 实体抽取：基于统计学习的方法
  - 基于统计学习的方法通常会先将实体识别转换为序列标注问题，然后运用统计机器学习模型来实现实体识别。
  - 优点是能够利用标注数据训练模型，适应性较强；
  - 缺点是特征工程依赖人工设计，泛化能力受限。

10.2.1 非结构化数据知识抽取

- 实体抽取：基于深度学习的方法
  - 在基于深度学习的方法中，模型可以自动学习文本中的特征表示用于实体识别。
  - 优点是能自动学习特征，泛化能力强；
  - 缺点是训练依赖大量数据，计算成本较高。

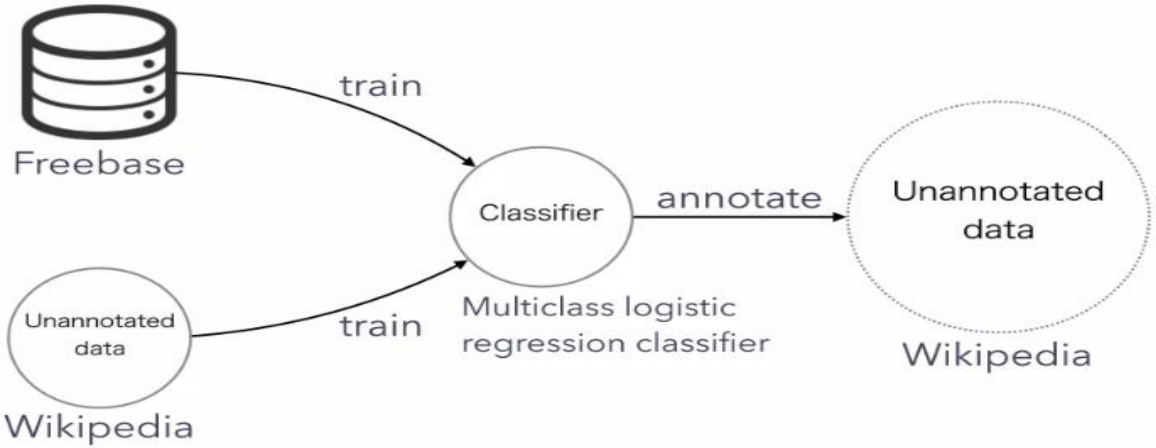
10.2.1 非结构化数据知识抽取

- 实体关系抽
  - 目标是对实体之间的语义关系自动识别或抽取，以形成知识三元组。
  - 可以在实体抽取的基础上进行，也可以和实体抽取联合进行。
  - 基于规则的方法
  - 基于统计学习的方法
  - 基于深度学习的方法



10.2.1 非结构化数据知识抽取

- 实体关系抽
  - 基于统计学习的方法：远程监督
  - 2009 年，Mike D. Mintz 等人提出用Freebase作为远程监督信号自动进行实体关系抽取。
  - 减轻对语义标注数据集的依赖



- Freebase: 102 relations, 940k entities, 1.8M instances.

10.2.1 非结构化数据知识抽取

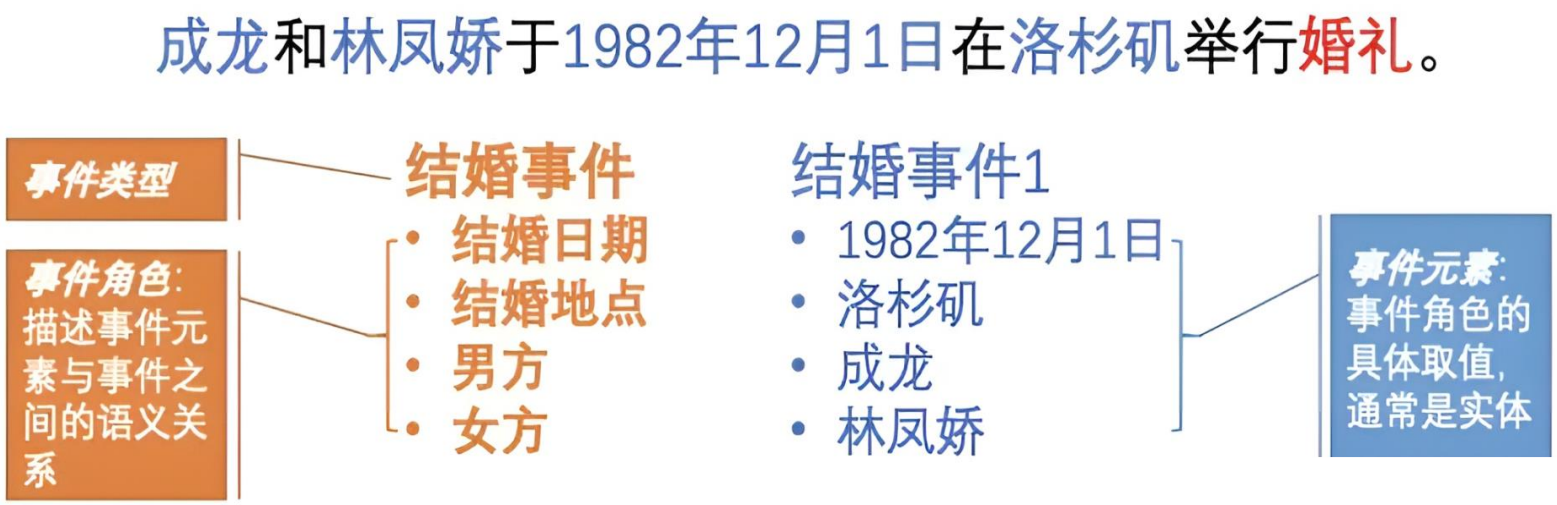
- 实体关系抽
  - 基于统计学习的方法：远程监督
    - 基本假设：如果两个实体参与一个关系，则包含这两个实体的任何句子都可能表达该关系。
    - 在Freebase中，“位置包含”关系的两个实例分别是<Virginia, Richmond>和<France, Nantes>。
    - 处理“Richmond, the capital of Virginia”或“Henry’s Edict of Nantes helped the Protestants of France ”这样的句子时, Richmond句子中的特征可能对关系预测尤为关键
    - 若遇到类似“Vienna, the capital of Austria”这样的句子，其中的特征与Richmond句子的特征高度匹配
    - 可以推断出<Austria, Vienna>也属于“位置包含”关系

10.2.1 非结构化数据知识抽取

- 实体关系抽
  - 基于统计学习的方法：远程监督
  - 在训练步骤中，首先使用命名实体识别器在句子中识别所有人名、地名、机构名实体。
    - 如果一个句子包含两个实体，并且是Freebase中的实例，就从该句子中提取特征并将其添加到关系的特征向量中。
  - 在关系预测中
    - 首先使用命名实体识别器标识数据集中每个句子所包含的实体，句子中的实体对都被视为一个潜在的关系实例；
    - 然后从句子中抽取特征，并添加到该实体对的特征向量中；
    - 最后使用训练好的分类器来预测每个实体对最可能的关系类型。

10.2.1 非结构化数据知识抽取

- 事件抽取
  - 检测文本中事件及其相关信息。



10.2.1 非结构化数据知识抽取

- 事件抽取
  - 开域事件抽取：不需要任何预定义的事件结构
  - 闭域事件抽取：基于预定义的事件结构来抽取事件内容，如事件的参与者及其与事件的关系
    - 多语言数据集ACE-2005（Automatic Content Extraction）中为事件抽取任务提供了标准和指导
      - 事件范围：是包含事件信息的句子。
      - 事件触发器：是事件发生的单词或短语，通常是句子中的主要动词。
      - 事件论元：是参与事件的实体和属性。
      - 论元角色：论元在事件中扮演的角色。

10.2.1 非结构化数据知识抽取

- 事件抽取
  - 闭域事件抽取：ACE-2005实例

“Earlier documents in the case have included embarrassing details about perks Welch received as part of his retirement package from GE at a time when corporate scandals were sparking outrage”

Trigger	Retirement
Event type	Personnel:End-Position
Person-Arg	Welch
Entity-Arg	GE
Position-Arg	-
Time-Arg	-
Place-Arg	-

10.2.2 结构化数据知识抽取

- 结构化数据知识抽取：将常规数据库数据自动转换为图数据库数据
  - 例：以MySQL数据自动导入Neo4j
  - 方法1：使用ETL工具连接MySQL和Neo4j数据库，进行数据抽取、转换和加载。
    - ETL工具：Talend、Pentaho等
  - 方法2：将MySQL数据导出为CSV文件，然后使用Neo4j提供的NEO4j-Import工具进行导入
  - 方法3：查询MySQL数据，并将查询结果转换成Cypher语句，然后导入Neo4j。
  - 方法4：使用APOC插件的apoc.load.jdbc存储过程，直接从MySQL数据库中加载数据到Neo4j中。

10.2.3 半结构化数据知识抽取

- 半结构化数据
  - 半结构化数据介于结构化数据与非结构化数据之间，它并不具备严格的数据格式，但是也有一定的规律可循。
  - 半结构化数据通常包含一些标记或标签，这些标记有助于解析和理解数据的内容。
  - 许多专业数据以半结构化方式呈现，因此半结构化数据也是知识获取的重要来源。
    - 如医疗健康领域的电子病历就是具有半结构化特点的数据资源，其中蕴含了丰富的医疗专业知识和实践经验。

10.2.3 半结构化数据知识抽取

- 半结构化数据知识抽取方法
  - 基于规则的方法
    - 通过人工编写的规则
    - 适用于特定领域和格式固定的数据，维护成本高，通用性差，难以应对复杂和变化的数据结构。
  - 基于统计学习的方法
    - 通过特征工程和分类模型
    - 适应性强，需要标注数据进行训练。
  - 基于深度学习的方法
    - 基于神经网络
    - 自动化程度高，泛化能力强，需要标注数据进行微调，训练成本较高，计算资源需求大。

主要内容

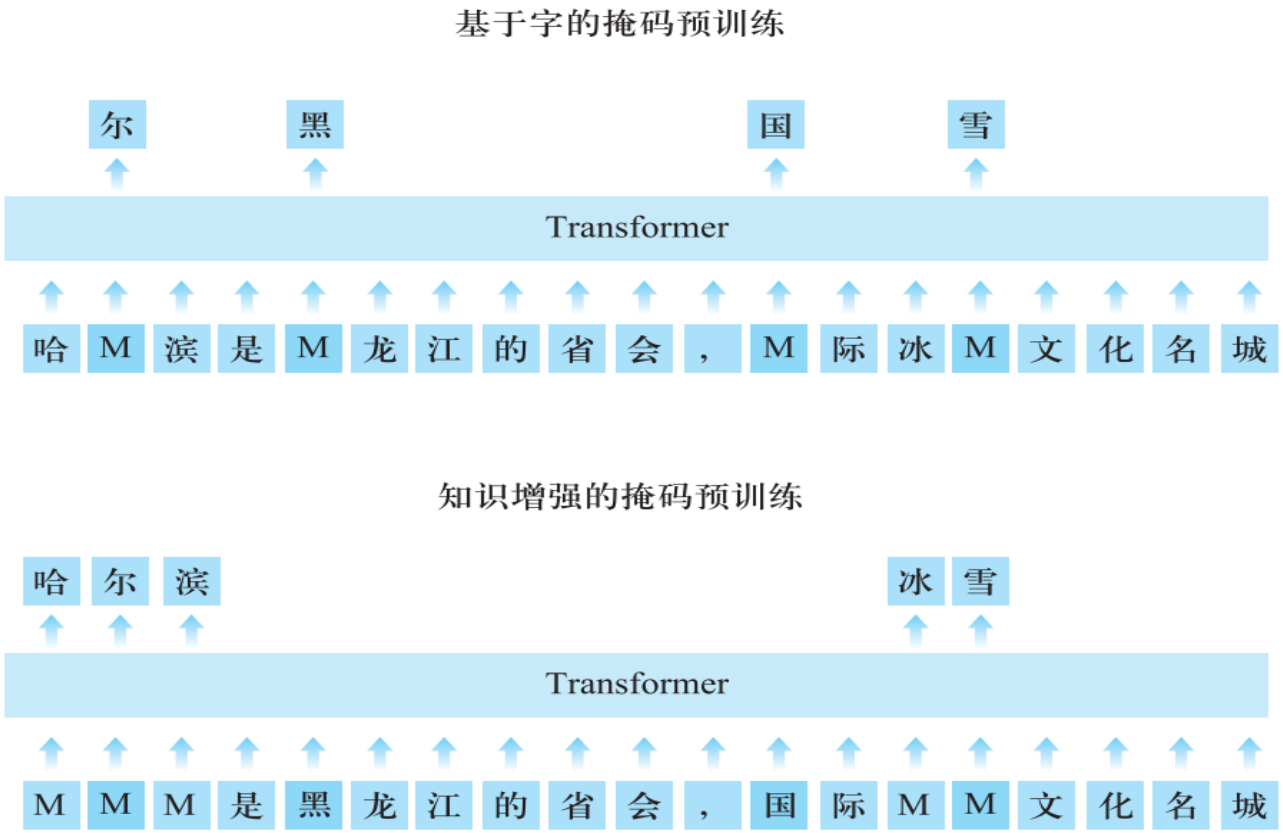
- 知识与知识图谱
- 知识抽取
- 知识增强的大语言模型
- 大语言模型的评价体系

10.3 知识增强的大语言模型

- 知识增强的大语言模型（Knowledge-Augmented Large Language Model，KALLM）
  - 通过融合大语言模型技术与知识增强技术，全面提升模型效果和效率，增强模型可解释性，扩展模型应用领域，是大语言模型的重要发展趋势
- 工作原理：在模型训练或推理阶段将知识融入
  - 知识内化：预训练过程中，从知识与数据中融合学习，把知识内化到模型参数
  - 知识外用：在推理过程中，模型动态选择和运用外部知识，增强 输出结果的准确性

10.3.1 知识增强的模型预训练

融合语言知识的预训练-词法知识



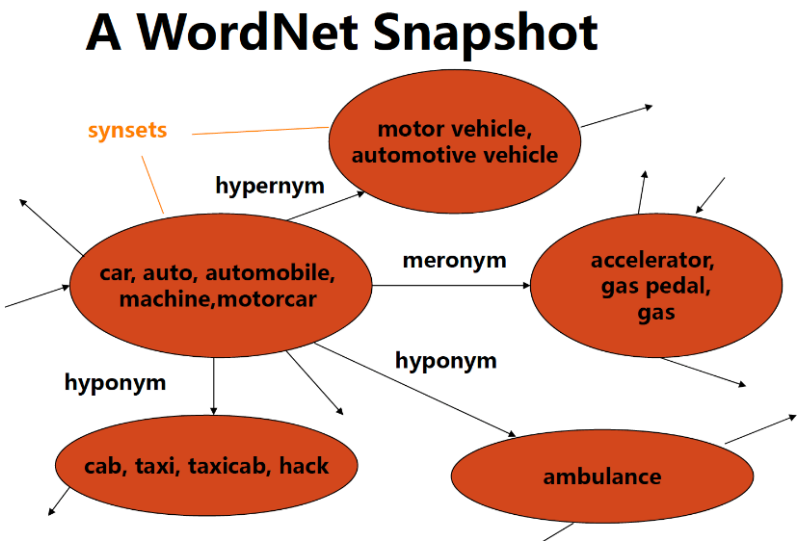
哈滨尔是黑龙江的省会，国际冰雪文化名城

10.3.1 知识增强的模型预训练

- 融合语言知识的预训练-语义知识
  - 训练模型识别句子间的逻辑关系来学习语义知识
  - 首先从大规模语料中挖掘出具有逻辑关系的句子，将句子中的连词去掉，构建蕴含逻辑关系的预训练数据
  - 采用无监督方法进行逻辑关系分类训练
- 例子
  - “因为人们的乱砍滥伐， 所以今年以来洪涝不断 “
  - “尽管风雨交加，但是同学们还是坚持按时到校上课”

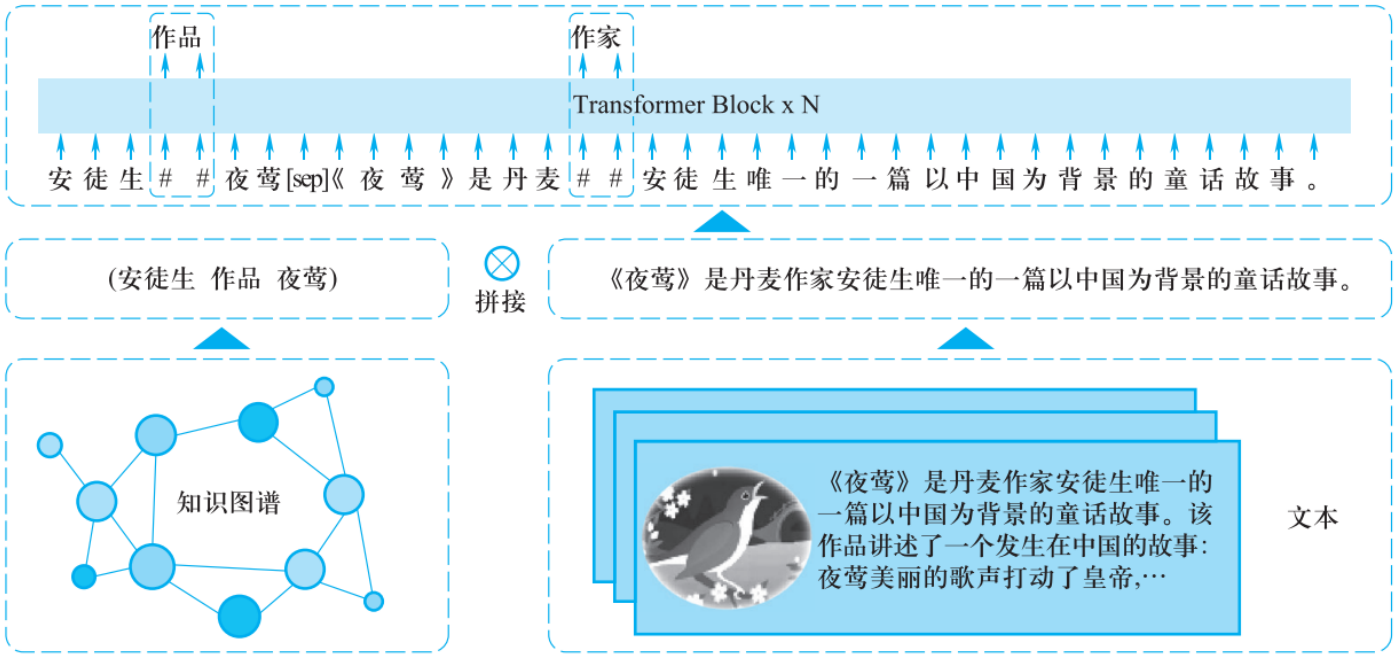
10.3.1 知识增强的模型预训练

- 融合语言知识的预训练-人工知识库
  - WordNet 是一个大型的词汇知识库，其中每个同义词集合 包含一个或多个同义词，表示特定概念或意义
  - 用语义关系将这些集合连接成一个复杂的网络
  - 设计任务：掩盖词还原、词汇关系分类



10.3.1 知识增强的模型预训练

- 融合世界知识的预训练
  - 世界知识可以基表示为知识图谱的形式
  - 在预训练阶段采用联合掩码策略，将知识图谱的三元组知识与包含该知识的文本信息同时进行训练



10.3.2 知识增强的模型推理

- 推理中的知识缺陷
  - 知识时效问题
  - 幻觉问题
- 引入外部知识库
  - 在理解用户需求的基础上细化知识点
  - 利用搜索引擎或外部数据库、知识库，检索整合信息
  - 综合分析各方信息，生成回应

10.3.2 知识增强的模型推理

- 外部知识的优势
  - 外部知识作为高质量、专业化的信息源，有效弥补了模型记忆的不准确和信息覆盖的不完整
  - 快速更新的外部知识确保了信息的时效性，很好地解决了大语言模型的知识陈旧问题

10.3.2 知识增强的模型推理

- 例子：
  - 用户需求：“请给出这个国庆档票房排行前十的电影”
  - 鉴于电影票房数据会实时变动，此类问题对信息时效性要求极高，模型内化的知识难以满足
  - 通过接入专业的电影票房数据库，大语言模型能够获取到最新、最权威的信息，进而为用户提供精确且高质量的答复

10.3.2 知识增强的模型推理

- 两个关键步骤
  - 内容规划
    - 主要涉及需求理解、知识检索和选择等
  - 内容生成
    - 根据选择的知识进行显式知识和隐式知识的交互验证，最后生成恰当的回复

10.3.2 知识增强的模型推理

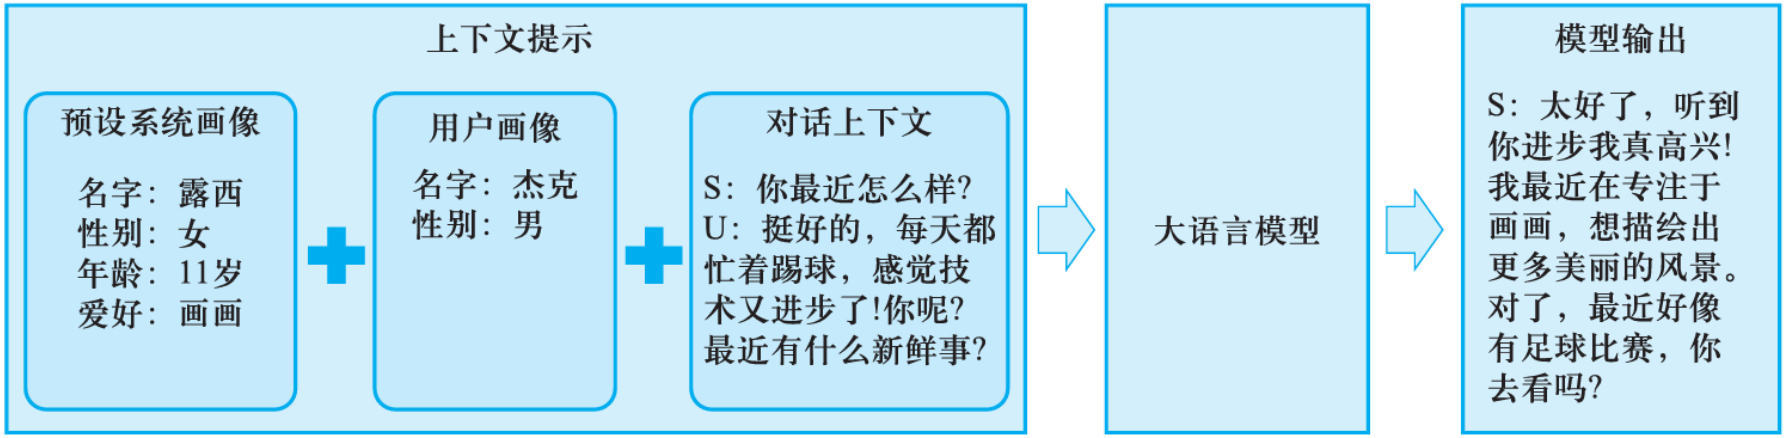
- 知识增强的内容规划
  - 目标：提高输出内容的逻辑性、准确性、结构性和深度
  - 方法：检索增强
    - 理解阶段：对用户的输入进行深度理解，并自动判断是否需要访问外部知识库
    - 检索阶段：模型通过检索系统从外部信息源，包括领域知识库、学术论文、专业文档或实时更新的信息源等获取信息

10.3.2 知识增强的模型推理

- 知识增强的内容规划
  - 目标：提高输出内容的逻辑性、准确性、结构性和深度
  - 方法：检索增强
  - 方法：思维链推理COT
    - 将复杂问题拆解成一系列逻辑连贯、循序渐进的步骤，并通过逐步推导来得出最终答案
    - 在每一步推理过程中，不仅基于模型内化的知识，还会通过访问外部知识库来获取与当前步骤相关的参考信息

10.3.2 知识增强的模型推理

- 知识增强的内容规划
  - 目标：提高输出内容的逻辑性、准确性、结构性和深度
  - 方法：检索增强、思维链推理COT
  - 方法：基于上下文学习
    - 将预设知识转化为大语言模型可在线学习的数据形式



10.3.2 知识增强的模型推理

- 知识增强的内容生成
  - 核心思想是利用外部知识，通过显式知识和隐式知识的交互验证，来提升生成内容的质量
  - 这种知识的协同作用通过显式知识与隐式知识的交互验证得体现

10.3.2 知识增强的模型推理

- 例子
  - 用户询问：“庆承瑞教授的出生年份”
  - 训练数据中存在不同的说法：一种是她出生于1933年；另一种则是1935年
  - 外部知识：“2021年的一场访谈中提到：何院士今年94岁，庆教授88岁，他们夫妇分别毕业于国立交通大学和清华大学。”

10.3.3 知识增强大语言模型的典型应用

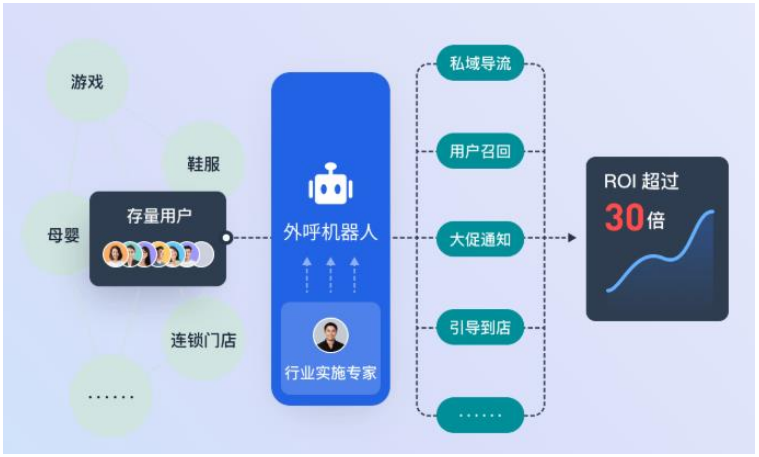
- 搜索引擎应用
  - 传统搜索引擎：链接分析与关键词匹配
  - 新检索架构：基于深度语义理解与语义匹配架构的复杂性显著降低，结果更准确
  - 例子：
    - 谷歌引入BERT
    - 微软Turing-NLG
    - 百度基于知识增强大语言模型的新一代检索架构

10.3.3 知识增强大语言模型的典型应用

- 人机对话应用
  - 智能音箱
  - 智能客服
  - 智能车载







10.3.3 知识增强大语言模型的典型应用

- 行业应用
  - 医疗行业：临床医疗辅助系统，实现可循证的医学决策
  - 金融行业：帮助从业人员从金融文本中快速抽取信息
  - 媒体行业：分析热点资讯，提供素材推荐、智能纠错、标题生成、用词润色和文章审校等服务

主要内容

- 知识与知识图谱
- 知识抽取
- 知识增强的大语言模型
- 大语言模型的评价体系

10.4 大语言模型的评价体系

- 基础能力评估：理解、生成、逻辑、记忆
  - 阅读理解：输入一段或多段文本，模型能够理解文本并准确回答与这些文本相关问题的能力
    - 重点是模型的文本理解能力
    - **例：**小明今天早上吃了一个苹果和一个香蕉。他带了一个橙子作为午餐后的水果。
      - 问题：小明早餐吃了什么？
      - 模型回答：一个苹果和一个香蕉。

10.4 大语言模型的评价体系

- 基础能力评估：理解、生成、逻辑、记忆
  - 阅读理解
  - 文本生成：在给定输入的基础上，生成符合语义逻辑和语言规范的自然语言文本的能力
    - 评估重点：语言理解能力、 表达能力，以及生成内容的准确性、多样性和一致性

10.4 大语言模型的评价体系

- 基础能力评估：理解、生成、逻辑、记忆
  - 阅读理解、文本生成
  - 代码生成
    - 根据特定需求，自动生成符合编程语法和逻辑的代码的能力
    - 评估重点：对编程语言的理解、语法正确性以及生成代码的可执行性和性能

10.4 大语言模型的评价体系

- 基础能力评估：理解、生成、逻辑、记忆
  - 阅读理解、文本生成、代码生成
  - 逻辑推理
    - 基于逻辑关系和已知事实，进行推理与决策的能力
    - 评估重点：考查模型理解概念之间的关联性、遵循逻辑规则进行推理的能力

已知前提：所有猫都喜欢吃鱼；咪咪是一只猫。

问题：咪咪喜欢吃什么？

模型的推理与回答：喜欢吃鱼。

10.4 大语言模型的评价体系

- 基础能力评估：理解、生成、逻辑、记忆
  - 阅读理解、文本生成、代码生成、逻辑推理
    - 数学推理理解和解决数学问题时所展现的能力，通常包括问题理解、多步骤推理及数值计算等多个方面
    - 评估重点：模型的逻辑推理、数理理解等能力，以及解决数学问题时的准确性

10.4 大语言模型的评价体系

- 基础能力评估：理解、生成、逻辑、记忆
  - 阅读理解、文本生成、代码生成、逻辑推理、数学推理
  - 记忆能力
    - 理解和运用长上下文的能力
    - 评估重点：模型对长期和短期记忆的保持及灵活运用的水平

10.4 大语言模型的评价体系

- 应用能力评价
  - 指令遵循
    - 模型理解、执行和响应自然语言指令的能力
    - 要求模型具备精确解读用户意图的能力，并生成符合指令规范的回复

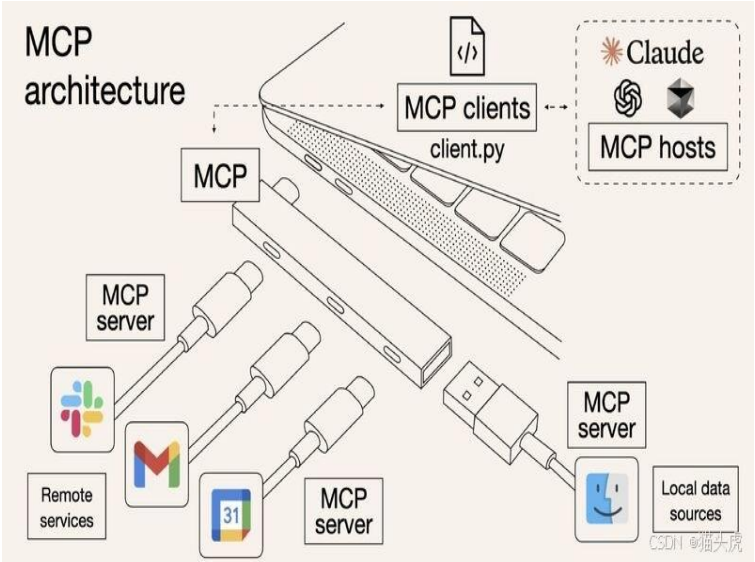
用户的指令：请将下面这句话翻译成中文，并以诗歌的格式分行排列：

"The evening sun sets behind the mountains, painting the sky in hues of orange and purple.“

模型回答：夕阳西下沉山后， 漫漫天际染画布， 橙紫交织绘彩图。

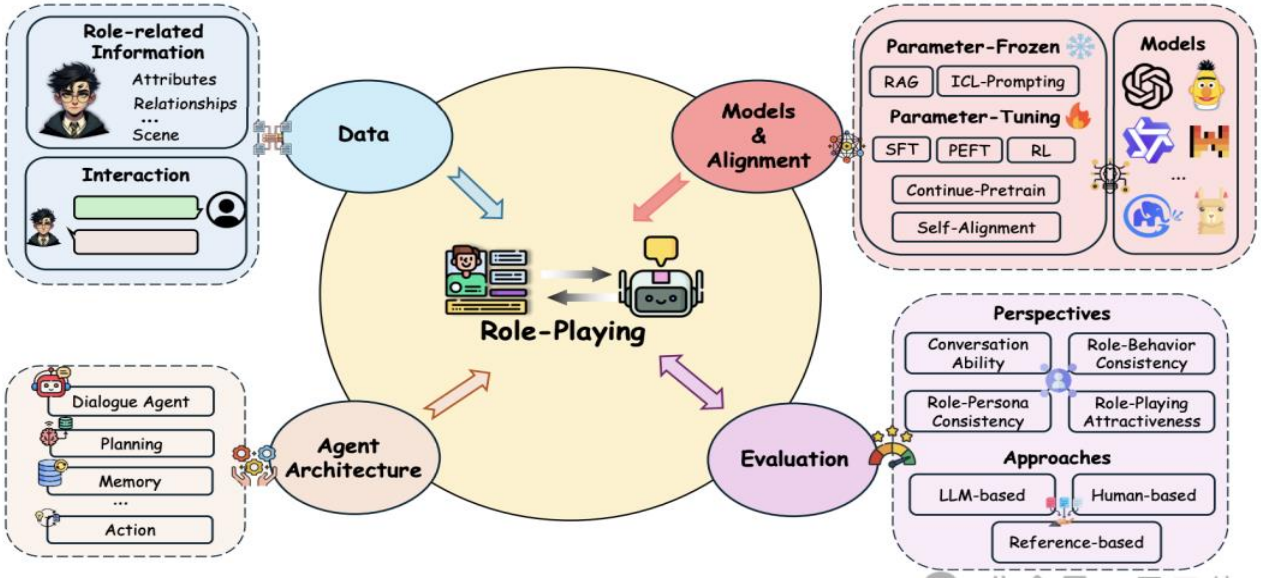
10.4 大语言模型的评价体系

- 应用能力评价
  - 指令遵循
  - 工具使用
    - 指模型能够利用外部工具来完成任务的能力
    - 要求大语言模型能够借助外部资源，解决精确计算、信息检索、处理等复杂问题，以及实现多步推理、跨领域信息整合等



10.4 大语言模型的评价体系

- 应用能力评价
  - 指令遵循、工具使用
  - 角色扮演
    - 模型模仿和扮演不同角色的能力，包含基于人物的角色扮演和基于性格的角色扮演等



10.4 大语言模型的评价体系

- 安全可靠性评价
  - 安全与伦理
    - 语言模型的安全伦理包含多种不同的评价体系或维度，如冒犯性、不公平与偏见、身体健康、心理健康、非法活动、道德问题、隐私与财产等
  - 真实与可信
    - 事实准确性、一致性、 来源可靠性和抗攻击性等维度

大语言模型的评价实践

补充材料

- MMLU(Massive Multitask Language Understanding)
  - 通过在零样本学习和少样本学习的条件下评价大语言模型来衡量其在预训练阶段获得的知识
  - 旨在评价大语言模型在各种不同领域的知识理解与应用能力
  - 该评价基准涵盖STEM、人文科学、社会科学和其他领域等57个主题，问题难度从小学到高级专业水平均有涉及

大语言模型的评价实践

补充材料

- MMLU数据构成与指标
  - MMLU共有15908个问题，均为包含一个问题和若干个候选答案的多选题
  - 划分为少样本开发集、验证集和测试集
  - 其评测通常会使用少样本开发集中的5个问题作为测试时提示模板中的示例
  - 大语言模型需要根据任务描述和问题描述来预测概率最高的选项作为答案，最终采用平均准确率作为评价指标。

大语言模型的评价实践

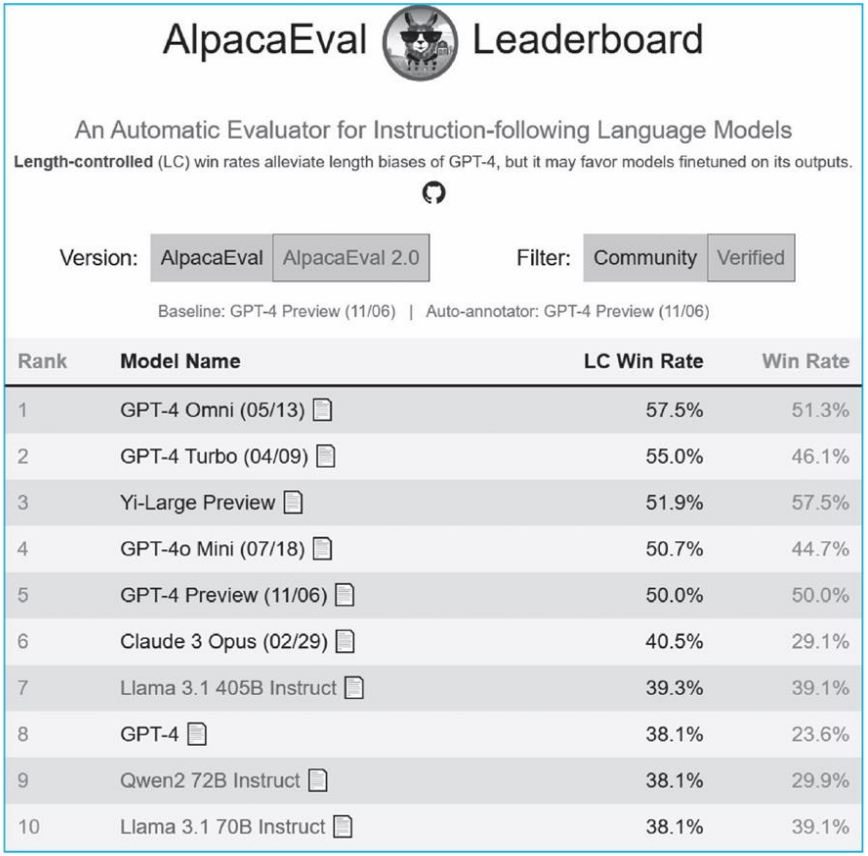
补充材料

- AlpacaEval
  - AlpacaEval旨在评价大语言模型遵循用户指令的能力，目前已发布了AlpacaEval和 AlpacaEval 2.0 两个版本
  - 该评价基准通过基于GPT-4的自动评价器，对大语言模型输出的回复和由大语言模型生成的参考回复比较
    - AlpacaEval使用Davinci003生成参考回复
    - AlpacaEval 2.0 使用 GPT-4 Preview 生成参考回复

大语言模型的评价实践

补充材料

- AlpacaEval
  - AlpacaEval对比较的结果维护了一个模型的排行榜
  - 该排行榜还对胜率进行了长度控制，旨在消除基于GPT-4的自动评价器的冗长偏见
  - 评价结果与人工评价的结果具有很高的一致性



AlpacaEval Leaderboard

An Automatic Evaluator for Instruction-following Language Models

Length-controlled (LC) win rates alleviate length biases of GPT-4, but it may favor models finetuned on its outputs.

Version: AlpacaEval | AlpacaEval 2.0 Filter: Community | Verified

Baseline: GPT-4 Preview (11/06) | Auto-annotator: GPT-4 Preview (11/06)

Rank	Model Name	LC Win Rate	Win Rate
1	GPT-4 Omni (05/13)	57.5%	51.3%
2	GPT-4 Turbo (04/09)	55.0%	46.1%
3	Yi-Large Preview	51.9%	57.5%
4	GPT-4o Mini (07/18)	50.7%	44.7%
5	GPT-4 Preview (11/06)	50.0%	50.0%
6	Claude 3 Opus (02/29)	40.5%	29.1%
7	Llama 3.1 405B Instruct	39.3%	39.1%
8	GPT-4	38.1%	23.6%
9	Qwen2 72B Instruct	38.1%	29.9%
10	Llama 3.1 70B Instruct	38.1%	39.1%

截至2024.10.18

大语言模型的评价实践

补充材料

- Chatbot Arena
  - 一个以匿名竞争为特色的基准平台
  - 用户可以同时与两个匿名模型交互，向两者提出同样的问题，并投票选出回复更优的模型，投票后两个模型的真实身份将向用户揭晓
  - 最后根据PK结果使用Elo评分系统对模型更新模型的评分

习题

- 在大语言模型进行知识增强时，以下哪种方法通常用于将知识融入模型参数中？
  - （1）简单地增加训练数据的数量。
  - （2）把结构化知识转换成纯文本数据并参与模型训练过程。
  - （3）引入知识图谱并设计知识与文本的融合学习机制。
  - （4）调整模型的超参数以改善性能。
- 请举例说明预训练模型融合知识的类型。
- 试论述在大语言模型中进行知识增强的意义，并给出至少两个实际应用场景
- 大语言模型的基础能力评估包含哪些方面？请列举出至少3个方面，并且加以简单说明。