主要内容

- 12.1 提示工程
- 12.2 检索增强RAG
- 12.3 基于大语言模型的智能体

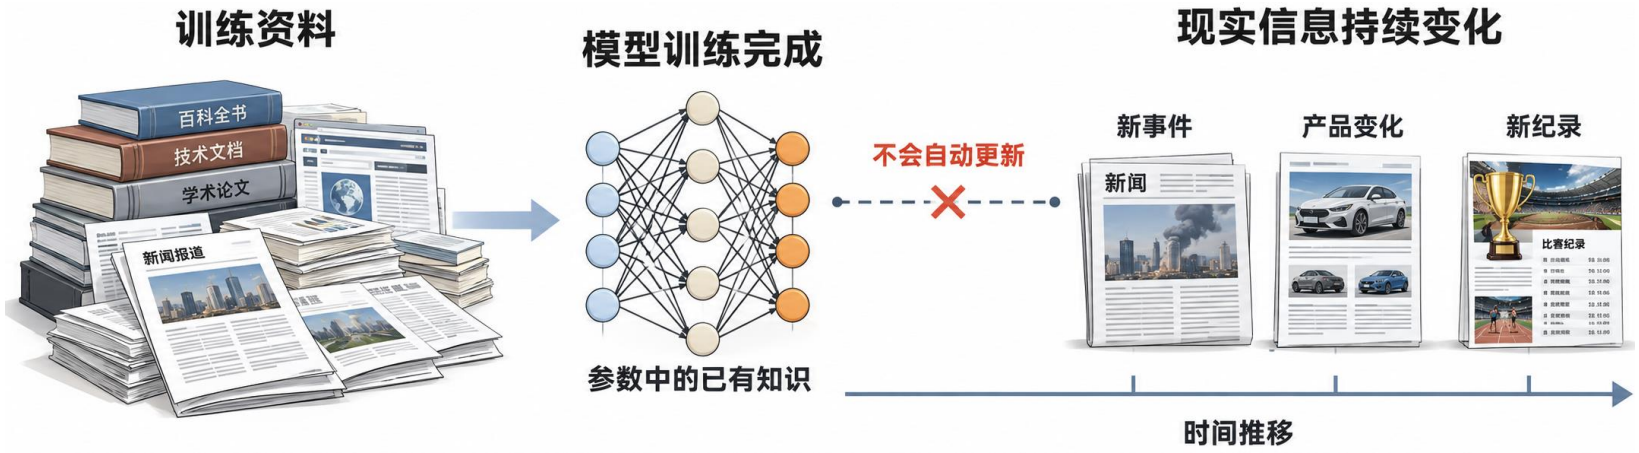
12.2 检索增强RAG

- 12.2 检索增强RAG
  - 12.2.1 检索增强概述
  - 12.2.2 RAG系统架构
  - 12.2.3 RAG核心技术
  - 12.2.4 进阶RAG技术
  - 12.2.5 多模态RAG
  - 12.2.6 Agentic RAG

12.2.1 检索增强概述

模型训练完成后，世界仍在变化

- 大语言模型通过训练学习知识，并将其编码在模型参数中。训练完成后，参数中的知识不会随现实世界的变化自动更新。
- 面对新发生的事件、已经变化的事实，或训练中覆盖不足的专业知识，仅依靠模型已有知识可能难以准确作答。



[1] VU T, IYYER M, WANG X, et al. FreshLLMs: Refreshing Large Language Models with Search Engine Augmentation[C]// Findings of the Association for Computational Linguistics: ACL 2024. 2024: 13697-13720. DOI: 10.18653/v1/2024.findings-acl.813.

12.2.1 检索增强概述

问题存在不同类型

问题类型	问题	2024年问题的答案	当前答案或更新情况 (2026年10月20日核验)
基本不变	伊丽莎白二世以饲养哪种犬而闻名?	彭布罗克威尔士柯基犬	————
缓慢变化	特斯拉提供多少款车型?	六款：Model S、X、3、Y、 Tesla Semi及Cybertruck	产品阵容已调整：Model S/X停产
快速变化	布拉德·皮特最近出演的电影是哪部?	《IF》	《Heart of the Beast》(2026年9月上映)
错误前提	德约科维奇在2022年澳网的哪一轮被淘汰?	他未获准参赛，不存在被淘汰的轮次	————

- 若未核实参赛事实就生成“被淘汰的轮次”，回答便可能包含虚构内容。

“————”表示答案无更新。

[1] VU T, IYYER M, WANG X, et al. FreshLLMs: Refreshing Large Language Models with Search Engine Augmentation[C]// Findings of the Association for Computational Linguistics: ACL 2024. 2024: 13697-13720. DOI: 10.18653/v1/2024.findings-acl.813.
[2] TESLA. Model S; Model X; Cybertruck[EB/OL]. [2026-10-20]. https://www.tesla.com/.
[3] PARAMOUNT. Heart of the Beast[EB/OL]. [2026-10-20]. https://www.paramount.com/movies/heart-of-the-beast. 据[1]图1译编；当前答案为编者补充。

12.2.1 检索增强概述

大模型回答的来源追溯

- 分析前页提到的问题：
  - 特斯拉当前的车型阵容，以什么资料为准？
  - 德约科维奇究竟有没有参加2022年澳网？
- 仅依靠模型参数生成的回答，通常不附带可直接核查的原始资料，使用者难以追溯具体事实的来源。
- 因此，针对上述遇到的各种情况，模型频繁重训练显然不现实，我们需要一种让模型能够查阅外部资料、依据资料回答问题的方法。

[4] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C]//Advances in Neural Information Processing Systems. 2020, 33: 9459-9474.

12.2.1 检索增强概述

什么是RAG?

- 大语言模型在文本生成、开放域问答等领域取得了显著成果。
- 同时面临挑战：幻觉、可解释性、专业领域表现、知识更新
- 检索增强（Retrieval-augmented Generation，RAG）：为大语言模型构建了一个搜索引擎，可以让预训练好的大语言模型访问外部动态信息，获取预训练过程中未学习到的知识与信息
  - 提供了一个大语言模型与外部数据空间交互的新途径

12.2.1 检索增强概述

RAG应用示例



12.2.1 检索增强概述

RAG应用示例

AI在医疗领域具体有哪些应用?

人工智能 医疗诊断 应用

人工智能（AI）在医疗领域的应用已覆盖"诊前—诊中—诊后"全链条，核心可归纳为以下七大场景，并附最新进展与典型案例：

---

1. 医学影像分析：看得更快、更准

代表技术：卷积神经网络(CNN)、Transformer
落地场景：

- **肺癌早筛**：AI在3秒内完成1张CT分析，可检出直径 < 3 mm的结节，漏诊率 < 5%；某三甲医院接入后，早期肺癌检出率从68%升至92% CSDN博客 。
- **乳腺癌筛查**：Google Health的AI系统使假阳性率降低5.7%，假阴性率降低9.4% 。
- **脑卒中急救**：AI自动完成CT灌注分析，秒级输出ASPECTS评分，指导溶栓/取栓决策 。

网页搜索 120

微信公众号(中山区生物医药科技产业园) 2025/08/15

跨越学科的革新：多模态AI开启生物医学研究的新纪元

随着Anthropic最新大模型Claude3模型的登场，人工智能（AI）的浪潮已开始席卷学术科研领域。AI大模型...

微信公众号(科学之友) 2025/08/15

视点｜人工智能应用于医疗领域面临的机遇与挑战

原创 严峰 科学之友 随着信息技术的飞速发展，人工智能（AI）在医疗领域的应用前景正日益受到关注。近...

微信公众号(gif动图表情包动图) 2025/08/13

北京医院人工智能ai

在当今科技日新月异的时代，人工智能（AI）已经悄然渗透到我们生活的方方面面，尤其是在医疗领域，AI...

familydoctor.cn 2025/08/11

10个AI在医疗保健领域的最佳应用案例-家医大健康

本文系统梳理了AI在医疗保健领域的十大突破性应用，涵盖医学影像分析、疾病预测、药物研发等关键领域...

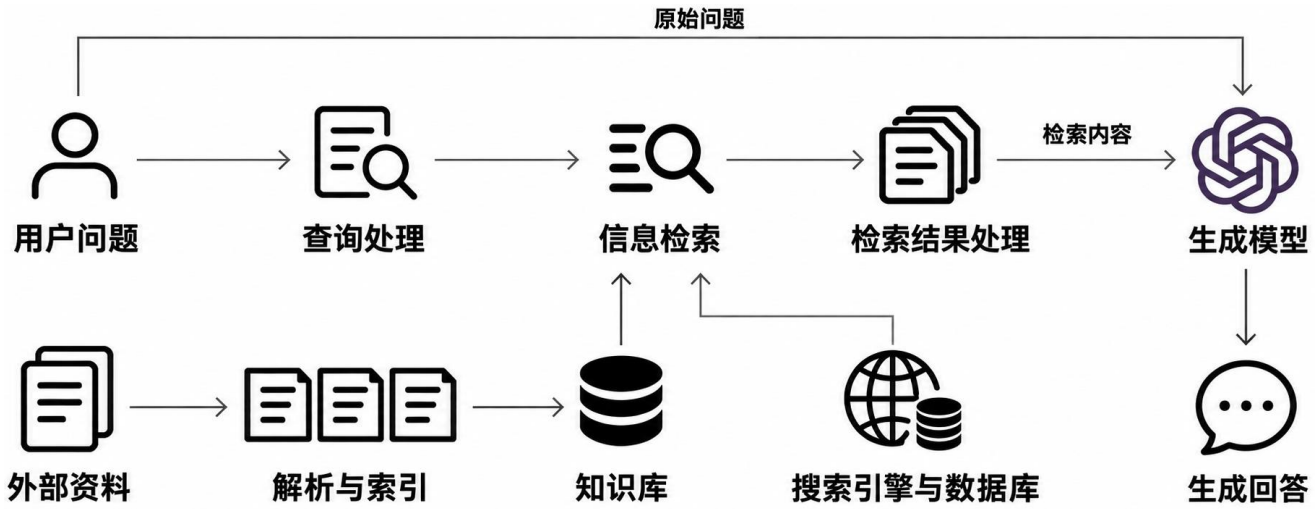
微信公众号(健澜科技) 2025/08/08

AI Agent：医疗领域的"智慧体"核心技术，未来医生的"超级第二大脑"！

原创 健澜科技 健澜科技 1. 引言 1.1 研究背景与意义 随着人工智能技术的飞速发展，其在医疗领域的应用逐...

12.2.1 检索增强概述

RAG技术框架



- 首先收集任务相关的外部资料，如网络信息、企业文档和专业资料等。
- 对资料进行解析与组织，建立便于检索的索引。
- 用户输入问题后，系统依据查询，从知识库或其他外部信息源中检索相关内容。
- 将检索到的内容组织为参考信息，与用户问题共同输入生成模型。
- 生成模型结合参考信息及自身已有知识，生成最终回答。

[5] 袁乐, 刘绍华, 王禹, 等. 大语言模型检索增强生成优化技术研究综述[J]. 计算机学报, 2026, 49(2): 383-422.
DOI: 10.11897/SP.J.1016.2026.00383. 图：据通用RAG流程重绘的教学示意，非论文原图。

12.2.1 检索增强概述

RAG技术示例

- 问题:“我是今天新入职的员工小王，咱们XX公司几点下班？”

- 可以理解，大模型在没有见过“XX公司”《员工手册》的情况下无法正确回答这个问题，事实上，企业私有数据一般也不会被大模型的预训练数据所覆盖。而RAG技术可以让大模型接入外部数据（如企业私有数据），弥补知识上的空缺，从而更好地解决特定问题。

- RAG技术解决此问题的步骤如下:
- 首先，基于用户的提问，到XX公司的《员工手册》里找到最相关的N个文本片段；然后，把用户提问和N个文本片段一起送到大模型中，大模型会理解问题并参考这些文本片段，从而获得正确答案。

12.2.1 检索增强概述

RAG技术示例



本例中的问题“XX公司几点下班？” 经过RAG技术处理后就变成：

提问：『请参考员工手册，回答以下问题：XX公司几点下班？员工手册内容如下：遵守上班时间不迟到、不早退……工作时间每周一至周五上午9:00到下午5:00……』

回复：『下班时间是下午5点。』

12.2.1 检索增强概述

RAG技术的优势

- 灵活性：在实际应用场景中，知识每时每刻都在迭代与更新，传统的微调技术需要定期地使用新数据更新模型参数，而RAG技术只需要更新外部数据库中的知识即可，无需重新训练模型。此外，RAG可以通过接入特定领域的知识库和构建相关提示，快速具备该领域的能力。

- 安全性：通过在数据库层面进行权限划分与安全管控，RAG有效强化了对数据使用的管理，相较于微调模型在数据权限管理上的潜在模糊性，RAG系统展现出更高的安全性。

- 可解释性：RAG系统的答案来自数据库，其回复具有很强的可解释性，用户可以通过信息来源核实答案的准确性。

12.2.1 检索增强概述

RAG技术发展历史

- RAG的诞生恰逢transformer架构的兴起，早期的RAG技术专注于为预训练语言模型整合额外的知识来增强模型。
- ChatGPT提出后，RAG的研究转向在推理阶段为大语言模型提供更丰富的信息以解决更复杂、知识更密集的任务。
- 随着研究的持续深入，RAG技术也不再局限于推理阶段，而是开始更多地与大模型微调技术相融合

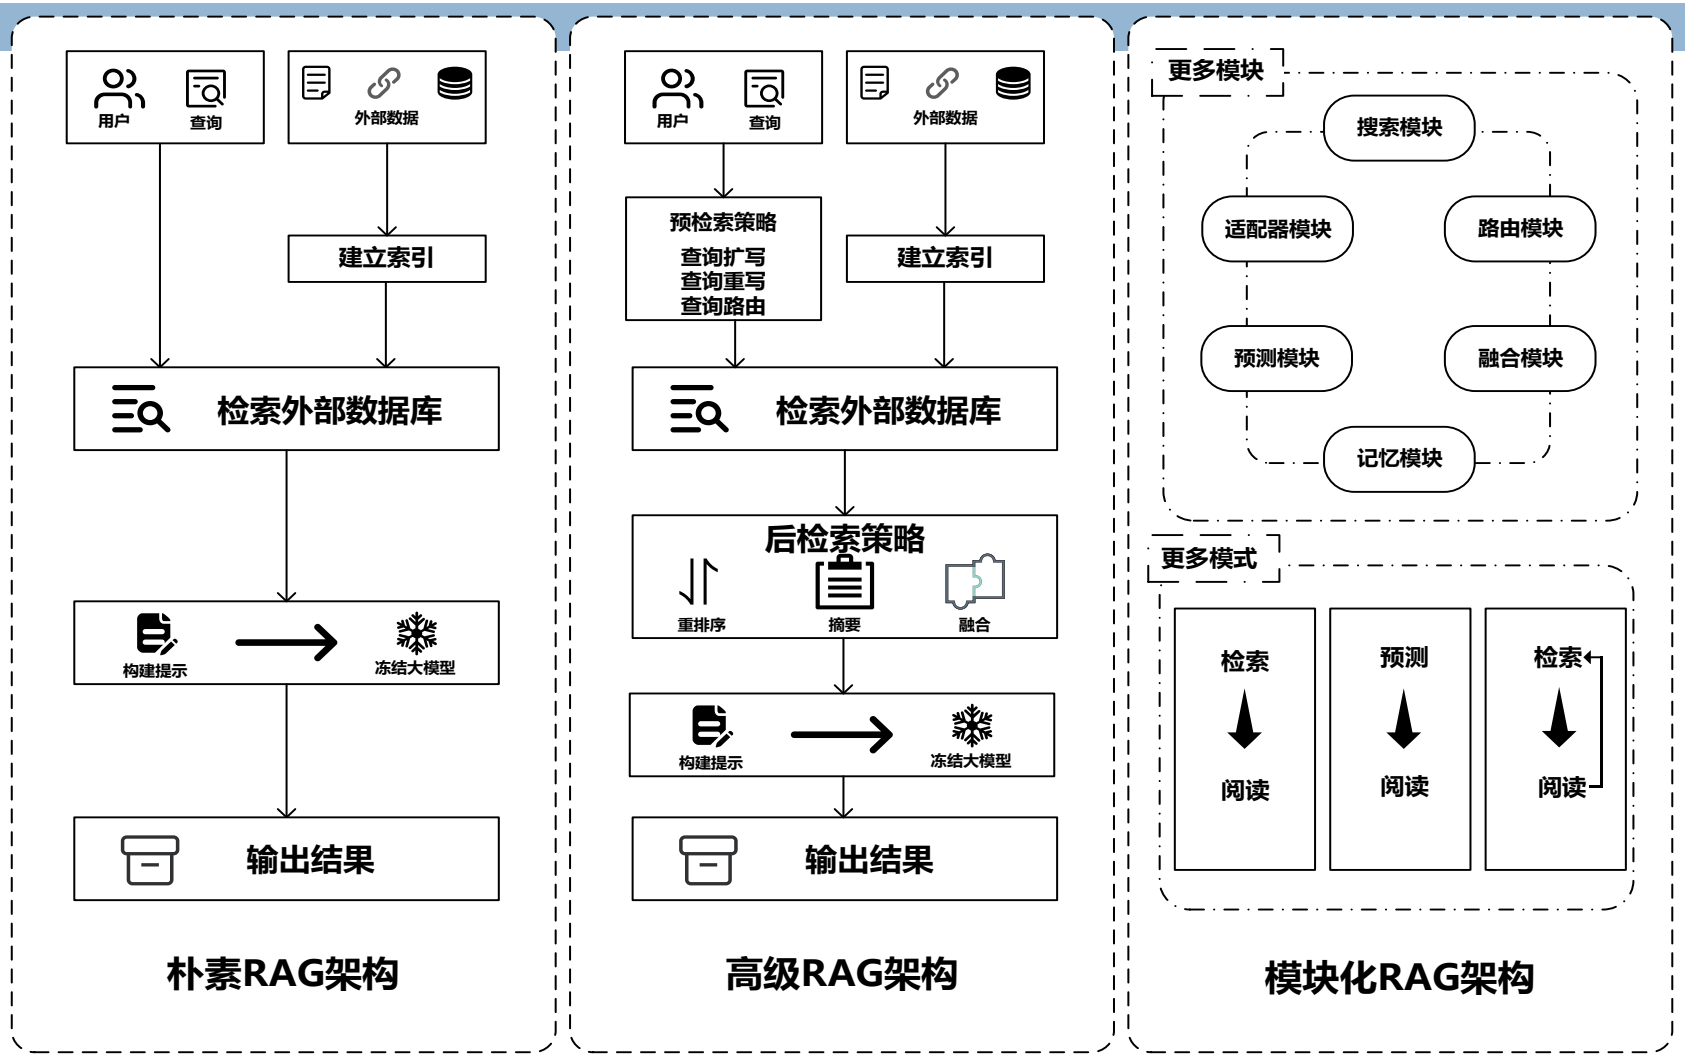
12.2 检索增强RAG

- 12.2 检索增强RAG
  - 12.2.1 检索增强概述
  - 12.2.2 RAG系统架构
  - 12.2.3 RAG核心技术
  - 12.2.4 进阶RAG技术
  - 12.2.5 多模态RAG
  - 12.2.6 Agentic RAG

12.2.2 RAG系统架构

RAG系统架构

- RAG技术发展阶段
  - 朴素RAG
  - 高级RAG
  - 模块化RAG

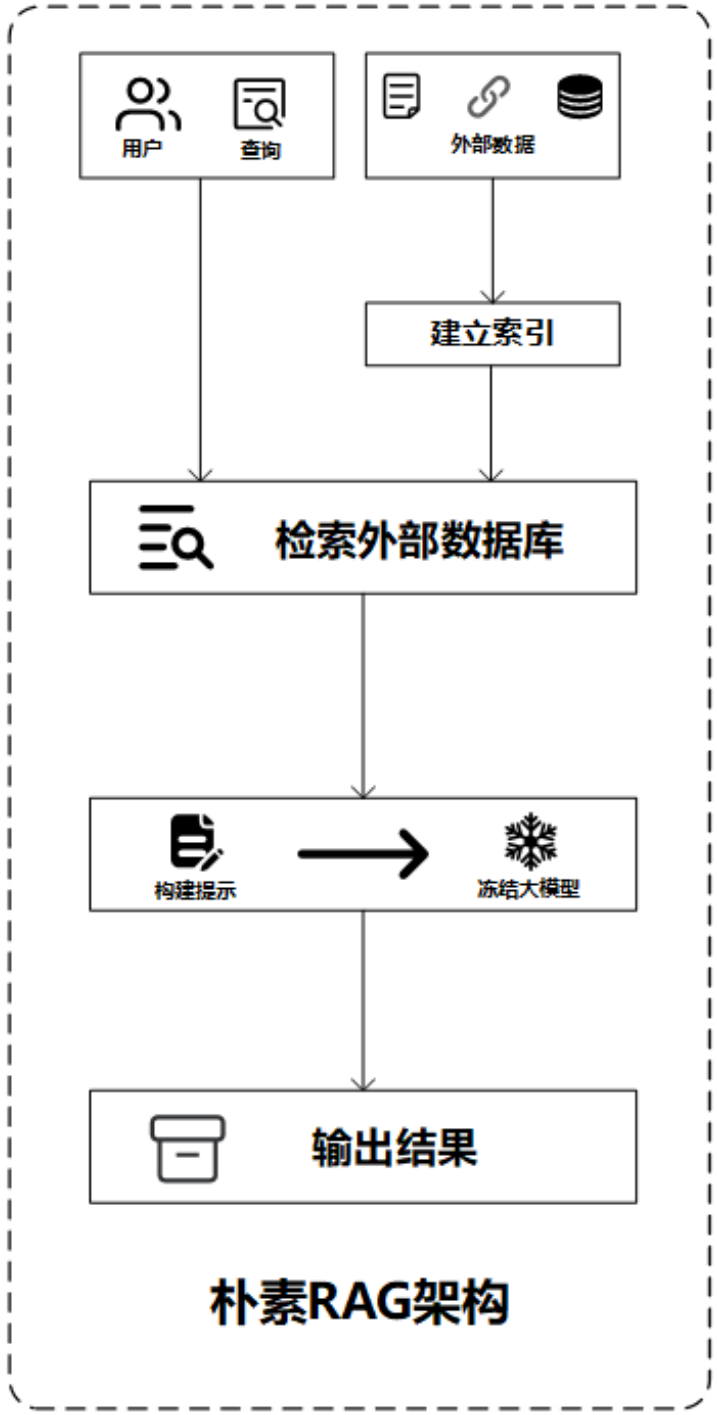


12.2.2 RAG系统架构

朴素RAG

- 朴素RAG架构代表着最早的方法论，遵循最基础的RAG流程，即建立索引 - 检索 - 生成，也称作“检索 - 读取”框架

- **（1）建立索引：**外部数据库中的数据往往以多种格式（PDF, doc, Markdown，HTML，Json等）存储，而RAG要求使用纯文本构建数据库。因此构建索引的第一步是对原始数据进行文本提取，将其转换为纯文本格式。为了适应语言模型的上下文限制，处理过的文本会被分割成更小的文本块。最后，使用嵌入模型将文本块编码为向量表示，存储在向量数据库中用于后续的检索。



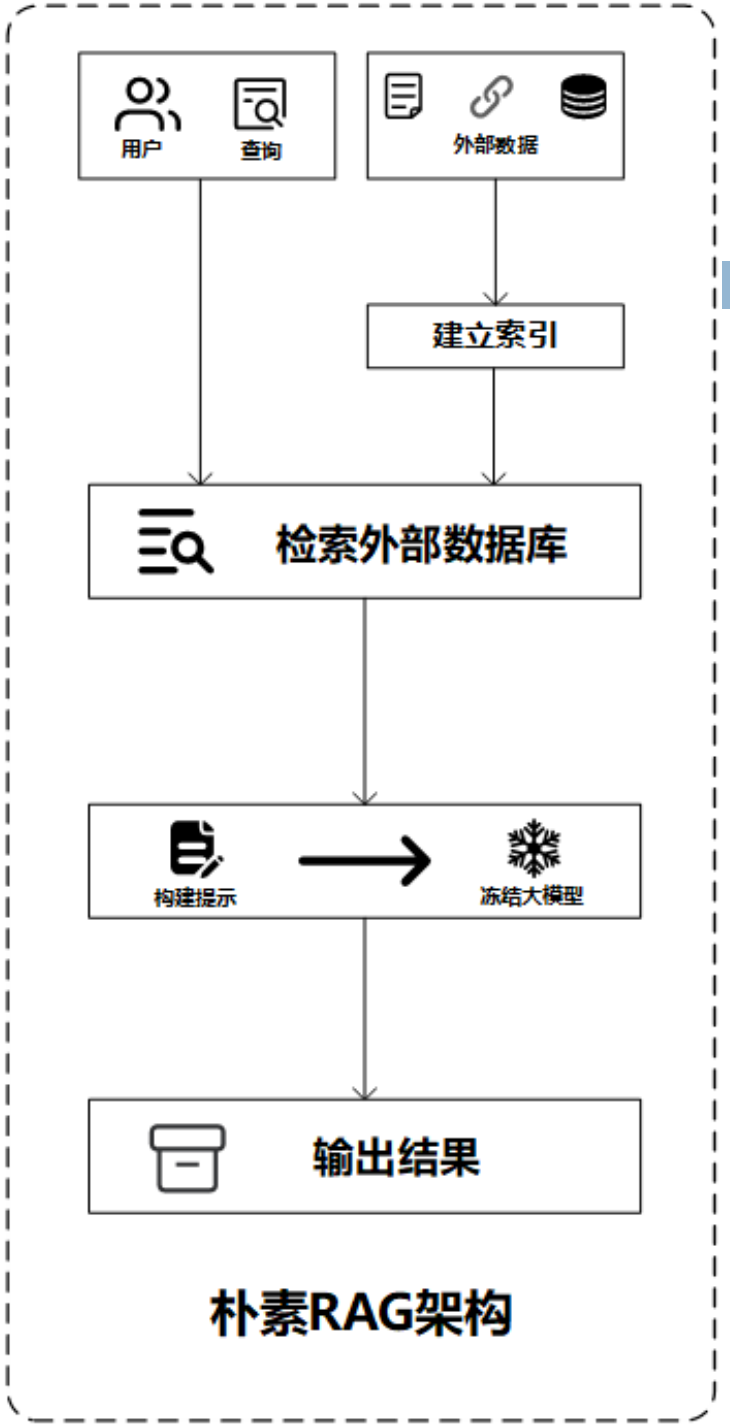
朴素RAG架构

12.2.2 RAG系统架构

朴素RAG

- **（2）检索：**在接收到用户的查询后，RAG系统使用与索引阶段相同的嵌入模型将查询转化为向量，随后计算查询向量与向量数据库中文本块的相似度得分，选择K个相似度最高的文本块用于后续构建提示。

- **（3）生成：**系统将用户的查询与检索出的文本块组合成提示，输入到大语言模型中，大语言模型凭借其内化的知识及检索出的参考文本，为用户生成答案

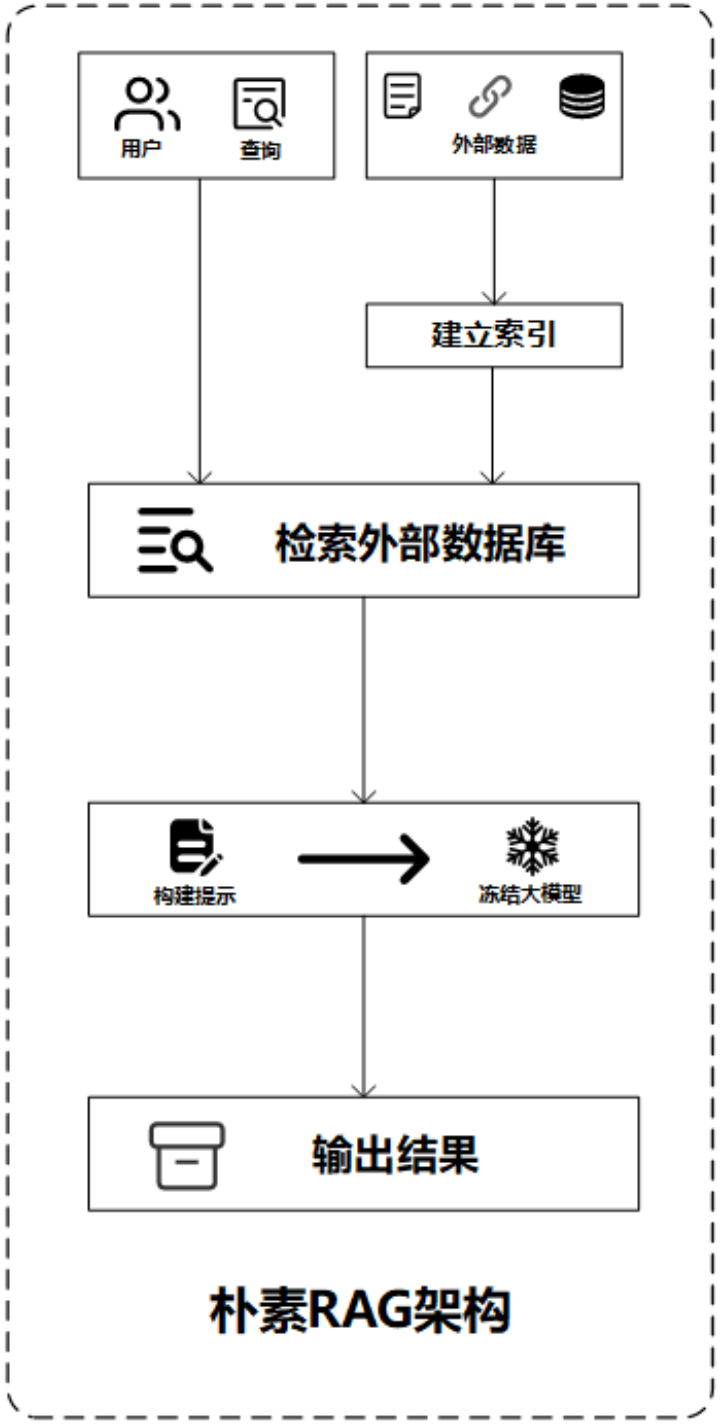


12.2.2 RAG系统架构

朴素RAG

可以看出，朴素RAG架构存在显著的局限性：

- 在检索阶段，朴素RAG系统的检索精度与召回率较低，往往会检索到不相关的文本块或遗漏掉关键文本块。
- 当从多个信息源检索时，系统可能会召回重复内容，造成冗余。
- 面对复杂问题时，单一原始查询往往无法检索到全面、充分的相关内容。
- 在生成阶段，模型仍然可能产生幻觉，即生成的答案和检索到的内容并不相符。

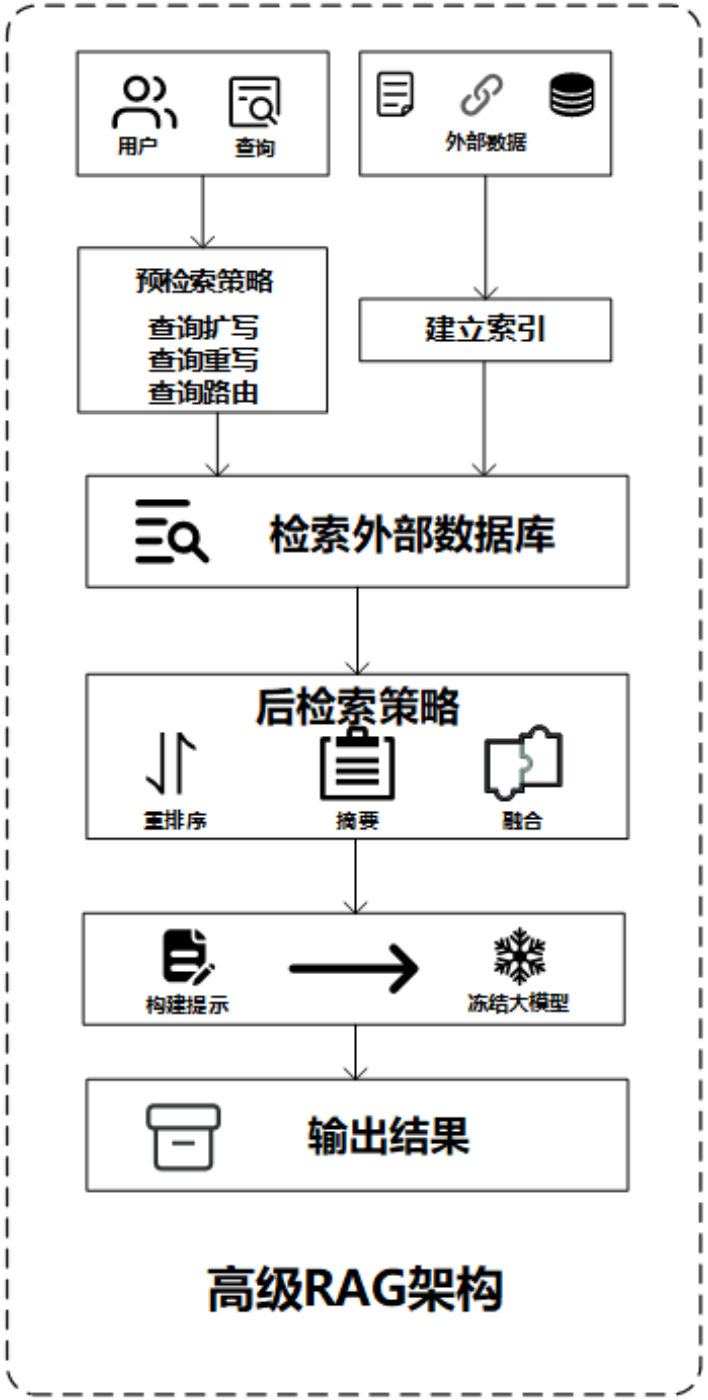


12.2.2 RAG系统架构

高级RAG

- 针对朴素RAG架构中存在的问题，高级RAG架构进行了改进，主要包括预检索与后检索策略。

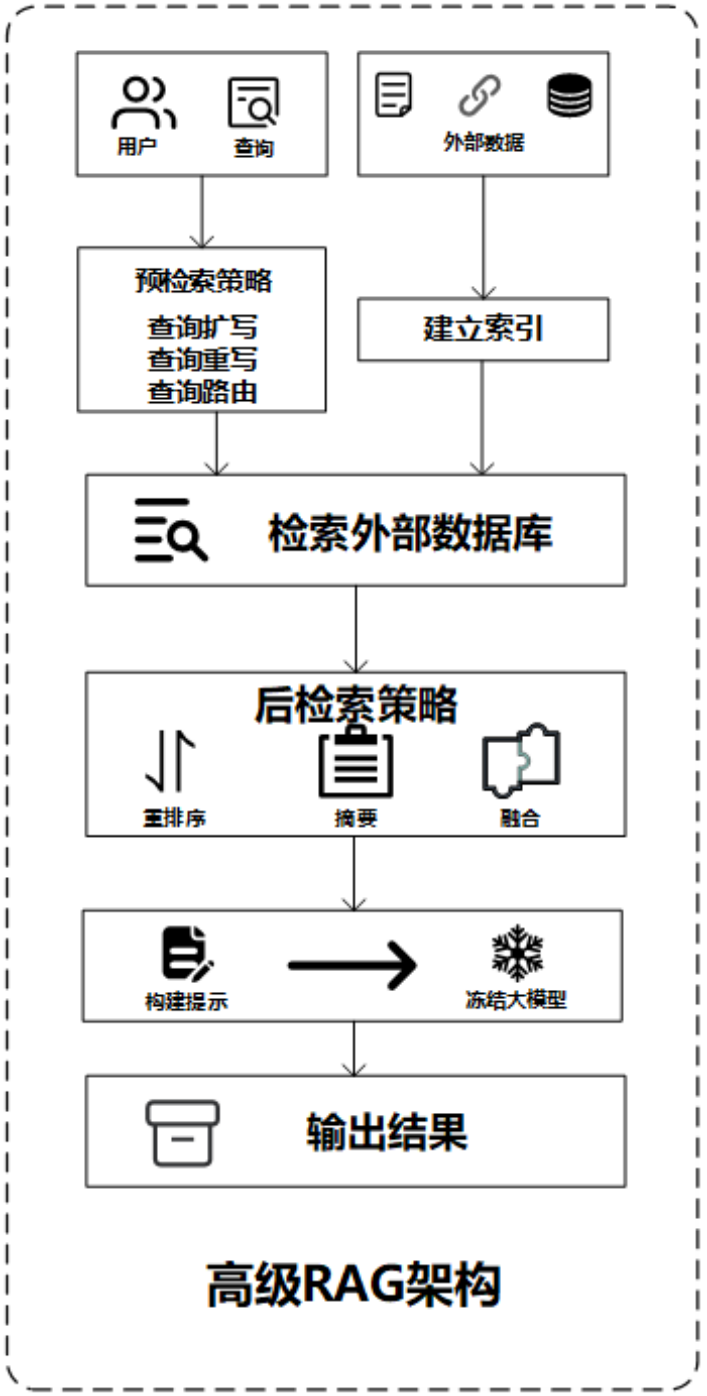
- **（1）预检索：**预检索阶段的策略主要为优化索引方法与扩展原始查询。
  - 在数据预处理阶段，高级RAG架构使用了元数据技术为原始数据增加了更多的标识信息。
  - 在构建索引阶段，新增了多种检索粒度使得检索更加精准灵活，引入了层次索引结构（如树状索引）来提高检索效率。
  - 高级RAG架构引入了原始查询优化方法，使用查询转换、查询扩写等技术来丰富原始查询的内容。



12.2.2 RAG系统架构

高级RAG

- 针对朴素RAG架构中存在的问题，高级RAG架构进行了改进，主要包括预检索与后检索策略。
- **（2）后检索：**朴素RAG可能会检索到不相关内容从而影响系统性能。
  - 重排序策略，将检索到的文本块进行一次重新排序与筛选。
  - 上下文压缩方法，通过摘要或者压缩手段有效缩减最终提示的上下文长度。

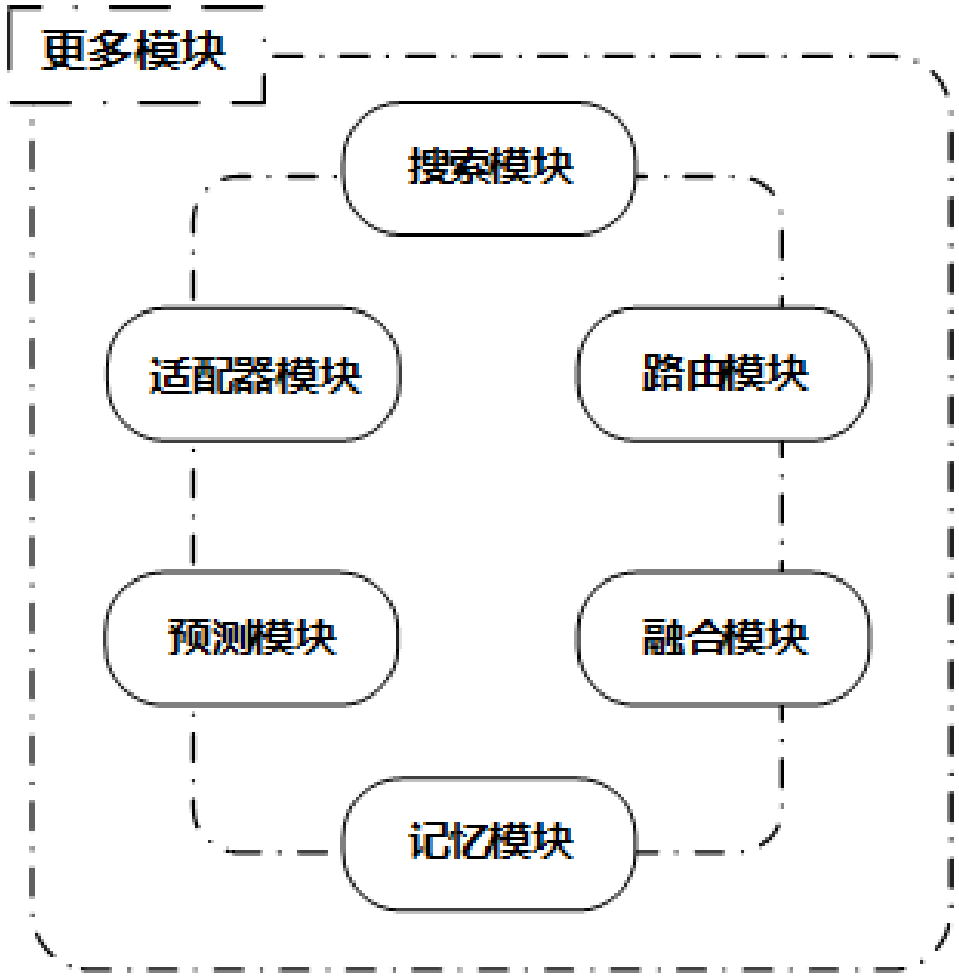


12.2.2 RAG系统架构

模块化RAG

- 模块化RAG不再拘泥于原本的RAG架构，引入了更多的功能模块与新的运行模式，并允许不同模块之间替换以及排列组合，这种高度的灵活性，使架构能够根据不同任务的需求，动态调整模块间的交互流程，从而显著增强其适应性。

- 研究者们为模块化RAG架构设计了诸多功能模块，下面选择具有代表性的功能模块简要介绍。



12.2.2 RAG系统架构

模块化RAG

- 搜索模块：不同于原本的检索架构，模块化RAG中的搜索模块针对不同的领域，使用大语言模型生成相应的代码或查询语言（SQL等），直接进入各类搜索源（如搜索引擎、维基百科、知识图谱等）进行精确检索。
- 路由模块：在RAG系统中，往往会涉及多个不同的信息源，路由模块则负责根据查询，自动规划最优的检索路径和策略，以确保系统能够高效、准确地获取相关信息。
- 融合模块：融合模块结合了预检索策略的思路，使用大语言模型为原始查询生成多个不同的查询并进行检索，最后融合这些检索结果，形成更深层次、更全面的参考信息。
- 记忆模块：记忆模块创建了一个动态的、无边界的记忆池，用以存储原始问题以及检索结果，从而提供与当前输入相似的记忆片段。

12.2.2 RAG系统架构

模块化RAG

- 预测模块：预测模块直接调用大语言模型生成所需要的上下文信息，这种方式可以一定程度地减少冗余与不相关内容。
- 任务适配器模块：任务适配器模块可以根据不同的下游任务，定制专属的检索器。例如，UPRISE提出了一种轻量级检索器，能够自动从预先构建的提示库中，筛选出对当前查询帮助最大的示例，从而有效增强上下文的质量。
- 模块化RAG支持更多的运行模式，以上文所提到的新模块为例，“Generate-Then-Read”方法使用预测模块替换掉了原本的检索器；Iter-RetGen在原架构的基础上增添了迭代流程（使用记忆模块记录迭代信息）来增强模型的能力。

12.2 检索增强RAG

- 12.2 检索增强RAG
  - 12.2.1 检索增强概述
  - 12.2.2 RAG系统架构
  - 12.2.3 RAG核心技术
  - 12.2.4 进阶RAG技术
  - 12.2.5 多模态RAG
  - 12.2.6 Agentic RAG

12.2.3 RAG核心技术：R

XX公司案例：管理规定如何供模型检索？

- “XX公司几点下班？”可以从员工手册中找到答案。
  如果询问请假、出差和报销等问题，则需要查阅不同的管理规定。

公司资料	员工可能提出的问题
员工手册	公司几点下班？
考勤与请假规定	请假需要提前申请吗？
差旅报销规定	出差住宿可以报销多少？
制度调整通知	住宿报销标准是否有更新？

- 这些资料需要经过整理、切分和索引，才能根据员工的问题检索相关内容。

[5] 袁乐, 刘绍华, 王禹, 等. 大语言模型检索增强生成优化技术研究综述[J]. 计算机学报, 2026, 49(2): 383-422.
DOI: 10.11897/SP.J.1016.2026.00383. XX公司为虚构教学设定；案例与公司标志为自制，理论参考[5]。

12.2.3 RAG核心技术

RAG索引技术—数据来源

数据来源：RAG技术中，数据来源广泛且多样，包括但不限于以下几个方面

- 1. 在线文档和数据库，如维基百科、专业期刊、书籍和学术数据库等。
- 2. 实时网络搜索，主要包括搜索引擎、社交媒体和新闻网站等。
- 3. 企业内部数据库，包括企业知识库，如企业政策、流程和产品信息等。
- 4. 特定领域的数据库，如医疗数据库，PubMed、Medline等，包含大量医学文献和病例数据。
- 5. 其他数据源，通过调用各种API接口，获取不同数据源的信息，如天气数据和地理位置信息等。



12.2.3 RAG核心技术

RAG索引技术—检索粒度

- 索引粒度，也称为检索粒度，指检索单元的大小
  - 粗粒度的文本单元可以为问题提供更多的相关信息，但也会包含冗余与不相关内容，分散下游任务中检索模型与大语言模型的注意力；
  - 细粒度检索会增加检索系统的负担，并且无法保证语义完整性与知识覆盖度。
- 在推理过程中选择适当的检索粒度，能够有效提高检索器的性能和下游任务的效果。

12.2.3 RAG核心技术

RAG索引技术—索引构建

- 索引构建：将文本切分并转换为嵌入形式存储在向量数据库中
  - 索引构建的质量很大程度会影响后续检索模块的性能
- 分块策略：最常见的方法是根据固定数量的词元（如128，256，512）将文本拆分成块，但这种方法切分的文本块可能会导致句子被截断成不同的块。有研究者通过设计滑动窗口技术，通过合并多个检索过程中的全局信息实现分层检索，以此来解决上述问题。
- 索引优化：为文档建立层次结构是优化检索效率的一个有效方法。比如，为文档设计父子结构，并将文本摘要链接到父节点上。这些方法都可以显著地提高检索效率。
- 编码方法
  - 稀疏编码：One-Hot编码、词袋模型、TF-IDF编码和BM25；存在语义鸿沟问题（无法计算词间相似度）和维度爆炸问题（稀疏向量维度通常与词典等长）
  - 稠密编码方法：稠密向量表示

12.2.3 RAG核心技术：QforR

XX公司案例：员工的问题怎样检索?

- 公司员工问：“出差住宿费怎么报销？”
- 员工接着问第二个问题：“那发票抬头填什么？还要交哪些材料？”
- 如果直接检索后面一句，“发票”则可能对应住宿、交通或采购等业务。
- 需要结合前文，补全当前咨询的业务背景。

结合对话形成检索查询

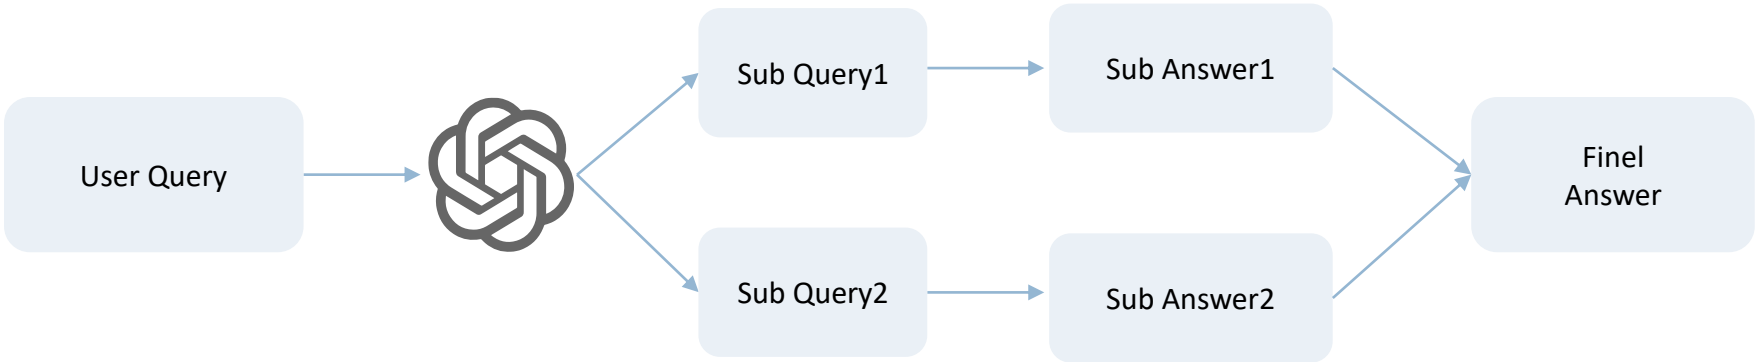
- 差旅住宿报销的发票抬头要求
- 差旅住宿报销所需的申请材料
- 补全查询中的业务背景，有助于检索符合当前需求的规定。

[5] 袁乐, 刘绍华, 王禹, 等. 大语言模型检索增强生成优化技术研究综述[J]. 计算机学报, 2026, 49(2): 383-422.
DOI: 10.11897/SP.J.1016.2026.00383. 虚构教学案例；据[5]查询优化相关内容设计，非论文实验。

12.2.3 RAG核心技术

RAG检索技术—查询优化

- 查询优化：查询扩写、查询转换、查询路由等
  - 朴素RAG 面临的主要挑战之一是它只使用用户的原始查询进行检索，然而用户提出一个精确而清晰的问题是很困难的，基于这种不精准提问的查询往往检索效果不佳。
- 查询扩写旨在将单个查询扩展为多个相关查询的过程。典型的方法有多查询策略（multi-query）与子查询策略（sub-query）。多查询策略是指使用大语言模型直接将原始查询扩写为多个语义相关的查询。子查询策略指的是将原始复杂问题分解为一系列子问题。

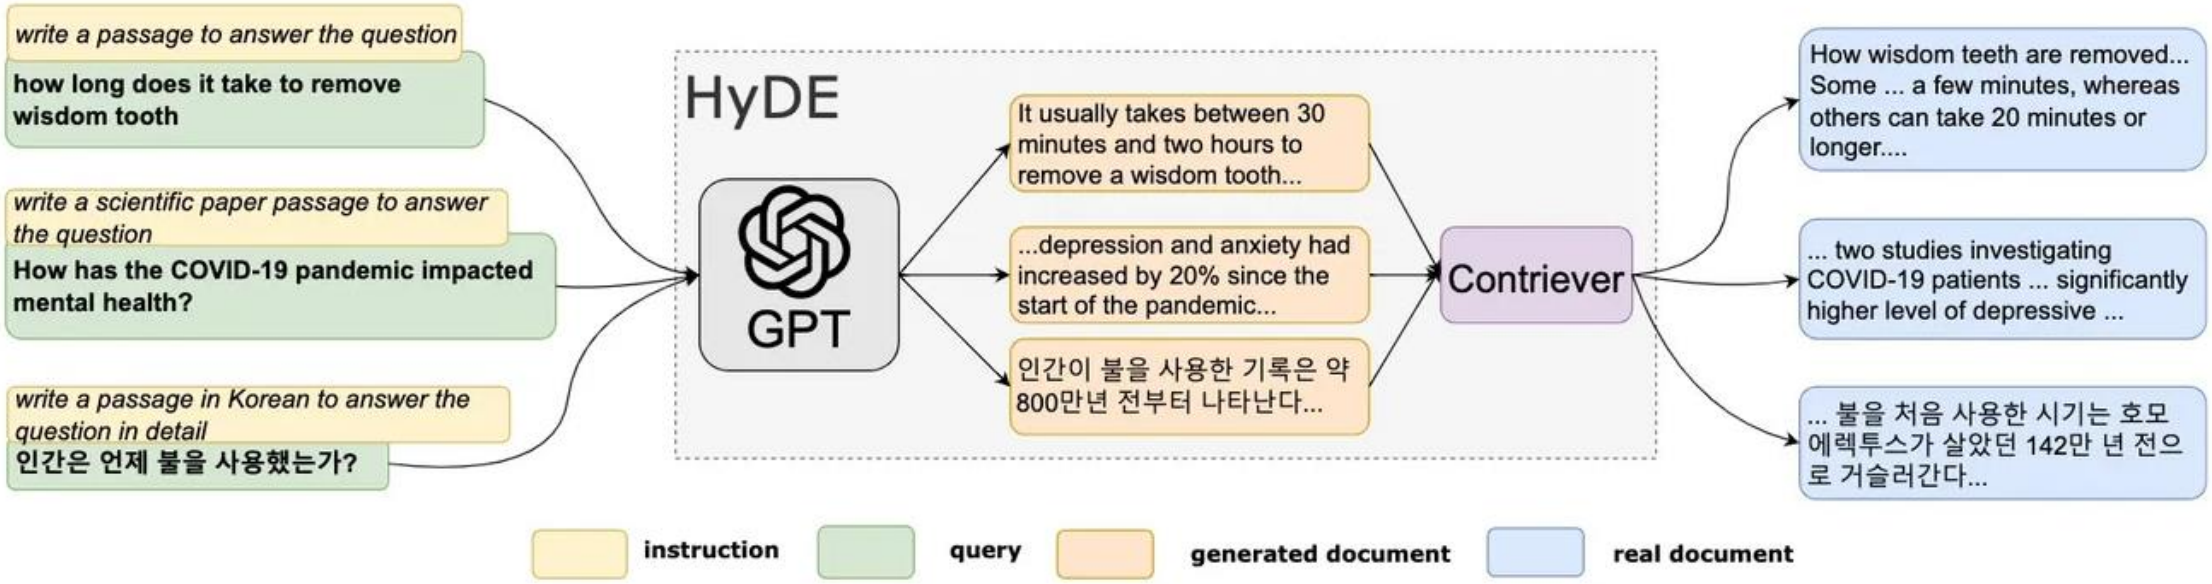


子查询策略示意图

12.2.3 RAG核心技术

RAG检索技术—查询优化

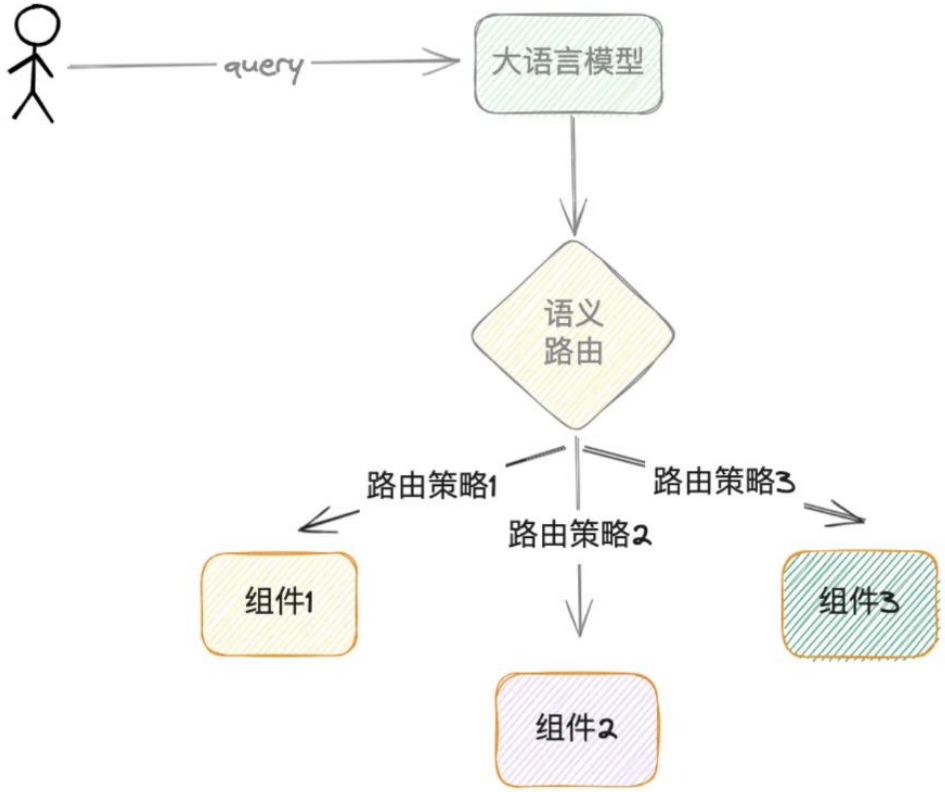
- 查询转换的核心概念是使用某些方法将原始查询转换后，使用生成的新查询进行检索。与查询扩写类似，可以通过提示让大语言模型直接将原始查询转写为更加精确、适配的查询。



12.2.3 RAG核心技术

RAG检索技术—查询优化

- 查询路由旨在将不同的查询导向最相关的索引区域，即前文提到的路由模块，其中代表性的工作为元数据路由器。该方法首先从原始数据中提取关键字，然后根据关键字来过滤掉不相关的块，最后在相关数据块中进行检索。



12.2.3 RAG核心技术

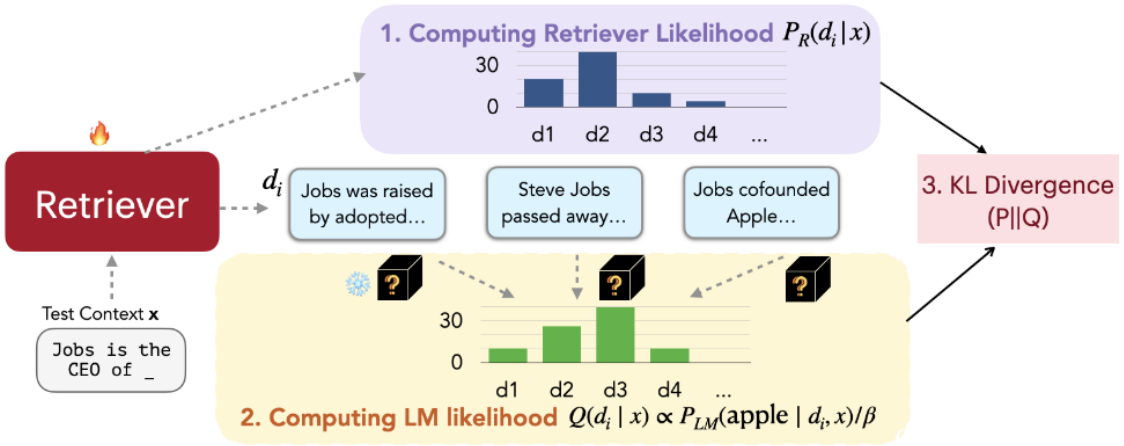
RAG检索技术—检索方法

- 实际应用场景中，由于向量数据规模庞大且复杂，寻找绝对的最优解往往面临极高的计算成本，有时甚至是不可行的。此外，大模型本质上并不是完全确定性的系统，这些模型在搜索时追求的是语义上的相似性。例如，推荐系统中，用户不太可能察觉到或关心是否每个推荐的项目都是绝对的最佳匹配；他们更关心推荐是否总体上与他们的兴趣相符。因此，我们的目标并不是检索与查询向量完全相同的数据块，而是要找到“足够接近”或“相似”的数据块，这便是最近似近邻搜索（Approximate Nearest Neighbor Search，ANN）。
- 为了实现这一目标，各种ANN方法，如基于树的方法KD-tree和局部敏感度哈希算法（Locality Sensitive Hashing，LSH）等，通过构建高维向量的索引结构，牺牲一定的精度来提高检索效率。这种权衡不仅能满足实际应用需求，也为检索优化带来巨大的潜力。

12.2.3 RAG核心技术

RAG检索技术—检索器微调

- 在某些专业领域的任务（如医疗、法律）中，文本的语义分布与检索器（嵌入模型）和生成器（后续LLM）的训练语料差距较大，为了弥补差距，可以使用该领域的数据微调嵌入模型，以注入必要的领域知识，增强其语义表示能力。
- 除补充领域知识外，微调嵌入模型的另一个目的是使检索器与生成器对齐。LSR（LM-supervised Retriever）是一类代表性的方法，该方法使用RAG系统中最后大语言模型生成的结果作为监督信号对检索器进行微调。



LSR示意图，使用大模型生成作为监督信号来对齐检索器

12.2.3 RAG核心技术：ReRanking

XX公司案例：检索结果如何组织?

XX公司

- 员工提问：“住宿报销需要提交哪些材料？”

检索召回的内容	与当前问题的关系
住宿报销材料条款	直接相关
内部问答中的同一份材料清单	内容重复
交通费报销条款	与住宿材料无关
住宿预订及酒店选择说明	关联较弱

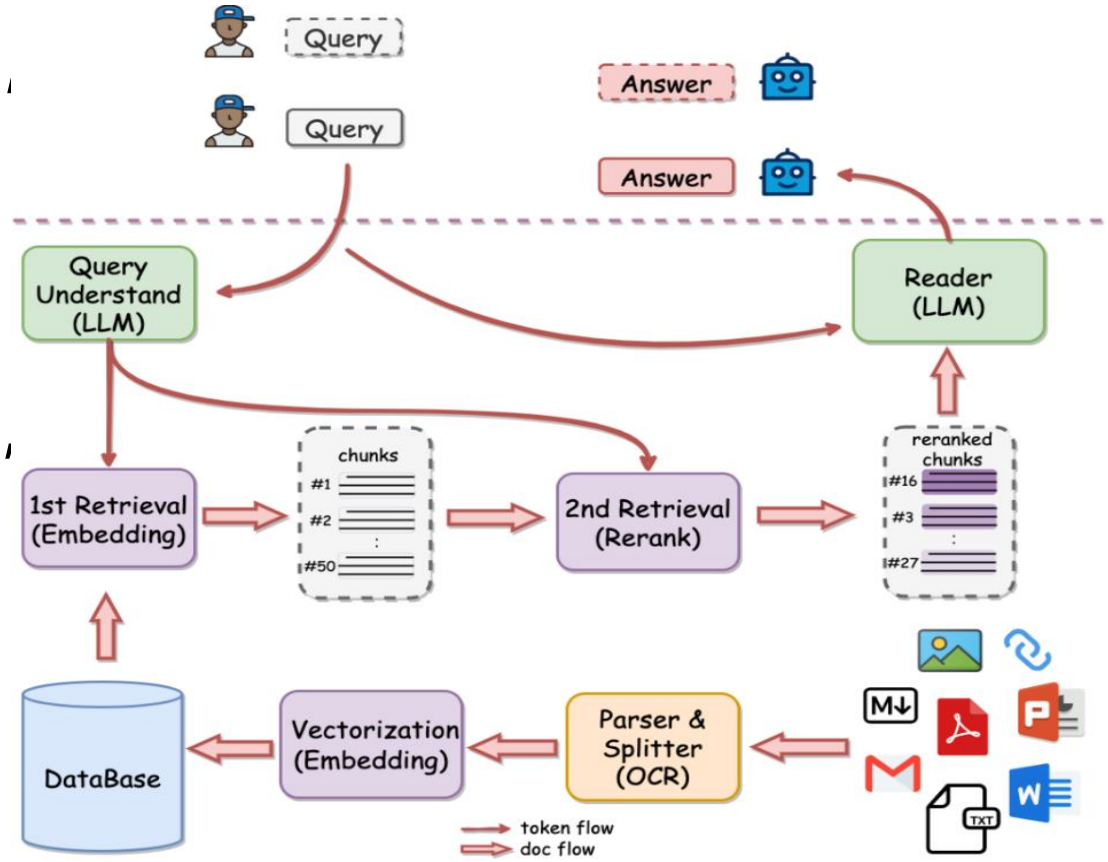
- 保留材料清单及必要条件，合并重复说明，去除无关内容。
- 检索结果需要进一步筛选与组织，使提供给模型的上下文集中于当前问题。

[5] 袁乐, 刘绍华, 王禹, 等. 大语言模型检索增强生成优化技术研究综述[J]. 计算机学报, 2026, 49(2): 383-422.
DOI: 10.11897/SP.J.1016.2026.00383. 虚构教学案例；据[5]重排序与上下文压缩相关内容设计。

12.2.3 RAG核心技术

RAG生成技术—提示构建

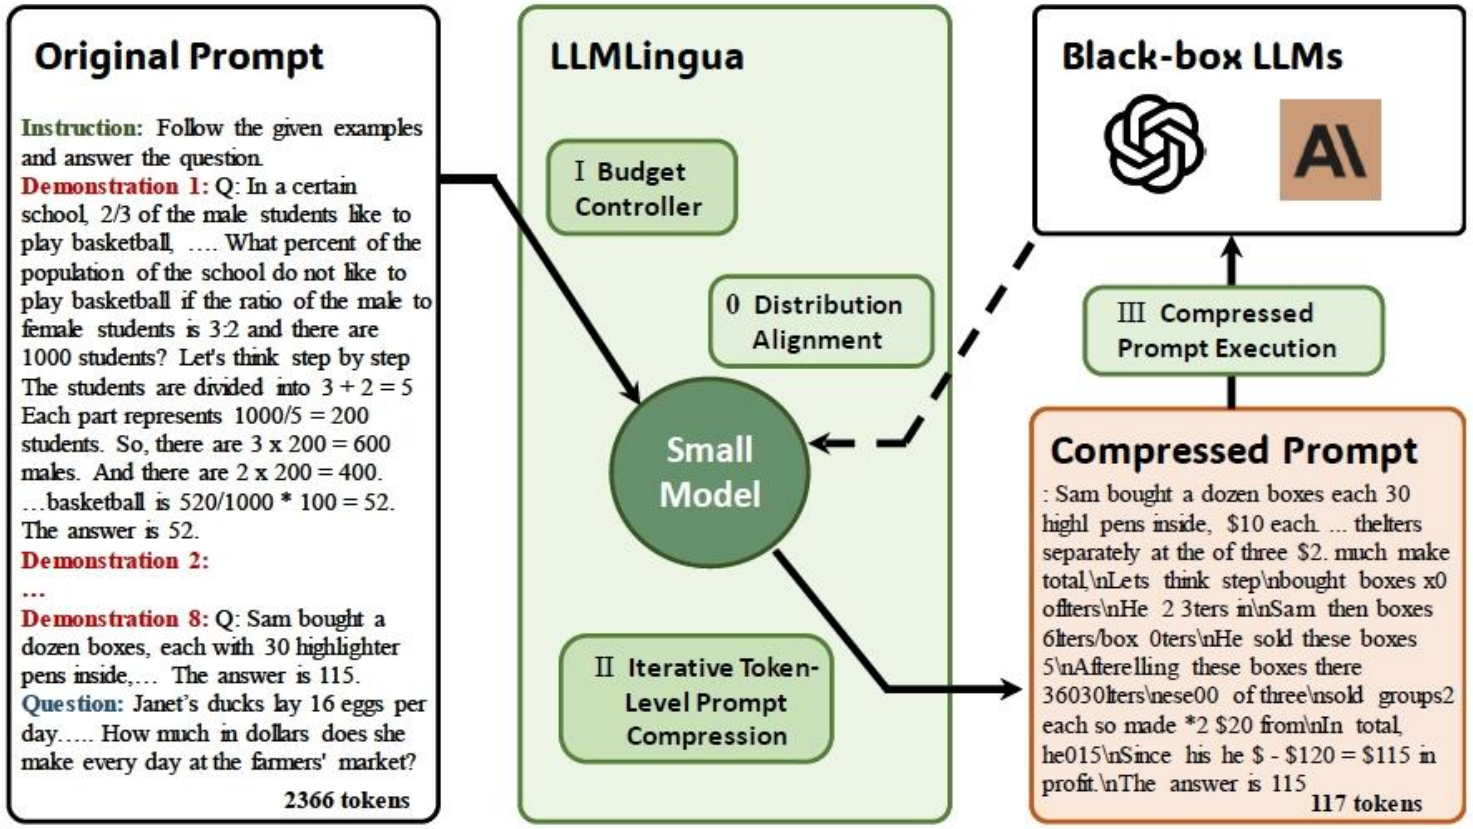
- 检索召回的文本可能存在较多的冗余与不相关内容，而过长的上下文会导致模型忽略其中的重要内容。因此，在构建最终的提示之前，通常需要对召回的文本进行重排序、上下文压缩等进一步处理。
- 重排序策略旨在将召回的文本重新排序，以进一步过滤掉文本块中的冗余与不相关信息。与人类一样，大语言模型往往只关注文本的开头和结尾，而忽略中间部分。因此，重排序模块也会将重要的文本块放置到最终提示的开头或结尾。



12.2.3 RAG核心技术

RAG生成技术—提示构建

- 过多的上下文会导致冗余与噪声问题，提取出上下文关键信息可以进一步强化RAG模型的性能。LLMLingua就是一个典型的提示压缩方法。该方法首先将提示中给定的示例进行排序，然后按比例删去不重要的示例，其次，采用类似的方法，删去单个示例中不重要的词元来达到压缩的效果。

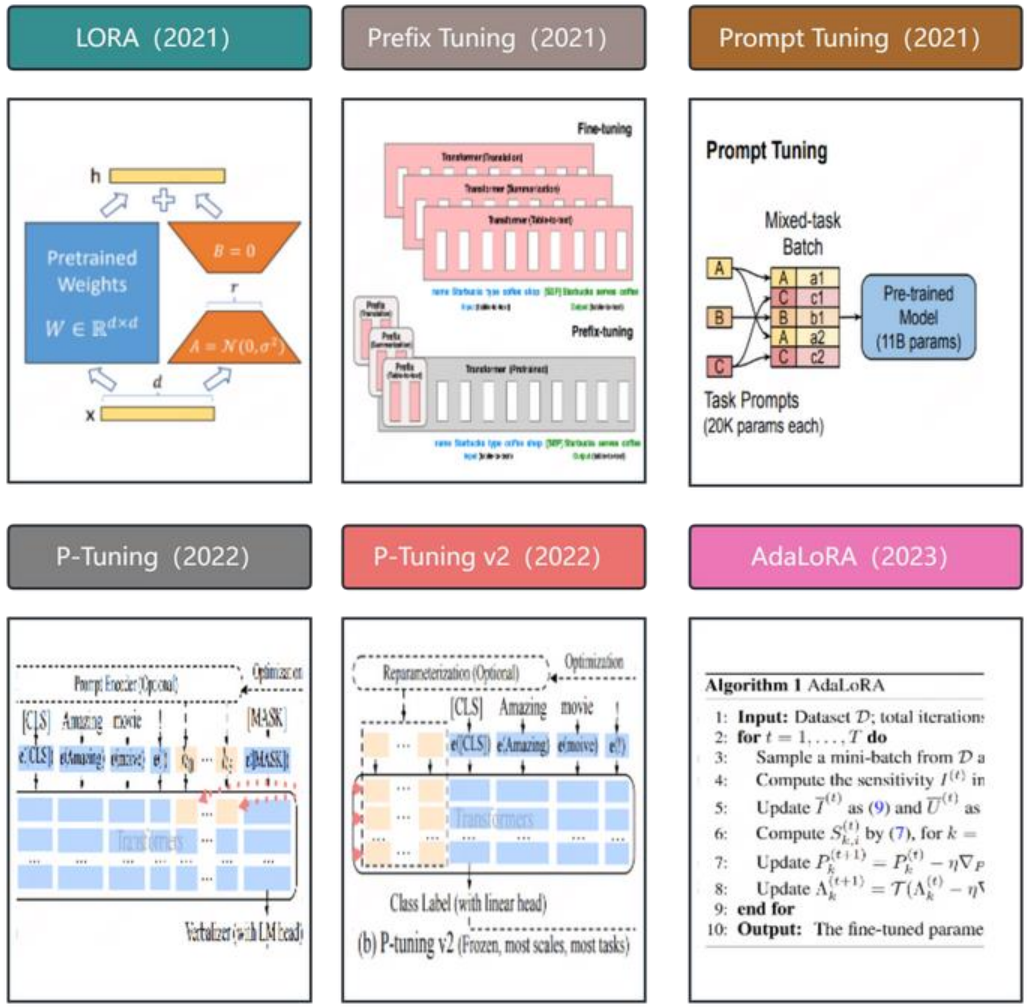


提示压缩方法LLMLingua示意图

12.2.3 RAG核心技术

RAG生成技术—生成器微调

- 当面对新的专业领域时，大语言模型固有的知识往往无法很好解决问题，可以通过微调来为生成器注入相应的领域知识。微调的另一个作用是可以调整模型的输入与输出格式，它可以使大语言模型适应特定的数据格式，并按照指令生成特定样式的响应。



12.2 检索增强RAG

- 12.2 检索增强RAG
  - 12.2.1 检索增强概述
  - 12.2.2 RAG系统架构
  - 12.2.3 RAG核心技术
  - 12.2.4 进阶RAG技术
  - 12.2.5 多模态RAG
  - 12.2.6 Agentic RAG

12.2.4 进阶RAG技术

RAG进阶技术—增加元数据

- 在向量数据库中存储向量数据时，有些数据库支持将向量与元数据（即非向量化的数据）一同存储。为向量添加元数据标注是一种提高检索效率的有效策略，它在处理搜索结果时发挥着重要作用。



12.2.4 进阶RAG技术

RAG进阶技术—增加元数据

- 例如，日期就是一种常见的元数据标签，它能帮助系统按时间顺序筛选数据。设想一下，如果开发一款电子邮件查询的应用程序，日期越近的电子邮件可能与用户的查询越相关。然而，从嵌入（即文本的向量表示）的角度来看，无法直接判断这些邮件与用户查询的相似度。通过将电子邮件的日期作为元数据附加到其嵌入中，可以在检索过程中优先考虑最近日期的邮件，从而提高搜索结果的相关性。

- 此外，还可以添加诸如章节或小节的引用、文本的关键信息、小节标题或关键词等作为元数据。这些元数据不仅有助于改进知识检索的准确性，还能为最终用户提供更加丰富和精确的搜索体验。

12.2.4 进阶RAG技术

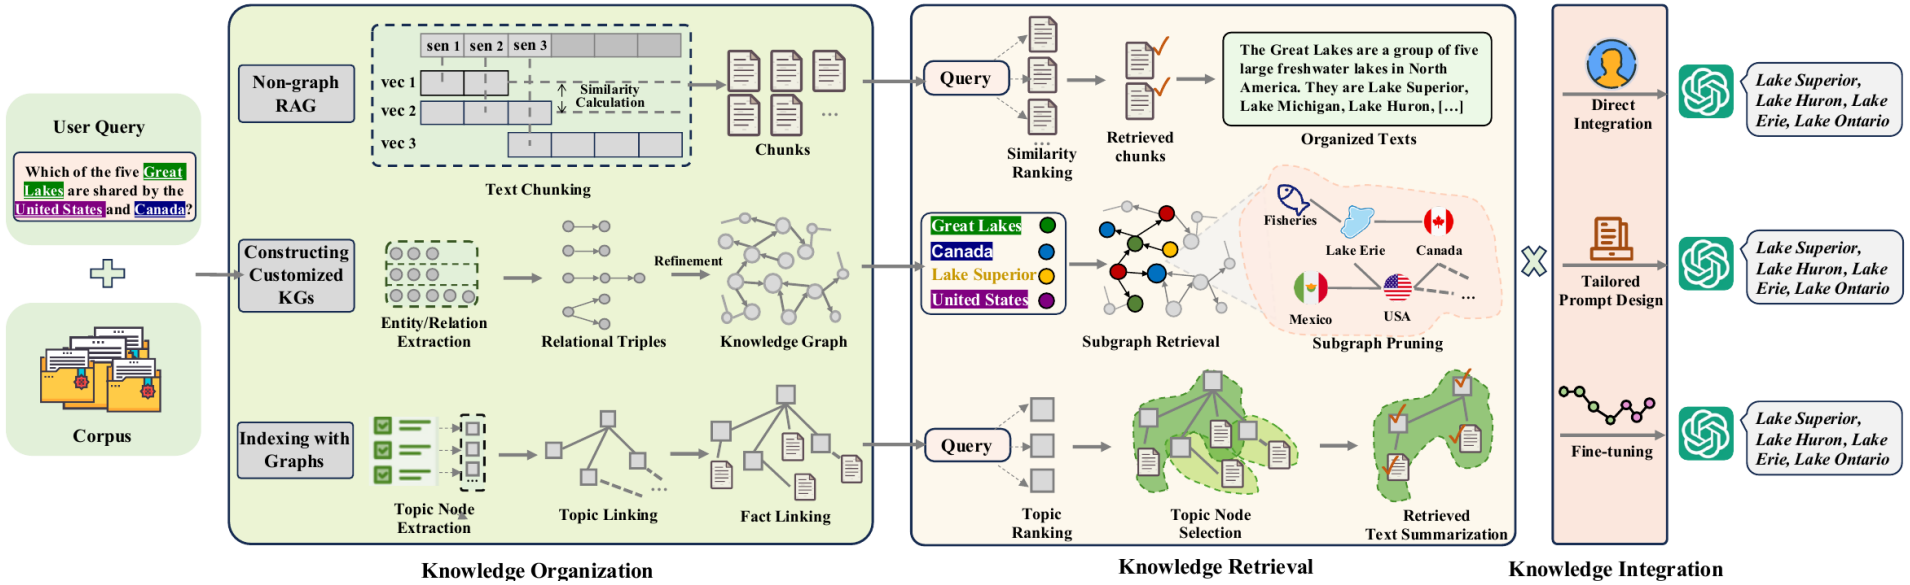
RAG进阶技术—混合检索

- 稀疏和稠密嵌入方法可以捕获不同的文本特征，利用其互补的相关性信息，可以进一步优化检索结果。例如，稀疏检索模型可以为稠密检索模型提供初步的检索结果，大幅缩小搜索范围，提高检索性能。同时，有研究表明，稀疏检索模型可以增强稠密检索模型的零样本（zero-shot）检索能力，并协助稠密检索器处理包含稀有实体的查询。

12.2.4 进阶RAG技术

RAG进阶技术—图结构检索

- 知识组织：将资料中的实体及其关系组织为图，显式表示分散信息之间的联系。
- 关联检索：依据问题定位相关实体，获取关联节点、关系路径及相关资料，为生成模型提供回答依据。



[6] ZHANG Q, CHEN S, BEI Y, et al. A Survey of Graph Retrieval-Augmented Generation for Customized Large Language Models[EB/OL]. (2025-09-29)[2026-10-20]. https://arxiv.org/abs/2501.13958v3. 图引自[6]图2（裁剪）。

12.2.4 进阶RAG技术

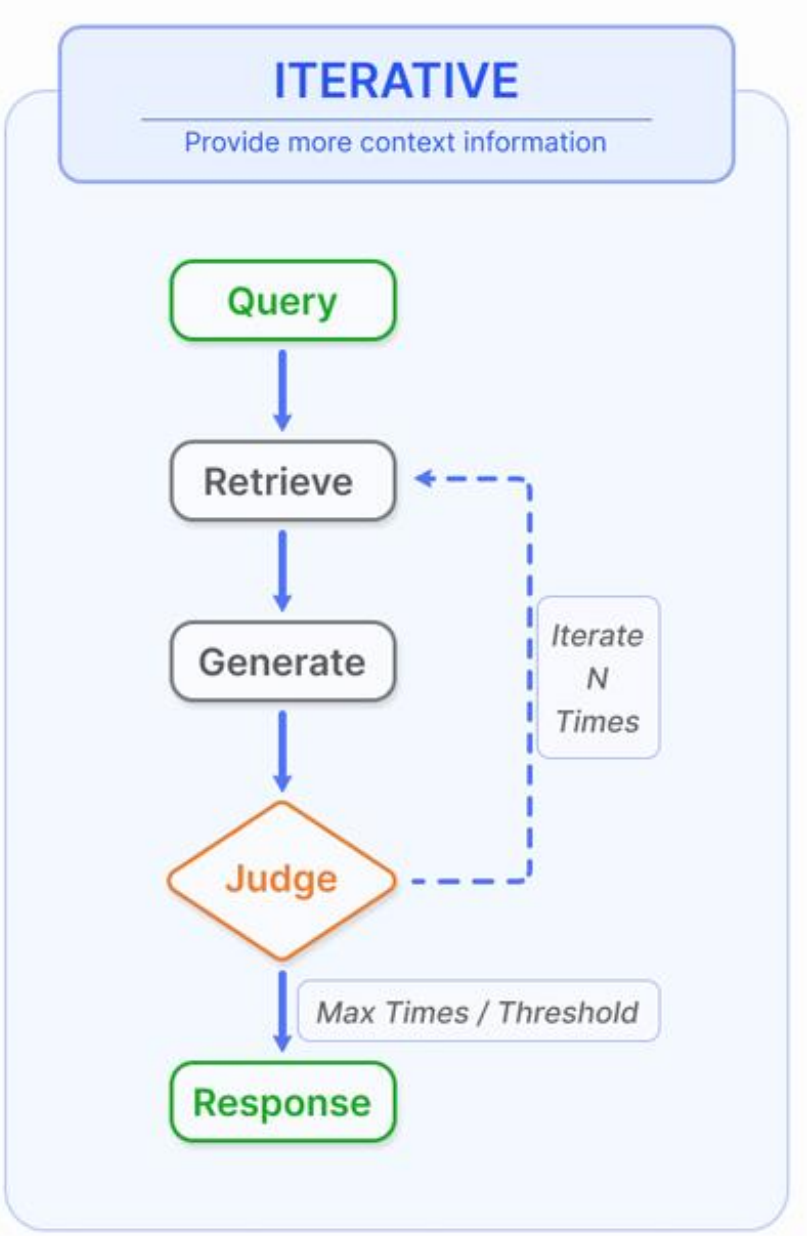
RAG进阶技术—RAG增强

- 在常规的RAG系统中，模型通常只执行一次流程（检索 - 生成）便完成任务。然而，对于某些复杂任务来说，一次流程往往难以生成符合要求的结果。针对此问题，研究者们提出了迭代、递归与自适应三种增强策略。

12.2.4 进阶RAG技术

RAG进阶技术—RAG增强

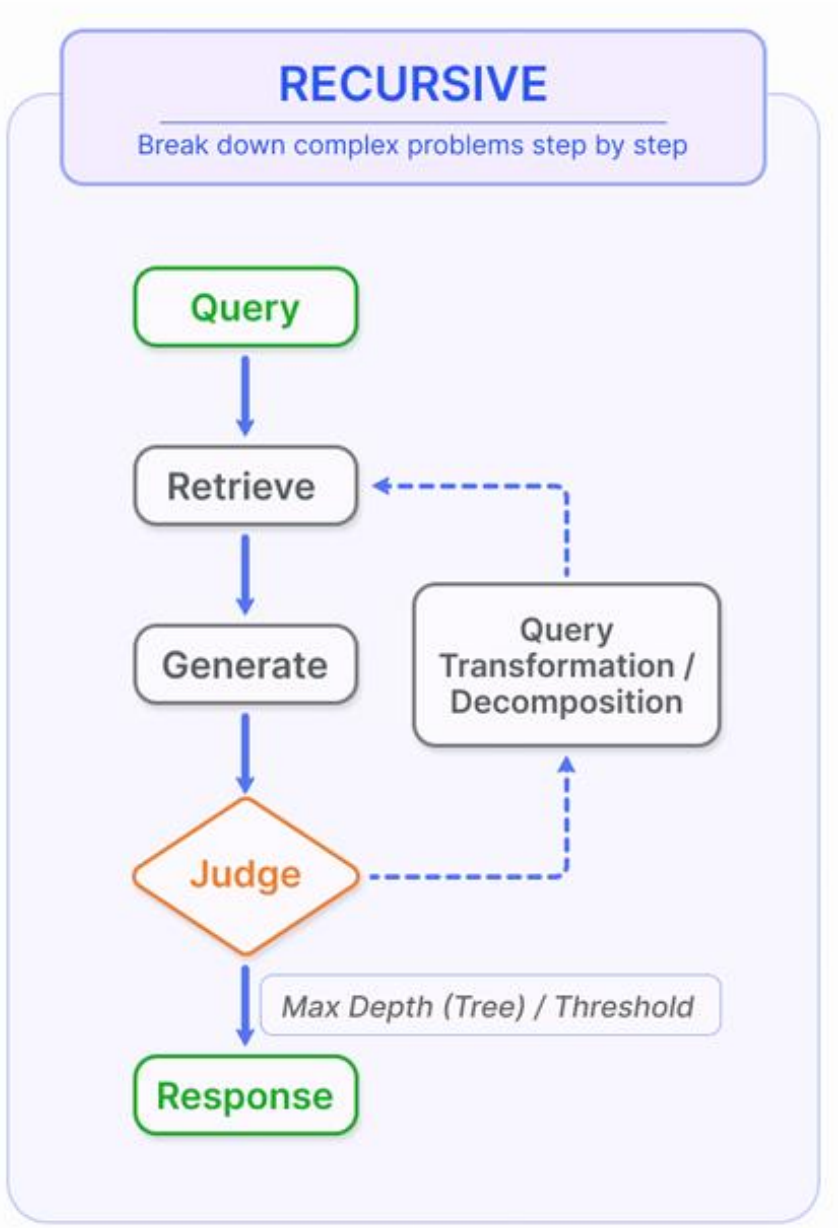
- 迭代式RAG是基于初始查询和迄今为止生成的文本反复搜索知识库的过程。通过不断累积检索到的上下文，为后续的生成器提供更丰富的参考信息，但也会受到语义不连续性与累积不相关信息的负面影响。



12.2.4 进阶RAG技术

RAG进阶技术—RAG增强

- 递归式RAG通过不断分解或重写初始查询，增强搜索的深度与相关性。在不断递归过程中，检索器可以获得更加深入、细化的知识，为后续的生成提供参考。

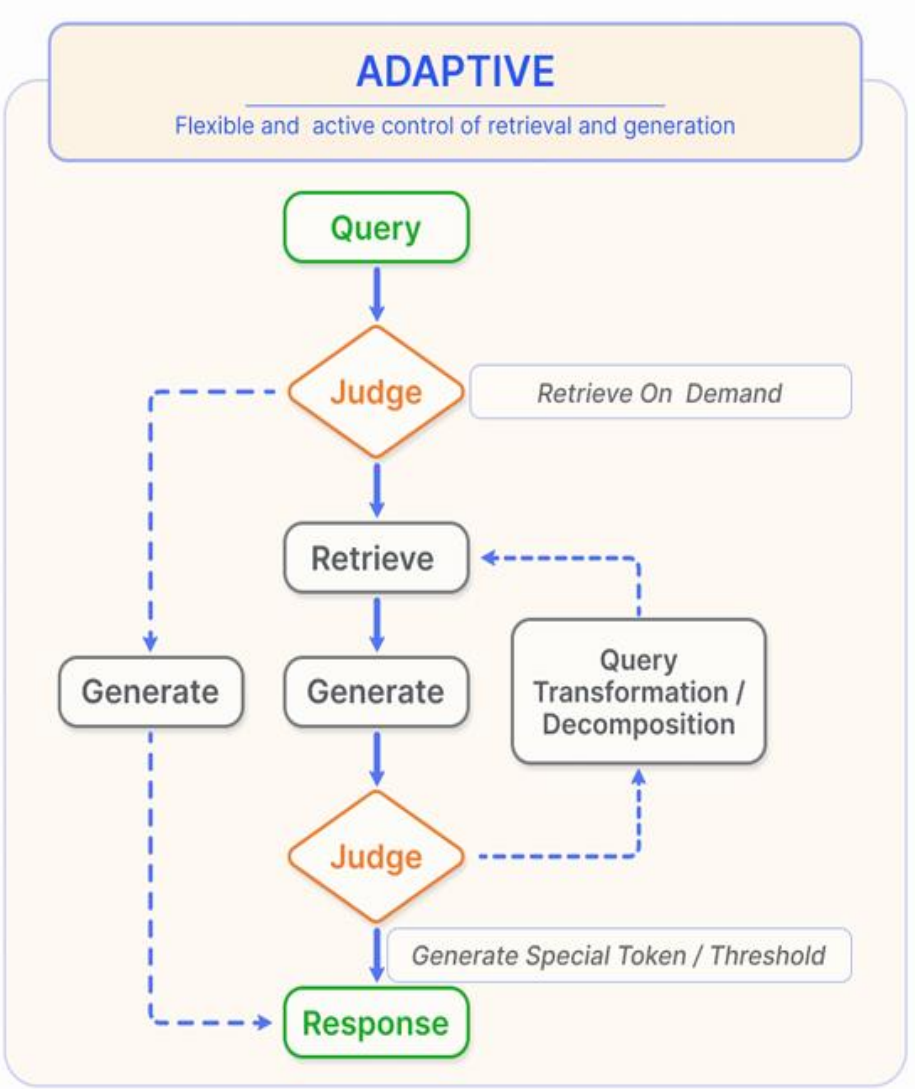


12.2.4 进阶RAG技术

RAG进阶技术—RAG增强

- 自适应RAG通过引入反思机制，让大语言模型在生成过程中能够动态地调整其处理策略，从而提升生成内容的质量和可信度。

- 以Self-RAG为例，该方法首先依据输入内容预测是否需要检索；若需要检索，模型会并行处理多个检索到的文档，并对检索结果进行筛选和评估；最终，结合符合要求的检索结果，优化答案选择和生成过程，确保输出内容既符合事实，又保持语言的流畅性和连贯性。



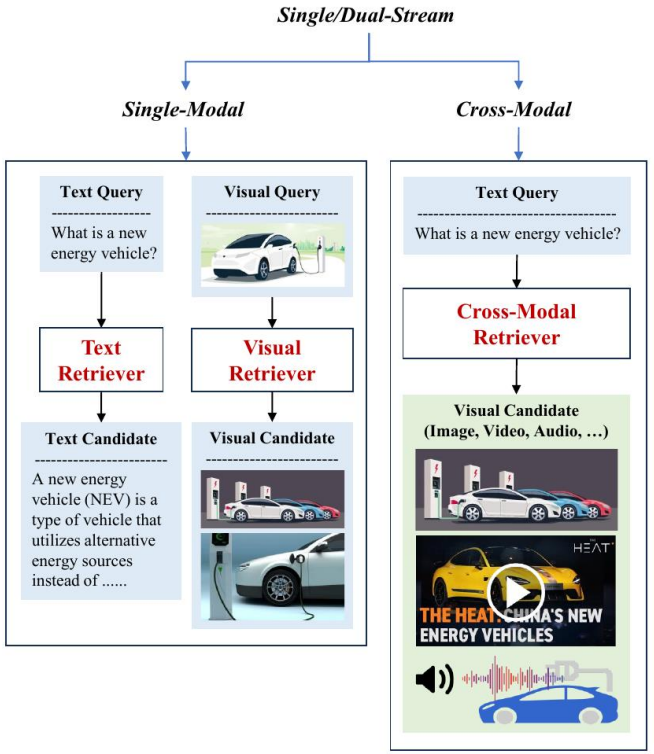
12.2 检索增强RAG

- 12.2 检索增强RAG
  - 12.2.1 检索增强概述
  - 12.2.2 RAG系统架构
  - 12.2.3 RAG核心技术
  - 12.2.4 进阶RAG技术
  - 12.2.5 多模态RAG☆
  - 12.2.6 Agentic RAG

12.2.5 多模态RAG

多模态知识获取的需求

- 前文介绍了基于文本资料的检索增强生成。外部知识还包含图像、音频和视频，回答可能依赖视觉、声音或时序信息。
- 图像提供对象外观与空间关系，音频包含语音及环境声音，视频记录动作过程与事件顺序。多模态RAG通过检索相关资料，为问题求解和内容生成提供这些信息。

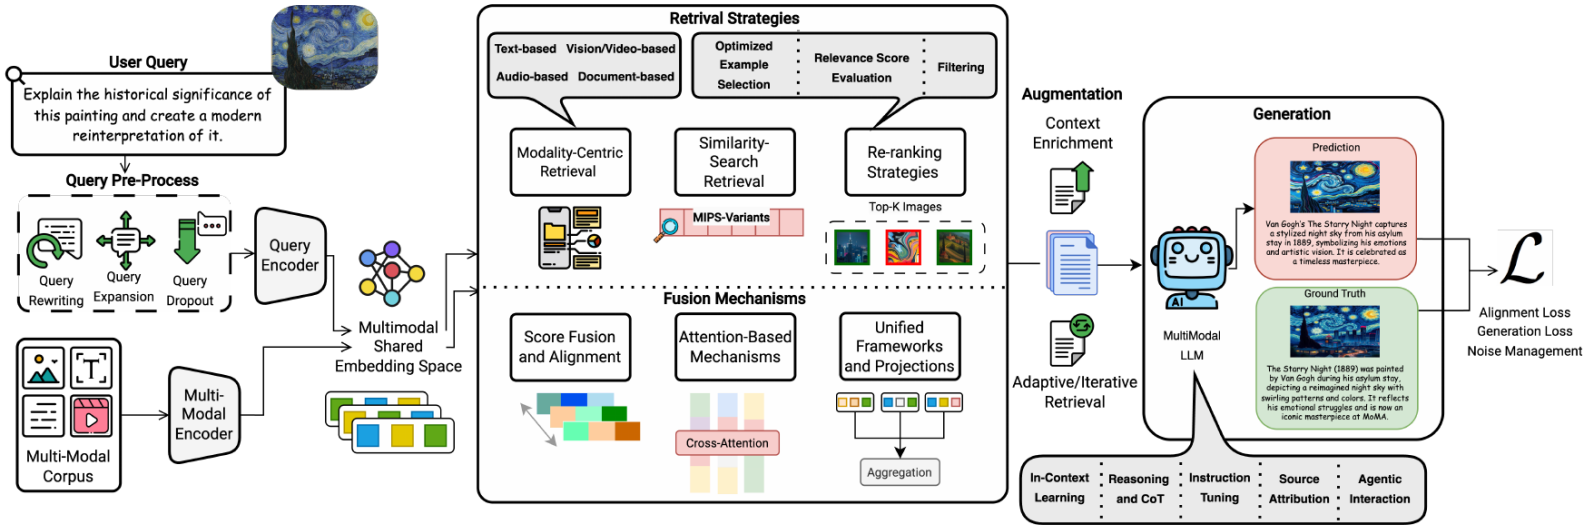


[7] MEI L, MO S, YANG Z, et al. A Survey of Multimodal Retrieval-Augmented Generation[EB/OL]. (2025-03-26)[2026-10-20]. https://arxiv.org/abs/2504.08748v1.
[8] ABOOTORABI M M, ZOBEIRI A, DEHGHANI M, et al. Ask in Any Modality: A Comprehensive Survey on Multimodal Retrieval-Augmented Generation[C]//Findings of the Association for Computational Linguistics: ACL 2025. 2025: 16776-16809. 配图引自[7]图7（局部）；模态范围参考[8]。

12.2.5 多模态RAG

多模态RAG的基本流程

- 多模态RAG将外部多模态知识引入生成过程，基本环节包括资料处理与索引、相关内容检索和检索增强生成。
- 系统建立可检索的内容表示，依据查询获取相关资料，再结合查询与检索内容完成生成任务。查询与检索对象可以属于不同模态。

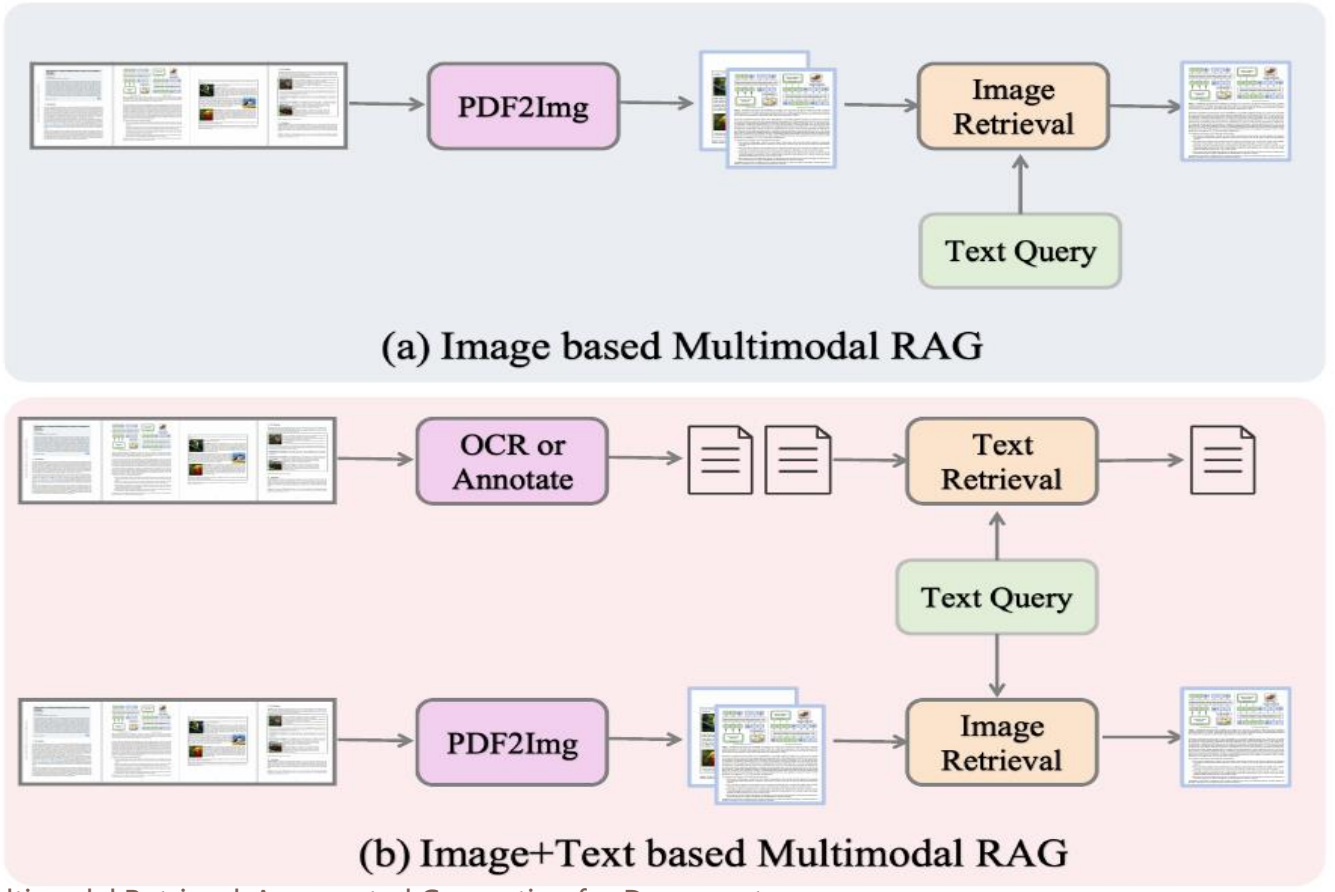


[8] ABOOTORABI M M, ZOBEIRI A, DEHGHANI M, et al. Ask in Any Modality: A Comprehensive Survey on Multimodal Retrieval-Augmented Generation[C]//Findings of the Association for Computational Linguistics: ACL 2025. 2025: 16776-16809. 配图引自[8]图1（裁剪）。

12.2.5 多模态RAG

多模态知识的表示与检索

- 文本转换：通过OCR、图像描述和语音转写获得文本，再进行索引与检索。视频可结合字幕、语音转写和画面描述组织内容。
- 模态表示：使用相应编码器建立图像、音频或视频的表示，计算查询与候选内容的相关性，支持同模态或跨模态检索。
- 文本表示与模态表示可以结合使用，共同提供检索线索。

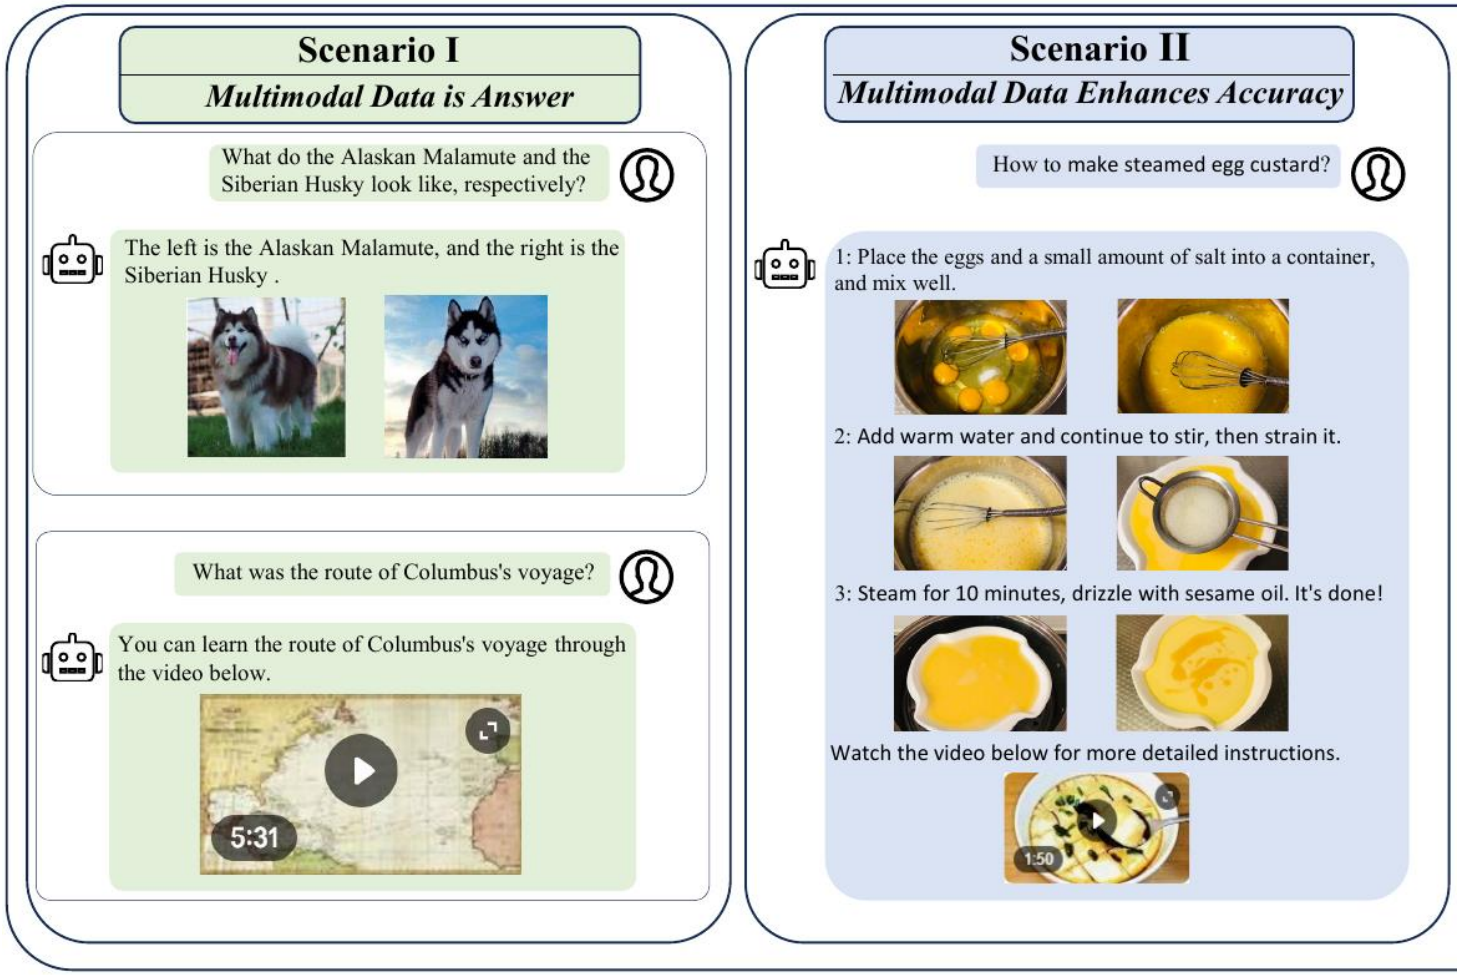


[9] GAO S, ZHAO S, JIANG X, et al. Scaling Beyond Context: A Survey of Multimodal Retrieval-Augmented Generation for Document Understanding[C]//Proceedings of ACL 2026 (Volume 1: Long Papers). 2026: 4458-4489.
[7] MEI L, MO S, YANG Z, et al. A Survey of Multimodal Retrieval-Augmented Generation[EB/OL]. (2025-03-26)[2026-10-20]. https://arxiv.org/abs/2504.08748v1. 配图引自[9]图3；表示与检索的归纳另参考[7]。

12.2.5 多模态RAG

多模态生成与组合输出

- 检索内容可以支持多模态理解与问答，也可以为图像、视频等内容生成提供参考。例如，检索对象的参考图像可为生成该对象的图像提供外部信息。
- 组合回答可以由模型直接产生，也可以整合检索素材。素材整合包括确定插入位置、检索候选内容，以及匹配和插入，形成相互对应的文字与非文本内容。



[7] MEI L, MO S, YANG Z, et al. A Survey of Multimodal Retrieval-Augmented Generation[EB/OL]. (2025-03-26)[2026-10-20]. https://arxiv.org/abs/2504.08748v1. 配图引自[7]图5的Scenario I、II（裁剪）。

12.2.5 多模态RAG

RAG应用实例：腾讯ima

- 腾讯ima将文件、图片、网页和公众号文章等资料组织为知识库，支持订阅或自建知识库，检索知识库内容、基于资料问答并溯源。
  - 以《小说写作知识库》为例，它收集了写作文章，介绍人物怎么写、情节怎么安排、故事如何吸引读者。
  - 文章太多，不必一篇篇翻找，可以直接围绕自己的疑问提问。



[10] 腾讯. ima：腾讯AI知识管家[EB/OL]. [2026-10-20]. https://ima.qq.com/. 界面截图：腾讯ima《小说写作知识库》

12.2.5 多模态RAG

腾讯ima：回答与来源核验

为什么有些小说让人忍不住追更，有些读了几章就弃了？请根据知识库中的资料解释，并注明来源。

- 围绕“追更”和“弃文”的原因，在知识库中查找相关文章

ima

我需要从知识库中检索关于小说"追更"和"弃文"原因的相关资料。让我进行知识搜索。

知识库搜索 为什么小说让人忍不住追更 悬念钩子 读者留存,...

- 结合查到的内容，归纳总结，并标注出引用文章。

总结

追更与弃文的分水岭，本质上取决于作者是否持续为读者供应**期待感、悬念钩子、情绪起伏和代入感**这四样东西。知识库用一句极简的话概括了这一机制：

> 读者追更，追的不是剧情，是情绪的起伏。不是你在写故事，是你在操控读者的心跳。 6

资料出处：以上结论分别来自《网文之魂——期待感的设计技

[10] 腾讯. ima：腾讯AI知识管家[EB/OL]. [2026-10-20]. https://ima.qq.com/. 问答与引用界面：腾讯ima《小说写作知识库》

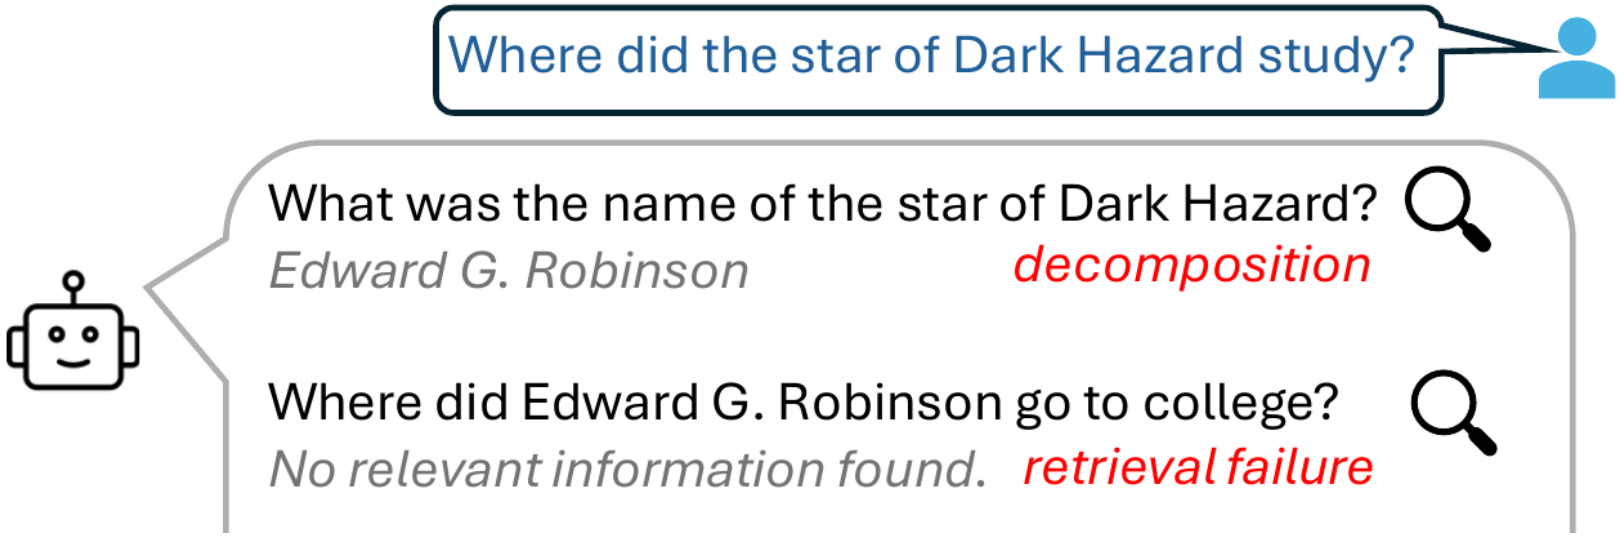
12.2 检索增强RAG

- 12.2 检索增强RAG
  - 12.2.1 检索增强概述
  - 12.2.2 RAG系统架构
  - 12.2.3 RAG核心技术
  - 12.2.4 进阶RAG技术
  - 12.2.5 多模态RAG
  - 12.2.6 Agentic RAG☆

12.2.6 Agentic RAG

Agentic RAG：示例引入

问题：《Dark Hazard》的主演曾在哪所大学就读?



- 已经查到主演，但一轮检索尚未获得就读院校的信息。后续检索需要利用已知结果进行调整，应对检索中的失败。

[11] WANG L, CHEN H, YANG N, et al. Chain-of-Retrieval Augmented Generation[C]//Advances in Neural Information Processing Systems. 2025, 38. DOI: 10.52202/085713-2003. 配图引自[11]图1(b)局部。

12.2.6 Agentic RAG

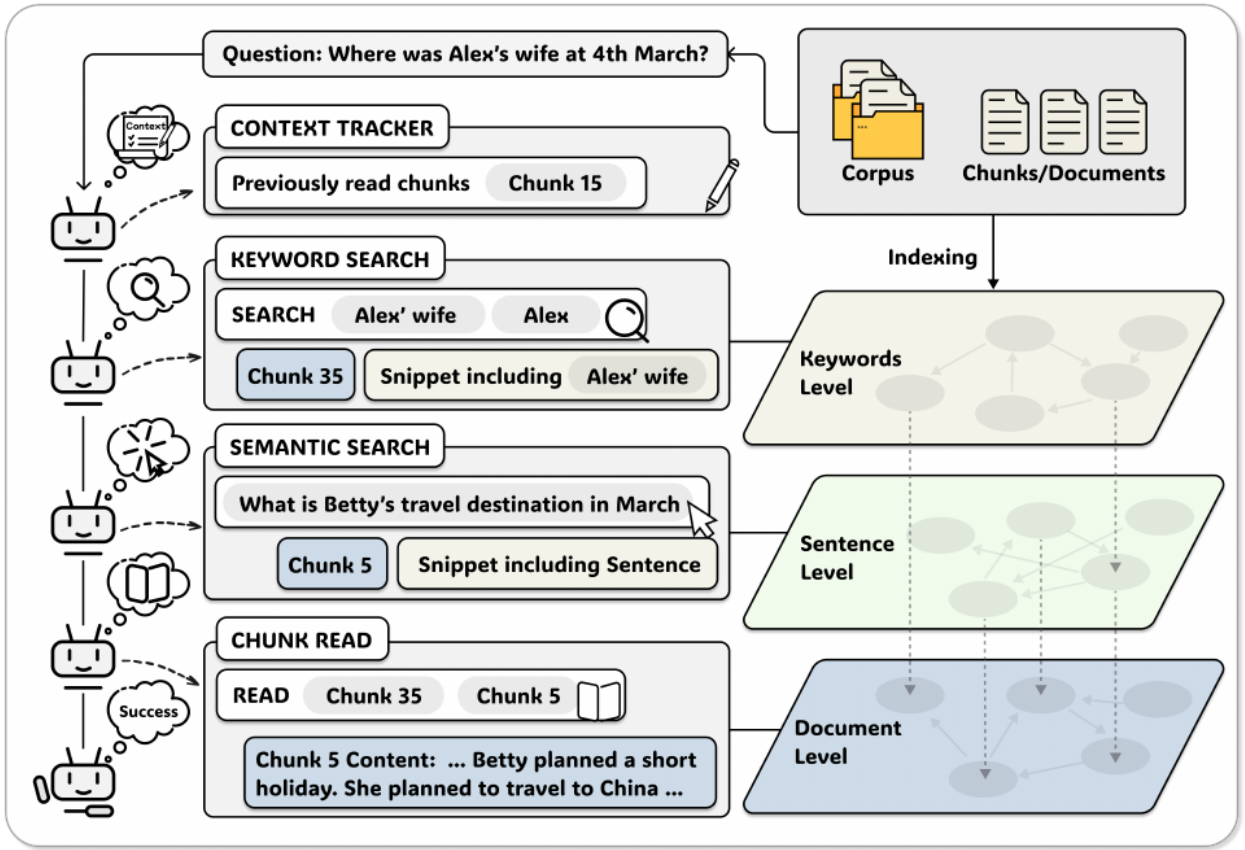
Agentic RAG：基本概念

- 智能体检索增强生成在RAG流程中引入智能体，利用其规划与决策能力，根据任务要求和中间结果，组织外部知识的获取与利用。
- RAG可以采用多轮检索。这里关注如何依据实际返回的资料，决定后续查询、检索工具及处理步骤。
- 检索为回答提供外部依据；智能体负责组织检索与证据处理。其自主决策仍受可用工具、工作流程和资源预算约束。

[12] SINGH A, EHTESHAM A, KUMAR S, et al. Agentic Retrieval-Augmented Generation: A Survey on Agentic RAG[EB/OL]. (2026-04-01)[2026-10-20]. https://arxiv.org/abs/2501.09136v4. 定义据[12]摘要、引言及第5节归纳。

12.2.6 Agentic RAG

Agentic RAG：检索计划与工具决策



确定下一步查询

利用已取得的实体与事实，确定后续待查信息。

选择工具与粒度

依据查询线索选择工具，片段不足时读取原文。

根据反馈组织操作

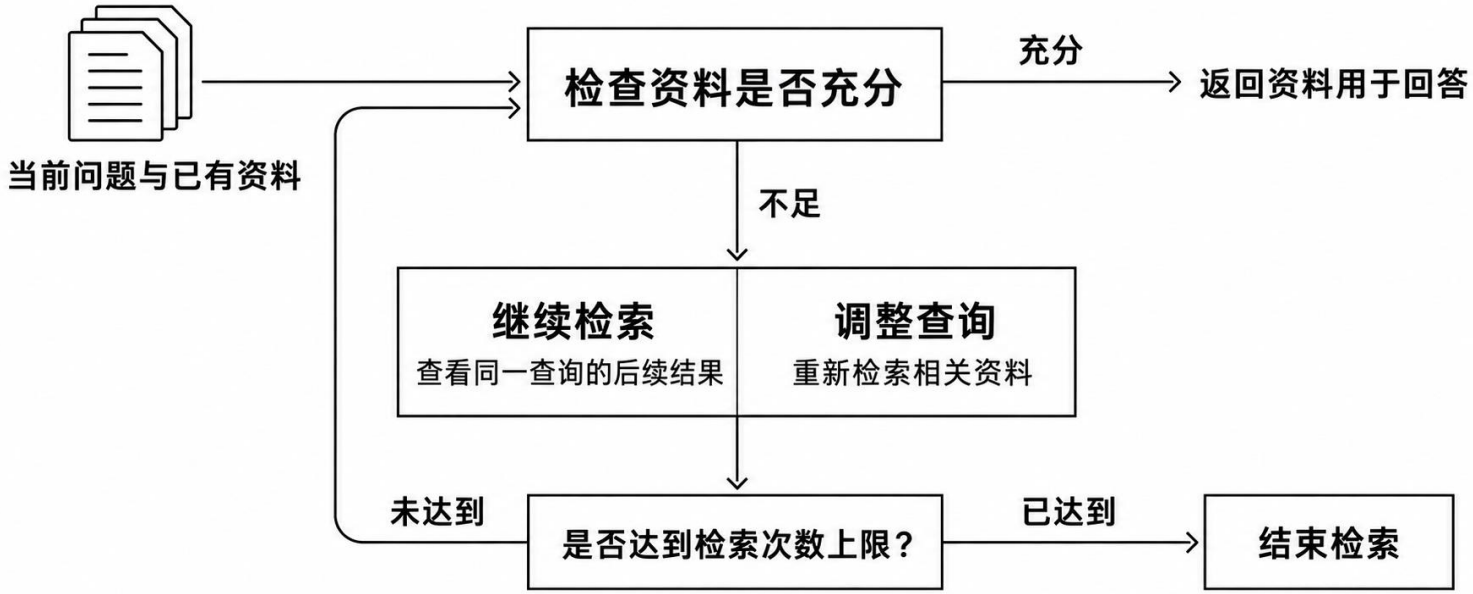
图中为一种工具组合，实际次序由返回结果决定。

[13] DU M, XU B, ZHU C, et al. A-RAG: Scaling Agentic Retrieval-Augmented Generation via Hierarchical Retrieval Interfaces[EB/OL]. (2026-02-03)[2026-10-20]. https://arxiv.org/abs/2602.03442v1. 配图引自[13]图3。

12.2.6 Agentic RAG

Agentic RAG：检索反馈与调整

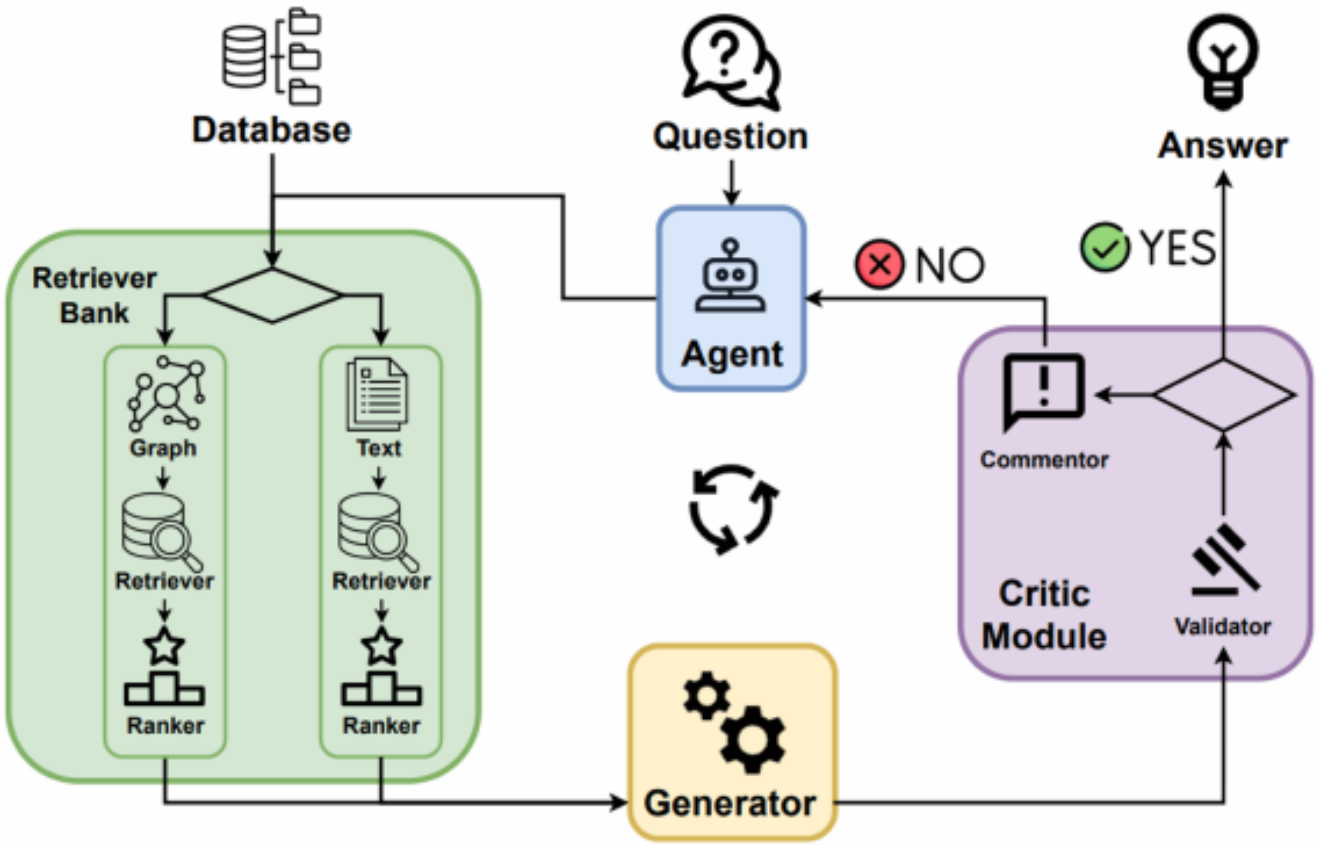
- 智能体依据工具返回的资料选择后续操作。继续获取结果、调整查询或结束检索等判断，需要转化为相应的工具调用。



[14] SALEMI A, MADDIPATLA M, ZAMANI H. CIIR@LiveRAG 2025: Optimizing Multi-Agent Retrieval Augmented Generation through Self-Training[C]// Proceedings of the LiveRAG Challenge at ACM SIGIR 2025. 2025. 据[14]第3.1节Searcher机制译编；图为自制中文教学示意。

12.2.6 Agentic RAG

Agentic RAG：核验反馈与处理



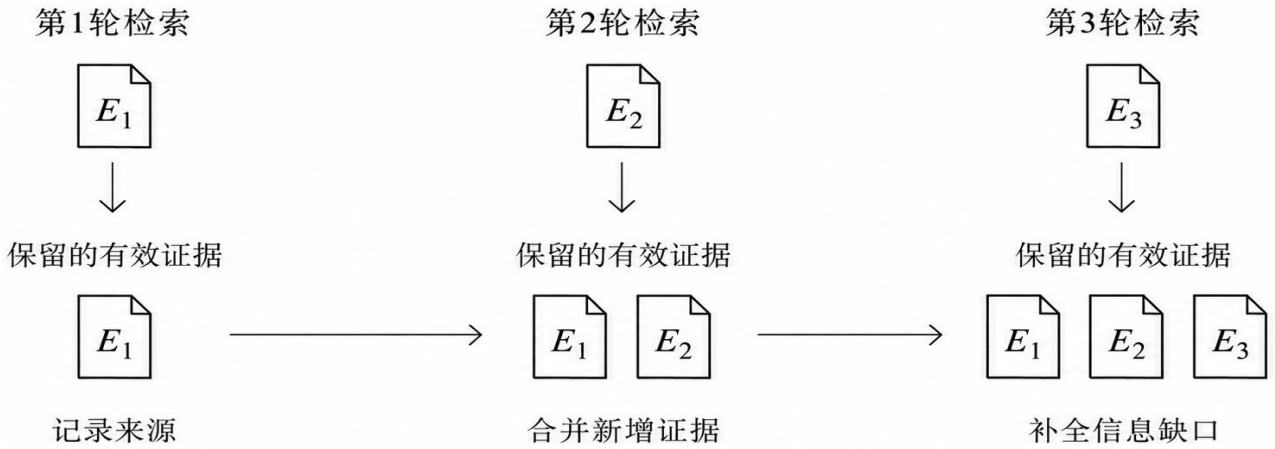
- 资料未满足查询条件时，返回检索环节，修订查询或补充资料。
- 资料相关但结论缺乏支持时，应修订回答或继续查证。
- 核验模块将发现的问题反馈给协调角色，后续操作围绕具体缺口展开。

[12] SINGH A, EHTESHAM A, KUMAR S, et al. Agentic Retrieval-Augmented Generation: A Survey on Agentic RAG[EB/OL]. (2026-04-01)[2026-10-20]. https://arxiv.org/abs/2501.09136v4. 配图引自[12]图21（Agent-G架构）。

12.2.6 Agentic RAG

Agentic RAG：检索状态维护

- 跨轮处理需要维护已获得的证据、已执行的检索操作和尚未解决的问题。状态记录为后续决策提供依据。



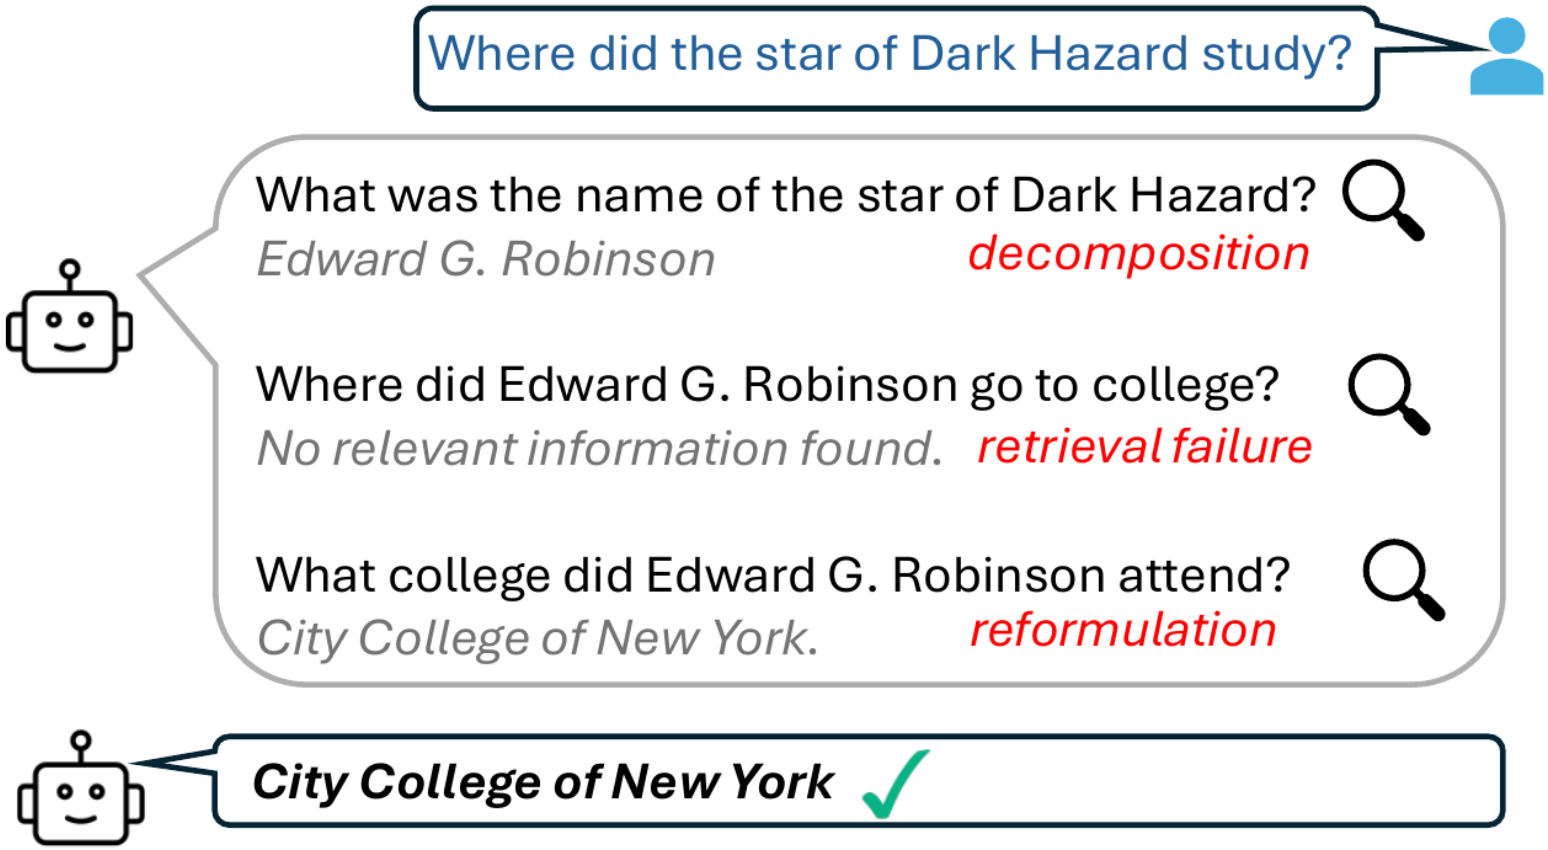
- 已读记录减少重复操作；证据保留来源，待查问题随新结果更新。

[13] DU M, XU B, ZHU C, et al. A-RAG: Scaling Agentic Retrieval-Augmented Generation via Hierarchical Retrieval Interfaces[EB/OL]. (2026-02-03)[2026-10-20]. https://arxiv.org/abs/2602.03442v1.
[14] SALEMI A, MADDIPATLA M, ZAMANI H. CIIR@LiveRAG 2025: Optimizing Multi-Agent Retrieval Augmented Generation through Self-Training[C]// Proceedings of the LiveRAG Challenge at ACM SIGIR 2025. 2025.

状态维护据[13]第3.3节及[14]第3.1节归纳；图为自制教学示意。

12.2.6 Agentic RAG

Agentic RAG：示例检索演示



确定下一步查什么

先查主演，再查其就读院校。

检索失败后调整

重新表述查询，再次获取相关信息。

依据资料形成答案

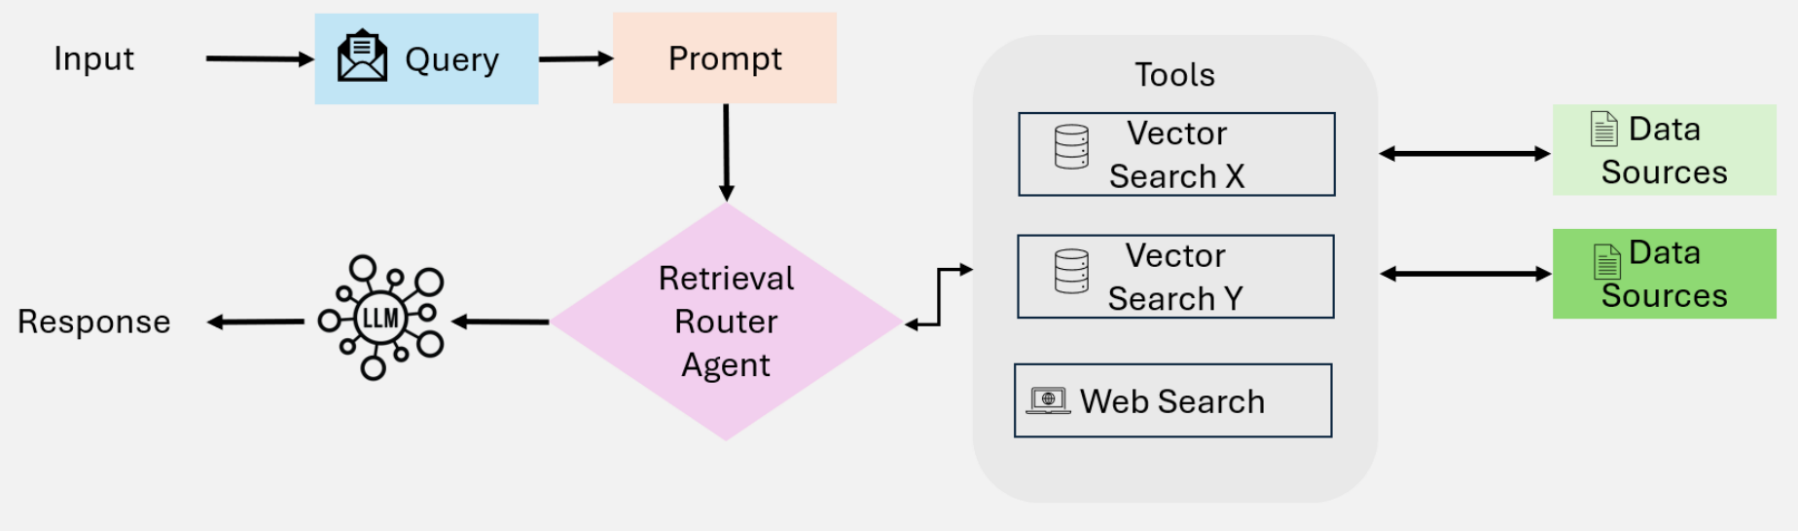
取得纽约城市学院的信息，回答原问题。

[11] WANG L, CHEN H, YANG N, et al. Chain-of-Retrieval Augmented Generation[C]//Advances in Neural Information Processing Systems. 2025, 38. DOI: 10.52202/085713-2003. 配图引自[11]图1(b)。

12.2.6 Agentic RAG

Agentic RAG：单智能体架构

- 同一智能体维护任务状态，并统一决定后续检索与回答步骤。不同工具的返回结果进入同一处理过程。



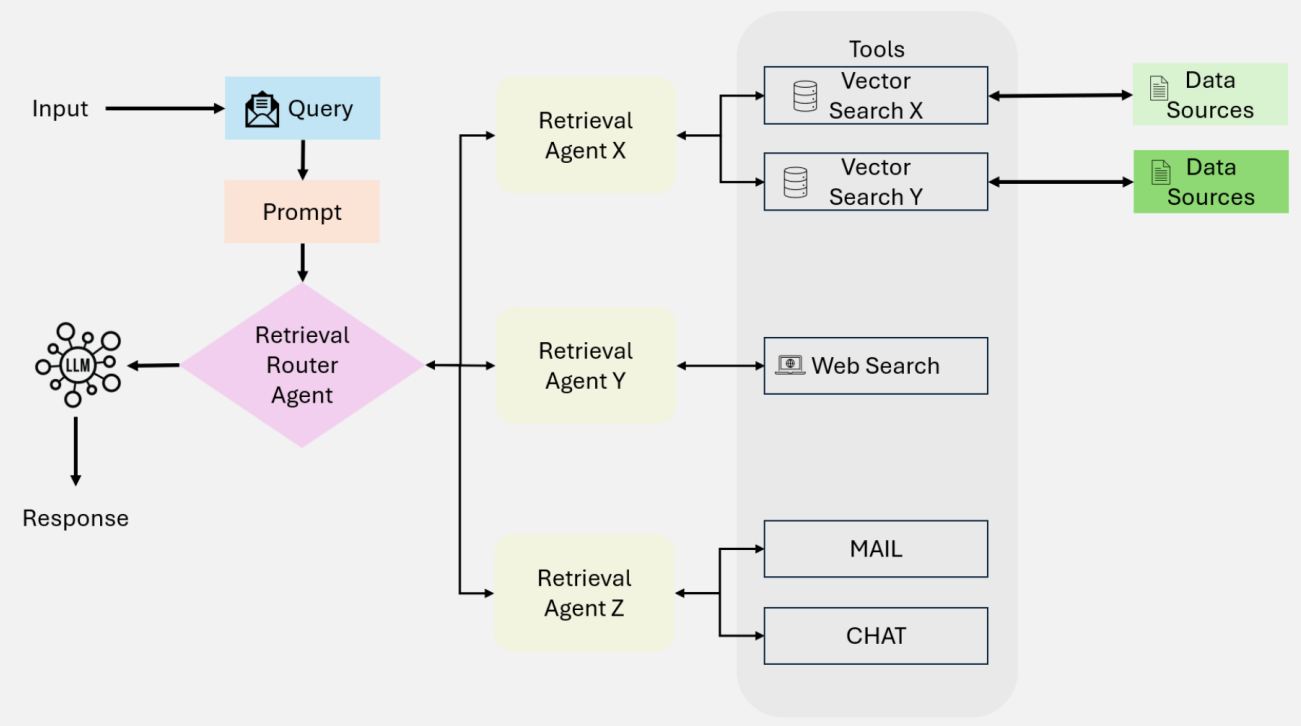
- 一个智能体可以调用多个工具、访问多个知识源。工具数量与智能体数量分别描述不同的系统组成。

[12] SINGH A, EHTESHAM A, KUMAR S, et al. Agentic Retrieval-Augmented Generation: A Survey on Agentic RAG[EB/OL]. (2026-04-01)[2026-10-20]. https://arxiv.org/abs/2501.09136v4. 配图引自[12]图16；正文据第5.1节归纳。

12.2.6 Agentic RAG

Agentic RAG：多智能体分工

- 多智能体RAG可按知识来源分工，分别面向文档、数据库或网络资料；也可按检索、分析、核验和生成等职责分工。
- 分工后需要明确各角色接收的信息与返回的证据，使局部结果能够支撑同一问题的回答。

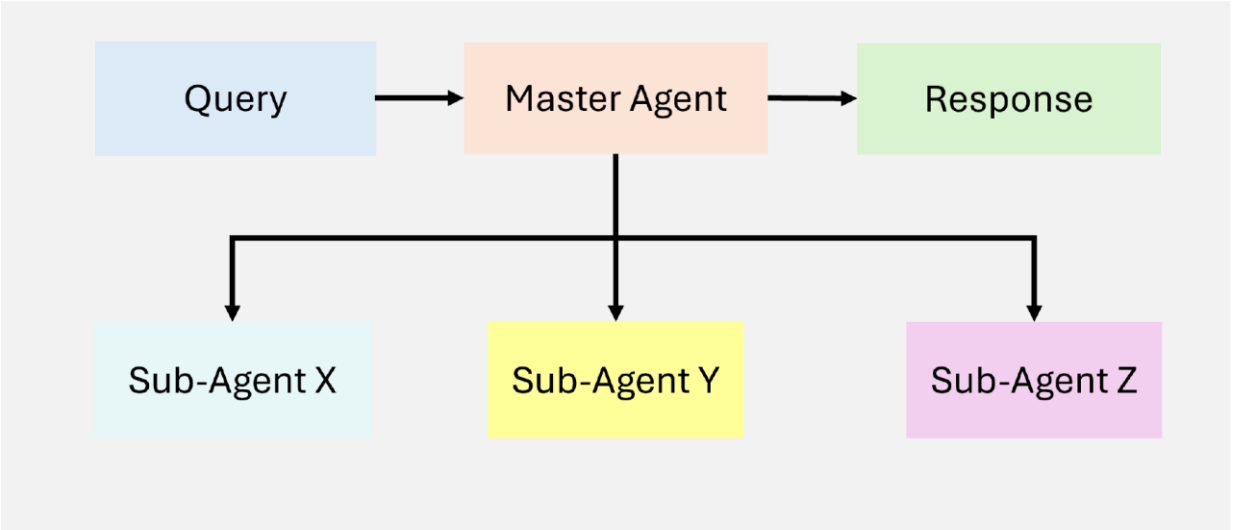


[12] SINGH A, EHTESHAM A, KUMAR S, et al. Agentic Retrieval-Augmented Generation: A Survey on Agentic RAG[EB/OL]. (2026-04-01)[2026-10-20]. https://arxiv.org/abs/2501.09136v4.
[14] SALEMI A, MADDIPATLA M, ZAMANI H. CIIR@LiveRAG 2025: Optimizing Multi-Agent Retrieval Augmented Generation through Self-Training[C]// Proceedings of the LiveRAG Challenge at ACM SIGIR 2025. 2025. 配图引自[12]图17；职责分工另参考[14]第3.1节。

12.2.6 Agentic RAG

Agentic RAG：分层检索协作

- 问题涉及多个知识域或子任务时，可采用分层组织：上层分配总体信息需求，下层在指定范围内协调检索与证据处理。

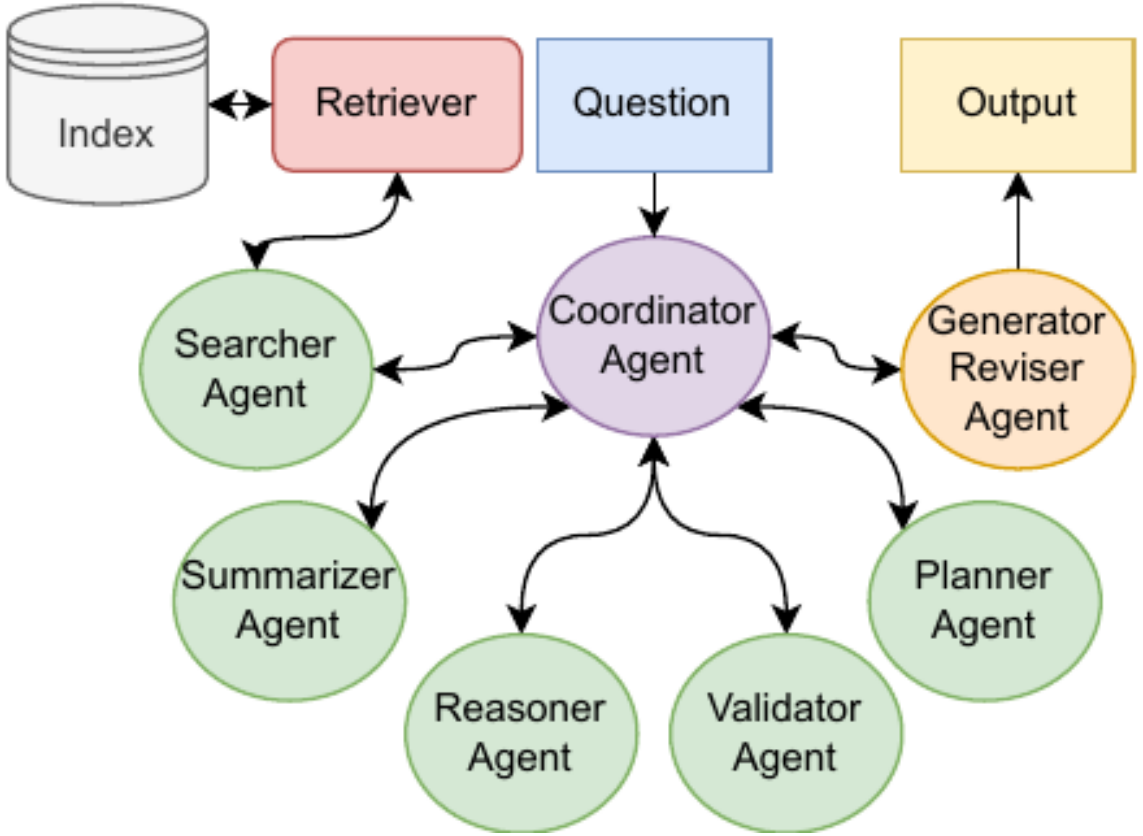


- 下层结果逐级汇总，并回到原问题核对。分层改变的是检索任务的协调范围，各层仍需保留证据依据。

[12] SINGH A, EHTESHAM A, KUMAR S, et al. Agentic Retrieval-Augmented Generation: A Survey on Agentic RAG[EB/OL]. (2026-04-01)[2026-10-20]. https://arxiv.org/abs/2501.09136v4. 配图引自[12]图18；正文据第5.3节归纳。

12.2.6 Agentic RAG

Agentic RAG：mRAG协作流程实例



- mRAG的协调器根据当前状态，调用搜索、摘要、分析、核验或生成修订角色。
- 角色返回资料及处理结果。生成修订角色整合支持资料，核验角色检查问题条件是否满足；回答保留可核查的来源。
- 协调器更新支持文档与交互状态，再根据新资料或未满足的条件安排补充检索或回答修订。

[14] SALEMI A, MADDIPATLA M, ZAMANI H. CIIR@LiveRAG 2025: Optimizing Multi-Agent Retrieval Augmented Generation through Self-Training[C]// Proceedings of the LiveRAG Challenge at ACM SIGIR 2025. 2025. 配图引自[14]图1；正文据第3.1节归纳。