自然语言处理

实验1：文本分类和情感分析

杨沐昀

哈尔滨工业大学计算学部
语言技术研究中心

2026年秋季学期

yangmuyun@hit.edu.cn

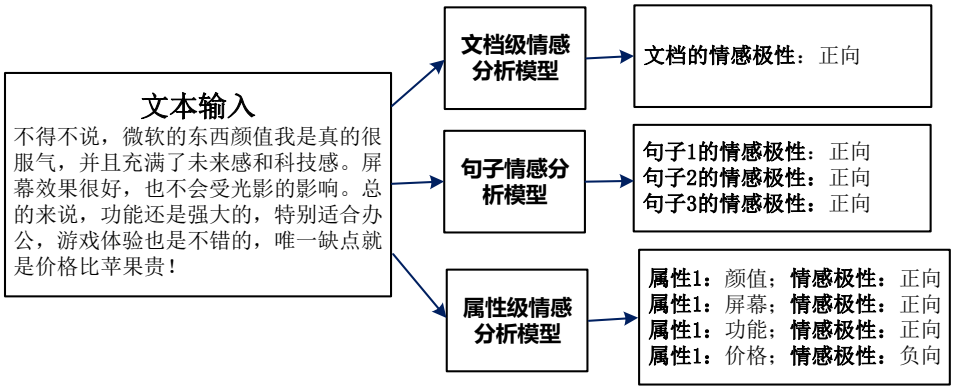
主要内容

- 13.1 文本分类与聚类
- 13.2 情感分析

13.1 文本分类和聚类

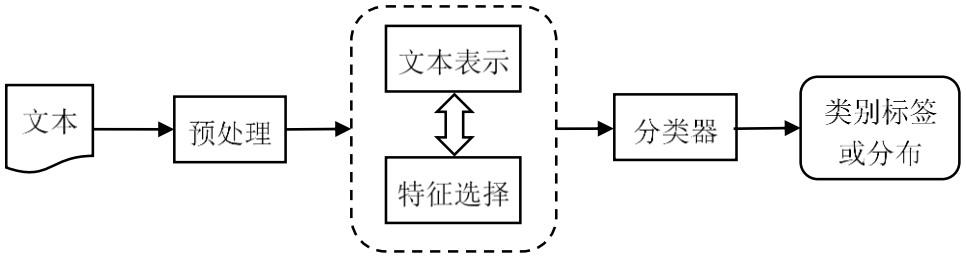
基本概念：

- 文本分类的输入为计算机能够处理的文本格式，输出为定义好的某个或某几个类别标签（一般还会带有文本属于该类别的置信度评分，如概率）；在无类别标签的情况下，文本数据被自动聚成类，某一文本会被归类到特定的类别中。



文本分类流程-概率统计

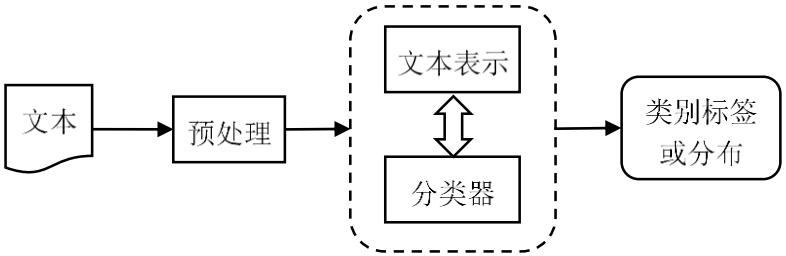
- 预处理（包括切词（tokenization）、去停词（stopwords removal）等操作）后的文本送入分类器之前会有一个特征选择的过程，也就是我们熟知的特征工程（feature engineering），其中，文本表示往往和文本特征提取联系非常紧密，有时一并完成。



概率统计范式下的文本分类流程

文本分类流程-深度学习

- 深度学习（deep learning）的文本分类技术将特征提取甚至文本表示一并纳入基于深度神经网络的建模过程中，实现端到端（end-to-end）的学习与推理



深度学习范式下端到端的文本分类流程

13.1.1 统计文本分类

- 文本表示与特征选择
- 分类算法

文本表示与特征选择

- 1、向量空间模型（Vector Space Model，VSM）
  - 将文本表示为高维空间中的向量，希望通过文本的空间相似性逼近其语义相似性。
  - VSM中的每一维是基本语言单元，称作特征项，一般是词，也可以是字或短语等。
  - 对含有个特征项的文本，每个特征项都根据一定原则被赋予一个权重，表示该特征项在文本中的重要性以及与文本的相关性，这样一个文本便可表示为向量。
  - 文本分类中文本表示和特征选择等步骤，便是确定这些特征项（通常是词项）的权重。

文本表示与特征选择

2、词袋模型（Bag of Words model, BOW）

- 词袋模型的基本思想是，假定对于一个文本，忽略其词序和句法，仅仅将其看作是一些词汇的集合，文本中的每个词汇都是独立的。
- 我们可以为数据集中的所有单词构建一个词表，为每个词建立一个位置索引；对于待编码的文本，统计词表中每个位置对应的词在该文本中出现的频次。
- 例如，文本为：“我喜欢春天，我也喜欢夏天”，
  - 切词后我们得到：“我 喜欢 春天 ， 我 也 喜欢 夏天”，
  - 根据词袋模型，该文本被表示成 { “我”:2, “喜欢”:2, “春天”:1, “也”:1, “夏天”:1}，其中，每个词后面的数字表示该词在该文本中出现的次数。
  - 将{“我”，“喜欢”，“春天”，“也”，“夏天”}作为词表，这样，文本就被表示成了一个的向量。

文本表示与特征选择

- 词袋模型有以下明显的缺点：
  - 没有考虑词的相似关系以及文本中词之间的位置（修饰）关系：“我喜欢北京”与“我爱北京”表达了非常接近的语义关系，但词袋模型不能表示“喜欢”和“爱”之间紧密的相似关系；“我喜欢北京”、“我不喜欢北京”这两个文本语义相悖，但词袋模型会判其为高度相似；
  - 不能指示文本中的关键词，也即能够代表文本主题等类别的显著词汇，基于词袋模型的向量表示虽然可以直接用于分类器（如朴素贝叶斯模型），但本质上缺少了特征选择的过程。

文本表示与特征选择

3、TF-IDF：

- TF-IDF算法，其在保留词袋模型的词表和单词索引结构的基础上，通过引入词频（Term Frequency，TF）和逆文档频率（Inverse Document Frequency，IDF）来识别文本中的关键词，即用TF 和IDF 两个参数来表示词语在文本中的重要程度。
- 一般情况下，词语（停词除外）在文本中出现的次数越多，重要性越大，例如词袋模型直接用词频来表示该特征。
- 另一方面，如果某个词语仅出现在少数文本中，说明该词语对于文本的区别性强，更有显著性，对应的分类特征值高，用IDF来衡量。
- 将TF和IDF结合得到词的TF-IDF值，用以表示文本。

词频-逆文档频率(TF-IDF)

- 利用词频(Term Frequency)

f_{ij} = frequency of term t_i in document d_j

$$TF_{ij} = \frac{f_{ij}}{\max_k f_{kj}}$$

- TF可以采用不同的计算方式，如

$$TF_{ij} = \log(f_{ij} + 1)$$

词频-逆文档频率(TF-IDF)

- 词频越高越重要吗?
  - 如何降低频率高但是却不重要的词的权重
  - 逆文档频率 (Inverse Document Frequency)

df_i = number of docs that mention term i

N = total number of docs

$$IDF_i = \log \frac{N}{\mathrm{df}_i}$$

- TF-IDF权重W_{ij}

$$W_{ij} = TF_{ij} \times IDF_i$$

小贴士：IDF与Karen Spärck Jones

- 1935年8月26 – 2007年4月4日
- 1972年提出IDF。IDF作为 TF-IDF 权重计算模式的一部分，已被用在大多数搜索引擎中。
  - Spärck Jones, Karen (1972). "A statistical interpretation of term specificity and its application in retrieval". *Journal of Documentation* **28** (1): 11–21. doi:10.1108/eb026526.
- 2004年获得ACL终身成就奖（the ACL Lifetime Achievement Award ）



http://en.wikipedia.org/wiki/Karen_Sp%C3%A4rck_Jones

文本表示与特征选择

4、特征选择

- 在送入分类算法之前通常需要对高维的特征空间进行降维。
- 降维方法主要分为特征提取（feature extraction）和特征选择（feature selection）。
  - 特征提取的目的：是将原始的高维稀疏特征空间映射为低维稠密的特征空间，在概率统计框架下，基于奇异值分解操作的LSA（Latent Semantic Analysis，潜在语义分析）、PLSA（Probabilistic Latent Semantic Analysis，概率化潜在语义分析）和LDA（Latent Dirichlet Allocation，潜在狄利克雷分布）等都被用于特征空间的降维。
  - 特征选择是从特征空间中择优选出一部分特征子集，用于文本分类的过程。包括互信息法（MI）、信息增益法（IG）和卡方统计量法（）等特征选择方法则依赖文本的类别标签，通过分析特征与类别之间的关系，能够筛选出对文本分类更有帮助的特征

分类算法

- 统计分类模型可以归为：生成式的模型（generative models）和判别式的模型（discriminative models）
  - 生成式分类器的典型代表是贝叶斯模型（Bayes models）
  - 判别式分类器的代表有Logistic回归、Softmax回归、最大熵（maximum entropy）模型以及支持向量机（Support Vector Machine，SVM）等。

（1）生成式模型

- 生成式模型对观测变量（待分类的输入）和类别的联合概率分布$p(x,y)$建模
- 观测值由类别生成，即$p(x,y)=p(y)p(x|y)$。
- 分类时，基于贝叶斯推断*(Bayesian inference)*，给定一个观测结果，返回最有可能生成该观测结果的类别：

$$y^* = \underset{y}{\operatorname{argmax}}\, P(y|x) = \underset{y}{\operatorname{argmax}} \frac{P(x|y)P(y)}{P(x)} \propto \underset{y}{\operatorname{argmax}}\, P(x|y)P(y)$$

- 生成式模型理论基础强，参数估计简单，能够通过采样等方法生成符合分布的数据。但其难以在线学习及整合复杂特征，往往效果不如直接对条件概率建模的判别式模型。

（2）判别式模型

- 1. 朴素贝叶斯（naïve Bayes）模型用于文本分类
  - 朴素贝叶斯模型提出了两个假设：
    - 1）词袋假设：只关心文本中每个词出现的频次而忽略这些词在文本中的位置；
    - 2）朴素贝叶斯假设：即给定类别c，概率$p(w_k|c)$是相互独立的条件独立性假设。因此，上面的类条件概率可以写成：

$$P(w_1, w_2, ..., w_n|c) = P(w_1|c) \cdot P(w_2|c) \cdot ... \cdot P(w_n|c)$$

    - 则：

$$c^* = \underset{c \in C}{\operatorname{argmax}} P(d|c)P(c) = \underset{c \in C}{\operatorname{argmax}} P(c) \prod_{k=1}^{n} P(w_k|c)$$

    - 朴素贝叶斯模型对文本类别的建模，是建立在词袋表示基础上的，较强的独立性假设使其不易刻画精细的特征，但其简单性使其在文本分类特别是情感分析任务中是一种不错的选择。

2、线性判别模型用于文本分类

- 如果将文本表示为特征形式并输入分类器，那么基于词袋模型的朴素贝叶斯模型所利用的文本特征即为词袋特征：每一个词代表一个特征。
- 线性判别模型直接优化分类的后验概率，并将其建模为多种特征的线性组合：

$$y^* = \underset{y}{\operatorname{argmax}} P(y|x) = \underset{y}{\operatorname{argmax}} \sum_{i=1}^{K} \lambda_i f_i(x, y)$$

- 与朴素贝叶斯模型相比，在线性判别模型中可以灵活设计特征函数来增强对输入文本的表征能力；同时，对输入到输出的直接优化，一般情况下能够获得更精确的分类结果。

- 对不同的线性判别模型来讲，上式中特征函数的形式以及因变量的分布假设会有所不同，即上式对线性判别函数的描述只在argmax条件下成立。
- 对感知机（perceptron）来说： $y = \text{sign}(W^{\mathrm{T}}x + b) = \text{sign}\left(\sum_{i=1}^{K} w_i x_i + b\right)$
- 对最大熵模型来说： $P(y|x) = \frac{1}{Z(x)} \exp\left(\sum_{i=1}^{K} \lambda_i f_i(x, y)\right)$
- 对Logistic回归的推广Softmax回归来说：

$$P(y|x) = \text{softmax}(o) = \text{softmax}(W^{\mathrm{T}}x + b)$$

$$P(y_j|x) = \frac{\exp(o_j)}{\sum_m \exp(o_m)}$$

13.1.2 深度神经网络文本分类

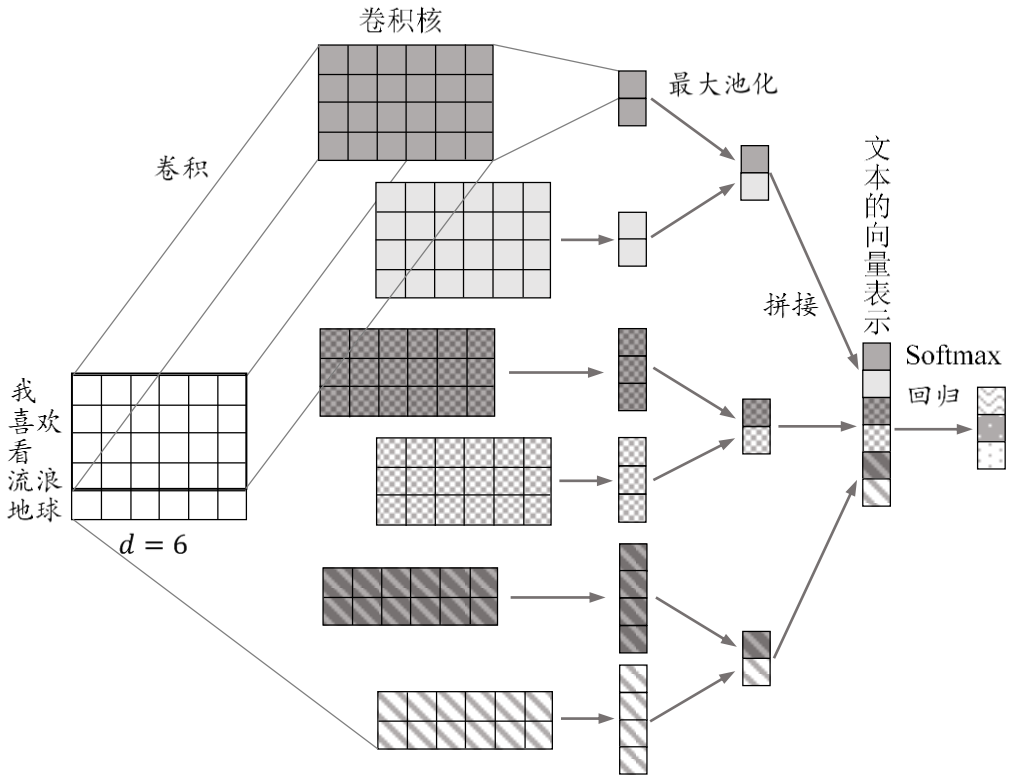
- 典型的深度学习以深层神经网络为基础，基于多层非线性变换实现对复杂非线性问题的建模，特征自动提取也使端到端的学习与推理成为可能。
- 在语音识别和图像处理领域取得突破之后，在自然语言处理领域也逐渐成为了主流。
- 文本分类任务通过对输入文本的理解给出其在某个维度的类别标签，如主题、情感等。
- 基础的神经网络如多层感知机（MultiLayer Perceptron，MLP）、卷积神经网络（Convolutional Neural Network，CNN）和循环神经网络（Recurrent Neural Network，RNN）等，都可以对文本及其结构进行表征并通过在输出层接入Softmax回归实现对类别的判别。

1、经典深度神经网络用于文本分类

- MLP是典型的前馈神经网络（FeedForward Neural Network，FFN），因其简单的全连接结构，不易建模自然语言文本中词之间的关联，尤其不易建模文本中的长距离依赖，因此通常不直接用于文本分类。
- CNN具有局部的组合性和多层特征抽象能力，多用于具有栅格（grid）结构的图像数据处理。
  - 有研究[Kim 2014]将CNN应用到文本分类任务，利用多个不同大小的卷积核（在CNN中用来提取特征）来提取句子中的关键信息（类似于多窗口大小的n-gram），从而更好地捕捉局部文本中词的相关性。

利用CNN进行文本分类的基本结构

- 以3×6的卷积核为例，得到的是一个3×1的矩阵，另一个维度也是3×1的矩阵，取矩阵中的最大值（最大池化，max-pooling），拼接起来形成一个特征向量，经过全连接层，使用softmax来对其进行分类，输出结果是类别标签的概率分布。

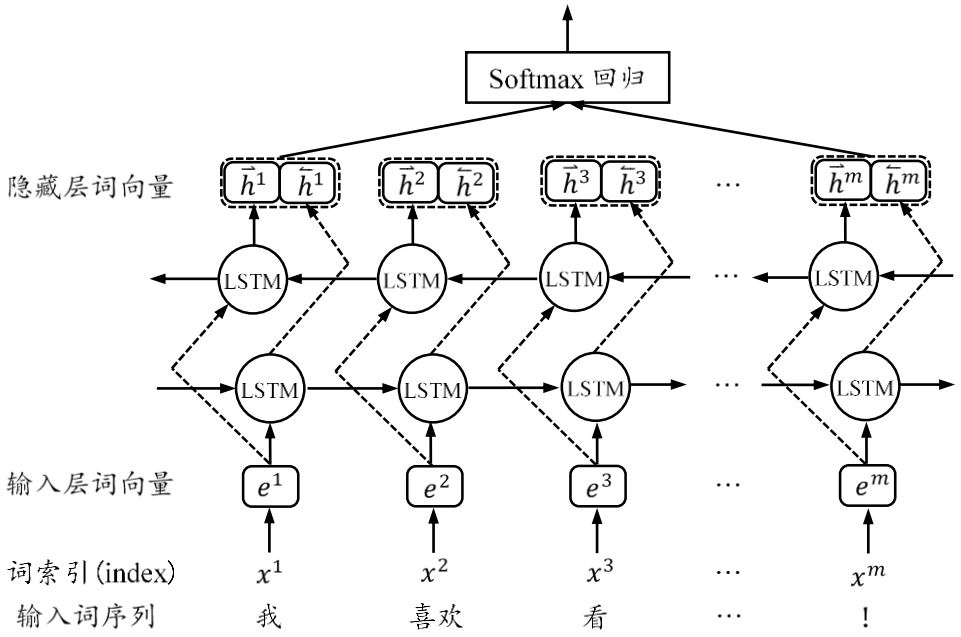


基于CNN的文本分类示意

- CNN用于文本分类的更主要的问题是：
  - 视野固定，不易建模长距离依赖（一般要通过构建更深层的卷积层来实现），其本质是做文本的特征表达工作——提取句子中类似n-gram的关键信息等；可以认为，CNN相对于文本句子来说，过于“均匀”了。
- 神经网络建模文本，首先会通过词嵌入层*（word embedding layer）*进行词的分布式表征。词向量可以通过word2vec、GloVe等词向量训练工具预先训练，然后在文本分类任务中微调。
- 如果用于分类的训练数据足够丰富，也可以随机初始化并和文本分类任务一并训练。低维稠密的实数向量表示，使得对词的语义关系如相似关系的建模成为可能，克服了统计模型的缺陷。

利用RNN建模文本网络

- RNN引入状态变量，存储过去的信息和当前的输入来确定当前的输出



一种基于Bi-LSTM的文本分类实现

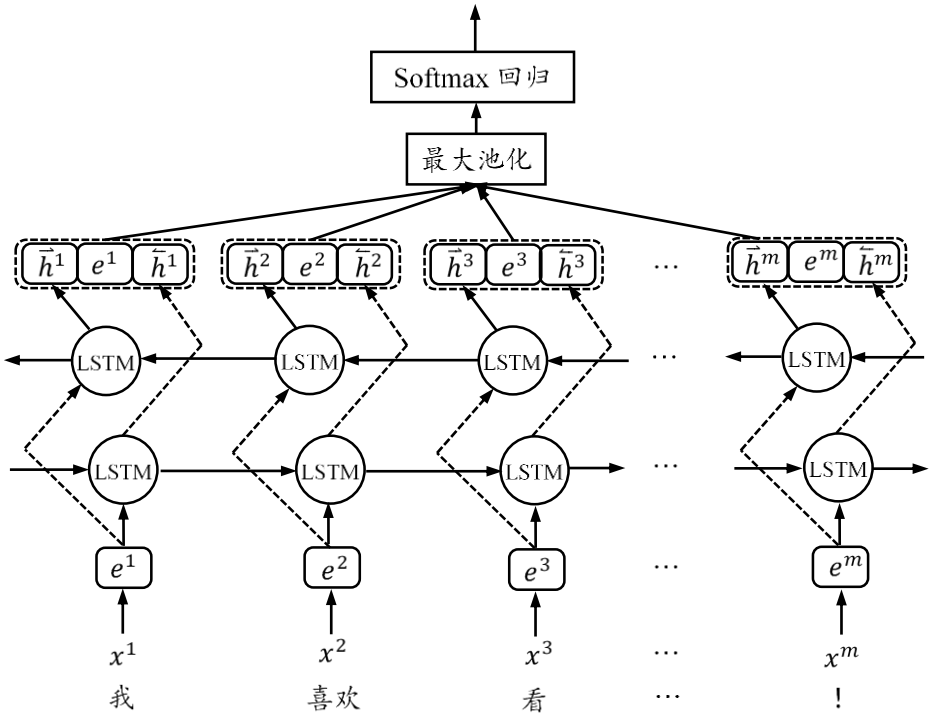
- LSTM是RNN的变种之一，它通过三个均以x^t和前一时刻隐藏层状态h^{t-1}为输入的“门”赋予RNN更大的自由度，缓解其长距离依赖问题。
- 在Transformer提出之前，LSTM特别是Bi-LSTM一直是编码文本的主流网络。
  - 编码层，基于Bi-LSTM的文本分类与其他自然语言理解任务没有大的区别，经过词嵌入层的词表示分别送入前向（forward）LSTM神经元和后向（backward）神经元，叠加对上文和下文的感知，使得文本的表征获得全局的结构化信息。
  - 输出层，首先将最后隐藏层词向量的首状态和尾状态拼接起来，作为文本序列的表示，然后通过softmax回归，将此单一文本表示转换为输出类别。

RNN 和 CNN

- 因为时间上的递归性，RNN是一个有偏差的模型，表现为后面的词比前面的词更占优势。因此，当它用于捕捉整个文本的语义时，可能会低效，因为关键的特征可能出现在文本的任何位置，而不是在文本的末尾。
- 而CNN是一个无偏差模型，它可以通过最大池化层公平地确定文本中有差别的成分如短语，从而更好地捕捉文本的语义。

RCNN模型

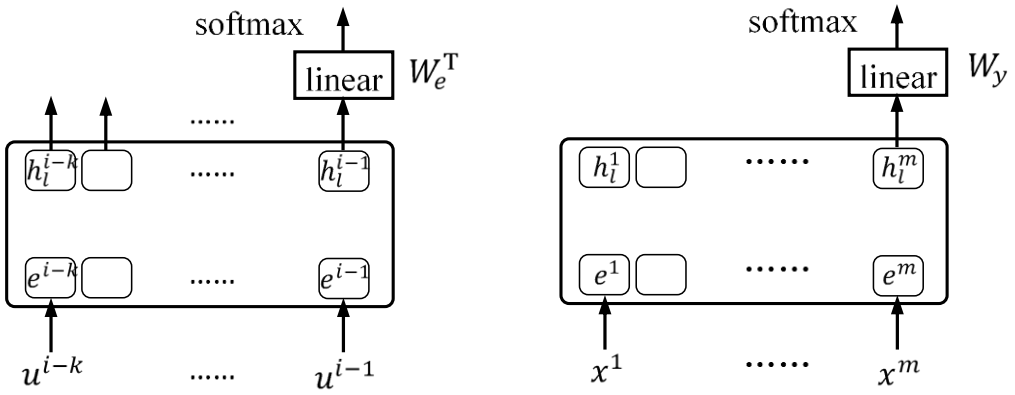
- 研究者[Lai 2015]结合RNN与CNN对文本建模的优势，提出RCNN模型（图13-5所示）：利用Bi-LSTM编码输入的文本，使用一个最大池化层（max-pooling layer）自动判断哪些特征在文本分类中起关键作用，以捕获文本中的关键成分。



2、预训练及大语言模型用于文本分类

- 2018年之后，自然语言处理领域的预训练-微调模式被提出并迅速席卷各项自然语言处理任务，成为新的范式。
  - 以GPT-1、BERT、ERNIE、BART等为代表的预训练模型，均以语言模型为主要的预训练任务，利用大量无标注数据，赋予以Transformer为核心架构的深度神经网络理解或生成自然语言的能力，从而更好地辅助下游任务的执行。
  - 预训练-微调范式主要在于设计什么样的预训练任务以及如何用于下游任务的微调。
  - 通常，每一个发布的预训练模型都会预定义好如何将其用于下游任务（相当于接口设计）。

GPT-1的预训练和文本分类微调

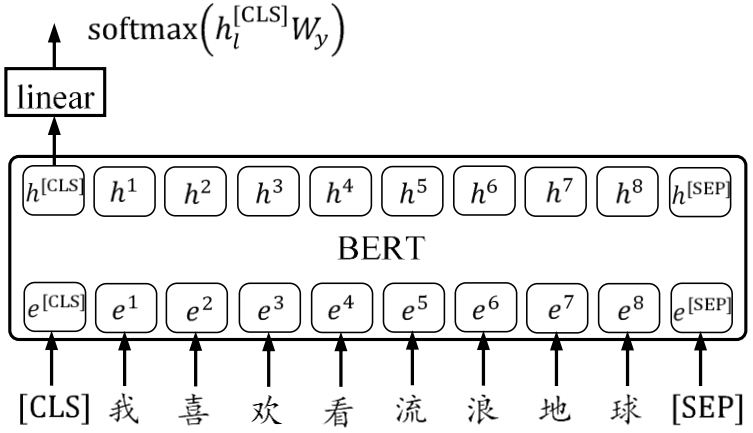


GPT-1的预训练和文本分类微调

- 微调的参数主要是词嵌入层和Transformer编码层，而输出层因下游任务和预训练任务不一致，映射矩阵形状不同，需要从头（随机初始化）开始训练。

BERT文本分类任务微调

- BERT预训练模型[Devlin 2018]以基于自编码的语言模型为预训练任务，同时利用上下文学习词元（token）的语义表示，在自然语言文本理解任务上可以取得更好的性能。
- 与GPT-1不同，BERT留给下游文本分类任务的接口不是输入文本的最后一个位置，而是文本序列前面的一个特殊位置（special token）：[CLS]。这是因为BERT预训练时利用NSP（next sentence predition）任务监督这一位置以便更好地建模文本的整体语义。



大模型时代

- （1）基于提示（prompt）的零样本（zero shot）学习：
  - 根据所使用的LLMs特点，设计合适的提示，完全利用LLMs预训练过程中学到的知识来推断文本的类别。
- （2）基于上下文学习（incontext learning）的少样本（few shot）学习：
  - 通过在提示中为 LLMs 提供每个类别的少量示例，来提高LLMs在目标任务上的适应性，从而提升分类精度。这是LLMs用于文本分类的常见做法，既可以通过示例明确任务范畴和形式，又无需担心因硬件、数据量和时间等限制导致无法微调。
- （3）微调：
  - 如果算力和数据量充足，可以尝试用目标领域的标注数据微调已有LLMs，更大程度上增强LLMs对文本分类任务的能力。

示例：

Prompt（zero shot）：

请根据以下文本内容判断其主题，从“科技”“体育”“娱乐”“财经”中选择一个最合适的主题类别。

文本："苹果公司发布了最新款 iPhone，具备更快的处理器和更强大的摄像功能。"
类别：[科技/体育/娱乐/财经]

Prompt（few shot）：

请根据以下文本内容判断其主题，从“科技”“体育”“娱乐”“财经”中选择一个最合适的主题类别。以下是几个示例：
示例 1：
文本："梅西在比赛中打入制胜一球，带领球队夺得冠军。"
类别：体育
示例 2：
文本："最新的漫威电影大获成功，全球票房突破 10 亿美元。"
类别：娱乐
根据以上示例分类：
文本："苹果公司发布了最新款 iPhone，具备更快的处理器和更强大的摄像功能。"
类别：[科技/体育/娱乐/财经]

基于零样本或少样本的提示，利用LLMs实现文本分类的示例

13.1.3 文本聚类

- 机器学习中的无监督学习主要包括聚类算法和降维算法。
- 文本聚类（text clustering）的基本假设是：
  - 同一类别的文本在语义或其他特征上具有较高的相似度，而不同类别的文本相似度较小。
  - 基于该假设，通过计算各个文本之间的相似度，将相近文本自动聚集在一起，这与有监督文本分类不同，文本聚类无需预先对文本手工标注类别，也无需模型训练。
  - 另一种被广泛和深入研究的无监督文本分析方法为主题模型（topic model），该方法用数学框架来建模文本的主题概率分布和字词在主题中的概率分布之间的关系，将文本的隐含语义结构（latent semantic structure）进行降维和聚类。

1、文本距离度量

- 最简单且直接的一类文本距离度量方法并不对文本进行编码或数学表示，而是直接基于文本字符串进行距离计算。
- 主要包括编辑距离、最长公共子序列、Jaccard相似度等
  - 编辑距离定义增、删、改三种编辑操作，通过计算由一个文本转换成另一个文本所需要的最少编辑操作次数，来衡量两个文本之间的距离
  - 最长公共子序列算法以两个文本的最长公共子序列的长度来表征文本的相似度，两个文本间的最长公共子序列越长，认为其相似度越高，距离越小。
  - Jaccard相似度则将文本看作词的集合，通过关注两个文本对应的单词集合之间的重合程度来衡量文本间的相似度。

基于向量空间的文本表示

- 另一类常用的文本距离度量方法基于向量空间的文本表示
  - 首先将文本通过词袋、词嵌入等模型编码为向量，再计算向量间的距离或相似度来实现文本之间的距离度量。
  - 常用的距离计算方式包括余弦相似度、欧式距离、曼哈顿距离等。
    - 对于两个文本的向量化表示x和y，其余弦相似度为：

$$\cos < x, y > = \frac{x \cdot y}{\|x\|\|y\|} = \frac{\sum_{i=1}^{n}(x_i \times y_i)}{\sqrt{\sum_{i=1}^{n}(x_i)^2} \times \sqrt{\sum_{i=1}^{n}(y_i)^2}}$$

    - 两个向量之间的余弦相似度越大，认为两个文本越相似，或距离越小。

- 长为n的向量x、y之间的欧氏距离是两个向量在维空间中所表示的点的真实距离，其数学公式为：

$$d = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}$$

  - 向量之间的欧氏距离越小，认为两个文本越相似，或距离越小。
- 类似地，也可用曼哈顿距离来衡量向量、之间的距离，其数学公式为：

$$d = \sum_{i=1}^{n} |x_i - y_i|$$

- 上述基于字符串或向量度量文本距离的方法存在一个较为明显的缺陷，即难以捕捉到相同语义的不同表达之间的关联性。

- 研究者们提出了基于语义计算的文本距离度量方法，来衡量文本语义之间的相似度，词移距离（Word Mover’s Distance，WMD）就是其中的代表性算法。
  - 对于两个文本x、y，WMD算法定义x、y间的词移距离为x中的词汇从欧式空间上分别移动到y中词汇的位置的距离总和。

$$\mathrm{WMD}(x,y) = \sum_{i,j=1}^{n} T_{ij}c(i,j)$$

  - 虽然WMD算法的表现更好，但由于其复杂度较高，在实际应用中，基于字符串和基于向量空间的文本距离度量方法仍然被广泛运用。

2、K均值算法及改进

- 基本思想：在K-means算法中，按照数据点间距离的大小，将数据集划分为个簇，使得每个簇内数据点之间的相似性尽可能大，簇间的数据点的相似性尽可能小。
- 具体方法：
  - 首先随机初始化个点为簇的质心，为簇数；
  - 每次迭代，将所有数据点划分给距其最近的质心所在簇，并重新计算所有新簇的质心，直到稳定或达到预先设定的最大迭代数。

K-means算法的流程：

K-means 算法的流程：

输入：包含n个数据点的数据集$D = \{d_1, d_2, ..., d_n\}$，聚类的簇数为$K$，最大迭代数为$N$；

输出：划分好的簇$C = \{C_1, C_2, ..., C_K\}$；

1.从数据集D中随机选择K个数据点作为K个簇的质心，这K个点分别记作：$\{a_1, a_2, ..., a_K\}$；

2.循环每次迭代的步骤，不超过N:

(1)初始化簇内数据点，即将C_i设置为空集，$i = 1, 2, ..., K$；

(2)对于每个数据点$d_1, d_2, ..., d_n$，计算数据点$d_j (j = 1,2, ..., n)$和每个质心$a_t (t = 1,2, ..., K)$的距离 $\text{distance}_{jt} = \|d_j - a_t\|_2^2$，将$d_j$加入到离它距离最小的质心所在的簇中；

(3)对于$t = 1,2, ..., K$，对C_t中所有的样本点重新计算更新过的簇的质心$a_t = \frac{1}{|C_t|}\sum_{d \in C_t} d$；

(4)若K个聚类簇的质心向量都不变，则转到步骤3，否则转到步骤2的开始部分；

3.输出划分好的簇：$C = \{C_1, C_2, ..., C_K\}$。

K-means++算法[Arthur 2006]

- 在选择初始的聚类中心时，遵循使初始聚类中心之间的距离尽可能大的原则，具体步骤为：

K-means++算法的流程：

1.随机从数据点中选取1个数据点作为第一个聚类中心；

2.计算并保存每个数据点d_i与离它最近的聚类中心的距离$D(d_i)$，并计算这些距离的和 $\text{sum}\left(D(d_i)\right)$；

3.根据$D(d_i)$较大的点被选取作为聚类中心的概率相对较大的原则，从不是聚类中心的数据点中选取新的数据点作为新的聚类中心。具体做法为：

首先在 0~ $\text{sum}\left(D(d_i)\right)$中随机选择一个值$r$，然后从$r$中逐步减去$D(d_i)$，$(i \in \{1,2,\dots,n\}$，$n$为数据集中数据点的个数)，当$r \leq 0$ 时，此时数据点i即为新的聚类中心。这种做法满足$D(d_i)$较大的点被选取作为聚类中心的概率相对较大的原则；

4.重复2、3，直至选出K个聚类中心；

5.将上述方法中选出的K个聚类中心作为K-means算法的初始聚类中心，再运行标准K-means算法。

- K-means聚类是一种硬聚类算法，即每一个数据点（候选文本）都只会被划分到唯一一个簇（类别）中，不适合多标签分类或者对那些处于类簇边缘的数据点不太友好。此时可以选择采用概率形式确定类别归属的高斯混合模型等。
- 此外，还可以根据具体需求选择层级聚类、密度聚类等多种聚类方法。

主要内容

- 13.1 文本分类与聚类
- 13.2 情感分析

13.2 情感分析

- 情感分析（sentiment analysis）本质上是一种文本分类任务，也是文本分类的重要应用领域。与主题分类或垃圾邮件识别等任务不同，其基本目标是识别和提取文本中所蕴含的主观情感倾向。在情感分析和情感检测中，核心概念包括：
  - （1）情感倾向：指文本、图像等信息中的情感方向，如积极、消极、中性等；
  - （2）情感强度：指情感倾向的程度，如轻度、中度、重度等；
  - （3）情感词汇：指表达情感的词汇，如“好”、“坏”、“喜欢”、“不喜欢”等；
  - （4）情感特征：指文本信息中与情感相关的特征，如词汇频率、词性、语义关系等。

13.2.1 词级情感分析

- 词级情感分析主要关注单个词语的情感倾向，一般通过构建情感词典，将情感信息赋予词语，为句子级和文档级的情感分析奠定基础。
- 词级情感分析的核心是构建情感词典。
  - 情感词典中的每个词语都被赋予了情感分值，通常分为正面（positive）、负面（negative）和中性（neutral）。
  - 例如，正面词语如“好”被赋予+1分值，负面词语如“坏”被赋予-1分值，中性词语如“一般”被赋予0分值。
  - 有了情感词典以后，文本情感判别最简单的一种方法，便是通过计算文本中所有词语的情感分值总和，得到整个文本的情感倾向性。

示例

- 对例句“这个电影真的非常好看”进行情感分析的流程如下：
  - 1. 分词：将句子分词，得到词语序列：“这个 电影 真的 非常 好看”，一共包含五个词：“这个”，“电影”，“真的”，“非常”，“好看”。
  - 2. 查找情感词：遍历每个词，发现“好看”在情感词典中的pos词典（表示积极情感的词典）中出现，因此pos_score的初始得分为1。
  - 3. 查找程度词：继续向前遍历，查看是否存在程度词。在情感词“好看”之前发现词“非常”，它在程度词列表中，属于较强的正向程度词，通常赋值为2倍，所以将pos_score乘以2，得到pos_score = 1*2 = 2。
  - 4. 查找否定词：继续向前查找否定词。在词“非常”之前是词“真的”，而“真的”并不是否定词，因此不改变分数。
  - 5. 计算情感得分：根据公式，pos_score - neg_score = 2 - 0 = 2，最终得分大于0，所以这个句子的情感判定为正向（pos）。

构建情感词典的方法

- 1. 人工构建情感词典
  - 人工构建词典是抓取数据之后进行多次人工标注，根据情感表达区分词语的正负向和强弱程度。
  - 比较典型的中文情感词典是台湾大学的中文情感极性词典（NTUSD）[Ku 2006]、知网（HowNet）情感词典和基于微博数据构建的极性词典[王勇 2014]等。
  - 尽管人工构建情感词典在词条扩充和使用便利性方面有一定的优势，但是人工构建成本较高，并且应用范围有限，不适合跨领域迁移。
- 2. 自动构建情感词典
  - （1）基于知识库的方法
  - （2）基于数据集的方法

自动构建词典方法

- （1）基于知识库的方法：
  - 利用完备的语义知识库（如WordNet）中词与词之间的关系，如同义、反义、上下位等，通过扩展方法来构建通用的情感词典。
  - 该方法的优点是能构建出通用性较强的情感词典，满足大部分情感分析任务需求。
  - 缺点是难以覆盖特定领域的情感词汇，领域适应性较差。
- （2）基于数据集的方法：
  - 利用大规模文本数据，通过学习词语的共现关系或连接关系，自动发现情感词汇并构建情感词典。
  - 其优点是能够针对特定领域构建领域情感词典，满足领域特定的情感分析需求；
  - 缺点是需要大量领域数据支持，构建过程较为复杂。

- 词级情感分析由于分析的粒度相对较小，一般不考虑句子上下文的含义。
- 但有时句子上下文对某个词的情感有着至关重要的作用，比如“你可真行啊，实验做得一塌糊涂”中的“真行”在这句话中表达了讽刺和负面情感。
- 因此更精确的文本情感分析还需依赖句子级和文档级的建模。

13.2.2 句子级与文档级情感分析

- 词级别情感分析研究的是如何给词赋予情感信息，而句子级和文档级情感分析研究的是如何给整个句子或篇章打情感标签，这些任务不仅需要考虑文本全局语义信息，还需要对文本复杂结构建模。
- 因此，它们不是简单的文本分类，有其独特的性质和挑战。

1 与文本分类不同之处

- 句子级和文档级情感分析与经典的文本分类任务有以下几个方面的差异：
  - （1）语言特征差异：情感表达具有更强的主观性，情感强度呈现连续性，同时还存在诸如讽刺、反讽等复杂的语言现象。这使得情感分析面临着比一般文本分类更大的挑战，例如可能需要对更复杂的语言结构建模等。
  - （2）任务目标差异：情感分析不仅需要识别文本的情感极性，还需要理解情感的程度和强弱，关注情感的持有者是谁。这与单纯的类别预测任务有一定区别。
  - （3）评价标准差异：情感分析需要考虑情感判断的模糊性和连续性，不能简单地采用标准的分类准确率。同时，还需要注重主观判断的一致性。

2 情感特征提取

- 主要包括以下常用特征:
  - （1）基本特征：
    - i.词法特征，如n-gram、词性序列、情感词频率等；
    - ii.句法特征，如依存关系、句法树结构、修饰关系等；
  - （2）情感特定特征：
    - i.情感词特征，如情感词密度、情感词序列、情感词聚合度等；
    - ii.语用特征，如否定词作用域、转折关系、语气词效果等；
- 这些特征从不同角度刻画了文本的情感语义和表达特点，在完成特征提取后，可以采用最大熵、SVM等判别式分类器进行情感分析。

3 基于结构文本表示的情感分析

- 文本主题分类主要是关注文本的宏观信息，将其归类至政治、体育、科技等宽泛类别，一般不需要考虑文本的复杂结构，因此即使是基于词袋模型的朴素贝叶斯方法，也能取得不错的分类效果。
- 要分析文本的情感倾向性，则需要考虑句法和语义结构，甚至文本中句子和句子间的修辞逻辑关系。
- 在概率统计范式下，句法结构特征曾被广泛用于句子的情感分析。
- 在深度学习范式下，采用适于复杂结构建模的神经网络，能够实现对复杂文本结构的有效表示学习。

4 情感分析新趋势和挑战

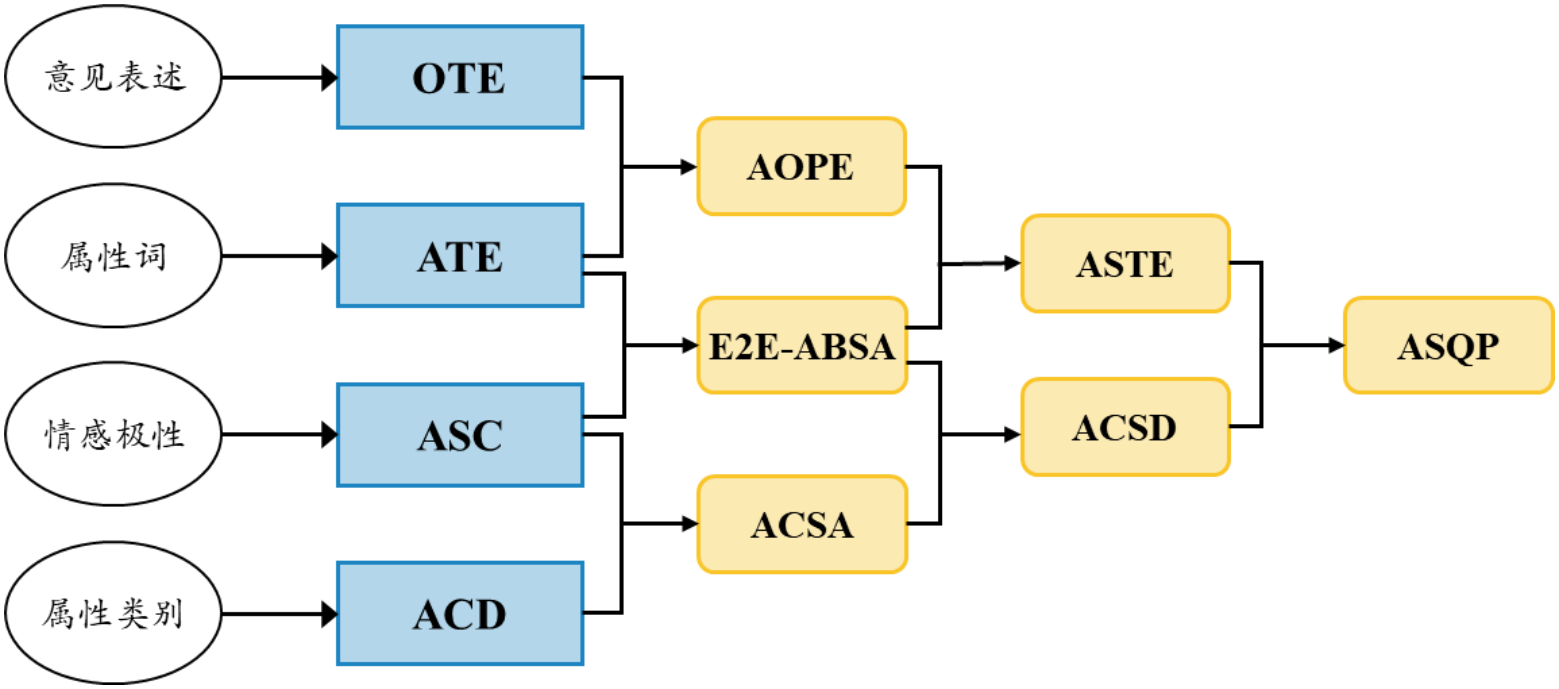
- 相比于传统的深度学习模型，大语言模型在情感分析任务上的优势如下：
  - （1）强大的上下文理解能力：大语言模型能够理解复杂的上下文关系，适用于情感分析中的隐含情感和复杂情感推断。
  - （2）丰富的世界知识：大语言模型在预训练过程中学习了大量世界知识，能够帮助模型在情感分析中理解更广泛的背景信息。
  - （3）多任务迁移学习能力：通过微调，大语言模型能够适应各种情感分析任务，包括极性分类、情感强度识别等。

13.2.3 属性级情感分析

- 属性级情感分析（Aspect-Based Sentiment Analysis，ABSA），或称方面级情感分析，引入了四种情感元素，任务本身基于这些元素来定义：
  - 属性词（aspect term）：给定文本中明确出现的意见对象，
    - 例如，“这个餐厅的比萨饼定价过高！”中的“比萨饼”。当意见对象为隐式表达时（例如，“它定价过高！”），通常将属性词设定为null等。
  - 属性类别（aspect category）：为了整理意见而预先设定的属性词类别。
    - 例如，在对餐厅的评论文本进行情感分析时可定义属性的类别是食物、服务、环境印象等等。例如，句子“这个餐厅的比萨饼定价过高！”中的属性词“比萨饼”属于食物一类。
  - 观点表述（opinion term）：意见词是发表意见者用来表达其对意见对象情感的表述。
    - 例如句子“这个餐厅的比萨饼定价过高！”中的“定价过高”即为观点表述。
  - 情感极性（sentiment polarity）：情感极性指的是评论文本中蕴含的发表意见者的褒贬倾向。在通用领域常规设定是在积极、消极和中性三类中取一类。
    - 例如句子“这个餐厅的比萨饼定价过高！”情感极性为消极。（普遍意义上的情感分析主要就是指情感极性的判别。）

代表性属性级情感分析子任务关系

- 基于识别和提取的情感元素的不同，属性级情感分析可分为不同的子任务。

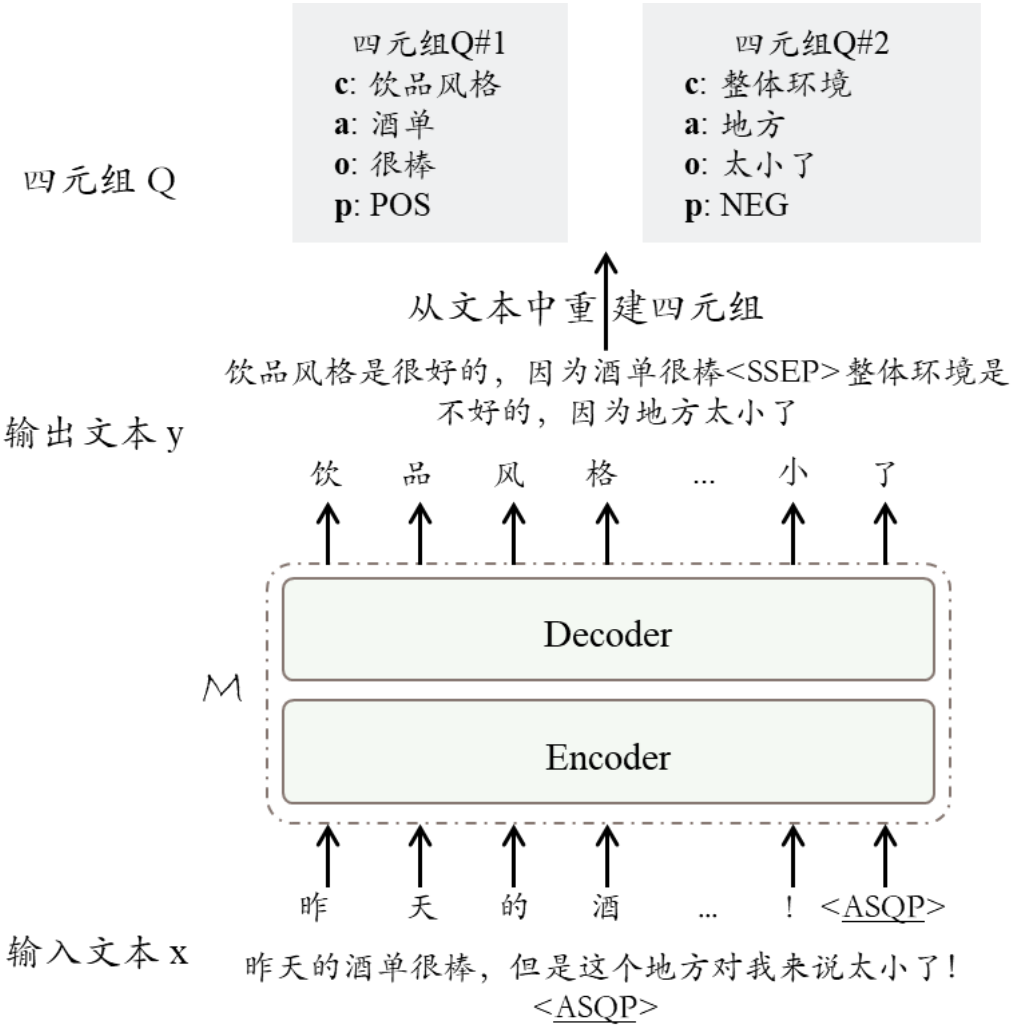


- 简单属性级情感分析代表性的任务有
  - 观点提取（Opinion Term Extraction，OTE），
  - 属性词提取（Aspect Term Extraction，ATE），
  - 属性情感分类（Aspect Sentiment Classification，ASC）
  - 属性类别检测（Aspect Category Detection，ACD）；
- 复合属性级情感分析主要是：
  - 属性观点对提取（Aspect-Opinion Pair Extraction，AOPE），
  - 端到端属性级情感分析（end-to-end ABSA），
  - 属性类别情感分析（Aspect Category Sentiment Analysis，ACSA），
  - 属性情感三元组提取（Aspect Sentiment Triplet Extraction，ASTE），
  - 属性类别情感检测（Aspect Category Sentiment Detection，ACSD）
  - 属性情感四元组预测（Aspect Sentiment Quad Prediction，ASQP）等。

属性级情感分析的解决方案

- 流水线（pipeline）解决方案：采用相应的方法分别解决每个情感分析任务；
  - 可以胜任单一情感元素提取任务，但是难以处理不同情感元素之间存在较为复杂相关关系的情况，此外，误差累积等问题影响性能
- 端到端（end-to-end）的解决方案：整体优化
- 端到端的属性级情感四元组预测任务（ASQP）：
  - 给定文本x，属性级情感四元组预测旨在预测所有相对应的属性类别（c）、属性词（a）、意见表述（o）和情感极性（p）构成的四元组集合。
  - 相比简单的属性级情感分析，该任务输出更为复杂，采用序列到序列（seq2seq）方法完成。

序列到序列方法解决ASQP问题示例



3 当代属性级情感分析新挑战

- 属性级情感分析在这一背景下面临着新的挑战，即数据类型、数据结构和数据来源变得复杂多样。
  - 用户在反馈评论时可以附图片甚至短视频来表达自己的意见，有些用户甚至以短视频等纯视觉的形式，在流媒体平台上表达对于产品或服务的看法。这些多样化的表达方式大大增加了情感分析任务的复杂性和技术难度。
- 大语言模型的出现，也给属性级情感分析带来了新的解决思路。
  - 大语言模型能够靠丰富的知识和强大的逻辑能力准确理解蕴含在评论文本背后的情感倾向，在效果上远强于传统方法，但同时计算成本很高。
  - 如何以较低的计算成本，利用大语言模型完成情感分析任务被人们所关注。