哈尔滨工业大学

自然语言处理

实验报告

(2026 年秋季学期)

姓名：	邴海诺、高新来
学号：	2024112353、2024112774
学院：	计算学部
教师：	杨沐昀

实验二：基于 Transformer 神经机器翻译建模与优化

——参数调优与编码器局部性偏置

摘要 我们在 WMT18 英汉平行语料（252,385 个句对，共享词表 38,814 项）上复现了 63,976,448 个参数的 Transformer 基线，并在 10 epoch 预算内完成参数调优和代码级改进。评测前发现默认的 `max_length = 256` 会过滤 newstest2018 的第 1415、3708 句，若直接与未过滤参考比较，译文从第 1415 行起整体错位。我们改用对齐参考，并同时保留课程口径：基线在对齐口径下 newstest2017/2018 BLEU 为 10.24/11.31，课程口径下 2018 为 4.65。调参实验中，把预热缩短到 4000 步对 2017 最有利（+0.35），但 2018 仅 +0.01；降低标签平滑、组合配置和增大束宽都使 2018 变差。四个种子的基线重训极差达到 0.93/1.07，因此改进采用同种子成对比较。改进方法在全部 6 层编码器自注意力上叠加 T5 分桶相对位置偏置和 Yang 等（2018）的查询相关高斯局部性偏置，仅增加 1,626,768 个参数（+2.5%）。四个种子下，相对同种子基线的 2018 BLEU 平均提升 +0.26（3/4 为正），2017 为 +0.11（3/4 为正）；训练后的窗口统计显示深层窗口更窄、中心随查询移动，改进模型的译文重复率和长度比也有下降。

关键词 神经机器翻译；Transformer；局部性建模；相对位置偏置；BLEU；PaddlePaddle

1 任务与数据

实验在英汉方向上构建端到端翻译系统。训练语料为 WMT18 英汉平行数据（Bojar 等, 2018），共 252,385 个句对，已经过 tokenization 和清洗。BPE 合并规模为 32,000，词表文件还包含特殊符号与未参与合并的字符，最终共享词表为 38,814 项，源端和目标端共用同一词表，因此嵌入层与输出投影可以共享权重。测试使用 newstest2017（2,001 句）和 newstest2018（3,981 句）。

翻译质量用 mosesdecoder 的 `multi-bleu.perl` 计算：统计 1–4 gram 精度，取几何平均后乘以长度惩罚因子 BP。解码结果先去掉 BPE 续接符 `@@`，再与 `newstest20XX.tok.zh` 参考答案比对。

评测时有一个会直接影响分数的问题。`transformer.yaml` 的 `max_length = 256` 会在预测阶段过滤超长句；newstest2018 的第 1415、3708 句源文分别为 293 和 279 个 BPE 词元，因此被跳过，输出只有 3,979 行。`multi-bleu.perl` 只读取与假设行数相同的参考，但前 3,979 行参考并没有剔除这两句，于是从第 1415 行开始，每条译文都对应到后一句的参考，BLEU 被严重压低。我们从参考中删掉同样的两句，得到 3,979 个一一对应的句对（`ref_len = 89721`），下称对齐口径；课程原始口径仍按未过滤参考计算，只用于和课程给出的 4.46 比较。newstest2017 没有超长句，两种口径一致。课程修正版 `reader.py` 的过滤结果与本文脚本逐行一致（同为 3,979 行）。

2 方法

2.1 基线模型

基线是标准的 Transformer base（Vaswani 等，2017）：编码器和解码器各 6 层，每层 8 个注意力头，$d_{\text{model}} = 512$，前馈隐层 2048，$d_k = d_v = 64$。子层采用 Pre-LN（先对输入做 LayerNorm），dropout 为 0.1；源词嵌入、目标词嵌入和输出投影三处共享权重，位置信息由正弦绝对位置编码提供。按 38,814 的词表计算，参数量为 63,976,448。

训练参数沿用项目默认值：按词元数组批，每批最多 4096 个词元（含填充）；Adam 优化器（$\beta_1 = 0.9$，$\beta_2 = 0.997$，$\varepsilon = 10^{-9}$）；Noam 学习率，系数 2.0、预热 8000 步，峰值约 1.0×10^{-3}，之后按步数的平方根倒数衰减；标签平滑 0.1；训练 10 个 epoch（约 18,400 步），每 5000 步保存检查点，最后用 `step_final` 解码。解码用束搜索，束宽 5，最大输出长度 255 个 BPE 词元。

2.2 性能分析实验设计

10 个 epoch 只有约 18,400 步，远少于原论文训练 base 模型的 10 万步（Popel 与 Bojar，2018；Chen 等，2018）。训练预算受限时，学习率调度和正则化强度的作用会和标准设置不同，因此我们选了四个因素做单因素实验：

（1）学习率系数（lr3）。Noam 调度的峰值学习率与基础系数成正比。把系数从 2.0 提到 3.0（峰值约 1.5×10^{-3}），看固定步数下能否在衰减前走到更远的参数区域。

（2）预热步数（warmup4k）。基线预热 8000 步，占总步数的 43%，衰减阶段只剩约 10,400 步。把预热缩短到 4000 步；由于 Noam 峰值与 $\sqrt{\text{warmup}}$ 成反比，峰值同时升到约 1.4×10^{-3}，所以这个实验实际检验的是“更短预热 + 更长衰减”的整体调度形状。

（3）标签平滑（ls05）。标签平滑（Szegedy 等，2016）把目标分布和均匀分布混合，抑制模型过度自信。基线取 0.1，这里降到 0.05，看在固定轮数下减弱正则是否更有利于拟合。

（4）解码束宽（beam10）。束搜索不改变参数，只把束宽从 5 提到 10，检查扩大搜索空间是否还有收益。

之后把三项训练端改动合成 combo，看收益能否叠加。BLEU 是离散的语料级指标，单次训练的差异可能来自初始化或数据顺序，因此另外用 23、42、7、123 四个种子重训基线，改进实验与同种子基线配对比较。

2.3 编码器局部性偏置改进

注意力打分只由内容向量的点积决定，绝对位置编码在第一层之后只以加性方式进入表示，注意力本身没有距离先验。相对位置表示（Shaw 等，2018）把键和查询的距离直接加入打分，T5（Raffel 等，2020）用分桶把任意距离压到有限个桶里。Yang 等（2018）进一步让每个查询预测一个高斯窗的中心和宽度，在 WMT17 英汉上把 base 模型从 24.13 提到 24.77，再加相对位置后达到 24.96。我们采用这一组合，加在编码器自注意力上。

相对位置偏置。对位置 i 的查询和位置 j 的键，令距离 $d=j-i$，用 32 个桶编码：正负方向各 16 个，绝对距离 0–7 逐距离精确分桶，8 以上按对数间隔映射，超过 128 归入最后一个桶。每层、每个头有一张独立的零初始化偏置表 $B_l^m(\text{bucket}(d))$。第 l 层第 m 个头的注意力打分改为

$$e_{ij}^m=\frac{\boldsymbol{q}_i^m\cdot\boldsymbol{k}_j^m}{\sqrt{d_{\text{model}}}}+B_l^m(\text{bucket}(j-i))+G_{ij}^m,$$

其中 G_{ij}^m 是下面的局部性偏置。项目沿用原始实现的缩放方式，分母用 d_{model} 而不是每头维度 d_k；我们保持这一设置，使所有模型处于同一缩放尺度。

查询相关高斯窗。设源句长度为 I，第 l 层的查询表示为 $\boldsymbol{h}_i$。先做共享变换 $\boldsymbol{g}_i=\tanh\big(\boldsymbol{W}_p\boldsymbol{h}_i\big)$，再由每个头自己的投影预测窗口中心 P_i^m 和宽度 D_i^m：

$$P_i^m=I\cdot\text{sigmoid}\big(\boldsymbol{u}_p^m\cdot\boldsymbol{g}_i\big),\quad D_i^m=I\cdot\text{sigmoid}(\boldsymbol{u}_d^m\cdot\boldsymbol{g}_i).$$

取标准差 $\sigma_i^m=\frac{D_i^m}{2}$，该头对键位置 j 的打分修正为

$$G_{ij}^m=-\frac{(j-P_i^m)^2}{2(\sigma_i^m)^2}\cdot s_l^m,$$

其中 s_l^m 是每个头可学习的尺度。长度 I 取掩码统计出的真实源句长度，而不是填充后的批长度，这样不同长度的句子处在同一个相对坐标系里。

初始化需要说明一下。中心与宽度投影 $\boldsymbol{u}_p^m,\boldsymbol{u}_d^m$ 零初始化，所以训练起点处 $P_i^m=D_i^m=\frac{I}{2}$，高斯窗以句中央为中心、标准差 $\frac{I}{4}$，是一个覆盖整句的宽窗，并不是零偏置。基线用 $d_{\text{model}}^{-0.5}$ 缩放 logits，Yang 等用的是标准 $d_k^{-0.5}$，同样的高斯偏置在前者中相对更强。为了让初始偏置与基线 logits 处于同一量级，我们把每头尺度初始化为 $\sqrt{\frac{d_k}{d_{\text{model}}}}\approx0.354$（若用标准缩放则初始化为 1.0）。该初始化下，4 个种子的平均步 0 损失为 11.094，基线为 11.102，第 100 步均为 9.383，训练动态没有被破坏。

Yang 等只在编码器前 3 层加局部性偏置，其消融中前 3 层（23.29）优于全部 6 层（23.13）。但在我们的数据与预算下结论相反：对最终采用的“相对位置 + 局部性”组合，同种子下 6 层在两个测试集上都优于 3 层（10.95/11.54 对 10.67/11.26，见 4.3 节），所以最终把局部性偏置加在全部 6 层编码器上。

改动只增加编码器参数。每层的局部性模块包含 $512\times512+512$ 的共享变换、2 组 $512\times8+8$ 的投影和 8 个尺度，共 270,872 个参数；6 层合计 1,625,232 个，加上每层 32×8 的相对位置表（共 1,536 个），总计 1,626,768 个，相对基线增加 2.5%。解码端和束搜索没有改动，推理超参数与基线完全一致。

3 实验设置

训练和解码在百度 AI Studio 的免费算力上完成（单卡 NVIDIA Tesla V100-SXM2-16GB，16 GB 显存），软件环境为 Python 3.11 和 PaddlePaddle 3.3.1（CUDA 12.6；Ma 等，2019）。每个训练任务约 51–54 分钟（5.6–6.0 step/s），两个测试集的解码和 BLEU 评测另需约 5–10 分钟。除 2.2 节和 2.3 节的因素外，所有实验共用同一份数据、词表、模型结构和训练轮数；解码批大小为 64，束宽 5，最大输出长度 255。基线配置见表 1，原始训练日志、BLEU 日志和评测脚本随代码提交，报告中的数值可以逐项复算。

项目	取值	说明
编码器 / 解码器层数	6 / 6	Pre-LN，dropout 0.1
注意力头数	8	$d_k = d_v = 64$
模型维度 / 前馈维度	512 / 2048	嵌入、输出与源端共享权重
批大小	4096	按词元数组织（含填充）
训练轮数	10	约 18,400 步
优化器	Adam	$\beta_1 = 0.9$，$\beta_2 = 0.997$，$\varepsilon = 10^{-9}$
学习率调度	Noam	系数 2.0，预热 8000 步，峰值约 1.0×10^{-3}
标签平滑	0.1	混合均匀分布的强度
检查点间隔	5000 步	最终模型为 `step_final`
解码	束宽 5	批大小 64，最大输出长度 255

表 1　基线模型结构与训练超参数

4 结果与分析

4.1 基线复现与评测口径

基线训练 10 epoch 后，对齐口径的 BLEU 在 newstest2017 上为 10.24，在 newstest2018 上为 11.31（1–4 gram 精度 42.2/15.7/7.1/3.5）。两个测试集的长度惩罚因子都是 1.000，ratio 分别为 1.035 和 1.054，译文整体略长于参考但没有触发惩罚。2018 的译文长度为 94,571，对齐参考长度为 89,721，多出的约 5% 主要是中文译文里的重复表达。同一批译文按课程口径只有 4.65（23.8/5.8/2.6/1.3），比课程参考值 4.46 高 0.19；两个数都受错位影响，只能互相比较。

测试集	BLEU	1–4 gram 精度	BP	ratio	hyp/ref 长度
newstest2017（对齐）	10.24	40.7/14.5/6.3/3.0	1.000	1.035	48778/47144
newstest2018（对齐）	11.31	42.2/15.7/7.1/3.5	1.000	1.054	94571/89721
newstest2018（课程口径）	4.65	23.8/5.8/2.6/1.3	1.000	1.051	94571/90019
2018 参考值（课程口径）	4.46	23.3/5.7/2.5/1.2	1.000	1.087	97832/90019

表 2　基线模型在两个测试集上的 BLEU 及分解指标（2018 同时给出对齐口径与课程口径）

4.2 调参实验与随机种子

表 3 列出四个单因素实验和 combo 的结果。三项训练端改动都提高了 2017：warmup4k 最多（+0.35），ls05 和 lr3 分别为 +0.29 和 +0.23。但 2018 上只有 warmup4k 基本持平（+0.01），lr3 下降 0.20，ls05 下降 0.45。combo 在 2017 上到 10.63（+0.39），2018 却只有 11.00（-0.31），说明提高学习率和减弱标签平滑叠加后没有带来跨测试集的收益。束宽从 5 增到 10 后两个测试集同时下降（-0.07/-0.43），在这个低 BLEU 的英中任务上，扩大搜索空间没有帮助。

实验	改动	BLEU 2017	BLEU 2018	Δ2017	Δ2018
baseline	—	10.24	11.31	—	—
lr3	学习率系数 2.0 → 3.0	10.47	11.11	+0.23	−0.20
warmup4k	预热 8000 → 4000 步	10.59	11.32	+0.35	+0.01
ls05	标签平滑 0.1 → 0.05	10.53	10.86	+0.29	−0.45
combo	lr3 + warmup4k + ls05	10.63	11.00	+0.39	−0.31
beam10	束宽 5 → 10	10.17	10.88	−0.07	−0.43

表 3　参数调优实验的 BLEU（2018 为对齐口径；差值为相对默认基线）

这些 0.2–0.5 的差异要放到种子波动里看。四个种子的基线在 2017 上是 10.23–11.16（极差 0.93），在 2018 上是 10.24–11.31（极差 1.07），仅换种子造成的波动就超过表 3 里最大的单次调参差异。所以表 3 不能单

独用来判断某个因素的好坏，ls05 和 beam10 的下降也不能完全排除随机性。这里能比较稳妥地说的规律有两条：一是 2017 和 2018 对同一改动的反应经常相反，例如 lr3 和 ls05 都是 2017 升、2018 降；二是把三项训练端改动叠加并不会让收益相加，combo 的 2017 最高，但 2018 仍比基线低 0.31。可能的原因是 2018 的句子更长（平均源句 32.8 个 BPE 词元，超过 50 词元的有 550 句，2017 只有 181 句），在短预算下提高学习率、减弱正则更容易破坏长句的建模。这个解释只是从现有结果推断，还没有单独验证。

4.3 改进模型结果

先看种子 23 下的结构消融（表 4）。单独加相对位置偏置在两个测试集上都略低于基线（2017 −0.06，2018 −0.12）；单独在 3 层加局部性对 2018 有 +0.10，但 2017 为 −0.16；把局部性扩到 6 层后 2018 到 +0.40，2017 仍是 −0.20。两者组合后收益最大：3 层组合为 2018 +0.25、2017 −0.11，6 层组合为 2018 +0.53、2017 +0.17，是表中唯一在两个测试集上同时为正的配置。另一个负对照是把注意力缩放改成标准的 $d_k^{-0.5}$（不加偏置），BLEU 为 10.37/10.78，分别下降 0.41 和 0.23；这说明基线缩放不该在改进里顺手改掉，也说明局部性偏置的尺度校准是必要的。

配置	2017	2018	Δ2017	Δ2018
基线（无偏置）	10.78	11.01	—	—
+ 相对位置偏置（6 层）	10.72	10.89	−0.06	−0.12
+ 局部性（前 3 层）	10.62	11.11	−0.16	+0.10
+ 相对位置 + 局部性（前 3 层）	10.67	11.26	−0.11	+0.25
+ 局部性（全部 6 层）	10.58	11.41	−0.20	+0.40
+ 相对位置 + 局部性（全部 6 层）	10.95	11.54	+0.17	+0.53

表 4　同种子（23）下的结构消融（2018 为对齐口径；差值为相对同种子基线）

单种子结果只能用来选结构，最终结论看四个种子的成对比较（表 5）。组合配置在 2018 上平均 +0.26，样本标准差 0.38，四个种子中三个为正（-0.30、+0.53、+0.36、+0.44）；2017 上平均 +0.11，标准差 0.52，也是三个为正。只加局部性（全部 6 层）在 2018 上平均 +0.07（标准差 0.60，2/4 为正），2017 上平均 −0.30（1/4 为正）。可见相对位置偏置不是可有可无的附加项：它给注意力一个与内容无关、全句共享的距离先验，局部性窗口在短预算下才不至于只拟合少数位置模式。但即使加上它，单个种子仍可能为负（种子 123 的 2018 为 −0.30），0.2–0.4 量级的效应需要多种子平均才看得出来。图 1 画出了同一组比较，2018 上组合组有 3 个点高于对应基线，只加局部性的组只有 2 个；2017 上两组点都落在基线两侧，组间差异和种子波动差不多大。

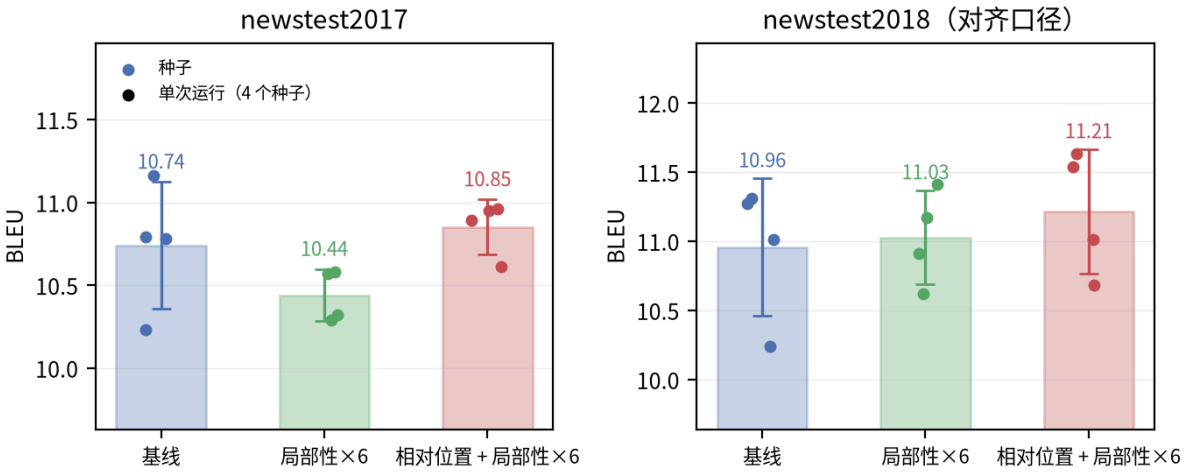


图 1　三组配置在各随机种子下的 BLEU（柱为均值，误差线为样本标准差，圆点为单次运行）

配置	2017 均值±std	2018 均值±std	Δ2017	Δ2018
基线	10.74±0.38	10.96±0.50	—	—
+ 局部性（全部 6 层）	10.44±0.16	11.03±0.34	−0.30±0.50	+0.07±0.60
+ 相对位置 + 局部性（全部 6 层）	10.85±0.16	11.21±0.45	+0.11±0.52	+0.26±0.38

表 5　4 个随机种子的成对比较（2018 为对齐口径；Δ 为同种子改进减基线）

从 n-gram 分解看，改进带来的变化分散在各阶精度上，不只是词汇覆盖。以种子 23 的 2018 为例，1–4 gram 精度从基线的 41.4/15.2/6.9/3.4 升到 42.5/15.8/7.3/3.6，长度比从 1.071 降到 1.039，句内四元重复率从 1.83% 降到 1.01%；2017 上前三阶精度上升、4-gram 持平，长度比从 1.038 降到 1.022，重复率从 0.96% 降到 0.86%。只加局部性的 loconly6 没有这个效果：它在 2018 上的长度比 1.058、重复率 1.87%，和基线差不多。也就是说，相对位置和查询窗口一起使用时，精确率和译文紧凑度才同时改善。一个直观的例子是 2018 中的短句 “Kelly is trying to do the same thing, three months later.”，参考为「凯利打算做同样的事，在三个月后。」；基线输出「凯利也在做同样的事情，三个月后又开始做同样的事情。」，把「做同样的事情」重复了一遍；改进模型输出「凯利正在试图做同样的事情，三个月后。」，冗余消失，长度也更接近参考。

2017 上的结果要谨慎。组合配置的逐种子增益是 +0.10、+0.17、-0.55、+0.73，平均 +0.11，标准差 0.52，种子波动比 2018 更大，不能排除个别种子上的负增益。能下的结论是：这种显式距离先验在 2018 上平均有 +0.26 的收益、3/4 种子为正；在 2017 上只能算与基线相当。两个测试集的差异与 2018 句长更大、长句更多是一致的，但现有实验还解释不了全部原因。

训练动态方面，图 2 是三组配置按种子平均后的训练损失（指数滑动平均）。三条曲线在训练过程中几乎重合，终值都在 3.1 附近，说明改进没有改变收敛行为，BLEU 差异来自注意力结构本身，而不是训练是否充分。

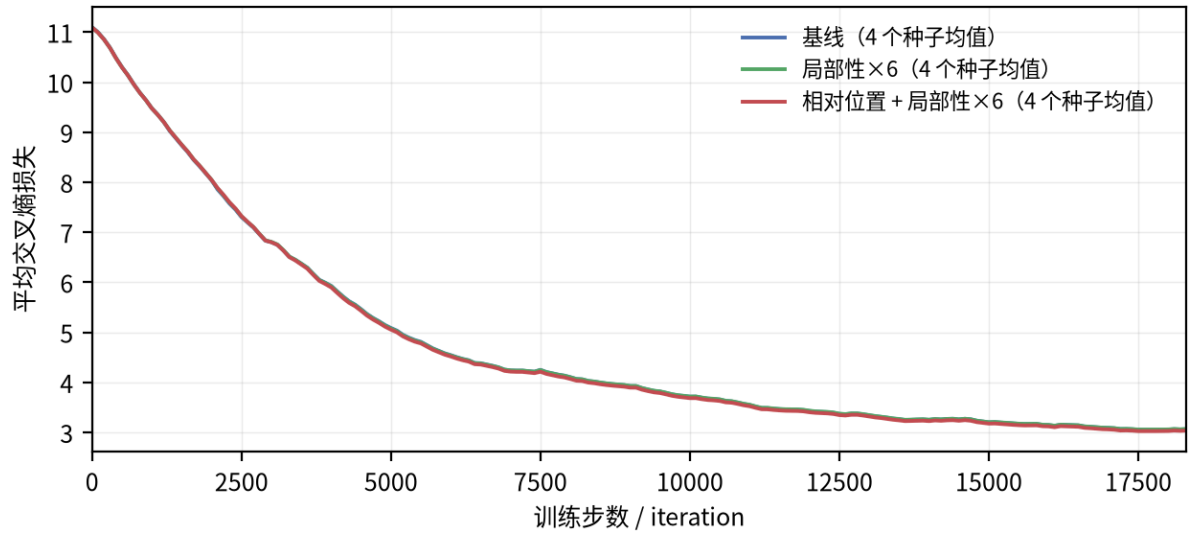


图 2　三组配置的平均训练损失曲线（各种子均值，指数滑动平均平滑）

4.4 学到的局部窗口

为了确认局部性模块没有退化成常数或噪声，我们把种子 23 的 `step_final` 载入改进模型，在 newstest2017 的 200 个句子上逐层、逐头导出窗口参数（`scripts/analyze_localness.py`）。图 3 给出每层 8 个头按句长归一化的平均窗口宽度、中心偏移和平均尺度。三个量都随层深变化：第 0 层窗口最宽（平均 0.92 个句长，8 个头都高于 0.84），中心偏移最大（0.34），尺度最小（0.25）；第 3、5 层窗口收窄到 0.75 和 0.74，中心偏移降到 0.19，部分头的宽度只有 0.63–0.65。第 4 层有回升（宽度 0.91、偏移 0.27），所以变化不是严格单调的，但总体上是浅层宽而弱、深层窄而强。尺度从第 0 层的 0.25 升到第 1 层的 0.54，之后稳定在 0.42–0.48，说明局部性约束主要在深层起作用，第 0 层仍以内容和相对位置信息为主。同一层内各头的差异比层间还大：第 2 层的 8 个头宽度从 0.62 到 0.99，尺度从 0.19 到 0.61；第 4 层尺度覆盖 0.16–0.78。模型没有学成所有头共用一个固定邻域，而是让不同头承担不同宽度的上下文。

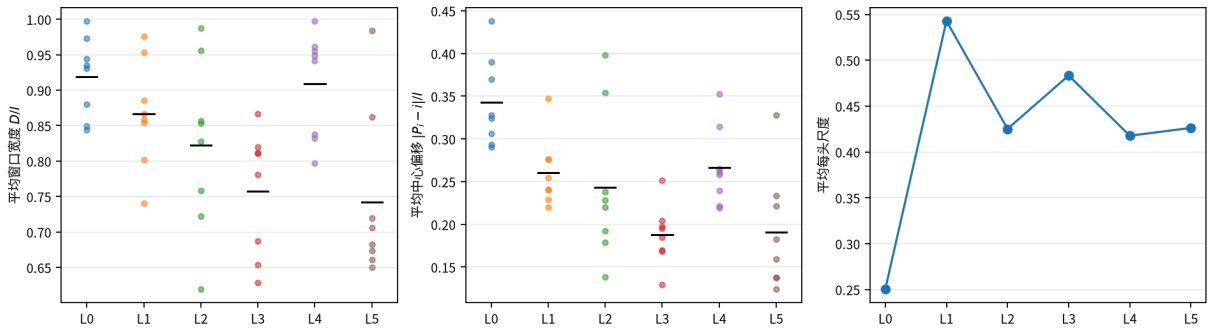


图 3　训练后各层各头的局部性窗口统计（每点为一个头，横线为该层均值）

4.5 讨论与结论

综合调参和改进两组实验，有三点值得记录。第一，固定 10 epoch 时，种子方差比多数调参效应都大：基线在 2018 上跨 1.07 个 BLEU，而表 3 中最大的单次调参差异只有 0.45。不采用同种子成对比较，0.2–0.5 量级的改动很可能只是重新抽了一次种子。第二，评测口径对 2018 的绝对值影响很大，但对同一口径下的成对比较没有影响；对齐参考是让分数可解释的前提，课程参考值只能和课程口径比较。第三，改进是否有效要看跨种子的均值和一致性，而不是单次最好结果。我们的相对位置 + 局部性组合在 2018 上平均 +0.26±0.38（3/4 种子为正），2017 上 +0.11±0.52（3/4 为正），是本文尝试的配置中唯一在两个测试集上平均都为正的；但它只增加 2.5% 的参数，优势幅度有限，单个种子仍可能低于基线。局限也很明显：每个配置只有 4 个种子，2017 的估计不精确；改进只在编码器侧；10 epoch 的预算也限制了对更长训练的推断。

5 参考文献

[1] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems 30 (NIPS 2017). Long Beach: Curran Associates, 2017: 5998–6008.

[2] Shaw P, Uszkoreit J, Vaswani A. Self-attention with relative position representations[C]//Proceedings of NAACL-HLT 2018. New Orleans: ACL, 2018: 464–468.

[3] Raffel C, Shazeer N, Roberts A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer[J]. Journal of Machine Learning Research, 2020, 21(140): 1–67.

[4] Yang B, Tu Z, Wong D F, et al. Modeling localness for self-attention networks[C]//Proceedings of EMNLP 2018. Brussels: ACL, 2018: 4449–4458.

[5] Popel M, Bojar O. Training tips for the Transformer model[J]. The Prague Bulletin of Mathematical Linguistics, 2018, 110(1): 43–70.

[6] Szegedy C, Vanhoucke V, Ioffe S, et al. Rethinking the Inception architecture for computer vision[C]// Proceedings of CVPR 2016. Las Vegas: IEEE, 2016: 2818–2826.

[7] Chen M X, Firat O, Bapna A, et al. The best of both worlds: Combining recent advances in neural machine translation[C]//Proceedings of ACL 2018. Melbourne: ACL, 2018: 76–86.

[8] Bojar O, Federmann C, Fishel M, et al. Findings of the 2018 conference on machine translation (WMT18) [C]//Proceedings of the Third Conference on Machine Translation, Volume 2: Shared Task Papers. Brussels: ACL, 2018: 272–307.

[9] Ma Y, Yu D, Wu T, et al. PaddlePaddle: An open-source deep learning platform from industrial practice[J]. Frontiers of Data and Computing, 2019, 1(1): 105–115.

实验成绩：_____

教师签名：_____