

自然语言处理 C 实验 II

基于 Transformer 神经机器翻译建模与优化

计算学部人工智能学院

2026 年秋季学期

一、实验目标

本次实验目的是掌握基于 Transformer 构建一个英汉机器翻译模型，包括数据预处理、模型训练、翻译解码实现、模型评价与性能分析、模型优化与改进等环节。

本次实验所要用到的知识如下：

- 基本编程能力（文件处理、数据统计等）
- 自然语言处理知识
- 机器学习与深度学习知识
- Transformer 模型相关知识
- 机器翻译技术相关知识

本实验分两部分完成：

- 第一部分：基于深度学习的机器翻译建模，包含 3.2-3.5 的实验内容。
- 第二部分：基于深度学习的机器翻译模型优化，包含 3.6-3.7 的实验内容。

二、实验环境和算力配置介绍

本次实验基于 Paddlepaddle 深度学习框架（https://www.paddlepaddle.org.cn/ ）完成，实验过程中大约需要 16GB 显存。

根据实验实际需求，推荐在百度的飞桨人工智能平台 AI Studio 上完成实验（网址：https://aistudio.baidu.com/overview ）。从 AI Studio 一方面可以获取完成本次实验的免费算力，另外可以直接使用最新版 paddlepaddle-gpu 3.3 环境，基本满足完成实验的需求。

本次实验用到的项目【HIT-基于 Transformer 神经机器翻译建模与优化实验】发布地址为：https://aistudio.baidu.com/projectdetail/10747476 ，版本 refactor-paddle3.3，注意手动在项目界面左侧选取。

下面主要针对本实验需求，介绍 AI Studio 平台的相关使用方法。

2.1 领取免费算力与项目的基本操作

- 访问 AI Studio，用百度账号登录；按页面要求完成账号资料、实名或安全验证。
- 进入「项目」或「我的项目」。先实际创建或使用一个项目，并且准备开始运行，此时就获取了本日的 8 点算力。

这里可以直接使用本次实验的参考项目，点击右上角的“运行一下”，



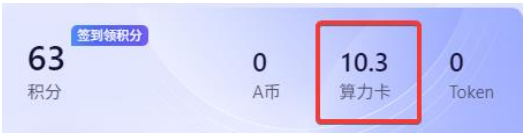
或是手动 frok 项目在右上角选择运行。只要出现如下的算力选择界面，此时 8 点算力卡应该已经发放到账户。

本次实验中，单次训练、推理、评测流程可在 4 小时内使用 V100 16GB 算力卡完成，预计单次实验消耗不超过每天可领取的免费算力额度。



运行环境选择和价格界面

- 点击右上角头像，进入「个人中心→算力卡管理」（https://aistudio.baidu.com/coupon/manage ），可以看到当前余额、有效期和发放明细。



算力卡明细入口

2.2 项目基本操作

按上一节的基本操作指导准备运行项目。**首次运行项目建议先选用无限额度的纯 CPU 环境**，CPU 环境无法训练推理，但提供相同的代码界面，供同学们阅读和熟悉代码，数据和说明文件，以对实验项目先进行整体的把握。

项目默认的编辑器是网页版 vscode，如果发现浏览器白屏进不去的情况，可以点击右侧  按钮，切换为 BML codelab，这两种网页版编码环境的操作逻辑，和常用的 vscode 总体上类似。BML codelab 还可以快捷的对文件/文件夹进行打包/解压和上传/下载操作，方便保存实验结果。

当准备好使用 GPU 算力进行正式实验的时候，可以在项目入口页标题旁边的环境处点击，直接将 CPU 环境切换升级到 V100 16GB GPU 环境：



我的项目-切换环境

也可以停止项目后再用 GPU 环境启动项目。**切记在停止/切换前保存文件！**

进入环境后如何验证现在处于 GPU 环境：

- 终端中运行命令 nvidia-smi，应看到显卡信息面板；
- 终端运行命令 pip show paddlepaddle-gpu，应看到 gpu 版本的 paddle 环境信息。

本实验所需的第三方 pypi 依赖仅有 paddlepaddle-gpu，因而不用额外配置任何环境，一切正常后就可以在算力环境中开始进行实验了。

2.3 实验所需资源一览

- **代码和数据等文件：**由 HIT-基于 Transformer 神经机器翻译建模与优化实验 项目（https://aistudio.baidu.com/project/edit/10747476 ）提供；
- **环境：**仅依赖 paddlepaddle-gpu，由项目提供开箱即用的环境；
- **算力：**V100 16GB（每小时消耗两点算力点，请注意额度）；
- **单次完整实验耗时：**在上述环境中使用项目默认的参数训练需两小时左右，训练、推理、评测完整流程总耗时不会超过三小时，建议在单张算力卡时间范围内完成一轮完整实验。

三、 实验内容{计 15 分}

3.1 实验环境下基线模型介绍

访问和 fork 实验项目 https://aistudio.baidu.com/projectdetail/10747476 （版本 refactor-paddle3.3）。该项目提供了基于 transformer 机器翻译模型下，英中翻译系统的基线实例。

在该项目中进行实验的要求包括：

- 阅读 readme，重点掌握基于 transformer 的机器翻译建模流程，能够基于此实现英中翻译功能；
- 了解项目框架结构，学会如何使用 AI Studio 平台提供的 Linux 开发环境，BML codelab/vscode 编辑器，和 GPU 等，对模型进行训练；
- 掌握机器翻译流程，会评价翻译结果。

备注：由于训练耗时较长，单次训练时长约两小时，无法保证浏览器中项目打开状态的同学，可以使用平台提供的任务功能进行后台训练，详情参考 https://aistudio.baidu.com/aistudio/projectdetail/1173726，项目已经针对后台训练功能进行适配。

3.2 英汉基线模型实现：数据简介

项目使用的数据集托管于 AI Studio 平台并已经正确链接到项目当中，数据集地址为 https://aistudio.baidu.com/aistudio/datasetdetail/60419 （包含预处理好的 wmt2017，wmt2018 测试集。vocab_all.bpe.32000 为词典。

本实验项目的训练集为经过处理和筛选的数据 train.tok.clean.bpe.32000.en-zh，已下载到本实验项目的 wmt18_zhen_data_bpe3 文件夹中。该数据集包含约 25 万个中英文句对，文件名中 tok 表示已经过 tokenization 处理，clean 表示已清洗去除了异常句，bpe.32000 表示使用了 Byte Pair Encoding 子词分词算法，子词词表大小为 32000，en-zh 表示内容为中英文平行句对。

3.3 英汉基线模型实现：模型训练

输入：3.2 节中经过处理与筛选的待训练数据及对应词典

输出：在 AI Studio 上训练英-汉翻译模型，应完整保存训练时的输出 log，推荐使用命令行管道符将输出重定向到磁盘文件中。

要求：

- 参考提供的开源代码及命令行语句在 AI Studio 上训练模型；
- 规定训练 10 个 epoch 时停止训练 （10 个 epoch 这一限制仅在此处

有效）；

- 规定 batchsize 大小为 4096；
- 训练结束后的模型参数保存在命名为 saved_models 的文件夹，模型参数及 checkpoints 命名为 step_X, X 为此时的 iteration 值；
- 规定每 100 个 iteration 打印一下日志文件到标准输出；
- 规定每 5000 个 iteration 将当前训练的参数值保存到对应文件夹中；
- 其他训练参数可自行调整。

3.4 英汉基线模型实现：翻译解码

输入：训练完成的模型 final 检查点、处理好的英-汉测试集文件

输出：翻译结果文本文件

要求：

- 参考提供的开源代码及命令行语句在 AI Studio 上进行翻译预测；；
- 要求用训练的最终模型分别对 newstest2017.tok.bpe.32000.en-zh 和 newstest2018.tok.bpe.32000.en-zh 进行翻译结果预测
- 所有翻译结果保存在命名为 output_file 的文件夹中，翻译结果文本文件命名格式为 predict_Y.txt，Y 为年份。

3.5 英汉基线模型实现：翻译质量评价

{**完成** 3.1-3.5，**本次实验计分** 60%}

输入：模型推断的翻译结果文本文件

输出：BLEU 分数

要求：

- 参考提供的开源代码及命令行语句在 AI Studio 上进行翻译结果评价；
- 使用 3.2 中介绍的 wmt 数据集的 newstest2017.tok.zh 和 newstest2018.tok.zh 为标准答案进行模型验证；
- 利用项目中 mosesdecoder 文件夹下 BLEU 评估工具进行翻译模型评估。

作为参考，此处给出基线模型在 newstest2018 上测试结果：

- newstest2018 ： BLEU = 4.46, 23.3/5.7/2.5/1.2 (BP=1.000, ratio=1.087, hyp_len=97832, ref_len=90019)

3.6 基于 Transformer 模型的翻译性能分析

通过查找相关论文知识并阅读学习，了解可能影响 Transformer 模型翻译质量的各种因素，了解各个模型参数对训练结果会产生什么影响。

然后选取若干参数进行实际实验，通过对模型参数调优，提升基线模型效果。

注：影响模型质量的因素有很多，对于自己选择进项实验分析的若干因素，要给出动机。不论结果是否得到提升，都应给出实验结果，尝试探讨其中的规律。

3.7 基于 Transformer 机器翻译模型改进

通过阅读学习，寻找相对于基线模型的改进方案，并编程实现改进。

提交：所实现的模型，要求**在改进处必须有规范的代码注释**。所实现的模型翻译性能报告，并对比基线对其进行分析。

注：为了推动对模型本身的关注，NMT 性能优化中的一些过程性策略如 back translation, translation ensemble 等、以及改变输入表示而不涉及代码实现的策略的，在此环节不得分。判断的标准是对 transformer 模型流程的代码级改进，才能得分

***模型改进样例**（这个实现过于简单，直接复现不得分）：

某研究小组在论文 WEIGHTED TRANSFORMER NETWORK FOR MACHINE TRANSLATION 提出：通过两种权重值，并且将一些不同的线性层放入注意力机制中，使得各个头（head）更加多样，互动更加强。两个权值分别是 κ 和 α，κ 是在多头注意力机制后，对每个头进行权值加成，论文中称为 concatenate weight，而 α 是将 κ 加权处理后再经过一层前馈处理（就是上面的 Feed Forward，FFN）的值再次进行加权，最后将这些头直接加起来。公式如下：

$$\begin{aligned}\text{head}_i &= \text{Attention}(QW_i^Q, KW_i^K, VW_i^V),\\ \overline{\text{head}}_i &= \text{head}_i W^{O_i} \times \kappa_i,\end{aligned}$$

$$\text{BranchedAttention}(Q,K,V) = \sum_{i=1}^{M} \alpha_i \text{FFN}(\overline{\text{head}}_i).$$

这篇论文中将这种注意力机制叫做：multi-branch attention (多支注意力机制)。

四、 实验报告{计 5 分}

- 按照学术论文标准撰写梳理自己的工作，凝练自己的核心发现（贡献），巧妙的将上述实验结果，包括的实现及评估过程总结、心得，融入其中；

- 避免流水账，4 页左右为好，最长不应超过 8 页（不含参考文献）；
- 格式参考所提供的模板；
- 实验报告在说明问题时建议加入实例作为辅助说明；
- 请确保实验报告格式清晰、一致，内容的条理性和完整性。

五、 评分方式

1）该实验成绩满分 20 分：代码成绩 15 分，报告成绩 5 分；

2）采用基线模型实现英汉翻译，对基线模型翻译质量进行实验分析：记为 5 分；

3）采用调参的方式，不改变训练语料，提升了基线模型翻译质量，记为 10 分；

备注：调参规模应该限制在提供的算力额度内，请预先调研相关资料，合理制订调参计划。

4）改进基线模型代码并使翻译质量得到提高，计满 15 分；

备注：注意在算力额度限制内完成。

5）报告成绩:5 分。报告要求：

学术论文写作风格，避免纯实验过程的记叙和代码讲解的堆砌；内容完整，能详实回答实验要求、格式规范；**包含实验中额外参考的文献[重要]**。

注意：如果不提交实验报告，或者只有实验报告而无代码，本次实验成绩清零；如果实验报告表述和实验内容严重不一致，缺少关键内容，或是反映出没有切实完成实验的，本次实验总成绩直接降为 12 分。