哈尔滨工业大学

自然语言处理

实验报告

(2026 年秋季学期)

姓名：	邴海诺、高新来
学号：	2024112353、2024112774
学院：	计算学部
教师：	杨沐昀

实验三：Qwen2-7B-Instruct 的中文医疗对话微调与交互质量评估 ——LoRA 参数分析、DoRA 对比与格式遵循诊断

摘要 本文在 DISC-Med-SFT 上对 Qwen2-7B-Instruct 做 LoRA 有监督微调，并在 Chinese-medical-dialogue（前 100/500 条，ROUGE-1/2/L F1）与 CMMLU computer_science（204 题）上对比基座与六个参数高效适配器，另做格式对齐续训与同预算回放对照。医疗上，仅 252 万参数（0.033%）的 L8-QV 把 ROUGE-L 从 0.1359 提到 0.1807（95% 区间 $[+0.0403, +0.0495]$），前 500 条从 0.1446 提到 0.1915，生成长度由 437 字符降到 257；扩容到 16 倍没有可靠增益。CMMLU 官方短提示下基座/L8-QV 严格准确率为 78.9%/77.5%，差异不显著；训练系统提示下的 61.3%/27.0% 主要是输出格式不匹配。仅用训练语料合成 2,000 条四选一格式样本并混入 1,000 条医疗回放后续训 L8-QV，官方严格准确率升到 83.3%，相对基座 +4.4 个百分点（McNemar $p = 0.093$，边缘显著），显著高于 L8-QV（$p = 0.002$）与同预算纯回放（$p = 0.001$），医疗 ROUGE 同时提高。DoRA-8 相对基座把医疗 R-1/L 提高 0.0104/0.0443（区间不跨零），CMMLU 仅低 1.0 个百分点且不显著，是可行的替代方法；DoRA-16 医疗 R-L 也提高 0.0429，但 CMMLU 降至 66.2%。综合参数效率与通用能力，医疗生成推荐 L8-QV；官方选择题口径下推荐 L8-QV+FMT。交互上，微调把时延从约 8.4 秒降到 2–4 秒，角色代入与三点硬约束仍不完整。

关键词 大语言模型；LoRA；DoRA；参数高效微调；医疗对话；CMMLU；人机交互评价

1 任务与数据

1.1 模型与任务

基座为 Qwen2-7B-Instruct[3]（7.62B，28 层解码器）。任务是在中文医疗对话上做有监督微调：给定系统提示与患者提问，自回归生成医生回复。

训练数据为 DISC-Med-SFT[4]（464,898 段多轮对话、1,362,284 条医生回复）。按指导书把每条医生回复与其前一条用户提问配对，随机抽取 100,000 条并去重得 96,293 条训练对；验证集按对话级抽取 2,000 条，与医疗测试集前 500 条零重叠。主实验按固定种子取 12,000 条，六组主配置共享同一子集与顺序，1 epoch 共 375 步；4.2 节另构造 3,000 条续训数据。

1.2 评测数据

Chinese-medical-dialogue 为 Alpaca 格式医疗问答，取前 100 条为主评测集、前 500 条为扩展集；源文取 `input`（缺失时用 `instruction`），参考取 `output`。**CMMLU computer_science**[5]共 204 道四选一题，题干与选项拼成源文，正确字母为目标。评测使用课程两版脚本完全相同的三级解析器（整句字母、显式表述、行首字母），无法解析计错。远程 `gen_batch.py` 的短系统提示、256 新词元、重复惩罚 1.05 作为主口径；本地指导书第 3.17 节的专用提示、32 新词元作为复核口径。为区分答错与格式不遵循，另报告只重判未解析输出的内容匹配上界与代理 MRR；训练系统提示下的结果作为提示敏感性对照。

2 方法

2.1 LoRA 低秩适配

LoRA[1]冻结预训练权重 $\boldsymbol{W}_0 \in \mathbb{R}^{d\times k}$，在旁路注入低秩矩阵 $\boldsymbol{B} \in \mathbb{R}^{d\times r}$ 与 $\boldsymbol{A} \in \mathbb{R}^{r\times k}$：

$$\boldsymbol{h} = \boldsymbol{W}_0\boldsymbol{x} + (\alpha/r)\boldsymbol{B}\boldsymbol{A}\boldsymbol{x},$$

其中 r 为秩，α 为缩放系数。训练只更新 $\boldsymbol{A}$ 与 $\boldsymbol{B}$，$\boldsymbol{B}$ 零初始化，因此训练起点与基座等价。单层可训练参数为 $r(d+k)$。Qwen2 的 q, o 投影为 3584×3584，k, v 为 3584×512，MLP 的 gate/up 为 3584×18944、down 为 18944×3584。$r = 8$ 仅 q, v 时每层增加 90,112 个参数，28 层共 2,523,136 个（0.033%）；$r = 16$ 全线性层每层 1,441,792 个，共 40,370,176 个（0.530%）；$r = 32$ 为 80,740,352 个（1.060%）。

2.2 参数分析设计

固定 $\alpha = 2r$、dropout 0.05、有效批大小 32、余弦退火（预热 3%），比较四组 LoRA：L8-QV（$r = 8$、q, v、$1e-4$，指导书默认）；L16-ALL-1e4（$r = 16$、全线性层、$1e-4$，隔离秩与目标模块的影响）；L16-ALL-2e4（在上一组把学习率提到 $2e-4$）；L32-ALL（$r = 32$、$2e-4$，检验容量是否在 $r = 16$ 附近饱和）。

2.3 DoRA：权重分解的低秩适配

DoRA[2]把冻结权重分解为幅度与方向，并只对方向做低秩更新：

$$\boldsymbol{W}' = \boldsymbol{m}\frac{\boldsymbol{W}_0 + \boldsymbol{B}\boldsymbol{A}}{\|\boldsymbol{W}_0 + \boldsymbol{B}\boldsymbol{A}\|_c},$$

其中 $\boldsymbol{m} \in \mathbb{R}^d$ 为输出通道的幅度向量，$\|\cdot\|_c$ 为按列范数。除 LoRA 参数外，每个适配层增加一个长度等于输出维度的幅度向量。本文设两个对照：DoRA-8-QV 与 L8-QV 同秩、同目标、同学习率，总可训练参数 2,637,824（0.0346%）；DoRA-16-ALL 与 L16-ALL-2e4 完全一致，总参数 41,760,768（0.548%），仅比同 rank LoRA 多 3.4%。DoRA 的额外开销主要来自每步的权重范数计算；推理时更新可合并回原权重，不引入额外延迟。

2.4 交互评估设计

按人机交互评价[11]补充四类探针：在 6 个固定问题上测量端到端时延与吞吐；“不超过 30 字”“分三点、每点不超过 20 字”两条硬约束及儿科医生/药剂师角色提示检查指令遵循[9]；三轮头痛对话与急症题检查上下文和安全升级；从测试集抽 15 题，把基座、L8-QV、DoRA-16 的回答盲化后由单个 LLM 评审按相关性、准确性、流畅性打 1–5 分[10]。单评审结果仅作探索性证据。

3 实验设置

3.1 训练配置

全部训练与评测在百度 AI Studio 的免费算力上完成（单卡 Iluvatar BI-V150S32G，32 GB 显存）。课程 PaddleFormers 环境在实验期间不可用，改用 PyTorch + Transformers + PEFT，数据格式、训练目标与官方评测口径保持一致；官方 bfloat16/eager 改为 fp16 + SDPA，预实验未观察到乱码或重复退化。训练采用梯度检查点、截断长度 1,024、AdamW、权重衰减 0、梯度裁剪 1.0；所有配置有效批大小均为 32（微批 4 × 累积 8，DoRA-8 为 2 × 16）。表 1 汇总可训练参数，表 2 汇总各配置，表 3 给出训练开销。

配置	方法	秩	目标模块	学习率	总参数	占比
L8-QV	LoRA	8	q, v	$1e-4$	2,523,136	0.033%
L16-ALL-1e4	LoRA	16	全部	$1e-4$	40,370,176	0.530%
L16-ALL-2e4	LoRA	16	全部	$2e-4$	40,370,176	0.530%
L32-ALL	LoRA	32	全部	$2e-4$	80,740,352	1.060%
DoRA-8-QV	DoRA	8	q, v	$1e-4$	2,637,824	0.0346%
DoRA-16-ALL	DoRA	16	全部	$2e-4$	41,760,768	0.548%

表 1　LoRA / DoRA 可训练参数（Qwen2-7B-Instruct，28 层）

项目	取值	说明
基座 / 框架	Qwen2-7B-Instruct / PyTorch + PEFT	7.62B 参数
训练 / 验证样本	12,000 / 2,000	96,293 条去重对中抽取
截断长度	1,024	超长样本截断
有效批大小	32	微批 4 × 累积 8（DoRA-8 为 2 × 16）
训练轮数 / 步数	1 / 375	所有配置一致
学习率调度	余弦退火	预热 3%，峰值见表 1
精度	fp16 + SDPA	梯度检查点开启
随机种子	42	单种子，未做多种子重复

表 2　六组主配置的共享训练超参数

配置	训练时长	峰值显存
L8-QV	31.3 min	21.55 GB
L16-ALL-1e4	40.9 min	22.19 GB
L16-ALL-2e4	41.0 min	22.19 GB
L32-ALL	41.1 min	22.86 GB
DoRA-8-QV	42.9 min	18.12 GB
DoRA-16-ALL	2 h 05 min	22.21 GB

表 3　训练开销（单卡，fp16，梯度检查点）

3.2 评测协议与指标

所有模型使用同一聊天模板、贪心搜索、批大小 8 与左填充；适配器推理前合并回基座，使参数量差异只体现在训练阶段。医疗主实验使用训练系统提示，另以官方短提示做敏感性对照；CMMLU 主结果使用官方短提示，复核使用指导书专用提示，训练提示下的结果作为格式对照。

ROUGE[6]先经 jieba 分词[12]再计算 ROUGE-1/2/L F1，空输出计 0；BLEU-4[7]为语料级 4-gram 精度加简短惩罚，EM 为规范化完全匹配，F1 为词元多重集重叠。CMMLU 按三级规则解析，未解析计错，并报告内容匹配与代理 MRR。时延在 6 个固定问题上测量，医疗主表取 5 个医学问题的平均时延。统计上，医疗与

CMMLU 分别使用 500/2000 次配对 bootstrap，只对不跨零的差异作结论；单种子、12k 子集与 1 epoch 限制外推。

4 结果与分析

4.1 基座与 LoRA 基线

表 4 给出主结果。基座医疗 ROUGE-1/2/L 为 0.2150/0.0338/0.1359，平均生成 437 字符（约为参考的 2.4 倍），99/100 条在 256 词元处截断；L8-QV 仅训练 252 万参数，即把 ROUGE-L 提到 0.1807（+0.0450，95% 区间 $[+0.0403, +0.0495]$），长度压到 257 字符、截断降到 8 条；前 500 条 ROUGE-L 从 0.1446 升到 0.1915（图 1），说明 100 条子集低估了基座的冗长程度。EM 对所有模型均为 0，说明该任务为开放式生成，字面匹配不适用。换用官方短提示后，基座/L8-QV 的医疗 ROUGE-L 为 0.1809/0.1988，L8-QV 仍显著领先（+0.0180，$[+0.0032, +0.0321]$），但增益小于训练提示，部分优势来自对训练提示的适配。

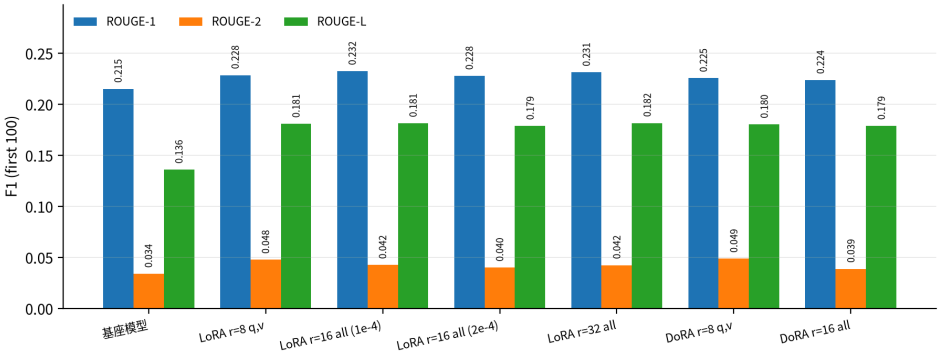


图 1　各模型在医疗对话前 100 条上的 ROUGE-1/2/L F1

模型	R-1	R-2	R-L	BLEU-4	F1	严格	内容	长度	时延
基座	0.2150	0.0338	0.1359	0.0071	0.258	78.9	82.8	437	8.4
L8-QV	0.2284	0.0476	0.1807	0.0166	0.303	77.5	81.9	257	3.7
L16-1e4	0.2323	0.0424	0.1813	0.0174	0.299	74.0	78.9	233	2.3
L16-2e4	0.2277	0.0400	0.1786	0.0159	0.299	65.7	77.5	254	2.2
L32-ALL	0.2311	0.0423	0.1815	0.0158	0.299	60.3	75.0	230	2.1
DoRA-8	0.2254	0.0486	0.1802	0.0175	0.296	77.9	82.4	236	3.5
DoRA-16	0.2236	0.0387	0.1787	0.0151	0.297	66.2	77.5	252	2.2

表 4　主结果（医疗为训练系统提示下前 100 条 F1；CMMLU 为官方短提示下 204 题严格准确率 / 内容匹配上界）

官方短提示下，基座/L8-QV 的 CMMLU 严格准确率为 78.9%/77.5%（差 1.5 个百分点，2000 次配对 bootstrap 区间 $[-3.4, +6.4]$ 跨零），内容匹配 82.8%/81.9%，MRR 0.840/0.819，通用知识基本保留。参数扩容的代价更明显：L16-1e4、L16-2e4、L32 的严格准确率依次为 74.0%、65.7%、60.3%，内容匹配降至 78.9%、77.5%、75.0%；同预算 DoRA-8 为 77.9%/82.4%，与基座接近，DoRA-16 降至 66.2%/77.5%。可见该预算下容量越大、学习率越高，领域适配越充分，但通用知识漂移越明显（图 2）。

格式与知识的分离。 本地指导书的专用提示把基座/L8-QV 提到 85.3%/82.4%（未解析 0），差距缩至 2.9 个百分点（$[0.0, +5.9]$，触及零）。若沿用训练系统提示，两者严格准确率只有 61.3%/27.0%，未解析 48/131 题；但内容匹配仍有 75.5%/69.6%，抽样可见模型直接复述正确选项内容而不写字母。因此训练提示下的大幅下降主要是格式不遵循而非知识遗忘；严格准确率随容量上升（27.0→48.0→51.0）同样只是格式遵循改善[8]。

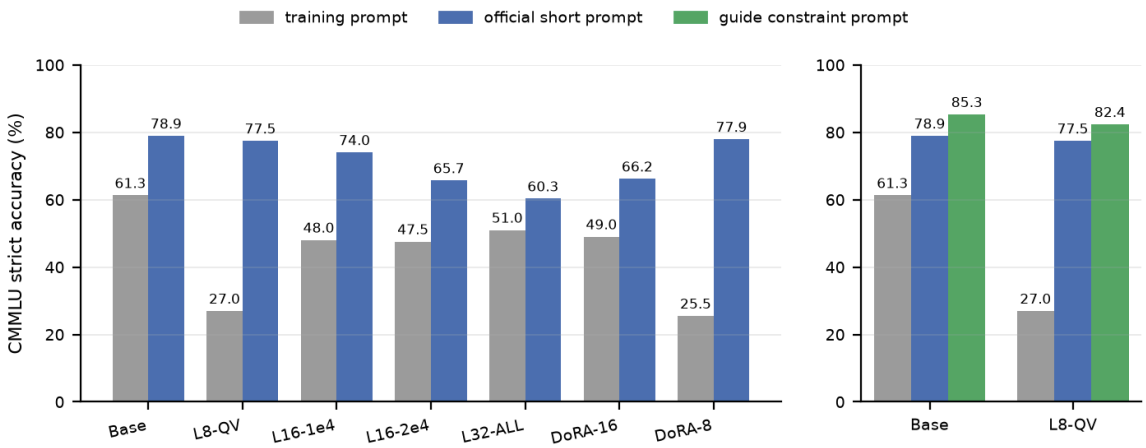


图 2　CMMLU computer_science（204 题）严格准确率：左为六个参数配置在训练提示与官方短提示下的对照，右为基座与 L8-QV 在三种口径下的对照

4.2 格式对齐续训

官方短提示下 L8-QV 的 16 条未解析题多数已包含正确内容（内容匹配 81.9% 对严格 77.5%），差距主要是“答对但不按选项格式作答”。为此，仅用同一训练语料构造 3,000 条续训集：2,000 条合成四选一题（正确选项为配对的医生回复，干扰项为其他训练对的回复，随机打乱，要求输出“字母. 选项文本”，系统提示与官方评测一致），另混入 1,000 条原始医疗对回放。以 L8-QV 为初始化续训 1 epoch（93 步，$5e-5$）得到 L8-QV+FMT；控制组 L8-QV+REPLAY 用同预算纯医疗回放、同初始化与同步数训练。未使用任何 CMMLU 题目或选项。

模型	R-1	R-2	R-L	严格	内容	MRR	未解析
基座	0.2150	0.0338	0.1359	78.9	82.8	0.840	17
L8-QV	0.2284	0.0476	0.1807	77.5	81.9	0.819	16
L8-QV+FMT	0.2448	0.0510	0.1915	83.3	83.8	0.838	3
L8-QV+REPLAY	0.2285	0.0479	0.1806	77.0	81.9	0.819	17

表 5　格式对齐续训与对照（医疗为训练系统提示下前 100 条 F1；CMMLU 为官方短提示下 204 题）

表 5 显示，FMT 把严格准确率从 77.5% 提到 83.3%（170/204），未解析从 16 降到 3；相对基座高 4.4 个百分点（$[0.0, +8.8]$，McNemar $p = 0.093$），相对 L8-QV 高 5.9（$[+2.5, +9.3]$，$p = 0.002$），相对纯回放高 6.4（$[+2.9, +10.3]$，$p = 0.001$）。纯回放仅 77.0%，与 L8-QV 持平，说明增益来自格式样本而非额外训练。内容匹配 83.8%、MRR 0.838 与基座相当，字母分布均衡（A 54/B 50/C 48/D 49），说明模型学会按选项作答，而不是知识增长。医疗侧同步提高：前 100 条 R-1/R-L 为 0.2448/0.1915（相对 L8-QV +0.0164/+0.0109），前 500 条 R-1/R-L 为 0.2637/0.1999（+0.0115/+0.0084），未牺牲生成质量。

4.3 参数分析

容量扩展没有带来可靠的医疗增益。L16-ALL-1e4 的 ROUGE-1 为 0.2323，比 L8-QV 高 0.0040（$[-0.0079, +0.0157]$），ROUGE-L 高 0.0007（$[-0.0059, +0.0070]$），均不显著，ROUGE-2 反而从 0.0476 降到 0.0424；学习率翻倍后 ROUGE-1/L 分别下降 0.0051/0.0029，方向一致偏负；$r = 32$ 相对 L16-2e4 的回升也不显著。参数从 252 万增至 4,037 万（16 倍）乃至 8,074 万（32 倍），医疗 ROUGE 绝对提升不足 0.5 个点，说明领域适配主要来自句长、语气与叙述结构的低秩调整，q, v 在 $r = 8$ 时已覆盖大部分信号。CMMLU 的方向相反：官方短提示下严格准确率随容量上升而下降（77.5→74.0→65.7→60.3），内容匹配同步下降；训练提示下的“容量增益”只是格式遵循改善。训练损失则随容量下降（最后 10 次均值 1.314→1.231→1.219→1.211），但测试指标没有同步提高，说明更低损失更多反映对 12,000 条子集的过拟合与通用知识漂移。

4.4 DoRA 与基座的对比

同预算的 DoRA-8-QV（$r = 8$、q, v、$1e-4$，2,637,824 个参数，训练 42.9 分钟）相对基座，医疗 ROUGE-1/2/L 从 0.2150/0.0338/0.1359 提高到 0.2254/0.0486/0.1802，R-1 与 R-L 的 95% 区间分别为 $[+0.0005, +0.0201]$ 与 $[+0.0402, +0.0487]$，均不跨零；前 500 条 R-L 为 0.1911（基座 0.1446）。官方短提示下 CMMLU 严格准确率 77.9%、内容匹配 82.4%、MRR 0.824，与基座的 78.9%/82.8%/0.840 相比仅低 1.0 个百分点且不显著。可见 DoRA 作为替代方法，能够在不显著损失通用知识的前提下提升医疗生成。

更大预算的 DoRA-16-ALL（$r = 16$、全线性层、$2e-4$，训练 2 h 05 min）医疗 R-L 为 0.1787，相对基座提高 0.0429（$[+0.0380, +0.0480]$），R-1 提高 0.0086（$[-0.0017, +0.0189]$，区间跨零）；但 CMMLU 严格准确

率降到 66.2%、内容匹配 77.5%，相对基座 78.9%/82.8% 的退化显著。可见 DoRA 的领域适配有效，但大容量配置以通用知识漂移为代价；综合效果与开销，DoRA-8 是更合适的替代方案。

4.5 交互质量评估

响应时间与吞吐。 基座在 5 个医学问题上的平均时延为 8.4 秒，L8-QV 为 3.7 秒，其余适配器为 2.1–2.3 秒；解码吞吐稳定在 28.7–30.5 词元/秒（图 3）。差异主要来自生成长度：基座几乎每题都生成满 256 词元，微调模型多在 45–95 词元内结束。交互等待从约 8 秒降到 2–4 秒，但单位时间计算效率未变。

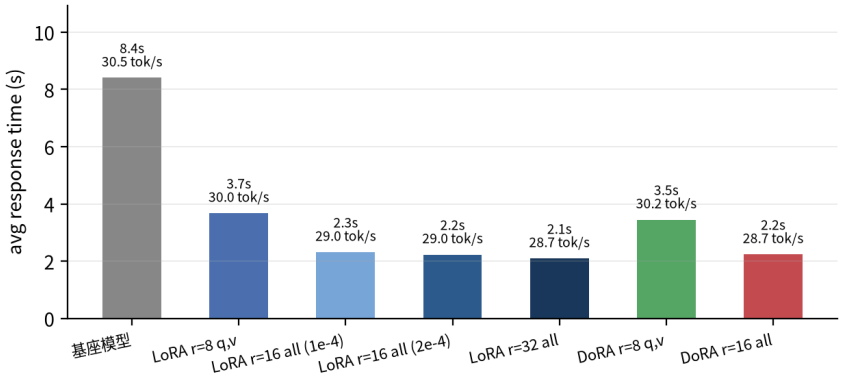


图 3　5 个医学问题的平均端到端时延与解码吞吐

指令遵循与角色扮演。 六个模型都满足 30 字、急症与多轮规则，三轮头痛对话能引用上一轮信息；三点约束只有基座与 L8-QV 完全满足，四个更大预算的适配器至少一点超过 20 字。角色代入也只有基座完成，五个适配器均未代入，其中四个直接自称“AI 医疗助手”（表 6）。

模型	角色	共情	≤30 字	三点	急症	多轮上下文
基座	√	√	√	√	√	√
L8-QV	×	√	√	√	√	√
L16-1e4	×	√	√	×	√	√
L16-2e4	×	√	√	×	√	√
L32-ALL	×	√	√	×	√	√
DoRA-16	×	√	√	×	√	√

表 6　交互探针结果（√ 表示满足规则，× 表示未满足）

格式消融。 训练系统提示下追加“只输出字母”指令后，严格准确率变化均在 1 个百分点以内，未解析数没有实质下降（表 7）；未解析输出是直接复述正确选项内容而非乱答。可见 SFT 风格是强先验，追加用户指令难以覆盖系统提示；换成官方短提示即恢复到 77.5%，专用提示达到 82.4% 且未解析为 0。部署时应固定任务对应的系统提示并做格式约束或后处理，无需重新训练。

模型	严格准确率	未解析	加指令准确率	加指令未解析	变化
基座	61.3	48	60.8	50	−0.5
L8-QV	27.0	131	27.0	131	0.0
L16-1e4	48.0	78	48.0	78	0.0
L16-2e4	47.5	75	47.5	74	0.0
L32-ALL	51.0	67	51.5	66	+0.5
DoRA-16	49.0	72	48.0	74	−1.0

表 7　CMMLU 格式消融（训练系统提示下追加“只输出字母”指令；变化为准确率百分点差）

盲评与 A/B。 15 道医疗题、3 个系统共 45 条回答盲化后由单个 LLM 评审打分（表 8）。这是代理评价，评审可能偏好信息量更大的长回答，不能替代多名真人评审。

模型	相关性	准确性	流畅性	总分	vs 基座
基座	5.00	4.33	3.07	4.13	—
L8-QV	3.60	3.80	4.07	3.82	0/6/9
DoRA-16	3.47	3.53	4.07	3.69	1/1/13

表 8　盲评三维度得分（1–5）与成对胜负（W/T/L，相对基座）

结果与自动指标方向相反：基座在相关性/准确性上更高（5.00/4.33，L8-QV 3.60/3.80，DoRA-16 3.47/3.53），微调模型在流畅性上更高（4.07 对 3.07）；成对胜负 L8-QV 0/6/9、DoRA-16 1/1/13。逐条检查可见，基座的

长清单覆盖更多要点（尽管多在 256 词元处截断），微调回答更短、更常直接建议就医。ROUGE 奖励与参考的措辞和长度对齐，评审偏好信息量，二者衡量不同；单评审的长度偏差说明医疗“好回答”仍需多维度、多评审定义。

4.6 定性分析与讨论

定性对比表明，微调首先改变回复形态。第 33 条的参考为口语化段落，基座输出分点 Markdown 并在 256 词元处截断，L8-QV 生成约 200 字连贯答复，涵盖运动、饮食与就医建议，ROUGE-L 从 0.154 升到 0.262；第 497 条同样从分点标题转为直接建议。但长度对齐并非总是有益：第 225 条的参考详细列举咽痛、发热、吞咽困难等要素，基座虽冗长却覆盖大部分，L8-QV 只保留三项，ROUGE-L 从 0.185 降到 0.123。医疗场景还需关注安全性，盲评样本中个别回答建议自行购买滴耳液或口服抗生素，部署需要额外规则或人工审核；ROUGE 与内容匹配都不能验证医学正确性。

综合来看，医疗生成推荐小容量、低学习率、q, v 的 L8-QV：以 0.033% 参数获得显著 ROUGE 增益，短提示下仍有 +0.0180 的优势，时延降到 3.7 秒；扩容没有可靠额外收益。DoRA-8 相对基座同样有效，DoRA-16 通用知识退化明显。若以官方选择题口径为主，则推荐 L8-QV+FMT（严格 83.3%，医疗 ROUGE 也高于 L8-QV）。CMMLU 的多口径结果表明领域 SFT 的知识损失很小，真正的风险是系统提示与输出格式不匹配，部署与评测都应把格式和知识分开。局限包括单种子、12,000 条子集、1 epoch、医疗主集仅 100 条、CMMLU 仅一个学科、盲评仅一名 LLM 评审，且未做事实性核查与多轮安全红队。

5 结论

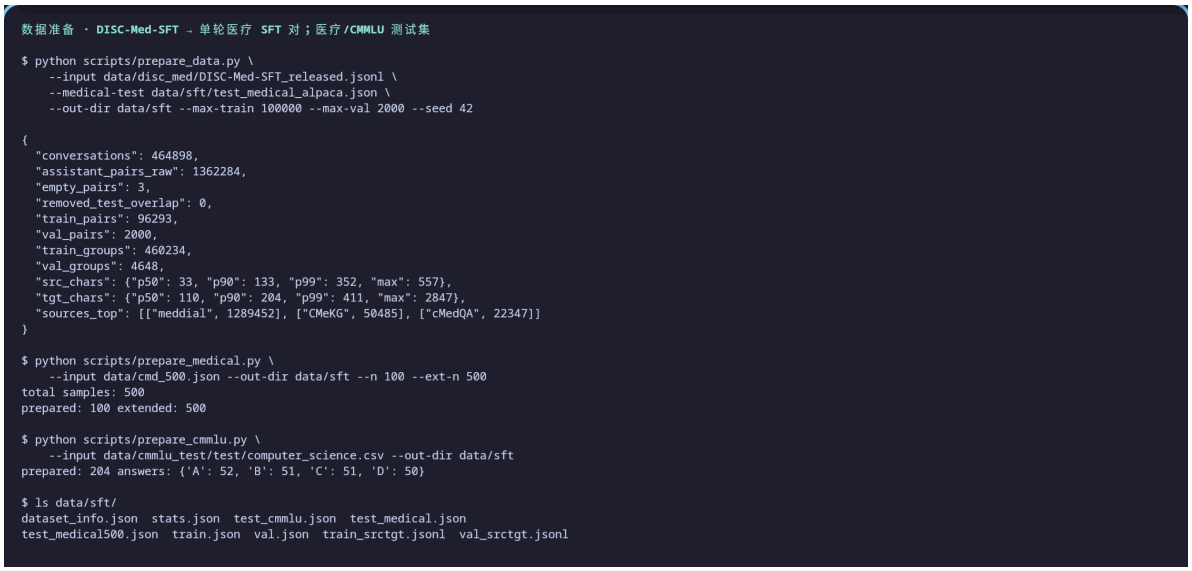
本文完成了 Qwen2-7B-Instruct 在 DISC-Med-SFT 上的 LoRA 微调、参数分析、DoRA 对照与交互评估。L8-QV 以 0.033% 参数显著提升医疗 ROUGE，并保持 CMMLU 稳定；格式对齐续训把官方严格准确率提到 83.3%，相对基座 +4.4 个百分点（$p = 0.093$），医疗 ROUGE 同步提高。DoRA-8 是可行的替代方法，DoRA-16 通用知识退化明显。后续应补多种子、真人评审、事实性核查与安全红队，并在部署侧固定系统提示、加入格式约束与急症升级规则。

6 参考文献

[1] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-rank adaptation of large language models[C]
[2] Liu S Y, Wang C Y, Yin H Z, et al. DoRA: Weight-decomposed low-rank adaptation[C]
[3] Qwen Team. Qwen2 technical report[R]. arXiv preprint arXiv:2407.10671, 2024.
[4] Bao Z, Chen W, Xiao S, et al. DISC-MedLLM: Bridging general large language models and real-world medical consultation[R]. arXiv preprint arXiv:2308.14346, 2023.
[5] Li H, Zhang Y, Koto F, et al. CMMLU: Measuring massive multitask language understanding in Chinese[C]
[6] Lin C Y. ROUGE: A package for automatic evaluation of summaries[C]
[7] Papineni K, Roukos S, Ward T, et al. BLEU: A method for automatic evaluation of machine translation[C]
[8] Biderman D, Prashanth R, Ranjan K, et al. LoRA learns less and forgets less[J]. Transactions on Machine Learning Research, 2024.
[9] Zhou J, Lu T, Mishra S, et al. Instruction-following evaluation for large language models[R]. arXiv preprint arXiv:2311.07911, 2023.
[10] Zheng L, Chiang W L, Sheng Y, et al. Judging LLM-as-a-judge with MT-Bench and Chatbot Arena[C]
[11] Amershi S, Weld D, Vorvoreanu M, et al. Guidelines for human-AI interaction[C]
[12] Sun J. jieba: Chinese text segmentation[CP/OL]. https://github.com/fxsjy/jieba, 2012.

7 附录 A　实验过程截图

以下截图为实验三各环节终端日志的回放记录。



```
数据准备 · DISC-Med-SFT → 单轮医疗 SFT 对；医疗/CMMLU 测试集

$ python scripts/prepare_data.py \
    --input data/disc_med/DISC-Med-SFT_released.jsonl \
    --medical-test data/sft/test_medical_alpaca.json \
    --out-dir data/sft --max-train 100000 --max-val 2000 --seed 42

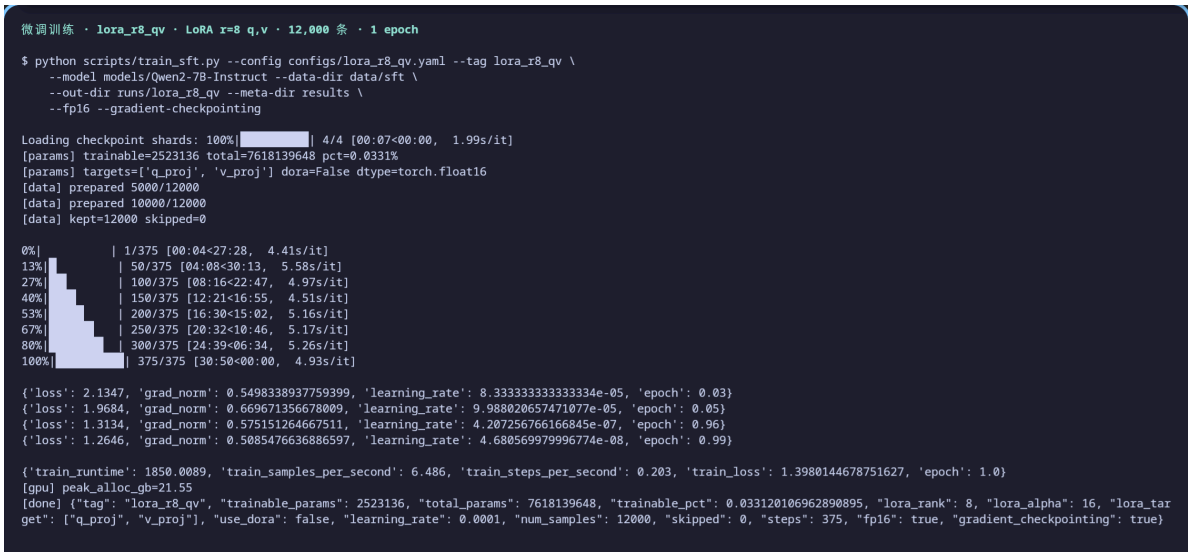
{
  "conversations": 464898,
  "assistant_pairs_raw": 1362284,
  "empty_pairs": 3,
  "removed_test_overlap": 0,
  "train_pairs": 96293,
  "val_pairs": 2000,
  "train_groups": 460234,
  "val_groups": 4648,
  "src_chars": {"p50": 33, "p90": 133, "p99": 352, "max": 557},
  "tgt_chars": {"p50": 110, "p90": 204, "p99": 411, "max": 2847},
  "sources_top": [["meddial", 1289452], ["CMeKG", 50485], ["cMedQA", 22347]]
}

$ python scripts/prepare_medical.py \
    --input data/cmd_500.json --out-dir data/sft --n 100 --ext-n 500
total samples: 500
prepared: 100 extended: 500

$ python scripts/prepare_cmmlu.py \
    --input data/cmmlu_test/test/computer_science.csv --out-dir data/sft
prepared: 204 answers: {'A': 52, 'B': 51, 'C': 51, 'D': 50}

$ ls data/sft/
dataset_info.json  stats.json  test_cmmlu.json  test_medical.json
test_medical500.json  train.json  val.json  train_srctgt.jsonl  val_srctgt.jsonl
```

图 4　数据准备：DISC-Med-SFT 训练对构造，以及医疗测试集与 CMMLU 处理脚本的运行。



```
微调训练 · lora_r8_qv · LoRA r=8 q,v · 12,000 条 · 1 epoch

$ python scripts/train_sft.py --config configs/lora_r8_qv.yaml --tag lora_r8_qv \
    --model models/Qwen2-7B-Instruct --data-dir data/sft \
    --out-dir runs/lora_r8_qv --meta-dir results \
    --fp16 --gradient-checkpointing

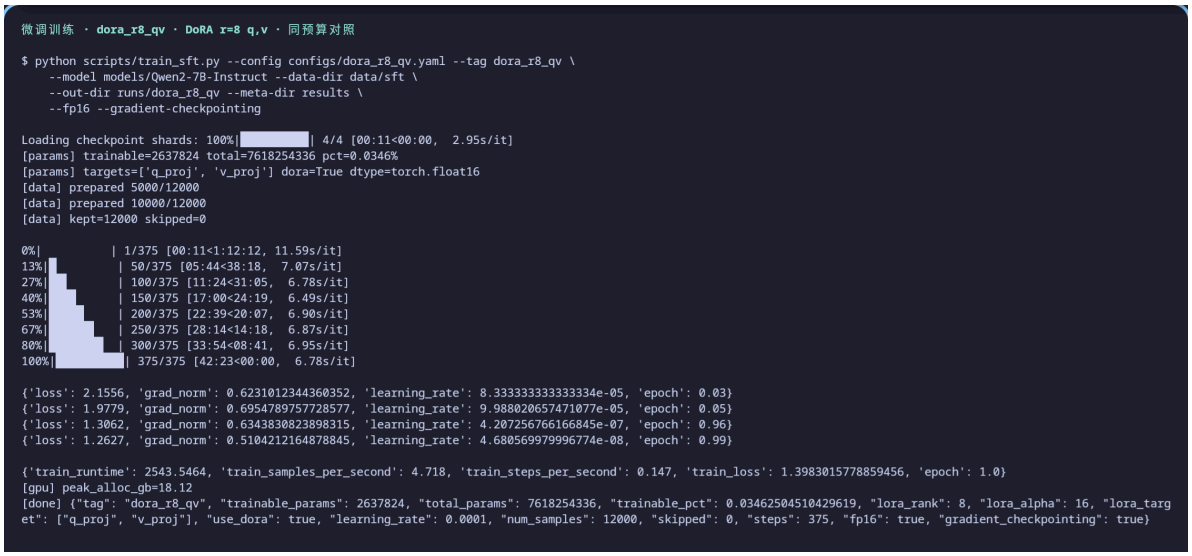
Loading checkpoint shards: 100%|████████| 4/4 [00:07<00:00,  1.99s/it]
[params] trainable=2523136 total=7618139648 pct=0.0331%
[params] targets=['q_proj', 'v_proj'] dora=False dtype=torch.float16
[data] prepared 5000/12000
[data] prepared 10000/12000
[data] kept=12000 skipped=0

0%|          | 1/375 [00:04<27:28,  4.41s/it]
13%|▉        | 50/375 [04:08<30:13,  5.58s/it]
27%|▊       | 100/375 [08:16<22:47,  4.97s/it]
40%|▊       | 150/375 [12:21<16:55,  4.51s/it]
53%|▊       | 200/375 [16:30<15:02,  5.16s/it]
67%|▊       | 250/375 [20:32<10:46,  5.17s/it]
80%|▊       | 300/375 [24:39<06:34,  5.26s/it]
100%|████████| 375/375 [30:50<00:00,  4.93s/it]

{'loss': 2.1347, 'grad_norm': 0.5498338937759399, 'learning_rate': 8.333333333333334e-05, 'epoch': 0.03}
{'loss': 1.9684, 'grad_norm': 0.669671356678009, 'learning_rate': 9.988020657471077e-05, 'epoch': 0.05}
{'loss': 1.3134, 'grad_norm': 0.575151264667511, 'learning_rate': 4.207256766166845e-07, 'epoch': 0.96}
{'loss': 1.2646, 'grad_norm': 0.5085476636886597, 'learning_rate': 4.680569979996774e-08, 'epoch': 0.99}

{'train_runtime': 1850.0089, 'train_samples_per_second': 6.486, 'train_steps_per_second': 0.203, 'train_loss': 1.3980144678751627, 'epoch': 1.0}
[gpu] peak_alloc_gb=21.55
[done] {"tag": "lora_r8_qv", "trainable_params": 2523136, "total_params": 7618139648, "trainable_pct": 0.033120106962890895, "lora_rank": 8, "lora_alpha": 16, "lora_tar
get": ["q_proj", "v_proj"], "use_dora": false, "learning_rate": 0.0001, "num_samples": 12000, "skipped": 0, "steps": 375, "fp16": true, "gradient_checkpointing": true}
```

图 5　LoRA 微调训练（$r = 8$，目标 q, v，12,000 条，1 epoch）：可训练参数 2,523,136（占总量 0.0331%），375 步，训练耗时 1,850 秒，GPU 峰值显存 21.55 GB。



```
微调训练 · dora_r8_qv · DoRA r=8 q,v · 同预算对照

$ python scripts/train_sft.py --config configs/dora_r8_qv.yaml --tag dora_r8_qv \
    --model models/Qwen2-7B-Instruct --data-dir data/sft \
    --out-dir runs/dora_r8_qv --meta-dir results \
    --fp16 --gradient-checkpointing

Loading checkpoint shards: 100%|████████| 4/4 [00:11<00:00,  2.95s/it]
[params] trainable=2637824 total=7618254336 pct=0.0346%
[params] targets=['q_proj', 'v_proj'] dora=True dtype=torch.float16
[data] prepared 5000/12000
[data] prepared 10000/12000
[data] kept=12000 skipped=0

0%|          | 1/375 [00:11<1:12:12, 11.59s/it]
13%|▉        | 50/375 [05:44<38:18,  7.07s/it]
27%|▊       | 100/375 [11:24<31:05,  6.78s/it]
40%|▊       | 150/375 [17:00<24:19,  6.49s/it]
53%|▊       | 200/375 [22:39<20:07,  6.90s/it]
67%|▊       | 250/375 [28:14<14:18,  6.87s/it]
80%|▊       | 300/375 [33:54<08:41,  6.95s/it]
100%|████████| 375/375 [42:23<00:00,  6.78s/it]

{'loss': 2.1556, 'grad_norm': 0.6231012344360352, 'learning_rate': 8.333333333333334e-05, 'epoch': 0.03}
{'loss': 1.9779, 'grad_norm': 0.6954789757728577, 'learning_rate': 9.988020657471077e-05, 'epoch': 0.05}
{'loss': 1.3062, 'grad_norm': 0.6343830823898315, 'learning_rate': 4.207256766166845e-07, 'epoch': 0.96}
{'loss': 1.2627, 'grad_norm': 0.5104212164878845, 'learning_rate': 4.680569979996774e-08, 'epoch': 0.99}

{'train_runtime': 2543.5464, 'train_samples_per_second': 4.718, 'train_steps_per_second': 0.147, 'train_loss': 1.3983015778859456, 'epoch': 1.0}
[gpu] peak_alloc_gb=18.12
[done] {"tag": "dora_r8_qv", "trainable_params": 2637824, "total_params": 7618254336, "trainable_pct": 0.03462504510429619, "lora_rank": 8, "lora_alpha": 16, "lora_targ
et": ["q_proj", "v_proj"], "use_dora": true, "learning_rate": 0.0001, "num_samples": 12000, "skipped": 0, "steps": 375, "fp16": true, "gradient_checkpointing": true}
```

图 6　DoRA 同预算对照训练（$r = 8$，目标 q, v）：与 LoRA 使用同一份数据与配置，仅将 `use_dora` 置为 true。

```
导出合并 · LoRA adapter 合并回基座，导出独立 fp16 checkpoint

$ python scripts/export_merge.py \
    --base-model models/Qwen2-7B-Instruct \
    --adapter runs/lora_r8_qv \
    --out exports/lora_r8_qv_merged \
    --dtype float16 --device cpu

[1/4] loading tokenizer from models/Qwen2-7B-Instruct
[2/4] loading base weights on cpu (float16)
Loading checkpoint shards: 100%|██████████| 4/4 [01:01<00:00, 15.29s/it]
[3/4] merging adapter runs/lora_r8_qv
[4/4] saving merged checkpoint to exports/lora_r8_qv_merged
done in 111.1s: 7,615,616,512 parameters -> exports/lora_r8_qv_merged

$ ls -lh exports/lora_r8_qv_merged
total 15G
-rw-r--r-- 1 user user 4.6G model-00001-of-00004.safetensors
-rw-r--r-- 1 user user 4.6G model-00002-of-00004.safetensors
-rw-r--r-- 1 user user 4.1G model-00003-of-00004.safetensors
-rw-r--r-- 1 user user 1.1G model-00004-of-00004.safetensors
-rw-r--r-- 1 user user  28K model.safetensors.index.json
-rw-r--r-- 1 user user 1.3K tokenizer_config.json
-rw-r--r-- 1 user user 6.8M tokenizer.json
-rw-r--r-- 1 user user 2.7M vocab.json
```

图 7　导出合并：把 LoRA adapter 合并回基座并导出独立 fp16 checkpoint 的四步流程。

```
批量推理 · gen_test.py · 6 个固定问题 · 贪心解码 (max_new_tokens=256)

$ python scripts/gen_test.py \
    --base-model models/Qwen2-7B-Instruct --adapter runs/lora_r8_qv \
    --tag lora_r8_qv --out-dir results/official \
    --dtype float16 --attn sdpa --system qwen --merge-adapter

loading base=models/Qwen2-7B-Instruct adapter=runs/lora_r8_qv dtype=float16 attn=sdpa
Loading checkpoint shards: 100%|██████████| 4/4 [00:11<00:00,  2.85s/it]
[1/6] 2.7s, 56 tok
头晕可能是由多种原因引起的，包括贫血、低血压、颈椎病等。为了确定具体原因，
建议您进行一些检查，如血常规、血压测量和颈椎X光片等。这些检查可以帮助医生
了解您的身体状况并给出相应的治疗建议。

[2/6] 2.9s, 91 tok
荨麻疹是一种常见的过敏性疾病，饮食方面需要注意避免食用可能引起过敏的食物。

[3/6] 2.4s, 75 tok
[4/6] 2.3s, 73 tok
[5/6] 8.1s, 256 tok
[6/6] 0.2s, 6 tok
wrote results/official/gen_test_lora_r8_qv.json results/official/gen_test_lora_r8_qv.txt
```

图 8　批量推理：6 个固定医疗问题的贪心解码（`max_new_tokens=256`），输出写入 `results/official`。

```
医疗评测 · 主集 100 条指标 / 扩展 500 条推理 · ROUGE / BLEU-4 / EM / F1

$ python scripts/eval_models.py \
    --base-model models/Qwen2-7B-Instruct --adapter runs/lora_r8_qv \
    --tag lora_r8_qv --data-dir data/sft --out-dir results/official500 \
    --datasets medical --medical-file test_medical500.json --medical-limit 500 \
    --batch-size 8 --dtype float16 --attn sdpa --system qwen --merge-adapter

loading base=models/Qwen2-7B-Instruct adapter=runs/lora_r8_qv dtype=float16 attn=sdpa
Loading checkpoint shards: 100%|██████████| 4/4 [00:11<00:00,  2.83s/it]
model loaded in 12.6s
  medical limit 500
  medical 8/500
  medical 200/500
  medical 400/500
  medical 500/500
medical {"n": 500, "rouge-1": 0.25215550233307005, "rouge-1_p": 0.25407028506874363, "rouge-1_r": 0.2635373877838414, "rouge-2": 0.053139713963411724, "rouge-2_p": 0.05
408602152219067, "rouge-2_r": 0.05582187574776406, "rouge-l": 0.1914887978323629, "rouge-l_p": 0.19527897356220716, "rouge-l_r": 0.20311893195835082, "valid": 500, "emp
ty": 0, "avg_chars": 234.406, "median_chars": 214.0, "short_rate": 0.002, "long_rate": 0.07, "list_rate": 0.27, "question_rate": 0.0, "caution_rate": 0.974, "repeat_4gr
am": 0.02002802442835281, "cjk_ratio": 0.891476448265264, "elapsed_s": 493.74299788475037, "samples_per_s": 1.0126725890636532, "avg_new_tokens": 139.106, "hit_limit":
14}
wrote results/official500/metrics_lora_r8_qv.json

$ column -s, -t results/official/medical_extra.csv
tag                 n    bleu4   em   f1
base                100  0.0071  0.0  0.2579
lora_r8_qv          100  0.0166  0.0  0.3025
lora_r16_all_lr1e4  100  0.0174  0.0  0.299
lora_r16_all        100  0.0159  0.0  0.2985
lora_r32_all        100  0.0158  0.0  0.2988
dora_r16_all        100  0.0151  0.0  0.2967
dora_r8_qv          100  0.0175  0.0  0.296
```

图 9　医疗评测：主集 100 条计算 ROUGE/BLEU-4/EM/F1，扩展 500 条用于推理统计。

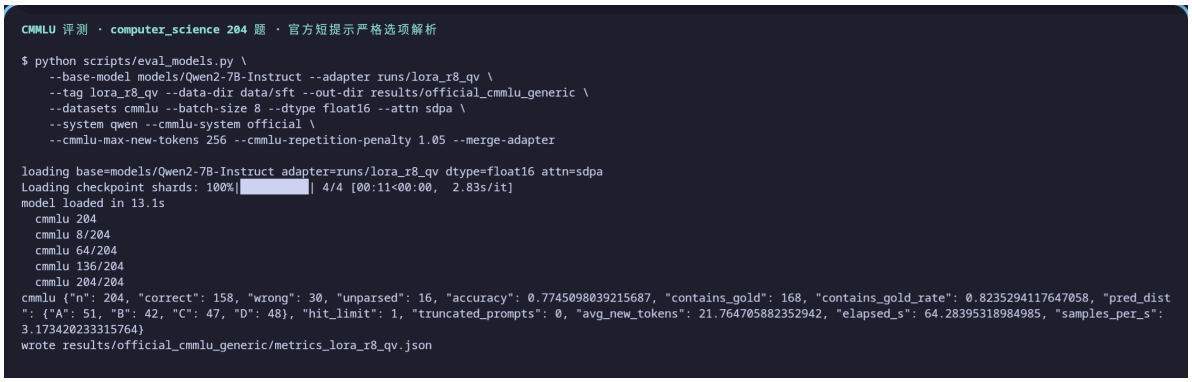


图 10　CMMLU 评测：computer_science 204 题，采用官方短提示与官方严格选项解析口径。



图 11　CMMLU 格式诊断：官方短提示下的严格解析、仅重判未解析输出的内容匹配与代理 MRR，用于区分知识缺失与格式不遵循。

实验成绩：_____

教师签名：_____