自然语言处理

第20讲 大语言模型应用与展望

杨沐昀

哈尔滨工业大学计算学部
语言技术研究中心

2026年秋季学期

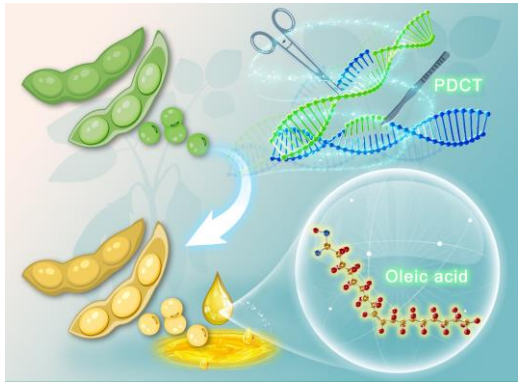
yangmuyun@hit.edu.cn

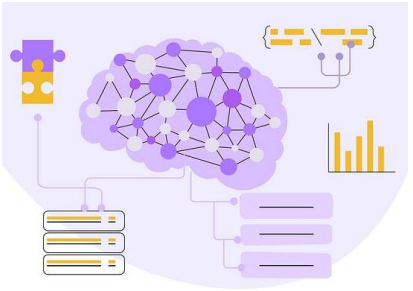
大模型应用直观感知

- Copilot贡献GitHub代码25%——**编程助手**
  - 截至2023年，GitHub平台超过1/4的项目代码由Copilot贡献
  - 大模型正在提供真实生产力，已经从研究进入实际生产
- 腾讯健康服务超1000家医院——**医疗行业**
  - 语言技术进入医疗已经形成规模
- AgroNT：参与48种作物的基因组预训练——**农科**
  - 语言模型架构可以直接参与生命密码的研究
- NeuroLM：2.5万小时EEG训练17亿参数——**脑科学**
- ……









编程、医疗、农科、脑科学、具身……大模型已经进入千行万业；科研、金融、农业等更多平台，也逐渐得到大模型的生产助力。

主要内容

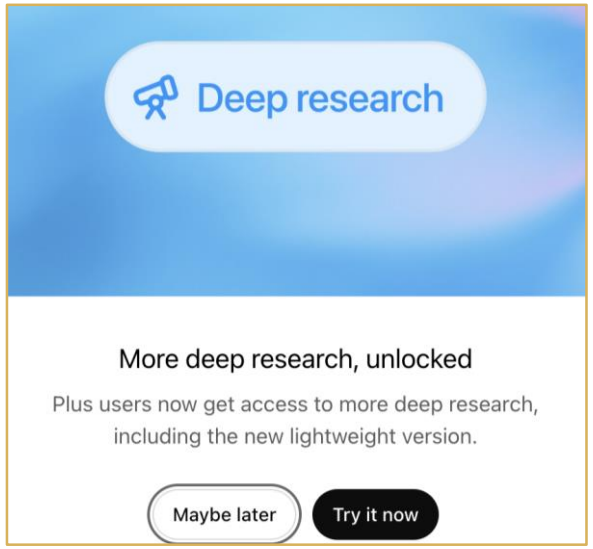
- 20.1 大模型原生助手
- 20.2 大模型行业应用
- 20.3 AI4S：从文献助手到自主实验室
- 20.4 展望大模型：从规模到智能密度

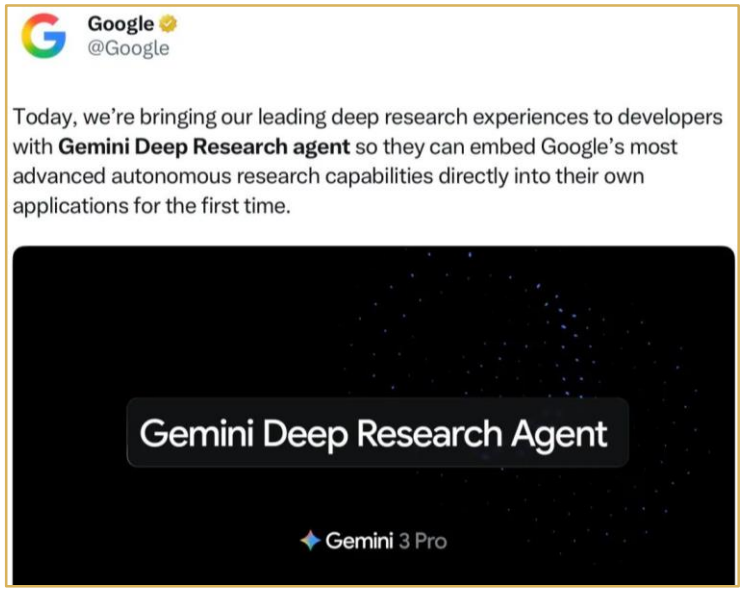
大模型原生助手：从内容生成走向任务流程

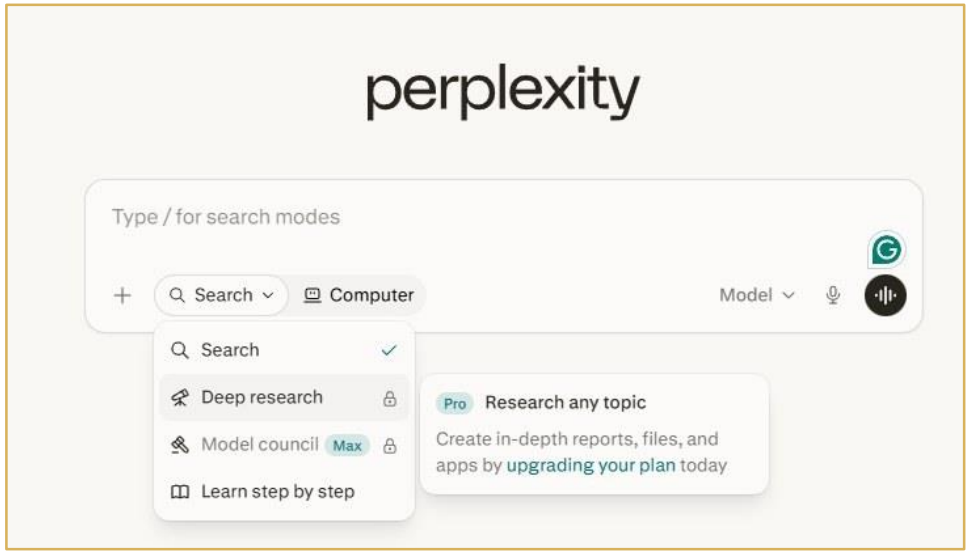
- 六类最有代表性的大模型原生助手：
  - 深度研究（Deep Research）：把传统搜索升级成一项先调研，后交付的研究型任务；
  - 编程和桌面助手：最开始用于补全代码，现在已有接管整个开发任务/日常操作的能力；
  - 写作助手：专注于具有认知协同能力的文本生成任务；
  - 设计助手：参与用户界面（UI）、演示文稿与创意视觉内容的生产和设计；
  - 心理支持：探索低成本、可负担，但具备专业素养的陪伴能力；
  - 社会模拟：让一批大模型组成虚拟社会，充当社会科学的实验装置。
- 六类大模型原生驱动的助手具备的共同点是：
  - **它们都把大模型的“单次生成”范式拓展为“任务级协同”能力。**

Deep Research：从检索到研究

- 传统搜索的工作方式是：用户给出关键词，引擎返回一批链接；用户手动把多条结果读完、比对矛盾、整合成结论。
- Deep Research 颠覆了上述范式。它的整个过程以任务驱动，模型自己规划研究步骤、自己多轮取证、自己整合证据。
- 成熟的产品主要集中在2024-2025年出现：
  - OpenAI、Google、Perplexity 等公司均开发了自己的深度调研工具。

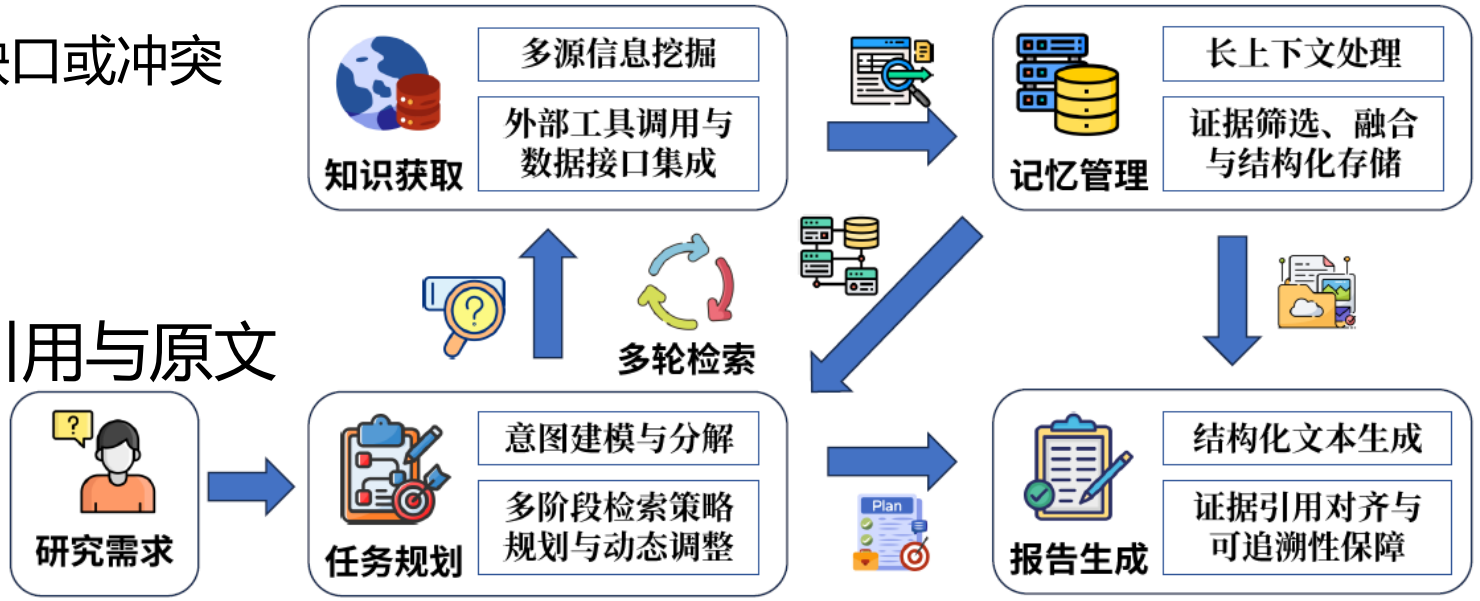






Deep Research：从检索到研究

- Deep Research的四步闭环工作流：
  1. 查询意图建模与任务规划
     - 系统先解析用户的研究意图，把复杂需求拆成若干子问题，再据此规划多阶段的检索路径
  2. 证据驱动的多轮检索
     - 包括信息的接收和评估，发现缺口或冲突时主动发起下一轮查询
  3. 研究记忆管理
  4. 生成结构化研究报告，对齐引用与原文



代表系统与工作流

同样都是 Deep Research，各家的做法并不完全相同。

- 从时间线来看，最先进入大众视野并真正完成“长程复杂调研”的工具是**Google Gemini**。
  - Gemini 会先给出一份显式的研究计划，执行流程可以编辑和讨论甚至重新形成，其工作流程大体就是上面讲的“四步循环工作流”。
- 现阶段，**OpenAI的GPT系列是比较热门的深度研究工具之一。**
  - OpenAI 的产品强调复杂问题分解与长报告生成；
  - 一次深度研究通常需要二十到三十分钟甚至更长时间，用户可以退出，让任务自动完成；
  - 系统性的搜索会显式查询多达数百条来源，形成“综述性”的长篇报告。
- **Claude Research** 采用多代理协作，倾向调度多个代理分别研究并汇总。
- 国内品牌同样在深度研究方面：
  - 百度文心 X1、阿里通义 Qwen-DeepResearch、字节豆包、智谱 AutoGLM 沉思、月之暗面 Kimi-Researcher，都引入了多步研究、工具调用与长文本生成，并更强调中文网络环境的适配和垂直场景的落地。

科研领域对深度研究的探索

- 深入科研领域，学术界正在训练会自主完成科学研究的模型。
- 有代表意义的工作：
  - Search-R1 用强化学习教模型学会检索时机，把搜索变成推理过程中可触发的动作；
  - Search-o1 进一步把检索嵌入长链推理，缓解长推理中知识不足、误差累积的问题；
  - Beyond Ten Turns 则在四十次以上工具调用的长链路交互中，学习稳定的检索与决策策略

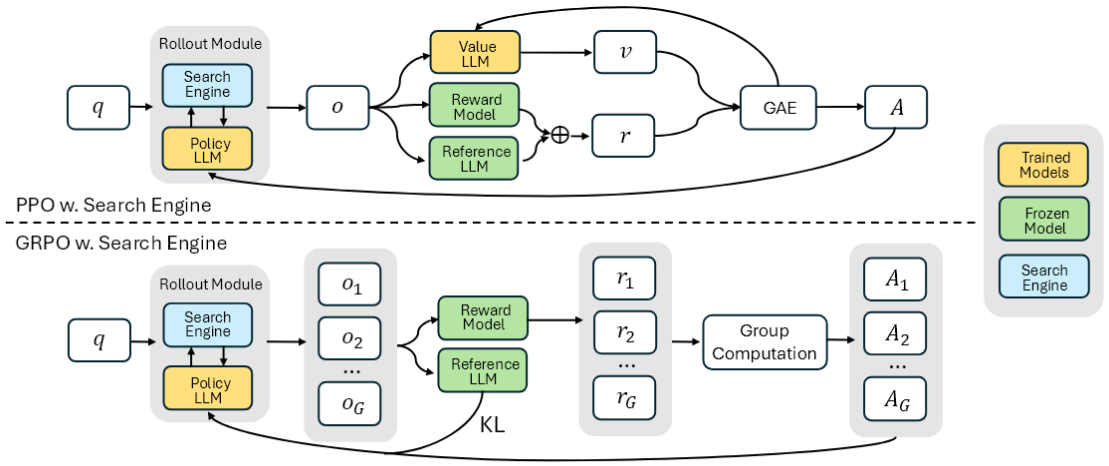
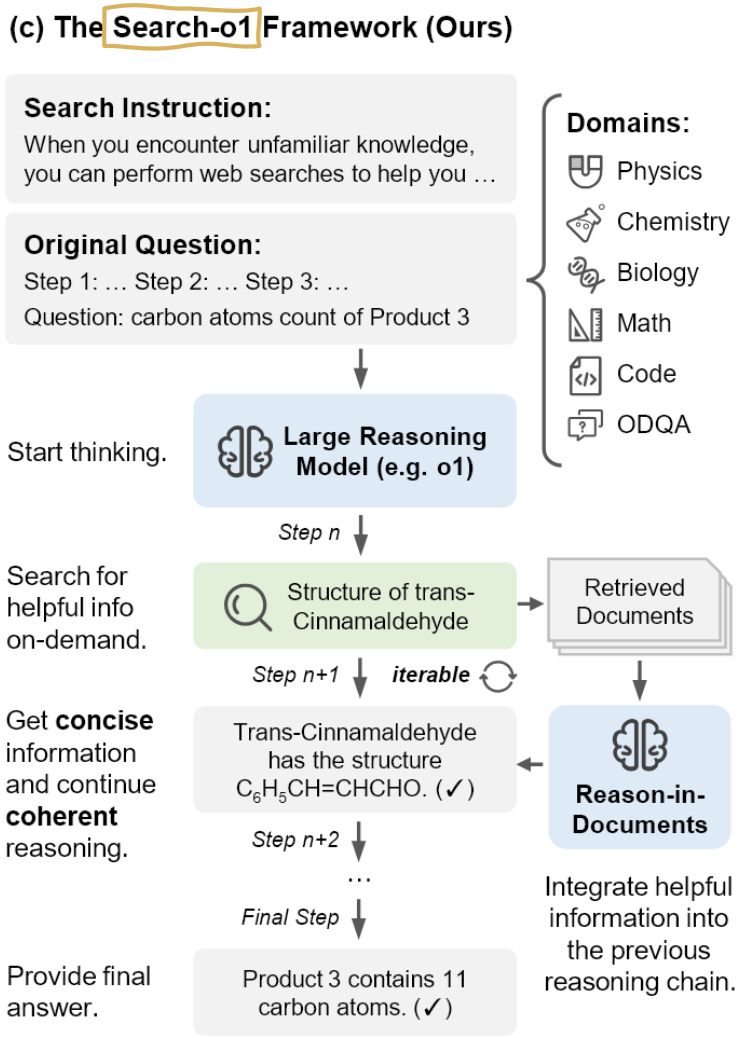
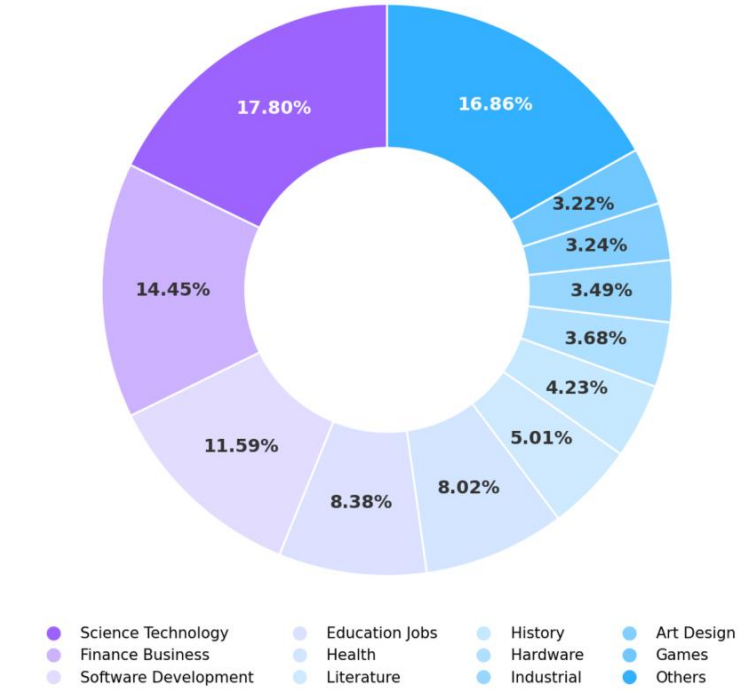


Figure 1: Demonstration of PPO and GRPO training with the search engine (SEARCH-R1). During the rollout, LLMs can conduct multi-turn interactions with the search engine.



深度研究系统评测与待解决问题

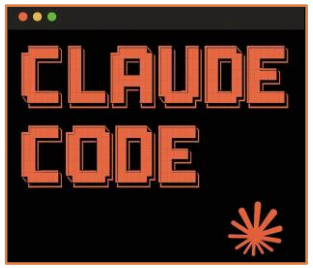
- 针对深度研究领域，传统的模型评测标准也需要进行一定的改变，主要变化是从“答案是否正确”转向“研究过程与覆盖面”。
- 有代表意义的工作：
  - BrowseComp：主要考察答案可验证但信息极难获取的问题，
    考察持续浏览和定位关键信息的能力；
  - DeepResearch Bench：把任务扩展到22个领域的PhD级研究问题，
    设定更难的题目来考察模型的研究深度
- 目前尚未解决的问题集中在三处：
  - 长程任务的训练目标与评价机制;
  - 研究记忆组织与证据冲突处理;
  - 幻觉控制与隐私合规。
- **总结：Deep Research正把大模型适配到科研工作流中，这也是后续AI for Research一类专用工具的起点。**



DeepResearch Bench的问题领域分布

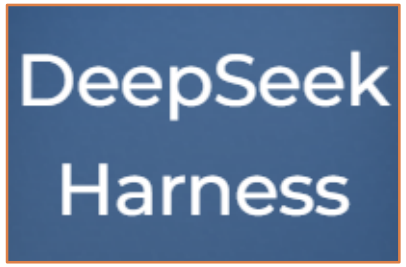
编程与桌面助手生态概览

- 编程是大模型智能体进军最早的应用方向，人机协同编码的范式近年出现并飞速完善。
- 早期的编程智能体也经过了从单薄到完备的发展流程：
  - 早期智能体的工作方式是进行代码预测和补全（Fill-in-the-Middle，FIM）
  - 从仅能根据上文代码片段预测，变为能读取工作区、调用MCP和内置工具（tool-calling），预测更准确，更智能。
- 如今开发助手已经可以参与甚至自主完成整个软件开发周期的全部工作。
  - 自动规划从需求到实现的完整路径，边执行边验证，形成“规划—执行—验证”的闭环。
  - 得益于Agent协作范式的完善、Harness生态的形成和成熟。
- 以OpenClaw为代表的个人桌面助手红极一时，甚至一度引发“龙虾热”。













编程与桌面助手生态演进

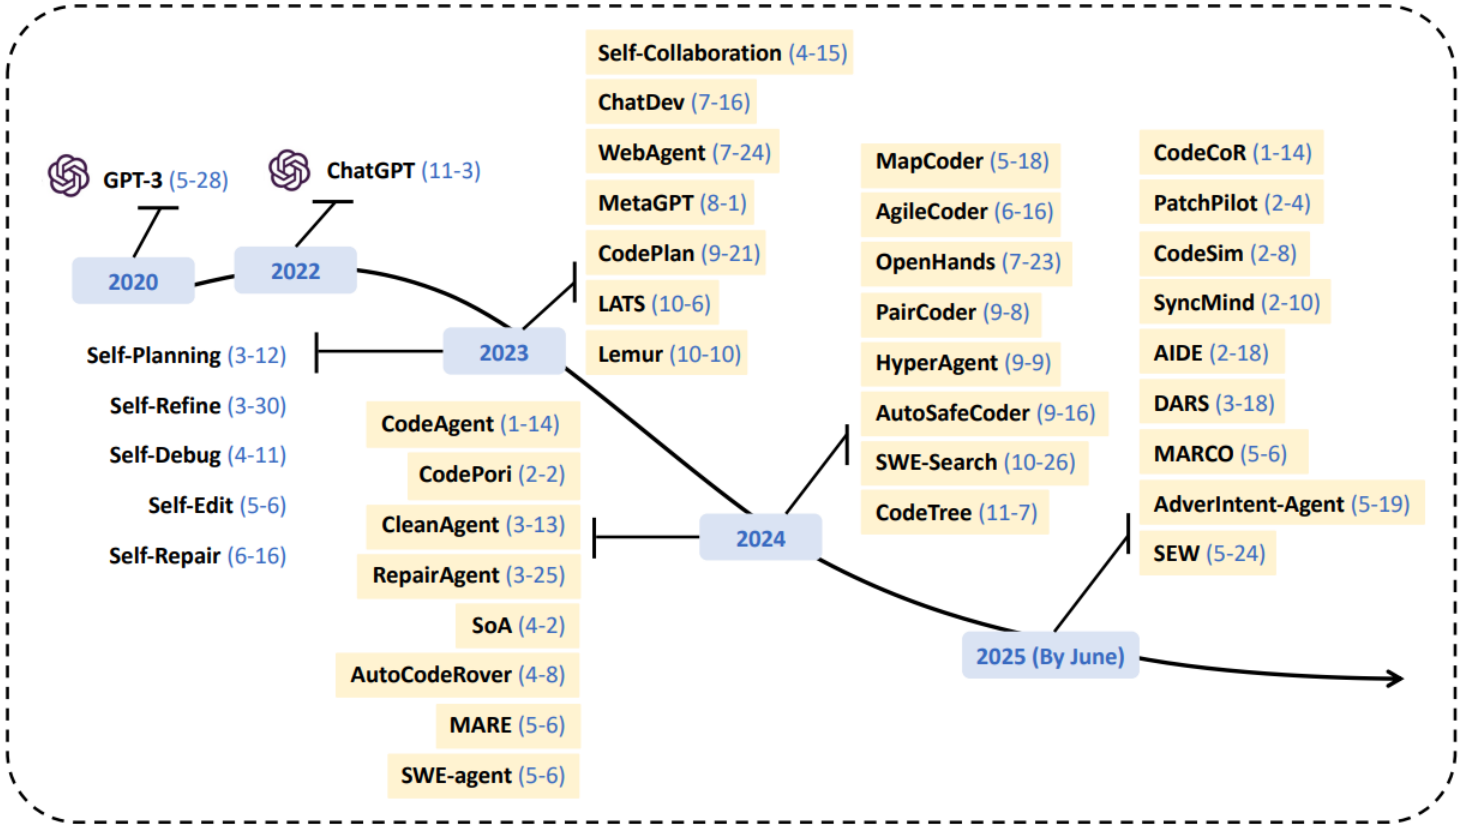


Fig. 2: Evolution of key technologies in LLM-based code generation agents, where works not marked in yellow are important prerequisite technologies.

Dong Y, Jiang X, Qian J, et al. A survey on code generation with llm-based agents[J]. arXiv preprint arXiv:2508.00083, 2025. https://arxiv.org/abs/2508.00083

```
+-------------------------------------------------------------------+
|                    2026 Tool-Use Ecosystem                        |
+-------------------------------------------------------------------+
|                                                                   |
|  +------------------+  +------------------+  +------------------+ |
|  | LOCAL AGENTS     |  | CLOUD AGENTS     |  | IDE AGENTS       | |
|  |                  |  |                  |  |                  | |
|  | OpenClaw         |  | Claude Code      |  | Cursor           | |
|  | Open Interpreter |  | OpenAI Codex     |  | Windsurf         | |
|  | OpenHands (local)|  | OpenHands Cloud  |  | Cline            | |
|  | OpenCode         |  | Google Jules     |  | GitHub Copilot   | |
|  +------------------+  +------------------+  +------------------+ |
|                                                                   |
|  +------------------+  +------------------+  +------------------+ |
|  | COMPUTER-USE     |  | MCP SERVERS      |  | MESSAGING AGENTS | |
|  |                  |  |                  |  |                  | |
|  | Claude computer  |  | 10,000+ servers  |  | OpenClaw (multi) | |
|  | and browser tools|  | TS SDK v1: ~232M |  | Custom bots      | |
|  | Gemini 3.8 Flash |  | npm downloads    |  | via MCP bridges  | |
|  | Copilot (preview)|  | (Sep 2026)       |  |                  | |
|  +------------------+  +------------------+  +------------------+ |
|                                                                   |
|  +------------------+  +-------------------------------------+    |
|  | MANAGED HARNESS  |  | PERSISTENT AGENTS (own VM and identity) |
|  |                  |  |                                     |    |
|  | Claude Managed   |  | OpenAI dots, Meta Muse,             |    |
|  | Agents, OpenAI   |  | Copilot Autopilot (private preview),|    |
|  | Agents API       |  | Cursor Projects (beta)              |    |
|  +------------------+  +-------------------------------------+    |
+-------------------------------------------------------------------+
```

https://github.com/ombharatiya/ai-system-design-guide/blob/main/17-tool-use-and-computer-agents/01-tool-use-landscape.md

写作助手的应用和风险

- 据 2025 年第一季度的统计，约 18% 的金融消费者投诉文本、24% 的企业新闻稿由大模型生成或经深度辅助润色。
- 大模型写作助手已经远不止文本生成那样直白，前沿研究将其未来定位在“认知协同”：
  - WriteHERE 把写作任务建模为检索、推理、创作交织的异构递归图，让规划与执行交替进行；
  - CogWriter 采用"规划代理+生成代理"的双层架构，模拟人类写作中的监控与回顾；
  - 多智能体路线上，Chain of Agents 分块处理并接力传递信息，Debate-to-Write 用角色辩论提升论证深度。
- 评估方法方面：BLEU、ROUGE 这类字面匹配指标在开放式写作中失效，新的评估方向倾向**带生成式思维链的偏好评估**。
- 应用路线分化：学术写作重在**溯源与引用可信**，创意写作重在**角色与情节的长程一致**。

写作助手的应用和风险

- 大模型驱动的写作助手存在着**幻觉**和**版权**两大独立风险。
- **幻觉风险：**
  - 研究表明，25年末的旗舰模型在幻觉相关基准上，对摘要任务幻觉率低至1.8%，但通用事实查询中的幻觉仍高达3%-6%。另外，不同模型在溯源证据的过程中，能力较不稳定。
  - 人类应对事实性幻觉高风险场景应该保持保留“人机回环”，即由人做最终把关的底线。
- **版权与内容：**
  - 由大模型输出的内容在版权所属仍无一个确切的定论。比如美国版权局坚持“非人类创作不受保护”（人类编辑部分可受保护）。
  - 另外，模型生成的内容容易变得“同质化”，比如部分模型的叙事风格倾向于“英雄之旅”这类套路，教育界担心学生在使用模型的时候被模型输出影响，造成“认知脱钩”。
- **幻觉与同质化内容的治理方法：**
  - RAG + 微调 + 长上下文 + 智能体工作流

LLM参与的音视频创作助手

- AI设计助手正从“效率工具”演进为“共创伙伴”，交互方式也从“指令—执行”的单向模式转向“对话—共同创作”的双向协作。
  - 生成式界面设计：Figma Make 能把一句提示词直接变成 React 应用，Gemini的canvas可以实时生成交互式网页；
  - PPT生成：很多人用过的PPT Master工具包就支持在Harness/IDE中设计并直接创作PPT；Codex，Kimi Work，Gemini都推出了对应的工具帮用户生成面向工作/汇报的演示文稿。
  - 视觉与视频生成：“AI绘画圈”众所周知的Midjourney，Stable Diffusion，Nano Banana，视频生成赛道有Sora，Kling，Seedance，Hailuo。这些主流创作模型已经有能力输出以假乱真的效果，AI短剧的火热也在持续帮助视频生成模型升温。
- 值得注意的是，社区主流观点认为，现阶段AI设计助手只能放大效率，还**不能完全替代人类审美**，真正的创作主体仍需具备一流的审美与设计能力。

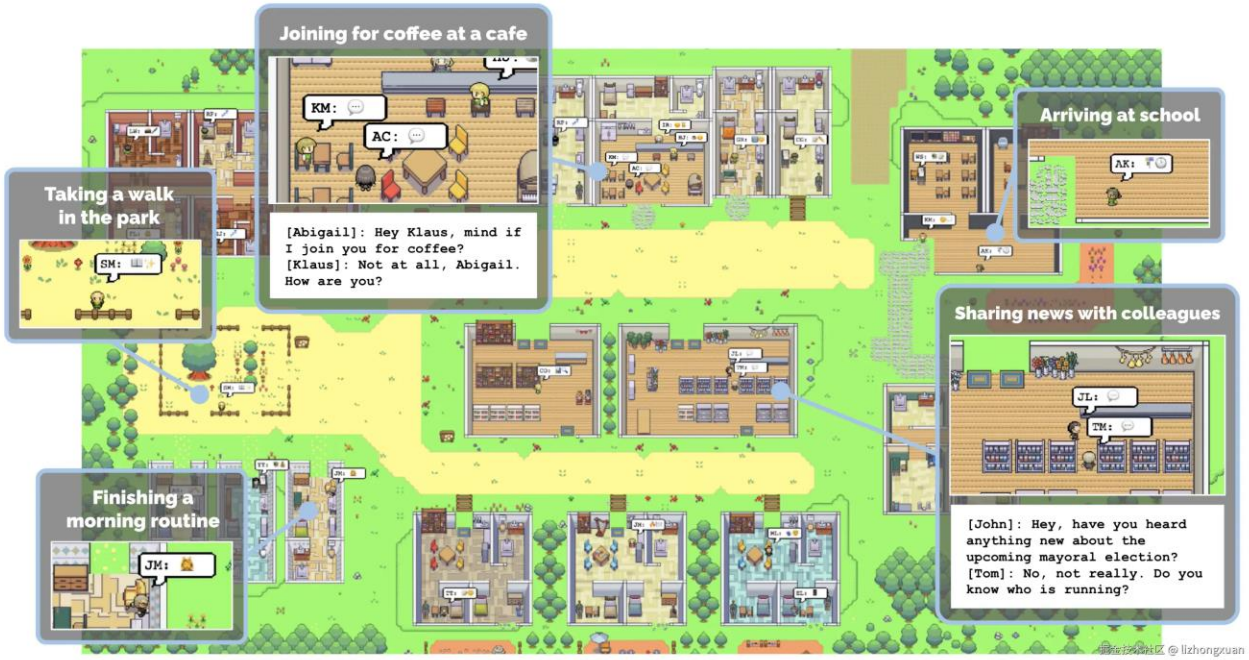


LLM辅助支持心理咨询

- 心理咨询行业面临的现实问题：专业咨询师人力短缺、治疗成本高，还有部分人对心理问题的歧视，导致大量心理支持需求没有得到满足。
- 大模型辅助心理咨询的技术路线：
  - 第一步：获取数据。真实咨询语料因隐私极难获取，研究者转而构建合成语料，模拟真实疗程；
  - 第二步：拓展工作长度。让大模型适应从单轮问答走向多疗程的长程建模工作，例如模拟来访者心理状态随疗程推进的演变轨迹；
  - 第三步：优化机制。从意图驱动与主动倾听的方向入手，例如沿着“情绪—感受—需求—记忆”的范式识别潜在需求，从被动应答转向主动提供服务。
- 目前尚存的问题：只能做辅助支持，不能替代执业咨询师；临床落地需要伦理审查、安全规范与制度的支持。

斯坦福AI小镇中的LLM社会模拟

- 2023 年，斯坦福大学与谷歌的研究人员联合发表了论文Generative Agents: Interactive Simulacra of Human Behavior，在AI领域引发了广泛关注。研究构建了一个名为 Smallville（斯坦福小镇）的沙盒RPG世界，并在其中放入了25个由大语言模型驱动的虚拟角色（NPC）。
- 斯坦福小镇之所以成为AI发展史上的里程碑，是因为它展示了一个关键事实：**当给大语言模型加入记忆与自主规划能力后，系统会涌现出复杂、逼真且令人惊叹的社会行为。**
- 这类“生成式小社会”实验验证了大模型社会模拟的可行性：
  - 个体层面的大模型能生成连贯行为，群体层面便能看到社会的涌现现象。
  - 当一组简单的个体规则彼此交织时，会自然生成复杂的群体社会现象。



LLM 社会模拟的范式演进与平台突破

- 斯坦福小镇仍然具有一定的局限性，这制约了其应用到真实社会模拟应用中：
  - 尽管生成式社会模拟具有可行性，但是大模型的行为只是模拟训练语料先验，缺乏明确对齐机制的模拟难以保证群体行为与真实人群分布之间的一致性；
  - 背后的认知与因果过程不可追踪，结果难以复现、干预和解释，还算不上严肃的社会研究方法。
- 2025 年研究重心转型：转向“类社会实验”
  - 告别早期黑箱生成，要求模拟做到可复现、可干预、可评估。
- 技术支撑：
  - AgentSociety：支持万级代理长时运行，用于政策与社会冲击实验。
  - SocioVerse：连接千万级真实用户池，精准锚定代理的人群属性与行为分布。
  - YuLan-OneSim：支持无代码建模，可扩展至十万级代理并行。
- 可靠性突破：构建“可审计”的认知仿真
  - 显式建模代理的信念、目标、记忆与推理路径。让社会模拟从单纯的“行为拟态”，演进为**认知过程与因果路径可追踪的严谨仿真。**

大模型原生助手 小结

- 本节核心：
  - 大模型已从单点内容生成跨越至任务级全流程接管；
  - 六大主流助手应用的落地现状共同表明，应用的重心正式从“能不能生成”转向“是否可信”。
- 重点应用边界回顾：
  - 编程：强调开发者主导项目和审阅代码的工作；
  - 写作：坚持人机回环，创作主体仍应是人类
  - 心理：恪守伦理与审查底线，真正服务于人，有益于人
  - 社会模拟：要求过程透明与审慎的评估

主要内容

- 20.1 大模型原生助手
- 20.2 大模型行业应用
- 20.3 AI4S：从文献助手到自主实验室
- 20.4 展望大模型：从规模到智能密度

大模型行业应用：从通用对话走向深度决策

- 随着对大模型可靠性要求的逐级升级，大模型的行业应用也在不断深化：
  - 能力迁移：从“通用文本对话”嵌入“行业专业知识与核心业务链条”。
  - 核心突破：大模型开始承担领域内的逻辑推理、高严谨性合规与自主决策。
  - 关键命题：垂直行业落地的瓶颈，正在从“语言表达能力”转向“知识深度与系统确定性”。
- 五大垂直领域落地总览

行业领域	核心应用范式	关键难点与可靠性需求
教育	“教-学-管-评”全流程闭环	教学逻辑对齐、个性化路径规划与自适应诊断
医疗	临床全流程Agent与多模态辅助	要求极致的安全性、可追溯性与医生的可控介入
金融	多智能体投研与因果风控	因果推断、逻辑校验与严格合规审查
法律	深度检索、法理推理与智能体尽调	要用法理推演与神经符号校验来保证严谨性
农业	基因育种、智能田间作业与知识服务	语言能力与基因序列、遥感数据跨模态深度融合

教育大模型中的系统性教学闭环

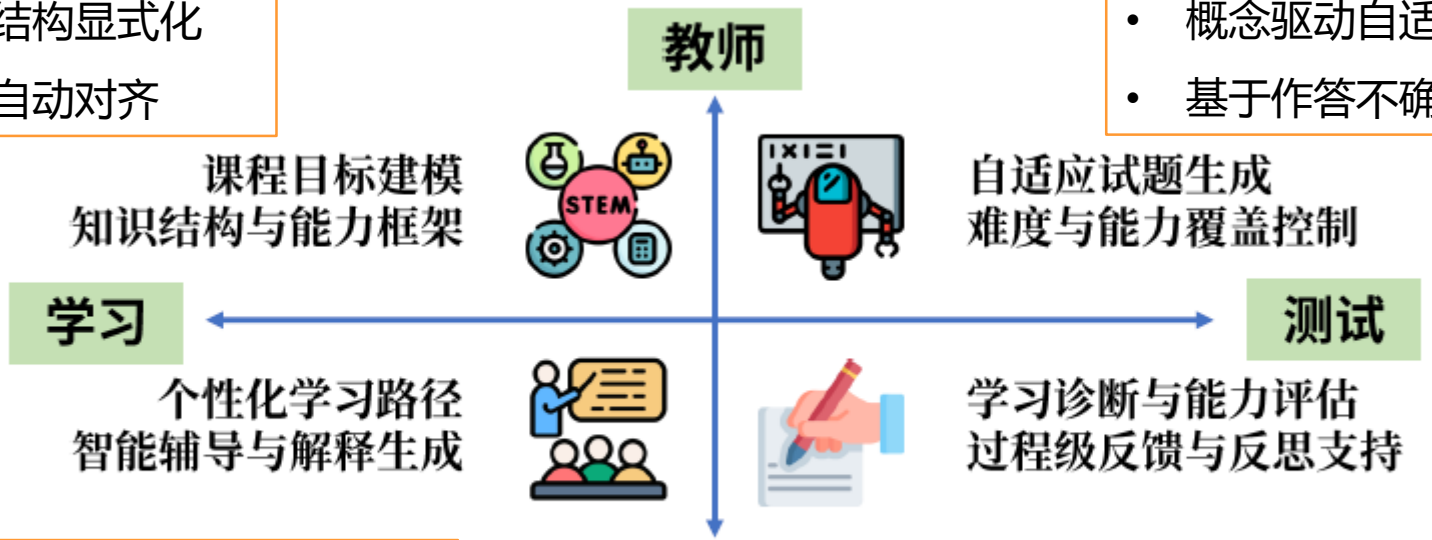
“四象限结构化范式”

教学设计与能力框架对齐

- 课程目标建模与知识结构显式化
- 机构认证与能力框架自动对齐

自适应测评与能力覆盖

- 概念驱动自适应试题生成
- 基于作答不确定性与隐藏状态的难度预测



个性化路径与学习智能体

- 动态学习轨迹规划与目标拆解
- 多模态交互与过程级引导式答疑

精确诊断与过程级反馈

- 对话日志与解题过程知识追踪
- 认知诊断与思维路径归因

这四个维度并非孤立存在，而是**通过LLM的统一语义表示与推理能力实现联动**，共同构成新一代智能教育闭环。

海内外产品生态与政策规划

- 海外产品：侧重个性化辅导与角色扮演
  - Khanmigo：基于启发式引导与过程性提示，针对K-12辅导与教师端备课场景；
  - Duolingo Max：结合 LLM 实现Roleplay场景对话练习与错误原因解释。
- 国内产品：强调“教-学-评”闭环与自适应系统
  - 讯飞星火（教育）：依托自研大模型与教育专有数据，面向课堂辅导、作业批改与学情分析；
  - 豆包爱学、文心大模型、猿辅导、松鼠AI……
- 高校与科研解决方案：本地化与知识库定制
  - ChatGLM（Edu）：主打国产开源与可定制路线，提供 RAG 检索增强、微调及本地化部署友好的校内应用方案。

政策导向（2026.04）：教育部等五部门发布《“人工智能+教育”行动计划》，明确提出分教育阶段研发人工智能教育大模型，确定战略目标：**到 2030 年人工智能与教育深度融合格局基本形成。**

医疗行业模型的评价范式和准入要求

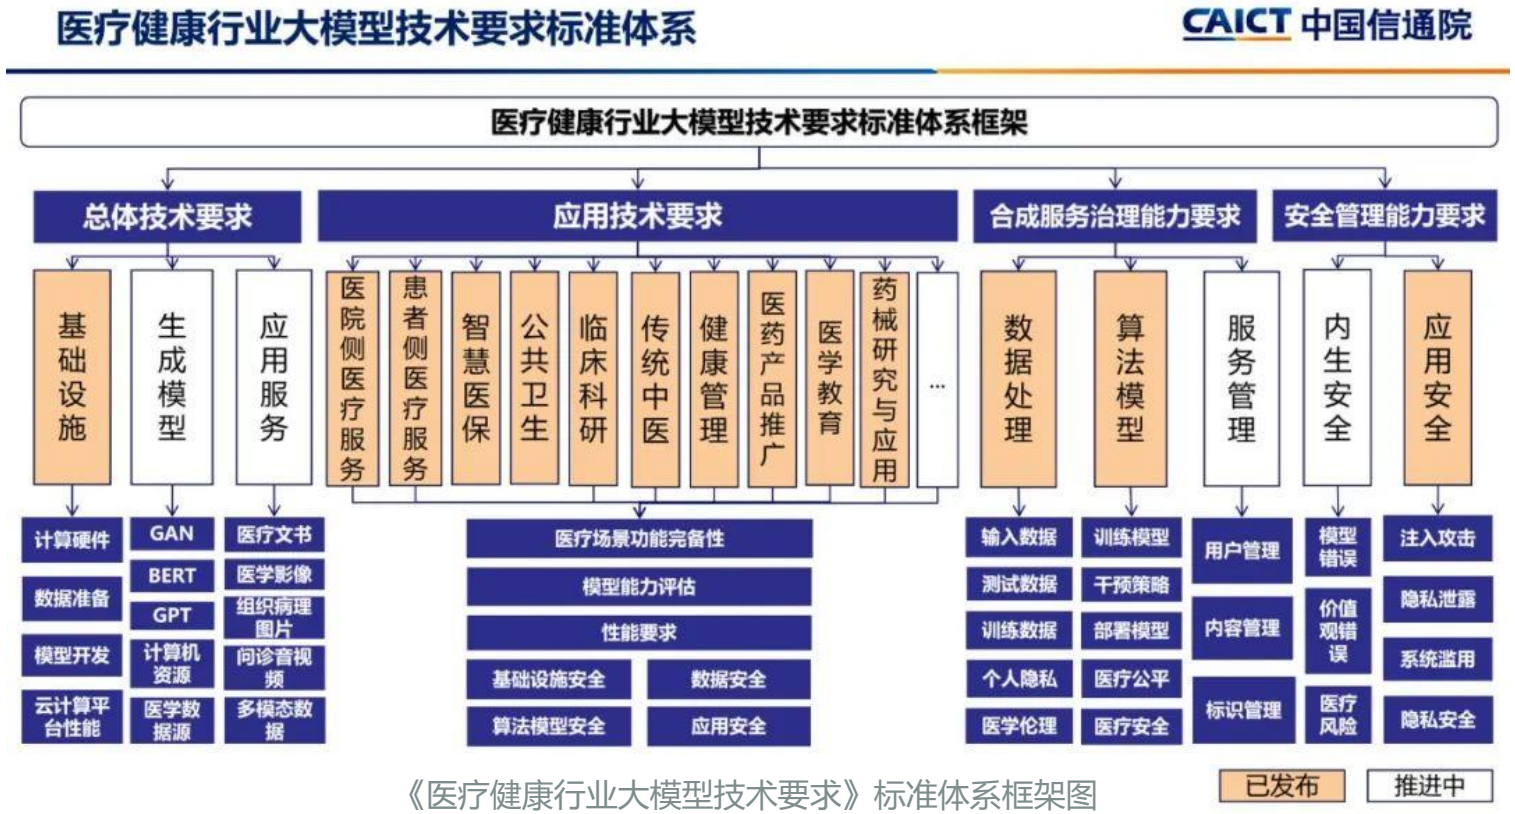
- 评价标准的变化：研究与评估重心从单纯的医学问答或相关数据集评测得分，转向评估在真实临床语境中稳定且可靠地工作的能力。

- 医疗大模型三大硬性准入要求
  - 安全性（Safety）：

    严格抑制模型幻觉，防范误诊与高风险治疗建议。
  - 可解释性（Explainability）：

    推理逻辑可验证，诊疗依据与医学文献/电子病历严格可追溯。
  - 交互性（Interactivity）：

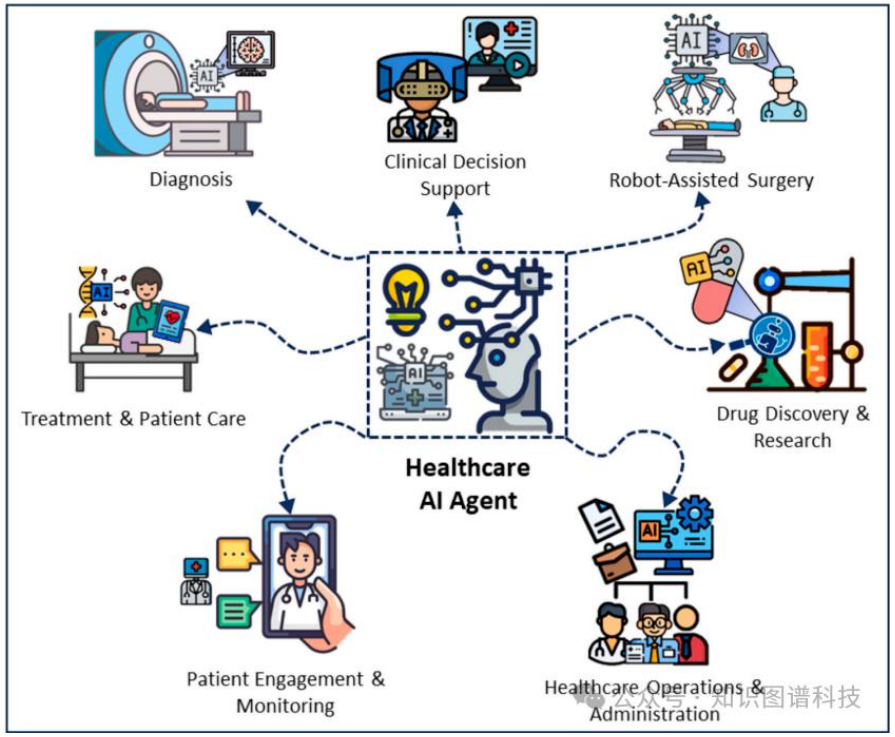
    具备主动追问、信息总结与多角色顺畅协同能力。



《医疗健康行业大模型技术要求》标准体系框架图

全流程医疗智能体的技术演进

- 医疗智能体从被动问答工具升级为可以组织流程的管理工具：
  - 覆盖：病史采集 → 针对性追问 → 检查建议 → 结果解释 → 鉴别诊断 → 总结报告。
  - 关键节点配置医生介入策略（Doctor-in-the-Loop），确保**AI流程编排 + 医师最终决策**这一安全可控形态。
- 技术路线演进：
  - 训练范式：早期使用SFT/领域知识微调，现阶段主要做“持续预训练 + 慢思考/强化学习”；
  - 能力拓展：不再局限于纯文本问答，逐渐接手“多模态影像分析 + 医疗智能体工作流编排”。



医疗大模型能力建设路径

维度	代表性路线/工作	核心技术攻坚与临床价值
知识适配与开源生态	• **Med-PaLM 2/Me-LLaMA/MedFound** • **HuaTuo**(华驼) **/PMC-LLaMA**	• 强基座结合医学适配与文献/临床笔记持续预训练 • MedFound实现诊断决策偏好对齐 • PMC-LLaMA证明130亿参数开源模型通过大规模知识注入亦具备强竞争力
“慢思考”慢推理训练	• **M1** • **Fleming-r1** • **MedS3**	• **测试时扩展**：m1探索推理时扩展收益并防范过度推理/瞎编风险 • **可验证推理**：Fleming-r1采用冷启动+强化学习强化逻辑稳定性 • **过程监督**：MedS3引入软过程监督信号约束推理步骤质量
多模态临床感知	• **TITAN** • **MIMO**	• **病理底座**：TITAN将“全切片自监督+多模态对齐”打造为可复用底座 • **精细定位**：MIMO实现视觉指代与像素级定位，满足临床看图凭据需求
真实临床评测	• **ArchEHR-QA** • **MedChain**	• **证据可追溯**：ArchEHR-QA 要求回答必须严格绑定电子病历证据 • **连续决策**：MedChain 评估复杂临床工作流中的动态连续决策能力

医疗行业产业案例与系统能力

- 国内案例注重平台化应用能力与诊疗闭环
  - 腾讯健康：以“一底一台双引擎”融合DeepSeek与混元大模型，主要接入院内场景，服务全国医院。
  - 蚂蚁AQ：以医疗大模型为底座，对接200余家医院云陪诊，主要面向C端咨询与院后服务。
- 国际标杆主要针对临床减负与循证合规
  - Oracle Health：推出嵌入 EHR 的 Clinical AI Agent，覆盖 30 多个专科，通过自动化临床记录减轻医生文书负担（据称可减少约 30% 文书时间）。
  - OpenEvidence：主打“循证检索与可追溯引用”，官方称已与 NEJM、JAMA、NCCN 等权威机构深度合作，覆盖超 40% 的美国医生。
- 总体趋势：向系统能力转移
  - 行业竞争已彻底从早期的“单轮回答质量”或“模型参数大小”，转向权限隔离、合规审计与私有化部署等系统级能力。
  - 能否将大模型稳定且安全地嵌入医院现有的EHR（电子病历）与诊疗工作流，或许将成为决定产品能否规模化商业落地的根本。

金融大模型：关注因果与合规

- 核心范式演进：因果推断与逻辑校验
  - 能力阶梯跨越：早期的文本抽取与情感分析任务，全面升级到至高风险场景下的因果关系发现与逻辑严密校验任务。工作方式也从从单体问答转向多智能体博弈协作。
  - 零幻觉治理机制：引入自然语言推理（NLI as a Judge）自动检测自我推理矛盾，利用LAVA框架识别金融文档内部数字与条款的逻辑冲突。
- 生产端协作与架构降本
  - 多智能体研报流水线：模拟“宏观分析师、微观数据员、合规审查员”角色分工，引入FinDebate等辩论对抗机制打磨论证逻辑，提升研报客观性。
  - 高效基础设施（FinMoE）：采用混合专家（MoE）稀疏激活架构，显著降低中文金融大模型的高昂推理与计算成本。
- 需要注意的应用能力限制
  - 在纯结构化表格的信用评级场景，传统机器学习的稳定性与精准度仍优于生成式大模型；大模型的绝对优势在于融合文本、动态图谱等非结构化信息。

法律行业中的大模型逻辑推演

- 我们知道，通用大模型仅依赖概率词汇预测，缺乏自我纠错与法理审查能力；斯坦福有研究指出，通用SOTA模型在特定法律查询中的幻觉率曾高达69%–88%。
- 因而应用于法律这种对逻辑和事实证据要求极为严苛的行业，需要从单纯的文本表征与语言检索，升级为遵循法律“三段论”、严密推演与结果可验证的法理思维逻辑。
- 底层技术路线与方案支撑：
  - 神经符号架构（L4M）：融合符号逻辑与形式化验证，为高风险法律判决与赔偿金计算提供数学证明级的逻辑保障。
  - 强化学习与慢思考（Legal-R1）：引入信息增益奖励机制并增加测试时计算量（Test-Time Compute），显著提升复杂法律思维链（CoT）的推演质量。
  - 结构化逻辑约束（SyLeR）：强制模型推理遵循“大前提—小前提—结论”的传统法律三段论，消除事实与法条适用中的逻辑断层。

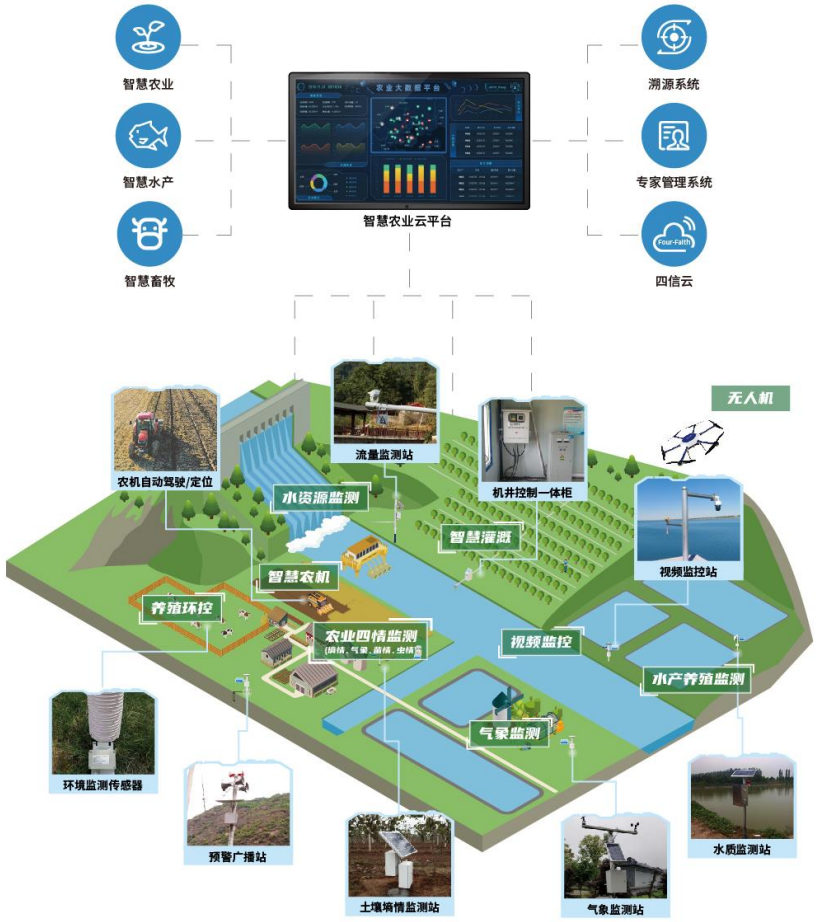
法律行业中的典型实践方案

- **文书生成范式：**采用LexKeyPlan框架，确立“先规划—后检索—再生成”流向，配合置信度复制解码（CoCoLex）严防文书幻觉。
- **合规与深度检索：**引入LegalAgentBench自动化执行尽职调查，利用CitaLaw实现法条与判例引证的全流程可验证。
- **现实司法与产业生态：**
  - 2025年12月，最高人民法院启用新版平台并集成一定的AI辅助能力，如传统诉状智能转写、智能辅助填写等；
  - 通义法睿在2025年推出了更强的API接口，支持企业将法律AI助手快速集成到钉钉或内部系统中，从单一的SaaS工具转向PaaS服务。



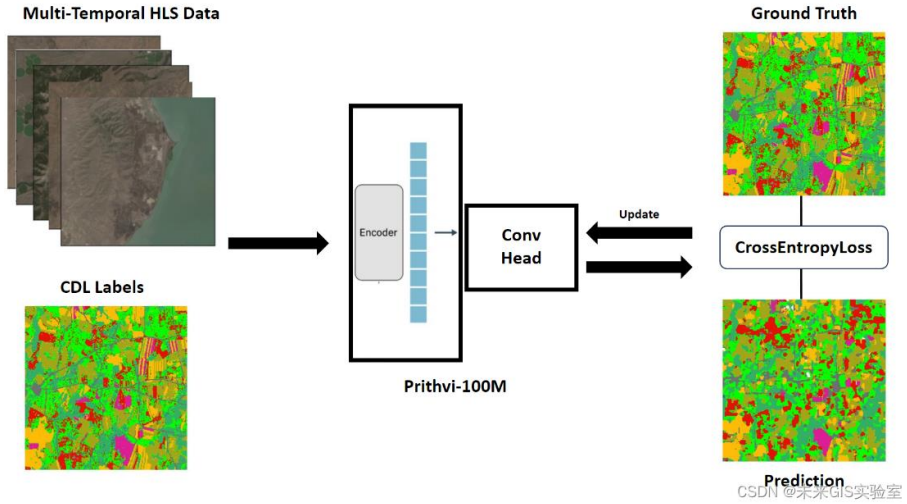
农业大模型的感知、决策与设计

- 生物育种5.0：数据驱动的从头生成设计
  - 基因突变预测（AgroNT）：基于 48 种作物基因组预训练，实现对数百万突变位点的零样本（Zero-shot）硅基筛选，大幅降低试错成本。
  - 新型生物工具设计（ProGen3）：基于数十亿蛋白质序列训练，成功从头设计出自然界不存在的 OpenCRISPR-1 基因编辑工具，推动育种从“筛选”走向“设计”。
- 田间具身智能：毫米级感知与精细作业
  - 实时精准除草（See & Spray Ultimate）：约翰迪尔结合视觉大模型与实时推理，实现毫秒级“作物-杂草”区分，除草剂用量减少三分之二以上。
  - 动态水肥决策（LLM-RL Agent）：将作物水分胁迫指数编码为自然语言进行强化学习决策，单篇实验研究显示可节水 15%–30%。



农业大模型的感知、决策与设计

- 知识服务与智慧供应链：抗幻觉RAG与空间地理底座
  - 农艺问答：严格限定本地知识库RAG以克服幻觉，在肯尼亚实证中展现高采纳率；
  - 中国农大神农大模型3.0配套千万级知识图谱与专用智能体。
- 遥感与金融风控：
  - NASA与IBM联合发布开源Prithvi地理空间底座，支持全球作物产量预测；
  - 单篇研究显示，云原生AI平台可将农业信贷处理时间缩短81%、违约率降低30%。





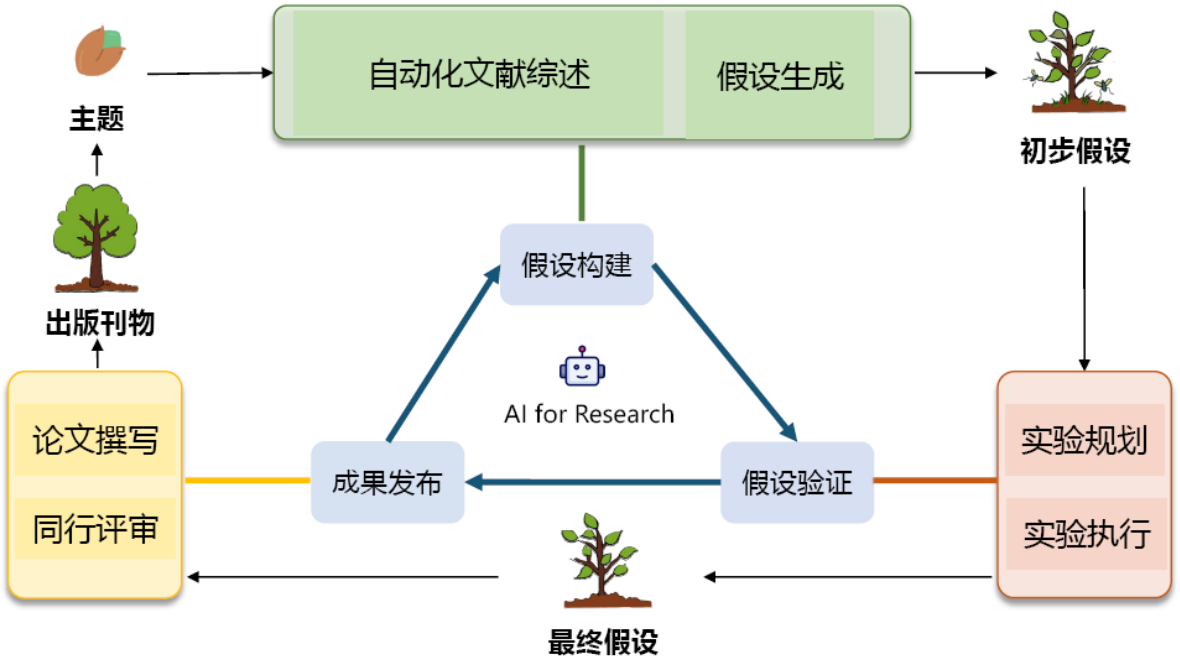
CSDN @未来GIS实验室

主要内容

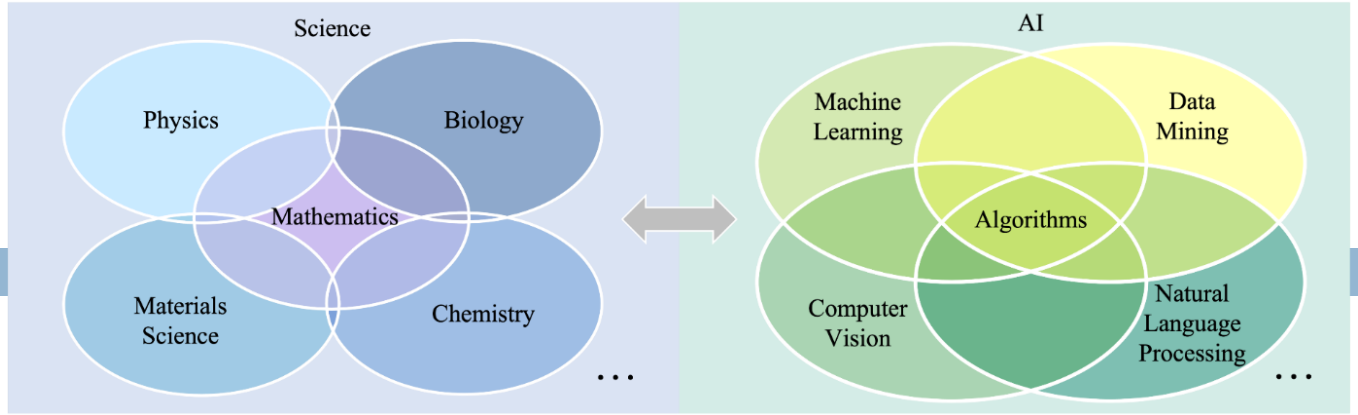
- 20.1 大模型原生助手
- 20.2 大模型行业应用
- 20.3 AI4S：从文献助手到自主实验室
- 20.4 展望大模型：从规模到智能密度

AI4S：从文献助手走向自主实验室

- 核心：大模型与生成式 AI 深入科研现场，驱动科学发现范式从“辅助工具”向“全流程自主闭环”跨越。
- 科研范式的历史性跨越
  - 大模型在科研中的传统定位：以“检索文献、撰写综述、辅助代码”为主的辅助性工具；
  - 当前大模型的科研智能演变：深入科研核心现场，全面参与“假设生成→实验/仿真设计→自动化执行→数据解析→迭代优化”的科研完整流程；
  - 核心基础设施：AI算法与自动化实验硬件深度结合，“自主实验室（Autonomous Lab）”正成为科学研究的新型基础设施。



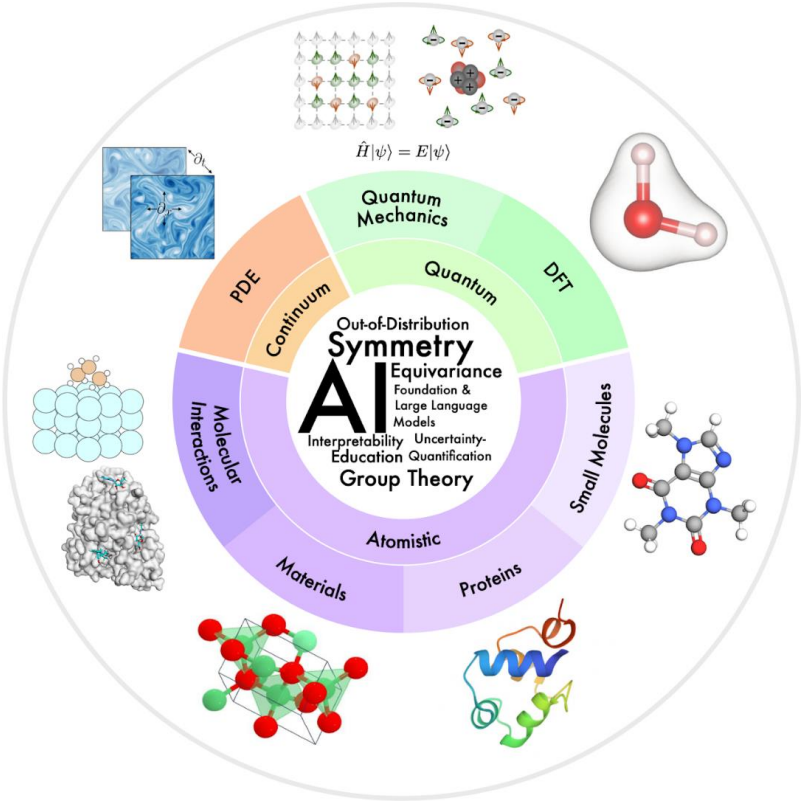
区分三个AI4S概念



- **AI+X**：把已有AI工具用到某个科学领域
  - 把图像识别用于显微图像分析，把大语言模型用于文献整理，把机器学习用于材料性质预测……
  - 先把工具用好，知道能做什么、不能做什么
- **AI for Science**：为科学问题专门发展AI模型和平台
  - 为了科学问题本身去发展AI：分子是图结构，蛋白质三维构象，大气是时空连续场，社会是复杂互动系统……
  - 科学问题本身会要求我们改造模型结构、训练目标、评测方式和工具链
- **X for AI**：用科学知识解释、改造、启发AI，让科学反过来帮助AI
  - 数学帮我们理解优化、泛化和表示学习；
  - 物理启发能量模型、对称性和动力系统视角；
  - 认知与神经科学启发注意力、记忆和类脑计算。

为什么现在AI for Science变热?

- 科学数据越来越大
  - 基因、蛋白、气象、材料、社会数据快速积累
- AI模型越来越强
  - 深度学习、大模型、多模态、科学智能体……
- 计算平台越来越成熟
  - GPU、自动微分、开源框架、AI实验室……
- 公众专注度提高，说明AI已经从工具走向科学史的一部分
  - 2024年诺贝尔化学奖：计算蛋白设计和结构预测；
  - 同年诺贝尔物理学奖：人工神经网络。

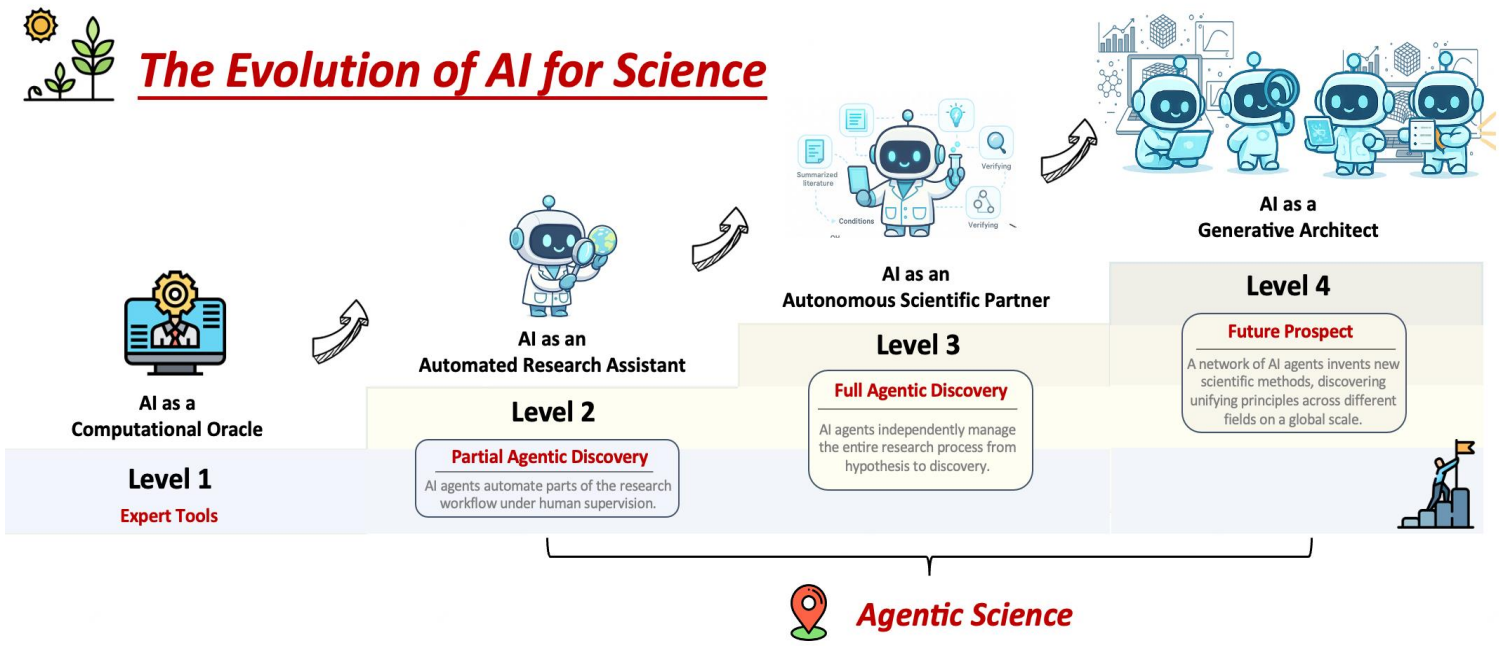


AI4S不是单一技术突然出现，而是数据、模型和平台共同成熟后的结果。

AI在科学中的四级角色

- **Level 1 专家工具，解决单个任务：**例如自动识别显微图像中的细胞
- **Level 2 自动助手，完成部分研究流程：**生成候选实验方案、调用模拟器、整理结果
- **Level 3 科学伙伴，参与假设—实验—分析闭环**
  - 例如：AI提出下一轮材料合成条件，机器人实验室执行，表征结果反馈给AI，AI再更新策略……
  - 这时AI与人共同推进发现过程。
- **Level 4 AI“独立科学家”**
  - 提出问题
  - 设计实验
  - 执行验证
  - 写出论文
  - 接受审查

“端到端”科研

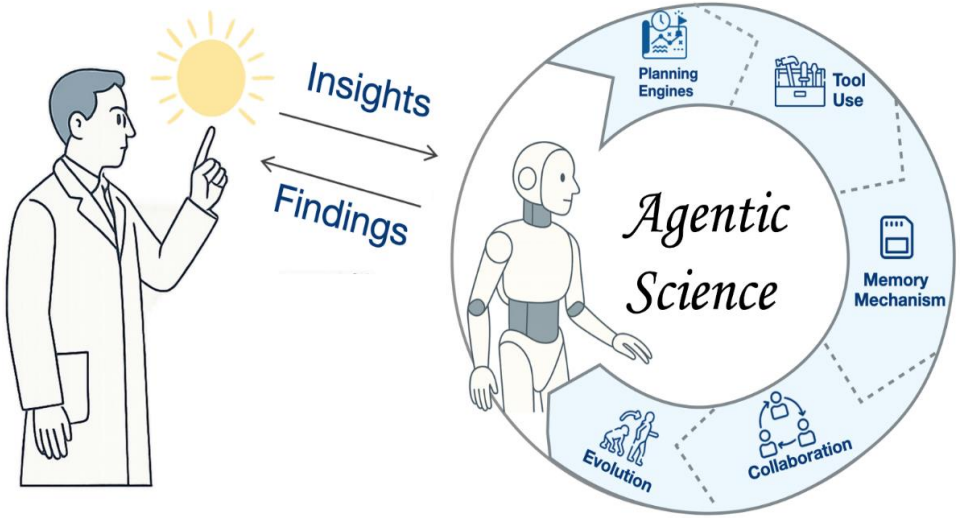


LLM驱动的科学发现

- 所谓“LLM驱动”定义是：以语言模型作为“认知与调度引擎”，通过自然语言理解、逻辑推理与工具调用，全流程赋能科研生命周期。
- 不取决于具体研究对象（如化学、生物或社会科学），而取决于语言能力是否在科研链路中承担实质性的推理与协作角色。大致有如下四类：
  - **规划引擎：**将高阶、复杂的科学问题拆解为结构化的可执行子任务链。
  - **检索与阅读引擎：**跨海量文献与数据库定位关键证据，自动提取、比对并处理知识冲突。
  - **推理与调度引擎：**协同外部专业工具、计算算法及机器人实验平台，驱动“假设-验证”闭环。
  - **写作与表达引擎：**整合多源实验数据与推理过程，自动化生成高质量研究报告与学术论文。

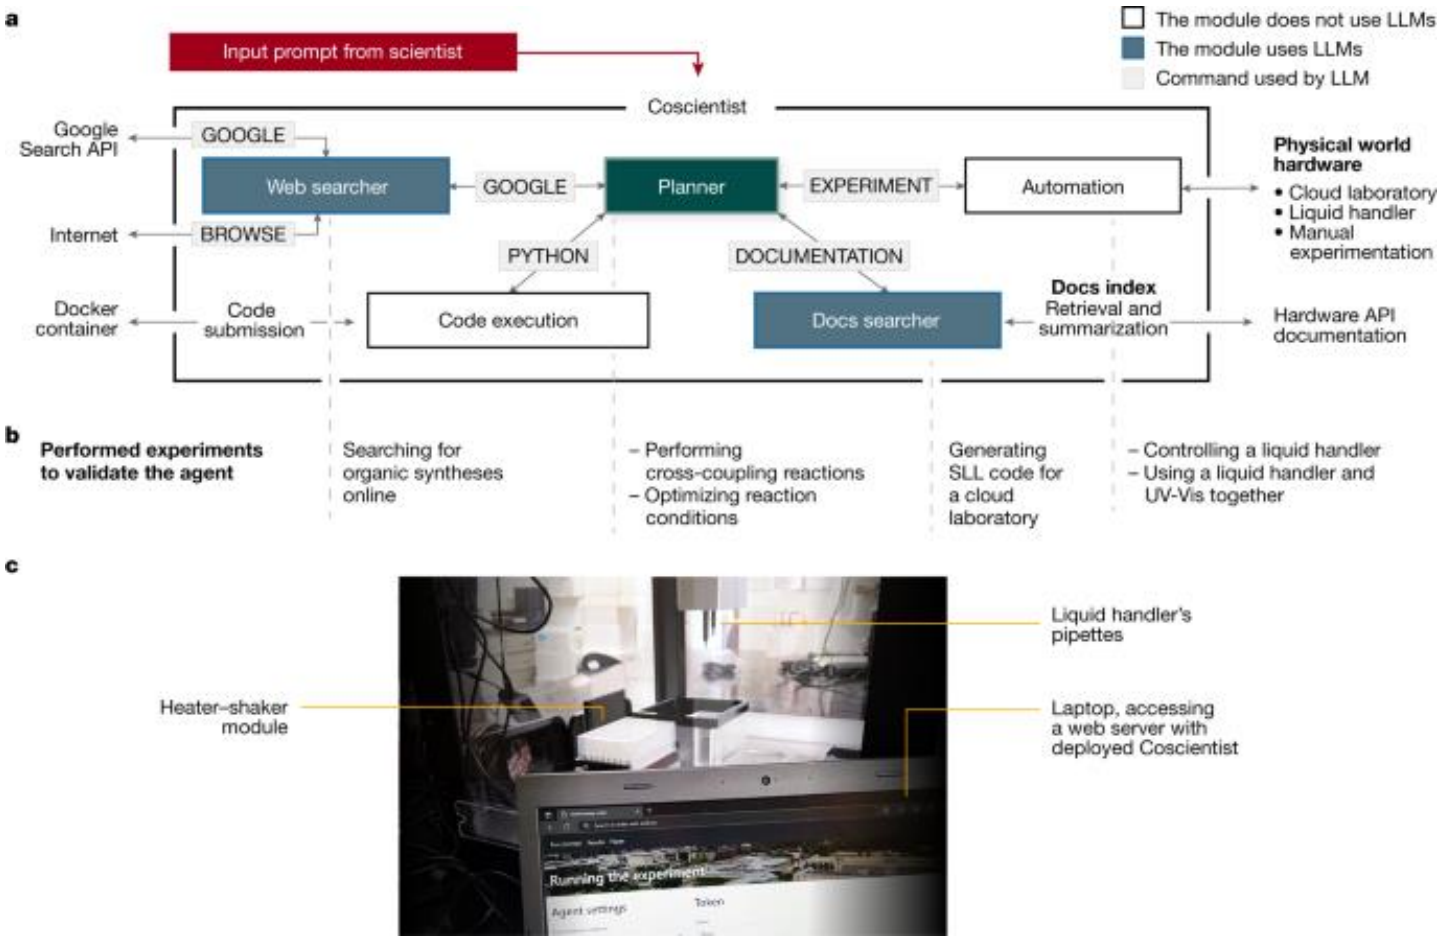
Agentic Science：智能体参与研究闭环

- 科学智能体需要规划、工具调用、记忆、协作、优化
  - 规划：把复杂问题拆成多个子问题。
  - 检索：从网页、论文、数据库和文件中查找证据。
  - 阅读：比较来源、提取关键事实、发现矛盾。
  - 工具调用：运行代码、分析表格、生成图表、调用专业工具能力。
- 研究流程包括：
  - 假设生成、实验设计、结果分析、验证迭代。
- 研究目标：
  - 不取代科学家，但可以形成“人+AI共同发现”的模式。



Coscientist化学智能体

- 会查资料、写代码、能操作实验设备；
- 基于大语言模型进行文献检索、计划生成、代码执行；
- 通过机器人实验平台执行部分化学实验；
- 展示了“AI+自动化实验室”的闭环雏形。



自动综述进入日常科研

- 在第一个章节中我们的典型案例：以Gemini Deep Research和ChatGPT PRO为代表的新型工具，把“多步检索 + 资料综合 + 报告生成”产品化。而当它们专注于科研文献工作时：
- 它们适合做什么：为选题、课程报告、文献阅读提供起点。
  - 快速了解一个陌生领域。
  - 梳理研究问题的技术脉络。
  - 比较不同观点和资料来源。
- 它们不适合直接做什么？
  - 不能把生成报告当作最终论文。
  - 不能替代原文阅读和实验验证。
  - 不能保证没有遗漏、误引或幻觉。
- 对使用者的要求
  - 要求会检查引用、追溯原文、指出不确定性、补充反例
  - 把AI素养从“会用提示词”推进到“会审查证据”



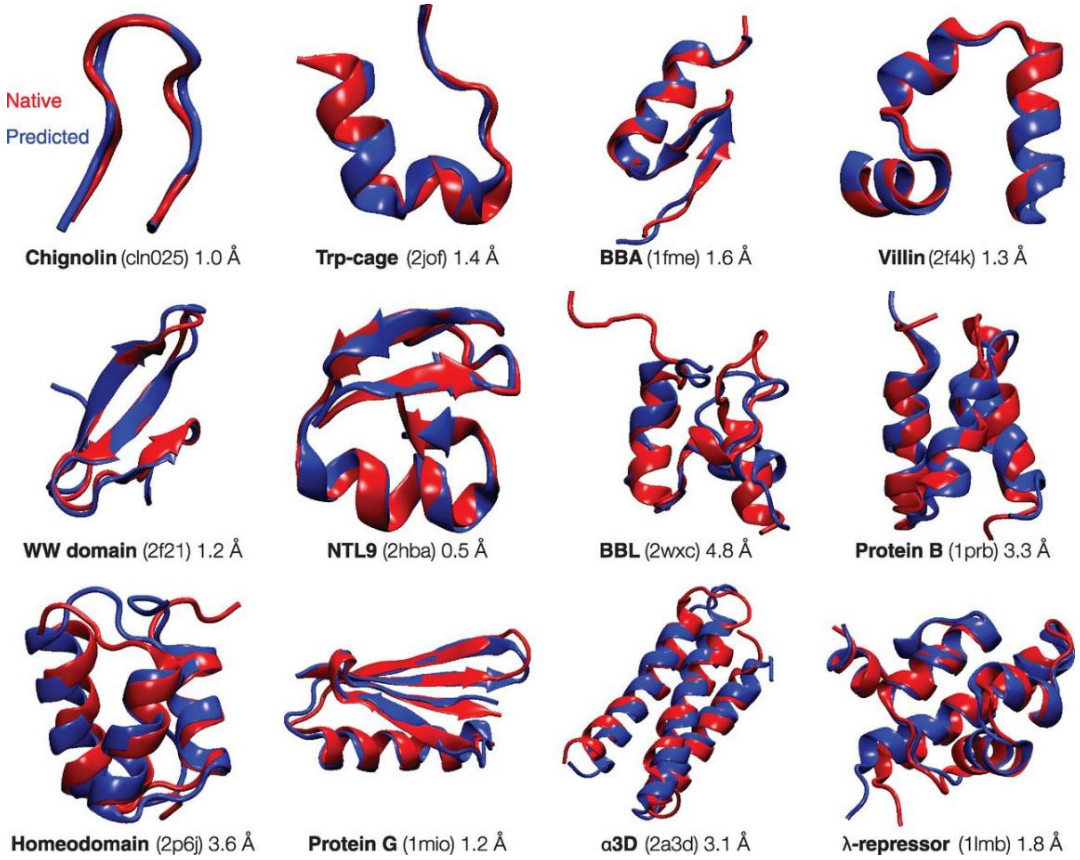


拓展了解：非语言模型驱动的科学发现

- 定义：直接面向物理、化学、生物等领域的结构化数据进行建模，以拟合与发现客观科学规律为目标的数据驱动路线。大致包括：
  - **处理专用数据形态的：**处理分子序列（氨基酸/核酸）、图结构（原子与化学键）、连续物理场（全球气象场/电磁场）等非自然语言数据的科学模型。
  - **物理规律驱动的：**拟合三维空间结构、热力学稳定性、流体演化与微分方程，而非自然语言语义的科学模型。
  - **架构与目标分化的：**即便底层和语言模型一样，使用Transformer等通用骨干网络，其损失函数与优化目标依然由能量标量、空间坐标误差或物理约束（如 PINN 残差）决定的科学模型。

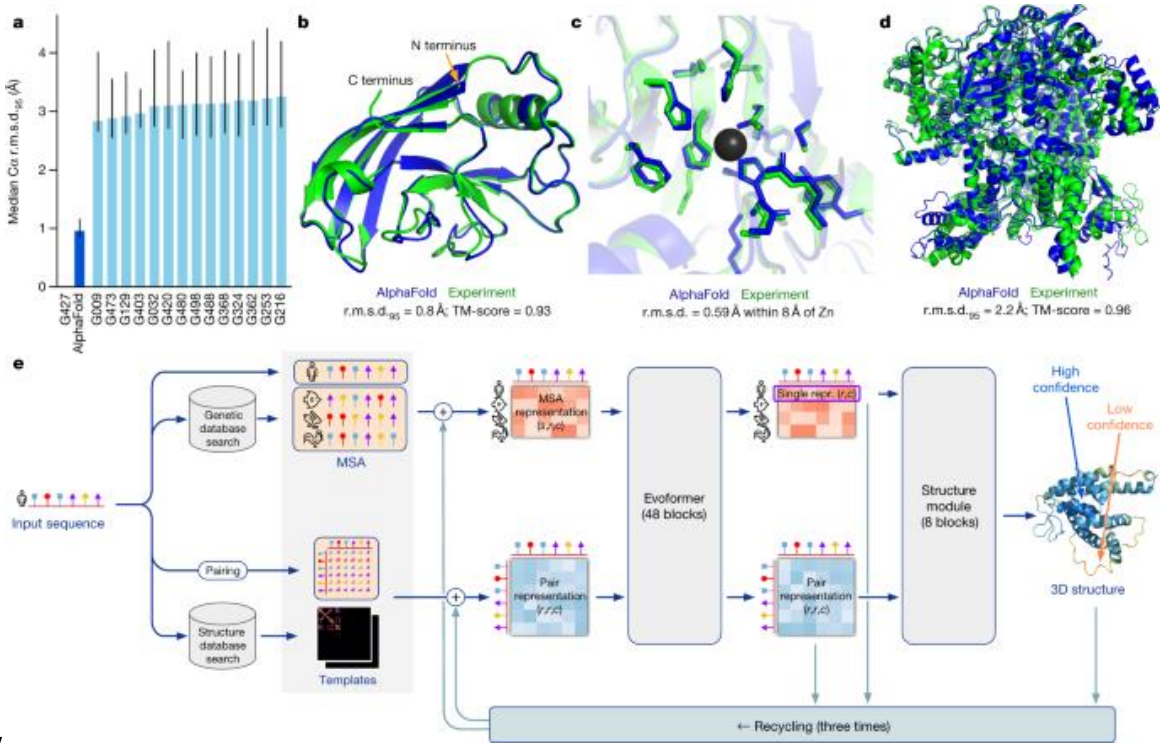
案例1：蛋白质结构探索的重要性

- 蛋白质是生命机器，功能常与三维形状相关
- 实验测结构昂贵、耗时，不可能覆盖所有蛋白结构
- 预测是生命科学长期核心难题之一
  - 蛋白结构预测被称为“50余年挑战”
  - AI尚且不能替代实验，目前主要帮助科学家加速获得结构假设，再由科学家用实验或进一步计算验证。



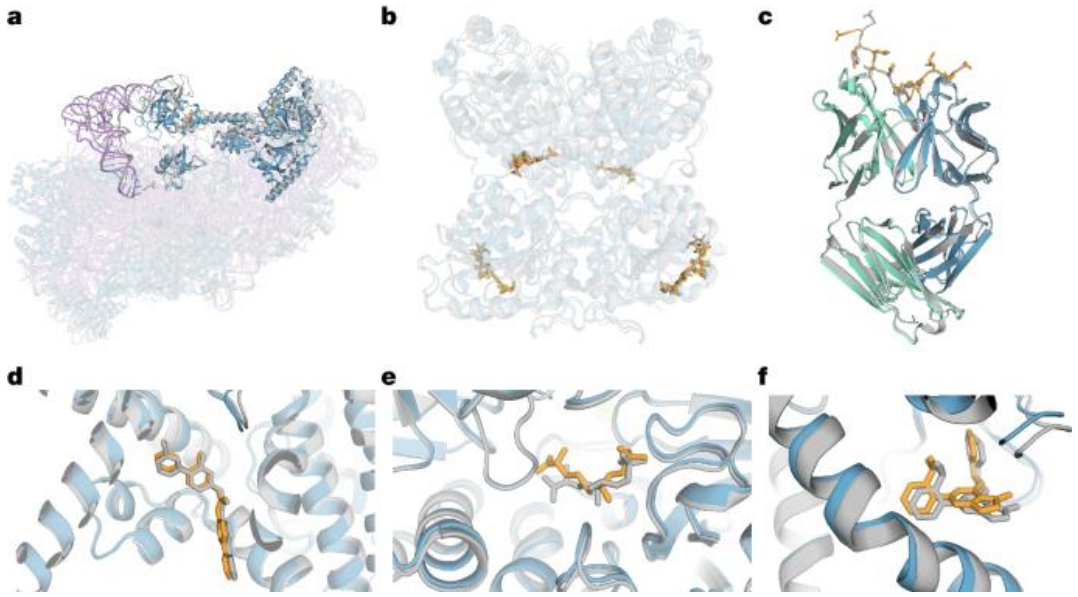
AlphaFold 2：从序列预测结构

- **AlphaFold 2是AI4S走进公众视野的标志性事件，体现了AI对科学问题的强大建模能力。**
- 模型不仅学习单个序列到结构的关系，还利用了进化信息。多个相关蛋白在进化中会共同变化，这些共同变化可以提示哪些氨基酸残基在空间中可能彼此接近。
  - 输入：氨基酸序列与进化相关信息
  - 输出：蛋白质三维结构及置信度
  - 意义：在CASP14中达到接近实验精度的预测水平。
- AlphaFold 2突破了“模型处理序列”的简单思路，把生物进化信息、几何结构和深度学习结合起来。



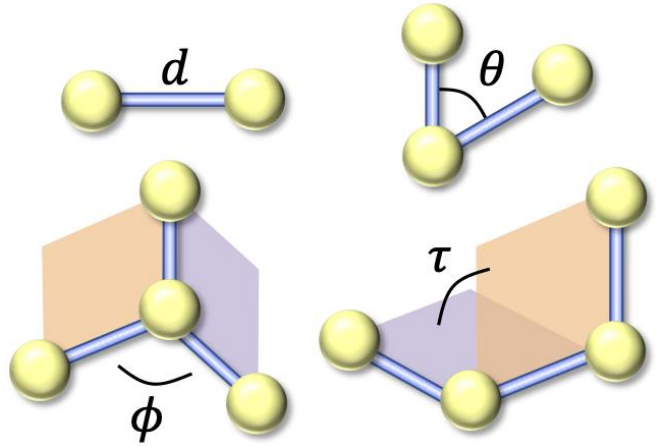
AlphaFold 3：从单个蛋白到分子相互作用

- AlphaFold 3把问题从“单个蛋白怎么折叠”推进到“多种生物分子如何共同形成复合物”。
- 药物研发尤其关心“谁和谁结合、结合姿态是什么、结合是否稳定”。
- 输入上不再局限于单个蛋白序列，而是可以包括蛋白、核酸、小分子、离子和修饰残基等多种分子类型。输出是它们共同形成的三维结构。
- 方法上引入扩散式（diffusion）结构生成框架，**和常见的“AI绘图”原理类似**



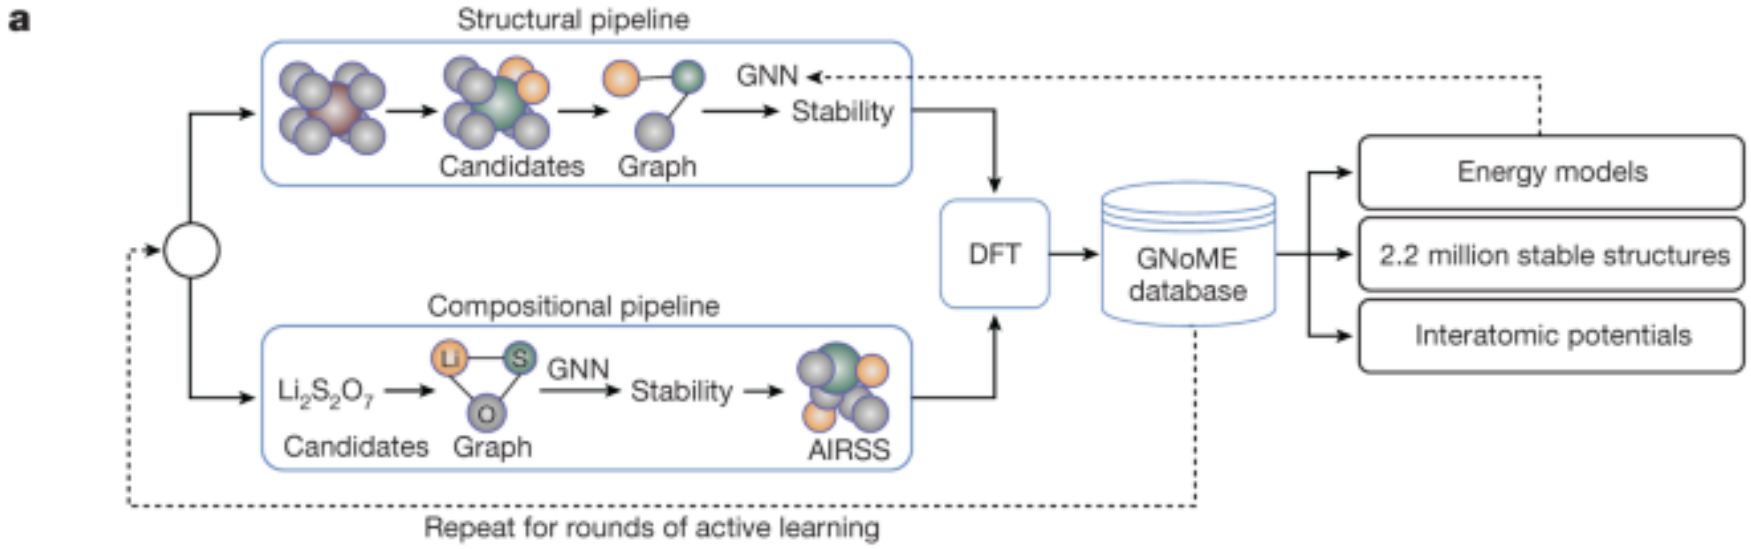
案例2：材料发现的难点

- 材料空间巨大：元素组合、晶体结构、制备条件都很多
- 传统方法如何进行搜索？——速度都很慢
  - 科学家的经验和直觉
  - 计算模拟
  - 实验合成测试、重新多次循环迭代
- AI目标：先筛出更可能稳定、可合成、有价值的候选材料
  - AI的作用是根据已有规律，先为科学家指出更有希望的区域，减少盲目搜索



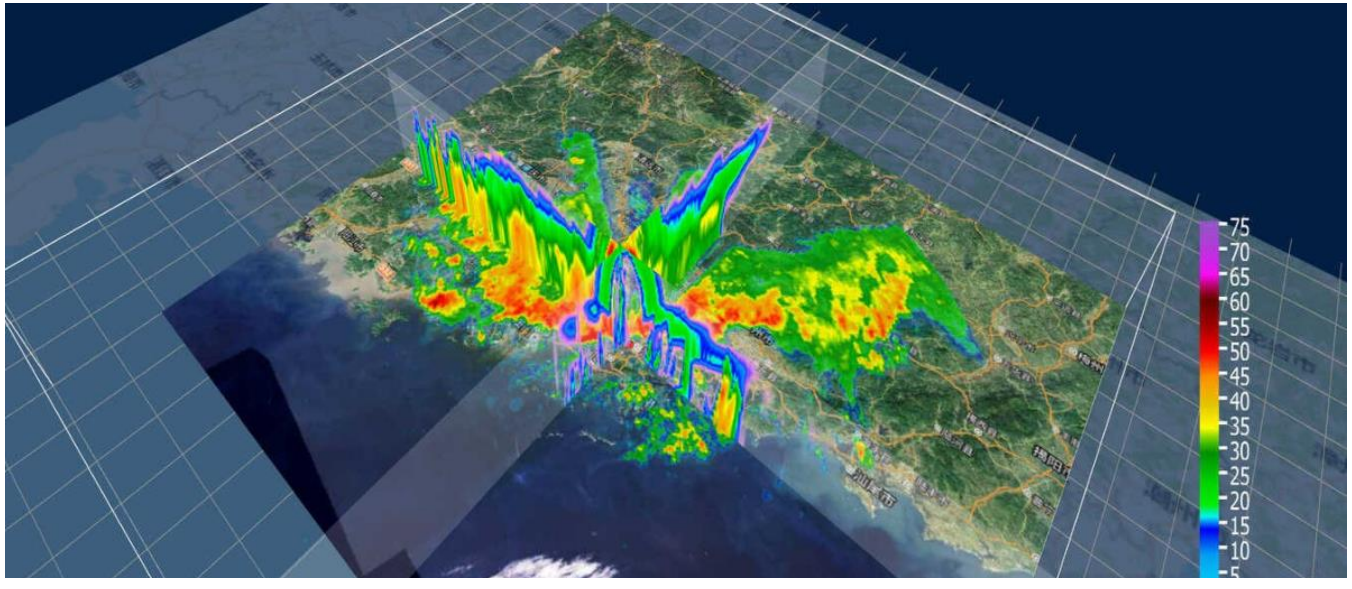
GNoME：用图神经网络筛选新晶体

- 把晶体看成“原子—键”的图结构
- 用图神经网络预测稳定性，大规模主动学习提出候选结构，再结合计算方法验证
- DeepMind报告发现约220万候选结构，其中约38万稳定候选进入材料项目数据资源



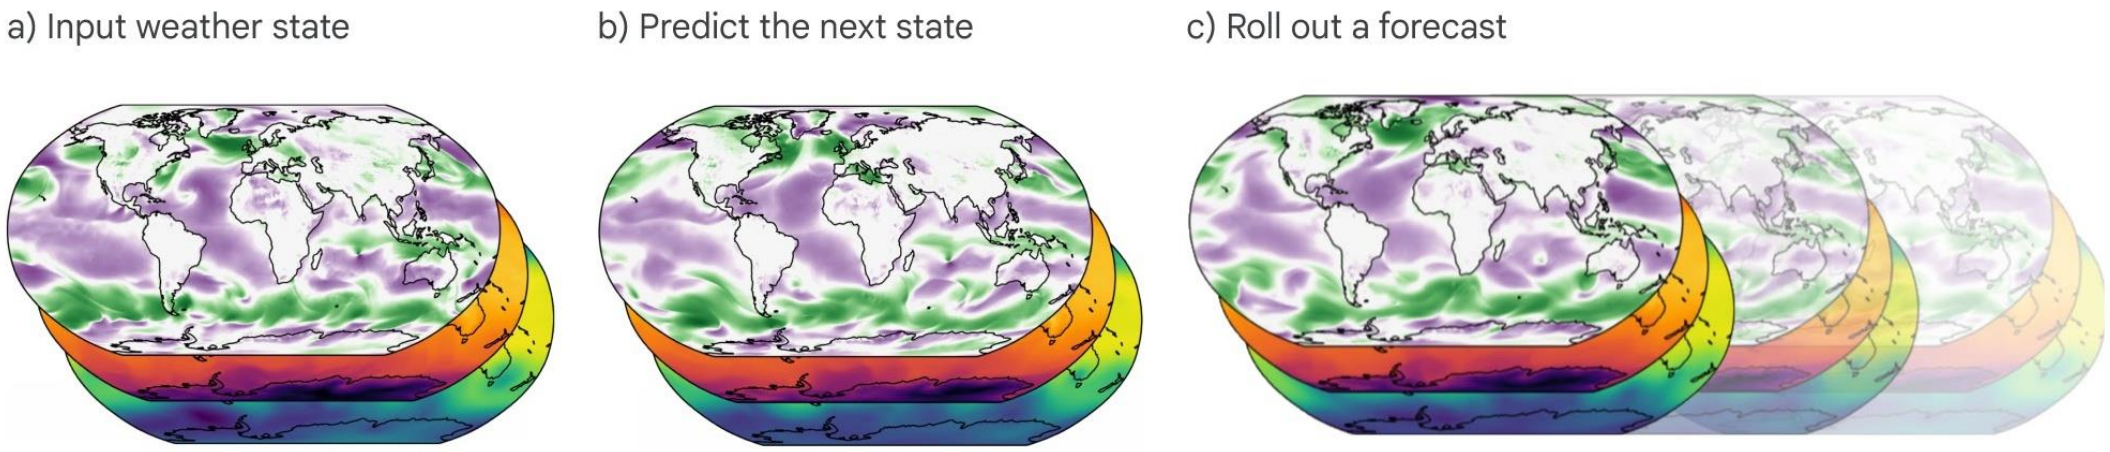
案例3：天气预测，从数值模式到AI模型

- 传统数值天气预报：求解大气物理方程，计算量巨大
  - 依赖全球观测数据、数据同化、大气动力学方程和超级计算机
  - 每次预报都要从当前大气状态出发进行复杂积分
- AI天气模型：从历史再分析数据中学习大气演化规律
  - 经过训练的AI模型，可以快速从当前状态预测未来状态
- 定位：替代或加速传统流程的一部分，而非取代物理观测，适合早期预警和快速粗略估算



GraphCast：一分钟级的全球中期预报

- 输入：当前和过去的大气状态；输出：未来多步全球天气场
- 代表性结果：以0.25度分辨率预测未来10天的数百个天气变量，推理时间可达一分钟级。
  - 说明AI模型在训练完成后，可以显著加速预报生成
- 传统数值模式类似于每次都重新求解复杂物理方程”，GraphCast则从大量历史演化中学会了一个快速近似模拟器。

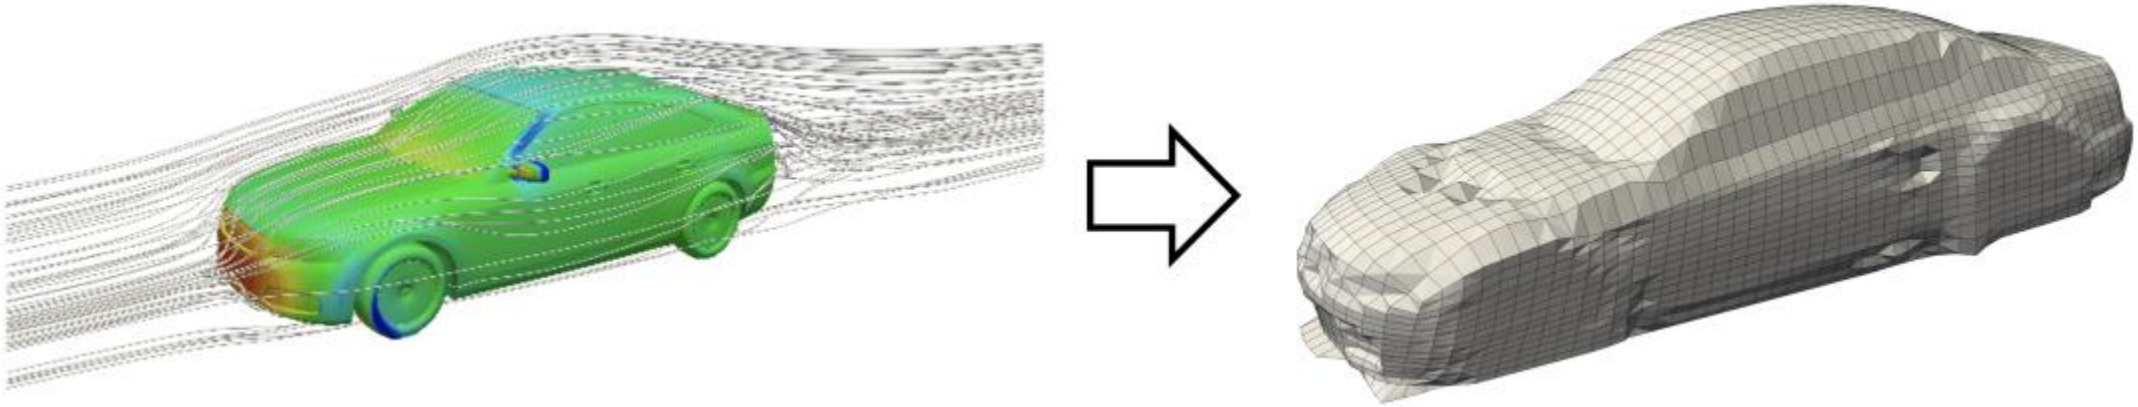


国产案例：Pangu-Weather 与 FengWu

- Pangu-Weather
  - 华为提出的三维地球特定先验天气模型
  - 采用三维地球特定先验建模全球中期天气预报，体现了把大气垂直结构和地球空间结构放进模型设计的思想
- FengWu：从多模态、多任务角度建模全球中期天气预报
- AI气象是国内AI4S具有国际影响力的方向之一，它连接了机器学习、大气科学、高性能计算和公共服务需求。
- AI气象预测可以快速地不通过高精度计算，直接推理：可能发生的情况、预测对应概率、预警可能出现的风险

案例4：PDE，AI4S对计算机提出的硬核问题

- 偏微分方程（PDE）描述许多连续系统：流体、热传导、电磁、结构力学……
- 传统数值方法通过网格离散和迭代求解来获得近似解
  - 有清晰的数学基础，精度和稳定性可以分析，是工程仿真的基础工具
  - 复杂工程场景可能非常慢：复杂几何结构、多物理场耦合和高分辨率三维模拟……
- AI目标：在可接受误差下加速求解、反演和优化，而非完全替代数值方法
  - 用神经算子学习一类方程的快速求解器
  - AI代理模型快速预测不同设计参数下的流场



小结：AI4S今天能做什么？难以做到什么？

- 蛋白与药物
  - 今天能做：预测许多蛋白结构，建模部分分子相互作用，辅助候选分子筛选。
  - 还不能做：完全解释细胞环境中的动态功能，直接证明药物安全有效。
- 材料
  - 今天能做：大规模筛选和生成候选材料，连接自动实验室形成闭环。
  - 还不能做：保证候选材料一定可合成、可量产、低成本、长期安全。
- 天气与PDE
  - 今天能做：快速生成全球中期预报，加速部分PDE和流体仿真。
  - 还不能做：在所有极端场景下完全可靠，替代物理观测和高精度验证。
- 社会科学
  - 今天能做：分析大规模文本和行为数据，辅助政策评估和社会仿真。
  - 还不能做：把模型输出当作真实人类意愿，绕过隐私、伦理和民主讨论。

AI4S现阶段重点并非让AI解决一切科学问题，是“AI让问题变得更可探索”

主要内容

- 20.1 大模型原生助手
- 20.2 大模型行业应用
- 20.3 AI4S：从文献助手到自主实验室
- 20.4 展望大模型：从规模到智能密度

展望：大模型规模和智能密度

趋势一：智能密度

- Scaling Law 的演进与范式转移
  - 单纯堆规模变味算力最优：行业形成共识——若缺乏足量高质量数据与有效训练目标，仅扩大参数规模会出现明显的边际收益递减。
  - 预训练Scaling转向智能密度与推理期Scaling：评估价值观从“参数/数据规模”转向“智能密度”（即单位算力与单位参数下的有效智能产出）；将多步推导、自我校验等复杂推理能力作为衡量智能密度的核心指标。
- 标志性突破：纯强化学习驱动推理涌现
  - 自主发现推理策略：DeepSeek-R1证实纯强化学习可在不依赖大量人工推理轨迹的前提下，自发涌现自我反思、验证与策略自适应行为。
  - 实现了从“模仿人类推理”向“自主探索与发现推理策略”的转变，大幅提升模型在高阶认知任务上的智能密度。

展望：大模型规模和智能密度

趋势二：主动智能体

- 模型交互与评测的变化
  - 目标驱动的自主闭环：交互入口从“被动问答生成”跨越为“目标驱动的自主任务执行”；构建“目标分解→规划生成→工具调用→执行监控→反思改写”的完整闭环。
  - 多智能体协同分工：通过多Agent协作模拟社会分工机制，支撑大型软件工程开发、城市交通调度等长链路复杂场景。
  - 评估要点变为动态的：评估维度从静态知识问答转向动态交互基准，AgentBench（多环境交互）与GAIA（真实助理任务/工具调用/多模态）等，改变了智能体能力评估体系。
- 关键落地场景：AI for Science（科学智能体）
  - 参与科研全流程：如前面讲到的，AI4S 从“文献泛读与综述生成”升级为“假设生成→实验设计→自动执行→数据解析→迭代优化”的科研闭环。
  - 与物理世界接轨（Self-driving Lab）：自主实验室成为连接“计算推理”与“物理实验”的关键基础设施；目前发展受限于实验成本、标准规范、可复现协议及数据规模。
- 系统风险
  - 随着智能体行动链条延长，长链决策目标偏离（Goal Drift）、工具误用与非预期策略行为等治理难题被显著放大。

展望：大模型规模和智能密度

趋势三：世界模型与具身智能

- 通用推理引擎：三元耦合架构
  - 面向2035年的发展规划，通用推理引擎形态不再是单纯扩大的单一LLM，将会演进为“世界模型+因果模型+规划器”的深度耦合架构。由世界模型负责环境动力学模拟，因果模型提供机制解释与反事实推断，规划器进行策略搜索与验证，支撑家庭机器人完成多日家务等长期规划任务。
- 具身智能载体与“系统 2”控制
  - VLA 端到端统一架构：以视觉-语言-动作（VLA）统一模型为关键载体，将多模态感知、指令理解与低层动作生成压缩至统一框架，覆盖导航、精准抓取与多步复杂操作。
  - “先思考再行动”的推理雏形：在动作输出前显式生成内部推理序列（如 Gemini Robotics 1.5），标志着“慢速、可验证”的系统 2 式推理开始融入具身控制链路。
- 空间智能突破与 AGI 演化路径
  - 跨越“语言会说、空间难做”的断裂：针对当前模型在几何关系、视角变换与三维一致性上的空间认知短板，演进方向为“原生 3D 多模态表示 + 世界模型滚动预测”
  - 持续学习与 AGI 终化形态：突破训练后知识冻结与灾难性遗忘，在开放物理环境中建立“经验获取-参数更新-评估循环”的自我演化机制，使具身智能成为通向 AGI 的关键路径。

	System 1	System 2
思考速度	快速	较慢
思考方式	直觉	下意识
难易程度	自然而然	需要动点脑筋
应用场景	日常问题	复杂问题
错误率	容易被骗（被自己的直觉被别人设的陷阱）	更加可靠

展望：大模型规模和智能密度

挑战一：安全与治理

- 风险管控（社会技术系统）
  - 管控边界延展：随着大模型接入外部系统与工具，安全核心应该兼顾“生成内容合规”与“行动决策可控”，覆盖权限分配、责任归属与故障止损。
  - 全生命周期风控：将“模型+部署环境”统筹为社会技术系统，把风险防控贯穿研发、训练、上线及运行全过程。
- 治理合规落地（完善法律约束）
  - 运行期监控约束：欧盟《人工智能法案》分阶段生效，将运行期监控与可追溯证据链设为产品可用性的硬性指标。
  - 国内AI相关法律法规也在以较快的速度不断完善中。
- 智能体防护与可信溯源
  - 新型链路风险：重点防范提示注入与 Agent潜伏后门等持久化风险。
  - 纵深防御体系：部署“权限最小化 + 运行期监控”，结合文本水印与 加密凭证等技术构建可信溯源链。
  - 对齐范式升级：依赖显式规范推理与标准化红队实证，打造可验证的系统科学防线。



展望：大模型规模和智能密度

挑战二：算力鸿沟与跨学科融合

- 算力极化与学术审计困难
  - 资源过度集中：全球智算资源极化严重（美国托管5,427座数据中心，超过其他国家总和10倍以上），工业界垄断试错优势，学术界在算力密集型前沿研究中面临边缘化风险。
  - 可复现性与审计失衡：算力壁垒削弱了第三方的独立安全审计、红队测试与实验复现能力，建立普惠性公共算力与开放科学机制仍存在制度与工程瓶颈。
- 低算力下“精度-效率”的工程博弈
  - 计算最优理论有待探索：受限算力下，如何精准匹配参数规模、数据 Token 与训练目标以达成“计算最优配比”，仍缺乏统一的理论指导。
  - 降门槛技术的性能折损：LoRA/QLoRA、FlashAttention、ZeRO及MoE等技术虽降低了训练与显存门槛，但低比特量化与稀疏激活带来的表达力损耗、训练不稳定性依然存疑，且缺乏统一的“绿色 AI”能效评估标准。
- 科研智能体可靠性与跨学科认知壁垒
  - 科研闭环的幻觉隐患：科研智能体接管“假设生成-实验规划-执行验证”流程时，长链条下的幻觉累积与错误传播缺乏有效纠错机制，且受制于高保真仿真环境与标准化协议的匮乏。
  - 跨学科翻译的隐性风险：把大模型作为学科沟通桥梁时，面临领域隐性知识难以符号化、非专业人员误用量化模型等风险，亟待解决科学严谨性与工具平权之间的张力。

结语：未来的语言模型

- 通往AGI所需的关键能力
  - 支撑因果推理（可解释）：从相关性学习转向干预与反事实推断，提升高风险决策的可解释性与逻辑推导能力。
  - 世界模型（可模拟）：构建环境动力学模型，在想象空间内完成多步滚动预测与策略规划。
  - 具身空间智能（可落地）：结合原生三维空间理解与物理交互，解决“能说，也要能操作”的问题。
  - 安全与治理（可托付）：将安全规范与运行期监控融入工程实践，确保系统行为可预测、可审计、可追责。
- 单一的语言模型一再放大规模并不足够通向AGI，因果、世界模型、具身与治理能力的协同集成才是AGI之路。
- 把语言模型落地物理世界，不仅取决于模型能力上限的单点突破，更取决于可靠性、可控性与治理能力的同步跟进。